




Vorlesung Wahrscheinlichkeits- theorie und Statistik

Sommersemester 2026

Vorlesung von Prof. Gentz

Vorlesungsnotizen und Aufarbeitung

Liliana Sanfilippo

Inhaltsverzeichnis

I	Skript	1
1	Modellieren zufälliger Ereignisse	5
1.1	Wahrscheinlichkeitsräume	5
1.1.1	Elementarereignisse	5
1.1.2	Ereignisräume	6
1.1.3	Ereignisse	7
1.1.4	Zähldichten und Wahrscheinlichkeitsmaße	8
1.1.5	Wahrscheinlichkeitsräume	9
1.1.6	Modellierung	10
1.2	Gleichverteilung auf einer endlichen Menge	12
1.3	Wahrscheinlichkeitsräume, deren Ereignisraum nicht abzählbar ist	14
1.3.1	Eindimensionale Dichten	15
1.3.2	Wahrscheinlichkeitsräume mit Dichten	17
1.3.3	Uniforme Verteilung	20
1.3.4	Exponentialverteilung	22
2	Rechnen mit Wahrscheinlichkeiten	23
2.1	Mengenoperationen und Ereignisse	23
2.1.1	Disjunktheit	24
2.2	Erste Rechenregeln für Wahrscheinlichkeiten	27
2.2.1	Das Ein- und Ausschlußprinzip	29
3	Bedingte Wahrscheinlichkeiten	31
4	Zufallsvariablen und ihre Verteilung	39
4.1	Die Verteilung einer Zufallsvariablen	39
4.2	Notationen	41
4.3	Zufallsvariablen mit abzählbarem Bildbereich	42
4.4	Zufallsvariablen mit Dichte	43
4.5	Mehrdimensionale Zufallsvariablen und ihre gemein- same Verteilung: Abzählbare Bildbereiche	43
4.6	Mehrdimensionale Zufallsvariablen und ihre gemein- same Verteilung: Dichten	44
5	Unabhängigkeit und Bernoulli-Experimente	45
5.1	Stochastische Unabhängigkeit von Ereignissen	45
5.2	Unabhängige Nacheinanderausführung von Zufallsexperimenten	46
5.3	Die Binomialverteilung	47

6	Unabhängigkeiten von Zufallsvariable (ZV)	49
6.1	Unabhängigkeit für Zufallsvariable mit abzählbarem Bildbereich	51
6.1.1	Poisson-Verteilte ZV	53
6.2	ZV mit Dichten	54
6.3	Widerlegen von Unabhängigkeiten	55
7	Erwartungswert und Varianz von Zufallsvariablen	61
8	Varianz und Covarianz	79
8.1	Vorlesung 8	79
9	Grenzwertsätze	81
9.0.1	Beispielaufgabe Laubfrosch	96
10	Statistik	99
10.1	Daten, Häufigkeitsverteilungen und ihre Darstellung in der beschreibenden Statistik	99
10.1.1	Daten und Häufigkeitsverteilungen	99
10.1.2	Graphische Darstellungen eindimensionaler Daten	102
10.2	Empirische Häufigkeitsverteilungen und ihre Lagemaße	104
10.3	Empirische Häufigkeitsverteilungen und ihre Streumaße	108
11	Schließende Statistik: Testtheorie I	113
II	Tutorien	121
12	Tutorium 20.04.2026	123
12.1	PÜ 1.1.4 - Faire Münze 3-mal Werfen	123
12.2	PÜ 1.1.5 - Faire Münze n-mal Werfen	123
12.3	PÜ 1.1.6 - Mensch ärgere dich nicht	123
13	Tutorium 27.04.2026	125
13.1	PÜ 1.2.4	125
14	Tutorium 04.05.2026 (Zusatztutorial)	127
14.1	PÜ 1.0.1	127
14.2	PÜ 1.0.2.	128
14.3	PÜ 1.0.3.	129
15	Tutorium 11.05.2026	131
15.1	PÜ 1.3.4.	131
16	Tutorium 18.05.2026	133
16.1	PÜ 1.4.4.	133
16.2	PÜ 1.4.5.	133
17	Tutorium 26.05.2026	135
17.1	PÜ 1.5.4.	135
17.2	PÜ 1.5.5.	135

18 Tutorium 01.06.2026	137
18.1 PÜ 1.6.4.	137
18.2 Besprechung ÜB 1.5.1	139
18.3 Besprechung ÜB 1.5.2	140
18.4 Besprechung ÜB 1.5.3	141
18.5 PÜ 2.1.4	141
18.6 PÜ 2.1.5	141
18.7 PÜ 2.1.6	141
19 Tutorium 15.06.2026	143
19.1 PÜ 2.2.4.	143
19.2 PÜ 2.2.5	144
19.3 PÜ 2.2.6	146
20 Tutorium 22.06.2026	147
20.1 PÜ 2.3.4	147
20.2 PÜ 2.3.5	148
20.3 PÜ 2.3.6	148
21 Tutorium 29.06.2026	149
21.1 PÜ 2.4.4	149
21.2 PÜ 2.4.5	149
22 Tutorium 06.07.2026	151
22.1 PÜ 2.5.4	151
22.2 PÜ 2.5.5	151
23 Tutorium 13.07.2026	153
23.1 PÜ 2.6.4	153
23.2 PÜ 2.6.5	155
23.3 Besprechung ÜB 2.5.1	156
III Anhang	157
23.4 Übersichten	159
23.5 Referenzen	159
Glossary	159
Index	163

Teil I

Skript

Legende

Skript	normale schwarze Schrift
Meine Anmerkungen und Notizen	Lila Schrift
Schriftliche Anmerkungen der Professorin	Orangene Schrift

KAPITEL 1

Modellieren zufälliger Ereignisse

Vorlesung 11.04.2025 (V01 2025), ergänzt durch Skript (Skript 2026)

1.1 | Wahrscheinlichkeitsräume

Kommentar 1.1 Fehlkalkulationen durch unzureichende Modelle bzw. fehlende Parameter werden oft als Zufall gesehen. Wir versuchen Modelle so zu wählen, dass sie möglichst einfach sind




Abbildung 1.1

Lernziele

- modellieren einfacher Zufallsexperimente
- **Wahrscheinlichkeitsraum** kennen und verwenden
- **Gleichverteilung** kennen und erkennen

1.1.1 | Elementarereignisse

Definition 1.1 **Elementarereignis** ω (2025)

Möglicher Ausgang eines Zufallsexperiments.

Es ist üblich, für Elementarereignisse den kleinen griechischen Buchstaben ω (omega) zu verwenden. Davon weichen wir in konkreten Situationen manchmal ab. So schreiben wir zum Beispiel auch k , wenn das Elementarereignis eine natürliche Zahl ist, oder x , wenn es eine reelle Zahl ist.

Beispiel 1.1 Zu Definition 1.1 (2025)

- Würfeln: $\omega = 3$ (3 gewürfelt)
- Zeitmessung: $\omega = 100$ (Sec)

Karteikarte 1.1 Was ist ein Elementarereignis?

Ein möglicher Ausgang eines Zufallsexperiments. Notation: kleiner griechischer Buchstabe ω (omega). Je nach Kontext auch andere Symbole, z.B. k für natürliche Zahlen oder x für reelle Zahlen..

1.1.2 | Ereignisräume**Definition 1.2** Ereignisraum Ω (2025)

Die Menge aller Elementarereignisse $\Omega \neq \emptyset$ ist die Menge aller möglichen Ausgänge eines Zufallsexperiments. Ein Ereignisraum ist also zunächst einmal einfach eine nichtleere Menge.

Für einen Ereignisraum verwenden immer den großen griechischen Buchstaben Ω (Omega). Wenn wir mehrere Ereignisräume benötigen, so schreiben wir $\Omega, \tilde{\Omega}, \Omega_1, \Omega_2, \dots$ usw.

Beispiel 1.2 Zu Definition ?? (2025)

- **Würfeln:** $\Omega = \{1, \dots, 6\}$ oder $\Omega = \{wuerfelsymbole\}$

Die Modellierung durch Würfelsymbole zeigt, daß es beim Modellieren wichtig ist anzugeben, welche Interpretation unsere Kodierung der Elementarereignisse haben soll. Man soll daher stets einen Satz der Art

“Dabei bedeutet $\omega = wuerfelsymbol1$, dass der Würfel eine Eins zeigt”

schreiben, wenn man einen Ereignisraum angibt.

- **Zeitmessung:** $\Omega = [0, \infty)$ ist grundsätzlich eine sinnvolle Wahl, wenn wir das Messen einer zufälligen Zeit modellieren wollen. Sofern Zusatzinformationen vorliegen, können wir natürlich ein kleineres Intervall wählen.

Kommentar 1.2 Siehe die Klammersymbolnotation, die bedeutet die Null ist drin, aber infinity nicht. ∞ ist keine normale Zahl, sondern ein Symbol für Unbeschränktheit. Deshalb schreibt man praktisch immer die runde Klammer auf der Seite.

Häufig interessiert uns gar nicht der exakte Ausgang eines Zufallsexperiments, sondern nur, ob der Ausgang eine bestimmte Eigenschaft hat: Haben wir eine gerade Zahl gewürfelt? Ist die gemessene Zeit kürzer als eine Minute? Wir fassen also jene Elementarereignisse zusammen, die die gewünschte Eigenschaft haben. Dies führt zur folgenden Definition.

Karteikarte 1.2 Was ist ein Ereignisraum Ω ?

Die Menge aller Elementarereignisse, also aller möglichen Ausgänge eines Zufallsexperiments. Muss nichtleer sein ($\Omega \neq \emptyset$). Notation: großer griechischer Buchstabe Ω (Omega). Bei mehreren Ereignisräumen: $\Omega, \tilde{\Omega}, \Omega_1, \Omega_2, \dots$

Karteikarte 1.3 Wie wählt man den Ereignisraum beim Würfeln bzw. bei der Zeitmessung?

Würfeln: $\Omega = \{1, \dots, 6\}$ (oder Würfelsymbole). Zeitmessung: $\Omega = [0, \infty)$ als sinnvolle Grundwahl, kann bei Zusatzinformationen auf ein kleineres Intervall eingeschränkt werden. Wichtig: Bei Angabe von Ω stets die Interpretation der Elementarereignisse angeben, z.B. “Dabei bedeutet $\omega = 1$, dass der Würfel eine Eins zeigt”.

1.1.3 | Ereignisse

Definition 1.3 Ereignis A (2025)

(Messbare) Teilmenge des Ereignisraums $A \subseteq \Omega$ ($A = \emptyset, A = \Omega$) sind zulässig

Sprechweise: $\omega \in A$ bedeutet “ A ist eingetroffen”

Im Fall, dass der Ereignisraum $\Omega \subseteq \mathbb{R}^n$ weder eine endliche noch eine abzählbar unendliche Menge ist, beschränken wir uns auf Ereignisse, die Intervalle oder bekannte geometrische Figuren wie Dreieck, Rechteck oder Kugel sind. Auch abzählbare Schnitte oder Vereinigungen solcher Objekte sind zulässig, sowie deren abzählbare Schnitte oder Vereinigungen. Und so weiter. Diese Einschränkung erlaubt es uns, Fragen der mathematischen Maß- und Integrationstheorie zu vermeiden.

Bemerkung 1.1 Zu Definition ?? (2026)

- Ein Ereignis $A \subseteq \Omega$ ist also ein (messbares) Element der Potenzmenge $\mathcal{P}(\Omega)$ von Ω , das heißt, $A \in \mathcal{P}(\Omega)$.
- Ist $\omega \in \Omega$ ein Elementarereignis, so ist die einelementige Menge $\{\omega\} \in \mathcal{P}(\Omega)$ ein Ereignis in Ω .

Beispiel 1.3 (2025) Zu Definition 1.3

- **Würfeln** einer geraden Zahl:

$$A = \{2, 4, 6\}, \quad \omega = 4 \Rightarrow \omega \in A$$

Wir sagen: “gerade Zahl gewürfelt”

- **Zeitmessung:** $A = [100, 200] \subset \Omega = [0, \infty)$

Karteikarte 1.4 Was ist ein Ereignis A ?

Eine (messbare) Teilmenge des Ereignisraums, $A \subseteq \Omega$. Auch $A = \emptyset$ und $A = \Omega$ sind zulässig. Sprechweise: $\omega \in A$ bedeutet “ A ist eingetroffen”. Formal ist A ein Element der Potenzmenge $\mathcal{P}(\Omega)$, also $A \in \mathcal{P}(\Omega)$.

Karteikarte 1.5 Ist ein Elementarereignis auch ein Ereignis?

Ja. Ist $\omega \in \Omega$ ein Elementarereignis, so ist die einelementige Menge $\{\omega\} \in \mathcal{P}(\Omega)$ ein Ereignis in Ω .

Kommentar 1.3 Beim geeigneten Ω können Modelle sich bereits unterscheiden. Bspw. Münzwurf: Man kann “k”, “z” nehmen oder “Kopf”, “Zahl”. Das sind verschiedenen Ω , aber beide wären passend.

- Finden des geeigneten Ω
- Ereignisse müssen **Wahrscheinlichkeiten (WS)** zugeordnet bekommen

1. Möglichkeit: WS für Ω abzählbar

Kommentar 1.4 Wenn sie abzählbar sagt, meint sie sowohl endlich als auch abzählbar unendlich.

Karteikarte 1.6 Welche Ereignisse betrachtet man, wenn $\Omega \subseteq \mathbb{R}^n$ weder endlich noch abzählbar unendlich ist?

Man beschränkt sich auf Ereignisse, die Intervalle oder bekannte geometrische Figuren sind (Dreieck, Rechteck, Kugel), sowie abzählbare Schnitte oder Vereinigungen solcher Objekte. Dies vermeidet Probleme der Maß- und Integrationstheorie..

1.1.4 | Zähldichten und Wahrscheinlichkeitsmaße

Definition 1.4 Zähldichte / μ (2025)

Sei $\Omega \neq \emptyset$ eine abzählbare Menge.

1. Eine Abbildung $\mu : \Omega \rightarrow [0, 1]$ heißt mit

$$\underbrace{\sum_{\omega \in \Omega} \mu(\omega)}_{\text{Normierung}} = 1$$

Zähldichte / Wahrscheinlichkeitsfunktion auf Ω .

2. Die WS $\mathbb{P}(A)$ einer Ereignisses $A \subseteq \Omega$ ist bei gegebener Wahrscheinlichkeitsfunktion μ definiert durch

$$\mathbb{P}(A) := \sum_{\omega \in A} \mu(\omega)$$

$\mathbb{P}$ heißt Wahrscheinlichkeitsmaß und liegt immer zwischen Null und 1

Kommentar 1.5 Zu Definition 1.4 (i): Die Reihe (Normierung) muss 1 sein und konvergieren.

Wenn man max abzählbar hat, dann sind die Wahrscheinlichkeiten einfach teile der Summe (Normierung) und daher ist das einfach.

Kommentar 1.6 TODO: Was hat die Potenzmenge von Omega damit zu tun?

Bemerkung 1.2 (2025) Zu Definition 1.4 (ii)

Konvention: $\mathbb{P}(\emptyset) = 0$

Bemerkung 1.3 Zu Definition 1.4 (2025)

$$0 \leq \mathbb{P} \leq 1, \quad \forall A \subseteq \Omega \quad \underbrace{(\forall A \in \mathcal{P}(\Omega))}_{\mathcal{P}(\Omega) \text{ Potenzmenge von } \Omega}$$

$\mathbb{P}$ ist eine Abb.

$$\mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1] \quad \text{mit } \mathbb{P}(\emptyset) = 0, \quad \mathbb{P}(\Omega) = 1$$

Lemma 1.1 Eigenschaften des Wahrscheinlichkeitsmaßes für abzählbare Ereignisräume (2026)

Sei $\Omega \neq \emptyset$ eine abzählbare Menge und $\mathbb{P}$ ein Wahrscheinlichkeitsmaß auf Ω . Dann gelten:

- $0 \leq \mathbb{P}(A) \leq 1$ für alle $A \subseteq \mathcal{P}(\Omega)$
- $\mathbb{P}(\emptyset) = 0$
- $\mathbb{P}(\Omega) = 1$

Beweis.

- Untere Schranke: Da $\mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega)$ gilt und alle Summanden nichtnegativ sind, folgt $\mathbb{P}(A) \geq 0$
- Obere Schranke: Aus

$$\mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega) \leq \sum_{\omega \in \Omega} \mu(\omega) = 1$$

folgt $\mathbb{P}(A) \leq 1$. Dabei haben wir in der Abschätzung erneut verwendet, daß alle Summanden nichtnegativ sind.

■ $\mathbb{P}(\emptyset) = 0$ gilt gemäß Konvention aus 1.2.

■ $\mathbb{P}(\Omega) = \sum_{\omega \in \Omega} \mu(\omega) = 1$ folgt direkt aus der Normierung der Wahrscheinlichkeitsfunktion.

Karteikarte 1.7 Was ist eine Zähldichte / Wahrscheinlichkeitsfunktion μ ?

Sei $\Omega \neq \emptyset$ abzählbar. Eine Abbildung $\mu : \Omega \rightarrow [0, 1]$ mit $\sum_{\omega \in \Omega} \mu(\omega) = 1$ (Normierung) heißt Zähldichte bzw. Wahrscheinlichkeitsfunktion auf Ω .

Karteikarte 1.8 Wie berechnet man aus einer Zähldichte μ die Wahrscheinlichkeit $P(A)$ eines Ereignisses?

$P(A) := \sum_{\omega \in A} \mu(\omega)$. P heißt Wahrscheinlichkeitsmaß und liegt immer zwischen 0 und 1..

Karteikarte 1.9 Welchen Wert hat $P(\emptyset)$?

Konvention: $P(\emptyset) = 0$.

Karteikarte 1.10 Welche drei Grundeigenschaften hat ein Wahrscheinlichkeitsmaß P auf abzählbarem Ω ?

(1) $0 \leq P(A) \leq 1$ für alle $A \in \mathcal{P}(\Omega)$. (2) $P(\emptyset) = 0$. (3) $P(\Omega) = 1$. P ist eine Abbildung $P : \mathcal{P}(\Omega) \rightarrow [0, 1]$.

Karteikarte 1.11 Wie zeigt man $0 \leq P(A) \leq 1$?

Untere Schranke: $P(A) = \sum_{\omega \in A} \mu(\omega) \geq 0$, da alle Summanden nichtnegativ sind. Obere Schranke: $P(A) = \sum_{\omega \in A} \mu(\omega) \leq \sum_{\omega \in \Omega} \mu(\omega) = 1$, ebenfalls weil alle Summanden nichtnegativ sind.

Karteikarte 1.12 Was ist der Unterschied zwischen μ und P bezüglich ihres Definitionsbereichs?

μ hat als Argument ein einzelnes Elementarereignis ω (also $\mu(\omega)$), während P auf der Potenzmenge $\mathcal{P}(\Omega)$ definiert ist und daher das einelementige Ereignis $\{\omega\}$ als Argument hat (also $P(\{\omega\})$).

1.1.5 | Wahrscheinlichkeitsräume

Definition 1.5 Wahrscheinlichkeitsraum (2025)

$(\underbrace{\Omega, \mathbb{P}}_{(\Omega, \mu)})$ heißt Wahrscheinlichkeitsraum.

Bemerkung 1.4 Zu Definition 1.5 (2025)

Für Ω abzählbar: μ legt $\mathbb{P}$ eindeutig und umgekehrt!

$$\mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega) \quad \forall A \in \mathcal{P}(\Omega)$$

$$\mu(\omega) = \mathbb{P}(\underbrace{\{\omega\}}_{\text{1-elementige Menge}}) \quad \forall \omega \in \Omega$$

Länger aus dem Skript: (2026) Da es eine ein-eindeutige Zuordnung zwischen der Wahrscheinlichkeitsfunktion μ und dem Wahrscheinlichkeitsmaß $\mathbb{P}$ gibt, bezeichnen wir auch das Paar $(\Omega, \mathbb{P})$ als Wahrscheinlichkeitsraum. Die Zuordnung von μ zu $\mathbb{P}$ ist direkt durch die Definition von $\mathbb{P}$ in Definition 1.4 gegeben. Für eine gegebene Wahrscheinlichkeitsfunktion erhalten wir so ein eindeutig bestimmtes Wahrscheinlichkeitsmaß. Ist ein Wahrscheinlichkeitsmaß $\mathbb{P}$ gegeben, so ergibt sich die zugehörige Wahrscheinlichkeitsfunktion μ sofort aus den Wahrscheinlichkeiten der Elementarereignisse:

$$\mu(\omega) = \mathbb{P}(\{\omega\}), \quad \forall \omega \in \Omega$$

Beachten Sie hier, dass die Wahrscheinlichkeitsfunktion μ als Argument ein Elementarereignis, also ein einzelnes $\omega \in \Omega$ hat, während das Wahrscheinlichkeitsmaß $\mathbb{P}$ auf der Potenzmenge $\mathcal{P}(\Omega)$ von Ω definiert ist und daher das einelementige Ereignis $\{\omega\}$ als Argument hat.

Karteikarte 1.13 Was ist ein Wahrscheinlichkeitsraum?

Das Paar (Ω, μ) heißt Wahrscheinlichkeitsraum. Es besteht eine ein-eindeutige Zuordnung zwischen der Wahrscheinlichkeitsfunktion μ und dem Wahrscheinlichkeitsmaß P : $P(A) = \sum_{\omega \in A} \mu(\omega)$ und umgekehrt $\mu(\omega) = P(\{\omega\})$.

1.1.6 | Modellierung**Beispiel 1.4 Einmal Würfeln (2025)**

$\Omega = \{1, \dots, 6\}$, $A = \{6\}$ (sechs gewürfel), $B = \{2, 4, 6\}$ (gerade Zahl).

Dabei beudeute $\omega = k$, dass der Würfel k Augen hat. Wie wählen wir μ ?

1. fairer Würfel:

$$\mu(k) = \text{const} \quad \forall k \in \Omega$$

$$\mu(k) := \frac{1}{6} \left(\text{weil } \sum_{k=1}^6 \mu(k) \stackrel{!}{=} 1 \right)$$

$$\mathbb{P}(A) = \mu(a) = \frac{1}{6}, \quad \mathbb{P}(B) = \sum_{k \in \{2,4,6\}} \mu(k) = \frac{1}{6} \cdot \#B = \frac{3}{6} = \frac{1}{2}$$

2. gezinkter Würfel: Seien

$$\mu(1) = \frac{1}{2}, \mu(2) = \mu(3) = \mu(4) = \mu(5) = \frac{1}{12}, \mu(6) = \frac{1}{6}$$

$$\text{Probe: } \sum_{k=1}^6 \mu(k) \stackrel{!}{=} 1$$

Kommentar 1.7 Zu Beispiel ??: In Hausaufgaben zu jedem Omega hinzuschreiben, was es bedeutet! “Dabei beudeute $\omega = k$, dass ...”

Kommentar 1.8 Zu Beispiel ?? (1.): Ein ebener Würfel ist ein “fairer Würfel”, weil alle Seiten gleich Wahrscheinlich sind.

Kommentar 1.9 Zu Beispiel ?? (2.): In der Klausur wenn bei einer Probe ein Fehler herauskommt, gerne hinschreiben man hat gemerkt da ist ein Fehler und wo der gewesen sein muss, besser als nichts hinschreiben.

Wie wählen wir Ω und μ (bzw. $\mathbb{P}$)?

■ Frage der Erfahrung

■ wichtiges Thema und Lernziel dieses Semester

Beispiel 1.5 Zweimal würfeln mit fairem Würfel - Augensumme (2025)

1. **Ansatz:** $\Omega_1 = \{1, \dots, 6\}^2 = \{(i, j) : i, j \in \{1, \dots, 6\}\}$

Für $\omega = (i, j) \in \Omega_1$ bedeutet i die Augenzahl des ersten Würfels und j jene des zweiten Würfels.

Aus Symmetriegründen wählen wir $\mu_1(\omega)$ konstant, also

$$\mu_1(\omega) = \frac{1}{|\Omega_1|} = \frac{1}{36} \quad \forall \omega \in \Omega_1$$

$A_k^{(1)} \leq \Omega_1$: Augensumme ist k

Für $k \leq 1$ oder $k \geq 13$:

$$A_k^{(1)} = \emptyset \Rightarrow \mathbb{P}_1(A_k^{(1)}) = 0$$

Für $k = \{2, \dots, 12\}$:

$$\mathbb{P}_1(A_2^{(1)}) = \mathbb{P}_1(\{(1, 1)\}) = \mu_1((1, 1)) = \frac{1}{36}$$

$$\mathbb{P}_1(A_3^{(1)}) = \mathbb{P}_1(\{(1, 2), (2, 1)\}) = \mu_1((1, 2)) + \mu_1((2, 1)) = \frac{2}{36}$$

usw...Es wird immer eines mehr

k	2	3	4	5	6	7	8	9	10	11	12
$\mathbb{P}_1(A_k^{(1)})$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{5}{36}$	$\frac{6}{36}$	$\frac{5}{36}$	$\frac{4}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{1}{36}$

Probe:

$$\sum_{k=2}^{12} \mathbb{P}_1(A_k^{(1)}) = 1$$

2. **Ansatz:** "Wir beachten die Reihenfolge beim Würfeln nicht"

$$\Omega_2 = \{(i, j) \in \Omega_1 : i \leq j\}$$

Dabei bedeute $\omega = (i, j)$, dass sowohl i als auch j gewürfelt wurden.

Finde μ_2 !

(1) $i \leq j$: $1 \times i$ und $1 \times j$ gewürfelt

$$\mu_2((i, j)) = \mu_1((i, j)) + \mu_1((j, i)) = \frac{2}{36}$$

(2) $i = j$: $2 \times i$ gewürfelt

$$\mu_2((i, i)) = \frac{1}{36}$$

Probe machen!

$$A_k^{(2)} = \{(i, j) \in \Omega_2 : i + j = k\}$$

Exemplische Ausrechnung:

$$\mathbb{P}_2(A_4^{(2)}) = \mu_2((1, 3)) + \mu_2((2, 2)) = \frac{2}{36} + \frac{1}{36} = \frac{3}{36}$$

3. **Ansatz:** $\Omega_3 = \{2, 3, \dots, 12\}$

Finde μ_3 ? $\rightarrow$ Verwende Tabelle aus dem 1. Ansatz, denn $\mu_3(k) = \mathbb{P}(A_k^{(1)})$:

k	2	3	4	5	6	7	8	9	10	11	12
$\mu_3(k)$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{5}{36}$	$\frac{6}{36}$	$\frac{5}{36}$	$\frac{4}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{1}{36}$

Kommentar 1.10 Man hat beim Modellieren immer die Wahl. Und man muss aufpassen wie man es macht.

Beispiel 1.6 Reißzwecke “würfeln” - Symmetrieüberlegungen helfen nicht (2025)

$\Omega = \{R, S\}$ (R auf Kopf, S auf Seite)

Definition: $\mu(S) > \mu(R)$

10.000 Würfe; 4213 R

Möchte $\mu(R) \approx \frac{4213}{10.000} = 0,4213$ (relative Häufigkeit)

-> Gesetz der gr. Zahlen

-> Statistik

Kommentar 1.11 Take-Home message: Wann immer möglich, modelliere so, dass $\mu(\omega) = \text{const} \forall \omega \in \Omega$ (erfordert Symmetrieargumente)

Karteikarte 1.14 Was ist die Take-Home-Message beim Modellieren von μ ?

Wann immer möglich, modelliere so, dass $\mu(\omega) = \text{const} \forall \omega \in \Omega$ gilt (Gleichverteilung). Dies erfordert Symmetrieargumente..

1.2 | Gleichverteilung auf einer endlichen Menge

(2025)

Definition 1.6 Gleichverteilung (2025)

Sei $\Omega \neq \emptyset$ eine endl. Menge, d.h. $0 < \#\Omega < \infty$. Gilt $\mu(\omega) = \mu(\tilde{\omega}) \quad \forall \omega, \tilde{\omega} \in \Omega$ d.h. die **Wahrscheinlichkeitsfunktion** μ ist konstant, so heißen die wfkt μ und das zugehörige Maß P die Gleichverteilung auf Ω

Lemma 1.2 Rechnen mit der Gleichverteilung (2026)

Sei μ die Gleichverteilung auf Ω . Dann gelten:

$$(a) \mu(\omega) = \frac{1}{\#\Omega} \quad \forall \omega \in \Omega$$

$$(b) \mathbb{P}(A) = \frac{\#A}{\#\Omega} \quad \forall A \in \mathcal{P}(\Omega) \quad (\forall A \subseteq \Omega)$$

Beweis.

$$(a) 1 = \sum_{\omega \in \Omega} \mu(\omega) \stackrel{a)}{=} c \cdot \#\Omega \Rightarrow c = \frac{1}{\#\Omega}$$

$$(b) \mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega) \stackrel{a)}{=} \frac{\#A}{\#\Omega}$$

$\mathbb{P}(A)$ ist die Anzahl der günstigen Ausgänge, geteilt durch die Anzahl aller möglichen Ausgänge

^aWir dürfen annehmen, dass ein $c \in [0, 1]$ existiert mit $\mu(\omega) = c \quad \forall \omega \in \Omega$

Bemerkung 1.5 (2025) Im Fall der Gleichverteilung reduziert sich das Berechnen von **WS** auf Abzählprobleme.

Bemerkung 1.6 Keine Gleichverteilung, wenn der Ereignisraum nicht endlich ist (Skript 26 - Bemerkung 1.18)

Warum müssen wir voraussetzen, dass $\#\Omega < \infty$? Nehmen wir an, es gäbe eine Gleichverteilung μ auf einer abzählbar unendlichen Menge Ω . Wir können der Einfachheit halber annehmen, dass Ω die Menge der natürlichen Zahlen $\mathbb{N}$ ist. Dann gibt es also ein $c \in [0, 1]$ mit

$$1 = \sum_{k=1}^{\infty} \mu(k) = c \cdot \#\mathbb{N}$$

Nun gibt es zwei Fälle. Entweder, $c = 0$. Dann erhalten wir den Widerspruch $1 = 0$. Andernfalls, wenn $c > 0$ gilt, erhalten wir ebenfalls einen Widerspruch, nämlich $1 = \infty$. Folglich kann es auf einer nicht endlichen Menge keine Gleichverteilung geben

Beispiel 1.7 Gleichverteilung

- $1 \times$ Werfen einer fairen Münze: $\Omega = \{K, Z\}, \mu(\omega) = \frac{1}{2} \forall \omega \in \Omega$
- $1 \times$ Würfeln oder $2 \times$ Würfeln mit fairem Würfel

Beispiel 1.8 KEINE Gleichverteilung (2026)

- Augensumme beim wiederholten Würfeln
- Werfen einer Reißzwecke

Karteikarte 1.15 Wann heißt μ Gleichverteilung auf Ω ?

Sei $\Omega \neq \emptyset$ endlich, d.h. $0 < \#\Omega < \infty$. Gilt $\mu(\omega) = \mu(\tilde{\omega})$ für alle $\omega, \tilde{\omega} \in \Omega$ (d.h. μ ist konstant), so heißen μ und das zugehörige P die Gleichverteilung auf Ω .

Karteikarte 1.16 Wie berechnet man $\mu(\omega)$ und $P(A)$ bei Gleichverteilung?

(a) $\mu(\omega) = \frac{1}{\#\Omega}$ für alle $\omega \in \Omega$. (b) $P(A) = \frac{\#A}{\#\Omega}$ für alle $A \subseteq \Omega$. Anschaulich: Anzahl der günstigen Ausgänge geteilt durch Anzahl aller möglichen Ausgänge..

Karteikarte 1.17 Wie beweist man $\mu(\omega) = \frac{1}{\#\Omega}$ bei Gleichverteilung?

Da μ konstant ist, existiert ein $c \in [0, 1]$ mit $\mu(\omega) = c$ für alle ω . Aus der Normierung folgt $1 = \sum_{\omega \in \Omega} \mu(\omega) = c \cdot \#\Omega$, also $c = \frac{1}{\#\Omega}$.

Karteikarte 1.18 Worauf reduziert sich das Berechnen von Wahrscheinlichkeiten bei Gleichverteilung?

Auf reine Abzählprobleme (Kombinatorik), da $P(A) = \frac{\#A}{\#\Omega}$ gilt..

Karteikarte 1.19 Warum kann es keine Gleichverteilung auf einer abzählbar unendlichen Menge geben?

Annahme: Gleichverteilung μ auf $\Omega = \mathbb{N}$ mit Wert c . Aus $1 = \sum_{k=1}^{\infty} \mu(k) = c \cdot \#\mathbb{N}$ folgt ein Widerspruch: Für $c = 0$ ergibt sich $1 = 0$, für $c > 0$ ergibt sich $1 = \infty$. Beide Fälle sind unmöglich, also existiert keine Gleichverteilung auf unendlichen Mengen. Deshalb ist in der Definition $\#\Omega < \infty$ vorausgesetzt..

Vorlesung 25.04.2025 (V02 2025), ergänzt mit dem Skript aus 2026

Lernziele

- Unterschied zwischen disjunkten und paarweise disjunkten Mengen
- Rechenregeln für Wahrscheinlichkeiten
 - Komplementär Wahrscheinlichkeit
 - Ein- und Ausschlussprinzip
 - Spezialfall paarweise disjunkter Mengen

1.3 | Wahrscheinlichkeitsräume, deren Ereignisraum nicht abzählbar ist

Beispiel 1.9 Wahrscheinlichkeitsraum (2025)

Stoppen einer Zeit bis zu einer Stunde in ms.

$$\begin{aligned} \Omega &= \{0, 1, \dots, 360000\} && \text{(Zeit in ms)} \\ \mu(\omega) &:= \frac{1}{\#\Omega} \quad \forall \omega \in \Omega && \text{(Gleichverteilung)} \\ \mathbb{P}(A) &= \frac{\#A}{\#\Omega} \\ A &= \{600000, \dots, 9000000\} && \text{Zeit liegt zw. 10 und 15 Minuten} \\ \mathbb{P}(A) &= \frac{300001}{3600001} \approx \frac{300000}{3600000} = \frac{1}{12} \end{aligned}$$

Wir wollen kontinuierlich modellieren:

$$\begin{aligned}\tilde{\Omega} &= [0, 60] && \text{(in Minuten)} \\ \text{bzw. } \tilde{\Omega} &= [0, 360000] && \text{(in ms)} \\ \tilde{A} &= [10, 15] \\ \tilde{\mathbb{P}}(\tilde{A}) &\stackrel{!}{=} \frac{15 - 10}{60 - 0} = \frac{5}{60} = \frac{1}{12}\end{aligned}$$

Um auch modellieren zu können, dass Intervalle **WS** haben, die nicht **iwas** von ihrer Länge abgängen, arbeiten wir mit R-Integralen. **R-Integral**?

Kommentar 1.12 TODO: Was genau ist $\tilde{\Omega}$?

1.3.1 | Eindimensionale Dichten

Definition 1.7 Eindimensionale Dichte (2025, Skript 26 - Definition 1.22)

Eine Funktion $f : \mathbb{R} \rightarrow [0, \infty)$, die (uneigentlich) Riemann-integrierbar ist, heißt Dichte, sofern

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

Bemerkung 1.7 Zu Definition 1.7 (Skript 26 - Bemerkung 1.23)

Dichten sind nichtnegativ: Die Definition einer **Dichte** f beinhaltet die Forderung $f \leq 0$, das heißt, es muss

$$f(x) \geq 0 \forall x \in \mathbb{R}$$

gelten.

Die folgende Bemerkung erinnert uns wohl an die für den Zweck dieser Vorlesung wichtigsten Aussagen über die Existenz von Riemann-Integralen.

Bemerkung 1.8 Zu Definition 1.7 (2025, Skript 26 - Bemerkung 1.24)**Riemann-Integrierbarkeit**

■

- f monoton oder f stetig $\Rightarrow \int_a^b f(x)dx$ existiert für alle $(a, b \in \mathbb{R})$ auch: für $-\infty < a < b < \infty$
- f stückweise stetig oder stückweise monoton, $\Rightarrow \int_a^b f(x)dx$ existiert $(a, b \in \mathbb{R})$ auch: für $-\infty < a < b < \infty$
- $f \geq 0$: f Riemann-integrierbar $\Leftrightarrow \lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx < \infty$
 - Damit ist gemeint: Ist $f \geq 0$, so ist f genau dann uneigentlich Riemann-integrierbar über $\mathbb{R}$, wenn das Riemann-Integral $\int_a^b f(x)dx$ für jede Wahl $-\infty < a < b < \infty$ existiert und $\lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx$ existiert. In diesem Fall gilt $\int_{-\infty}^{\infty} f(x)dx = \lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx$
- f ist uneigentlich Riemann-integrierbar über $\mathbb{R}$, gdw. sowohl $(-\infty, 0]$ als auch $[0, \infty)$ uneigentlich Riemann-integrierbar ist.
- f ist genau dann uneigentlich Riemann-integrierbar über $[0, \infty)$, wenn f über jedes Intervall $[0, b]$ Riemann-integrierbar ist und $\lim_{b \rightarrow \infty} \int_0^b f(x)dx$ existiert. In diesem Fall schreiben wir

$$\int_0^{\infty} f(x)dx = \lim_{b \rightarrow \infty} \int_0^b f(x)dx$$

- Analog: f ist genau dann uneigentlich Riemann-integrierbar über $(-\infty, 0]$, wenn f über jedes Intervall $[a, 0]$ Riemann-integrierbar ist und $\lim_{a \rightarrow -\infty} \int_a^0 f(x)dx$ existiert. In diesem Fall schreiben wir

$$\int_{-\infty}^0 f(x)dx = \lim_{a \rightarrow -\infty} \int_a^0 f(x)dx$$

Karteikarte 1.20 Was ist eine (eindimensionale) Dichte?

Eine Funktion $f : \mathbb{R} \rightarrow [0, \infty)$, die (uneigentlich) Riemann-integrierbar ist, heißt Dichte, sofern $\int_{-\infty}^{\infty} f(x)dx = 1$ (Normierungsbedingung)..

Karteikarte 1.21 Welche Vorzeichenbedingung erfüllt eine Dichte f ?

Dichten sind nichtnegativ: $f(x) \geq 0$ für alle $x \in \mathbb{R}$.

Karteikarte 1.22 Welche hinreichenden Kriterien für Riemann-Integrierbarkeit von f auf $[a, b]$ kennst du?

$\int_a^b f(x)dx$ existiert für $-\infty < a < b < \infty$, wenn f monoton ODER stetig ist, oder wenn f stückweise stetig ODER stückweise monoton ist..

Karteikarte 1.23 Wann ist eine nichtnegative Funktion $f \geq 0$ uneigentlich Riemann-integrierbar über $\mathbb{R}$?

Genau dann, wenn $\lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx < \infty$ existiert (und $\int_a^b f(x)dx$ für jede Wahl $-\infty < a < b < \infty$ existiert). In diesem Fall gilt $\int_{-\infty}^{\infty} f(x)dx = \lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx$.

Karteikarte 1.24 Wie zerlegt man die uneigentliche Riemann-Integrierbarkeit von f über $\mathbb{R}$?

f ist uneigentlich Riemann-integrierbar über $\mathbb{R}$ genau dann, wenn sowohl $(-\infty, 0]$ als auch $[0, \infty)$ uneigentlich

Riemann-integrierbar sind. Für $[0, \infty)$: f integrierbar über jedes $[0, b]$ und $\lim_{b \rightarrow \infty} \int_0^b f(x) dx$ existiert; man schreibt dann $\int_0^\infty f(x) dx := \lim_{b \rightarrow \infty} \int_0^b f(x) dx$. Analog für $(-\infty, 0]$ mit $\lim_{a \rightarrow -\infty} \int_a^0 f(x) dx$.

1.3.2 | Wahrscheinlichkeitsräume mit Dichten

Definition 1.8 Wahrscheinlichkeitsräume mit Dichten (2025, Skript 26 - Definition 1.25)

Sei eine Dichte $f \geq 0$ gegeben (also $f : \mathbb{R} \rightarrow [0, \infty)$). Wir setzen

$$\begin{aligned}\mathbb{P}([a, b]) &:= \int_a^b f(x) dx && \text{für alle } -\infty < a < b < \infty \\ \mathbb{P}([-\infty, b]) &:= \int_{-\infty}^b f(x) dx \\ \mathbb{P}([a, \infty]) &:= \int_a^\infty f(x) dx \\ \mathbb{P}\left(\bigcup_{i \in I} [a_i, b_i]\right) &:= \sum_{i \in I} \int_{a_i}^{b_i} f(x) dx && \text{für } I \subseteq \mathbb{N} \text{ (abzählbar) und } a_i < b_i \leq a_{i+1}^*\end{aligned}$$

Falls

$$a_1 = -\infty : (-\infty, b_1] \quad ; \quad b = +\infty : [a, \infty)$$

* Auch geschrieben als: Seien $I \subseteq \mathbb{N}$ eine abzählbare Indexmenge und $[a_i, b_i]$ Intervalle mit $a_i \leq b_i \leq a_{i+1} \leq b_{i+1}$ für alle $i, i+1 \in I$.

Beispiel 1.10 (2025) fehlt

Kommentar 1.13 Zu Definition 1.8 Die Definition von $\mathbb{P}$ auf einer abzählbaren Vereinigung disjunkter, aufsteigend geordneter Intervalle $[a_i, b_i]$ ist additiv über die Dichte f definiert. Uneigentliche Randintervalle ($a_1 = -\infty$ bzw. $b_{\max} = +\infty$) werden gesondert als Halboffene Intervalle behandelt. Eine alternative, schwächere Formulierung erlaubt statt $a_i < b_i$ auch $a_i \leq b_i$, wodurch entartete (einpunktige) Intervalle zugelassen werden; da diese jeweils das Maß 0 besitzen, ändert sich der Wert von $\mathbb{P}$ dadurch nicht.

Bemerkung 1.9 Zu Definition 1.8 (Skript 26 - Bemerkung 1.26)

- Wann immer das Wahrscheinlichkeitsmass $\mathbb{P}$ durch eine eindimensionale Dichte gegeben ist, betrachten wir nur Wahrscheinlichkeiten von Mengen, die wir darstellen können als maximal abzählbar unendliche Vereinigung oder als maximal abzählbar unendlichen Schnitt von Intervallen. Auch können wir wiederum Vereinigungen und Schnitte von derart erhaltenen Mengen betrachten. Diese Prozedur kann beliebig oft wiederholt werden. Trotzdem gibt es Mengen, denen wir keine Wahrscheinlichkeit zuordnen können. Da es nicht ganz einfach ist, derartige - pathologische - Mengen zu konstruieren, bedeutet das für uns keine wesentliche Einschränkung.
- Um ein Zufallsexperiment zu modellieren, in dem nur Elementarereignisse aus einer echten Teilmenge $I \subseteq \mathbb{R}$ angenommen werden können, wählen wir eine Dichte, die außerhalb von I Null ist, das heißt, es soll $f(x) = 0$ für alle $x \notin I$

Lemma 1.3 Wahrscheinlichkeit einelementiger Mengen (Skript 26 - Lemma 1.27)

Ist ein Wahrscheinlichkeitsmass $\mathbb{P}$ durch eine Dichte f gegeben, so gilt

$$\mathbb{P}(\{a\}) = 0 \quad \forall a \in \mathbb{R}$$

Beweis. Skript 26 Seite 11

Korollar 1.1 Dichten sind nicht eindeutig bestimmt (Skript 26 - Korollar 1.28)

Das Wahrscheinlichkeitsmass $\mathbb{P}$ sei durch eine Dichte f gegeben. Sei g eine weitere Dichte, die sich in höchstens abzählbar vielen Punkten von f unterscheidet, das heißt, es gebe eine abzählbare Menge M derart, dass $g(x) = f(x)$ für alle $x \in \mathbb{R} \setminus M$. Dann definiert g dasselbe Wahrscheinlichkeitsmass $\mathbb{P}$ wie f .

Korollar 1.2 Wahrscheinlichkeit von Intervallen (Skript 26 - Korollar 1.29)

Sei $\mathbb{P}$ durch eine Dichte f gegeben. Dann gilt für jede Wahl von $a, b \in \mathbb{R}$ mit $-\infty < a < b < \infty$,

$$\mathbb{P}([a, b]) = \mathbb{P}((a, b]) = \mathbb{P}([a, b)) = \mathbb{P}((a, b))$$

Beispiel 1.11 Messen einer zufälligen Zeit (Skript 26 - Beispiel 1.30)

Wir wählen $\Omega = \mathbb{R}$ und die Dichte

$$f(x) = \begin{cases} \frac{1}{60} & x \in [0, 60] \\ 0 & \text{sonst} \end{cases}$$

Dabei verstehen wir $\omega \in \Omega$ als die gemessene Zeit (in Minuten) bei einer Realisierung des Zufallsexperiments. Die Tatsache, daß $f = 0$ außerhalb von $[0, 60]$ gilt, reflektiert, daß in unserem Experiment nur Zeiten innerhalb einer Stunde ab Start möglich sein sollen.

Wir müssen zeigen, daß f eine Dichte ist

1. $f \geq 0$ gilt per Definition von f
2. f ist **stückweise stetig** und daher Riemann-integrierbar
3. Die Normierungsbedingung ist erfüllt, weil

$$\int_{-\infty}^{\infty} f(x) dx = \int_0^{60} f(x) dx = \int_0^{60} \frac{1}{60} dx = \frac{60 - 0}{60} = 1$$

Wir sehen, dass, wie zuvor,

$$\mathbb{P}([10, 15]) = \int_{10}^{15} f(x) dx = \int_{10}^{15} \frac{1}{60} dx = \frac{5}{60} = \frac{1}{12}$$

gilt.

Bemerkung 1.10 Vorgehen beim Berechnen von Integralen mit stückweise gegebener Dichte (Skript 26 - Bemerkung 1.31)

Es empfiehlt sich, sukzessive wie in obigem Beispiel vorzugehen:

1. Integral über Intervall aufschreiben
2. Grenzen anpassen, so daß nicht mehr über Intervalle integriert wird, auf denen $f = 0$ gilt
3. Konkrete Form von f einsetzen
4. Integral ausrechnen

Genauer

1. Integral über Intervall aufschreiben:

- $\int_{-\infty}^{\infty} f(x) dx$, um zu verifizieren, daß f die Normierungsbedingung erfüllt
- $\mathbb{P}([a, b]) = \int_{-\infty}^{\infty} f(x) dx$, um eine Wahrscheinlichkeit zu berechnen

2. Grenzen anpassen, so daß nicht mehr über Intervalle integriert wird, auf denen $f = 0$ gilt:

- $\int_{-\infty}^{\infty} f(x) dx = \int_0^{60} f(x) dx$
- $\mathbb{P}([50, 70]) = \int_{50}^{70} f(x) dx = \int_{50}^{60} f(x) dx$

3. Konkrete Form von f einsetzen:

- $\mathbb{P}([10, 15]) = \int_{10}^{15} f(x) dx \int_{10}^{15} \frac{1}{60} dx$
- $\mathbb{P}([50, 70]) = \int_{50}^{70} f(x) dx = \int_{50}^{60} f(x) dx = \int_{50}^{60} \frac{1}{60} dx$

4. Integral ausrechnen:

- $\mathbb{P}([10, 15]) = \int_{10}^{15} f(x) dx \int_{10}^{15} \frac{1}{60} dx = 1$
- $\mathbb{P}([50, 70]) = \int_{50}^{70} f(x) dx = \int_{50}^{60} f(x) dx = \int_{50}^{60} \frac{1}{60} dx = \frac{1}{6}$

Bemerkung 1.11 (Skript 26) Falls f durch eine Fallunterscheidung mit mehr Fällen als in unserem Beispiel gegeben ist, so muss im dritten Schritt das Integral entsprechend aufgespalten werden,

$$\int_a^d f(x) dx = \int_a^b f(x) dx + \int_b^c f(x) dx + \int_c^d f(x) dx$$

Für $a < b < c < d$, bevor die konkrete Form von f eingesetzt wird.

Losgelöst von der Idee, daß wir eine zufällige Zeit messen wollen, können wir ganz allgemein für ein beliebiges beschränktes Intervall I eine Dichte definieren derart, daß die Wahrscheinlichkeit, daß der Ausgang des entsprechenden Zufallsexperiments in einem Teilintervall $J \subseteq I$ liegt, weiterhin nur von der Länge des entsprechenden Teilintervalls J abhängt

Karteikarte 1.25 Wie definiert man P auf Intervallen, wenn eine Dichte $f \geq 0$ gegeben ist?

$P([a, b]) := \int_a^b f(x) dx$ für $-\infty < a < b < \infty$; $P([-\infty, b]) := \int_{-\infty}^b f(x) dx$; $P([a, \infty]) := \int_a^{\infty} f(x) dx$. Für abzählbare, aufsteigend geordnete disjunkte Intervalle $[a_i, b_i]$, $i \in I \subseteq \mathbb{N}$: $P(\bigcup_{i \in I} [a_i, b_i]) := \sum_{i \in I} \int_{a_i}^{b_i} f(x) dx$.

Karteikarte 1.26 Welche Mengen können bei einem Wahrscheinlichkeitsraum mit Dichte überhaupt eine Wahrscheinlichkeit bekommen?

Nur Mengen, die als maximal abzählbar unendliche Vereinigung oder Schnitt von Intervallen darstellbar sind (auch wiederholt kombiniert). Es gibt zwar pathologische Mengen ohne zugeordnete Wahrscheinlichkeit, diese sind aber schwer zu konstruieren und für die Praxis irrelevant..

Karteikarte 1.27 Wie modelliert man ein Zufallsexperiment, bei dem nur Werte aus einer Teilmenge $I \subseteq \mathbb{R}$ angenommen werden können?

Man wählt eine Dichte f , die außerhalb von I Null ist, also $f(x) = 0$ für alle $x \notin I$.

Karteikarte 1.28 Welche Wahrscheinlichkeit hat eine einelementige Menge $\{a\}$, wenn P durch eine Dichte gegeben ist?

$P(\{a\}) = 0$ für alle $a \in \mathbb{R}$. (Dichte-Modelle weisen einzelnen Punkten also stets Wahrscheinlichkeit 0 zu, im Gegensatz zu diskreten Modellen.).

Karteikarte 1.29 Sind Dichten, die zu einem gegebenen Wahrscheinlichkeitsmaß gehören, eindeutig bestimmt?

Nein. Unterscheiden sich zwei Dichten f und g nur auf einer höchstens abzählbaren Menge M (d.h. $g(x) = f(x)$ für alle $x \notin M$), so definieren sie dasselbe Wahrscheinlichkeitsmaß P .

Karteikarte 1.30 Spielt es bei einer Dichte eine Rolle, ob ein Intervall offen, halboffen oder abgeschlossen ist?

Nein. Für $-\infty < a < b < \infty$ gilt $P([a, b]) = P((a, b]) = P([a, b)) = P((a, b))$, da einzelne Randpunkte jeweils Wahrscheinlichkeit 0 haben..

Karteikarte 1.31 In welchen 4 Schritten berechnet man Integrale mit stückweise gegebener Dichte?

(1) Integral über das gewünschte Intervall aufschreiben (Normierung oder $P([a, b])$). (2) Grenzen anpassen, sodass nicht mehr über Bereiche integriert wird, auf denen $f = 0$ gilt. (3) Konkrete Form von f einsetzen. (4) Integral ausrechnen. Beispiel: $P([50, 70]) = \int_{50}^{70} f(x)dx = \int_{50}^{60} f(x)dx = \int_{50}^{60} \frac{1}{60}dx = \frac{1}{6}$.

Karteikarte 1.32 Wie geht man vor, wenn die Dichte f durch mehr als zwei Fälle definiert ist?

Das Integral muss vor dem Einsetzen der konkreten Form von f entsprechend aufgespalten werden: $\int_a^d f(x)dx = \int_a^b f(x)dx + \int_b^c f(x)dx + \int_c^d f(x)dx$ für $a < b < c < d$.

1.3.3 | Uniforme Verteilung

Definition 1.9 Uniforme Verteilung auf einem Intervall (Kontinuumsäquivalent zu gleichverteilt) (2025, Skript 26 - Definition 1.32)

Die uniforme Verteilung auf einem beschränkten Intervall $I \subseteq \mathbb{R}$ (äquivalent zu $I = [a, b]$ mit $-\infty < a < b < \infty$) ist gegeben durch eine Dichte

$$f(x) = \begin{cases} \frac{1}{|I|} & x \in I \\ 0 & \text{sonst} \end{cases} = \begin{cases} \frac{1}{b-a} & x \in I \\ 0 & \text{sonst} \end{cases}$$

wobei $|I|$ die Intervalllänge bezeichnet.

Beispiel 1.12 Zu Definition 1.9 txc(Skript 26 - Definition 1.32)

Sei nun $[a, b] = [0, 10]$. Die Wahrscheinlichkeit, daß der Ausgang des Zufallsexperiments sehr klein oder sehr groß

ist, sagen wir entweder kleiner als 0.1 oder größer als 9.9 ist, beträgt

$$\mathbb{P}((-\infty, 0.0) \cup (9.9, \infty)) = \int_0^{0.1} f(x) dx + \int_{9.9}^{10} f(x) dx = \frac{1}{10}[0.1 + 0.1] = \frac{2}{100} = \frac{1}{50}$$

Bemerkung 1.12 Zu Beispiel 1.11 (Skript 26 - Bemerkung 1.33)

Der Wert $\frac{1}{b-a}$ ergibt sich aus der Normierungsbedingung. Daraus ergibt sich, daß es auf einem nicht beschränkten Intervall keine uniforme Verteilung geben kann. Der Beweis verwendet dieselbe Idee wie jene, die wir in Bemerkung 1.6 benutzt haben.

Wir können die Definition der uniformen Verteilung verallgemeinern.

Definition 1.10 Uniforme Verteilung auf einer Menge M (Skript 26 - Definition 1.34)

Sei $M \subseteq \mathbb{R}$ eine Menge, der wir einen Inhalt $|M| = \lambda(M)$ zuordnen können. Ist $|M| < \infty$, so ist die uniforme Verteilung auf M gegeben durch die Dichte

$$f(x) = \begin{cases} \frac{1}{|M|} & x \in M \\ 0 & \text{sonst} \end{cases}$$

Bemerkung 1.13 (Skript 26 - Bemerkung 1.35)

Die uniforme Verteilung auf einer beschränkten Menge $M \subseteq \mathbb{R}$ ist das kontinuierliche Analogon der Gleichverteilung auf einer endlichen Menge. Es gilt

$$\mathbb{P}(A) = \frac{|A \cap M|}{|M|}$$

für alle $A \subseteq \mathbb{R}$, für die der Inhalt $|A|$ definiert ist.

Wartezeiten werden häufig mit Hilfe der Exponentialverteilung modelliert.

Karteikarte 1.33 Was ist die uniforme Verteilung auf einem Intervall $I = [a, b]$ (Kontinuumsäquivalent zur Gleichverteilung)?

Gegeben durch die Dichte $f(x) = \frac{1}{|I|} = \frac{1}{b-a}$ für $x \in I$, sonst 0, wobei $|I|$ die Intervalllänge ist. Voraussetzung: I beschränkt, $-\infty < a < b < \infty$.

Karteikarte 1.34 Warum kann es keine uniforme Verteilung auf einem unbeschränkten Intervall geben?

Der Dichtewert $\frac{1}{b-a}$ ergibt sich aus der Normierungsbedingung $\int f(x) dx = 1$. Bei unbeschränktem Intervall würde dies (analog zum Beweis, dass es keine Gleichverteilung auf unendlichen Mengen gibt) zu einem Widerspruch führen — daher ist eine uniforme Verteilung nur auf beschränkten Intervallen definierbar..

Karteikarte 1.35 Wie verallgemeinert man die uniforme Verteilung von Intervallen auf beliebige Mengen $M \subseteq \mathbb{R}$?

Sei $M \subseteq \mathbb{R}$ eine Menge mit Inhalt $|M| = \lambda(M) < \infty$. Die uniforme Verteilung auf M ist gegeben durch $f(x) = \frac{1}{|M|}$ für $x \in M$, sonst 0..

Karteikarte 1.36 Wie berechnet man bei uniformer Verteilung auf M die Wahrscheinlichkeit eines beliebigen Ereignisses A ?

$P(A) = \frac{|A \cap M|}{|M|}$ für alle $A \subseteq \mathbb{R}$, für die der Inhalt $|A|$ definiert ist. Dies ist das kontinuierliche Analogon zur

Gleichverteilung auf einer endlichen Menge ($P(A) = \frac{\#A}{\#\Omega}$)..

1.3.4 | Exponentialverteilung

Definition 1.11 Exponentialverteilung (2025, Skript 26 - Definition 1.36)

Die Exponentialverteilung zum Parameter $\alpha > 0$ ist gegeben durch die **Dichte**

$$f(x) = \begin{cases} 0 & \text{für } x < 0 \\ \alpha e^{-\alpha x} & \text{für } x \geq 0 \end{cases} \quad (1.1)$$

Bemerkung 1.14 Zu Definition 1.11 - Die Exponentialverteilung ist wohldefiniert (2025, Skript 26 - Lemma 1.37)

Gleichung 1.1 ist eine **Dichte** :

■ $f \geq 0$

■ f R-integrierbar, da stückweise stetig

$$\begin{aligned} g(x) &= e^{-\alpha x} \\ g'(x) &= (-\alpha)e^{-\alpha x} \quad (\text{Produktregel}) \end{aligned}$$

■ ???:

$$\begin{aligned} \int_{-\infty}^{\infty} f(x) dx &= \int_0^{\infty} f(x) dx \\ &= \int_0^{\infty} \alpha e^{-\alpha x} dx \\ &= \lim_{N \rightarrow \infty} \int_0^N \alpha e^{-\alpha x} dx \\ &= \lim_{N \rightarrow \infty} [-e^{-\alpha x} \Big|_{x=0}^N] \\ &= \lim_{N \rightarrow \infty} [-e^{-\alpha N} - \underbrace{(-e^{-\alpha \cdot 0})}_{=1}] \\ &= 1 - \underbrace{\lim_{N \rightarrow \infty} e^{-\alpha N}}_{=1} \\ &= 1 \end{aligned}$$

Rechnen mit Wahrscheinlichkeiten

Vorlesung 25.04.2025 (V02 2025), ergänzt durch Skript 2026

Lernziele

- Unterschied zwischen disjunkten und paarweise disjunkten Mengen kennen
- Rechenregeln für Wahrscheinlichkeiten anwenden und beweisen können, insbesondere
 - Komplementärwahrscheinlichkeit (“Gegenwahrscheinlichkeit”)
 - Ein-und-Ausschlußprinzip
 - Spezialfall: Wahrscheinlichkeit der Vereinigung paarweise disjunkter Mengen

2.1 | Mengenoperationen und Ereignisse

Definition 2.1 Komplement von Mengen (Skript 2026 - Definition 2.1)

Gilt $A \subseteq \Omega$, so schreiben wir A^c für das Komplement von A in Ω , das heißt, wir setzen

$$A^c = \Omega \setminus A$$

Bemerkung 2.1 Zu Definition 2.1 (Skript 2026 - Definition 2.1)



Diese Notation ist mit Vorsicht anzuwenden, da sie voraussetzt, dass klar ist, auf welche Referenz- Obermenge Ω wir uns beziehen.

Definition 2.2 Vereinigung/Schnitt abzählbar vieler Mengen (2025, Skript 2026 - Definition 2.2)


$I \subseteq \mathbb{N}$ Indexmenge.

Für jedes $i \in I$ sei $A_i \subseteq \Omega$:

- $A_i \in \mathcal{R}(\Omega)$ für Ω abzählbar
 - A_i ein Intervall für $\Omega = \mathbb{R}$ (oder $\Omega = [0, \infty)$ oder $\Omega = [a, b]$)
- (a) $\bigcup_{i \in I} A_i = \{\omega \in \Omega : \omega \in A_i \text{ für mind. ein } i \in I\} = \{\omega \in \Omega : \exists j \in I \text{ mit } \omega \in A_j\}$
- (b) $\bigcap_{i \in I} A_i = \{\omega \in \Omega : \omega \in A_i \text{ für alle } i \in I\} = \{\omega \in \Omega : \omega \in A_i \forall j \in I\}$

Lemma 2.1 Rechenregeln für Mengen und Ereignisse (2025, Skript 26 - Lemma 2.3)Seien $A, B, C \subset \Omega$.(a) Transitivität: $A \subset B, B \subset C \Rightarrow A \subset C$ (b) Distributivgesetz: $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$ und $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$

- Kommutativitätsgesetz: $A \cup B = B \cup A$ und $A \cap B = B \cap A$
- Assoziativgesetz: $(A \cup B) \cup C = A \cup (B \cup C)$ und $(A \cap B) \cap C = A \cap (B \cap C)$
- de Morgansche Regeln: $(A \cup B)^c = A^c \cap B^c$ und $(A \cap B)^c = A^c \cup B^c$

Beweis. Skript 26 Seite 20**Karteikarte 2.1** Wie ist das Komplement A^c einer Menge $A \subseteq \Omega$ definiert? $A^c := \Omega \setminus A$. Achtung: Diese Notation setzt voraus, dass klar ist, auf welche Referenz-Obermenge Ω man sich bezieht..**Karteikarte 2.2** Wie sind Vereinigung und Schnitt abzählbar vieler Mengen $A_i, i \in I$, definiert? $\bigcup_{i \in I} A_i = \{\omega \in \Omega : \exists j \in I \text{ mit } \omega \in A_j\}$ (mind. ein A_i enthält ω). $\bigcap_{i \in I} A_i = \{\omega \in \Omega : \omega \in A_i \forall i \in I\}$ (alle A_i enthalten ω)..**Karteikarte 2.3** Welche drei Rechenregeln für Mengen/Ereignisse kennst du (Kommutativ-, Assoziativ-, de Morgan)?Kommutativität: $A \cup B = B \cup A, A \cap B = B \cap A$. Assoziativität: $(A \cup B) \cup C = A \cup (B \cup C)$, analog für $\cap$. De Morgan: $(A \cup B)^c = A^c \cap B^c$ und $(A \cap B)^c = A^c \cup B^c$..**2.1.1 | Disjunktheit****Definition 2.3** $A, B, A_1, A_2, \dots \subset \Omega$ (2025)(a) A und B heißen disjunkt, wenn $A \cap B = \emptyset$ **Abbildung 2.2:** Disunkte Mengen.

Sei I eine beliebige Indexmenge. Für jedes $i \in I$ sei eine Menge $A_i \subseteq \Omega$ gegeben.

(b) $A_1, A_2, \dots$ heißen disjunkt, wenn $\bigcap_i A_i = \emptyset$ (Alle Mengen liegen getrennt voneinander)




Abbildung 2.3: Disjunkte Mengen.

(c) $A_1, A_2, \dots$ heißen paarweise disjunkt, wenn $A_i \cap A_j = \emptyset \quad \forall i, j \text{ mit } i \neq j$




Abbildung 2.4: Disjunkte Mengenfamilie; paarweise disjunkte Mengen.

(d) Sind $A_1, A_2, \dots$ paarweis disjunkt, so schreiben wir $\dot{\bigcup}_i A_i$ für die Vereinigung $\bigcup_i A_i$.

■ Wir sprechen von einer disjunkten Vereinigung

Bemerkung 2.2 (2025)

paarweise disjunkt $\Rightarrow$ disjunkt

$$\bigcup_i A_i \subset A_1 \cap A_2 = \emptyset$$

Beispiel 2.1 Disjunkte und paarweise disjunkte Mengen beim Würfeln (Skript 26 - Beispiel 2.5)

Sei $\Omega = \{1, \dots, 6\}$

- Setze $A = \{2, 4, 6\}$, $B = \{3, 6\}$ und $C = \{1\}$. Dann ist $A \cap B = \{6\} \neq \emptyset$, also sind A und B nicht disjunkt, während $A \cap C = \emptyset$ impliziert, daß A und C disjunkt sind.
- Seien $A_1 = \{1, 3\}$, $A_2 = \{3, 5\}$ und $A_3 = \{1, 5\}$. Dann sind A_1, A_2 und A_3 disjunkt, aber nicht paarweise disjunkt, weil $A_1 \cap A_2 \cap A_3 = \emptyset$, aber $A_1 \cap A_2 = \{3\} \neq \emptyset$.

Lemma 2.2 Relation zwischen den Konzepten “disjunkt” und “paarweise disjunkt” (Skript 26 - Lemma 2.6)

Sei I eine beliebige Indexmenge. Für jedes $i \in I$ sei eine Menge $A_i \subseteq \Omega$ gegeben.

1. paarweise disjunkt $\Rightarrow$ disjunkt:

$$A_i \cap A_j = \emptyset \quad \forall i, j \in I \text{ mit } i \neq j \Rightarrow \bigcap_{i \in I} A_i = \emptyset$$

2. disjunkt $\nRightarrow$ paarweise disjunkt.

Es gibt Beispiele von disjunkten Mengen, die nicht paarweise disjunkt sind.

Beweis. Skript 26 Seite 22

Beispiel 2.2 Disjunkte und paarweise disjunkte Mengen (Skript 26 - Beispiel 2.7) Wir wählen

$$\begin{aligned} A_1 &= \{1, 2, 3, 4, \dots\}, \\ A_2 &= \{2, 3, 4, \dots\}, \\ A_3 &= \{3, 4, \dots\}, \\ &\vdots \\ A_k &= \{k, k+1, \dots\} = \{j \in \mathbb{N} : j \geq k\}. \end{aligned}$$

Die Mengen A_i , $i \in \mathbb{N}$, sind *nicht paarweise disjunkt*:

Für jede Wahl von $i, j \in \mathbb{N}$ mit $i < j$ gilt

$$A_i \cap A_j = A_j \neq \emptyset.$$

Dennoch sind die Mengen A_i , $i \in \mathbb{N}$ *disjunkt*

$$\bigcap_{i \in \mathbb{N}} A_i = \emptyset.$$

Zum Beweis nehmen wir an, es gäbe ein $\ell \in \mathbb{N}$ mit

$$\ell \in \bigcap_{i \in \mathbb{N}} A_i.$$

Dann müsste $\ell \in A_i$ für alle $i \in \mathbb{N}$ gelten. Insbesondere müsste

$$\ell \in A_{\ell+1} = \{\ell+1, \ell+2, \dots\}$$

sein. Dies ist jedoch unmöglich. Also existiert kein solches ℓ , und damit folgt

$$\bigcap_{i \in \mathbb{N}} A_i = \emptyset.$$

Karteikarte 2.4 Wann heißen zwei Mengen A, B disjunkt?

Wenn $A \cap B = \emptyset$ gilt..

Karteikarte 2.5 Wann heißt eine Familie $A_1, A_2, \dots$ (allgemein $A_i, i \in I$) disjunkt?

Wenn der Gesamtschnitt aller Mengen leer ist: $\bigcap_i A_i = \emptyset$. (Es reicht, dass es keinen gemeinsamen Punkt in ALLEN Mengen gibt — einzelne Paare können sich trotzdem überschneiden!).

Karteikarte 2.6 Wann heißt eine Familie $A_1, A_2, \dots$ paarweise disjunkt?

Wenn $A_i \cap A_j = \emptyset$ für alle $i \neq j$ gilt (jedes Paar einzeln betrachtet ist disjunkt). Achtung: In der Quelldefinition steht fälschlich $\neq \emptyset$, korrekt ist aber $= \emptyset$ für paarweise Disjunktheit..

Karteikarte 2.7 Welche Notation verwendet man für die Vereinigung paarweise disjunkter Mengen?

$\dot{\bigcup}_i A_i$ statt $\bigcup_i A_i$, wenn die A_i paarweise disjunkt sind. Man spricht von einer disjunkten Vereinigung..

Karteikarte 2.8 Folgt aus paarweiser Disjunktheit die (einfache) Disjunktheit einer Mengenfamilie?

Ja: paarweise disjunkt $\Rightarrow$ disjunkt, denn $\bigcap_i A_i \subseteq A_1 \cap A_2 = \emptyset$.

Karteikarte 2.9 Beispiel: Sind $A = \{2, 4, 6\}$, $B = \{3, 6\}$, $C = \{1\}$ beim Würfeln disjunkt?

$A \cap B = \{6\} \neq \emptyset \Rightarrow A, B$ NICHT disjunkt. $A \cap C = \emptyset \Rightarrow A, C$ disjunkt. Zweites Beispiel: $A_1 = \{1, 3\}$, $A_2 = \{3, 5\}$, $A_3 = \{1, 5\}$ sind disjunkt ($A_1 \cap A_2 \cap A_3 = \emptyset$), aber NICHT paarweise disjunkt (da z.B. $A_1 \cap A_2 = \{3\} \neq \emptyset$).

Karteikarte 2.10 Gilt auch die Umkehrung: disjunkt $\Rightarrow$ paarweise disjunkt?

Nein. Disjunkt impliziert NICHT paarweise disjunkt — es gibt Gegenbeispiele (siehe $A_k = \{k, k+1, \dots\}$: die Mengen sind disjunkt, aber keine zwei von ihnen sind paarweise disjunkt, da $A_i \cap A_j = A_j \neq \emptyset$ für $i < j$).

Karteikarte 2.11 Beispiel: Warum sind $A_k = \{k, k+1, k+2, \dots\}$ für $k \in \mathbb{N}$ disjunkt, aber nicht paarweise disjunkt?

Nicht paarweise disjunkt: Für $i < j$ gilt $A_i \cap A_j = A_j \neq \emptyset$. Aber disjunkt: $\bigcap_{i \in \mathbb{N}} A_i = \emptyset$, denn gäbe es ein ℓ im Gesamtschnitt, müsste $\ell \in A_{\ell+1} = \{\ell+1, \ell+2, \dots\}$ gelten — unmöglich, da $\ell < \ell+1$.

2.2 | Erste Rechenregeln für Wahrscheinlichkeiten

Satz 2.1 (2025)

Seien $A, B, A_1, A_2, \dots \subset \Omega$ (und Intervalle, falls $\mathbb{P}$ durch Dichte gegeben ist)

(a) Additivität: Seien $A_1, A_2, \dots$ paarweise disjunkt, dann gilt:

$$\mathbb{P}(\dot{\bigcup}_i A_i) = \sum_i \mathbb{P}(A_i)$$

Gilt auch für Dichten!

Beweis.

$$\begin{aligned} \mathbb{P}(\dot{\bigcup}_i A_i) &= \mathbb{P}(\{\omega \in \Omega : \exists i \text{ mit } \omega \in A_i\}) \\ &= \sum_i \underbrace{\sum_{\omega \in A_i} \mu(\omega)}_{\mathbb{P}(A_i)} \\ &= \sum_i \mathbb{P}(A_i) \end{aligned}$$

Wir haben die Summe/Reihe umsortiert

(b) Komplementärwahrscheinlichkeit (“Gegenwahrscheinlichkeit”)

$$\mathbb{P}(A^c) = \mathbb{P}(\Omega \setminus A) = 1 - \mathbb{P}(A)$$

Beweis.

$$\begin{aligned} \Omega = A \dot{\cup} A^c &\stackrel{(a)}{\Rightarrow} 1 \stackrel{\text{Normierung}}{=} \mathbb{P}(\Omega) = \mathbb{P}(A \dot{\cup} A^c) \stackrel{(a)}{=} \mathbb{P}(A) + \mathbb{P}(A^c) \\ &\Rightarrow \mathbb{P}(A^c) = 1 - \mathbb{P}(A) \end{aligned}$$

(c) Monotonie:

$$A \subset B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$$

Beweis

$$\begin{aligned} B &= A \dot{\cup} (B \setminus A) \\ \mathbb{P}(B) &= \mathbb{P}(A) + \underbrace{\mathbb{P}(B \setminus A)}_{\geq 0} \geq \mathbb{P}(A) \end{aligned}$$

(d) $A \subset B \Rightarrow \mathbb{P}(A) = \mathbb{P}(B) - \mathbb{P}(B \setminus A)$

(e) Wahrscheinlichkeit von Vereinigungen:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$$

Beweis.

$$\begin{aligned} A \cup B &= A \dot{\cup} [B \setminus (A \cap B)] \\ \mathbb{P}(A \cup B) &= \mathbb{P}(A) + \underbrace{\mathbb{P}(B \setminus (A \cap B))}_{\stackrel{(d)}{=} \mathbb{P}(B) - \mathbb{P}(A \cap B)} \\ &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \end{aligned}$$

Weitere Beweise Skript 2026 ab Seite 23.

Bemerkung 2.3 (2025)Sind A, B disjunkt, so gilt nach (a): $\mathbb{P}(A \dot{\cup} B) = \mathbb{P}(A) + \mathbb{P}(B)$.Sind A, B nicht disjunkt, so gilt nach (e): $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$.Sind A, B, C paarweise disjunkt, so gilt nach (a): $\mathbb{P}(A \cup B \cup C) \stackrel{(a)}{=} \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C)$.Was passiert, wenn A, B, C nicht paarweise disjunkt sind?

$$\begin{aligned} \mathbb{P}(A \cup B \cup C) &= \mathbb{P}(A \cup (B \cup C)) \\ &= \mathbb{P}(A) \mathbb{P}(B \cup C) - \mathbb{P}(A \cap (B \cup C)) \\ &= \mathbb{P}(A) + [\mathbb{P}(B) + \mathbb{P}(C) - \mathbb{P}(B \cap C)] - \mathbb{P}((A \cap B) \cup (A \cap C)) \\ &= \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) \\ &\quad - \mathbb{P}(A \cap B) - \mathbb{P}(A \cap C) - \mathbb{P}(B \cap C) \\ &\quad + \underbrace{\mathbb{P}((A \cap B) \cap (A \cap C))}_{= A \cap B \cap C} \end{aligned}$$

Mengen

Paare von Mengen

Tripel von Mengen

Karteikarte 2.12 Additivität von P : Wie berechnet man P einer disjunkten Vereinigung $\bigcup_i A_i$?

$P\left(\bigcup_i A_i\right) = \sum_i P(A_i)$, für paarweise disjunkte $A_1, A_2, \dots$. Gilt auch bei durch Dichten gegebenem P . Beweis: Umsortieren der Doppelsumme $\sum_i \sum_{\omega \in A_i} \mu(\omega) = \sum_i P(A_i)$.

Karteikarte 2.13 Wie lautet die Formel für die Komplementärwahrscheinlichkeit (Gegenwahrscheinlichkeit)?

$P(A^c) = P(\Omega \setminus A) = 1 - P(A)$. Beweis: $\Omega = A \dot{\cup} A^c \Rightarrow 1 = P(\Omega) = P(A) + P(A^c) \Rightarrow P(A^c) = 1 - P(A)$ (folgt aus

Additivität)..

Karteikarte 2.14 Monotonie von P : Was folgt aus $A \subseteq B$ für $P(A)$ und $P(B)$?

$A \subseteq B \Rightarrow P(A) \leq P(B)$. Beweis: $B = A \dot{\cup} (B \setminus A) \Rightarrow P(B) = P(A) + \underbrace{P(B \setminus A)}_{\geq 0} \geq P(A)$..

Karteikarte 2.15 Wie berechnet man $P(A)$, wenn $A \subseteq B$ bekannt ist (Formel mit $B \setminus A$)?

$A \subseteq B \Rightarrow P(A) = P(B) - P(B \setminus A)$..

Karteikarte 2.16 Wie lautet die Formel für $P(A \cup B)$ bei nicht notwendig disjunkten A, B ?

$P(A \cup B) = P(A) + P(B) - P(A \cap B)$. Beweis: $A \cup B = A \dot{\cup} [B \setminus (A \cap B)]$, dann Additivität und $P(B \setminus (A \cap B)) = P(B) - P(A \cap B)$ einsetzen..

Karteikarte 2.17 Wie berechnet man $P(A \cup B)$ bzw. $P(A \cup B \cup C)$ je nachdem ob die Mengen (paarweise) disjunkt sind?

A, B disjunkt: $P(A \dot{\cup} B) = P(A) + P(B)$. A, B nicht disjunkt: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$. A, B, C paarweise disjunkt: $P(A \cup B \cup C) = P(A) + P(B) + P(C)$. Allgemein (nicht paarweise disjunkt): siehe Ein- und Ausschlussprinzip für drei Ereignisse..

2.2.1 | Das Ein- und Ausschlußprinzip

Satz 2.2 Ein- und Ausschlußprinzip für drei Ereignisse (Skript 26 - Lemma 2.9)

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) && \text{(Mengen)} \\ &\quad - P(A \cap B) - P(A \cap C) - P(B \cap C) && \text{(Paare von Mengen)} \\ &\quad + P(A \cap B \cap C) && \text{(Tripel von Mengen)} \end{aligned}$$

Beweis.

$$\begin{aligned} P(A \cup B \cup C) &= P((A \cup B) \cup C) \\ &= P(A \cup B) + P(C) - P((A \cup B) \cap C) \\ &= P(A \cup B) + P(C) - P((A \cap C) \cup (B \cap C)) \\ &= P(A) + P(B) - P(A \cap B) + P(C) \\ &\quad - \left[P(A \cap C) + P(B \cap C) - P((A \cap C) \cap (B \cap C)) \right] \\ &= P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) \\ &\quad - P(B \cap C) + P(A \cap B \cap C). \end{aligned}$$

Satz 2.3 Ein- und Ausschlußprinzip für n Ereignisse (2025, Skript 26 - Theorem 2.10)

$$\begin{aligned} &A_2, \dots, A_n \subset \Omega \\ \mathbb{P} \left(\bigcup_{i=1}^n A_i \right) &= \sum_{k=1}^n (-1)^{k+1} \sum_{a \leq i_1 \leq \dots \leq i_k \leq n} \mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}) \end{aligned}$$

Beweis. Die Fälle $n = 2$ und $n = 3$ haben wir bereits behandelt. Der Beweis für beliebiges n kann mit Hilfe vollständiger Induktion geführt werden.

Beispiel 2.3 Werfen einer Sechse bei n -maligem Würfeln (Skript 26 - Beispiel 2.11)

Wie groß ist die Wahrscheinlichkeit, bei n -maligem Würfeln mit einem fairen Würfel mindestens eine Sechse zu werfen?

Siehe Skript 2026 Seite 25

Karteikarte 2.18 Wie lautet das Ein- und Ausschlussprinzip für drei Ereignisse A, B, C ?

$$P(A \cup B \cup C) = \underbrace{P(A) + P(B) + P(C)}_{\text{Mengen}} - \underbrace{P(A \cap B) - P(A \cap C) - P(B \cap C)}_{\text{Paare}} + \underbrace{P(A \cap B \cap C)}_{\text{Tripel}}..$$

Karteikarte 2.19 Wie lautet das allgemeine Ein- und Ausschlussprinzip für n Ereignisse?

$P(\bigcup_{i=1}^n A_i) = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < \dots < i_k \leq n} P(A_{i_1} \cap \dots \cap A_{i_k})$. Man summiert über alle möglichen Schnitte von k Mengen (mit alternierendem Vorzeichen), für $k = 1, \dots, n$. Beweis für allgemeines n : vollständige Induktion (Fälle $n = 2, 3$ als Basis)..

KAPITEL 3

Bedingte Wahrscheinlichkeiten

Vorlesung 02.05.2025 (V03 2025) und Vorlauf Kapitel 6 am 22.05.2026 (V05 2026) und 29 Mai 2026 (V06 2026)

Lernziele

- Definition und Bedeutung bedingter Wahrscheinlichkeiten kennen
- Modellieren von Zufallsexperimenten, wenn diese durch bedingte Wahrscheinlichkeiten beschrieben sind
- Satz von der totalen Wahrscheinlichkeit kennen und anwenden können
- Bayes-Formel kennen und anwenden können

Kommentar 3.1 Warnung von ihr: Bei Aufgaben zur bedingten WS kommt es sehr auf die Sprache an.

Zusammenhang mit der Unabhängigkeit? Zwei Ereignisse A,B sind unabh. genau dann, wenn die WS der Schnitt auch das Produkt der einzelnen WS ist usw. (siehe Anschnitt aus alten Aufzeichnungen)...

Beispiel 3.1 Einmaliges Würfeln (2025+2026 zsm.)

Wie wahrscheinlich ist es, daß eine 1 oder eine 6 gewürfelt wurde? Einmaliges Würfeln

Wie wahrscheinlich ist es, dass eine 1 oder eine 6 gewürfelt wurde?

$|\Omega| = \{1, \dots, 6\}$, $\mathbb{P}$ Gleichverteilung, $A = \{1, 6\}$, $\mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{2}{6} = \frac{1}{3}$

Wie wahrscheinlich ist es, dass eine 1 oder eine 6 gewürfelt wurde, wenn wir schon wissen, dass die geworfene Zahl durch 3 teilbar ist?

Was ist “ $\mathbb{P}$ von A, gegeben B” $\mathbb{P}(A | B)$ mit $B = \{3, 6\}$?

Wahrscheinlichkeit von A:

$$\mathbb{P}(A) = \frac{\text{Anz. günstige Ausgänge}}{\text{Anz. mögliche Ausgänge}} = \frac{|A|}{|\Omega|}$$

Wahrscheinlichkeit von A gegeben B:

$$\mathbb{P}(A | B) = \frac{\text{Anz. günstige Ausgänge in } A \cap B}{\text{Anz. mögliche Ausgänge in } B} = \frac{|A \cap B|}{|B|} = \frac{|\{6\}|}{|\{3, 6\}|} = \frac{1}{2}$$

Notation 3.1 (2025+2026 zsm.)

$|A| = \#A$

Definition 3.1 Bedingte Wahrscheinlichkeit (B-WS) (2025+2026 zsm.)

Für Ereignisse A und B heißt

$$\mathbb{P}(A | B) = \begin{cases} \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, & \text{falls } \mathbb{P}(B) > 0, \\ 0, & \text{falls } \mathbb{P}(B) = 0, \end{cases}$$

die bedingte Wahrscheinlichkeit von A gegeben B.

Kommentar 3.2 Zu Definition 3.1: Wenn $\mathbb{P}$ durch eine Dichte gegeben ist, muss man die Definition über Integrale interpretieren.

Beobachtung 3.1 (2025+2026 zsm.)

Bei Gleichverteilung gilt

$$\mathbb{P}(A | B) = \frac{\frac{\#|A \cap B|}{\#|\Omega|}}{\frac{\#|B|}{\#|\Omega|}} = \frac{|A \cap B|}{|B|}$$

D.h., die bedingte Wahrscheinlichkeit von A gegeben B ist tatsächlich der relative Anteil von A in B.

Frage 3.1 (2025+2026 zsm.)

In obigem Beispiel gilt $\mathbb{P}(A | B) > \mathbb{P}(A)$. Gilt das immer?

Antwort Nein! Sowohl $\mathbb{P}(A_1 | B_1) > \mathbb{P}(A_1)$ als auch $\mathbb{P}(A_2 | B_2) < \mathbb{P}(A_2)$ sind möglich.

Beispiel 3.2 (2025+2026 zsm.)

$\Omega = \{1, \dots, 6\}$ mit Gleichverteilung $\mathbb{P}$

$$A_1 = \{1, 6\}, \quad A_2 = \{1, 2, 3, 4\}, \quad B = B_1 = B_2 = \{3, 6\}$$

Dann gelten

$$\mathbb{P}(A_1 | B) = \frac{|A_1 \cap B|}{|B|} = \frac{1}{2} > \frac{1}{3} = \mathbb{P}(A_1)$$

$$\mathbb{P}(A_2 | B) = \frac{|A_2 \cap B|}{|B|} = \frac{1}{2} < \frac{2}{3} = \mathbb{P}(A_2)$$

Beispiel 3.3 Beispiel: Zweifacher Wurf einer fairen Münze (2025+2026 zsm.)

$\Omega = \{KK, KZ, ZK, ZZ\}$ mit Gleichverteilung $\mathbb{P}$

Jemand wirft die Münze zweimal und sagt uns nur, dass dabei mindestens einmal Zahl gefallen ist.

Wie groß ist die Wahrscheinlichkeit, dass zweimal Zahl gefallen ist?

Antwort: $A = \{ZZ\}, \quad B = \{KZ, ZK, ZZ\}$

$$\mathbb{P}(A | B) = \frac{|A \cap B|}{|B|} = \frac{1}{3}$$

Frage 3.2 (2025+2026 zsm.)

Jemand wirft die Münze zweimal und sagt uns nur, dass beim ersten Wurf Zahl gefallen ist.

Wie groß ist die Wahrscheinlichkeit, dass zweimal Zahl gefallen ist?

$$A = \{ZZ\}, \quad C = \{ZK, ZZ\}$$

$$\mathbb{P}(A | C) = \frac{|A \cap C|}{|C|} = \frac{1}{2}$$

Regel 3.1 Rechenregeln für bedingte Wahrscheinlichkeiten (diskreter Fall - analog für Fall einer Dichte) (2025+2026 zsm.)

Für ein festes Ereignis B mit $\mathbb{P}(B) > 0$ definiert

$$\mu_B(\omega) = \mathbb{P}(\{\omega\} | B) = \begin{cases} \frac{\mathbb{P}(\{\omega\})}{\mathbb{P}(B)} = \frac{\mu(\{\omega\})}{\mathbb{P}(B)}, & \text{falls } \omega \in B, \\ 0, & \text{falls } \omega \notin B, \end{cases}$$

eine Wahrscheinlichkeitsfunktion, und es gilt

$$\sum_{\omega \in A} \mu_B(\omega) = \frac{1}{\mathbb{P}(B)} = \sum_{\omega \in A \cap B} \mu(\omega) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \mathbb{P}(A | B)$$

für alle $A \subseteq \Omega$.

Die Abbildung $A \mapsto \mathbb{P}(A | B)$ ist also ein Wahrscheinlichkeitsmaß.

Es gelten also alle bekannten Rechenregeln für Wahrscheinlichkeiten, z.B.

$$\mathbb{P}(A^c | B) = 1 - \mathbb{P}(A | B)$$

oder

$$\mathbb{P}(A_1 \cup^+ A_2 | B) = \mathbb{P}(A_1 | B) + \mathbb{P}(A_2 | B)$$

(Achtung: nur für disjunkte Ereignisse.)

Achtung! Die Abbildung $B \mapsto \mathbb{P}(A | B)$ ist kein Wahrscheinlichkeitsmaß!

(Beweisen Sie dies selbständig, indem Sie z.B. Beispiele finden mit $\mathbb{P}(A | B) \neq 1 - \mathbb{P}(A | B^c)$ oder $\mathbb{P}(A | B_1 \cup B_2) \neq \mathbb{P}(A | B_1) + \mathbb{P}(A | B_2)$.)

Beispiel 3.4 Gedächtnislosigkeit der Exponentialverteilung (2025+2026 zsm.)

Parameter $z > 0$; Dichte :

$$f(x) = \begin{cases} ze^{-zx}, & x \geq 0 \\ 0, & \text{sonst} \end{cases}$$

$$\mathbb{P}(I) = \int_a^b f(x) dx \text{ für } I = (a, b] \subset [0, \infty)$$

Warteschleife beim Kundenservice als Exponentialverteilung

- Sie haben schon 10 Min gewartet ($t = 10$)
- **WS**, dass Sie noch **mindestens** weitere 10 Minuten warten?
($T = t + 10 = 20$)

Gesucht: $\mathbb{P}([T, a] | [t, \infty))$

$$\mathbb{P}([T, a] | [t, \infty)) = \frac{\mathbb{P}([T, a]) \cap \mathbb{P}([t, \infty))}{\mathbb{P}([t, \infty))} = \frac{\mathbb{P}([T, \infty))}{\mathbb{P}([t, \infty))}$$

Nebenrechnung:

$$\begin{aligned}
 \mathbb{P}([\tau, \infty)) &= \int_{\tau}^{\infty} z e^{-zx} dx \\
 &= \lim_{N \rightarrow \infty} \int_{\tau}^{\infty} z e^{-zx} dx \\
 &= \lim_{N \rightarrow \infty} (-e^{-zx}) \Big|_{x=\tau}^N \\
 &= \lim_{N \rightarrow \infty} [\underbrace{-e^{-zN}}_{\rightarrow_{N \rightarrow \infty} 0} + e^{-z\tau}] \\
 &= e^{-z\tau}
 \end{aligned}$$

Zurück zur Hauptrechnung:

$$\begin{aligned}
 \mathbb{P}([T, a] | [t, \infty)) &= \frac{\mathbb{P}([T, \infty))}{\mathbb{P}([t, \infty))} \\
 &\stackrel{NR}{=} \frac{e^{-zT}}{e^{-zt}} \\
 &= e^{-z(T-t)} \\
 &\stackrel{T=10+t}{=} e^{-zt} \\
 &\stackrel{NR}{=} \mathbb{P}([t, \infty))
 \end{aligned}$$

Regel 3.2 Neue Rechenregel: Sukzessives Bedingen (2025+2026 zsm.)

Aus der Definition der bedingten Wahrscheinlichkeit folgt

$$\mathbb{P}(A \cap B) = \mathbb{P}(A | B) \mathbb{P}(B) \quad \forall A, B \subseteq \Omega.$$

Da Multiplikation mit Null wieder Null ergibt, gilt diese Formel auch im Fall $\mathbb{P}(B) = 0$.

$$\mathbb{P}(B) = 0 \Rightarrow \mathbb{P}(A \cap B) \leq \mathbb{P}(B) = 0 \Rightarrow \mathbb{P}(A \cap B) = 0$$

Wiederholtes Anwenden zeigt

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_3 | A_1 \cap A_2) \mathbb{P}(A_1 \cap A_2)$$

und damit

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_3 | A_1 \cap A_2) \mathbb{P}(A_2 | A_1) \mathbb{P}(A_1)$$

für alle $A_1, A_2, A_3 \subseteq \Omega$.

Mit vollständiger Induktion beweist man die allgemeine Formel

$$\mathbb{P}(A_1 \cap A_2 \cap \dots \cap A_n) = \mathbb{P}(A_n | A_1 \cap \dots \cap A_{n-1}) \dots \mathbb{P}(A_2 | A_1) \mathbb{P}(A_1)$$

für alle $A_1, \dots, A_n \subseteq \Omega$.

Beispiel 3.5 Wie wahrscheinlich ist es, dass beim Skat jeder der drei Spieler genau ein As hat? (2025+2026 zsm.)

Modell

$$\Omega = \left\{ (S_1, S_2, S_3) : S_i \subseteq \{1, \dots, 32\}, |S_i| = 10 \forall i \in \{1, 2, 3\}, S_i \cap S_j = \emptyset \text{ für } i \neq j \right\}.$$

$(S_1, S_2, S_3) \in \Omega$ bedeute:

- Spieler i erhält die 10 Karten S_i , $i \in \{1, 2, 3\}$.
- Die übrigen 2 Karten

$$\{1, \dots, 32\} \setminus (S_1 \cup S_2 \cup S_3)$$

liegen im Skat.

- Die vier Asse seien die Karten mit den Nummern 1, 2, 3, 4.
- Gleichverteilung:

$$\mu(\omega) = \frac{1}{|\Omega|} = \frac{1}{\binom{32}{10} \binom{22}{10} \binom{12}{10}} \quad \forall \omega \in \Omega.$$

Rechnung Beispiel: Wie wahrscheinlich ist es, dass beim Skat alle genau ein As haben?

$$A_i = \{ |S_i \cap \{1, 2, 3, 4\}| = 1 \}, \quad i = 1, 2, 3$$

(Spieler i hat genau ein As)

$$A = A_1 \cap A_2 \cap A_3$$

(Jeder Spieler hat genau ein As)

$$\mathbb{P}(A) = \mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_1) \mathbb{P}(A_2 | A_1) \mathbb{P}(A_3 | A_1 \cap A_2) = \mathbb{P}(A_3 | A_1 \cap A_2) \mathbb{P}(A_2 | A_1) \mathbb{P}(A_1)$$

$$\mathbb{P}(A_1) = \frac{|A_1|}{|\Omega|} = \frac{\binom{4}{1} \binom{28}{9} \binom{22}{10} \binom{12}{10}}{\binom{32}{10} \binom{22}{10} \binom{12}{10}} = \frac{\binom{4}{1} \binom{28}{9}}{\binom{32}{10}}$$

$$\mathbb{P}(A_2 | A_1) = \frac{|A_1 \cap A_2|}{|A_1|} = \frac{\binom{4}{1} \binom{28}{9} \binom{3}{1} \binom{19}{9} \binom{12}{10}}{\binom{4}{1} \binom{28}{9} \binom{22}{10} \binom{12}{10}} = \frac{\binom{3}{1} \binom{19}{9}}{\binom{22}{10}}$$

$$\mathbb{P}(A_3 | A_1 \cap A_2) = \frac{|A_1 \cap A_2 \cap A_3|}{|A_1 \cap A_2|} = \dots = \frac{\binom{2}{1} \binom{10}{9}}{\binom{12}{10}}$$

Somit

$$\mathbb{P}(A) = \frac{\binom{4}{1} \binom{28}{9}}{\binom{32}{10}} \cdot \frac{\binom{3}{1} \binom{19}{9}}{\binom{22}{10}} \cdot \frac{\binom{2}{1} \binom{10}{9}}{\binom{12}{10}}$$

$$\mathbb{P}(A) \approx 0.056.$$

Definition 3.2 Formel von der totalen Wahrscheinlichkeit (2025+2026 zsm.)

Sei $(\Omega, \mathbb{P})$ ein Wahrscheinlichkeitsraum und (abzählbar viele B_i) $B_1, B_2, \dots \subseteq \Omega$ paarweise disjunkte Ereignisse mit

$$\bigcup_i B_i = \Omega.$$

Dann gilt

$$\mathbb{P}(A) = \sum_i \mathbb{P}(A \mid B_i) \mathbb{P}(B_i)$$

für alle Ereignisse $A \subseteq \Omega$.

Hinweis: $B_1, B_2, \dots$ ist eine Partition von Ω

Beweis (im einfachsten Fall). Für

$$\Omega = B_1 \cup^+ B_2, \quad B_1 \cap B_2 = \emptyset$$

(also $B_1 = B$ und $B_2 = B^c$) gilt

$$A = A \cap (B_1 \cup^+ B_2) = (A \cap B_1) \cup^+ (A \cap B_2).$$

Da die Ereignisse $A \cap B_1$ und $A \cap B_2$ disjunkt sind, folgt (über Rechenregeln für Wahrscheinlichkeiten)

$$\mathbb{P}(A) = \mathbb{P}(A \cap B_1) + \mathbb{P}(A \cap B_2) \quad (1)$$

und mit der Definition der bedingten Wahrscheinlichkeit

$$\mathbb{P}(A \cap B_i) = \mathbb{P}(A \mid B_i) \mathbb{P}(B_i), \quad i = 1, 2. \quad (2)$$

Einsetzen von (2) in (1) ergibt

$$\mathbb{P}(A) = \mathbb{P}(A \mid B_1) \mathbb{P}(B_1) + \mathbb{P}(A \mid B_2) \mathbb{P}(B_2).$$

Der allgemeine Fall geht vollkommen analog und verbleibt als Hausaufgabe.

Beispiel 3.6 Herr Zimmerlich und sein Regenschirm (2025+2026 zsm.)

Herr Zimmerlich hasst es, nass zu werden. Wenn der Wetterbericht Regen ankündigt, nimmt er seinen Schirm mit einer Wahrscheinlichkeit von 90% mit. (Die fehlenden 10% sind seiner Vergesslichkeit geschuldet.)

Auch wenn der Wetterbericht einen trockenen Tag verheißt, nimmt Herr Zimmerlich mit einer Wahrscheinlichkeit von 30% trotzdem seinen Schirm mit.

Dem feuchten Bielefelder Klima gemäß nehmen wir an, dass für 60% aller Tage Regen vorhergesagt wird.

Frage: Wie groß ist die Wahrscheinlichkeit, dass Herr Zimmerlich das Haus ohne Schirm verlässt?

Modellierung

$$\Omega = \{r, \bar{r}\} \times \{s, \bar{s}\} = \{(r, s), (\bar{r}, s), (r, \bar{s}), (\bar{r}, \bar{s})\}$$

Dabei sei $(r, \bar{s})$ das Elementarereignis, dass Regen vorhergesagt wurde und Herr Zimmerlich keinen Schirm mitnimmt, usw.

$$R = \{(r, s), (\bar{r}, s)\} \quad (\text{Regen vorhergesagt})$$

$$S = \{(r, s), (\bar{r}, s)\} \quad (\text{Schirm dabei})$$

$$\mathbb{P}(S \mid R) = \frac{9}{10}, \quad \mathbb{P}(S \mid R^c) = \frac{3}{10}, \quad \mathbb{P}(R) = \frac{6}{10}.$$

Gesucht:

$$\mathbb{P}(S^c).$$

Problem: Wie können wir diese „absolute“ Wahrscheinlichkeit aus den bedingten Wahrscheinlichkeiten bestimmen?

Lösung: Die Formel der totalen Wahrscheinlichkeit mit

$$\Omega = R \cup R^c$$

zeigt:

$$\mathbb{P}(S^c) = \mathbb{P}(S^c \mid R) \mathbb{P}(R) + \mathbb{P}(S^c \mid R^c) \mathbb{P}(R^c).$$

Nach Zurückführen auf die gegebenen Daten und Einsetzen erhalten wir

$$\begin{aligned} \mathbb{P}(S^c) &= [1 - \mathbb{P}(S \mid R)] \mathbb{P}(R) + [1 - \mathbb{P}(S \mid R^c)] [1 - \mathbb{P}(R)] \\ &= \left(1 - \frac{9}{10}\right) \frac{6}{10} + \left(1 - \frac{3}{10}\right) \left(1 - \frac{6}{10}\right) = \frac{34}{100}. \end{aligned}$$

Satz 3.1 Satz von Bayes (einfache Version) (2025+2026 zsm.)

Seien (Ω, μ) ein Wahrscheinlichkeitsraum und $A, B \subseteq \Omega$ Ereignisse mit $\mathbb{P}(B) > 0$.

Dann gilt

$$\mathbb{P}(A \mid B) = \mathbb{P}(B \mid A) \cdot \frac{\mathbb{P}(A)}{\mathbb{P}(B)}.$$

Beweis. Direkt nach Definition der bedingten Wahrscheinlichkeit gilt

$$\mathbb{P}(A \mid B) \mathbb{P}(B) = \mathbb{P}(A \cap B) = \mathbb{P}(B \mid A) \mathbb{P}(A).$$

Division durch $\mathbb{P}(B)$ ergibt die gesuchte Formel:

$$\mathbb{P}(A \mid B) = \mathbb{P}(B \mid A) \cdot \frac{\mathbb{P}(A)}{\mathbb{P}(B)}.$$

Beispiel 3.7 (2025+2026 zsm.)

Neue Frage:

Sie haben den Wetterbericht nicht gehört, aber Sie sehen, dass Herr Zimmerlich seinen Schirm dabei hat.

Wie groß ist die Wahrscheinlichkeit, dass für diesen Tag Regen vorhergesagt wurde?

Gesucht:

$$\mathbb{P}(R \mid S).$$

Problem: Wie können wir „Bedingungen umkehren“?

Lösung: Satz von Bayes / Bayes-Formel.

Lösung Nach dem Satz von Bayes (einfache Version) ist

$$\mathbb{P}(R \mid S) = \mathbb{P}(S \mid R) \cdot \frac{\mathbb{P}(R)}{\mathbb{P}(S)}.$$

Da

$$\mathbb{P}(S) = 1 - \mathbb{P}(S^c) = 1 - \frac{34}{100} = \frac{66}{100},$$

folgt

$$\mathbb{P}(R \mid S) = \frac{9}{10} \cdot \frac{\frac{6}{10}}{\frac{66}{100}} = \frac{9}{11}.$$

Satz 3.2 Satz von Bayes (allgemeine Version) (2025+2026 zsm.)

Sei $(\Omega, \mathbb{P})$ ein Wahrscheinlichkeitsraum, $B_1, B_2, \dots \subseteq \Omega$ Ereignisse mit

$$\bigcup_i^+ B_i = \Omega,$$

und $A \subseteq \Omega$ ein Ereignis mit $\mathbb{P}(A) > 0$.

Dann gilt für jedes i

$$\mathbb{P}(B_i \mid A) = \frac{\mathbb{P}(A \mid B_i) \mathbb{P}(B_i)}{\underbrace{\sum_j \mathbb{P}(A \mid B_j) \mathbb{P}(B_j)}_{\stackrel{*}{=} \mathbb{P}(A)}}.$$

* Satz der totalen WS

Beweis. Kombiniere die einfache Version des Satzes von Bayes

$$\mathbb{P}(B_i \mid A) = \mathbb{P}(A \mid B_i) \frac{\mathbb{P}(B_i)}{\mathbb{P}(A)}$$

mit der Formel von der totalen Wahrscheinlichkeit

$$\mathbb{P}(A) = \sum_j \mathbb{P}(A \mid B_j) \mathbb{P}(B_j).$$

Einsetzen von $\mathbb{P}(A)$ in die Bayes-Formel ergibt

$$\mathbb{P}(B_i \mid A) = \frac{\mathbb{P}(A \mid B_i) \mathbb{P}(B_i)}{\sum_j \mathbb{P}(A \mid B_j) \mathbb{P}(B_j)}.$$

Die Details sind eine Hausaufgabe.

KAPITEL 4

Zufallsvariablen und ihre Verteilung

Vorlesung 09.05.2025 (V04 2025)

Zufallsvariablen ermöglichen es uns nicht nur, Ereignisse übersichtlicher darzustellen, sondern sind auch das optimale Werkzeug, um in systematischer Weise von einem Wahrscheinlichkeitsraum mit vielen Elementarereignissen zu einem kleineren Wahrscheinlichkeitsraum zu wechseln.

Lernziele

■ Konzepte

- Zufallsvariablen als Abbildung und ihre Verteilung als Wahrscheinlichkeitsmaß
- Verteilungsfunktion
- gemeinsame Verteilung von Zufallsvariablen, Randverteilung, Randdichte

■ Fakten

- Eigenschaften von Verteilungsfunktionen
- Die gemeinsame Verteilung bestimmt die Randverteilungen.
- Die Umkehrung ist im allgemeinen falsch.

4.1 | Die Verteilung einer Zufallsvariablen

Beispiel 4.1 n-faches Werfen einer fairen Münze (2025)

$$\Omega_n = \{0, 1\}^n, \quad \mu_n(\{\omega\}) = \left(\frac{1}{2}\right)^n \quad \forall \omega \in \Omega \quad (\text{Gleichverteilung})$$

$\omega_i = 1$ bedeute "Kopf"

Falls es uns interessiert, wie oft "Kopf" fällt:

$$S_n(\omega) := \sum_{i=1}^n \omega_i \quad \text{ist Anzahl "Erfolge" (Kopf)}$$

$$S_n : \Omega_n \rightarrow \{0, 1, \dots, n\} \quad \text{Abbildung!}$$

Falls der relative Anteil der Erfolge relevant ist:

$$T_n : \Omega_n \rightarrow [0, 1]$$

$$T_n(\omega) := \frac{1}{n} S_n(\omega) = \frac{1}{n} \sum_{i=1}^n \omega_i \quad \forall \omega \in \Omega$$

Definition 4.1 ZV (2025)

Für einen Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$ und eine Menge $E \neq \emptyset$ nennen wir eine messbare Abbildung

$$X : \Omega \rightarrow E$$

eine E -wertige ZV.

Kommentar 4.1 Zu Definition 4.1: ZV ist keine Variable: Es ist eine Zuordnungsvorschrift der Stochastik, welche jedem möglichen Ergebnis eines Zufallsexperiments eine Größe zuordnet. Also das Ergebnis eines Zufallsexperiments.

Bemerkung 4.1 (Skript 26 - Bemerkung 3.3.)

Ist der Ereignisraum Ω abzählbar, so ist eine Zufallsvariable nichts anderes als eine Abbildung, die auf dem Ω des Wahrscheinlichkeitsraums definiert ist. Ist $\Omega \subseteq \mathbb{R}_d$, kommen eigentlich noch Messbarkeitsfragen hinzu, die wir im Rahmen dieser Vorlesung jedoch ignorieren wollen.

Wie wir bereits in Beispiel 4.1 gesehen haben, ist es praktisch, Ereignisse mit Hilfe von Zufallsvariablen auszudrücken. Wenn uns nur Ereignisse interessieren, die durch ein und dieselbe Zufallsvariable ausgedrückt werden können, so können wir sogar noch einen Schritt weitergehen und einen neuen Wahrscheinlichkeitsraum einführen, der nur noch solche Ereignisse kennt. Die folgende Definition ist ein erster Schritt in diese Richtung.

Definition 4.2 Bild- und Wertebereich einer Zufallsvariablen (Skript 26 - Definition 3.4.)

Sei $X : \Omega \rightarrow E$ eine E -wertige Zufallsvariable auf einem Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$. Dann heißt E der Wertebereich von X , und

$$X(\Omega) = \{X(\omega) : \omega \in \Omega\}$$

der Bildbereich von X .

Bemerkung 4.2 (Skript 26 - Bemerkung 3.5.)

Es gilt stets $X(\Omega) \subseteq E$. Der Bildbereich ist die kleinstmögliche Menge, die alle Werte enthält, die X annehmen kann.

St. Sn wie in Beispiel 4.1 die Anzahl der Erfolge in einem Zufallsexperiment der Länge $n \in \mathbb{N}$, so können wir Sn auffassen als Abbildung von Ω nach $E = \mathbb{N}_0$, aber auch als Abbildung nach $E = \{0, 1, \dots, n\}$ oder gar nach $E = \mathbb{R}$. Unabhängig davon, wie wir den Wertebereich E wählen, gilt für den Bildbereich stets $X(\Omega) = \{0, 1, \dots, n\}$.

Definition 4.3 Verteilung einer ZV (2025)

Sei X eine E -wertige ZV auf $(\Omega, \mathbb{P})$

$$\mathbb{P}_X(B) := \mathbb{P}(\{\omega \in \Omega : X(\omega) \in B\}) \quad \forall \text{ messbaren } B \subset E = \underbrace{\mathbb{P}(X \in B)}_{\text{Kurzschreibweise}}$$

Das Wahrscheinlichkeitsmaß $\mathbb{P}_X$ auf E heißt Verteilung von X .

Kommentar 4.2 Zu Definition 4.3: Die Verteilung von X beschreibt, wie die Werte von X verteilt sind, also wie wahrscheinlich verschiedene Ergebnisse von X sind.

Beispiel 4.2 Münzwurf (Skript 26 - Beispiel 3.7.)

todo

Bemerkung 4.3 (Skript 26 - Bemerkung 3.8.)

todo

Lemma 4.1 (2025)

Ist Ω abzählbar und $\mathbb{P}$ durch die Wahrscheinlichkeitsfunktion μ gegeben, so ist $\mathbb{P}_X$ ein Wahrscheinlichkeitsmaß.

Beweis.

$$\mu_X(e) = \mathbb{P}_X(\{e\}) = \mathbb{P}(X \in \{e\}) = \mathbb{P}(X = e) = \sum_{\substack{\omega \in \Omega \\ X(\omega) = e}} \mu(\omega) \geq 0$$

z.z. Normierung

$$\sum_{e \in E} \mu_X(e) = \sum_{e \in E} \sum_{\substack{\omega \in \Omega: \\ X(\omega) = e}} \mu(\omega) = \sum_{\substack{\omega \in \Omega: \\ e \in E: \\ X(\omega) = e}} \mu(\omega) = \sum_{\substack{\omega \in \Omega: \\ X(\omega) = e}} \mu(\omega) = \sum_{\omega \in \Omega} \mu(\omega) = 1$$

(Ausführlicher auf Seite 31 im Skript 26)

Korollar 4.1 Induzierter Wahrscheinlichkeitsraum (Skript 26 - Korollar 3.10.)

$(E, \mathbb{P}_X)$ ist ein Wahrscheinlichkeitsraum.

Beispiel 4.3 (Skript 26 - Beispiel 3.11.)

todo

4.2 | Notationen

(2025)

$$\mathbb{P}(X \in B) = \mathbb{P}(\{\omega \in \Omega : X(\omega) \in B\})$$

Falls B ein Intervall ist:

$$\mathbb{P}(X \geq b), \quad \mathbb{P}(a < X \leq b), \dots$$

Definition 4.4 Wertebereich (2025)

Geg.:

$$X : \Omega \rightarrow E \quad \text{ZV auf } (\Omega, \mathbb{P})$$

Dann heißt E der Wertebereich und $X(\Omega) := \{X(\omega) : \omega \in \Omega\}$ heißt Bildbereich.

Lemma 4.2 (Skript 26 - Lemma 3.13.)

todo

Beispiel 4.4 Zu Definition 4.4 (2025)

$$S_n : \Omega_n \rightarrow \{0, \dots, n\}$$

$$S_n : \Omega_n \rightarrow \mathbb{N}_0$$

Bemerkung 4.4 Zu Definition 4.4 (2025)

$X(\Omega) \subset E$ gilt immer.

Kommentar 4.3 Denn $X(\Omega)$ ist ein $\omega \in \Omega$ und jedes ω ist ein Element aus E .

Bemerkung 4.5 Zu Definition 4.4 (2025)

Gegeben ist ein Wahrscheinlichkeitsmaß auf $\tilde{\Omega}$, so existiert eine ZV, deren Verteilung genau dieses Wahrscheinlichkeitsmaß ist.

Sei $(\tilde{\Omega}, \tilde{\mathbb{P}})$ ein beliebiger Wahrscheinlichkeitsraum.

$X : \Omega \rightarrow \tilde{\Omega}$ definiert durch:

$$\begin{aligned}\Omega &:= \tilde{\Omega} \\ \mathbb{P} &:= \tilde{\mathbb{P}} \\ X(\omega) &= \omega \quad \text{Identität} \quad \forall \omega \in \Omega \\ (X \in B) &= \mathbb{P}(\underbrace{\{\omega \in \Omega : X(\omega) \in B\}}_{=B}) = \mathbb{P}(B) = \tilde{\mathbb{P}}(B)\end{aligned}$$

$\Rightarrow X$ hat Verteilung $\tilde{\mathbb{P}}$

Kommentar 4.4 Zu jedem Wahrscheinlichkeitsmaß auf einem Messraum existiert eine Zufallsvariable, die genau dieses Maß als Verteilung hat.

aka. Für jede vorgegebene Wahrscheinlichkeitsverteilung kann man ein Zufallsexperiment konstruieren, das diese Verteilung als Ergebnis hat.

Definition 4.5 (Skript 26 - Definition 3.14.)

todo

Beispiel 4.5 (Skript 26 - Beispiel 3.15.)

todo

Lemma 4.3 (Skript 26 - Lemma 3.17.)

todo

Lemma 4.4 (Skript 26 - Lemma 3.17.)

todo

4.3 | Zufallsvariablen mit abzählbarem Bildbereich

Hier fehlt was

Beispiel 4.6 Geometrische Verteilung (Skript 26 - Beispiel 3.18.)

todo

Bemerkung 4.6 (Skript 26 - Bemerkung 3.19.)

todo

Lemma 4.5 (Skript 26 - Lemma 3.20.)

todo

4.4 | Zufallsvariablen mit Dichte

Definition 4.6 Dichte **einer ZV** (2025)

Gegeben Dichte f

Bemerkung 4.7 (Skript 26 - Bemerkung 3.22.)

todo

Beispiel 4.7 (Skript 26 - Beispiel 3.23.)

todo

Beispiel 4.8 (Skript 26 - Beispiel 3.24.)

todo

Lemma 4.6 (Skript 26 - Lemma 3.25.)

todo

Lemma 4.7 (Skript 26 - Lemma 3.26.)

todo

4.5 | Mehrdimensionale Zufallsvariablen und ihre gemeinsame Verteilung: Abzählbare Bildbereiche

Definition 4.7 Indikatorfunktion bzw. charakteristische Funktion (Skript 26 - Definition 3.27.)

todo

Beispiel 4.9 (Skript 26 - Beispiel 3.28.)

todo

Definition 4.8 Gemeinsame Verteilung und Randverteilung von Zufallsvariablen (Skript 26 - Definition 3.29.)

todo

Bemerkung 4.8 (Skript 26 - Bemerkung 3.30.)

todo

Lemma 4.8 (Skript 26 - Lemma 3.31.)

todo

4.6 | Mehrdimensionale Zufallsvariablen und ihre gemeinsame Verteilung: Dichten

Beispiel 4.10 (Skript 26 - Beispiel 3.32.)

todo

Definition 4.9 **Mehrdimensionale Dichten** (Skript 26 - Definition 3.33.)

todo

Definition 4.10 **uniforme Verteilung** (Skript 26 - Definition 3.34.)

todo

Lemma 4.9 (Skript 26 - Lemma 3.35.)

todo

Definition 4.11 **Randdichte** (Skript 26 - Definition 3.34.)

todo

Unabhängigkeit und Bernoulli-Experimente

Vorlesung 16.05.2025 (V05 2025)

5.1 | Stochastische Unabhängigkeit von Ereignissen

Was bedeutet stochastische Unabhängigkeit?

Intuition: Zwei Ereignisse A und B sind unabhängig, wenn die Information des Eintretens des jeweils einen keinen Einfluss darauf hat, als wie wahrscheinlich wir ein Eintreten auch des jeweils anderen einschätzen (Bspw. mehrmals hintereinander Würfeln).

Formal: Um A und B unabhängig zu nennen, sollten also gelten (2025)

$$\mathbb{P}(B|A) = \mathbb{P}(B) \text{ und } \mathbb{P}(A|B) = \mathbb{P}(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

($\mathbb{P}(A|B)$: die bedingte Wahrscheinlichkeit von A gegeben B.) wobei jede dieser beiden Gleichungen äquivalent ist zu.

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$$

Also

$$\mathbb{P}(A|B) = \mathbb{P}(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \Leftrightarrow \mathbb{P}(A) \cdot \mathbb{P}(B) = \mathbb{P}(A \cap B)$$

$\mathbb{P}(A \cap B)$: WS, dass A und B gleichzeitig eintreten

Definition 5.1 Zwei Ereignisse $A, B \subseteq \Omega$ heißen unabhängig, wenn $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$.

Beispiel 5.1 TODO

Beobachtung 5.1 (2025)

unabhängig $\neq$ disjunkt! Also sind disjunkte Ereignisse unabhängig, wenn $0 = \mathbb{P}(\emptyset) = \mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$, also muss entweder $\mathbb{P}(A) = 0$ oder $\mathbb{P}(B) = 0$ sein (mindestens eines der Ereignisse WS Null haben):

$$0 = \mathbb{P}(\emptyset) = \mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B) \Leftrightarrow \mathbb{P}(A) = 0 \text{ oder } \mathbb{P}(B) = 0$$

Kommentar 5.1 disjunkte Ereignisse: $A \cap B = \emptyset \Rightarrow$ A und B können nicht gleichzeitig eintreten.
unabhängige Ereignisse: $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$

Beobachtung 5.2 (2025)

Es gilt: A, B unabhängig $\Leftrightarrow A, B^c$ unabhängig $\Leftrightarrow A^c, B^c$ unabhängig.

Beweis. z.z. $\mathbb{P}(A \cap B^c) = \mathbb{P}(A) \cdot \mathbb{P}(B^c)$

Siehe Folie 9

Beobachtung 5.3 A kann unabhängig von sich selbst sein. (2025)

$$\mathbb{P}(A) = \mathbb{P}(A \cap A) = \mathbb{P}(A) \cdot \mathbb{P}(A) = \mathbb{P}(A)^2 \Leftrightarrow \mathbb{P}(A) \in \{0, 1\}$$

Umgangssprachlicher gesagt: A kann unabhängig von sich selbst sein, wenn seine WS entweder 0 oder 1 ist.

Definition 5.2 Unabhängigkeit von n Ereignissen. (2025)

Die Ereignisse $A_1, \dots, A_n \subseteq \Omega$ heißen unabhängig, wenn

$$\mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}) = \mathbb{P}(A_{i_1}) \cdots \mathbb{P}(A_{i_k})$$

für alle $k = 2, \dots, n$ und alle Auswahlen von k verschiedenen Indizes $i_1, \dots, i_k \in \{1, \dots, n\}$. (Also alle Paare, Tripel, etc. prüfen.)

Beispiel 5.2 siehe Folie 14--15**Bemerkung 5.1** (2025)

Es genügt nicht, paarweise Unabhängigkeit zu prüfen! Sachen können paarweise unabhängig, aber nicht insgesamt unabhängig sein.

Bemerkung 5.2 (2025) Es genügt nicht, $\mathbb{P}(A_1 \cap \dots \cap A_n) = \mathbb{P}(A_1) \cdots \mathbb{P}(A_n)$ zu prüfen. Es kann insgesamt unabhängig sein, aber nicht paarweise etc. unabhängig.

5.2 | Unabhängige Nacheinanderausführung von Zufallsexperimenten

(2025) Sollen Zufallsexperimente $(\Omega_1, \mathbb{P}_1), \dots, (\Omega_n, \mathbb{P}_n)$ unabhängig nacheinander ausgeführt werden, so modellieren wir dies mit dem W-Raum $(\Omega, \mathbb{P})$ mit

$$\Omega = \Omega_1 \times \dots \times \Omega_n$$

und – im Fall, dass wir abzählbare Ω_i haben –

$$\mu(\omega) = \mu_1(\omega_1) \cdots \mu_n(\omega_n) \forall \omega = (\omega_1, \dots, \omega_n) \in \Omega$$

Sind nämlich $A_1 \subseteq \Omega_1, \dots, A_n \subseteq \Omega_n$, so sind bei dieser Wahl

$$B_1 = A_1 \times \Omega_2 \times \dots \times \Omega_n$$

$$B_2 = \Omega_1 \times A_2 \times \Omega_3 \times \dots \times \Omega_n$$

$$\vdots$$

$$B_n = \Omega_1 \times \dots \times \Omega_{n-1} \times A_n$$

B_1 bedeutet: Im ersten Experiment tritt A_1 ein, die anderen sind egal. unabhängig, denn für $k = 2, \dots, n$ und $i_1, \dots, i_k \in \{1, \dots, n\}$ verschieden gilt:

$$\underbrace{\mathbb{P}(B_{i_1} \cap \dots \cap B_{i_k})}_{= A_1 \times A_2 \times \dots \times A_n} = \mathbb{P}_{i_1} A_{i_1} \cdot \dots \cdot \mathbb{P}_{i_k} A_{i_k} = \mathbb{P}(B_{i_1}) \cdot \dots \cdot \mathbb{P}(B_{i_k}) \quad (5.1)$$

Beweis. Selbstständig (siehe Hinweis Folie 20)

Beispiel 5.3 Folie 21

Sind die Ω_i nicht alle abzählbar, so definieren wir $\mathbb{P}$ auf $\Omega = \Omega_1 \times \dots \times \Omega_n$

$$\mathbb{P}(A_1 \times \dots \times A_n) = \mathbb{P}_1(A_1) \cdot \dots \cdot \mathbb{P}_n(A_n) \quad \forall A_i \subseteq \Omega_i \forall i \quad (5.2)$$

motiviert durch Formel (5.1).

Bemerkung 5.3 (2025)

Formel (5.2) kann immer als Definition verwendet werden. Falls alle $\mathbb{P}_i$ durch WS μ_i gegeben sind, folgt aus Formel (5.2):

$$\begin{aligned} \mu((\omega_1, \dots, \omega_n)) &= \mathbb{P}(\{(\omega_1, \dots, \omega_n)\}) \\ &= \mathbb{P}(\{\omega_1\} \times \{\omega_2\} \times \dots \times \{\omega_n\}) \\ &\stackrel{(5.2)}{=} \mathbb{P}_1(\{\omega_1\}) \cdot \mathbb{P}_2(\{\omega_2\}) \cdot \dots \cdot \mathbb{P}_n(\{\omega_n\}) \\ &= \mu_1(\omega_1) \cdot \mu_2(\omega_2) \cdot \dots \cdot \mu_n(\omega_n) \end{aligned}$$

5.3 | Die Binomialverteilung

Definition 5.3 Einfaches Bernoulli-Experiment (2025)

Ein Bernoulli-Experiment ist ein Zufallsexperiment mit genau zwei möglichen Ergebnissen: Einem "Treffer" oder einer "Niete".

$\Omega_1 = \{0, 1\}$; $\omega = 1$ bedeutet Erfolg, $\omega = 0$ bedeutet Misserfolg.

$\mu_1(1) = p$, $\mu_1(0) = 1 - p$ und dabei heißt $p \in [0, 1]$ die Erfolgswahrscheinlichkeit.

Definition 5.4 Bernoulli-Experiment der Länge n

Wiederhole dasselbe einfache Bernoulli-Experiment n -mal unabhängig.

$$\Omega_n = \{0, 1\}^n, \mu_n((\omega_1, \dots, \omega_n)) = p^{\overbrace{\sum_{i=1}^n \omega_i}^{=k}} \cdot (1-p)^{n-\overbrace{\sum_{i=1}^n \omega_i}^{=k}}$$

$$\begin{aligned} \Omega_n &= \underbrace{\Omega_1 \times \dots \times \Omega_n}_{n\text{-mal}} \\ \mu_n((\omega_1, \dots, \omega_n)) &= \mu_1(\omega_1) \cdot \dots \cdot \mu_1(\omega_n) \quad \forall \omega \in \Omega_n \\ &= p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{n-\sum_{i=1}^n \omega_i} \end{aligned}$$

Definition 5.5 Binomialverteilung (2025)

Suche WS für genau k Erfolge in **Bernoulli-Experiment** der Länge n .

$$A_k = \{S_n = k\} = \{(\omega_1, \dots, \omega_n) \in \{0, 1\}^n : \underbrace{\sum_{i=1}^n \omega_i}_{S_n(\omega)} = k\}$$

$\binom{n}{k}$ Möglichkeiten, k Einsen auf die n Stellen zu verteilen.

$$\Rightarrow \mathcal{B}_{n,p}(k) := \mathbb{P}(A_k) = \binom{n}{k} p^k (1-p)^{n-k} \text{ für alle } k \in \{0, \dots, n\}$$

$\mathcal{B}_{n,p}(k)$ ist eine Wahrscheinlichkeitsfunktion auf $\Omega = \{0, \dots, n\}$, denn

$$\sum_{k=0}^n \mathcal{B}_{n,p}(k) = \sum_{k=0}^n \mathbb{P}(A_k) = \mathbb{P}(\cup_{k=0}^n A_k) = \mathbb{P}(\{0, 1\}^n) = 1$$

$\mathcal{B}_{n,p}$ heißt **Binomialverteilung** mit den Parametern n und p .

Eine ZV X , deren Verteilung $\mathbb{P}_X$ die $\mathcal{B}_{n,p}$ -Verteilung ist, heißt **binomialverteilt mit den Parametern n und p** .

Beispiel 5.4 Einfaches **Bernoulli-Experiment** Siehe Folie 29

Beispiel 5.5 **Bernoulli-Experiment** der Länge n Siehe Folie 29

Beispiel 5.6 Binomialverteilung : Siehe Folie 29

Problem 5.1 Wie wahrscheinlich ist, dass in einem **Bernoulli-Experiment** der Länge n der erste Erfolg im n -ten Versuch eintritt? (2025)

$$A_n = \{(0, \dots, 0, 1)\}, \quad \mathbb{P}(A_n) = \mu_n((0, \dots, 0, 1)) = p(1-p)^{n-1}$$

Definition 5.6 geometrische Verteilung mit Erfolgswahrscheinlichkeit p (2025)

Siehe Folie 33

Definition 5.7 Unabhängigkeit von ZV (2025)

Siehe Folie 35

Unabhängigkeiten von ZV

Vorlesung 23 Mai 2025 (V06 2025) und Vorlesung 22.05.2026 (V05 2026)

Beispiel 6.1 Die Randverteilungen legen die gemeinsame Verteilung nicht eindeutig fest (2026)

Wir werfen eine faire Münze zweimal. Die Ergebnisse der beiden Würfe sollen notiert werden.

Alex schreibt korrekt auf, während Kim einen Moment lang abgelenkt ist, dadurch das Ergebnis des zweiten Wurfs verpasst und als Notlösung einfach so tut, als hätten beide Würfe dasselbe Ergebnis gehabt.

Modellierung

$$\Omega = \{0, 1\}^2$$

mit Gleichverteilung $\mathbb{P}$.

Zufallsvariable

- Alex notiert den zweifachen Münzwurf

$X : \Omega \rightarrow \Omega$ mit $X = (X_1, X_2)$ wobei $X_1((\omega_1, \omega_2)) = \omega_1$ und $X_2((\omega_1, \omega_2)) = \omega_2$ für alle $\omega \in \Omega$
(das heißt, X ist die Identität auf Ω)

- Kim notiert nur den ersten Münzwurf

$Y : \Omega \rightarrow \Omega$ mit $Y = (Y_1, Y_2)$ wobei $Y_1((\omega_1, \omega_2)) = \omega_1$ und $Y_2((\omega_1, \omega_2)) = Y_1((\omega_1, \omega_2)) = \omega_1$ für alle $\omega \in \Omega$

$\mu_X((x_1, x_2))$	$x_2 = 0$	$x_2 = 1$	$\mu_{X_1}(x_1)$
$x_1 = 0$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$
$x_1 = 1$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$
$\mu_{X_2}(x_2)$	$\frac{1}{2}$	$\frac{1}{2}$	1
$\mu_Y((y_1, y_2))$	$y_2 = 0$	$y_2 = 1$	$\mu_{Y_1}(y_1)$
$y_1 = 0$	$\frac{1}{2}$	0	$\frac{1}{2}$
$y_1 = 1$	0	$\frac{1}{2}$	$\frac{1}{2}$
$\mu_{Y_2}(y_2)$	$\frac{1}{2}$	$\frac{1}{2}$	1

Offensichtlich sind die Randverteilungen von X und von Y gleich, während die gemeinsame Verteilung von Y_1 und Y_2 nicht dieselbe ist wie jene von X_1 und X_2 .

Beispiel 6.2 n-mal würfeln mit fairem Würfel (2025)

$\Omega\{1, \dots, 6\}^n$, ω_i das Ereignis des i-ten Wurfs. $\mathbb{P}$ gleichverteilt.

$X_i : \Omega \rightarrow \{1, \dots, 6\}$, $X_i(\omega) = \omega_i \quad \forall i \in \{1, \dots, 6\}$

z.z. $X_i, \dots, X_n$ unabhängig

$$\mathbb{P}(X_1 = k_1, \dots, X_n = k_n) \quad \text{für } k_i \in \{1, \dots, 6\}$$

$$\mathbb{P}(\{(k_1, \dots, k_n)\}) = \frac{1}{6^n}$$

$$\begin{aligned} \mathbb{P}(X_i = k_i) &= \mathbb{P}(X_1 \in \{1, \dots, 6\}, \dots, X_{i-1} \in \{1, \dots, 6\}, X_i = k_i, X_{i+1} \in \{1, \dots, 6\}, \dots, X_n \in \{1, \dots, 6\}) \\ &= \mathbb{P}(\{1, \dots, 6\}^{i-1} \times \dots) \\ &= \frac{6^{n-1}}{6^n} = \frac{1}{6} \end{aligned}$$

$$\mathbb{P}(X_1 = k_1, \dots, X_n = k_n) = \mathbb{P}(X_1 = k_1) \cdot \dots \cdot \mathbb{P}(X_n = k_n)$$

! jetzt müssen wir noch prüfen: Paare, Tripel, ... Danach: $X_1, \dots, X_n$ bewiesenermaßen unabhängig
Beispielsweise: $\Rightarrow \{x_1 \in \{2, 4, 6\}, \dots, \{x_4 \leq 4\}\}$ unabhängig

Frage: müssen wir die Paare und Tripel wirklich prüfen?

Karteikarte 6.1 Legen die Randverteilungen von Zufallsvariablen deren gemeinsame Verteilung eindeutig fest?

Nein, im Allgemeinen nicht. Zwei Zufallsvektoren können identische Randverteilungen haben, aber unterschiedliche gemeinsame Verteilungen (z.B. weil im einen Fall Unabhängigkeit vorliegt und im anderen nicht). Erst zusätzliche Information wie Unabhängigkeit legt die gemeinsame Verteilung eindeutig fest (vgl. Korollar zur Verteilungsfunktion)..

Satz 6.1 (2026) Seien $X_1, \dots, X_n$ unabhängig $\Rightarrow \mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \mathbb{P}(X_1 \in B_1) \cdot \dots \cdot \mathbb{P}(X_n \in B_n)$

Beweis. Um zu zeigen, dass

$$\mathbb{P}(X_1 \in B_1, X_3 = B_3) = \mathbb{P}(X_1 \in B_1) \cdot \mathbb{P}(X_3 = B_3)$$

gilt, wählen wir

$$B_2 = E_2, B_4 = E_4, \dots, B_n = E_n$$

Definition 6.1 Unabhängigkeit von Zufallsvariablen (2026)

Auf einem Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$ seien Zufallsvariablen $X_1, \dots, X_n$ gegeben mit $X_i : \Omega \rightarrow E_i$ für $i = 1, \dots, n$. Die Zufallsvariablen $X_1, \dots, X_n$ heißen unabhängig, wenn die Ereignisse

$$\{X_1 \in B_1\}, \dots, \{X_n \in B_n\}$$

für alle Wahlen von messbaren Mengen $B_i \subseteq E_i, i = 1, \dots, n$, unabhängig sind.

Diese Definition ist zunächst einmal abschreckend. Wir haben bereits gesehen, wie viele Bedingungen für den Nachweis der Unabhängigkeit von n Ereignissen zu prüfen sind. Und nun sollen wir diesen Aufwand auch noch für jede Wahl von B_i betreiben! Wir werden uns daher im folgenden darum bemühen, einfacher nachzuweisende Kriterien für Unabhängigkeit herzuleiten.

Als erstes halten wir fest, dass es im diskreten Fall genügt, einelementige Mengen B_i zu betrachten.

6.1 | Unabhängigkeit für Zufallsvariable mit abzählbarem Bildbereich

Kommentar 6.1 In 2025 und 2026 wurden diese Informationen verschieden formuliert. Hier befinden sich alle drei Versionen und eine zusammengeführte Version. Es handelt sich dabei um verschiedene Charakterisierungen der Unabhängigkeit (also es sind nur verschiedene Betrachtungsweisen des gleichen Umstands). Es sind danach auch noch weitere Charakterisierungen bzw. Konsequenzen zu finden.

Satz 6.2 Satz I. - Charakterisierung über Ereignisse (2025)

Seien $X_1, \dots, X_n$ ZV auf $(\Omega, \mathbb{P})$; X_i sei E_i -wertig.

Dann

$$X_1, \dots, X_n \text{ unabhängig} \Leftrightarrow \{X_1 = x_1\}, \dots, \{X_n = x_n\} \text{ unabhängig } \forall x_i \in E_i (i = 1, \dots, n)$$

Beweis. Siehe Folie 2 (2025)

Satz 6.3 Satz II. - Neuformulierung von Satz I. / Charakterisierung über Produktform (2025)

Haben $X_1, \dots, X_n$ abzählbare Werte-/Bildbereiche. Dann

$$X_1, \dots, X_n \text{ unabhängig} \Leftrightarrow \mu_{X_1, \dots, X_n}((x_1, \dots, x_n)) = \prod_{i=1}^n \mu_{x_i}(x_i)$$

Theorem 6.1 Unabhängigkeit für Zufallsvariable mit abzählbarem Bildbereich (2026)

Auf einem Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$ seien ZVs $X_1, \dots, X_n$ mit abzählbarem Bildbereich gegeben. Dann sind $X_1, \dots, X_n$ genau dann unabhängig, wenn die Ereignisse

$$\{X_1 = x_1\}, \dots, \{X_n = x_n\}$$

für alle $x_i \in X_i(\Omega), i = 1, \dots, n$ unabhängig sind.

Beweis. Siehe Skript S. 58.

Kommentar 6.2 Gemeinsam haben alle drei Formulierungen:

$$X_1, \dots, X_n \text{ sind ZVs auf Wahrscheinlichkeitsraum } (\Omega, \mathbb{P})$$

Verschieden formuliert sind:

$$\text{“haben abzählbare Werte-/Bildbereiche”} \Leftrightarrow X_i \text{ sei } E_i\text{-wertig}$$

und

$$X_1, \dots, X_n \text{ unabhängig} \Leftrightarrow \underbrace{\text{wenn die Ereignisse } \{X_1 = x_1\}, \dots, \{X_n = x_n\} \text{ für alle } x_i \in X_i(\Omega), i = 1, \dots, n \text{ unabhängig sind.}}_{\mu_{X_1, \dots, X_n}((x_1, \dots, x_n)) = \prod_{i=1}^n \mu_{x_i}(x_i)} \underbrace{\{X_1 = x_1\}, \dots, \{X_n = x_n\} \text{ unabhängig } \forall x_i \in E_i (i = 1, \dots, n)}$$

Korollar 6.1 Konsequenz aus Satz 6.3 (2026)

Abzählbarer Bildbereich

Es genügt

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_1 = x_1) \cdot \dots \cdot \mathbb{P}(X_n = x_n) \forall x_i \in X_i(\Omega)$$

zu zeigen, um Unabhängigkeit von $X_1, \dots, X_n$ zu zeigen.

Satz 6.4 Charakterisierung über die Produktform der Verteilungsfunktion (2026)

$X_1, \dots, X_n$ unabhängig

$$\begin{aligned} \Leftrightarrow \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) &= \mathbb{P}(X_1 \leq a_1) \cdots \mathbb{P}(X_n \leq a_n) \\ &= F_{X_1}(a_1) \cdots F_{X_n}(a_n) \quad \forall a_i \in \mathbb{R} \end{aligned}$$

Korollar 6.2 Konsequenz aus Satz 6.4 (2025)

$X_1, \dots, X_n$ unabhängig $\Leftrightarrow$ gemeinsame Verteilung eindeutig bestimmt durch (Rand-)Verteilungen von $X_1, \dots, X_n$
Aka.:

$X_1, \dots, X_n$ unabhängig $\Rightarrow$ gemeinsame Verteilung von $X_1, \dots, X_n$ eindeutig bestimmt durch die Randverteilung

Bemerkung 6.1 Zu Korollar 6.2 (2025)

Das Korollar sagt uns, wie wir unabhängige Zufallsvariablen mit Zähldichte modellieren.
Ohne Unabhängigkeit ist das nicht der Fall!

Bemerkung 6.2 Erinnerung an mathematisches Kriterium für Unabhängigkeit (2026)

Wie haben gesehen, dass Unabhängigkeit bereits gezeigt ist, wenn $\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_1 = x_1) \cdots \mathbb{P}(X_n = x_n) \forall x_i \in E_i (i = 1, \dots, n)$ gilt. Wenn also die Produktform existiert. (Es ist nicht erforderlich $X_{i_1}, \dots, X_{i_k}$ separat zu betrachten.)

Bemerkung 6.3 Anwendung des mathematischen Kriteriums für Unabhängigkeit (2025)

(a) Wenn wir die Produktform finden: Beweis der Unabhängigkeit Wenn man also zeigen kann $\mathbb{P}_{X_1, \dots, X_n} = \prod_i \mathbb{P}_{X_i}$

Umkehridee:

(b) Gegeben Verteilung der X_i : Wir nutzen die Produktform, um die gemeinsame Verteilung für unabhängig X_i zu bestimmen. Also wenn die X_i unabhängig sind und die Randverteilungen bekannt sind, dann kann man die gemeinsame Verteilung berechnen durch

$$\mathbb{P}_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_i \mathbb{P}_{X_i}(x_i)$$

Karteikarte 6.2 Wie ist Unabhängigkeit von Zufallsvariablen $X_1, \dots, X_n$ allgemein (mit $X_i : \Omega \rightarrow E_i$) definiert?

$X_1, \dots, X_n$ heißen unabhängig, wenn für alle messbaren Mengen $B_i \subseteq E_i$ ($i = 1, \dots, n$) die Ereignisse $\{X_1 \in B_1\}, \dots, \{X_n \in B_n\}$ (im Sinne der Unabhängigkeit von Ereignissen) unabhängig sind, d.h. $P(X_1 \in B_1, \dots, X_n \in B_n) = P(X_1 \in B_1) \cdots P(X_n \in B_n)$ für alle Wahlen von $B_1, \dots, B_n$.

Karteikarte 6.3 Satz I: Wie lässt sich Unabhängigkeit von $X_1, \dots, X_n$ über einelementige Ereignisse charakterisieren?

$X_1, \dots, X_n$ unabhängig $\Leftrightarrow \{X_1 = x_1\}, \dots, \{X_n = x_n\}$ sind unabhängig für alle $x_i \in E_i$ ($i = 1, \dots, n$). Man muss also nicht beliebige messbare Mengen B_i prüfen, sondern es genügt, einzelne Werte zu betrachten..

Karteikarte 6.4 Satz II: Wie charakterisiert man Unabhängigkeit von $X_1, \dots, X_n$ mit abzählbaren Bildbereichen über die Produktform?

$X_1, \dots, X_n$ unabhängig $\Leftrightarrow p_{X_1, \dots, X_n}((x_1, \dots, x_n)) = \prod_{i=1}^n p_{X_i}(x_i)$ für alle $(x_1, \dots, x_n)$, d.h. die gemeinsame Zähldichte zerfällt in das Produkt der Randdichten..

Karteikarte 6.5 Welche einzelne Gleichung genügt, um Unabhängigkeit von $X_1, \dots, X_n$ mit abzählbarem Bildbereich zu zeigen?

Es genügt zu zeigen: $P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1) \cdots P(X_n = x_n)$ für alle $x_i \in X_i(\Omega)$. Man muss NICHT zusätzlich Paare, Tripel etc. separat prüfen — die Produktform für alle n -Tupel gleichzeitig reicht hier aus..

Karteikarte 6.6 Wie lässt sich Unabhängigkeit von $X_1, \dots, X_n$ über die (gemeinsame) Verteilungsfunktion charakterisieren?

$X_1, \dots, X_n$ unabhängig $\Leftrightarrow P(X_1 \leq a_1, \dots, X_n \leq a_n) = P(X_1 \leq a_1) \cdots P(X_n \leq a_n) = F_{X_1}(a_1) \cdots F_{X_n}(a_n)$ für alle $a_1, \dots, a_n \in \mathbb{R}$. Diese Charakterisierung funktioniert unabhängig davon, ob die X_i diskret sind oder eine Dichte haben..

Karteikarte 6.7 Was folgt aus Unabhängigkeit von $X_1, \dots, X_n$ für die gemeinsame Verteilung?

Sind $X_1, \dots, X_n$ unabhängig, so ist ihre gemeinsame Verteilung eindeutig durch die Randverteilungen von $X_1, \dots, X_n$ bestimmt. Ohne Unabhängigkeit gilt das nicht (siehe Alex/Kim-Beispiel: gleiche Randverteilungen, verschiedene gemeinsame Verteilung)..

Karteikarte 6.8 Muss man bei der Anwendung des Produktform-Kriteriums $X_{i_1}, \dots, X_{i_k}$ noch separat betrachten?

Nein. Gilt $P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1) \cdots P(X_n = x_n)$ für alle x_i , so ist damit die Unabhängigkeit von $X_1, \dots, X_n$ bereits vollständig gezeigt — es ist nicht nötig, Teilkollektionen (Paare, Tripel, ...) separat zu prüfen..

Karteikarte 6.9 Welche zwei Anwendungsrichtungen hat das Produktform-Kriterium für Unabhängigkeit?

(a) Beweisrichtung: Findet man die Produktform $p_{X_1, \dots, X_n} = \prod_i p_{X_i}$, so ist Unabhängigkeit gezeigt. (b) Konstruktionsrichtung: Sind die Randverteilungen der X_i bekannt und sollen die X_i unabhängig sein, so erhält man die gemeinsame Verteilung als Produkt der Randverteilungen: $p_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_i p_{X_i}(x_i)$..

6.1.1 | Poisson-Verteilte ZV

Satz 6.5 Summe unabhängiger Poisson-verteilter ZV ist wieder Poisson-verteilt. (2025)

Seien X_1, X_2 unabhängig und Poisson-verteilt mit

$$\mu_{x_1}(k) = \mathbb{P}(X_1 = k) = \frac{z_1^k}{k!} e^{-z_1} \quad (z_1 > 0) \forall k \in \mathbb{N}_0$$

$$\mu_{x_2}(k) = \mathbb{P}(X_2 = k) = \frac{z_2^k}{k!} e^{-z_2} \quad (z_2 > 0) \forall k \in \mathbb{N}_0$$

Dann gilt: $X_1 + X_2$ ist Poisson-Verteilt mit Parameter $z_1 + z_2$.

Kommentar 6.3 $X_1 + X_2$ nehmen beide Werte aus $\mathbb{N}_0$ an, also ist die Summe auch in $\mathbb{N}_0$.

Beweis. Siehe auch Folie 6--7 2025

$X_1 + X_2$ ist poisson verteilt mit Parameter $z_1 + z_2$

$$\begin{aligned}
 \mu_{X_1+X_2}(n) &= \mathbb{P}(X_1 + X_2 = n) \quad \text{für } n \in \mathbb{N}_0 \\
 &= \mathbb{P}\left(\bigsqcup_{k_1=0}^n \{X_1 = k_1, X_2 = n - k_1\}\right) \\
 &= \sum_{k_1=0}^n \mathbb{P}(X_1 = k_1, X_2 = n - k_1) \\
 &= \sum_{k_1=0}^n \mathbb{P}(X_1 = k_1) \mathbb{P}(X_2 = n - k_1) && \text{da unabhängig} \\
 &= \sum_{k_1=0}^n \frac{z_1^{k_1}}{k_1!} e^{-z_1} \frac{z_2^{n-k_1}}{(n-k_1)!} e^{-z_2} \\
 &= \sum_{k=0}^n \frac{n!}{k!(n-k)!} z_1^k z_2^{n-k} && \text{durch herausziehen von } \left[\frac{1}{n!} e^{-(z_1+z_2)}\right] \\
 &= \frac{(z_1 + z_2)^n}{n!} e^{-(z_1+z_2)}
 \end{aligned}$$

Karteikarte 6.10 Was gilt für die Summe zweier unabhängiger, Poisson-verteilter Zufallsvariablen X_1, X_2 mit Parametern λ_1, λ_2 ?

$X_1 + X_2$ ist wieder Poisson-verteilt, und zwar mit Parameter $\lambda_1 + \lambda_2$. Beweisidee: $P(X_1 + X_2 = n) = \sum_{k=0}^n P(X_1 = k)P(X_2 = n - k)$ (Unabhängigkeit), Einsetzen der Poisson-Zähldichten und Anwenden des Binomischen Lehrsatzes liefert $\frac{(\lambda_1 + \lambda_2)^n}{n!} e^{-(\lambda_1 + \lambda_2)}$.

6.2 | ZV mit Dichten

Satz 6.6 Satz III.: Unabhängigkeiten von ZV (mit und ohne Dichte) (2025)

Seien $X_1, \dots, X_n$ unabhängig $\Leftrightarrow \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) = \mathbb{P}(X_1 \leq a_1) \cdot \dots \cdot \mathbb{P}(X_n \leq a_n) = \mathcal{F}_{x_1}(a_1) \cdot \dots \cdot \mathcal{F}_{x_n}(a_n) \forall a_1, \dots, a_n \in \mathbb{R}$.

Beweis. Siehe Folie 8

Satz 6.7 Satz IV. (2025, ergänzt 2026)

$X_1, \dots, X_n$ mit Dichten $f_1, \dots, f_n$. Dann gilt: $X_1, \dots, X_n$ unabhängig $\Leftrightarrow$ gemeinsame Dichte hat Produktform $\Leftrightarrow (x_1, \dots, x_n) \mapsto f((x_1, \dots, x_n)) := f_1(x_1) \cdot \dots \cdot f_n(x_n)$ eine gemeinsame Dichte von $X_1, \dots, X_n$ ist.

Bemerkung 6.4 Zu Satz 6.7 (2026)

- Existenz der gem. **Dichte** ist nicht vorausgesetzt. Gegeben $X_1, \dots, X_n$ mit Dichten $f_1, \dots, f_n$

- Setze

$$f(x_1, \dots, x_n) := f_1(x_1) \cdots f_n(x_n) = \prod_{i=1}^n f_i(x_i) \quad \forall x_i \in \mathbb{R} (i = 1, \dots, n) \quad (6.1)$$

Aussage des Satzes ist: $X_1, \dots, X_n$ unabhängig $\Leftrightarrow f$ gem. **Dichte** von $X_1, \dots, X_n$ ist

- $X_1, \dots, X_n$ mit Dichten $f_1, \dots, f_n$. Modelliere unabhängige Experimente durch gemeinsame **Dichte** (6.1).
- Gegen eine gem. **Dichte** f für $X_1, \dots, X_n$ berechne Randdichten $f_{x_1}, \dots, f_{x_n}$.
Gilt Gleichung (6.1)? Falls ja: $X_1, \dots, X_n$ unabhängig. Falls (6.1) für $(x_1, \dots, x_n)$ aus einer Menge $\subseteq \mathbb{R}^n$ gilt mit $\mathbb{R}^n \setminus M$ abzählbar, dann gilt Unabhängigkeit

Kommentar 6.4 Vorsicht: Eine Wahrscheinlichkeitsdichte ist nur “fast überall” eindeutig.

Also: Die Produktform muss nicht an jedem einzelnen Punkt gelten. Es genügt, wenn sie fast überall gilt.

Karteikarte 6.11 Wie charakterisiert man Unabhängigkeit von $X_1, \dots, X_n$ mit Dichten $f_1, \dots, f_n$?

$X_1, \dots, X_n$ unabhängig $\Leftrightarrow$ die gemeinsame Dichte hat Produktform, d.h. $f(x_1, \dots, x_n) := f_1(x_1) \cdots f_n(x_n)$ ist eine gemeinsame Dichte von $X_1, \dots, X_n$.

Karteikarte 6.12 Muss die Existenz einer gemeinsamen Dichte bei Satz IV vorausgesetzt werden, und wie genau muss die Produktform gelten?

Nein, man setzt einfach $f(x_1, \dots, x_n) := f_1(x_1) \cdots f_n(x_n)$ und prüft, ob dies eine gemeinsame Dichte von $X_1, \dots, X_n$ ist. Eine Dichte ist nur “fast überall” eindeutig — die Produktform muss also nicht für jeden einzelnen Punkt gelten, es reicht, wenn sie auf einer Menge $M \subseteq \mathbb{R}^n$ gilt, deren Komplement abzählbar (bzw. vom Maß Null) ist..

6.3 | Widerlegen von Unabhängigkeiten

Bemerkung 6.5 Es genügt nicht einen Punkt zu finden, in dem (6.1) nicht gilt. (2025)

Wir brauchen eine Menge $D \subseteq \mathbb{R}^n$ mit $|D| = Z(D) > 0$, so dass (6.1) auf D nicht gilt.

Einfacher: Zeigen, dass $\mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) \neq \prod_{i=1}^n F_{x_i}(a_i)$.

Zeigen Sie, dass die Produktform **nicht** gilt auf Quader oder verwenden Sie die (nicht geltende) Produktform der Verteilungsfunktion.

Kommentar 6.5 Zu Bemerkung 6.5:

$\mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) \neq \prod_{i=1}^n F_{x_i}(a_i)$ bedeutet, die gemeinsame Verteilungsfunktion faktorisiert nicht. Das ist gemeint mit “verwenden Sie die (nicht geltende) Produktform der Verteilungsfunktion”, denn da $F_{X_1, \dots, X_n}(a_1, \dots, a_n) = \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n)$ gilt, ist das die Negation der Produktform der Verteilungsfunktion.

Kommentar 6.6 Zu Bemerkung 6.5:

Die Produktform der Verteilungsfunktion wird auf sogenannten “Quadern” geprüft. Damit sind Mengen der Form

$$(-\infty, a_1] \times \cdots \times (-\infty, a_n] \subseteq \mathbb{R}^n$$

gemeint.

Für den Zufallsvektor $(X_1, \dots, X_n)$ entspricht ein solcher Quader dem Ereignis

$$\{X_1 \leq a_1, \dots, X_n \leq a_n\}.$$

Die gemeinsame Verteilungsfunktion ist daher gerade

$$F_{X_1, \dots, X_n}(a_1, \dots, a_n) = \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n).$$

Sind $X_1, \dots, X_n$ unabhängig, so zerfällt diese Wahrscheinlichkeit in ein Produkt:

$$\mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) = \prod_{i=1}^n \mathbb{P}(X_i \leq a_i) = \prod_{i=1}^n F_{X_i}(a_i).$$

Man sagt dann:

Die Verteilungsfunktion besitzt Produktform auf Quadern.


Um zu zeigen, dass Zufallsvariablen nicht unabhängig sind, genügt es daher, einen Quader zu finden, für den diese Produktform nicht gilt.

Danke an ChatGPT [?] (Überprüft)

Kommentar 6.7 Bei Bild Tafel link ganz unten reicht es an einem Punkt zu zeigen, weil wir da ganze Mengen benutzt haben. Okay ????

Beispiel 6.3 uniform. verteilung auf Rechteck (2026)

Sei (X, Y) ein zufälliger Punkt in $\mathbb{R}$ (uniforme Verteilung)



(X, Y) hat (gem.) Dichte $f(x, y) = \chi_R(x, y) \frac{1}{a \cdot b} \quad \forall (x, y) \in \mathbb{R}^2$ Randdichten:

$$f_X(x) = \chi_{[0,a]}(x) \int_0^b \underbrace{f(x, y)}_{\frac{1}{a \cdot b}} dy = \frac{1}{a} \chi_{[0,a]}(x)$$

$$f_Y(y) = \frac{1}{b} \chi_{[0,b]}(y)$$

$$\begin{aligned} f(x, y) &= \chi_{[0,a] \times [0,b]}(x, y) \frac{1}{a \cdot b} \\ &= f_X(x) f_Y(y) \end{aligned}$$


schlauer:

$$f(x, y) = \chi_{\mathbb{R}}(x, y) \frac{1}{a \cdot b} = \frac{1}{a} \underbrace{\chi_{[0,a]}(x)}_{\text{Randdichte von } X} \cdot \frac{1}{b} \underbrace{\chi_{[0,b]}(y)}_{\text{Randdichte von } Y}$$

Wir müssen die Randdichten gar nicht berechnen! X, Y unabhängig

Kommentar 6.8 wenn man sieht die Dichte zerfällt in x und y Argument muss man nicht integrieren, sondern nur schauen, dass die Funktionen (?) das richtige Gewicht haben. OK. Gerald fragen...

Beispiel 6.4 Dreieck (2026)



Sei (X, Y) ein zufälliger Punkt **gleichverteilt** im Dreieck D .

Gleichverteilt bedeutet: Dichte ist konstant auf D und 0 außerhalb.

$$\begin{aligned} f(x, y) &= \frac{1}{|D|} \chi_D(x, y) \\ &= 2 \chi_D(x, y) \\ &= \begin{cases} 2 & 0 \leq y \leq x \leq 1 \\ 0 & \text{sonst} \end{cases} \end{aligned}$$

Randdichten: (Man “integriert die andere Variable weg”)

$$\begin{aligned} f_X(x) &= \chi_{[0,1]}(x) \int_{-\infty}^{\infty} f(x, y) dy \\ &= \chi_{[0,1]}(x) \int_0^x 2 dy = 2x \chi_{[0,1]}(x) \\ f_Y(y) &= \dots = 2(1-y) \chi_{[0,1]}(y) \end{aligned}$$

Wenn X, Y unabhängig wären, dann würde gelten :

$$f(x, y) = f_X(x) f_Y(y) \tag{6.2}$$

Einsetzen ergibt:

$$\begin{aligned} f(x, y) &= 2 \cdot \chi_D(x, y) \\ &\stackrel{?}{=} f_X(x) f_Y(y) \\ &= 2x2(1-y) \chi_{[0,1]}(x, y) \end{aligned}$$

Wir sehen: Für $(x, y) \in [0, 1]^2 \setminus D$ gilt $f(x, y) = 0$, also “rechte Seite” > 0 .

Keine Unabhängigkeit. Für Erklärung siehe Kommentar 6.10.

Alternative: Statt Dichten zu vergleichen, kann man Unabhängigkeit auch testen über:

$$\mathbb{P}(X \leq a, Y \leq b) \stackrel{?}{=} F_X(a) F_Y(b)$$

Explizit: Berechne F_X und F_Y , zeige, dass es **einen** Punkt $(a, b) \in \mathbb{R}^2$ gibt mit

$$\mathbb{P}(X \leq a, Y \leq b) \neq F_X(a) F_Y(b).$$

Kommentar 6.9 Symbole und Terme in Beispiel 6.4

■ $\chi_D(x, y) = \text{Indikatorfunktion}$:

$$\chi_D(x, y) = \begin{cases} 1 & (x, y) \in D \\ 0 & \text{sonst} \end{cases}$$

■ $|D| = \text{Fläche des Dreiecks}$ (hier: $|D| = \frac{1}{2}$)

■ $f(x, y) = \text{gemeinsame Dichte von } (X, Y)$

■ $f_X(x)$ beschreibt die Verteilung von X alleine

■ $f_Y(y)$ beschreibt die Verteilung von Y alleine

Kommentar 6.10 Für $(x, y) \in [0, 1]^2 \setminus D$ gilt $f(x, y) = 0$ weil in der Dichtefunktion oben explizit festgelegt wird, dass es außerhalb des Dreiecks 0 ist und $[0, 1]^2 \setminus D$ ist alles außer das Dreieck.

Also ist die “rechte Seite” $f_X(x) f_Y(y)$ aus 6.2).

Diese ist > 0 , denn x kann 0 sein (siehe Bild ??, 0 ist der innerste Randpunkt von “außerhalb des Dreiecks”) und y kann 1 sein (analog äußerster Randpunkt von “außerhalb des Dreiecks”). Aber da es Randpunkte sind, haben sie keinen Einfluss auf die Dichte, denn Punkte haben keine Fläche und somit keine relevante “Menge”. Also kann man diese Punkte wegnorieren und einfach sagen $x > 0$ und $y < 1$. Und wenn man das annimmt, dann erhält man:

$$f_X(x)f_Y(y) = 4x(1-y)\chi_{[0,1]^2}(x, y)$$

Denn wir haben ja oben ausgerechnet, dass $f_X(x) = 2x\chi_{[0,1]}(x)$ und $f_Y(y) = 2(1-y)\chi_{[0,1]}(y)$, INSOERN X und Y unabhängig sind.

Weil aber $y < 1$ gilt, muss $1 - y > 0$ sein, also

$$\underbrace{4 \underbrace{x}_{>0} \underbrace{(1-y)}_{>0}}_{>0}$$

Das ist dann ein Widerspruch damit, dass jeder Punkt außerhalb des Dreiecks $f(x, y) = 0$ hat. Wir haben einen Punkt außerhalb des Dreiecks betrachtet, und der hatte $f_X(x)f_Y(y) > 0$. Also $f(x, y) \neq f_X(x)f_Y(y)$, was äquivalent ist zu “ X und Y sind NICHT unabhängig”.

Kommentar 6.11 Zu Beispiel 6.4

Warum reicht ein einzelner Punkt zur Widerlegung? Wenn Unabhängigkeit gilt, muss die Gleichung für *alle* (a, b) gelten. Findet man *einen einzigen* Punkt (a, b) mit Ungleichheit, ist Unabhängigkeit widerlegt.

Unabhängigkeit ist eine globale Eigenschaft und ein Gegenbeispiel genügt, um sie zu zerstören.”

Karteikarte 6.13 Reicht ein einzelner Punkt, an dem die Produktform der Dichte nicht gilt, um Unabhängigkeit zu widerlegen?

Nein. Um Unabhängigkeit über die Dichte zu widerlegen, braucht man eine Menge $D \subseteq \mathbb{R}^n$ mit positivem (Lebesgue-)Maß $|D| > 0$, auf der die Produktform $f = f_1 \cdots f_n$ nicht gilt — ein einzelner Punkt hat Maß Null. Einfacher ist es meist, stattdessen zu zeigen, dass die Produktform der Verteilungsfunktion $P(X_1 \leq a_1, \dots, X_n \leq a_n) \neq \prod_i F_{X_i}(a_i)$ an einem einzigen Punkt $(a_1, \dots, a_n)$ verletzt ist — dort genügt bereits ein Punkt, da die Verteilungsfunktion (anders als die Dichte) punktweise eindeutig ist..

Karteikarte 6.14 Was ist ein “Quader” im Kontext der Verteilungsfunktion, und was bedeutet “Produktform auf Quadern”?

Ein Quader ist eine Menge der Form $(-\infty, a_1] \times \cdots \times (-\infty, a_n] \subseteq \mathbb{R}^n$, dem Ereignis $\{X_1 \leq a_1, \dots, X_n \leq a_n\}$ entsprechend. Sind $X_1, \dots, X_n$ unabhängig, so zerfällt $F_{X_1, \dots, X_n}(a_1, \dots, a_n) = P(X_1 \leq a_1, \dots, X_n \leq a_n)$ in $\prod_i F_{X_i}(a_i)$ — man sagt, die Verteilungsfunktion hat Produktform auf Quadern. Um Nicht-Unabhängigkeit zu zeigen, genügt es, einen Quader zu finden, für den diese Produktform verletzt ist..

Karteikarte 6.15 Muss man bei einer gemeinsamen Dichte immer erst die Randdichten f_X, f_Y berechnen, um Unabhängigkeit zu zeigen?

Nein. Lässt sich die gemeinsame Dichte bereits direkt als Produkt zweier Funktionen schreiben, von denen eine nur von x und die andere nur von y abhängt (und die jeweils zu einer Dichte normiert sind, d.h. Integral 1 ergeben), so sind diese Funktionen automatisch die Randdichten und die Unabhängigkeit folgt sofort aus der Faktorisierung — ohne die Randdichten separat auszurechnen..

Karteikarte 6.16 Ein typisches Muster, an dem man Abhängigkeit bei Dichten erkennt: Was passiert, wenn der Träger der gemeinsamen Dichte kein Rechteck (Produktmenge) ist?

Hängt der Wertebereich einer Variable vom Wert der anderen ab (der Träger der gemeinsamen Dichte ist also keine Produktmenge $A \times B$, sondern z.B. ein Dreieck), so kann die gemeinsame Dichte nicht als Produkt zweier eindimensionaler Funktionen geschrieben werden: es gibt stets Punkte außerhalb des Trägers, an denen $f = 0$ gilt, während $f_X(x)f_Y(y) > 0$ wäre — die Zufallsvariablen sind dann nicht unabhängig..

Karteikarte 6.17 Warum genügt ein einziger Gegenpunkt/Gegenquader, um Unabhängigkeit zu widerlegen?

Weil Unabhängigkeit verlangt, dass die Produktformel für ALLE Argumente (alle $a_1, \dots, a_n$ bzw. – bei Dichten – auf einer Menge vollen Maßes) gilt. Findet man EINEN Punkt bzw. Quader, an dem die Gleichheit verletzt ist, ist die Allaussage widerlegt. Unabhängigkeit ist also eine globale Eigenschaft, und ein einziges Gegenbeispiel genügt, um sie zu zerstören..

Definition 6.2 **Faltung** (2026)

X, Y unabhängig **ZV**. Dann heißt die Verteilung der Summe **Faltung** (der Verteilungen).

Karteikarte 6.18 Was versteht man unter der Faltung zweier unabhängiger Zufallsvariablen X, Y ?

Die Verteilung der Summe $X + Y$ zweier unabhängiger Zufallsvariablen X, Y heißt Faltung (der Verteilungen von X und Y)..

KAPITEL 7

Erwartungswert und Varianz von Zufallsvariablen

Vorlesung 30. Mai 2025 (V07 2025) und 05. Juni 2026 (V07 2026)

Lernziele

Konzepte

- Erwartungswert einer Zufallsvariablen (gewichteter Mittelwert)
- Varianz als weitere Kennzahl

Fakten

- Zwei verschiedene Darstellungen des Erwartungswerts.
- Der Erwartungswert ist linear.

Wissen

- Existenz des Erwartungswerts prüfen können.
- Spezialfall: $X(\Omega)$ ist eine endliche Menge (insbesondere erfüllt, wenn Ω endlich ist).
- Spezialfall: $X \geq 0$.
- Erwartungswerte berechnen können.
- Erwartungswert und Varianz für die wichtigsten Verteilungen kennen
- Erwartungswert von Produkten zum Widerlegen von Unabhängigkeit
- Erwartungswert von Produkten bei Unabhängigkeit berechnen können
- Markov-Ungleichung kennen und anwenden können

Grundgedanke

(2025) Die Verteilung charakterisiert eine ZV X eindeutig (Im Sinne ihrer statistischen Eigenschaften: Wir können Wahrscheinlichkeiten berechnen wie z.B. $\mathbb{P}(X \geq 2)$, und diese Wahrscheinlichkeiten hängen nur von der Verteilung ab, nicht von der Wahl des Wahrscheinlichkeitsraums $(\Omega, \mathbb{P})$).

Sind X und Y zwei ZVs mit derselben Verteilung, so gilt

$$\mathbb{P}(X \in A) = \mathbb{P}_X(A) = \mathbb{P}_Y(A) = \mathbb{P}(Y \in A)$$

für jedes A .

Es ist nicht immer klar, welche Verteilung zu einem sinnvollen Modell führt. Auch sind die Parameter der Verteilung nicht unbedingt bekannt. Siehe (2026)

■ **Binomialverteilung:**

$$\mathcal{B}_{n,p}(k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k \in \{0, \dots, n\}.$$

■ **Geometrische Verteilung:**

$$G_p(n) = p(1-p)^{n-1}, \quad n \in \mathbb{N}.$$

■ **Poisson-Verteilung:**

$$P_\lambda(k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k \in \mathbb{N}_0.$$

■ **Exponentialverteilung:**

$$f(x) = \omega e^{-\lambda x} \chi_{[0,\infty)}(x), \quad x \in \mathbb{R}.$$

Wie können wir trotzdem Vorhersagen treffen?

Dies führt uns in die Statistik (später).

Typische Fragestellungen: Wie ...*im Mittel*? (2025)

- Wie groß ist der mittlere Gewinn bei einem Glücksspiel?
- Wie lange muss man bei einem wiederholten Zufallsexperiment im Mittel warten, bis ein bestimmtes Ereignis eintritt?
- Wie viele weitere Personen steckt eine infizierte Person im Mittel an?

Beispiel 7.1 Ansteckungen (2026)

- Die **Basisreproduktionszahl** R_0 gibt an, wie viele Personen eine infizierte Person im Mittel ansteckt, wenn es in der Bevölkerung keine Immunität gibt. Gemäß RKI gilt:

$$R_0 \in [2.8, 3.8]$$

(vor möglicherweise ansteckenderen Mutationen).

- Die **zeitabhängige Reproduktionszahl**

$$R = R(t)$$

berücksichtigt Effekte durch Hygienemaßnahmen, Impfungen und Immunität. Sie gibt an, wie viele Personen eine infizierte Person in einem Zeitfenster gegebener Länge im Mittel ansteckt.

- Die **Inzidenz** setzt Neuinfektionen in Relation zur Bevölkerungsgröße. Die *7-Tage-Inzidenz* gibt beispielsweise an, wie viele neu infizierte Personen es in den vergangenen sieben Tagen pro 100 000 Einwohner gegeben hat.

Beispiel 7.2 1 × Würfeln mit einem fairen Würfel (2025)

Da herrscht eine Gleichverteilung, daher ist die erwartete Augenzahl ist das arithmetische Mittel.

$$\Omega = \{1, \dots, 6\}$$

mit Gleichverteilung $\mathbb{P}$.

Die Zufallsvariable

$$X : \Omega \rightarrow \mathbb{R}, \quad X(\omega) = \omega,$$

besitzt das Bild

$$X(\Omega) = \{1, \dots, 6\} \subseteq \mathbb{R}.$$

Für einen fairen Würfel ist der Erwartungswert die mittlere Augenzahl, also das arithmetische Mittel:

$$E[X] = \frac{1 + 2 + 3 + 4 + 5 + 6}{6} = 3.5.$$

Die erwartete Augenzahl entspricht der mittleren Zahl von Schritten, die man in einem Würfelspiel pro Wurf vorwärtsgehen würde.

Beispiel 7.3 Spiel, bei dem nicht alle Ausgänge gleichwahrscheinlich sind (2025)

1 × Würfeln eines fairen Würfels

Auszahlung:

- k Euro, falls 2 gewürfelt
- 6 Euro, falls 2, $\dots$, 6 gewürfelt
- $\Omega = \{1, \dots, 6\}$ mit Gleichverteilung $\mathbb{P}$.

$\Omega = \{1, \dots, 6\}$ mit Gleichverteilung $\mathbb{P}$

Die Auszahlung wird beschrieben durch die ZV Y mit

$$Y(\omega) = k \cdot \chi_{\{1\}}(\omega) + 6 \cdot \chi_{\{2, \dots, 6\}}(\omega) \quad \forall \omega \in \Omega$$

Erwartete Auszahlung als arithmetisches Mittel:

$$\mathbb{E}[Y] = \sum_{\omega \in \Omega} Y(\omega) \mu(\omega) = \frac{k + 5 \cdot 6}{6} = 6 \cdot \frac{5}{6} + k \cdot \frac{1}{6} = 6 \cdot \mathbb{P}(Y = 6) + k \cdot \mathbb{P}(Y = k) = \sum_{I \in Y(\Omega)} I \cdot \mathbb{P}(Y = I)$$

Definition 7.1 (2025) Der Erwartungswert einer ZV X mit abzählbarem Bildbereich $X(\Omega) \in \mathbb{R}$ ist gegeben durch

$$\mathbb{E}[X] = \mathbb{E}X = \sum_{x \in X(\Omega)} x \cdot \mathbb{P}(X = x)$$

insofern die Reihe absolut konvergiert, also $\sum_{x \in X(\Omega)} |x| \cdot \mathbb{P}(X = x) < \infty$.

Wir sprechen in diesem Fall von der Existenz des Erwartungswerts.

Der Erwartungswert einer ZV X mit einer Dichte f ist gegeben durch

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x) dx = \lim_{N \rightarrow \infty} \int_{-N}^N x f(x) dx$$

insofern $\int_{-\infty}^{\infty} |x| f(x) dx < \infty$.

Wir sprechen in diesem Fall von der Existenz des Erwartungswerts.

Hinweis: Für Dichten f , die gerade Funktionen sind, gilt $\int_{-N}^N x f(x) dx = 0$ für alle N , auch wenn der Erwartungswert ggf. gar nicht existiert.

Bemerkung 7.1 (2026) Absolute Konvergenz der Reihe, die den Erwartungswert definiert, garantiert, dass wir die Summanden beliebig umsortieren dürfen. Es gilt daher

$$\mathbb{E}[X] \stackrel{\text{Def.}}{=} \sum_{x \in X(\Omega)} x \mathbb{P}(X = x) = \sum_{x \in \Omega} X(\omega) \mu(\omega)$$

sofern eine der Reihen absolut konvergent ist. (Vgl. obiges Bsp. mit dem Spiel.)

Wenn Ω oder $X(\Omega)$ endlich ist, so existiert der Erwartungswert automatisch.

Nimmt X nur nichtnegative Werte an, können wir einfach anfangen, den Erwartungswert auszurechnen, weil

$$\sum_{x \in X(\Omega)} |x| \mathbb{P}(X = x) = \sum_{x \in X(\Omega)} x \mathbb{P}(X = x)$$

bzw.

$$\int_{-\infty}^{\infty} |x| f(x) dx = \int_{-\infty}^{\infty} x f(x) dx = \int_0^{\infty} x f(x) dx$$

Beispiel 7.4 Erwartungswert der Poisson-Verteilung (2026)

X Poisson-verteilt, d.h., es existiert ein $\lambda > 0$ mit

$$\mu_X(k) = \mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} \quad \text{für alle } k \in \mathbb{N}_0 = \{0, 1, 2, 3, \dots\}$$

Der Erwartungswert existiert, weil die folgende Rechnung ein endliches Ergebnis hat:

(Wir verwenden in dieser Argumentation, dass X nur nichtnegative Werte hat, d.h., $X \geq 0$.)

$$\begin{aligned} \mathbb{E}[X] &\stackrel{*1}{=} \sum_{k=0}^{\infty} k \mathbb{P}(X = k) \\ &\stackrel{*2}{=} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \sum_{k=1}^{\infty} k \cdot \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} e^{-\lambda} \\ &= \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \\ &= \lambda e^{-\lambda} \underbrace{\sum_{l=0}^{\infty} \frac{\lambda^l}{l!}}_{=e^{\lambda}} \\ &= \lambda \end{aligned}$$

$$*1 \quad X(\Omega) = \mathbb{N}_0$$

$$*2 \quad \mathbb{P}(X = k) = \mu_X(k) = \dots$$

Beispiel 7.5 Erwartungswert der geometrischen Verteilung (2026)

Wie lange müssen wir im Mittel warten, bis der erste Erfolg eintritt? (Zum Beispiel bis zur ersten Sechse beim Werfen eines fairen Würfels? – Raten Sie!)

X geometrisch verteilt mit Erfolgswahrscheinlichkeit $p \in (0, 1)$, d.h.,

$$\mu_X(k) = \mathbb{P}(X = k) = p(1-p)^{k-1} \quad \text{für alle } k \in \mathbb{N}_0 = \{0, 1, 2, 3, \dots\}$$

Der Erwartungswert existiert, weil die folgende Rechnung ein endliches Ergebnis hat (Wir verwenden wieder, dass $X \geq 0$).

$$h(x) = x^k \Rightarrow h'(x) = kx^{k-1}$$

$$\begin{aligned} \mathbb{E}[X] &\stackrel{*1}{=} \sum_{k=1}^{\infty} k p (1-p)^{k-1} \\ &= p \sum_{k=1}^{\infty} \left(\frac{d}{dx} x^k \right) \Big|_{x=1-p} \\ &\stackrel{*2}{=} p \frac{d}{dx} \sum_{k=1}^{\infty} (x^k) \Big|_{x=1-p} \\ &= p \frac{d}{dx} \sum_{k=0}^{\infty} (x^k) \Big|_{x=1-p} \\ &= p \frac{d}{dx} \left(\frac{1}{1-x} \right) \Big|_{x=1-p} \\ &= p \frac{1}{(1-x)^2} \Big|_{x=1-p} \\ &= \frac{1}{p} \end{aligned}$$

*1 Definition Erwartungswert

*2 gilt, weil gliedweises Differenzieren einer Potenzreihe im Innern ihres Konvergenzradius zulässig ist

Beispiel 7.6 Erwartungswert der uniformen Verteilung auf $[a, b]$ (2026)

(Raten. – Warum ist der Erwartungswert $(a+b)/2$?)

Der Erwartungswert existiert, weil... Denn: Zu prüfen ist: $\int_{-\infty}^{\infty} |x|f(x) dx < \infty$ für $f(x) = \frac{1}{b-a}\chi_{[a,b]}(x)$.

Hier ist $f(x) = 0$ außerhalb eines kompakten Intervalls (abgeschlossen und beschränkt).

$$\int_{-\infty}^{\infty} |x|f(x) dx = \int_a^b \frac{|x|}{b-a} dx \leq \int_a^b \frac{\max\{|a|, |b|\}}{b-a} dx = \max\{|a|, |b|\} \cdot 1 < \infty$$

...f stetig ist auf dem kompakten Intervall $[a, b]$ und $f = 0$ außerhalb des Intervalls $[a, b]$ gilt.

$$\mathbb{E}[X] = \int_a^b x \frac{1}{b-a} dx = \frac{1}{2(b-a)} x^2 \Big|_{x=a}^b = \frac{b^2 - a^2}{2(b-a)} = \underbrace{\frac{a+b}{2}}_*$$

* Mittelpunkt des Intervalls

Erinnerung: $\int_a^b x dx = \frac{x^2}{2} \Big|_{x=a}^b$

Beispiel 7.7 Erwartungswert der Exponentialverteilung (2026)

Erinnerung:

$$F(x) := -e^{-\alpha x}, \quad F'(x) := \alpha e^{-\alpha x}, \quad \mathbb{E}[X] = \frac{1}{\alpha}$$

Der Erwartungswert existiert genau dann, wenn die folgende Berechnung einen endlichen Wert ergibt (was der Fall ist, wir verwenden wieder, dass $X \geq 0$):

$$\begin{aligned} \mathbb{E}[X] &= \int_0^\infty \underbrace{x}_{\downarrow} \underbrace{\alpha e^{-\alpha x}}_{\uparrow} dx \\ &= - \lim_{N \rightarrow \infty} \underbrace{x e^{-\alpha x}}_{=0} \Big|_{x=0}^N + \int_0^\infty \underbrace{1 \cdot e^{-\alpha x}}_{=f(x) \cdot \frac{1}{\alpha}} dx \\ &= 0 + \frac{1}{\alpha} \underbrace{\int_{-\infty}^\infty f(x) dx}_{=1} \\ &= \frac{1}{\alpha}^* \end{aligned}$$

$$\begin{aligned} *f(x) &= \alpha e^{-\alpha x} \chi_{[0, \infty)}(x) \\ \Rightarrow \int_0^\infty e^{-\alpha x} dx &= \frac{1}{\alpha} \int_0^\infty \alpha e^{-\alpha x} dx \\ &= \frac{1}{\alpha} \int_{-\infty}^\infty f(x) dx \\ &= \frac{1}{\alpha} \end{aligned}$$

Satz 7.1 Der Erwartungswert ist linear (2026)

Geg. ZVs $X : \Omega \rightarrow \mathbb{R}$ und $Y : \Omega \rightarrow \mathbb{R}$ auf $(\Omega, \mathbb{P})$; Konstanten $a, b \in \mathbb{R}$.

Annahme: $\mathbb{E}[X]$ und $\mathbb{E}[Y]$ existieren.

Dann gelten $aX + bY$ ist ebenfalls eine Zufallsvariable. Der Erwartungswert von $aX + bY$ existiert und berechnet sich als

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

Beweis (für Zufallsvariable mit abzählbarem Bildbereich) Nehmen wir zunächst an, der Erwartungswert von $aX + bY$ existiert. Dann dürfen alle Reihen beliebig umsortiert werden:

$$\begin{aligned} \mathbb{E}[aX + bY] &= \sum_{\omega \in \Omega} [aX(\omega) + bY(\omega)] \mu(\omega) \\ &= a \sum_{\omega \in \Omega} X(\omega) \mu(\omega) + b \sum_{\omega \in \Omega} Y(\omega) \mu(\omega) \\ &= a\mathbb{E}[X] + b\mathbb{E}[Y] \end{aligned}$$

Eine analoge Rechnung mit Betragszeichen und Abschätzungen zeigt die Existenz des Erwartungswerts:

$$\sum_{\omega \in \Omega} \underbrace{|aX(\omega) + bY(\omega)|}_{\leq |a||X(\omega)| + |b||Y(\omega)|} \mu(\omega) \leq |a| \underbrace{\sum_{\omega \in \Omega} |X(\omega)| \mu(\omega)}_{< \infty \text{ unab. Ver.}} + |b| \underbrace{\sum_{\omega \in \Omega} |Y(\omega)| \mu(\omega)}_{< \infty \text{ unab. Ver.}} < \infty$$

da nach Voraussetzung $\mathbb{E}[X]$ und $\mathbb{E}[Y]$ existieren.

Beispiel 7.8 Augensumme bei mehrfachem Würfeln mit fairem Würfel (2026)

$$\Omega = \{1, \dots, 6\}^n$$

mit Gleichverteilung P .

Für $i = 1, \dots, n$ sei

$$X_i(\omega) = \omega_i,$$

wobei $\omega = (\omega_1, \dots, \omega_n) \in \Omega$.

Die Zufallsvariable

$$X = \sum_{i=1}^n X_i$$

beschreibt die Augensumme (Und X_i das Ergebnis des i -ten Wurfs) .

Berechnung der erwarteten Augensumme für zweimaliges Würfeln ($n = 2$):

Direkt über die Verteilung:

$$E[X] = \sum_{i=2}^{12} i \mathbb{P}(X_1 + X_2 = i) = \dots$$

was etwas aufwendig ist.

Alternativ:

$$\begin{aligned} E[X] &= \sum_{\omega \in \Omega} (X_1(\omega) + X_2(\omega)) \mu(\omega) \\ &= \frac{1}{36} \sum_{\omega_1, \omega_2=1}^6 [\omega_1 + \omega_2] \\ &= \frac{1}{36} \sum_{\omega_1=1}^6 \sum_{\omega_2=1}^6 (\omega_1 + \omega_2) \\ &= \frac{1}{36} \left[6 \sum_{\omega_1=1}^6 \omega_1 + 6 \sum_{\omega_2=1}^6 \omega_2 \right] \\ &= \frac{1}{36} (6 \cdot 21 + 6 \cdot 21) = 7. \end{aligned}$$

Mit der Linearität des Erwartungswertes erhält man sofort:

$$E[X] = E[X_1] + E[X_2] = 2 \cdot 3,5 = 7.$$

Dies verallgemeinert sich unmittelbar auf n -maliges Würfeln:

$$E[X] = E[X_1 + \dots + X_n] = E[X_1] + \dots + E[X_n] = n \cdot \frac{7}{2}.$$

Beispiel 7.9 Binomialverteilung $\mathbb{E}[X] = n \cdot p$ (2026)

$$X(\Omega) = \{0, \dots, n\}, \quad \#X(\Omega) = n + 1 < \infty$$

- X sei binomialverteilt mit den Parametern n und p .
- Der Erwartungswert* von X existiert, da der Bildbereich von X endlich ist.

erwartete Anzahl an Erfolgen in einem n -fach unabhängig wiederholten Bernoulli-Experiment

1. Versuch (mit binomischer Formel und etwas Geschick)

$$\mathbb{E}[X] = \sum_{k=0}^n k \underbrace{\binom{n}{k} p^k (1-p)^{n-k}}_{=\mathbb{P}(X=x)} = \dots$$

2. Versuch Wähle

$$\Omega = \{0, 1\}^n.$$

Die Anzahl der Erfolge lässt sich darstellen als

$$X = \sum_{i=1}^n X_i,$$

wobei

$$X_i(\omega) = \omega_i.$$

Für jede Indikatorvariable gilt

$$E[X_i] = 0 \cdot \mathbb{P}(X_i = 0) + 1 \cdot \mathbb{P}(X_i = 1) = p.$$

Mit der Linearität des Erwartungswertes folgt unmittelbar:

$$E[X] = \sum_{i=1}^n \underbrace{E[X_i]}_{=p} = \sum_{i=1}^n p = np.$$

Beispiel 7.10 St. Petersburg Paradoxon (Erwartungswert muss nicht existieren) (2026)

Ein Casino möchte folgendes Spiel anbieten: Eine faire Münze wird geworfen, bis zum ersten Mal Kopf erscheint. Passiert dies beim n -ten Wurf, so sei die Auszahlung $X = 2^n$

$$\Omega = \mathbb{N}, \quad \mu(n) = p(1-p)^{n-1}, \quad p = \frac{1}{2}.$$

Die Zufallsvariable $X : \Omega \rightarrow \mathbb{R}$ sei definiert durch $X(n) = 2^n$ (Auszahlung) für alle $n \in \Omega$

$$\mu_X(2^n) = \mathbb{P}(\underbrace{X = 2^n}_{\text{Kopf erstmalig im } n\text{-ten Wurf}}) = \mu(n) = p(1-p)^{n-1} = 2^{-n}, \quad n \in \Omega = \mathbb{N}.$$

$$\mu(n) = \left(\frac{1}{2}\right)^n = 2^{-n} \quad \forall n \in \Omega = \mathbb{N}$$

Was wäre ein fairer Einsatz für dieses Spiel? (Wir nennen den Einsatz fair, wenn der Einsatz gleich der erwarteten Auszahlung ist.)

Wir suchen also $\mathbb{E}[X]$

$X \geq 0$, EW existiert genau dann, wenn Rechnung endliches Ergebnis hat

Nun ist jedoch

$$\sum_{n=1}^{\infty} 2^n \mathbb{P}(X = 2^n) = \sum_{n=1}^{\infty} 2^n \mu_X(2^n) = \sum_{n=1}^{\infty} 2^n 2^{-n} = \sum_{n=1}^{\infty} 1 = \infty$$

Der Erwartungswert existiert also nicht. Ein fairer Einsatz kann nicht bestimmt werden.

Erinnerung 7.1 (2026)

Aus Satz (E), d.h. der Linearität des Erwartungswertes, folgen:

$$\mathbb{E}[aX] = a\mathbb{E}[X] \quad \text{und} \quad \mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$$

für $a \in \mathbb{R}$ und $\mathbb{R}$ -wertige X und Y mit existierendem Erwartungswert

Frage 7.1 (2026) Gilt auch $\mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y]$?

Spezialfall $X = Y$: $\mathbb{E}[E^2] = (\mathbb{E}[X])^2$.

Gilt das?

Beispiel 7.11 (2026) Es gibt Zufallsvariablen X, Y mit

$$\mathbb{E}[X \cdot Y] \neq \mathbb{E}[X] \cdot \mathbb{E}[Y].$$

Wähle

$$\mathbb{P}(X = +1) = \mathbb{P}(X = -1) = \frac{1}{2}$$

und

$$Y = X.$$

Dann gilt

$$\mathbb{E}[X] = \mathbb{E}[Y] = 0$$

und

$$\mathbb{E}[XY] = \mathbb{E}[X^2] = \mathbb{E}[1] = 1.$$

Satz 7.2 Satz (P) (2026)

Seien

$$X : \Omega \rightarrow \mathbb{R} \quad \text{und} \quad Y : \Omega \rightarrow \mathbb{R}$$

zwei unabhängige Zufallsvariablen, deren Erwartungswerte existieren.

Dann existiert auch der Erwartungswert von $X \cdot Y$, und es gilt

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y].$$

Beweis.

Schritt 1: Wir nehmen zunächst an, dass der Erwartungswert von $X \cdot Y$ existiert.

Wir beginnen mit der folgenden Darstellung. Für $z \neq 0$ gilt: ($xy = z$)

$$\begin{aligned} \mathbb{P}(XY = z) &= \sum_{y \neq 0}^* \mathbb{P}(XY = z \mid Y = y) \mathbb{P}(Y = y) \\ &= \sum_{y \neq 0} P\left(X = \frac{z}{y} \mid Y = y\right) \mathbb{P}(Y = y) \\ &= \sum_{y \neq 0} P\left(X = \frac{z}{y}\right) \mathbb{P}(Y = y), \end{aligned}$$

da X und Y unabhängig sind.

$$\mathbb{P}(X \cdot Y = z) = \sum_{y \in Y(\Omega)} \mathbb{P}(X \cdot Y = z, Y = y) \stackrel{z \neq 0}{=} \sum_{y \in Y(\Omega), y \neq 0} \mathbb{P}(X \cdot Y = z \mid Y = y) \cdot \mathbb{P}(Y = y)$$

Aus

$$\mathbb{P}(XY = z) = \sum_{y \neq 0} P\left(X = \frac{z}{y}\right) \mathbb{P}(Y = y), \quad z \neq 0,$$

folgt

$$\begin{aligned}\mathbb{E}[XY] &= \sum_{z \in XY(\Omega), z \neq 0} z \mathbb{P}(XY = z) \\ &= \sum_{z \neq 0} \sum_{y \neq 0} \frac{z}{y} y P\left(X = \frac{z}{y}\right) \mathbb{P}(Y = y) = \sum_{y \neq 0} \sum_{x \neq 0} xy \mathbb{P}(X = x) \mathbb{P}(Y = y) = \left(\sum_{y \neq 0} y \mathbb{P}(Y = y)\right) \left(\sum_{x \neq 0} x \mathbb{P}(X = x)\right) = \mathbb{E}[X] \cdot \mathbb{E}[Y].\end{aligned}$$

Schritt 2: Eine analoge Rechnung zeigt die Existenz des Erwartungswerts:

Satz 7.3 **Kurzfassung Satz (P)** (2026)

$$X, Y \text{ unabhängig mit ex. EW} \implies \mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y].$$

Beispiel 7.12 (2026)

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$$

impliziert nicht, dass X und Y unabhängig sind.

- Definiere Hilfszufallsvariablen X_1 und Y_1 , unabhängig mit

$$\mathbb{P}(X_1 = 0) = \mathbb{P}(X_1 = 1) = \frac{1}{2}$$

und

$$\mathbb{P}(Y_1 = 0) = \mathbb{P}(Y_1 = 1) = \frac{1}{2}.$$

- Setze

$$X := X_1 + Y_1, \quad Y := |X_1 - Y_1|.$$

Beobachtungen

- Bildbereiche:

$$X(\Omega) = \{0, 1, 2\}, \quad Y(\Omega) = \{0, 1\}.$$

-

$$Y = 0 \iff X_1 = Y_1 \iff X \in \{0, 2\}.$$

-

$$Y = 1 \iff X_1 \neq Y_1 \iff X = 1.$$

X und Y sind nicht unabhängig.

$$\mathbb{P}(X = 1, Y = 0) = 0,$$

da

$$\{X = 1, Y = 0\} = \emptyset.$$

Andererseits gilt

$$\mathbb{P}(X = 1) = 2 \cdot \frac{1}{4} > 0$$

und

$$\mathbb{P}(Y = 0) = 2 \cdot \frac{1}{4} > 0.$$

Dennoch gilt $\mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y]$.

$$\begin{aligned}\mathbb{E}[XY] &= 0 \cdot \mathbb{P}(XY = 0) + 1 \cdot \mathbb{P}(XY = 1) + 2 \cdot \mathbb{P}(XY = 2) \\ &= 0 + \mathbb{P}(X = 1) + 0 \\ &= \frac{1}{2}.\end{aligned}$$

Außerdem

$$\begin{aligned}\mathbb{E}[X] \mathbb{E}[Y] &= (\mathbb{E}[X_1] + \mathbb{E}[Y_1]) \mathbb{P}(Y = 1) \\ &= 2 \mathbb{E}[X_1] \mathbb{P}(X = 1) \\ &= 2 \cdot \frac{1}{2} \cdot \frac{1}{2} \\ &= \frac{1}{2}.\end{aligned}$$

Bemerkung 7.2 (2026)

Der Satz kann nicht nur zum Berechnen von Erwartungswerten von Produkten unabhängiger Zufallsvariablen verwendet werden, sondern kann auch benutzt werden, um zu zeigen, dass zwei Zufallsvariablen nicht unabhängig sein können, wenn der Erwartungswert des Produkts der Zufallsvariablen nicht ins Produkt der einzelnen Erwartungswerte zerfällt.

Definition 7.2 Zusammengesetzte Zufallsvariablen (2026)

Eine Zufallsvariable $X : \Omega \rightarrow \mathbb{R}$ und eine messbare Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$ können zusammengesetzt werden zu einer neuen Zufallsvariablen:

$$Y(\omega) = (f \circ X)(\omega) = f(X(\omega))$$

$$Y(\omega) = f(X(\omega)) \quad \forall \omega$$

Satz 7.4 (2026)

Sofern der Erwartungswert $\mathbb{E}[Y]$ existiert, gilt

$$\mathbb{E}[Y] = \sum_{x \in X(\Omega)} f(x) \mathbb{P}(X = x)$$

bzw., falls X Dichte d hat und EW von Y gleich $f(x)$ existiert

$$\mathbb{E}[Y] = \int_{-\infty}^{\infty} f(x) d(x) dx$$

Beweis.

$$\begin{aligned}\mathbb{E}[Y] &= \sum_{y \in Y(\Omega)} y \mathbb{P}(Y = y) \\&= \sum_{y \in Y(\Omega)} y \sum_{x \in X(\Omega): f(x)=y} \mathbb{P}(X = x) \\&= \sum_{y \in Y(\Omega)} \sum_{x \in X(\Omega): f(x)=y} \underbrace{y}_{=f(x)} \mathbb{P}(X = x) \\&= \sum_{y \in Y(\Omega)} \sum_{x \in X(\Omega): f(x)=y} f(x) \mathbb{P}(X = x) \\&= \sum_{x \in X(\Omega)} f(x) \mathbb{P}(X = x) \\&= \mathbb{E}[f(x)]\end{aligned}$$

$$*Y = y \Leftrightarrow f(x) = y, \quad \mathbb{P}(Y = y) = \sum_{x \in X(\Omega): f(x)=y} \mathbb{P}(X = x)$$

Beispiel 7.13 Zu Satz 7.4.

Mit $f(x) = x^2$

Definition 7.3 **n-tes Moment von X** (2026)

Für $n \in \mathbb{N}$ heißt $\mathbb{E}[X^n]$ das erste n-te Moment von X , insofern $\mathbb{E}[|X|^n] < \infty$. (Erwartungswert ist das 1. Moment)

Definition 7.4 (2026) $\mathbb{E}[(X - \mathbb{E}[X])^n]$ heißt das n-te zentrierte Moment von X . Es existiert, wenn $\mathbb{E}[|X|^n] < \infty$.

Definition 7.5 (2026) Die Varianz von X ist das 2 zentrierte Moment, d.h.

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

(mittlere quadratische Abweichung)

Die Varianz von X existiert, wenn $\text{Var}(X) < \infty$.

Die Varianz einer Zufallsvariable X mit existierendem Erwartungswert ist gegeben durch

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x)$$

(gewichtete quadratische Abweichung vom Erwartungswert) bzw.

$$\text{Var}(X) = \int_{-\infty}^{\infty} \underbrace{(x - \mathbb{E}[X])^2}_{=f(x)} d(x) dx$$

Bemerkung 7.3 (2026) $\text{Var}(X) \geq 0$

Definition 7.6 **Existierende Varianz** (2025)

Wir sagen, dass die Varianz existiert, wenn

$$\text{Var}(X) = \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x) < \infty$$

bzw.

$$\int_{-\infty}^{\infty} (x - \mathbb{E}[X])^2 d(x) < \infty$$

Beispiel 7.14 Bsp. (2026)

Seien X, Y Zufallsvariablen mit

$$\mathbb{P}(X = +1) = \frac{1}{2} = \mathbb{P}(X = -1)$$

und

$$Y = 100 \cdot X.$$

Anhand des Erwartungswertes: kein Unterschied!

$$\mathbb{E}[X] = 1 \cdot \mathbb{P}(X = 1) + (-1) \cdot \mathbb{P}(X = -1) = 1 \cdot \frac{1}{2} - 1 \cdot \frac{1}{2} = 0.$$

Da $Y = 100X$ gilt,

$$\mathbb{E}[Y] = 100 \cdot \mathbb{E}[X] = 0.$$

Die Varianz zeigt den Unterschied:

da $\mathbb{E}[X] = 0$,

$$\text{Var}(X) = \mathbb{E} \left[\underbrace{(X - \mathbb{E}[X])^2}_{=0} \right] = \mathbb{E} \left[\underbrace{X^2}_1 \right] = \mathbb{E}[1] = 1$$

Wegen $X \in \{-1, 1\}$ ist

$$X^2 = 1,$$

also

$$\text{Var}(X) = \mathbb{E}[1] = 1.$$

Ebenso gilt wegen $\mathbb{E}[Y] = 0$,

$$\text{Var}(Y) = \mathbb{E}[(Y - \mathbb{E}[Y])^2] = \mathbb{E}[Y^2] = \mathbb{E}[(100X)^2]$$

Damit folgt

$$\text{Var}(Y) = \mathbb{E}[100^2 X^2] = 100^2 \mathbb{E}[X^2] = 100^2.$$

Beispiel 7.15 Bernoulli-Variable (Spezialfall der Binomialverteilung mit $n = 1$) (2026)

Zufallsvariable X mit $\mathbb{P}(X = +1) = p = 1 - \mathbb{P}(X = 0)$ für Erfolgswahrscheinlichkeit $p \in [0, 1]$ und $\mathbb{E}[X] = p$.

$Var(X)$ existiert, da

$$\begin{aligned} Var(X) &= \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x) \\ &= (0 - \underbrace{\mathbb{E}[X] = p})^2 \underbrace{\mathbb{P}(X = 0)} = 1 - p + (1 - \underbrace{\mathbb{E}[X] = p})^2 \underbrace{\mathbb{P}(X = 1)} = p \\ &= p^2(1 - p) + (1 - p)^2 p \\ &= p(1 - p)[p + (1 - p)] \\ &= p(1 - p) < \infty \end{aligned}$$

$$\begin{aligned} Var(X) &= (1 - \mathbb{E}[X])^2 p + (0 - \mathbb{E}[X])^2 (1 - p) \\ &= (1 - p)^2 p + p^2 (1 - p) \\ &= p(1 - p) \end{aligned}$$

Beispiel 7.16 gleichverteilte Zufallsvariable auf $\{1, \dots, n\}$ (2026)

Zufallsvariable X mit $\mathbb{P}(X = k) = \frac{1}{n}$ für $k = 1, \dots, n$

$$\mathbb{E}[X] = \sum_{k=1}^n k \cdot \frac{1}{n} = \frac{n(n+1)}{2n} = \frac{n+1}{2}$$

und

$$Var(X) = \frac{n^2 - 1}{12}$$

weil

$$\begin{aligned} Var(X) &= \frac{1}{n} \sum_{k=1}^n (k - \mathbb{E}[X])^2 \\ &= \frac{1}{n} \sum_{k=1}^n (k^2 - 2k\mathbb{E}[X] + \mathbb{E}[X]^2) \\ &= \frac{1}{n} \sum_{k=1}^n k^2 - 2\mathbb{E}[X] \cdot \underbrace{\frac{1}{n} \sum_{k=1}^n k}_{=\mathbb{E}[X]} + \mathbb{E}[X]^2 \\ &= \frac{(n+1)(2n+1)}{6} - \mathbb{E}[X]^2 \\ &= \frac{n^2 - 1}{12} \end{aligned}$$

Lemma 7.1 Technisches Lemma (2026)

Für alle $a \in \mathbb{R}$ gilt $\mathbb{E}[(X - a)^2] = Var(X) + (\mathbb{E}[X] - a)^2$

Beweis TODO F 76

Folgerung 7.1 Folgerung I (2026)

$a \Leftrightarrow \mathbb{E}[(X - a)^2]$ wird minimal für $a = \mathbb{E}[X]$.

In diesem Fall ist $\mathbb{E}[(X - a)^2] = Var(X)$ per Definition der Varianz.

Folgerung 7.2 Folgerung II und wichtige Rechenregel (2026)

Die Wahl $a = 0$ zeigt

$$0 \leq \text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Es gilt daher stets $(\mathbb{E}[X])^2 \leq \mathbb{E}[X^2]$.

Satz 7.5 Satz (V) (2026)

Seien X, Y diskrete (?) Zufallsvariablen mit existierendem Erwartungswert, $a, b \in \mathbb{R}$.

(a) $\text{Var}(aX + b) = a^2 \text{Var}(X)$

$$\begin{aligned} \text{Var}(aX + b) &= \mathbb{E}[(aX + b - \mathbb{E}[aX + b])^2] \\ &= \mathbb{E}[(a(X - \mathbb{E}[X]))^2] \\ &= a^2 \mathbb{E}[(X - \mathbb{E}[X])^2] \\ &= a^2 \text{Var}(X) \end{aligned}$$

(b) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$ mit Kovarianz $\text{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$.

$$\begin{aligned} \text{Var}(X + Y) &= \mathbb{E}[(X + Y - \mathbb{E}[X + Y])^2] \\ &= \mathbb{E}[(X - \mathbb{E}[X])^2] + 2\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] + \mathbb{E}[(Y - \mathbb{E}[Y])^2] \\ &= \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y) \end{aligned}$$

(c) X und Y unabhängig $\Rightarrow \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$.

$$X \text{ und } Y \text{ unabhängig} \Rightarrow X - \mathbb{E}[X], Y - \mathbb{E}[Y] \text{ unabh.}$$

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \\ &\stackrel{(P)}{=} \mathbb{E}[X - \mathbb{E}[X]] \mathbb{E}[Y - \mathbb{E}[Y]] \\ &= 0 \end{aligned}$$

(d) Für diskrete Zufallsvariablen gilt:

$$\text{Var}(X) = 0 \Rightarrow \text{Es existiert eine Konstante } c \text{ mit } \mathbb{P}(X = c) = 1.$$

$$c = \mathbb{E}[X]$$

Beweis für (a) bis (c): Verwende $\text{Var}(Z) = \mathbb{E}[(Z - \mathbb{E}[Z])^2]$ und die Rechenregeln für den EW.

Beweis für (d): $0 = \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x).$

Alle Summanden sind ≥ 0 , folglich impliziert $\mathbb{P}(X = x) > 0$ sofort $x = \mathbb{E}[X]$, da die Summe nicht 0 sein könnte, wenn ein Summand nicht 0 wäre. Also muss jedes $(x - \mathbb{E}[X])^2 \mathbb{P}(X = x)$ sein und wenn $\mathbb{P}(X = x) > 0$, muss also $(x - \mathbb{E}[X])^2 = 0$ sein, also muss $x - \mathbb{E}[X] = 0$ sein, also $x = \mathbb{E}[X]$.

Damit ist gezeigt, dass $\mathbb{P}(X = \mathbb{E}[X]) = 1$, da jedes $x \in X$ gleich $\mathbb{E}[X]$ ist.

Kann nicht gelten, wenn f Dichte hat

Beispiel 7.17 Binomialverteilte Zufallsvariable S_n mit Parametern n und p (2026)

$$\Omega = \{0, 1\}^n \text{ und}$$

$$p(\omega) = p^{\sum_{i=1}^n \omega_i} (1 - p)^{n - \sum_{i=1}^n \omega_i}$$

Darstellung:

$$S_n = \sum_{i=1}^n X_i$$

mit

$$X_i(\omega) = \omega_i \quad \text{für alle } \omega \in \Omega.$$

Dabei sind die X_i unabhängig mit

$$\mathbb{P}(X_i = 1) = p$$

und

$$\mathbb{P}(X_i = 0) = 1 - p = q$$

für alle i .

$$\mathbb{E}[X] = \sum_{i=1}^n \mathbb{E}[X_i] = np$$

nach Satz (E).

Unter Verwendung der Unabhängigkeit der X_i folgt ohne weitere Arbeit aus Satz (V) (??)

$$Var(X) = \sum_{i=1}^n \underbrace{Var(X_i)}_{=pq} = npq$$

Beispiel 7.18 Poisson-verteilte Zufallsvariable X mit Parameter $\lambda > 0$ (2026)

$$\mathbb{E}[X] = \lambda = Var(X)$$

Trick:

$$Var(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \mathbb{E}[X(X-1)] + \mathbb{E}[X] - (\mathbb{E}[X])^2$$

Wir wissen bereits:

$$\mathbb{E}[X] = \lambda \quad \text{und} \quad (\mathbb{E}[X])^2 = \lambda^2$$

Die Behauptung folgt daher aus

$$\mathbb{E}[X(X-1)] = \sum_{k=2}^{\infty} k(k-1) \frac{\lambda^k}{k!} e^{-\lambda} = \lambda^2 \sum_{l=0}^{\infty} \frac{\lambda^l}{l!} e^{-\lambda} = \lambda^2$$

und damit

$$Var(X) = \mathbb{E}[X(X-1)] + \mathbb{E}[X] - (\mathbb{E}[X])^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

Beispiel 7.19 geometrisch verteilte Zufallsvariable X mit Erfolgswahrscheinlichkeit p (2026)

$$\mathbb{E}[X] = \frac{1}{p} \quad \text{und} \quad Var(X) = \frac{1-p}{p^2}$$

(Nicht auswendig lernen)

Beispiel 7.20 auf $[a, b]$ uniform verteilte Zufallsvariable X (2026)

Dann ist

$$\mathbb{E}[X] = \frac{a+b}{2}$$

und

$$\begin{aligned}\mathbb{E}[X^2] &= \int_a^b x^2 \frac{1}{b-a} dx \\ &= \frac{1}{3(b-a)} x^3 \Big|_{x=a}^b \\ &= \frac{b^3 - a^3}{3(b-a)} \\ &= \frac{1}{3}(a^2 + ab + b^2)\end{aligned}$$

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{a^2 + ab + b^2}{3} - \frac{a^2 + 2ab + b^2}{4} = \frac{(a-b)^2}{12}^*$$

* Nicht auswendig lernen.

Beispiel 7.21 Exponentialverteilte Zufallsvariable X (2026)

$$\mathbb{E}[X] = \frac{1}{\alpha}$$

$$\begin{aligned}\mathbb{E}[X^2] &= \int_0^\infty \underbrace{x^2}_{\downarrow} \underbrace{\alpha e^{-\alpha x}}_{\uparrow} dx \\ &= - \lim_{N \rightarrow \infty} x^2 e^{-\alpha x} \Big|_{x=0}^N + 2 \int_0^\infty x e^{-\alpha x} dx \\ &= 0 + \frac{2}{\alpha} \mathbb{E}[X] \\ &= \frac{2}{\alpha^2}\end{aligned}$$

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \frac{2}{\alpha^2} - \left(\frac{1}{\alpha}\right)^2 = \frac{1}{\alpha^2}$$

Ende der Vorlesung vom 5. Juni 2026

Satz 7.6 (2026) TODO F 98–100

KAPITEL 8

Varianz und Kovarianz

8.1 | Vorlesung 8

Grenzwertsätze

Vorlesung 13. Juni 2025 (V09 2025) und 12. Juni 2026 (V08 2026)

Satz 9.1 Markoffsche Ungleichung (2026)

Sei X eine Zufallsvariable. $\mathbb{E}[|X|^k]$ existiert für ein $k \in \mathbb{N}$. Dann existiert auch der Erwartungswert $\mathbb{E}[X]$, und es gilt

$$\mathbb{P}(\underbrace{|X - \mathbb{E}[X]|}_{*} \geq h) \leq \frac{\mathbb{E}[|X - \mathbb{E}[X]|^k]}{h^k} \quad \forall h > 0$$

* Menge aller $\omega \in \Omega$ derart, dass $X(\omega)$ um mindestens h von ihrem EW $\mathbb{E}[X]$ abweicht.

Satz 9.2 Tschebyscheffsche Ungleichung (Spezialfall $k = 2$) (2026)

Für eine Zufallsvariable X , deren Erwartungswert und Varianz existieren, gilt

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq h) \leq \frac{\text{Var}(X)}{h^2} \quad \forall h > 0$$

Beweis: Spezialfall diskreter Wahrscheinlichkeitsraums

$$\begin{aligned} \mathbb{P}(|X - \mathbb{E}[X]| \geq h) &= \sum_{\omega \in \Omega: |X(\omega) - \mathbb{E}[X]| \geq h} \mu(\omega) \\ &= \sum_{x \in X(\Omega): |x - \mathbb{E}[X]| \geq h} \mathbb{P}(\{\omega \in \Omega : X(\omega) = x\}) \\ &\leq \sum_{x \in X(\Omega): |x - \mathbb{E}[X]| \geq h} \left(\frac{|x - \mathbb{E}[X]|}{h}\right)^2 \mathbb{P}(X = x) \\ &\leq \frac{1}{h^2} \sum_{x \in X(\Omega)} |x - \mathbb{E}[X]|^2 \mathbb{P}(X = x) \\ &\leq \frac{1}{h^2} \text{Var}(X) \end{aligned}$$

Beispiel 9.1 Die Tschebyscheffsche Ungleichung kann nicht verbessert werden (2026)

Sei $N \in \mathbb{N}$ beliebig und die Zufallsvariable X mit $X(\Omega) = \{-N, 0, +N\}$ und $\mathbb{P}(X = \pm N) = \frac{1}{2N^2}$

$$\begin{aligned} \mathbb{P}(X = +N) &= \frac{1}{2N^2} \\ \mathbb{P}(X = -N) &= \frac{1}{2N^2} \\ \mathbb{P}(X = 0) &= 1 - \frac{1}{N^2} \end{aligned}$$

Aus $\mathbb{E}[X] = 0$ folgt

$$\text{Var}(X) = N^2 \mathbb{P}(X = -N) + N^2 \mathbb{P}(X = +N) = 1$$

Denn

$$\text{Var}(X) = \mathbb{E}[X^2] = N^2 \mathbb{P}(X^2 = N) = N^2 \frac{2}{2N^2} = 1$$

Für jedes $h \in (0, N]$ gilt

$$\begin{aligned} \mathbb{P}(|X - \underbrace{\mathbb{E}[X]}_{=0}| \geq h) &= \mathbb{P}(|X - \mathbb{E}[X]| > 0) \\ &= \mathbb{P}(X = N) + \mathbb{P}(X = -N) \\ &= \frac{1}{N^2} \\ &= \frac{\overbrace{\text{Var}(X)}^{=1}}{N^2} \\ &\leq \frac{1}{h^2} \text{Var}(X) \end{aligned}$$

Die Wahl $h = N$ zeigt: Ungleichung kann nicht verbessert werden.

Die Wahl $h = 2N$ dagegen zeigt, dass sie nicht immer gut ist:

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq 2N) = \mathbb{P}(|X| > N) = 0 < \frac{1}{(2N)^2} = \frac{\text{Var}(X)}{(2N)^2}$$

Beispiel 9.2 Werfen eines fairen Würfels (2026)

Wie oft müssen wir einen fairen Würfel werfen, bis mit Ws. $\geq 1 - 0.05$ die relative Häufigkeit einer Sechsen um weniger als $1/10$ von $1/6$ abweicht?

Ansatz: $\Omega = \{1, \dots, 6\}^N$ mit Gleichverteilung $\mathbb{P}$ (für N Würfe) und Zufallsvariablen $X_i \Omega \rightarrow \{0, 1\}$.

Dabei sind $X_i(\omega) = 1_{\{6\}}(\omega_i)$ unabhängig und identisch verteilt (u.i.v.) mit $\mathbb{P}(X_i = 1) = \frac{1}{6}$.

$S_N = \sum_{i=1}^N X_i$ ist die Anzahl der geworfenen Sechsen und $\frac{1}{N} S_N$ ist die relative Häufigkeit einer Sechsen.

Gesucht ist das kleinste N derart, dass $\mathbb{P}(|\frac{S_N}{N} - \frac{1}{6}| \geq \frac{1}{10}) \leq \frac{5}{100}$ (Gegenereignis zu $\mathbb{P}(|\frac{S_N}{N} - \frac{1}{6}| < \frac{1}{10}) \geq 1 - \frac{5}{100}$).

Lösung: für Tschebyscheffsche Ungleichung in Bezug auf EW und Var

Seien $p = 1/6$ und $q = 1 - p = 5/6$ und sei S_N binomialverteilt mit Parametern N und p . Dann ist

$$\mathbb{E}\left[\frac{1}{N} S_N\right] = \frac{1}{N} \mathbb{E}[S_N] \stackrel{*}{=} \frac{1}{N} Np = p = 1/6$$

* da S_N binomialverteilt ist und

$$\text{Var}\left(\frac{1}{N} S_N\right) = \frac{1}{N} \text{Var}(S_N) \stackrel{**}{=} \frac{1}{N} Npq = \frac{1}{N} pq = \frac{1}{N} \frac{1}{6} \frac{5}{6}$$

** Ebenfalls, weil S_N binomialverteilt ist.

Tschebyscheffsche Ungleichung:

$$\mathbb{P}\left(\underbrace{\left|\frac{S_N}{N} - \frac{1}{6}\right|}_{\text{Gegenereignis}} \geq \frac{1}{10}\right) \leq \frac{\text{Var}\left(\frac{S_N}{N}\right)}{(1/10)^2} = 100 \frac{5}{36N}$$

Wir wählen also N so groß, dass $100 \frac{5}{36N} \leq \frac{5}{100}$.

Fazit Jedes $N \approx 278$ (genauer aus der Abschätzung $(100)^2/36 \approx 277.7$) garantiert, dass mit Wahrscheinlichkeit ≥ 0.95 die relative Häufigkeit einer Sechsen bei N -maligem Würfeln um weniger als $1/10$ von $1/6$ abweicht.

Wenn wir $N = 278$ wählen, sind wir auf der sicheren Seite.

Da wir abgeschätzt haben, ist dieses N möglicherweise nicht das minimale.

Satz 9.3 Schwaches Gesetz der großen Zahlen (2025)

Gegeben Zufallsvariablen $X_1, X_2, X_3, \dots$ auf einem $(\Omega, \mathbb{P})$. Dabei muss die Verteilung der X_i nicht identisch sein. Es gilt $S_n = \sum_{i=1}^n X_i$

Angenommen alle Erwartungswerte $\mathbb{E}[X_i]$ existieren mit $\mathbb{E}[X_i] = \mathbb{E}[X_1]$ (es sind also alle gleich) für alle $i \in \mathbb{N}$. $\exists C > 0$ mit $\text{Var}(X_i) \leq C$ für alle $i \in \mathbb{N}$. (Beachte $\text{Var}(X_i) < \infty \Rightarrow \mathbb{E}[X_i]$ ex.)

Die Zufallsvariablen sind paarweise unkorreliert (Also wenn $\text{Cov}(X_i, X_j) = 0$ für $i \neq j$):

$$\mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])] = 0, \quad \text{für alle } i \neq j$$

Dann gilt:

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\frac{1}{n}S_n - \mathbb{E}[X_1]| \geq \epsilon) = 0 \quad \forall \epsilon > 0$$

S_n : arithmetisches Mittel und $\frac{1}{n}S_n$ relative Häufigkeit, falls x_i Bernoulli-verteilt

Soll heißen.: Generell ist $\frac{1}{n}S_n$ das arithmetische Mittel, aber bei einer Bernoulli-Verteilung ist $\frac{1}{n}S_n$ auch gleichzeitig die relative Häufigkeit der Erfolge, da S_n die Anzahl der Erfolge unter n Versuchen ist.

Beweis. (siehe Folie 4--2025 bzw. 18--19 2026)

Bemerkung 9.1 (2026) Unabhängigkeit $\Rightarrow$ paarweise Unabhängigkeit $\Rightarrow$ paarweise Unkorreliertheit

Bemerkung 9.2 (2026)

$$\mathbb{E}\left[\frac{1}{n}S_n\right] = \mathbb{E}[X_1]$$

Beispiel 9.3 Ermitteln der Erfolgswahrscheinlichkeit aus Daten (2025)

Geg. S_n , ges. $\mathbb{E}\left[\frac{1}{n}S_n\right] = \mathbb{E}[X_1] = p = \text{Erfolgswahrscheinlichkeit}$.

S_n ist hier die Anzahl der Erfolge in einem n -mal unabhängig wiederholten Bernoulli-Experiment, z.B. Anzahl Sechsen bei n -maligem Werfen eines möglicherweise nicht fairen Würfels.

Erinnerung: Die relative Häufigkeit $\frac{1}{n}S_n$ der Erfolge konvergiert gegen die Erfolgswahrscheinlichkeit p .

Die Wahrscheinlichkeit, daß die relative Häufigkeit um mindestens ϵ von der Erfolgswahrscheinlichkeit abweicht, konvergiert gegen Null

Notation 9.1 (2025)

$$x_k^{(n)} := (k - np) / \sqrt{npq} \quad \text{für } k = 0, \dots, n$$

$$\mathcal{B}_{n,p}(k) = \binom{n}{k} p^k q^{n-k}$$

Erinnerung 9.1 (2025) Ist S_n binomialverteilt mit Parametern n und p , so gelten

$$\mathbb{P}(S_n = k) = \mathcal{B}_{n,p}(k)$$

$$\mathbb{E}[S_n] = np$$

$$\text{Var}(S_n) = npq$$

Satz 9.4 Lokaler zentraler Gesetzswertsatz (2025)

Sei $L > 0$ eine beliebige Konstante. Dann gilt

$$\underbrace{\mathcal{B}_{n,p}(k)}_{\mathbb{P}(S_n=k)} \sim \frac{1}{\sqrt{2\pi npq}} e^{-(x_k^{(n)})^2/2} \text{ gleichm\"a\ss{}ig f\"ur alle } k \text{ mit } |x_k^{(n)}| \leq L \quad (9.1)$$

Dabei bedeutet $\sim$:

$$f(n) \sim g(n) \Leftrightarrow \lim_{n \rightarrow \infty} \frac{f(n)}{g(n)} = 1$$

Man kann 9.1 auch schreiben als

$$\lim_{n \rightarrow \infty} \sup_{k: |x_k^{(n)}| \leq L} \left| \frac{\mathcal{B}_{n,p}(k)}{\frac{1}{\sqrt{2\pi npq}} e^{-(x_k^{(n)})^2/2}} - 1 \right| = 0$$

Beweis.

- Ausschreiben des Binomialkoeffizienten in *Binomialverteilung*)
- Approximieren der Fakultäten mit Hilfe der Stirlingschen Formel (siehe unten)
- Sortieren der Terme
- Sorgfältiges Berechnen des Limes $n \rightarrow \infty$

schwaches Gesetz der großen Zahlen " $\frac{1}{n}S_n \rightarrow \frac{1}{6}$ " und $\mathbb{P}(\frac{1}{n}S_n = \frac{1}{6})$ ist sehr klein.

Ergänzung 9.1 Stirlingsche Formel (2025)

$$n! \sim \sqrt{2\pi n} \left(\frac{n}{e}\right)^n \text{ für große } n \quad (9.2)$$

n	n!	Approximation
1	1	0.922
2	2	1.919
3	6	5.836
4	24	23.506
5	120	118.019
6	720	710.078
7	5040	4980.4
8	40320	39902.4
9	362880	359537
10	3628800	$3.5987 \cdot 10^6$
11	39916800	$3.96156 \cdot 10^7$
12	479001600	$4.75687 \cdot 10^8$

Tabelle 9.1: Exact factorial values and their approximations.

Ergänzung 9.2 Stirlingsche Formel mit Fehlerabschätzung (2025)

$$1 \leq \frac{n!}{\sqrt{2\pi n} \binom{n}{e}^n} \leq 1 + \frac{1}{11n} \quad (9.3)$$

Die Approximation verwendet die untere Schranke und Fehler ist der Ordnung $\frac{1}{n}$.

Beispiel 9.4 1200-mal Würfeln mit einem fairen Würfel. (2025)

Wie groß ist die Wahrscheinlichkeit, genau k Sechsen zu werfen?

a) $k = 200$

$$B_{1200, \frac{1}{6}}(200) = 0.030888 \dots$$

Approximation gemäß lokalem zentralem Grenzwertsatz:

$$0.030901 \dots$$

b) $k = 250$

$$B_{1200, \frac{1}{6}}(250) = 0.0000244 \dots$$

Approximation gemäß lokalem zentralem Grenzwertsatz:

$$0.0000170 \dots$$

Neue Fragen: (2025)

Wie groß ist die Ws., zwischen 150 und 250 Sechsen zu werfen? Wie groß ist die Ws., mindestens 250 Sechsen zu werfen?

Satz 9.5 Satz von de Moivre-Laplace (Spezialfall des zentralen Grenzwertsatzes) (2025)

Sei S_n die Anzahl der Erfolge in einem n -fach unabhängig wiederholten Bernoulli-Experiment mit Erfolgswahrscheinlichkeit $p \in (0, 1)$.

Dann gilt für jede Wahl von Konstanten a, b mit $-\infty < a < b < \infty$:

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{x^2/2} dx = \int_a^b \varphi(x) dx \quad (9.4)$$

Dabei verstehen wir die rechte Seite als Riemann-Integral $\int_a^b \varphi(x) dx$ mit

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \quad (9.5)$$

Standartisieren: X ist ZV mit existierender Varianz.

$$Y := \frac{X - \mathbb{E}[X]}{\sqrt{\text{Var}(X)}} \text{ hat } \mathbb{E}[Y] = 0, \quad \text{Var}(Y) = 1$$

Beweisidee: Zunächst Approximieren der Summanden *Binomialverteilung* durch den lokalen zentralen Grenzwertsatz. Approximieren der Summe mithilfe eines Riemann-Integrals.

Beweis. Siehe Folie 23. 2025

Kommentar 9.1 Zu Satz 9.5

Der Satz von de Moivre-Laplace macht eine Aussage über einen Grenzwert. Das bedeutet: Wenn man n tatsächlich gegen unendlich gehen lässt, dann konvergiert diese Wahrscheinlichkeit exakt gegen $\Phi(b) - \Phi(a)$ in der Praxis hast du aber nie $n = \infty$.

Bemerkung 9.3 Zu Satz 9.5 (2025)

$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{x^2/2}$ heißt Dichte der Standardnormalverteilung .

Die Stammfunktion

$$\Phi(y) = \int_{-\infty}^y \varphi(x) dx = \int_{-\infty}^y \frac{1}{\sqrt{2\pi}} e^{x^2/2} dx \quad (9.6)$$

ist die Verteilungsfunktion der Standardnormalverteilung. .

Der Graph von φ ist die berühmte Gaußsche Glockenkurve.

$\Phi(y)$ st die Fläche unter der Kurve φ von $-\infty$ bis y .

Regel 9.1 Rechenregeln (2025)

Dichte:

$$\int_{-\infty}^{\infty} \varphi(x) dx = 1 \quad (9.7)$$

Verteilungsfunktion:

$$\Phi(y) \rightarrow \begin{cases} 0 & \text{für } y \rightarrow -\infty \\ 1 & \text{für } y \rightarrow \infty \end{cases} \quad (9.8)$$

gerade Funktion:

$$\Phi(0) = \frac{1}{2} \quad (9.9)$$

$$\Phi(z) = \int_{-\infty}^z \varphi(x) dx = 1 - \int_z^{\infty} \varphi(x) dx = 1 - \int_{-\infty}^{-z} \underbrace{\varphi(y)}_{f(y)} dy = 1 - \Phi(-z) \quad (9.10)$$

($y = -z$)

Illustration in Abbildung 9.1.




Abbildung 9.1

Ergänzung 9.3 (2026) Lokaler zentraler Grenzwertsatz und Satz von de Moivre-Laplace




Abbildung 9.2: Beispiel für $n = 10$, $p = 1/10$




Abbildung 9.3: Beispiel für $n = 20$, $p = 1/10$




Abbildung 9.4: Beispiel für $n = 100$, $p = 1/10$




Abbildung 9.5: Beispiel für $n = 500$, $p = 1/10$

Beispiel 9.5 Vorlesung vs. Schlaf (2025)

Frage: Wie groß ist die Wahrscheinlichkeit, dass von den 142 Hörern einer 8-Uhr-Vorlesung nächste Woche zwischen 30% und 70% die Vorlesung besuchen?

Geg.: $n = 142$ Hörer, jeder Einzelne besucht mit Wahrscheinlichkeit $p \in (0, 1)$ die Vorlesung ($p = \frac{2}{3}$).

Vereinfachende Annahmen: Alle Hörer besuchen die Vorlesung mit derselben Wahrscheinlichkeit und alle Hörer entscheiden sich unabhängig voneinander.

Modell: n -mal unabhängig wiederholtes Bernoulli-Experiment mit Erfolgswahrscheinlichkeit p . Also: Die Anzahl der Erfolge S_n ist $\mathcal{B}_{n,p}$ -verteilt. Man betrachte jeden Anwesenden der n eingeschriebenen Hörer als "Erfolg".

Also:

$$\Omega = \{0, 1\}^n, \quad \mu(\omega) = p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{n-\sum_{i=1}^n \omega_i} \quad (\text{mit } n = 142 \text{ und } p = 2/3)$$

Anzahl der Erfolge ist die Anzahl Anwesender

$$S_n(\omega_i) = \sum_{i=1}^n \omega_i$$

Dass n Leute anwesende sind, ist das Ereignis:

$$A_n = \left\{ \frac{3}{10} \leq \frac{1}{n} S_n \leq \frac{7}{10} \right\} = \{S_n \in \{\lceil \frac{3}{10} \cdot n \rceil, \lceil \frac{3}{10} \cdot n \rceil + 1, \dots, \lfloor \frac{7}{10} \cdot n \rfloor\}\}$$

Für $n = 142$ ist das $\lceil \frac{3}{10} \cdot n \rceil = 43$ und $\lfloor \frac{7}{10} \cdot n \rfloor = 99$ Mit $p = \frac{2}{3}$:

$$\mathbb{P}(A_n) = \sum_{k=\lceil \frac{3}{10} \cdot n \rceil}^{\lfloor \frac{7}{10} \cdot n \rfloor} \binom{142}{k} \left(\frac{2}{3}\right)^k \left(\frac{1}{3}\right)^{142-k} = \sum_{k=43}^{99} \binom{142}{k} \left(\frac{2}{3}\right)^k \left(\frac{1}{3}\right)^{142-k} \approx 0.80$$

Approximation mit dem Satz von de Moivre-Laplace (in Form $a < \dots \leq b$ bringen) :

$$\begin{aligned} \mathbb{P}(A_n) &= \mathbb{P}\left(\frac{3n}{10} \leq S_n \leq \frac{7n}{10}\right) \\ &= \mathbb{P}\left(\lceil \frac{3n}{10} \rceil \leq S_n \leq \lfloor \frac{7n}{10} \rfloor\right) \\ &= \mathbb{P}\left(\lceil \frac{3n}{10} \rceil - 1 < S_n \leq \lfloor \frac{7n}{10} \rfloor\right) && (\text{weil } S_n \text{ ganzzahlig ist}) \\ &= \mathbb{P}\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) && (\text{Standardisieren, } q = 1 - p = 1/3) \\ &\stackrel{*}{\approx} \Phi(b) - \Phi(a) && (\text{Satz von de Moivre-Laplace}) \\ &\approx \Phi(0.77) - 0 \\ &\approx 0.7794v && (Tabelle) \end{aligned}$$

$$* \int_a^b \varphi(x) dx = \Phi(b) - \Phi(a)$$

mit

$$a = \frac{\lceil \frac{3n}{10} \rceil - 1 - np}{\sqrt{npq}} \approx -9.38 \quad \text{und} \quad b = \frac{\lfloor \frac{7n}{10} \rfloor - 1 - np}{\sqrt{npq}} \approx 0.77$$

Das Resultat wirft einige Fragen auf:

Frage 9.1 Warum spielt die untere Grenze a , die von den 30% herrührt, praktisch keine Rolle? (2026)

1. Antwort: $\Phi(a) \approx \Phi(-9) = 1 - \Phi(9)$ und $\Phi(9)$ ist so nah an 1, dass wir diesen Wert nicht einmal in der Tabelle finden . . .

Aber das erklärt noch gar nichts – oder?

2. Antwort: Wir wissen aus dem Gesetz der großen Zahlen, dass $\frac{1}{n}S_n$ in einem gewissen Sinne gegen $p = 2/3 \approx 66\%$ konvergiert. Daher ist die Forderung, dass $\frac{1}{n}S_n \leq 70\%$ sein soll, sehr viel restriktiver als die Forderung $\frac{1}{n}S_n \geq 30\%$.

Kommentar 9.2 Da $\frac{1}{n}S_n$ nach dem Gesetz der großen Zahlen gegen $p = \frac{2}{3} \approx 66,7\%$ konvergiert, liegt es für große n mit hoher Wahrscheinlichkeit in der Nähe von 66,7%. Die Bedingung $\frac{1}{n}S_n \geq 30\%$ ist daher nahezu immer erfüllt, während $\frac{1}{n}S_n \leq 70\%$ nur eine kleine Abweichung vom Grenzwert zulässt und somit restriktiver ist.

Frage 9.2 Die exakte Rechnung ergab $\mathbb{P}(A_n) \approx 0.80$ (Genauer $\mathbb{P}(A_n) \approx 0.804486$). **Warum finden wir mit dem Satz von de Moivre-Laplace nur $pe(A_n) \approx 0.78$? (2026)**

1. Antwort: $n = 142$ ist noch kein wirklich großes n .

2. Antwort: Grob gesprochen, approximieren wir eine diskrete Größe, die Anzahl der Erfolge S_n , durch etwas Kontinuierliches. Eine Verbesserung ist oft möglich durch die sogenannte Stetigkeitskorrektur: .

Wir modifizieren die Grenzen in A_n geschickt und rechnen

$$\begin{aligned}\mathbb{P}(A_n) &= \mathbb{P}\left(\lceil \frac{3n}{10} \rceil - 1 < S_n \leq \lfloor \frac{7n}{10} \rfloor\right) \\ &= \mathbb{P}\left(\lceil \frac{3n}{10} \rceil - \frac{1}{2} < S_n \leq \lfloor \frac{7n}{10} \rfloor + \frac{1}{2}\right) && \text{(weil } S_n \text{ ganzzahlig ist)} \\ &\approx \Phi(0.86) \approx 0.8051 && \text{(Tabelle)}\end{aligned}$$

Bingo!

Beachte, dass die Stetigkeitskorrektur nicht immer besser ist (siehe Hausaufgaben).

Beispiel 9.6 Vorlesung vs. Schlaf II (2026)

Wie groß ist die Wahrscheinlichkeit, dass von 142 Hörern nächste Woche mindestens 90 die Vorlesung besuchen?

Was ist anders als im obigen Beispiel? Neu an dieser Frage ist, dass wir nur eine untere Schranke gegeben haben, d.h., wir suchen die Wahrscheinlichkeit von

$$B_n = \{S_n \geq 90\}$$

Dieser Fall ist in unserer Formulierung des Satzes von de Moivre-Laplace nicht vorgesehen!

Idee, das Problem zu umgehen: Wir werden uns künstlich eine triviale obere Schranke verschaffen.

$$\begin{aligned}
 \mathbb{P}(B_n) &= \mathbb{P}(S_n \geq 90) \\
 &= \mathbb{P}(89 < S_n \leq n) && \text{(triviale obere Schranke)} \\
 &= \mathbb{P}(89.5 < S_n \leq n) && (S_n \text{ ganzzahlig, Stetigkeitskorrektur}) \\
 &= \mathbb{P}\left(c_n < \frac{S_n - np}{\sqrt{npq}} \leq d_n\right) && \text{(Standardisieren)} \\
 &\approx \Phi(d_n) - \Phi(c_n) && \text{(Satz von de Moivre-Laplace)} \\
 &= \Phi(d_n) - [1 - \underbrace{\Phi(-c_n)}_{>0}] \approx 0.8212 && \text{(Tabelle)}
 \end{aligned}$$

mit

$$c_n = \frac{89.5 - np}{\sqrt{npq}} \approx -0.92 \quad \text{und} \quad d_n = \frac{nq}{\sqrt{npq}} \sqrt{\frac{nq}{p}} \approx 8.43.$$

Exakte Rechnung ergibt $\mathbb{P}(B_n) = 0.821556 \dots$

Bemerkung 9.4 (2026)

Generell gelten, sofern der Satz von de Moivre-Laplace anwendbar ist,

$$\mathbb{P}(s_n > c) = \mathbb{P}\left(\frac{c - np}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{n - np}{\sqrt{npq}}\right) \approx 1 - \Phi\left(\frac{c - np}{\sqrt{npq}}\right)$$

und

$$\mathbb{P}(s_n \leq d) = \mathbb{P}\left(\frac{-1 - np}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{d - np}{\sqrt{npq}}\right) \approx \Phi\left(\frac{d - np}{\sqrt{npq}}\right)$$

weil für große n

$$\Phi\left(\frac{-1 - np}{\sqrt{npq}}\right) \approx 0 \quad \text{und} \quad \frac{n - np}{\sqrt{npq}} \approx 1$$

Vorlesung 18. Juni 2026 (V09 2026)

Lernziele

- Zentraler Grenzwertsatz: Aussage formulieren können and anwenden können
- Poissonscher Grenzwertsatz: Aussage formulieren können and anwenden können
- Wann wird welche Approximation verwendet?

Erinnerung 9.2 Satz von de Moivre-Laplace (2026)

Sei S_n die Anzahl der Erfolge in einem n-fach unabhängigen wiederholten Bernoulli-Experiment mit Erfolgswahrscheinlichkeit $p \in (0, 1)$.

Dann gilt für jede Wahl von Konstanten a, b mit $-\infty < a < b < \infty$

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-x^2/2} dx$$

Für große n folgt insbesondere, dass

$$\mathbb{P}(np - c < S_n \leq np + c) \approx \int_{-c/\sqrt{npq}}^{c/\sqrt{npq}} \underbrace{\frac{1}{\sqrt{2\pi}} e^{-x^2/2}}_{\text{Verteilungsfunktion der Standardnormalverteilung}} dx = \frac{1}{\sqrt{2\pi}} \int_{-c/\sqrt{npq}}^{c/\sqrt{npq}} e^{-x^2/2} dx = 2\Phi\left(\frac{c}{\sqrt{npq}}\right) - 1$$

Das folgt direkt aus dem allgemeinen Satz, wenn man die Konstanten a und b passend wählt.

Denn die WS für $np - c < S_n \leq np + c$ ist äquivalent für die von $-c < S_n - np \leq c$. Weil $\sqrt{npq} > 0$ (und das ist gegeben, weil $p \in (0, 1)$, also p ist echt größer als 0 und echt kleiner als 1; $n \leq 1$ ist die Anzahl der Versuche; $q = 1 - p$ und wir wissen ja bereits, dass p echt kleiner 1, also $q > 0$), kann man dadurch teilen und das hat dann die passende Form, um Moivre-Laplace anzuwenden:

$$\frac{-c}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{c}{\sqrt{npq}}$$

Und die Gleichung ergibt sich aus

$$\Phi\left(\frac{c}{\sqrt{npq}}\right) - \Phi\left(-\frac{c}{\sqrt{npq}}\right) = \Phi\left(\frac{c}{\sqrt{npq}}\right) - \left(1 - \Phi\left(\frac{c}{\sqrt{npq}}\right)\right) = 2\Phi\left(\frac{c}{\sqrt{npq}}\right) - 1$$

- Ist $c > 0$ nicht von n abhängig, so geht die Ws. mit $n \rightarrow \infty$ gegen Null (c ist eine feste Konstante, hängt nicht von n ab)
- Ist $0 < c \ll \sqrt{n}$, so geht die Ws. mit $n \rightarrow \infty$ immer noch gegen Null (c wächst, aber langsamer als $\sqrt{n}$)
- Relevanter Beitrag, d.h., Ws. größer als null, nur für $c \approx \sqrt{n}$ (oder größer) (c wächst in derselben Größenordnung wie $\sqrt{n}$)

Das erklärt, wie sich die Wahrscheinlichkeit $\mathbb{P}(np - c < S_n \leq np + c) \approx 2\Phi\left(\frac{c}{\sqrt{npq}}\right) - 1$ verhält, je nachdem wie schnell c mit n wächst (oder eben nicht wächst).

Kommentar 9.3 Zu : Die Liste ist relevant, denn ist npq zu klein, ist die Normalapproximation schlecht, und man sollte lieber exakt mit der Binomialverteilung rechnen (oder mit der Poisson-Approximation, falls p sehr klein ist).

Beobachtung 9.1 Vergleich mit dem Gesetz der großen Zahlen (2026)

$$\begin{aligned} \mathbb{P}\left(\left|\frac{1}{n}S_n - \mathbb{E}[X_1]\right| \geq \epsilon\right) &= 1 - \mathbb{P}\left(-\epsilon < \frac{1}{n}S_n - p < \epsilon\right) \\ &\approx 1 - \mathbb{P}\left(-\frac{n\epsilon}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{n\epsilon}{\sqrt{npq}}\right) \end{aligned}$$

Gesetz der großen Zahlen:

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n}S_n - \mathbb{E}[X_1]\right| \geq \epsilon\right) = 0 \quad \forall \epsilon > 0$$

und Satz von de Moivre-Laplace

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{x^2/2} dx = \int_a^b \varphi(x) dx$$

Verhalten für beschrieben durch

- ϵ der Ordnung 1 (konstant) : Gesetz der großen Zahlen
- ϵ der Ordnung $\frac{1}{\sqrt{n}}$ ()

Kommentar 9.4 Benutzt man für Stichprobengröße bestimmen, Konfidenzintervalle, Fehlerabschätzung bei Simulationen / Monte-Carlo-Methoden, Qualitätskontrolle / Fehlerraten

Satz 9.6 Zentraler Grenzwertsatz Verallgemeinerung des Satzes von de Moivre-Laplace (2026)

Gegeben Zufallsvariablen $X_1, X_2, X_3, \dots$ auf einem Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$.

Angenommen $X_1, X_2, X_3, \dots$ sind unabhängig und identisch verteilt und $\sigma^2 = \text{Var}(X_i) \in (0, \infty)$ für alle i .

(Beachte $\text{Var}(X_i) < \infty \Rightarrow \mathbb{E}[X_i]$ ex.)

Dabei ist $S_n = \sum_{i=1}^n X_i$ und $\mathcal{M} = \mathbb{E}[X_i]$.

Dann gilt:

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(a < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq b \right) = \Phi(b) - \Phi(a)$$

Satz 9.7 Zentraler Grenzwertsatz für Bernoulli-Variablen (2026)

Sind die Zufallsvariablen $X_1, X_2, X_3, \dots$ unabhängige Bernoulli-Variablen, so gelten: $\mathcal{M} = \mathbb{E}[X_i] = p$ und $\sigma^2 = \text{Var}(X_1) = pq$ mit $q = 1 - p$ und es folgt

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(a < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq b \right) = \mathbb{P} \left(a < \frac{S_n - np}{\sqrt{npq}} \leq b \right) = \Phi(b) - \Phi(a)$$

Man kann den zentralen Grenzwertsatz verallgemeinern, indem man bestimmte Voraussetzungen abschwächt:

Lemma 9.1 Bekannte Verallgemeinerungen (2026)

- Die Voraussetzung der identischen Verteilung kann abgeschwächt werden (z.B. zur Lindeberg-Bedingung).
 - Also: man muss nicht verlangen, dass alle X_i dieselbe Verteilung haben. Zum Beispiel darf X_1 normalverteilt sein, X_2 exponentialverteilt, X_3 wieder was anderes, solange sie noch unabhängig sind. Damit der ZGWS trotzdem noch gilt, braucht man aber eine Ersatzbedingung, die dafür sorgt, dass keine einzelne Variable die Summe zu stark dominiert. Das ist die Lindeberg-Bedingung.
- Die Voraussetzung der Unabhängigkeit kann abgeschwächt werden (Zentraler Grenzwertsatz von Lindeberg-Feller).
 - Es gibt Verallgemeinerungen des ZGWS für gewisse Arten von abhängigen Zufallsvariablen. Diese Verallgemeinerung erlaubt es, den ZGWS trotzdem anzuwenden, solange die Abhängigkeit nicht zu stark ist.
- Die Voraussetzungen $\sigma^2 > 0$ und $\sigma^2 < \infty$ dagegen sind notwendig

Beispiel 9.7 Augensumme in 420 Würfeln eines fairen Würfels (2026)

Wie groß ist die Ws., daß die Augensumme zwischen 1400 und 1550 liegt?


- $\Omega = \{1, \dots, 6\}^n$ mit $n = 420$
- $\mathbb{P}$ Gleichverteilung auf Ω
- $X_i(\omega) = \omega_i$ für $i = 1, \dots, n$ sind unabhängige, identisch verteilte ZV
- $\mathcal{M} = \mathbb{E}[X_i] = \frac{7}{2}$ und $\sigma^2 = \text{Var}(X_i) = \frac{35}{12}$
- $S_n(\omega) = \sum_{i=1}^n X_i(\omega)$ ist die Augensumme in n Würfeln

$$\begin{aligned}
\mathbb{P}(1400 \leq S_n \leq 1550) &= \mathbb{P}(1399 < S_n \leq 1550) \\
&= \mathbb{P}\left(\frac{1399 - n\mathcal{M}}{\sqrt{n\sigma^2}} < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq \frac{1550 - n\mathcal{M}}{\sqrt{n\sigma^2}}\right) \\
&= \mathbb{P}\left(\frac{1399 - 420\frac{7}{2}}{\sqrt{420\frac{35}{12}}} < \frac{S_n - 420\frac{7}{2}}{\sqrt{420\frac{35}{12}}} \leq \frac{1550 - 420\frac{7}{2}}{\sqrt{420\frac{35}{12}}}\right) \\
&= \mathbb{P}\left(-\frac{71}{35} < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq \frac{80}{35}\right) \\
&\approx \Phi(2.29) - \Phi(-2.03) \\
&\approx 0.9890 - (1 - 0.9788) = 0.9678
\end{aligned}$$

Beispiel 9.8 Augensumme aus n Würfeln eines fairen Würfels (2026)

Jede Durchführung des Experiments ergibt die Augensumme aus n Würfeln eines fairen Würfels. Jedes Histogramm für ein festes n zeigt diese Augensumme in jeweils 5000 Durchführungen des Experiments. Vergleich mit der entsprechend skalierten Gaußschen Glockenkurve.

$n \in \{1, 2, 3, 4, 5, 10, 50, 100\}$



Satz 9.8 Poissonscher Grenzwertsatz Approximationen der Binomialverteilung (2026)

Gilt $np_n \rightarrow \alpha > 0$ für $n \rightarrow \infty$, so gilt für jedes feste $k \in \mathbb{N}$

$$\mathcal{B}_{n,p}(k) \rightarrow \mathcal{P}_\alpha(k) = \frac{\alpha^k}{k!} e^{-\alpha} \quad \text{für } n \rightarrow \infty$$

Beweis. Sei k fest und $np_n \rightarrow \alpha > 0$ für $n \rightarrow \infty$. Daraus folgt insbesondere: $p_n \rightarrow 0$ für $n \rightarrow \infty$.

$$\begin{aligned}
 \mathcal{B}_{n,p}(k) &= \binom{n}{k} p_n^k (1-p_n)^{n-k} \\
 &= \frac{n(n-1)\dots(n-k+1)}{k!} p_n^k (1-p_n)^{n-k} \\
 &= \underbrace{1 \cdot \left(1 - \frac{1}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right)}_{\rightarrow 1} \underbrace{\frac{(np_n)^k}{k!}}_{\rightarrow \frac{\alpha^k}{k!}} \underbrace{\left(1 - \frac{np_n}{n}\right)^n}_{\xrightarrow{*} e^{-\alpha}} \underbrace{(1-p_n)^{-k}}_{\rightarrow 1} \\
 &\rightarrow \frac{\alpha^k}{k!} e^{-\alpha} \\
 &= \mathcal{P}_\alpha(k)
 \end{aligned}$$

* $(1 - \frac{\alpha_n}{n})^n \rightarrow e^{-\alpha}$ gilt auch für Folge $(\alpha_n)_n$ mit $\alpha_n \rightarrow \alpha$, nicht nur für feste α .

Bemerkung 9.5 Fehlerabschätzung / Güte der Approximation (2026)

Gegeben S_n binomialverteilt mit Parametern n und p_n und Z_{np_n} poisson-verteilt mit Parameter np_n . Angenommen $np_n \rightarrow \alpha$. Dann gilt die Abschätzung

$$\sup_{C \subset \mathbb{N}_0} |\mathbb{P}(S_n \in C) - \mathbb{P}(Z_{np_n} \in C)| \leq 2np_n^2 = 2 \underbrace{np_n}_{\rightarrow \alpha} p_n$$

Und für jede Konstante $K > 2$ und n groß genug gilt

$$\sup_{C \subset \mathbb{N}_0} |\mathbb{P}(S_n \in C) - \mathbb{P}(Z_{np_n} \in C)| \leq K\alpha p_n \rightarrow 0 \quad \text{für } n \rightarrow \infty$$

Bemerkung 9.6 Die Poisson-Approximation ist gut, wenn n groß im Vergleich zu k ist ($n \gg k$) und p klein ist ($n \gg \alpha := np$). Das heißt insbesondere, daß die Erfolgswahrscheinlichkeit klein sein muss. Für derartige seltene Ereignisse verwenden wir $\mathbb{P}(S_n = k) \approx \mathcal{P}_\alpha(k)$ mit $\alpha := np$.

Karteikarte 9.1 Wann ist die Poisson-Approximation ist gut?

Wenn n groß im Vergleich zu k ist ($n \gg k$) und p klein ist ($n \gg \alpha := np$). Das heißt insbesondere, daß die Erfolgswahrscheinlichkeit klein sein muss..

Beispiel 9.9 Seltenes Ereignis / Roulette (2026)

Wir betrachten ein Roulettespiel mit 36 "Zahlen" und einer "Null".

Wir setzen immer auf eine bestimmte Zahl: $p = 1/37$ und wir tun dies $n = 37$ Mal. Das heißt, wir erwarten im Mittel einen Gewinn: $\alpha = np = 1$.

Wie groß ist die Ws., $0\times, 1\times, 2\times, \dots$ zu gewinnen?

k	$\mathcal{B}_{37,1/37}(k)$	$\mathcal{P}_1(k)$
0	0.363	0.368
1	0.363	0.368
2	0.186	0.184
$\vdots$	$\vdots$	$\vdots$
5	0.00261	0.00306
$\vdots$	$\vdots$	$\vdots$
15	$1.5 \cdot 10^{14}$	$2.8 \cdot 10^{13}$

Beispiel 9.10 Historisches Beispiel zur Poisson-Approximation: Tote durch Hufschlag in Preussen (2026)

Vorliegende Daten: 10 Armee-corps über 20 Jahre, entspricht 200 Corps-Jahren.

Tote k	Anzahl Jahre mit k Toten	$200 \cdot P_{\varrho}(k)$ mit $\varrho = 0,61$
0	109	109
1	65	66
2	22	20
3	3	4
4	1	1
≥ 5	0	0

Tabelle 9.2: Die durch Schlag eines Pferdes im preussischen Heere Getöteten (Ladislaus von Bortkiewicz, Das Gesetz der kleinen Zahlen, Teubner (1898))

Hier wurde α gewählt als die mittlere Anzahl an Toten pro (Corps-)Jahr:

$$\alpha = (165 + 222 + 33 + 14)/200 = 0,61$$

Beispiel 9.11 Beispiel zur Poisson-Approximation: Zellzählung im Gitternetz (2026)

Zellen unter dem Mikroskop, Gitternetz, im Schnitt ν Zellen pro kleinem Quadrat, N Quadrate.

Modellierung: Verteile $N\nu$ Zellen zufällig und unabhängig voneinander auf N Quadrate. Wahrscheinlichkeit $p = 1/N$ für eine Zelle, im vorab gewählten Quadrat φ zu landen. Wahrscheinlichkeit k Zellen im Quadrat φ zu finden, ist $\mathcal{B}_{N\nu, 1/N}(k)$.

$$np_n \equiv \nu \begin{cases} n &= N\nu \\ p_n &= \frac{1}{N} \end{cases}$$

Bei großer Zahl N von Quadraten gelten $N\nu \gg k$ und $N\nu \gg \underbrace{(N\nu)}_n \underbrace{\frac{1}{N}}_{p_n} = \nu$.

Poisson-Approximation zeigt $\mathcal{B}_{N\nu, 1/N}(k) \approx \mathcal{P}_{\nu}(k)$.

Dies rechtfertigt, eine derartige Verteilung von Zellen oder Teilchen mit Hilfe der Poisson-Verteilung zu modellieren.

Beispiel 9.12 Beispiel zur Poisson-Approximation: Im zeitlichen Verlauf eintreffende Rechenaufträge (2026)

Im Schnitt α eintreffende Rechenaufträge pro Zeiteinheit (z.B. pro Stunde)

Ws., daß ein Auftrag eintrifft in einem sehr kleinen Zeitfenster der Länge $\delta \ll 1$ sei näherungsweise $\alpha\delta$. (δ sehr klein, z.B. eine Millisekunde)).

Wir zerlegen das Gesamtzeitintervall $[0, t]$ in N sehr kleine, disjunkte Teilintervalle der Länge t/N . (für ein festes t , z.B. 30 Minuten, 24 Stunden, drei Wochen, . . .)

$$[0, t] = \bigcup_{k=1}^N \left[\frac{k-1}{N} \cdot t, \frac{k}{N} \cdot t \right)$$

Ws., dass ein Auftrag eintrifft in einem bestimmten dieser Zeitfenster, ist näherungsweise $\alpha t/N$.

Annahmen: Für großes N sind die Zeitfenster so klein, daß wir annehmen dürfen, daß in jedem Fenster ein oder kein Auftrag eintrifft (d.h., wir schließen aus, daß mehr als ein Auftrag eintreffen kann) . Ob ein Auftrag in einem bestimmten Fenster eintrifft, sei unabhängig vom Eintreffen von Aufträgen in allen anderen Zeitfenstern.

Modellierung: Damit haben wir jedem Zeitfenster, d.h. jedem k , eine Bernoulli-Variable zugeordnet, die uns sagt, ob im zugehörigen Zeitfenster k ein Auftrag eintrifft. Die Erfolgsws. dieser Bernoulli-Variable ist $\alpha t/N$ (Also die Ws, dass ein Auftrag in einem bestimmten Zeitfenster eintritt). Die Anzahl der Aufträge, die im Intervall $[0, t)$ eintreffen, ist binomialverteilt mit Parametern N und $\alpha t/N$.

$$n = N, \quad p_n = \frac{\alpha t}{N} = \alpha t \frac{1}{N}$$

Für die Ws., insgesamt φ Aufträge im Intervall $[0, t)$ zu haben, ergibt die Poisson-Approximation für große N :

$$\mathcal{B}_{N, \alpha t/N}(\varphi) \approx \mathcal{P}_{N \cdot \alpha t/N}(\varphi) = \mathcal{P}_{\alpha t}(\varphi)$$

(Beachten Sie, daß wir in diesem Problem N beliebig groß machen dürfen. Wir verwenden hier die beliebige Teilbarkeit der Zeit!)

Wiederum rechtfertigt unsere Betrachtung, beim Modellieren derartiger Prozesse generell die Poisson-Verteilung zu verwenden.

Lemma 9.2 Poisson-Approximation für Erfolgswahrscheinlichkeit p nahe 1 (2026)

Betrachte die Anzahl Erfolge S_n in einem unabhängig n -mal wiederholten Bernoulli-Experiment mit:

- n groß
- p nahe bei 1, d.h., $q = 1 - p$ klein

Zusatzüberlegung erlaubt es, die Poisson-Approximation anzuwenden: Tausche die Rollen von “Erfolg” und “Mißerfolg” (zähle Mißerfolge !)

$\tilde{S}_n = n - S_n$ zählt die Anzahl der “Mißerfolge” $\tilde{S}_n$ ist $\mathcal{B}_{n,q}$ -verteilt.

Sei $\tilde{\alpha} = \mathbb{E}[\tilde{S}_n] = nq$.

Poisson-Approximation:

$$\mathbb{P}(\tilde{S}_n = k) = \mathcal{B}_{n,q}(k) \approx \mathcal{P}_{\tilde{\alpha}}(k); \quad \forall k \in \mathbb{N}_0$$

“Zurück übersetzen”: : Für alle $k \in \mathbb{N}_0$ gilt:

$$\mathbb{P}(S_n = k) = \mathbb{P}(\tilde{S}_n = n - k) = \mathcal{B}_{n,q}(n - k) \approx \mathcal{P}_{\tilde{\alpha}}(n - k) = \frac{(nq)^{(n-k)}}{(n - k)!} e^{-nq}$$

Also:

$$\mathbb{P}(S_n = k) = \mathbb{P}((n - S_n) = n - k) = \mathcal{B}_{n,q}(n - k) \approx \mathcal{P}_{\mathbb{E}[n - S_n]}(n - k) = \frac{(nq)^{(n-k)}}{(n - k)!} e^{-nq}$$

Bzw.:

$$\mathbb{P}(S_n = k) = \mathbb{P}((n - S_n) = n - k) = \mathcal{B}_{n,q}(n - k) \approx \mathcal{P}_{nq}(n - k) = \frac{(nq)^{(n-k)}}{(n - k)!} e^{-nq}$$

9.0.1 | Beispielaufgabe Laubfrosch

(2026)

Ein Laubfrosch legt $n = 1000$ Eier. Aus jedem Ei entwickelt sich mit der WS $p = \frac{1}{200}$ ein Frosch.

Aufgabe 9.1 Wahrscheinlichkeitsraum angeben und Modell rechtfertigen

Ziel: Wahrscheinlichkeit, dass sich höchstens zwei Frösche entwickeln.

Lösung: $n = 1000$, $\Omega = \{0, 1\}^{1000}$

$\omega_i = 1$ bedeutet i-tes Ei entwickelt sich zum Frosch.

$$\mu(\omega) = p^{\sum_{i=1}^n \omega_i} (1-p)^{n-\sum_{i=1}^n \omega_i} \quad \forall \omega \in \Omega$$

Annahme: Frösche entwickeln sich unabhängig voneinander mit gleicher Ws.

Aufgabe 9.2 Zufallsvariable, die Anzahl der Frösche angibt, die Verteilung und ggf. Parameter

$S_n : \Omega \rightarrow \{0, \dots, n\}$ und

$$S_n(\omega) := \sum_{i=1}^n \omega_i \quad \forall \omega \in \Omega$$

Als Anzahl von Erfolgen in unabhängig wiederholten Bernoulli-Experimenten ist S_n binomialverteilt mit Parametern n und p .

Aufgabe 9.3 Erwartungswert und Varianz

S_n ist binomialverteilt mit Parametern n und p . Daher existieren EW und Varianz und es gilt:

$$\mathbb{E}[S_n] = np = 1000 \frac{1}{200} = 5$$

und

$$\text{Var}(S_n) = np(1-p) = 5 \cdot \left(1 - \frac{1}{200}\right) = 5 \cdot \frac{199}{200} = \frac{199}{40}$$

Aufgabe 9.4 WS. maximal zwei Frösche zu haben

$$\alpha = pn = 5$$

$$\mathbb{P}(S_n \leq 2) = \mathbb{P}(S_n = 0) + \mathbb{P}(S_n = 1) + \mathbb{P}(S_n = 2)$$

$$\approx \left[\frac{\alpha^0}{0!} e^{-\alpha} + \frac{\alpha^1}{1!} e^{-\alpha} + \frac{\alpha^2}{2!} e^{-\alpha} \right] \quad \text{Pois. - Approx.}$$

$$= \left[1 + 5 + \frac{25}{2} \right] e^{-\alpha} \quad *$$

$$= \left[1 + 5 + \frac{25}{2} \right] e^{-5} \quad **$$

* n groß, $p = \frac{1}{200}$ klein

** $k = 0, 1, 2$ klein gegenüber n

Bemerkung 9.7 Bruchrechnung im Kontext der Binomialapproximation nicht ausmultiplizieren! (2026)

Sondern mit Parametern rechnen und n und p so spät wie möglich einsetzen.

KAPITEL 10

Statistik

10.1 | Daten, Häufigkeitsverteilungen und ihre Darstellung in der beschreibenden Statistik

10.1.1 | Daten und Häufigkeitsverteilungen

Erstes Ziel: Darstellung empirischer Daten

Grundbegriffe

Definition 10.1 Datenerhebung (Skript 26)

Feststellen der Werte von Merkmalen an ausgewählten Versuchseinheiten.

Beispiel 10.1 Beispiel Datenerhebung (Skript 26)

Versuchseinheit	Merkmal
Schweinchen	Lage (beim Schweinewürfeln)
Schweinchen	Farbe (beim Ziehen aus Beutel)
Studierende	erster Buchstabe vom Vornamen
	Geburtstag
	Abiturnote
Schüler	Alter in Jahren
	Größe
	Gewicht

Definition 10.2 Merkmal (Skript 26)

zu untersuchende Größe (ein- oder mehrdimensional, vgl. Farbe mit dem Tripel (Alter, Größe, Gewicht)).

Beispiel 10.2 Schweinewürfeln (Skript 26)

Fünf bis sieben Elementarereignisse (abhängig von Problemstellung):

- **Suhle:** Das Schwein liegt auf dem Rücken
- **Haxe:** Das Schwein steht auf seinen Füßen
- **Schnauze:** Das Schwein balanciert auf Vorderpfoten und Schnauze
- **Backe:** Das Schwein lehnt auf Vorderpfoten, Schnauze und einem Ohr

- ☐ ...auf Vorderpfoten, Schnauze und linkem Ohr
- ☐ ...auf Vorderpfoten, Schnauze und rechtem Ohr

■ **Faule Sau:** Das Schwein liegt auf der Seite

- ☐ ...und der Punkt ist *sichtbar*
- ☐ ...und der Punkt ist *nicht sichtbar*

Wir betrachten die folgenden sechs Elementarereignisse: *Suhle*, *Haxe*, *Schnauze*, *Backe*, *Faul-mit-Punkt*, *Faul-ohne-Punkt*.


Modell

$$\Omega = \{\text{Suhle}, \text{Haxe}, \text{Schnauze}, \text{Backe}, \text{Faul-mit-Punkt}, \text{Faul-ohne-Punkt}\}$$


Wie finden wir $\mu(\omega)$ für alle $\omega \in \Omega$?

Experiment am 14.01.2026 (gerechtfertigt durch das Gesetz der großen Zahlen)


Elementarereignis	Anzahl	relative Häufigkeit
Suhle	59	$\frac{59}{166}$
Haxe	10	$\frac{10}{166}$
Schnauze	3	$\frac{3}{166}$
Backe	2	$\frac{2}{166}$
Faul-mit-Punkt	46	$\frac{46}{166}$
Faul-ohne-Punkt	46	$\frac{46}{166}$
Σ	166	1




(a) Kreisdiagramm — kleiner Datensatz (Beispiel 1.3)



(b) Kreisdiagramm — Experiment vom 14.01.2026 ($n = 166$)



(a) Balkendiagramm — kleiner Datensatz



(b) Balkendiagramm — Experiment vom 14.01.2026

Beispiel 10.3 Merkmale treten in verschiedenen Ausprägungen auf (Skript 26)

Versuchseinheit	Merkmal	Ausprägung
Schweinchen	Lage	Suhle, Haxe, Schnauze, Backe, Faul-mit-Punkt, Faul-ohne-Punkt
Schweinchen	Farbe	weiß, braun, rosa, schwarz
Studierende	erster Buchstabe vom Vornamen	A,...,Z
	Geburtstag	1, ..., 365
	Abiturnote	$x/10$ mit $x \in \{10, \dots, 40\}$
Schüler	Alter in Jahren	$n \in \mathbb{N}$
	Größe	$l \in (0, \infty)$
	Gewicht	untergewichtig, normal, übergewichtig

Definition 10.3 Arten von Merkmalen (Skript 26)

Für quantitative **Merkmale** unterscheiden wir zwischen *diskreten* und *stetigen Merkmalen* (vgl. Alter in Jahren mit Größe).

Für qualitative **Merkmale** unterscheiden wir zwischen *ordinalen Merkmalen* bzw. *Rangmerkmalen* einerseits und *nominalen Merkmalen* andererseits. Rangmerkmale weisen im Gegensatz zu nominalen **Merkmalen** eine natürliche Ordnung auf (vgl. untergewichtig, normal, übergewichtig mit weiß, braun, rosa, schwarz).

Definition 10.4 Grundgesamtheit / Population (Skript 26)

Die Menge aller Merkmalsträger, über die eine Aussage getroffen werden soll.

Die **Grundgesamtheit** muss bei jeder **Datenerhebung** sorgfältig definiert werden.

Versuchseinheit	Merkmal	Grundgesamtheit
Schweinchen	Lage	alle vorhandenen Schweinchen nach dem Würfeln
Schweinchen	Farbe	alle Schweinchen im Beutel
Studierende	erster Buchstabe vom Vornamen	alle Studierenden im Hörsaal
	Geburtstag	
	Abiturnote	
Schüler	Alter in Jahren	alle Schüler einer Jahrgangsstufe
	Größe	
	Gewicht	

Stichprobe: Die **Grundgesamtheit** ist oft zu groß, um komplett ausgewertet zu werden. In der Regel wird daher nur eine Stichprobe ausgewertet.

Definition 10.5 Stichprobe vom Umfang n (Skript 26)

Eine Teilmenge der Größe n , die zufällig aus der Grundgesamtheit gewählt wurde.

Dabei wird, leicht missbräuchlich, in der Regel nicht unterschieden zwischen den n **Versuchseinheiten**, die für die Stichprobe aus der **Grundgesamtheit** gewählt werden, und den zu der Stichprobe gehörenden **Merkmalsausprägungen**.

Definition 10.6 Urliste (Skript 26)

Die erhobenen Daten, d.h., die Elemente der Stichprobe zusammen mit ihren Merkmalsausprägungen.

Beispiel 10.4 (Skript 26)

Versuchseinheit	Merkmalsausprägung
Schweinchen 1	Suhle
Schweinchen 2	Schnauze
Schweinchen 3	Faul-mit-Punkt
Schweinchen 4	Haxe
Schweinchen 5	Backe
Schweinchen 6	Haxe
Schweinchen 7	Suhle
Schweinchen 8	Suhle

Kürzere Darstellung als Liste:

(1, Suhle), (2, Schnauze), (3, Faul-mit-Punkt), (4, Haxe), (5, Backe), (6, Haxe), (7, Suhle), (8, Suhle)

Definition 10.7 Häufigkeitsverteilung (Skript 26)

Gegeben: Stichprobe $x_1, \dots, x_n$; Merkmal X mit genau s möglichen Ausprägungen $a_1, \dots, a_s$.

- (a) **Absolute Häufigkeit** der Ausprägung a_i in der Stichprobe $x_1, \dots, x_n$:

$$H_n(a_i) = \#\{j \in \{1, \dots, n\} : x_j = a_i\}$$

- (b) **Absolute empirische Häufigkeitsverteilung** der Stichprobe $x_1, \dots, x_n$: Abbildung $H_n : \{a_1, \dots, a_s\} \rightarrow \{0, \dots, n\}$ mit $a_i \mapsto H_n(a_i)$ für $i = 1, \dots, s$.

- (c) **Relative Häufigkeit** der Ausprägung a_i in der Stichprobe $x_1, \dots, x_n$:

$$h_n(a_i) = \frac{1}{n} H_n(a_i)$$

- (d) **Relative Häufigkeitsverteilung** der Stichprobe $x_1, \dots, x_n$: Abbildung $h_n : \{a_1, \dots, a_s\} \rightarrow \{\frac{k}{n} : k \in \{0, \dots, n\}\}$ mit $a_i \mapsto h_n(a_i)$ für $i = 1, \dots, s$.

Bemerkung 10.1

$$H_n(a_1) + \dots + H_n(a_s) = n \quad \text{und} \quad h_n(a_1) + \dots + h_n(a_s) = 1$$

Beispiel 10.5 Werfen von acht Schweinchen (Skript 26)

Stichprobe: Suhle, Schnauze, Faul-mit-Punkt, Haxe, Backe, Haxe, Suhle, Suhle

bzw. Urliste: (1, Suhle), (2, Schnauze), (3, Faul-mit-Punkt), (4, Haxe), (5, Backe), (6, Haxe), (7, Suhle), (8, Suhle)

Merkmalsausprägung	$H_n(a_i)$	$h_n(a_i)$
Suhle	3	3/8
Haxe	2	1/4
Schnauze	1	1/8
Backe	1	1/8
Faul-mit-Punkt	1	1/8
Faul-ohne-Punkt	0	0

10.1.2 | Graphische Darstellungen eindimensionaler Daten

Für den kleinen Datensatz (Beispiel 10.5) und den großen Datensatz (aus der Vorlesung vom 14.01.2026) mit den Schweinchen haben wir u.a. folgende Möglichkeiten der graphischen Darstellung: Kreis- bzw. Tortendiagramm sowie Stab- bzw. Balkendiagramm (siehe Abbildungen oben).


Beispiel 10.6 Alter von Berufstätigen (Skript 26)

21, 22, 24, 28, 28, 28, 32, 32, 33, 35,
 35, 36, 37, 37, 37, 40, 40, 41, 43, 43,
 44, 47, 48, 48, 53, 53, 53, 58, 60, 60,
 24, 25, 26, 27, 27, 27, 27, 28, 29, 31,
 31, 31, 31, 32, 33, 33, 34, 34, 35, 35,
 35, 36, 36, 36, 36, 37, 37, 37, 37, 38,
 38, 39, 39, 39, 39, 41, 41, 41, 41, 42,
 42, 42, 45, 45, 45, 46, 47, 47, 47, 48,
 49, 49, 49, 52, 52, 52, 54, 54, 55, 55,
 55, 56, 57, 61, 64, 65, 65, 65, 65, 65

(Simulierte Daten, bereits der Größe nach geordnet, mit Stichprobengröße $n = 100$.)


Alter	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36	37
Anz.	0	0	0	1	1	0	2	1	1	4	4	1	0	4	3	3	2	5	5	7
Alter	38	39	40	41	42	43	44	45	46	47	48	49	50	51	52	53	54	55	56	57
Anz.	2	4	2	5	3	2	1	3	1	4	3	3	0	0	3	3	2	3	1	1
Alter	58	59	60	61	62	63	64	65	66	67										
Anz.	1	0	2	1	0	0	1	5	0	0										

Weder Balken- noch Kreisdiagramm sind sinnvoll bei so vielen verschiedenen Ausprägungen:



Histogramm Klasseneinteilung wählen: Jede Klasse möge 5 Jahre erfassen – aber stimmt das am Rand?

Alter	≤ 19	20–24	25–29	30–34	35–39	40–44	45–49	50–54	55–59	60–64	≥ 65
Anz.	0	4	11	12	23	13	14	8	6	4	5



Wenn als Alter zum Beispiel nur Werte im Bereich 18–67 auftreten können, sollte die Breite der Randbalken angepasst werden (schmalere Klassen “18–19” und “65–67”).

Bemerkung 10.2 Restklasse Sollte es Ausreißer in den Daten geben (z.B. einen Berufstätigen im Alter von 91 Jahren), so wird eine Restklasse gebildet. Für diese wird kein Balken gezeichnet, sondern nur vermerkt, wie viele Elemente sie hat.

Es gibt weitere übliche Darstellungen wie das Stamm-Blatt-Diagramm oder den Box-Plot. Wir verweisen diesbezüglich auf die Literatur.

10.2 | Empirische Häufigkeitsverteilungen und ihre Lagemaße

Ziel: Charakterisierung von **Häufigkeitsverteilungen** durch Kennzahlen.

Gegeben: Stichprobe $x_1, \dots, x_n$ eines eindimensionalen **Merkmals** X .

Definition 10.8 Lagemaß (Skript 26)

Sei X ein quantitatives **Merkmal**. Eine Funktion $l: \mathbb{R}^n \rightarrow \mathbb{R}$, $(x_1, \dots, x_n) \mapsto l(x_1, \dots, x_n)$, heißt *Lagemaß*, wenn

$$l(x_1 + a, \dots, x_n + a) = l(x_1, \dots, x_n) + a \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n \quad \forall a \in \mathbb{R}.$$

Anschaulich bedeutet das, dass ein Verschieben der Werte der Stichprobe um a äquivalent ist zum Verschieben des **Lagemaßes** um a .

Beispiel 10.7 Zu Definition 10.8 ■ Das *arithmetische Mittel* $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ der Stichprobe $x_1, \dots, x_n$ ist ein **Lagemaß**.

■ Das *geometrische Mittel* $\bar{x}_g = \sqrt[n]{x_1 \cdots x_n}$ der Stichprobe $x_1, \dots, x_n$ ist *kein* **Lagemaß**.

■ Das *harmonische Mittel* $\bar{x}_h = \frac{n}{\frac{1}{x_1} + \dots + \frac{1}{x_n}}$ der Stichprobe $x_1, \dots, x_n$ ist *kein* **Lagemaß**.

Wir wollen diese Aussagen beweisen.

Das arithmetische Mittel $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ist ein Lagemaß:

Sei $l_{\text{arith}}(x_1, \dots, x_n) = \frac{1}{n} \sum_{i=1}^n x_i$. Dann gilt für alle $(x_1, \dots, x_n) \in \mathbb{R}^n$ und alle $a \in \mathbb{R}$

$$l_{\text{arith}}(x_1 + a, \dots, x_n + a) = \frac{1}{n} \sum_{i=1}^n [x_i + a] = \frac{1}{n} \sum_{i=1}^n x_i + \frac{1}{n} \sum_{i=1}^n a = l_{\text{arith}}(x_1, \dots, x_n) + a.$$

Das geometrische Mittel $\bar{x}_g = \sqrt[n]{x_1 \cdots x_n}$ ist kein Lagemaß:

Beachte zunächst, dass das geometrische Mittel nur für $x_1, \dots, x_n \geq 0$ sinnvoll definiert ist. Auch wenn wir nur $x_1, \dots, x_n \geq 0$ und $a > 0$ betrachten, erfüllt das geometrische Mittel nicht die Anforderung an ein **Lagemaß**:

Seien $n = 2$ und $l_g(x_1, x_2) = \sqrt{x_1 \cdot x_2}$. Wäre l_g ein **Lagemaß**, so müsste gelten

$$(*) \quad l_g(x_1 + a, x_2 + a) = l_g(x_1, x_2) + a \quad \forall (x_1, x_2) \in \mathbb{R}^2 \quad \forall a \in \mathbb{R}.$$

Quadrieren beider Seiten zeigt, dass $(*)$ äquivalent ist zu $\sqrt{x_1 \cdot x_2} = \frac{x_1 + x_2}{2}$. Das heißt, dass das geometrische Mittel nur dann ein **Lagemaß** sein kann, wenn arithmetisches und geometrisches Mittel für alle $(x_1, x_2) \in \mathbb{R}^2$ gleich wären.

Das harmonische Mittel $\bar{x}_h = \frac{n}{\frac{1}{x_1} + \dots + \frac{1}{x_n}}$ ist kein Lagemaß:

Beachte zunächst, dass das harmonische Mittel nur für $x_1, \dots, x_n \neq 0$ sinnvoll definiert ist. Selbst wenn wir nur $x_1, \dots, x_n > 0$ und $a > 0$ betrachten, erfüllt das harmonische Mittel nicht die Anforderung an ein **Lagemaß**:


Seien $n = 2$ und $l_h(x_1, x_2) = \frac{2}{1/x_1 + 1/x_2}$. Die Wahl $x_1 = 1$, $x_2 = 2$ und $a = 1$ zeigt

$$l_h(x_1 + a, x_2 + a) = \frac{2}{\frac{1}{1+1} + \frac{1}{2+1}} = \frac{12}{5} \quad \text{und} \quad l_h(x_1, x_2) + a = \frac{2}{\frac{1}{1} + \frac{1}{2}} + 1 = \frac{7}{3},$$

also $l_h(x_1 + a, x_2 + a) \neq l_h(x_1, x_2) + a$.

Beispiel 10.8 10× Würfeln (Skript 26)

Stichprobe 6, 2, 5, 4, 1, 6, 5, 4, 5, 4 der Länge $n = 10$.



- Arithmetisches Mittel $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{10} [6 + 2 + 5 + 4 + 1 + 6 + 5 + 4 + 5 + 4] = 4.2$
- Geometrisches Mittel $\bar{x}_g = \sqrt[n]{x_1 \cdots x_n} = \sqrt[10]{6 \cdot 2 \cdot 5 \cdot 4 \cdot 1 \cdot 6 \cdot 5 \cdot 4 \cdot 5 \cdot 4} \approx 3.77$
- Harmonisches Mittel $\bar{x}_h = \frac{n}{\frac{1}{x_1} + \cdots + \frac{1}{x_n}} = \frac{10}{\frac{1}{6} + \frac{1}{2} + \frac{1}{5} + \frac{1}{4} + \frac{1}{1} + \frac{1}{6} + \frac{1}{5} + \frac{1}{4} + \frac{1}{5} + \frac{1}{4}} \approx 3.14$

Satz 10.1 Eigenschaften des arithmetischen Mittels (Skript 26)

- (a) **Schwerpunkteigenschaft:** $\sum_{i=1}^n (x_i - \bar{x}) = 0$
- (b) **Minimierungseigenschaft:** $\sum_{i=1}^n (x_i - c)^2 \rightarrow \min$ für $c = \bar{x}$.

Das arithmetische Mittel minimiert die quadratische Abweichung der Stichprobenwerte von einer Konstanten $c \in \mathbb{R}$:

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \inf_{c \in \mathbb{R}} \sum_{i=1}^n (x_i - c)^2$$

Beweis.

- (a) Linearität der Summe und die Definition von $\bar{x}$ zeigen, dass

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} = \sum_{i=1}^n x_i - n \cdot \frac{1}{n} \sum_{i=1}^n x_i = 0.$$

- (b) Eine Nullergänzung und Ausquadrieren zeigen, dass

$$\sum_{i=1}^n (x_i - c)^2 = \sum_{i=1}^n [(x_i - \bar{x}) + (\bar{x} - c)]^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + 2(\bar{x} - c) \sum_{i=1}^n (x_i - \bar{x}) + n(\bar{x} - c)^2.$$

Der erste Summand auf der rechten Seite hängt nicht von c ab. Der zweite Summand ist gleich Null aufgrund der Schwerpunkteigenschaft. Der dritte Summand ist stets nichtnegativ und gleich Null genau dann, wenn $c = \bar{x}$ ist. Somit wird

$$\sum_{i=1}^n (x_i - c)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - c)^2$$

minimal für $c = \bar{x}$ mit Wert $\sum_{i=1}^n (x_i - \bar{x})^2$.

Definition 10.9 Modalwert / Modus (Skript 26)

Sei X ein beliebiges eindimensionales **Merkmal** (X kann nominal sein) mit Ausprägungen $a_1, \dots, a_s$. Eine Ausprägung a des **Merkmals** X heißt *Modalwert* oder *Modus*, wenn

$$H_n(a) \geq H_n(x_i) \quad \forall i = 1, \dots, n.$$


Bemerkung 10.3 (Skript 26)

- (a) a ist genau dann ein Modalwert, wenn keine andere Ausprägung in der Stichprobe häufiger auftritt als a .
- (b) Der Modalwert ist in der Regel nicht eindeutig, siehe folgendes Beispiel.
- (c) $H_n(a) \geq H_n(x_i) \quad \forall i = 1, \dots, n \iff H_n(a) \geq H_n(a_k) \quad \forall k = 1, \dots, s$.
- (d) Für quantitative **Merkmale** ist der Modalwert ein **Lagemaß**.


Definition 10.10 Unimodal (Skript 26)

Wir schreiben x_{mod} für den Modalwert einer Stichprobe, sofern dieser eindeutig bestimmt ist. In diesem Fall heißen die Häufigkeitsverteilungen H_n und h_n *unimodal*.

Beispiel 10.9 Würfeln (Skript 26)



Stichprobe 6, 2, 5, 4, 1, 6, 5, 4, 5, 4, $n = 10$
Modalwerte 4 und 5 — *nicht unimodal*



Stichprobe 6, 2, 5, 4, 1, 6, 5, 4, 5, 4, 5, $n = 11$
Modalwert $x_{\text{mod}} = 5$ — *unimodal*

Definition 10.11 Median / Zentralwert (Skript 26)

Sei X ein quantitatives **Merkmal**. Ist die Stichprobe $x_1, \dots, x_n$ gegeben, so schreiben wir $x_{(1)}, \dots, x_{(n)}$ für die *geordnete Stichprobe*, d.h. es gelten

$$\{x_1, \dots, x_n\} = \{x_{(1)}, \dots, x_{(n)}\} \quad \text{und} \quad x_{(1)} \leq \dots \leq x_{(n)}.$$

Der *Median* oder *Zentralwert* ist definiert durch

$$x_{\text{med}} = \begin{cases} x_{(\frac{n+1}{2})} & \text{falls } n \text{ ungerade ist,} \\ \frac{1}{2} [x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}] & \text{falls } n \text{ gerade ist.} \end{cases}$$

Beispiel 10.10 Würfeln (Skript 26)

Stichprobe 6, 2, 5, 4, 1, 6, 5, 4, 5, 4
geordnet 1, 2, 4, 4, 4, 5, 5, 5, 6, 6, $n = 10$

$$x_{\text{med}} = \frac{1}{2} [x_{(5)} + x_{(6)}] = \frac{4+5}{2} = 4.5$$

Stichprobe 6, 2, 5, 4, 1, 6, 5, 4, 5, 4, 5
geordnet 1, 2, 4, 4, 4, 5, 5, 5, 6, 6, $n = 11$

$$x_{\text{med}} = x_{(6)} = 5$$

Satz 10.2 Eigenschaften des Medians (Skript 26)

(a) Der Median ist ein **Lagemaß**.

(b) Der Median x_{med} erfüllt

$$\sum_{\substack{k=1: \\ a_k \leq x_{\text{med}}}}^s h_n(a_k) \geq \frac{1}{2} \quad \text{und} \quad \sum_{\substack{k=1: \\ a_k \geq x_{\text{med}}}}^s h_n(a_k) \geq \frac{1}{2}.$$

Das heißt, mindestens die Hälfte der Werte in der Stichprobe sind kleiner oder gleich dem Wert des Medians und mindestens die Hälfte der Werte in der Stichprobe sind größer oder gleich dem Wert des Medians.

(c) Gelten

$$\sum_{\substack{k=1: \\ a_k \leq a}}^s h_n(a_k) \geq \frac{1}{2} \quad \text{und} \quad \sum_{\substack{k=1: \\ a_k \geq a}}^s h_n(a_k) \geq \frac{1}{2} \quad \text{für ein } a \in \mathbb{R},$$

so folgt $x_{(\lceil n/2 \rceil)} \leq a \leq x_{(\lceil n/2 \rceil + 1)}$. Dabei muss a keine Ausprägung des **Merkmals** X sein.

(d) **Minimierungseigenschaft:**

$$\sum_{i=1}^n |x_i - c| \rightarrow \min \quad \text{für ein } c \in [x_{(\lfloor \frac{n+1}{2} \rfloor)}, x_{(\lceil \frac{n+1}{2} \rceil)}].$$

Beweis.

(a) Können Sie diese Aussage selbst beweisen?

(b) Zu zeigen ist, dass der Median $\sum_{k=1: a_k \leq x_{\text{med}}}^s h_n(a_k) \geq \frac{1}{2}$ und $\sum_{k=1: a_k \geq x_{\text{med}}}^s h_n(a_k) \geq \frac{1}{2}$ erfüllt. Wir begnügen uns damit, die erste Aussage zu zeigen; die zweite lässt sich analog beweisen.

Unter Verwendung der Definition der absoluten empirischen Häufigkeitsverteilung sehen wir, dass

$$\sum_{\substack{k=1: \\ a_k \leq x_{\text{med}}}}^s h_n(a_k) = \frac{1}{n} \sum_{\substack{k=1: \\ a_k \leq x_{\text{med}}}}^s H_n(a_k) = \frac{1}{n} \# \{i \in \{1, \dots, n\} : x_i \leq x_{\text{med}}\} = \frac{1}{n} \# \{i \in \{1, \dots, n\} : x_{(i)} \leq x_{\text{med}}\}.$$

1. Fall: n ungerade. Für ungerade n ist $x_{\text{med}} = x_{(\frac{n+1}{2})}$, und daher

$$\# \{i \in \{1, \dots, n\} : x_{(i)} \leq x_{\text{med}}\} \geq \frac{n+1}{2} \geq \frac{n}{2},$$

weil mindestens die $\frac{n+1}{2}$ Elemente $x_{(1)} \leq \dots \leq x_{(\frac{n+1}{2})}$ in der Menge sind. Daraus folgt die Behauptung.

Beispiel: $n = 5$, geordnete Stichprobe 1, 1, 2, 2, 5 (Augenzahl beim Würfeln). Es ist $x_{\text{med}} = x_{(3)} = 2$, und $\frac{1}{5} \# \{i : x_{(i)} \leq 2\} = \frac{4}{5} \geq \frac{1}{2}$, ebenso $\sum_{k: a_k \leq x_{\text{med}}} h_5(a_k) = h_5(1) + h_5(2) = \frac{2}{5} + \frac{2}{5} = \frac{4}{5} \geq \frac{1}{2}$.

2. Fall: n gerade. Für gerade n ist $x_{\text{med}} = \frac{1}{2} \left[x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)} \right] \geq x_{(\frac{n}{2})}$, weil $x_{(\frac{n}{2}+1)} \geq x_{(\frac{n}{2})}$. Daher gilt $\#\{i : x_{(i)} \leq x_{\text{med}}\} \geq \frac{n}{2}$, weil mindestens die $\frac{n}{2}$ Elemente $x_{(1)} \leq \dots \leq x_{(\frac{n}{2})}$ in der Menge sind.

Beispiel: $n = 6$, geordnete Stichprobe 1, 1, 1, 2, 2, 5. Es ist $x_{\text{med}} = \frac{1}{2}[x_{(3)} + x_{(4)}] = \frac{3}{2}$, und $\frac{1}{6}\#\{i : x_{(i)} \leq \frac{3}{2}\} = \frac{3}{6} = \frac{1}{2} \geq \frac{1}{2}$, ebenso $h_6(1) = \frac{3}{6} = \frac{1}{2} \geq \frac{1}{2}$.

(c) Wir müssen zeigen: Gelten $\sum_{k: a_k \leq a} h_n(a_k) \geq \frac{1}{2}$ und $\sum_{k: a_k \geq a} h_n(a_k) \geq \frac{1}{2}$ für ein $a \in \mathbb{R}$, so folgt $x_{(\lceil n/2 \rceil)} \leq a \leq x_{(\lceil n/2 + 1 \rceil)}$.

Wir schreiben wieder die Summen um und erhalten $\#\{i : x_{(i)} \leq a\} \geq \frac{n}{2}$ und $\#\{i : x_{(i)} \geq a\} \geq \frac{n}{2}$.

1. Fall: n ungerade. Für ungerade n ist $\frac{n}{2} \notin \mathbb{N}$. Daher müssen sogar $\#\{i : x_{(i)} \leq a\} \geq \frac{n+1}{2}$ und $\#\{i : x_{(i)} \geq a\} \geq \frac{n+1}{2}$ gelten. Folglich ergibt sich durch Abzählen von unten bzw. oben, dass $x_{(1)} \leq \dots \leq x_{(\frac{n+1}{2})} \leq a$ und $x_{(n)} \geq \dots \geq x_{(\frac{n+1}{2})} \geq a$ gelten. Damit haben wir sogar $x_{\text{med}} = x_{(\frac{n+1}{2})} = a$ gezeigt.

Beispiel: $n = 5$, geordnete Stichprobe 1, 1, 2, 2, 5. Es gilt $h_5(1) = \frac{2}{5} < \frac{1}{2}$, aber $h_5(1) + h_5(2) \geq \frac{1}{2}$; ebenso von oben betrachtet muss $a = 2$ gelten.

2. Fall: n gerade. Für gerade n wissen wir nur $\#\{i : x_{(i)} \leq a\} \geq \frac{n}{2}$ und $\#\{i : x_{(i)} \geq a\} \geq \frac{n}{2}$. Wieder ergibt sich $x_{(1)} \leq \dots \leq x_{(\frac{n}{2})} \leq a$ und $x_{(n)} \geq \dots \geq x_{(\frac{n}{2}+1)} \geq a$. Damit haben wir $x_{(\frac{n}{2})} \leq a \leq x_{(\frac{n}{2}+1)}$ gezeigt.

Beispiel: $n = 6$, geordnete Stichprobe 1, 1, 1, 2, 2, 5. Es gilt $h_6(1) \geq \frac{1}{2}$, also muss $a \geq 1$ gelten; von oben betrachtet muss $a \leq 2$ gelten. Somit muss $1 \leq a \leq 2$ gelten; insbesondere ist der Median $x_{\text{med}} = \frac{3}{2}$ eine zulässige Wahl von a .

Beispiel 10.11 Würfeln (Skript 26)

geordnete Stichprobe 1, 2, 4, 4, 4, 5, 5, 5, 6, 6, $n = 10$,
 $x_{\text{med}} = 4.5$

$$\sum_{\substack{k=1: \\ a_k \leq x_{\text{med}}}}^s h_n(a_k) = \frac{1+1+0+3}{10} = \frac{5}{10} = \frac{1}{2} \geq \frac{1}{2}$$

$$\sum_{\substack{k=1: \\ a_k \geq x_{\text{med}}}}^s h_n(a_k) = \frac{3+2}{10} = \frac{5}{10} = \frac{1}{2} \geq \frac{1}{2}$$

geordnete Stichprobe 1, 2, 4, 4, 4, 5, 5, 5, 5, 6, 6, $n = 11$,
 $x_{\text{med}} = 5$

$$\sum_{\substack{k=1: \\ a_k \leq x_{\text{med}}}}^s h_n(a_k) = \frac{1+1+0+3+4}{11} = \frac{9}{11} \geq \frac{1}{2}$$

$$\sum_{\substack{k=1: \\ a_k \geq x_{\text{med}}}}^s h_n(a_k) = \frac{4+2}{11} = \frac{6}{11} \geq \frac{1}{2}$$

10.3 | Empirische Häufigkeitsverteilungen und ihre Streumaße

Ziel: Charakterisierung von Häufigkeitsverteilungen durch Kennzahlen (Fortsetzung).

Gegeben:

- Quantitatives, eindimensionales Merkmal X mit Ausprägungen $a_1, \dots, a_s$
- Stichprobe $x_1, \dots, x_n$
- geordnete Stichprobe $x_{(1)}, \dots, x_{(n)}$

Definition 10.12 Streumaß (Skript 26)

Eine Funktion $s : \mathbb{R}^n \rightarrow \mathbb{R}$, $(x_1, \dots, x_n) \mapsto s(x_1, \dots, x_n)$, heißt **Streumaß**, wenn

$$s(x_1 + a, \dots, x_n + a) = s(x_1, \dots, x_n) \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n \quad \forall a \in \mathbb{R}.$$

Anschaulich bedeutet das, dass ein Verschieben der Werte der Stichprobe um ein a den Wert eines Streumaßes nicht verändert.

Beispiel 10.12 Ein ganzer Zoo an Streumaßen (Skript 26)

Im Folgenden dient uns zur Illustration stets die (geordnete) Stichprobe 1, 1, 2, 2, 3, 4, 4, 4, 6 der Länge $n = 10$. Wir können uns die Stichprobe vorstellen als das Ergebnis von 10-maligem Würfeln.

- (a) Die *Spannweite* $x_{\max} - x_{\min} = x_{(n)} - x_{(1)}$ der Stichprobe $x_1, \dots, x_n$ ist ein **Streumaß** (nicht robust gegenüber Ausreißern).

Im Beispiel: $x_{\max} - x_{\min} = 6 - 1 = 5$.

- (b) Die *Medianabweichung* ist der “Median der absoluten Abweichung vom Median” und wird folgendermaßen definiert: Wir bilden zunächst eine neue Stichprobe $y_1, \dots, y_n$ mit $y_i = |x_i - x_{\text{med}}|$. Die Medianabweichung der ursprünglichen Stichprobe $x_1, \dots, x_n$ ist der Median y_{med} der neuen Stichprobe (robust gegenüber Ausreißern).

Im Beispiel: Es ist $x_{\text{med}} = 2.5$, und die geordnete Stichprobe $y_{(1)}, \dots, y_{(10)}$ ergibt sich folglich als 0.5, 0.5, 0.5, 0.5, 1.5, 1.5, 1.5, 1.5, 3.5, 3.5 mit Median $y_{\text{med}} = 1.5$.

- (c) Die *mittlere absolute Abweichung vom Median* ist definiert durch das arithmetische Mittel der Hilfsstichprobe $y_1, \dots, y_n$ mit $y_i = |x_i - x_{\text{med}}|$:

$$\bar{s} = \frac{1}{n} \sum_{i=1}^n |x_i - x_{\text{med}}| = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}$$

(nicht robust gegenüber Ausreißern; seien z.B. $n = 3$ sowie $x_1 = x_2 = 0$. Für x_3 betrachten wir zwei Werte: Ist $x_3 = 0$, so gelten $x_{\text{med}} = 0$ und folglich $\bar{s} = 0$. Haben wir dagegen mit $x_3 = 100$ einen Ausreißer, so ist weiterhin $x_{\text{med}} = 0$, denn der Median ist robust, aber es gilt $\bar{s} = 100/3$.)

Im Beispiel: $\bar{s} = \bar{y} = 1.3$.

- (d) Die *mittlere absolute Abweichung vom arithmetischen Mittel* ist definiert als

$$\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

(nicht robust gegenüber Ausreißern; seien z.B. $n = 100$ und alle x_i klein, d.h. $|x_i| \leq \varepsilon$. Dann ist auch $|\bar{x}| \leq \varepsilon$, und es folgt $\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \leq 2\varepsilon$. Haben wir dagegen einen Ausreißer $x_{100} = 10\,000$, während $|x_1|, \dots, |x_{99}| = 0$, so ist $\bar{x} = 100$ und $\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| = 198$.)

Im Beispiel: $\bar{x} = 29/10 = 2.9$ und $\bar{s} = \frac{1}{10} \sum_{i=1}^n |x_i - 2.9| = 1.3$.

- (e) Die *mittlere quadratische Abweichung vom arithmetischen Mittel* oder (Stichproben-) *Varianz* ist definiert als

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

(nicht robust gegenüber Ausreißern; verwenden Sie das Beispiel aus (d)).

Im Beispiel: $\bar{x} = 29/10 = 2.9$ und

$$s^2 = \frac{1}{10} \left[(1-2.9)^2 + (1-2.9)^2 + (2-2.9)^2 + (2-2.9)^2 + (2-2.9)^2 + (3-2.9)^2 + (4-2.9)^2 + (4-2.9)^2 + (4-2.9)^2 + (6-2.9)^2 \right] = \dots$$

Der folgende Satz wird uns eine bessere Methode zeigen, die Stichprobenvarianz in diesem Fall zu berechnen.

- (f) Die *Standardabweichung* ist definiert als $s = \sqrt{s^2}$ (nicht robust gegenüber Ausreißern, da die Stichprobenvarianz nicht robust ist).

Beweisen Sie als Hausaufgabe, dass es sich jeweils um **Streumaße** handelt.

Satz 10.3 Berechnen der (Stichproben-)Varianz / Steinersche Formel (Skript 26)

$$s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \left(\frac{1}{n} \sum_{i=1}^n x_i \right)^2$$

Beweis. Beweisen Sie dieses Resultat selbständig.

Beispiel 10.13 (Skript 26) Für die (geordnete) Stichprobe 1, 1, 2, 2, 2, 3, 4, 4, 4, 6 der Länge $n = 10$ gilt

$$s^2 = \frac{1}{10} [1^2 + 1^2 + 2^2 + 2^2 + 2^2 + 3^2 + 4^2 + 4^2 + 4^2 + 6^2] - 2.9^2 = \dots$$

Satz 10.4 Berechnen von $\bar{s}$ und s^2 mittels der Häufigkeitsverteilung (Skript 26)

$$(a) \quad \bar{s} = \frac{1}{n} \sum_{k=1}^s |a_k - x_{\text{med}}| H_n(a_k) = \sum_{k=1}^s |a_k - x_{\text{med}}| h_n(a_k)$$

$$(b) \quad s^2 = \frac{1}{n} \sum_{k=1}^s [a_k - \bar{x}]^2 H_n(a_k) = \sum_{k=1}^s [a_k - \bar{x}]^2 h_n(a_k)$$

Beweis.

$$\bar{s} = \frac{1}{n} \sum_{i=1}^n |x_i - x_{\text{med}}| = \frac{1}{n} \sum_{k=1}^s \sum_{\substack{i=1: \\ x_i=a_k}}^n |x_i - x_{\text{med}}| = \frac{1}{n} \sum_{k=1}^s |a_k - x_{\text{med}}| H_n(a_k) = \sum_{k=1}^s |a_k - x_{\text{med}}| h_n(a_k)$$

sowie

$$s^2 = \frac{1}{n} \sum_{i=1}^n [x_i - \bar{x}]^2 = \frac{1}{n} \sum_{k=1}^s \sum_{\substack{i=1: \\ x_i=a_k}}^n [x_i - \bar{x}]^2 = \frac{1}{n} \sum_{k=1}^s [a_k - \bar{x}]^2 H_n(a_k) = \sum_{k=1}^s [a_k - \bar{x}]^2 h_n(a_k).$$

In beiden Rechnungen haben wir verwendet, dass für gegebenes k in der inneren Summe $\sum_{i=1: x_i=a_k}^n \dots$ die jeweiligen Summanden $|x_i - x_{\text{med}}| = |a_k - x_{\text{med}}|$ bzw. $[x_i - \bar{x}]^2 = [a_k - \bar{x}]^2$ konstant sind. Daher müssen wir nur die Anzahl der Summanden bestimmen, und diese beträgt jeweils $H_n(a_k)$.

Beispiel 10.14 (Skript 26)

Für die geordnete Stichprobe 1, 1, 2, 2, 2, 3, 4, 4, 4, 6 der Länge $n = 10$ gilt

$$s^2 = \frac{1}{10} [2 \cdot (1 - 2.9)^2 + 3 \cdot (2 - 2.9)^2 + (3 - 2.9)^2 + 3 \cdot (4 - 2.9)^2 + (6 - 2.9)^2] \approx 2.9.$$

Definition 10.13 Empirisches p -Quantil (Skript 26)

Sei $p \in (0, 1)$. Dann heißt

$$x_p = \begin{cases} x_{(\lceil np \rceil)} & \text{falls } np \notin \mathbb{N} \\ \frac{1}{2} [x_{(np)} + x_{(np+1)}] & \text{falls } np \in \mathbb{N} \end{cases}$$

empirisches p -Quantil.

Bemerkung 10.4 (Skript 26)

- (a) $x_{1/2} = x_{\text{med}}$
- (b) Wie der Median ist auch das empirische p -Quantil ein robustes Lagemaß.

Beispiel 10.15 10× Würfeln (Skript 26)

Geordnete Stichprobe: 1, 1, 2, 2, 2, 3, 4, 4, 4, 6, $n = 10$.

- $p = 1/2$: $np = 5 \in \mathbb{N}$ und $x_{1/2} = x_{\text{med}} = \frac{1}{2}[x_{(5)} + x_{(6)}] = \frac{1}{2}[2 + 3] = \frac{5}{2} = 2.5$
- $p = 1/4$: $np = 2.5 \notin \mathbb{N}$, $\lceil np \rceil = 3$ und $x_{1/4} = x_{(3)} = 2$
- $p = 3/4$: $np = 7.5 \notin \mathbb{N}$, $\lceil np \rceil = 8$ und $x_{3/4} = x_{(8)} = 4$

Satz 10.5 Charakterisierung des p -Quantils (Skript 26)

- (a) Das p -Quantil x_p erfüllt

$$\sum_{\substack{k=1: \\ a_k \leq x_p}}^s h_n(a_k) \geq p \quad \text{und} \quad \sum_{\substack{k=1: \\ a_k \geq x_p}}^s h_n(a_k) \geq 1 - p.$$

Das heißt, mindestens $100p\%$ der Werte in der Stichprobe sind kleiner oder gleich dem Wert des p -Quantils und mindestens $100(1-p)\%$ der Werte in der Stichprobe sind größer oder gleich dem Wert des p -Quantils.

- (b) Gelten

$$\sum_{\substack{k=1: \\ a_k \leq a}}^s h_n(a_k) \geq p \quad \text{und} \quad \sum_{\substack{k=1: \\ a_k \geq a}}^s h_n(a_k) \geq 1 - p \quad \text{für ein } a \in \mathbb{R},$$

so folgt $x_{(\lceil np \rceil)} \leq a \leq x_{(\lceil np \rceil + 1)}$. Dabei muss a keine Ausprägung des Merkmals X sein.

Wir wissen sogar, dass $x_{(np)} \leq a \leq x_{(np+1)}$ für $np \in \mathbb{N}$ gilt, sowie $a = x_{(\lceil np \rceil)}$ sonst.

Definition 10.14 p -Quantilsabstand (Skript 26)

Sei $p \in (0, \frac{1}{2})$. Wir nennen $x_{1-p} - x_p$ den p -Quantilsabstand. Der $1/4$ -Quantilsabstand wird auch Quartilsabstand genannt.

Zeigen Sie das folgende Lemma als Hausaufgabe.

Lemma 10.1 p -Quantilsabstand als Streumaß (Skript 26)

Der p -Quantilsabstand ist ein Streumaß.

In unserem Beispieldatensatz zum Würfeln sehen wir, dass der Quartilsabstand

$$x_{3/4} - x_{1/4} = 4 - 2 = 2$$

beträgt.

Zur Unterhaltung: <https://mathwithbaddrawings.com/2016/07/13/why-not-to-trust-statistics>

KAPITEL 11

Schließende Statistik: Testtheorie I

Ziel: Schließen von einer Stichprobe auf Verteilungsparameter.

Annahme

Im Folgenden nehmen wir stets an, dass eine Stichprobe $x_1, \dots, x_n$ vorliegt, von der wir annehmen können, dass sie aus Werten besteht, die von einem n -fach unabhängig wiederholten Zufallsexperiment stammen.

Das heißt, wir nehmen an, dass es einen Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$, unabhängige, identisch verteilte, $\mathbb{R}$ -wertige Zufallsvariablen $X_1, \dots, X_n$ und ein $\omega \in \Omega$ gibt derart, dass

$$(x_1, \dots, x_n) = (X_1(\omega), \dots, X_n(\omega)).$$

Wir werden die Theorie jeweils am Beispiel von **Bernoulli-Variablen** illustrieren.

Beispiel 11.1 Fragestellung im Fall von Bernoulli-Variablen (Skript 26)

Die n unabhängigen **Bernoulli-Variablen** können wir als Modell verstehen für das Werfen einer (nicht unbedingt fairen) Münze, für das Werfen einer Reißzwecke oder auch für einen Spezialfall des Werfens unserer Schweinchen: Beim Werfen der Schweinchen in der Vorlesung haben wir die Schweinchen 166-mal geworfen. Wenn wir nur jene Würfe als Erfolg gezählt hätten, in denen ein Schweinchen auf der Schnauze gelandet ist, so wäre dies ein Bernoulli-Experiment gewesen. Wir können jedoch auch im Nachhinein die anderen Resultate ignorieren und unser Experiment als reines Bernoulli-Experiment betrachten, wenn uns nur eine der möglichen Positionen interessiert.

All diesen Situationen ist gemein, dass wir die tatsächliche Erfolgswahrscheinlichkeit nicht kennen und auch kein Symmetrieargument verwenden können, um diese zu bestimmen. Wir arbeiten daher zunächst mit einem Parameter, der in der Statistik üblicherweise mit θ bezeichnet wird und die Rolle der Erfolgswahrscheinlichkeit übernimmt.

Im Fall von **Bernoulli-Variablen** ist das Modell für das Zufallsexperiment also gegeben durch

- Ereignisraum $\Omega = \{0, 1\}^n$
- unbekannte Erfolgswahrscheinlichkeit $\theta \in [0, 1]$
- Wahrscheinlichkeitsfunktion $\mu_\theta(\omega) = \theta^{\sum_{i=1}^n \omega_i} (1 - \theta)^{n - \sum_{i=1}^n \omega_i}$ für alle $\omega \in \Omega$
- $X_i : \Omega \rightarrow \{0, 1\}$ mit $X_i(\omega) = \omega_i$ für alle $\omega \in \Omega$ und alle $i \in \{1, \dots, n\}$

Definition 11.1 Stichprobe, Stichprobenvariable und Stichprobenraum (Skript 26)

- (a) Die Zufallsvariablen $X_1, \dots, X_n$ heißen *Stichprobenvariable*.

(b) Eine Realisation

$$x = (x_1, \dots, x_n) = (X_1(\omega), \dots, X_n(\omega)) = X(\omega)$$

für ein gegebenes $\omega \in \Omega$ heißt *Stichprobe*.

(c) Der Bildbereich $\mathcal{X} = X(\Omega) = (X_1, \dots, X_n)(\Omega)$ der n -dimensionalen Zufallsvariablen X heißt *Stichprobenraum*. Der *Stichprobenraum* $\mathcal{X}$ ist die Menge aller möglichen Stichproben (bei gegebenem Experiment).

Beispiel 11.2 Bernoulli-Variable (Skript 26)

Im Fall von *Bernoulli-Variablen* erfüllen die unabhängigen *Stichprobenvariablen* $X_1, \dots, X_n$

$$\mathbb{P}_\theta(X_i = 1) = \theta \quad \text{und} \quad \mathbb{P}_\theta(X_i = 0) = 1 - \theta \quad \forall i \in \{1, \dots, n\}.$$

Ist $n = 3$ und $\omega \in \Omega$ zum Beispiel gegeben durch $\omega = (0, 0, 1)$, so ergibt sich die Stichprobe zu $x = (x_1, x_2, x_3) = (X_1(\omega), X_2(\omega), X_3(\omega)) = (0, 0, 1)$, weil die *Stichprobenvariablen* in diesem Fall die Projektionen von Ω auf die einzelnen Komponenten sind.

Der *Stichprobenraum* ist $\mathcal{X} = X(\Omega) = \{0, 1\}^3$.

Definition 11.2 Statistisches Modell (Skript 26)

Ein *statistisches Modell* für ein gegebenes Zufallsexperiment ist eine Familie $\mathcal{P}$ von Wahrscheinlichkeitsmaßen P auf dem *Stichprobenraum* $\mathcal{X}$, wobei die Wahrscheinlichkeitsmaße $P \in \mathcal{P}$ die möglichen Verteilungen von $X = (X_1, \dots, X_n)$ beschreiben.

Gilt $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$, so heißt Θ der *Parameterraum* und $\theta \in \Theta$ heißt *Parameter*.

Beispiel 11.3 Bernoulli-Variable (Skript 26)

Im Fall von unabhängigen *Bernoulli-Variablen* als *Stichprobenvariable* $X_1, \dots, X_n$ ist das zugehörige statistische Modell gegeben durch $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$, wobei wir im Allgemeinen $\Theta = [0, 1]$ wählen und $\mathbb{P}_\theta$ durch die Wahrscheinlichkeitsfunktion μ_θ mit

$$\mu_\theta(\omega) = \theta^{\sum_{i=1}^n \omega_i} (1 - \theta)^{n - \sum_{i=1}^n \omega_i} \quad \text{für alle } \omega \in \Omega$$

gegeben ist.

Wenn wir Grund haben anzunehmen, dass für die Erfolgswahrscheinlichkeit gewisse Werte ausgeschlossen werden können, so kann Θ auch als echte Teilmenge von $[0, 1]$ gewählt werden.

Unser Ziel ist es nun, systematisch aus Stichproben Schlüsse zu ziehen über die dem Zufallsexperiment zugrunde liegende Wahrscheinlichkeitsverteilung. Konkreter heißt das: Wir nehmen an, dass wir die Verteilung der *Stichprobenvariablen* bis auf den oder die Parameter der Verteilung kennen, und wollen nun anhand einer Stichprobe die Parameter der Verteilung bestmöglich schätzen. Im Fall von *Bernoulli-Variablen* heißt das, dass wir die Erfolgswahrscheinlichkeit θ schätzen wollen. Im Folgenden werden wir auch andere Kennzahlen der Wahrscheinlichkeitsverteilung wie Erwartungswert oder Varianz schätzen.

Grundsätzlich gibt es verschiedene Typen von Resultaten, die wir anhand einer Stichprobe gewinnen können:

1. Punktschätzer: Resultat ist ein Wert θ oder $g(\theta)$ mit $\theta \in \Theta$

2. Bereichsschätzer: Resultat ist eine Teilmenge von Θ

3. Hypothesentest: Resultat ist eine Ja-Nein-Entscheidung über eine den Parameter betreffende *Hypothese*

Wir befassen uns in diesem Kapitel mit *Punktschätzern*.

Definition 11.3 Punktschätzer (Skript 26)

Sei ein statistisches Modell der Form $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ gegeben.

- (a) Ein **Schätzer** für $\theta \in \Theta$ ist eine Abbildung $t : \mathcal{X} \rightarrow \Theta$. Wir nennen auch die Zufallsvariable $T = t(X) = t((X_1, \dots, X_n))$ einen **Schätzer** für $\theta \in \Theta$. Eine Realisierung $t(x) = t((x_1, \dots, x_n))$ bzw. $T(\omega)$ heißt *Schätzung* für θ .
- (b) Sei zusätzlich eine Abbildung $g : \Theta \rightarrow \Gamma$ gegeben. Ein **Schätzer** für $g(\theta)$ ist eine Abbildung $t : \mathcal{X} \rightarrow \Gamma$. Wir nennen auch die Zufallsvariable $T = t(X) = t((X_1, \dots, X_n))$ einen **Schätzer** für $g(\theta)$. Eine Realisierung $t(x) = t((x_1, \dots, x_n))$ bzw. $T(\omega)$ heißt *Schätzung* für $g(\theta)$.

Wir werden uns zunächst auf **Schätzer** für θ konzentrieren und später auf **Schätzer** für $g(\theta)$ zurückkommen.

Schätzer (Funktion)	Schätzung (Funktionswert)
Rechenvorschrift $t : \mathcal{X} \rightarrow \Theta$; ordnet jeder Stichprobe einen Parameterwert zu	Ergebnis $t(x)$ der Auswertung der Rechenvorschrift für eine konkrete Stichprobe

Bemerkung 11.1 Unterschied zwischen Schätzer und Schätzung für θ **Beispiel 11.4 Schätzer können absurd schlecht sein** (Skript 26)

Im Fall von unabhängigen **Bernoulli-Variablen** als **Stichprobenvariable** $X_1, \dots, X_n$ haben wir den **Stichprobenraum** $\mathcal{X} = \{0, 1\}^n$ sowie den Parameterraum $\Theta = [0, 1]$. Gemäß Definition ist die Abbildung $t : \mathcal{X} \rightarrow \Theta$ mit $t(x) = \frac{1}{2}$ für alle $x \in \mathcal{X}$ eine zulässige Wahl für einen **Schätzer** der Erfolgswahrscheinlichkeit. Offensichtlich ist diese, nicht von der Stichprobe abhängige Wahl nicht sinnvoll.

Motiviert durch das Gesetz der großen Zahlen und die Tatsache, dass für **Bernoulli-Variable** der Erwartungswert der Erfolgswahrscheinlichkeit entspricht, vermuten wir, dass das arithmetische Mittel der Stichprobenwerte $t(x) = \frac{1}{n} \sum_{i=1}^n x_i$ eine klügere Wahl sein sollte.

Dies wirft die Frage auf, wann ein **Schätzer** ein guter **Schätzer** ist. Wir benötigen Kriterien, um **Schätzer** systematisch beurteilen zu können.

Definition 11.4 Kriterien zur Beurteilung von Punktschätzern (Skript 26)

Gegeben seien ein statistisches Modell der Form $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$, eine Abbildung $g : \Theta \rightarrow \Gamma$, sowie ein **Schätzer** $t : \mathcal{X} \rightarrow \Gamma$ für $g(\theta)$.^a

- (a) Der *Bias* des **Schätzers** t ist definiert als

$$\text{Bias}_t(\theta) = \mathbb{E}_\theta[T] - g(\theta) = \mathbb{E}_\theta[t((X_1, \dots, X_n))] - g(\theta) \quad \text{für alle } \theta \in \Theta.$$

Dabei sei $\mathbb{E}_\theta$ der Erwartungswert, der mit dem Wahrscheinlichkeitsmaß $\mathbb{P}_\theta$ definiert ist.

- (b) Der **Schätzer** t heißt *erwartungstreu*, wenn $\text{Bias}_t(\theta) = 0$ für alle $\theta \in \Theta$ gilt.
- (c) Das *Risiko* des **Schätzers** t im Punkt $\theta \in \Theta$ ist definiert als die erwartete quadratische Abweichung des **Schätzers** von $g(\theta)$, das heißt,

$$R(\theta, t) = \mathbb{E}_\theta[(T - g(\theta))^2].$$

- (d) Die *Risikofunktion* des **Schätzers** t ist definiert als die Abbildung $\theta \mapsto R(\theta, t)$.
- (e) Sind $t_1, t_2 : \mathcal{X} \rightarrow \Gamma$ zwei **Schätzer** für $g(\theta)$, so sagen wir, dass t_1 *mindestens so gut* ist wie t_2 , wenn $R(\theta, t_1) \leq$

$R(\theta, t_2)$ für alle $\theta \in \Theta$ gilt. Gilt zusätzlich, dass es ein $\theta \in \Theta$ gibt mit $R(\theta, t_1) < R(\theta, t_2)$, so sagen wir, dass t_1 besser als t_2 ist.

^aDer Fall, dass wir mit einem **Schätzer** für den Parameter θ selbst arbeiten, entspricht der Wahl $\Gamma = \Theta$ und $g(x) = x$ für alle $x \in \mathcal{X}$. Wir müssen daher die beiden Fälle nicht unterscheiden.

Beispiel 11.5 Das arithmetische Mittel als **Schätzer** im Fall von **Bernoulli-Variablen** (Skript 26)

Im Fall von unabhängigen **Bernoulli-Variablen** als **Stichprobenvariable** $X_1, \dots, X_n$ erhalten wir folgende Ergebnisse für den **Schätzer** t mit

$$t(x) = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{für alle } x \in \{0, 1\}^n,$$

den wir verwenden wollen, um den Parameter θ , d.h. die Erfolgswahrscheinlichkeit, zu schätzen.

(a) Der Bias des **Schätzers** t ist

$$\text{Bias}_t(\theta) = \mathbb{E}_\theta \left[\frac{1}{n} \sum_{i=1}^n X_i \right] - \theta = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_\theta[X_i] - \theta = 0 \quad \text{für alle } \theta \in \Theta,$$

weil für die **Bernoulli-Variablen** $\mathbb{E}_\theta[X_i] = \theta$ gilt.


(b) Daher ist der **Schätzer** t erwartungstreu.

(c) Das Risiko des **Schätzers** t im Punkt $\theta \in \Theta$ ergibt sich zu

$$R(\theta, t) = \mathbb{E}_\theta \left[\left(\frac{1}{n} \sum_{i=1}^n X_i - \theta \right)^2 \right] = \text{Var}_\theta \left(\frac{1}{n} \sum_{i=1}^n X_i \right) = \frac{1}{n} \text{Var}_\theta(X_1) = \frac{\theta(1-\theta)}{n}.$$

Auch für unbekanntes $\theta \in \Theta = [0, 1]$ können wir eine von θ unabhängige obere Schranke an das Risiko bestimmen. Die Abbildung $\theta \mapsto \theta(1-\theta)$ wird maximal in $\theta = \frac{1}{2}$ mit Wert $\frac{1}{4}$. Daher gilt

$$R(\theta, t) = \frac{\theta(1-\theta)}{n} \leq \frac{1}{4n} \quad \text{für alle } \theta \in \Theta.$$



(d) Die **Risikofunktion** des **Schätzers** t ist gegeben durch die Abbildung $\theta \mapsto \frac{\theta(1-\theta)}{n}$.

(e) Wir wollen nun den **Schätzer** t mit einem anderen **Schätzer** vergleichen. Sei der **Schätzer** $\tilde{t}$ gegeben durch

$$\tilde{t}(x) = \frac{x_1 + x_n}{2} \quad \text{für alle } x \in \{0, 1\}^n,$$

das heißt, wir sind “faul” und verwenden nur den ersten und den letzten Stichprobenwert. Das Risiko von $\tilde{t}$ in θ ist gegeben durch $R(\theta, \tilde{t}) = \frac{\theta(1-\theta)}{2}$ (dieselbe Rechnung wie für t , nur diesmal mit Stichprobengröße 2).

Wir haben das – keineswegs überraschende – Ergebnis, dass t mindestens so gut ist wie $\tilde{t}$, sofern $n \geq 2$. Für $n > 2$ haben wir sogar, dass t besser als $\tilde{t}$ ist.

Lemma 11.1 Rechenregeln für Bias und Risiko (Skript 26)

Sei t ein **Schätzer** für $g(\theta)$. Dann gelten:

- (a) Der **Schätzer** t ist genau dann erwartungstreu, wenn $\mathbb{E}_\theta[T] = g(\theta)$ für alle $\theta \in \Theta$ gilt.
- (b) $R(\theta, t) = (\text{Bias}_t(\theta))^2 + \text{Var}_\theta(T)$
- (c) Ist t erwartungstreu, so gilt $R(\theta, t) = \text{Var}_\theta(T)$.

Beweis.

- (a) Folgt direkt aus der Definition des Bias und der Erwartungstreue.
- (b) Aus der Definition von Bias und Risiko folgt mit Hilfe einer Nullergänzung, dass

$$\begin{aligned} R(\theta, t) &= \mathbb{E}_\theta[(T - g(\theta))^2] = \mathbb{E}_\theta\left[\left((T - \mathbb{E}_\theta[T]) + (\mathbb{E}_\theta[T] - g(\theta))\right)^2\right] \\ &= \mathbb{E}_\theta[(T - \mathbb{E}_\theta[T])^2] + 2(\mathbb{E}_\theta[T] - g(\theta)) \mathbb{E}_\theta[T - \mathbb{E}_\theta[T]] + (\mathbb{E}_\theta[T] - g(\theta))^2 \\ &= \text{Var}_\theta(T) + (\text{Bias}_t(\theta))^2. \end{aligned}$$

- (c) Folgt direkt aus der Definition der Erwartungstreue.

Bisher haben wir ausschließlich den Parameter geschätzt, der im Spezialfall der **Bernoulli-Variablen** mit dem Erwartungswert zusammenfällt. Im allgemeinen Fall, wenn die **Stichprobenvariablen** möglicherweise eine andere Verteilung haben, dient das arithmetische Mittel als **Schätzer** für den Erwartungswert. Wir sehen uns als Nächstes ein paar Beispiele an. Der allgemeine Fall verbleibt als Hausaufgabe.

Beispiel 11.6 Das arithmetische Mittel als Schätzer des Erwartungswerts (Skript 26)

Seien $X_1, \dots, X_n$ **Stichprobenvariable** und t ein **Schätzer** für den Erwartungswert, der durch

$$t(x) = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{für alle } x \in \mathcal{X}$$

definiert ist.

- (a) **Geometrisch verteilte Stichprobenvariable.** Sei $\theta \in \Theta = [0, 1]$ und gelte

$$\mathbb{P}_\theta(X_i = k) = (1 - \theta)^{k-1} \theta \quad \text{für alle } k \in \mathbb{N}.$$

Dann ist der Bias des **Schätzers** t gegeben durch

$$\text{Bias}_t(\theta) = \mathbb{E}_\theta\left[\frac{1}{n} \sum_{i=1}^n X_i\right] - \mathbb{E}[\sum X_1] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_\theta[X_i] - \mathbb{E}[\sum X_1] = 0 \quad \text{für alle } \theta \in \Theta,$$

weil $X_1, \dots, X_n$ identisch verteilt sind. Wir schätzen mit t den Erwartungswert $\mathbb{E}[\sum X_1] = \frac{1}{\theta}$. Der **Schätzer** ist erwartungstreu.

- (b) **Gleichverteilte Stichprobenvariable.** Sei $\theta \in \Theta = \mathbb{N}$ und gelte

$$\mathbb{P}_\theta(X_i = k) = \frac{1}{\theta} \quad \text{für alle } k \in \{1, \dots, \theta\}.$$

Dann ist der Bias des **Schätzers** t gegeben durch

$$\text{Bias}_t(\theta) = \mathbb{E}_\theta \left[\frac{1}{n} \sum_{i=1}^n X_i \right] - \mathbb{E}_\theta[X_1] = 0 \quad \text{für alle } \theta \in \Theta,$$

weil $X_1, \dots, X_n$ identisch verteilt sind. Wir schätzen mit t den Erwartungswert $\mathbb{E}_\theta[X_1] = \frac{\theta+1}{2}$. Der **Schätzer** ist erwartungstreu.

(c) **Poisson-verteilte Stichprobenvariable.** Sei $\theta \in \Theta = \mathbb{N}$ und gelte

$$\mathbb{P}_\theta(X_i = k) = \frac{\theta^k}{k!} e^{-\theta} \quad \text{für alle } k \in \mathbb{N}_0.$$

Dann ist der Bias des **Schätzers** t gegeben durch

$$\text{Bias}_t(\theta) = \mathbb{E}_\theta \left[\frac{1}{n} \sum_{i=1}^n X_i \right] - \mathbb{E}_\theta[X_1] = 0 \quad \text{für alle } \theta \in \Theta,$$

weil $X_1, \dots, X_n$ identisch verteilt sind. Wir schätzen mit t den Erwartungswert $\mathbb{E}_\theta[X_1] = \theta$. Der **Schätzer** ist erwartungstreu.

Wir können auch Funktionen des Parameters schätzen. Wir betrachten hier exemplarisch die Varianz als eine solche Funktion.

Beispiel 11.7 Schätzer für die Varianz (Skript 26)

Seien $X_1, \dots, X_n$ unabhängige **Stichprobenvariable**^a und t ein **Schätzer** für den Erwartungswert, der durch

$$t(x) = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{für alle } x \in \mathcal{X}$$

definiert ist.

Eine naheliegende Idee ist es, analog zur Stichprobenvarianz, die Abbildung s^2 mit

$$s^2(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n \left(x_i - \frac{1}{n} \sum_{j=1}^n x_j \right)^2 \quad \text{für alle } x \in \mathcal{X}$$

zu wählen.

Ist dieser **Schätzer** erwartungstreu?

Wir können uns die (Schreib-)Arbeit etwas erleichtern, wenn wir annehmen, dass $\mathbb{E}_\theta[X_i] = 0$ gilt. Diese Annahme bedeutet keine Einschränkung der Allgemeingültigkeit des herzuleitenden Resultats, wie wir mittels einer Nullergänzung leicht sehen:

$$\begin{aligned} X_i - t(X) &= (X_i - \mathbb{E}_\theta[X_i]) + \left(\mathbb{E}_\theta[X_1] - \frac{1}{n} \sum_{i=1}^n X_i \right) \\ &= (X_i - \mathbb{E}_\theta[X_i]) - \left(\frac{1}{n} \sum_{i=1}^n (X_i - \mathbb{E}_\theta[X_i]) \right) \\ &= (X_i - \mathbb{E}_\theta[X_i]) - t((X_1 - \mathbb{E}_\theta[X_1], \dots, X_n - \mathbb{E}_\theta[X_n])). \end{aligned}$$

Das heißt, $X_i - t(X)$ hängt nicht vom Erwartungswert der **Stichprobenvariablen** ab.

Im Folgenden nehmen wir also an, dass $\mathbb{E}_\theta[X_i] = 0$ gilt. Umschreiben zeigt:

$$s^2(X) = \frac{1}{n} \sum_{i=1}^n \left[X_i^2 - 2X_i t(X) + (t(X))^2 \right] = \frac{1}{n} \sum_{i=1}^n X_i^2 - 2(t(X))^2 + (t(X))^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (t(X))^2.$$

Daher gilt

$$\mathbb{E}_\theta[s^2(X)] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_\theta[X_i^2] - \mathbb{E}_\theta[(t(X))^2] = \mathbb{E}_\theta[X_1^2] - \mathbb{E}_\theta[(t(X))^2] = \mathbb{E}_\theta[X_1^2] - \frac{1}{n^2} \sum_{i,j=1}^n \mathbb{E}_\theta[X_i X_j].$$

Für $i \neq j$ gilt aufgrund der Unabhängigkeit von X_i und X_j , dass $\mathbb{E}_\theta[X_i X_j] = \mathbb{E}_\theta[X_i] \mathbb{E}_\theta[X_j] = 0$. Daher bleiben von der Doppelsumme nur die Diagonalterme, das heißt,

$$\mathbb{E}_\theta[s^2(X)] = \mathbb{E}_\theta[X_1^2] - \frac{1}{n^2} \sum_{i=1}^n \mathbb{E}_\theta[X_i^2] = \mathbb{E}_\theta[X_1^2] - \frac{1}{n} \mathbb{E}_\theta[X_1^2].$$

Da wir angenommen haben, dass $\mathbb{E}_\theta[X_1] = 0$ gilt, folgt

$$\mathbb{E}_\theta[s^2(X)] = \left(1 - \frac{1}{n}\right) \text{Var}_\theta(X_1).$$

Wir sehen somit, dass s^2 *kein* erwartungstreuer **Schätzer** der Varianz ist. Wir sehen aber auch, dass der Unterschied nur im Vorfaktor $1 - \frac{1}{n}$ liegt. Wenn wir s^2 mit $\frac{n}{n-1}$ multiplizieren, erhalten wir einen erwartungstreuen **Schätzer**. In der Tat definiert

$$\hat{\sigma}^2(x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{für alle } x \in \mathcal{X}$$

einen erwartungstreuen **Schätzer** für die Varianz, wenn der Erwartungswert unbekannt ist und daher durch den **Schätzer** $\bar{x}$ ersetzt werden muss.

^aWir nehmen nicht an, dass die Stichprobenvariablen **Bernoulli-Variable** sind.

Teil II

Tutorien

KAPITEL 12

Tutorium 20.04.2026

12.1 | PÜ 1.1.4 - Faire Münze 3-mal Werfen

12.2 | PÜ 1.1.5 - Faire Münze n-mal Werfen

12.3 | PÜ 1.1.6 - Mensch ärgere dich nicht

KAPITEL 13

Tutorium 27.04.2026

13.1 | PÜ 1.2.4

Die Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$ sei gegeben durch

$$f(x) = \begin{cases} 3cx^2(1-x) & \text{für } x \in [0, 1], \\ 0 & \text{sonst} \end{cases}$$

wobei $c \in \mathbb{R}$ eine Konstante sei.

Aufgabe 13.1 (a) Bestimmen Sie ein $c \in \mathbb{R}$ derart, dass f eine Dichte ist

Lösung: $f(x)$ ist eine Dichte, wenn $\int_{\mathbb{R}} f(x) dx = 1$ also $\int_{-\infty}^{\infty} f(x) dx = 1$ (Von Studi vorgestellt)

$$\begin{aligned} \int 3cx^2(1-x) dx &= 3c \cdot \int x^2(1-x) dx \\ &= 3c \cdot \int_0^1 x^2 - x^3 dx \\ &= 3c \cdot \left[\frac{1}{3}x^3 - \frac{1}{4}x^4 \right]_0^1 \\ &= 3c \cdot \left(\frac{1}{3} - \frac{1}{4} \right) \\ &= c \cdot \frac{1}{4} \end{aligned}$$

$$c \cdot \frac{1}{4} = 1 \Rightarrow c = 4$$

Sei $\mathbb{P}$ das Wahrscheinlichkeitsmaß mit Dichte f , wie Sie sie in (a) bestimmt haben.

Hinweis: Falls Sie die Konstante c nicht bestimmen konnten, rechnen Sie im folgenden bitte mit der unbestimmten Konstanten weiter.

Aufgabe 13.2 (b) Berechnen Sie die folgenden Wahrscheinlichkeiten

$$\mathbb{P}\left(\left(\frac{1}{2}, \infty\right)\right), \mathbb{P}\left((-\infty, 0)\right), \mathbb{P}\left([1, \infty)\right) \text{ und } \mathbb{P}\left(\left\{\frac{1}{2}\right\}\right)$$

Lösung: (von Tutor)

$$pe((\frac{1}{2}, \infty)) = \frac{11}{16}$$

$$\begin{aligned}\mathbb{P}((-\infty, 0)) &= \int_{-\infty}^0 f(x) dx \\ &= \int_{-\infty}^0 0 dx \\ &= 0\end{aligned}$$

$$\begin{aligned}\mathbb{P}([1, \infty)) &= \int_1^{\infty} f(x) dx \\ &= \int_1^{\infty} 0 dx \\ &= 0\end{aligned}$$

$$\begin{aligned}\mathbb{P}(\{\frac{1}{2}\}) &= \int_{\frac{1}{2}}^{\frac{1}{2}} f(x) dx \\ &= 12 \cdot \left[\frac{1}{3} \cdot x^3 - \frac{1}{4} \cdot x^4 \right]_{\frac{1}{2}}^{\frac{1}{2}} \\ &= 12 \cdot \left(\frac{1}{3} \cdot \frac{1}{2^3} - \frac{1}{4} \cdot \frac{1}{2^4} - \frac{1}{3} \cdot \frac{1}{2^3} + \frac{1}{4} \cdot \frac{1}{2^4} \right) \\ &= 0\end{aligned}$$

KAPITEL 14

Tutorium 04.05.2026 (Zusatztutorium)

14.1 | PÜ 1.0.1

Aus dem Intervall $[0, 1]$ wird rein zufällig eine Zahl gezogen. Wir betrachten in dieser Aufgabe nur die Nachkommastellen der Dezimalentwicklung.

Aufgabe 14.1 (a) Modellieren Sie dieses Zufallsexperiment, indem Sie einen geeigneten Wahrscheinlichkeitsraum angeben.

$$\Omega = [0, 1]$$

Und Dichte:


$$f(x) = \begin{cases} 1, & x \in [0, 1] \\ 0, & \text{sonst} \end{cases}$$

Das ergibt:

$$\mathbb{P}(A) = \int_A f(x) dx$$

Aufgabe 14.2 (b) Definieren Sie die folgenden Ereignisse als Teilmengen des Ereignisraums, und zeichnen Sie diese in einer Skizze des Intervalls ein

1. Die erste Nachkommastelle der Zahl ist ungerade: $A_1 = \bigsqcup_{k=1}^5 [\frac{2k-1}{10}, \frac{2k}{10})$
2. Die zweite Nachkommastelle der Zahl ist gleich 4: $A_2 = \bigsqcup_{i=0}^9 [\frac{10i+4}{100}, \frac{10i+5}{100})$
3. Die Summe der ersten beiden Nachkommastellen der Zahl beträgt 5: $A_3 = \bigsqcup_{i=0}^5 [\frac{10i+(5-i)}{100}, \frac{10i+(5-i)+1}{100})$
4. Die Zahl ist exakt $\frac{1}{\pi}$: $A_4 = \{\frac{1}{\pi}\} = 0,3138\dots$
5. Die Zahl ist um höchstens $\frac{1}{100}$ von $\frac{1}{\pi}$ entfernt: $A_5 = [\frac{1}{\pi} - \frac{1}{100}, \frac{1}{\pi} + \frac{1}{100}]$



Aufgabe 14.3 Berechnen Sie die Wahrscheinlichkeiten dieser Ereignisse.**Lösung:** Für 1.

$$\mathbb{P}(A_1) = \mathbb{P}\left(\bigcup_{k=1}^5 \left[\frac{2k-1}{10}, \frac{2k}{10}\right)\right) = \sum_{k=1}^5 \mathbb{P}\left(\left[\frac{2k-1}{10}, \frac{2k}{10}\right)\right) = \sum_{k=1}^5 \mathbb{P}\left(\left[\frac{1}{10}, \frac{2}{10}\right)\right) = 5 \mathbb{P}\left(\left[\frac{1}{10}, \frac{2}{10}\right)\right) = 5 \cdot \frac{1}{10} = \frac{1}{2}$$

Für 2.

$$\mathbb{P}(A_2) = \sum_{i=0}^9 \mathbb{P}\left(\left[\frac{10i+4}{100}, \frac{10i+5}{100}\right)\right) = 10 \cdot \frac{1}{100} = \frac{1}{10}$$

Für 3.

$$\mathbb{P}(A_3) = \sum_{i=0}^5 \mathbb{P}\left(\left[\frac{10i+(5-i)}{100}, \frac{10i+(5-i)+1}{100}\right)\right) = 6 \cdot \frac{1}{100} = \frac{3}{50}$$

Für 4. WS für Einpunktmenge bei Dichte ist $0 = \int_{1/\pi}^{1/\pi} 1 dx = \frac{1}{\pi} - \frac{1}{\pi}$

Für 5.

$$\mathbb{P}(A_5) = \mathbb{P}\left(\left[\frac{1}{\pi} - \frac{1}{100}, \frac{1}{\pi} + \frac{1}{100}\right]\right) = \frac{2}{100}$$

14.2 | PÜ 1.0.2.

Beim Spiel Mensch ärgere dich nicht würfelt der Spieler zunächst einmal. Dann wird die Figur des Spielers auf dem Brett um die entsprechende Anzahl an Feldern vorgerückt. Falls der Spieler eine 6 würfelt hat, so darf er anschließend erneut würfeln. Wieder wird die Figur um die entsprechende Anzahl an Feldern vorgerückt. Dieser Vorgang wird wiederholt, bis der Würfel zum ersten Mal keine 6 zeigt. Uns interessiert nur, um wie viele Felder die Figur insgesamt vorgerückt wird

Aufgabe 14.4 Geben Sie einen geeigneten Wahrscheinlichkeitsraum für dieses Zufallsexperiment an.**Lösung:** $\Omega = \mathbb{N}$ also

$$\tilde{\Omega} = \{(k, l) \mid k \in \mathbb{N}_0, l \in \{0, \dots, 5\}\} = \mathbb{N}_0 \times \{0, \dots, 5\}$$

$$\mu = \text{?} \rightarrow \mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega)$$

Für $1 \leq \omega \leq 6 :: \mu_1 \sim \cup_{\{1, \dots, 6\}}$

$$\mu(\omega) = \mu_1(\omega) = \frac{1}{6} \quad \forall \omega \in \{1, \dots, 5\}$$

$$\mu(6) = 0$$

Für $7 \leq \omega \leq 12 :: \mu_2 \sim \cup_{\{1, \dots, 6\}^2}$

$$\mu(\omega) = \mu_2((6, 6 - \omega)) = \frac{1}{36} \quad \forall \omega \in \{7, \dots, 11\}$$

 $\mu(12) = \mu_2((6, 6)) = 0$ ist falsch!, weil wir direkt nochmal würfeln würden nach der zweiten 6, richtig wäre:

$$\mu(12) = 0 \text{ und } \mu_2((6, 6)) = \frac{1}{36}$$

Weitere Beispiele:

$$\text{bspw. } \mu(7) = \mu_2((6, 1))$$

$$\text{und bspw. } \mu(72) = \mu(6 \cdot 12 + 1) = \frac{1}{6^{13}}$$

Damit man überhaupt den zweiten Wurf machen darf, muss das erste ja schon eine 6 gewesen sein, deswegen $1/36$

Aufgabe 14.5

$$\frac{\mathbb{N}}{6} = \{n \in \mathbb{N} : n \text{ nichtkongruent mod } 6\}$$

also auch

$$\mathbb{N}_0 \times \{0, \dots, 5\}$$

dannam ende mit dem squiggy arrow muss man noch ausrechnen, dass das eine Zähldichte ist

14.3 | PÜ 1.0.3.

KAPITEL 15

Tutorium 11.05.2026

15.1 | PÜ 1.3.4.

KAPITEL 16

Tutorium 18.05.2026

16.1 | PÜ 1.4.4.

16.2 | PÜ 1.4.5.

KAPITEL 17

Tutorium 26.05.2026

17.1 | PÜ 1.5.4.

17.2 | PÜ 1.5.5.

KAPITEL 18

Tutorium 01.06.2026

18.1 | PÜ 1.6.4.

Auf einem Tisch stehen zwei Urnen.

- Urne U_K enthalte eine schwarze Kugel und zwei weiße Kugeln.
- Urne U_Z enthalte zwei schwarze Kugeln und eine weiße Kugel.

Die Kugeln unterscheiden sich nur durch ihre Farbe. Mavi wirft eine faire Münze, um sich zwischen den beiden Urnen zu entscheiden.

- Wenn die Münze Kopf zeigt, dann zieht Mavi nacheinander und ohne Zurücklegen zwei Kugeln aus Urne U_K .
- Wenn die Münze Zahl zeigt, dann zieht Mavi nacheinander und ohne Zurücklegen zwei Kugeln aus Urne U_Z .

Aufgabe 18.1 (a) Geben Sie einen geeigneten Ereignisraum Ω an, mit dem Sie die folgenden Aufgabenteile bearbeiten können.

Meine Lösung: $\Omega = \{k, z\} \times \{s, w\}^2$, wobei $\omega = (k, s, w)$ bedeutet, dass aus der Urne U_K erst eine schwarze und dann eine weiße Kugel gezogen wurde.

Tutor Lösung: $\Omega = \{k, z\} \times \{s, w\}^2$ mit der Bemerkung, dass $\mathbb{P}((k, s, s)) = \mathbb{P}(z, w, w) = 0$. Die Bemerkung muss nicht dazu. Dabei ist $\{k, z\}$ der Münzwurf und $\{s, w\}^2$ das Ziehen zweier Kugeln.

Man kann es auch direkt mit Tripeln machen, aber das ist mehr Schreibarbeit. Aber dann hat man die Sachen mit $\mathbb{P} = 0$ auch nicht drin, sondern nur das, was tatsächlich möglich ist.

Aufgabe 18.2 (b) Definieren Sie jene Ereignisse als Teilmengen von Ω , die Sie benötigen, um die folgenden Aufgabenteile bearbeiten zu können.

Meine Lösung:

$$\begin{aligned}
 S_i &= \{\text{i schwarze Kugeln gezogen}\} \\
 W_i &= \{\text{i weiße Kugeln gezogen}\} \\
 S_1 = W_1 &= \{(k, s, w), (k, w, s), (z, w, s), (z, s, w)\} \\
 S_0 = W_2 &= \{(k, w, w)\} \\
 S_2 = W_0 &= \{(z, s, s)\} \\
 U_K &= \{\text{Es wurde aus Urne } U_K \text{ gezogen}\} \\
 &= \{(k, s, w), (k, w, s), (k, w, w)\} \\
 U_Z &= \{\text{Es wurde aus Urne } U_Z \text{ gezogen}\} \\
 &= \{(z, s, w), (z, w, s), (z, s, s)\}
 \end{aligned}$$

(Alle Ereignisse, nicht nur die für die Aufgaben relevanten...)

Tutor Lösung:

$$\begin{aligned}
 W &= \{k, z\} \times \{w\}^2 \\
 K &= \{k\} \times \{s, w\}^2 \\
 Z &= \{z\} \times \{s, w\}^2
 \end{aligned}$$

Aufgabe 18.3 (c) Bestimmen Sie aus dem Text die Wahrscheinlichkeiten bzw. bedingten Wahrscheinlichkeiten der Ereignisse aus (b).

Meine Lösung:

$$\begin{aligned}
 P(U_Z) &= P(U_K) = \frac{1}{2} \\
 P(S_0 \mid U_K) &= \frac{2}{3} \cdot \frac{1}{2} = \frac{2}{6} \\
 P(S_0 \mid U_K) &= 0
 \end{aligned}$$

(Nicht weiter gemacht)

Tutor Lösung:

$$\begin{aligned}
 \mathbb{P}(K) &= \mathbb{P}(Z) = \frac{1}{2} \\
 \mathbb{P}(W \mid K) &= \frac{2}{3} \cdot \frac{1}{2} = \frac{2}{6} = \frac{1}{3} \\
 \mathbb{P}(W \mid Z) &= 0
 \end{aligned}$$

Aufgabe 18.4 (d) Berechnen Sie die Wahrscheinlichkeit, dass Mavi mindestens eine schwarze Kugel zieht (d.h., die Wahrscheinlichkeit, dass Mavi eine oder zwei schwarze Kugeln zieht)

Tutor Lösung: $\mathbb{P}(\text{"Mindestens eine schwarze Kugel gezogen"}) = \mathbb{P}(W^c) = 1 - \mathbb{P}(W)$, wobei $W = \{\text{"Es werden nur weiße Kugeln gezogen"}\}$

$$\begin{aligned}\mathbb{P}(W) &= \mathbb{P}(W \mid K) \cdot \mathbb{P}(K) + \mathbb{P}(W \mid Z) \cdot \mathbb{P}(Z) \\ &= \frac{1}{3} \cdot \frac{1}{2} + 0 \cdot \frac{1}{2} \\ &= \frac{1}{6}\end{aligned}$$

Aufgabe 18.5 (e) Sie wissen, dass Mavi mindestens eine schwarze Kugel gezogen hat. Berechnen Sie die Wahrscheinlichkeit, dass Mavi aus der Urne U_Z gezogen hat.

Tutor Lösung:

$$\begin{aligned}\mathbb{P}(\text{"Zahl"} \mid \text{"min. 1 schwarze Kugel"}) &= \mathbb{P}(Z \mid W^c) \\ &\stackrel{\text{Bayes}}{=} \frac{\mathbb{P}(W^c \mid Z) \cdot \mathbb{P}(Z)}{\mathbb{P}(W^c)} \\ &= \frac{(1 - \mathbb{P}(W \mid Z)) \cdot \mathbb{P}(Z)}{\mathbb{P}(W^c)} \\ &= \frac{\frac{1}{2}}{\frac{5}{6}} = \frac{6}{10} \\ &= \frac{3}{5}\end{aligned}$$

18.2 | Besprechung ÜB 1.5.1

Seien X, Y ZVs mit gemeinsamer Dichte f :

$$f(x, y) = \begin{cases} c \cdot e^{-x + \frac{y}{2}}, & x \in [0, 1], y \geq 0 \\ 0, & \text{sonst} \end{cases}$$

(a) Finde c , sodass f Dichte ist

$f \geq 0$ sqiggy-Pfeil zu $c \stackrel{!}{\geq} 0$

$$\begin{aligned}1 &\stackrel{!}{=} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy \\ &= c \cdot \int_0^1 e^{-x} dx \int_0^{\infty} e^{\frac{1}{2}y} dy \\ &= c \cdot [-e^{-x}]_0^1 \cdot [-2 \cdot e^{-\frac{y}{2}}]_0^{\infty} \\ &= c \cdot (1 - e^{-1}) \cdot (2)\end{aligned}$$

sqiggy-Pfeil zu:

$$c = \frac{1}{2(1 - e^{-1})} \geq 0$$

(b)

Bemerke: χ

$$f(x, y) = \underbrace{c_1 \cdot e^{-x} \cdot \chi_{[0,1]}(x)}_{f_X(x)} \cdot \underbrace{c_2 \cdot e^{-\frac{y}{2}} \cdot \chi_{[0,\infty)}(y)}_{f_Y(y)}$$

mit $c = c_1 \cdot c_2$ TO-DO von Bild abtippen, hat weggewischt

(c)

 F_X & $F_Y = ?$ $x < 0$: $F_X(x) = 0$

$$x \in [0, 1]: F_X(x) = \int_0^x c_1 e^{-\tilde{x}} d\tilde{x} = c_1 \cdot (1 - e^{-x}) = \frac{1-e^{-x}}{1-e^{-1}}$$

 $x > 1$: $F_X(x) = 1$

sqiggy-Pfeil zu:

$$f_X(x) = \begin{cases} 0, & x < 0 \\ \frac{1-e^{-x}}{1-e^{-1}}, & x \in [0, 1] \\ 1, & x > 1 \end{cases}$$

TO-DO von Bild abtippen, hat weggewischt

(d)

(e)

$$\begin{aligned} \mathbb{P}(X > Y) &= \int_0^1 f_X(x) \underbrace{\int_0^x f_Y(y) dy}_{F_Y(x)} dx \\ &= \int_0^1 2ce^{-x} \cdot (1 - e^{-\frac{x}{2}}) dx \\ &= 2c \int_0^1 e^{-x} - e^{-\frac{3}{2}x} dx \\ &= 2c \cdot ((1 - e^{-1}) - [-\frac{2}{3}e^{-\frac{3}{2}x}]_0^1) \\ &= 2c \cdot ((1 - e^{-1}) - (-\frac{2}{3} - \frac{2}{3}e^{-\frac{3}{2}})) \end{aligned}$$

18.3 | Besprechung ÜB 1.5.2

Seien $X, Y \sim \text{Exp}(\lambda)$, $X \perp\!\!\!\perp Y$

(a)

$$\mathbb{P}(X > 10) = 1 - \mathbb{P}(X \leq 10)$$

Für $\lambda = \frac{1}{5}$

$$\mathbb{P}(X > 10) = 1 - \mathbb{P}(X \leq 10) = 1 - F_X(10) = 1 - (1 - e^{-\frac{1}{5} \cdot 10}) = e^{-2}$$

(c)

$$\underbrace{\mathbb{P}(X + Y \leq Z)}_{F_{X+Y}(z)} = \int_0^2 f_X(x) \overbrace{\int_0^{z-x} f_Y(y) dy}^{F_Y(z-x)} dx$$

= TODOrestvonBild

subsubsection*(c oder b?)

18.4 | Besprechung ÜB 1.5.3

To-do von Bild

18.5 | PÜ 2.1.4**18.6 | PÜ 2.1.5****18.7 | PÜ 2.1.6**

KAPITEL 19

Tutorium 15.06.2026

Binomialverteilung benutzt man, wenn es aus der Aufgabenstellungen hervor sinnvoll ist oder wenn die Aufgabenstellung sagt, dass etwas binomialverteilt ist.

$$\begin{aligned}\mathbb{P}(X_n \leq \delta) &= \mathbb{P}(X_n - np \leq \delta - np) \\ &= \mathbb{P}\left(\frac{X_n - np}{\sqrt{npq}} \leq \frac{\delta - np}{\sqrt{npq}}\right) \\ &\approx \Phi\left(\frac{\delta - np}{\sqrt{npq}}\right)\end{aligned}$$

* das ist das Anwenden von Moire-Laplace.

Tscheby:

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq \delta) \leq \frac{\text{Var}(X)}{\delta^2}$$

19.1 | PÜ 2.2.4.

Der Lufthansa Airbus A380 bietet insgesamt 526 Fluggästen Platz. Da Kunden manchmal ihren Flug nicht antreten, lassen Fluggesellschaften zwecks optimaler Auslastung Überbuchungen zu. Es sollen möglichst viele Tickets verkauft werden, wobei jedoch die Wahrscheinlichkeit einer Überbuchung maximal 5% betragen soll. Erfahrungsgemäß erscheinen Kunden mit einer Wahrscheinlichkeit von 10% nicht zum Flug.

Aufgabe 19.1 (a) Geben Sie einen geeigneten Wahrscheinlichkeitsraum an, der es erlaubt, die folgenden Aufgabenteile zu bearbeiten. Diskutieren Sie, welche Annahmen Sie machen müssen, um Ihre Wahl des Wahrscheinlichkeitsraums zu rechtfertigen.

Lösung Tutor

$$\Omega = \left\{ \underbrace{0}_{\text{kommt nicht}}, \underbrace{1}_{\text{kommt}} \right\}^n$$

kommt nicht ist $q = \frac{1}{10}$ und kommt ist $p = \frac{9}{10}$.

$$\mathbb{P}(\{\omega\}) = p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{\sum_{i=1}^n (1-\omega_i)}$$

Bspw. $\{\omega\} = (1, 0, 1, 1, 0)$

Wenn Binomialverteilt, geht man davon aus jeder hat die gleich WS zu kommen und sie sind unabhängig (wir ignorieren bspw., dass Familien meistens zusammen reisen oder absagen).

Erwartungswert berechnet den Durchschnitt einer ZV!

Aufgabe 19.2 (b) Geben Sie ein Verfahren an, wie die Frage, wie viele Tickets unter den oben genannten Bedingungen maximal angeboten werden können, exakt beantwortet werden könnte

Lösung des Tutors: Man definiert eine ZV S_n über die aufsummiert wird:

$$S_n(\underbrace{\omega}_{\omega=\omega_1, \dots, \omega_n}) = \sum_{i=1}^n \omega_i$$

S_n ist die Anzahl der Leute, die kommen.

Wenn wir die WS der Überbuchung auf maximal 0,05 halten wollen, interessiert uns

$$\mathbb{P}(S_n > 526) \leq 0,05$$

■ n = Anzahl verkaufte Tickets (wir wollen n maximieren)

■ S_n = Anzahl der Personen, die kommen

Auf Basis dessen oben:

$$\underbrace{\mathbb{P}(S_n \leq 526)}_{=\sum_{i=1}^{526} \binom{n}{i} p^i (1-p)^{n-i}} \geq 0,95$$

Starte bei $n = 526$ und berechne $\mathbb{P}(S_n \leq 526)$ mit inkrementierendem n und wenn es bei einem n über 0,95 liegt, dann ist das das gesuchte n das $n-1$ ist.

$$\begin{aligned} \mathbb{P}(S_n \leq 526) &= \mathbb{P}(S_n - np \leq 526 - np) \\ &= \mathbb{P}\left(\frac{S_n - np}{\sqrt{npq}} \leq \frac{526 - np}{\sqrt{npq}}\right) \\ &\approx \phi\left(\underbrace{\frac{526 - np}{\sqrt{npq}}}_{\geq 1,65}\right) \end{aligned}$$

$$\frac{526 - np}{\sqrt{npq}} \geq 1,65$$

p und q einsetzen

$$526 - (\sqrt{n})^2 \cdot \frac{9}{10} \geq 1,65\sqrt{n} \cdot \frac{3}{10}$$

und dann landet man durch Rumschieben bei

$$\underbrace{(\sqrt{n})^2}_x + \underbrace{1,65 \cdot \frac{1}{3}}_{c_1} \underbrace{\sqrt{n}}_x - \underbrace{\frac{10}{90,9?}}_{c_2} \leq 0$$

TODO noch das letzte von der Tafel

Aufgabe 19.3 (c) Nutzen Sie den Satz von de Moivre-Laplace, um näherungsweise zu bestimmen, wie viele Tickets unter den oben genannten Bedingungen maximal angeboten werden können.

19.2 | PÜ 2.2.5

Eine Süßwarenfirma gibt an, daß 25% ihrer Gummibärchen die beliebte Farbe rot haben. Im folgenden gehen wir davon aus, daß die Angaben des Herstellers richtig sind. Wir nehmen auch an, daß die Gummibärchen unabhängig voneinander rot sind oder eine andere Farbe haben.

Trotzdem waren in einer kleineren Stichprobe lediglich 20% der Gummibärchen rot. Wir wollen der Sache auf den Grund gehen und kaufen daher n weitere Gummibärchen. Sei b_n die Wahrscheinlichkeit, dass höchstens 20% der neu gekauften n Gummibärchen rot sind.

Aufgabe 19.4 (a) Geben Sie für jedes beliebige $n \in \mathbb{N}$ einen geeigneten Wahrscheinlichkeitsraum an, der es erlaubt, die folgenden Aufgabenteile zu bearbeiten

$$\Omega = \left\{ \underbrace{0}_{\text{nicht rot}}, \underbrace{1}_{\text{rot}} \right\}^n$$

wobei n die Anzahl der gekauften Gummibärchen ist.

$$\mathbb{P}(\{\omega\}) = p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{\sum_{i=1}^n (1-\omega_i)}$$

mit $p=0,25$ = WS für rot und $q = 1-p$

Aufgabe 19.5 (b) Definieren Sie eine Zufallsvariable S_n , die die Anzahl der roten Gummibärchen unter den n gekauften Gummibärchen angibt.

$$S_n = \sum_{i=1}^n \omega_i, \quad S_n \sim \text{Bin}(n, p)$$

Aufgabe 19.6 (c) Sei $n = 20$. Berechnen Sie b_{20} auf drei Nachkommastellen genau, d.h., geben Sie die Wahrscheinlichkeit in der Form 0.xyz bzw. xy.z % an.

$$\frac{S_n}{n} (= \text{mitHtchenzeichen}) \text{ Durchschnittliche Anzahl rot}$$

Es gilt

$$\mathbb{P}\left(\frac{1}{n}S_n \leq \frac{1}{5}\right) = \mathbb{P}\left(S_n \leq \frac{n}{5}\right)$$

Und mit $n = 20$

$$\mathbb{P}\left(S_{20} \leq \frac{20}{5}\right) = \mathbb{P}(S_{20} \leq 4) = \sum_{i=1}^4 \binom{20}{i} p^i \cdot (1-p)^{20-i} = 0,4148\dots$$

Aufgabe 19.7 (d) Beweisen Sie mit Hilfe der Tschebysche!schen Ungleichung, daß $b_{200} < b_{20}$ gilt.

Also $b_n = \mathbb{P}\left(\frac{1}{n}S_n \leq \frac{1}{5}\right)$

Heißt wir müssen $\mathbb{P}(|X - \mathbb{E}[X]| \geq \delta) \leq \frac{\text{Var}(X)}{\delta^2}$ in jene Form umwandeln. Erstmal Erwartungswert von beiden Seiten abziehen(?):

$$\mathbb{P}\left(\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right] \leq \frac{1}{5} - \mathbb{E}\left[\frac{1}{n}S_n\right]\right)$$

Es ist ja

$$\mathbb{E}\left[\frac{1}{n}S_n\right] = \frac{1}{n}\mathbb{E}[S_n] = \frac{1}{n} \cdot np = p \stackrel{\text{Aufgabe}}{=} \frac{1}{4}$$

Also

$$\begin{aligned} \mathbb{P}\left(\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right] \leq \frac{1}{5} - \mathbb{E}\left[\frac{1}{n}S_n\right]\right) &= \mathbb{P}\left(\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right] \leq -\frac{1}{20}\right) \\ &= \mathbb{P}\left(\left|\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right]\right| \geq \frac{1}{20}\right) \end{aligned}$$

TODO die Sachen von der Tafel noch zu ende

Aufgabe 19.8 (e) Zeigen Sie mit Hilfe der Tschebysche!schen Ungleichung, dass $\lim_{n \rightarrow \infty} b_n = 0$ gilt

19.3 | PÜ 2.2.6

KAPITEL 20

Tutorium 22.06.2026

20.1 | PÜ 2.3.4

Bei einer Maschine, die Elektronikbauteile produziert, ist im Schnitt jedes 50. Bauteil fehlerhaft. Wir testen eine Lieferung von 300 Bauteilen. Wie groß ist die Wahrscheinlichkeit, dass genau 3 Bauteile fehlerhaft sind?

Denken Sie daran, einen Wahrscheinlichkeitsraum anzugeben und die benötigten Zufallsvariablen zu definieren!

Aufgabe 20.1

$$\Omega = \{0, 1\}^n, \quad n = 300$$

mit

$$\mu(\omega) = p^{\sum_{i=1}^n \omega_i} q^{n - \sum_{i=1}^n \omega_i} \quad \text{mit} \quad p = \frac{1}{50}, q = \frac{49}{50}$$

Teil ist kaputt ist Erfolg, damit wir uns nicht mit Gegenwahrscheinlichkeiten auseinandersetzen müssen.

$$S_n(\omega) = \sum_{i=1}^n \omega_i$$

Aunahme: teile sind Unabhängig voneinander kaputt und immer $p = \frac{1}{50}$

$$\begin{aligned} \mathbb{P}(S_n = x) &= \binom{n}{x} \cdot p^x \cdot q^{n-x} \\ &= \binom{300}{3} \left(\frac{1}{50}\right)^3 \left(\frac{49}{50}\right)^{297} \\ &\approx 0,0883 \end{aligned}$$

Poisson Approximation (p klein q groß)

$$\alpha = np = \frac{300}{50} = 6$$

Sei $X \sim Poi(\alpha)$

$$\begin{aligned} \mathbb{P}(S_n = 3) &\approx \mathbb{P}(X = 3) \\ &= \frac{\alpha^3}{3!} e^{-\alpha} \\ &= \frac{6^3}{3!} e^{-6} \\ &\approx 0,0892 \end{aligned}$$

$$\mathbb{P}(S_n = k) = \binom{n}{k} p^k q^{n-k}$$

$$\begin{aligned}\mathbb{P}(S_n \in A) &= \sum_{k \in A} \mathbb{P}(S_n = k) \\ &= \sum_{k \in A}\end{aligned}$$

TODO ! Noch Rest von Bildern eintragen

20.2 | PÜ 2.3.5

20.3 | PÜ 2.3.6

KAPITEL 21

Tutorium 29.06.2026

21.1 | PÜ 2.4.4

21.2 | PÜ 2.4.5

KAPITEL 22

Tutorium 06.07.2026

22.1 | PÜ 2.5.4

22.2 | PÜ 2.5.5

Tutorium 13.07.2026

23.1 | PÜ 2.6.4

Ein Politiker fällt wiederholt durch fragwürdige Äußerungen auf. Während er bei der letzten Wahl noch 30% der Stimmen erhalten hat, geht sein Wahlkampfteam mittlerweile davon aus, daß dieser Wert gesunken ist. Der Politiker widerspricht dem vehement.

In einer Stichprobe werden 200 Personen befragt. 45 Personen sprechen sich weiterhin für den Politiker aus.

Aufgabe 23.1 Läßt sich die Hypothese, daß sich die Unterstützung der Wähler für den Politiker nicht verändert hat, halten? Verwenden Sie einen geeigneten Hypothesentest zum Signifikanzniveau von 5%.

Parameter (Tutor): $H_0 = \theta \in \Theta_0 = \left\{\frac{3}{10}\right\}$ und $H_A = \theta \in \Theta_A = \left[0, \frac{3}{10}\right)$. Man muss dann einen Hypothesentest mit Signifikanzniveau $\alpha = 0,05$.

Modell dahinter (extra Info für Kontext, noch von der Aufgabe gefordert):

- Stichprobenraum: $\chi = \{0, 1\}^n$ mit $n = 200$
 - Jedes $x \in \chi$ ist ein n-fach unabhängig wiederholtes Bernoulli-Experiment
- $\Theta = [0, 1] \leftarrow$ "Zustimmung"
- $P = \{\mathbb{P}_\theta : \theta \in \Theta\}$, wobei
 - $\mathbb{P}_\theta$ durch die Wahrscheinlichkeitsfunktion μ_θ mit $\mu_\theta(x) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}$, $\forall x \in \chi$ gegeben ist.
- Konkrete Stichprobe: $\tilde{x} \in \chi$ mit $\sum_{i=1}^n \tilde{x}_i = 45$
- $n = 200$
- Stichprobenvariablen:
 - $X = (X_1, \dots, X_n)$ mit $\{X_i\}_{i=1}^n$ unabhängig identisch verteilt
 - $X_i \sim \text{Ber}()$

Weitere Lösung:

$$t : \chi \rightarrow \{0, \dots, n\}$$

Möglich:

$$t(x) = n\bar{x} = \sum_{i=1}^n x_i$$

$$t(x) = n - n\bar{x} = n - \sum_{i=1}^n x_i$$

ABER: $t(x) = n\bar{x} = \sum_{i=1}^n x_i$ dann wäre das bei Zustimmung irgendwie sehr groß, also nehmen wir:

$$t(x) = n - n\bar{x} = n - \sum_{i=1}^n x_i$$

deshalb

$$\begin{aligned} p(x) &= \sup_{\theta \in \Theta_0} \mathbb{P}_{\theta}(t(X) \geq t(x)) \\ &= \mathbb{P}_{\frac{3}{10}}(t(X) \geq t(x)) \\ &= \mathbb{P}_{\frac{3}{10}}\left(n - \sum_{i=1}^n X_i \geq n - \sum_{i=1}^n x_i\right) \\ &= \mathbb{P}_{\frac{3}{10}}\left(\sum_{i=1}^n X_i \leq \underbrace{\sum_{i=1}^n x_i}_{n\bar{x}}\right) \end{aligned}$$

$\phi(x) = 1 \Rightarrow H_0$ wird verworfen (Die konkrete Stichprobe soll 1 sein, wenn wir unsere Stichprobe verwerfen.)

$$\phi(x) = \begin{cases} 1, & p(x) \leq \alpha \\ 0, & \text{sonst} \end{cases} = \mathbb{I}_{[0, \alpha]}$$

Betrachte $p(\tilde{x}) = \mathbb{P}_{\frac{3}{10}}(\sum_{i=1}^n X_i \leq 45)$

$$\begin{aligned} \sum_{i=1}^n X_i &\sim \text{Bin}\left(n, \frac{3}{10}\right) = \text{Bin}_{200, \frac{3}{10}}(\{0, \dots, 45\}) \\ &= \sum_{i=1}^{45} \binom{n}{i} \left(\frac{3}{10}\right)^i \left(\frac{7}{10}\right)^{n-i} \\ &\approx 0,011 \end{aligned}$$

Taschenrechner

$$\Rightarrow \phi(\tilde{x}) = \mathbb{I}_{[0, 0.05]}(p(\tilde{x})) = \mathbb{I}_{[0, \alpha]}(0,011) = 1$$

H_0 muss verworfen werden.

Ablauf so einer Aufgabenlösung:

1. Hypothese aufstellen
2. Signifikanzniveau festlegen
3. Teststatistik aufstellen
4. p-Wert und Test + Entscheidungsregel
5. "Durchführung" / Auswertung der Stichprobe
6. Schlussfolgerung

Hier umgesetzt als:

1. Hypothese aufstellen

- $H_0 = \theta \in \Theta_0 = \left\{\frac{3}{10}\right\}$ (Punkthypothese, keine Veränderung)
- $H_A = \theta \in \Theta_A = \left[0, \frac{3}{10}\right)$ (Alternative Hypothese, negative Veränderung)

2. Signifikanzniveau festlegen
3. Teststatistik aufstellen
4. p-Wert und Test + Entscheidungsregel
5. “Durchführung” / Auswertung der Stichprobe
6. Schlussfolgerung

Zusatz des Tutors:

$k =$	45	46	47	48	49
$\mathbb{P}_{\frac{3}{10}}(\sum_{i=1}^n X_i \leq k)$	0,011	0,017	0,025	0,036	0,056

Tabelle 23.1: Ab 49 Zustimmungen hätte man die Hypothese nicht verwefen müssen - “48 und kleiner” ist unser Verwerfungsbereich

23.2 | PÜ 2.6.5

Beantworten Sie die folgenden Fragen zur Theorie der **Hypothesentests**. Eine Begründung Ihrer Antworten ist nicht nötig.

Aufgabe 23.2 Ein Fehler erster Art tritt ein, wenn ...

Lösung: wir H_0 verwerfen, wenn H_0 wahr ist (Definition **Fehler erster Art**)

Anmerkung: Fehler zweiter Art ist wir verwerfen H_0 nicht, obwohl H_0 falsch ist (wir H_0 akzeptieren, wenn H_0 falsch ist)

Kommentar 23.1 Es KANN passieren, dass Definitionen abgefragt werden in der Klausur (in Form von Multiple Choice oder speziellen Fragen). Oder man einen Hypothesentest aufstellen muss.

Aufgabe 23.3 Wenn eine Hypothese zum Signifikanzniveau 0.6 verworfen wird, dann ...

Herleitung: Entspricht ja

$$\phi(x) = \begin{cases} 1, & p(x) \leq 0.6 \\ 0, & \text{sonst} \end{cases} = \mathbb{1}_{[0,0.6]}$$

Muss nicht für jedes Alpha verworfen werden, daher auch nicht für 0,5.

Lösung: kann es der Fall sein, dass sie zum Signifikanzniveau 0.5 verworfen wird

Aufgabe 23.4 Der p-Wert eines Hypothesentests gibt folgendes an:

Lösung: Das kleinste Signifikanzniveau für das Verwerfen der Hypothese H_0 (per Definition, denn wenn wir eine konkrete Stichprobe haben (also $p(x)$ festhalten)) und das Signifikanzniveau danach aussuchen, dann kann das SN nicht kleiner als $p(x)$ sein??)

Aufgabe 23.5 Ordnen Sie die folgenden Schritte gemäß der korrekten Durchführung eines Hypothesentests

Lösung:

1. Wahl von Hypothese und Alternative
2. Wahl des Signifikanzniveaus
3. Wahl der Teststatistik
4. Wahl der Entscheidungsregel
5. Auswertung der Stichprobe
6. Schlussfolgerung

23.3 | Besprechung ÜB 2.5.1

Wir nehmen in dieser Aufgabe an, daß unsere Stichprobe von einem n -mal unabhängig wiederholten Bernoulli-Experiment mit unbekannter Erfolgswahrscheinlichkeit $\theta \in (0, 1)$ stammt.

Wir wissen aus der Vorlesung, daß das arithmetische Mittel der Stichprobenwerte ein erwartungstreuer Schätzer für θ ist.

todo

Aufgabe 23.6 Begründen Sie, warum t so definiert ein Schätzer für die Varianz $\theta(1 - \theta)$ ist.

Siehe Bild TODO

Ist dieser Schätzer erwartungstreu?

Teil III

Anhang

23.4 | Übersichten

Verteilung	Parameter	$E[X]$	$\text{Var}(X)$	Anwendung
Bernoulli $\text{Ber}(p)$	$p \in (0, 1)$	p	pq	Einzelnes Ja/Nein-Experiment
Binomial $\text{Bin}(n, p)$	$n \in \mathbb{N}, p \in (0, 1)$	np	npq	Anzahl Erfolge bei n unabh. Bernoulli-Versuchen
Geometrisch $\text{Geo}(p)$	$p \in (0, 1)$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	Wartezeit bis zum ersten Erfolg
Poisson $\text{Poi}(\lambda)$	$\lambda > 0$	λ	λ	Seltene Ereignisse in festem Intervall
Diskret Gleichverteilt $U\{1, \dots, n\}$	$n \in \mathbb{N}$	$\frac{n+1}{2}$	$\frac{n^2-1}{12}$	Würfel, Zufallszahl aus endlicher Menge

Tabelle 23.2: Diskrete Verteilungen

Verteilung	Parameter	$E[X]$	$\text{Var}(X)$	Anwendung
Stetig Gleichverteilt $U(a, b)$	$a < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	”Keine Information auf Intervall
Normal $N(\mu, \sigma^2)$	$\mu \in \mathbb{R}, \sigma^2 > 0$	μ	σ^2	Grenzverteilung durch ZGWS, Messfehler
Exponential $\text{Exp}(\lambda)$	$\lambda > 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	Wartezeit bis zum nächsten Ereignis, gedächtnislos

Tabelle 23.3: Stetige Verteilungen

Satz	Anwendbar auf	Aussage / Zweck
Satz von de Moivre-Laplace	$\text{Bin}(n, p)$	$\text{Bin}(n, p) \rightarrow N(np, npq)$ für $n \rightarrow \infty$; Approximation der Binomial- durch Normalverteilung
Poisson-Approximation (Gesetz seltener Ereignisse)	$\text{Bin}(n, p)$ mit kleinem p , großem n	$\text{Bin}(n, p) \rightarrow \text{Poi}(\lambda)$ für $n \rightarrow \infty, p \rightarrow 0, np \rightarrow \lambda$
Zentraler Grenzwertsatz (ZGWS)	beliebige unabh. X_i mit endlicher Varianz (i.i.d. oder Lindeberg-Bedingung)	$\frac{S_n - E[S_n]}{\sqrt{\text{Var}(S_n)}} \rightarrow N(0, 1)$ in Verteilung
Schwaches Gesetz der großen Zahlen (WGGZ)	i.i.d. X_i mit endlichem $E[X_i]$	$\frac{S_n}{n} \xrightarrow{P} \mu$ (stochastische Konvergenz)
Starkes Gesetz der großen Zahlen (SGGZ)	i.i.d. X_i mit endlichem $E[X_i]$	$\frac{S_n}{n} \xrightarrow{\text{f.s.}} \mu$ (fast sichere Konvergenz)
Ungleichung von Chebyshev	jede Verteilung mit endlicher Varianz	$\mathbb{P}(X - \mu \geq k\sigma) \leq \frac{1}{k^2}$; grobe Abschätzung, kein Verteilungswissen nötig
Ungleichung von Markov	jede nichtnegative Zufallsvariable	$\mathbb{P}(X \geq a) \leq \frac{E[X]}{a}$; schwächer, aber allgemeiner als Chebyshev

23.5 | Referenzen

Symbole und Begriffe

Gegenstand	Beschreibung	Symbol
Binomialverteilung		$\mathcal{B}_{n,p}$
Dichte		f
Elementarereignis		ω
Ereignisraum		Ω
Erwartungswert	$\mathbb{E}[X]$	$\mathbb{E}$
Potenzmenge		$\mathcal{P}$
Wahrscheinlichkeitsfunktion		μ
Wahrscheinlichkeitsmaß		$\mathbb{P}$
Wahrscheinlichkeitsraum		$(\Omega, \mathbb{P})$

Glossar

Absolute Konvergenz . 63

B-WS Bedingte Wahrscheinlichkeit. 31

Bernoulli-Experiment . 47, 48

Covarianz todo. 75, 83

Ereignis B . 7, 8, 10–12, 14, 15, 17, 23–25, 27–29, 89

Gleichverteilung . 5

paarweise unkorreliert todo. 83

stückweise stetig Eine Funktion $f: [a, b] \rightarrow \mathbb{R}$ heißt *stückweise stetig*, wenn es eine Zerlegung

$$a = x_0 < x_1 < \dots < x_n = b$$

gibt, sodass f auf jedem offenen Teilintervall

$$(x_{i-1}, x_i), \quad i = 1, \dots, n,$$

stetig ist und an den Zerlegungspunkten die einseitigen Grenzwerte

$$\lim_{x \rightarrow x_i^-} f(x) \quad \text{und} \quad \lim_{x \rightarrow x_i^+} f(x)$$

jeweils existieren und endlich sind.. 16, 18, 22

Summe der ersten n Zufallsvariablen todo. 83–85, 88–94, 96, 97

Varianz todo. 72–77, 81–85, 92, 97

Verteilungsfunktion der Standardnormalverteilung $\int_{-\infty}^y \frac{1}{\sqrt{2\pi}} e^{x^2/2} dx$. 85, 86, 88–93

WS Wahrscheinlichkeiten. 7, 8, 12, 15, 33

ZV Zufallsvariable. iv, 40–43, 48, 49, 51, 53, 54, 59, 61, 63, 66

Index

Bernoulli-Experiment, 45, 47, 48

Binomialverteilung, 48, 62, 83–85, 88, 93–96

Dichte, 15–22, 27, 33, 43, 54, 55, 63–66

Dichte der Standardnormalverteilung, 86

Faltung, 59

Produktform, 51, 52, 56

Standardnormalverteilung, 86

Stetigkeitskorrektur, 89

Verteilungsfunktion der Standardnormalverteilung, 86