




# Vorlesung Wahrscheinlichkeits- theorie und Statistik

Sommersemester 2026

Vorlesung von Prof. Gentz

Vorlesungsnotizen und Aufarbeitung

**Liliana Sanfilippo**



# Inhaltsverzeichnis

|          |                                                                                                     |           |
|----------|-----------------------------------------------------------------------------------------------------|-----------|
| <b>I</b> | <b>Skript</b>                                                                                       | <b>1</b>  |
| <b>1</b> | <b>Modellieren zufälliger Ereignisse (V01)</b>                                                      | <b>5</b>  |
| 1.1      | Wahrscheinlichkeitsräume . . . . .                                                                  | 5         |
| 1.1.1    | Elementarereignisse . . . . .                                                                       | 5         |
| 1.1.2    | Ereignisräume . . . . .                                                                             | 6         |
| 1.1.3    | Ereignisse . . . . .                                                                                | 7         |
| 1.1.4    | Zähldichten und Wahrscheinlichkeitsmaße . . . . .                                                   | 8         |
| 1.1.5    | Wahrscheinlichkeitsräume . . . . .                                                                  | 9         |
| 1.1.6    | Modellierung . . . . .                                                                              | 10        |
| 1.2      | Gleichverteilung auf einer endlichen Menge . . . . .                                                | 12        |
| 1.3      | Wahrscheinlichkeitsräume, deren Ereignisraum nicht abzählbar ist . . . . .                          | 14        |
| 1.3.1    | Eindimensionale Dichten . . . . .                                                                   | 15        |
| 1.3.2    | Wahrscheinlichkeitsräume mit Dichten . . . . .                                                      | 17        |
| 1.3.3    | Uniforme Verteilung . . . . .                                                                       | 20        |
| 1.3.4    | Exponentialverteilung . . . . .                                                                     | 22        |
| <b>2</b> | <b>Rechnen mit Wahrscheinlichkeiten (V02)</b>                                                       | <b>23</b> |
| 2.1      | Mengenoperationen und Ereignisse . . . . .                                                          | 23        |
| 2.1.1    | Disjunktheit . . . . .                                                                              | 24        |
| 2.2      | Erste Rechenregeln für Wahrscheinlichkeiten . . . . .                                               | 27        |
| 2.2.1    | Das Ein- und Ausschlußprinzip . . . . .                                                             | 29        |
| <b>3</b> | <b>Bedingte Wahrscheinlichkeiten (V03 2025; V06 2026)</b>                                           | <b>31</b> |
| <b>4</b> | <b>Zufallsvariablen und ihre Verteilung einer Zufallsvariablen</b>                                  | <b>39</b> |
| 4.1      | Die Verteilung einer Zufallsvariablen . . . . .                                                     | 39        |
| 4.2      | Notationen . . . . .                                                                                | 42        |
| 4.3      | Zufallsvariablen mit abzählbarem Bildbereich . . . . .                                              | 44        |
| 4.4      | Zufallsvariablen mit Dichte . . . . .                                                               | 46        |
| 4.5      | Mehrdimensionale Zufallsvariablen und ihre gemeinsame Verteilung: Abzählbare Bildbereiche . . . . . | 48        |
| 4.6      | Mehrdimensionale Zufallsvariablen und ihre gemeinsame Verteilung: Dichten . . . . .                 | 50        |
| <b>5</b> | <b>Unabhängigkeit von Ereignissen (und Bernoulli-Experimente)</b>                                   | <b>53</b> |
| 5.1      | Stochastische Unabhängigkeit von Ereignissen . . . . .                                              | 53        |
| 5.2      | Unabhängige Nacheinanderausführung von Zufallsexperimenten . . . . .                                | 54        |
| 5.3      | Die Binomialverteilung . . . . .                                                                    | 55        |

|           |                                                                                     |            |
|-----------|-------------------------------------------------------------------------------------|------------|
| <b>6</b>  | <b>Unabhängigkeiten von Zufallsvariable</b>                                         | <b>57</b>  |
| 6.1       | Unabhängigkeit für Zufallsvariable mit abzählbarem Bildbereich                      | 59         |
| 6.1.1     | Poisson-Verteilte ZV                                                                | 61         |
| 6.2       | Zufallsvariable mit Dichten                                                         | 62         |
| 6.3       | Widerlegen von Unabhängigkeiten                                                     | 63         |
| <b>7</b>  | <b>Erwartungswert und Varianz von Zufallsvariablen</b>                              | <b>69</b>  |
| 7.1       | Definition und Existenz des Erwartungswerts                                         | 71         |
| 7.1.1     | Rechenregeln für den Erwartungswert                                                 | 75         |
| 7.2       | Varianz                                                                             | 82         |
| 7.2.1     | Rechenregeln für die Varianz                                                        | 85         |
| <b>8</b>  | <b>Varianz und Covarianz</b>                                                        | <b>93</b>  |
| 8.1       | Vorlesung 8                                                                         | 93         |
| <b>9</b>  | <b>Grenzwertsätze</b>                                                               | <b>95</b>  |
| 9.1       | Markoffsche und Tschebyscheffsche Ungleichung                                       | 95         |
| 9.2       | Schwaches Gesetz der großen Zahlen                                                  | 98         |
| 9.3       | Lokaler zentraler Grenzwertsatz und Stirlingsche Formel                             | 99         |
| 9.4       | Satz von de Moivre-Laplace und die Standardnormalverteilung                         | 101        |
| 9.4.1     | Anwendungstechniken zum Satz von de Moivre-Laplace                                  | 105        |
| 9.5       | Vergleich Gesetz der großen Zahlen vs. Zentraler Grenzwertsatz (ZGWS)               | 109        |
| 9.6       | ZGWS                                                                                | 110        |
| 9.7       | Poissonscher Grenzwertsatz (PGWS)                                                   | 112        |
| <b>10</b> | <b>Statistik</b>                                                                    | <b>119</b> |
| 10.1      | Daten, Häufigkeitsverteilungen und ihre Darstellung in der beschreibenden Statistik | 119        |
| 10.1.1    | Daten und Häufigkeitsverteilungen                                                   | 119        |
| 10.1.2    | Graphische Darstellungen eindimensionaler Daten                                     | 124        |
| 10.2      | Empirische Häufigkeitsverteilungen und ihre Lagemaße                                | 125        |
| 10.3      | Empirische Häufigkeitsverteilungen und ihre Streumaße                               | 131        |
| <b>11</b> | <b>Schließende Statistik: Testtheorie I</b>                                         | <b>139</b> |
| 11.1      | Punktschätzer                                                                       | 141        |
| 11.1.1    | Kriterien zur Beurteilung von Punktschätzern                                        | 143        |
| <b>II</b> | <b>Tutorien</b>                                                                     | <b>151</b> |
| <b>12</b> | <b>Tutorium 20.04.2026</b>                                                          | <b>153</b> |
| 12.1      | PÜ 1.1.4 - Faire Münze 3-mal Werfen                                                 | 153        |
| 12.2      | PÜ 1.1.5 - Faire Münze n-mal Werfen                                                 | 153        |
| 12.3      | PÜ 1.1.6 - Mensch ärgere dich nicht                                                 | 153        |
| <b>13</b> | <b>Tutorium 27.04.2026</b>                                                          | <b>155</b> |
| 13.1      | PÜ 1.2.4                                                                            | 155        |
| <b>14</b> | <b>Tutorium 04.05.2026 (Zusatztutorial)</b>                                         | <b>157</b> |
| 14.1      | PÜ 1.0.1                                                                            | 157        |
| 14.2      | PÜ 1.0.2.                                                                           | 158        |
| 14.3      | PÜ 1.0.3.                                                                           | 159        |

|                                                                                                                                               |            |
|-----------------------------------------------------------------------------------------------------------------------------------------------|------------|
| <b>15 Tutorium 11.05.2026</b>                                                                                                                 | <b>161</b> |
| 15.1 PÜ 1.3.4. . . . .                                                                                                                        | 161        |
| <b>16 Tutorium 18.05.2026</b>                                                                                                                 | <b>163</b> |
| 16.1 PÜ 1.4.4. . . . .                                                                                                                        | 163        |
| 16.2 PÜ 1.4.5. . . . .                                                                                                                        | 163        |
| <b>17 Tutorium 26.05.2026</b>                                                                                                                 | <b>165</b> |
| 17.1 PÜ 1.5.4. . . . .                                                                                                                        | 165        |
| 17.2 PÜ 1.5.5. . . . .                                                                                                                        | 165        |
| <b>18 Tutorium 01.06.2026</b>                                                                                                                 | <b>167</b> |
| 18.1 PÜ 1.6.4. . . . .                                                                                                                        | 167        |
| 18.2 Besprechung ÜB 1.5.1 . . . . .                                                                                                           | 169        |
| 18.3 Besprechung ÜB 1.5.2 . . . . .                                                                                                           | 170        |
| 18.4 Besprechung ÜB 1.5.3 . . . . .                                                                                                           | 171        |
| 18.5 PÜ 2.1.4 . . . . .                                                                                                                       | 171        |
| 18.6 PÜ 2.1.5 . . . . .                                                                                                                       | 171        |
| 18.7 PÜ 2.1.6 . . . . .                                                                                                                       | 171        |
| <b>19 Tutorium 15.06.2026</b>                                                                                                                 | <b>173</b> |
| 19.1 PÜ 2.2.4. . . . .                                                                                                                        | 173        |
| 19.2 PÜ 2.2.5 . . . . .                                                                                                                       | 174        |
| 19.3 PÜ 2.2.6 . . . . .                                                                                                                       | 176        |
| <b>20 Tutorium 22.06.2026</b>                                                                                                                 | <b>177</b> |
| 20.1 PÜ 2.3.4 . . . . .                                                                                                                       | 177        |
| 20.2 PÜ 2.3.5 . . . . .                                                                                                                       | 178        |
| 20.3 PÜ 2.3.6 . . . . .                                                                                                                       | 178        |
| <b>21 Tutorium 29.06.2026</b>                                                                                                                 | <b>179</b> |
| 21.1 PÜ 2.4.4 . . . . .                                                                                                                       | 179        |
| 21.2 PÜ 2.4.5 . . . . .                                                                                                                       | 179        |
| <b>22 Tutorium 06.07.2026</b>                                                                                                                 | <b>181</b> |
| 22.1 PÜ 2.5.4 . . . . .                                                                                                                       | 181        |
| 22.2 PÜ 2.5.5 . . . . .                                                                                                                       | 181        |
| <b>23 Tutorium 13.07.2026</b>                                                                                                                 | <b>183</b> |
| 23.1 PÜ 2.6.4 . . . . .                                                                                                                       | 183        |
| 23.2 PÜ 2.6.5 . . . . .                                                                                                                       | 185        |
| 23.3 Besprechung ÜB 2.5.1 . . . . .                                                                                                           | 186        |
| <b>III Anhang</b>                                                                                                                             | <b>187</b> |
| 23.4 Übersichten . . . . .                                                                                                                    | 189        |
| 23.4.1 Zusammenhang Poissonscher Grenzwertsatz, Zentraler Grenzwertsatz, Satz von de Moivre-Laplace<br>und Gesetz der großen Zahlen . . . . . | 189        |
| 23.5 Referenzen . . . . .                                                                                                                     | 192        |
| Glossary . . . . .                                                                                                                            | 192        |
| Index . . . . .                                                                                                                               | 196        |



**Teil I**

**Skript**





---

## Legende

|                                          |                          |
|------------------------------------------|--------------------------|
| Skript                                   | normale schwarze Schrift |
| Meine Anmerkungen und Notizen            | Lila Schrift             |
| Schriftliche Anmerkungen der Professorin | Orangene Schrift         |



# KAPITEL 1

## Modellieren zufälliger Ereignisse (V01)

Vorlesung 11.04.2025 (V01 2025), ergänzt durch Skript (Skript 2026) für Vorlesung 17.04.2026 (V01 2026)

### 1.1 | Wahrscheinlichkeitsräume

**Kommentar 1.1** Fehlkalkulationen durch unzureichende Modelle bzw. fehlende Parameter werden oft als Zufall gesehen. Wir versuchen Modelle so zu wählen, dass sie möglichst einfach sind




Abbildung 1.1

### Lernziele

- modellieren einfacher Zufallsexperimente
- **Wahrscheinlichkeitsraum** kennen und verwenden
- **Gleichverteilung** kennen und erkennen

#### 1.1.1 | Elementarereignisse

**Definition 1.1** **Elementarereignis**  $\omega$  (2025)

Möglicher Ausgang eines Zufallsexperiments.

Es ist üblich, für Elementarereignisse den kleinen griechischen Buchstaben  $\omega$  (omega) zu verwenden. Davon weichen wir in konkreten Situationen manchmal ab. So schreiben wir zum Beispiel auch  $k$ , wenn das Elementarereignis eine natürliche Zahl ist, oder  $x$ , wenn es eine reelle Zahl ist.

**Beispiel 1.1** Zu Definition 1.1 (2025)

- Würfeln:  $\omega = 3$  (3 gewürfelt)
- Zeitmessung:  $\omega = 100$  (Sec)

**Karteikarte 1.1** Was ist ein Elementarereignis?

Ein möglicher Ausgang eines Zufallsexperiments. Notation: kleiner griechischer Buchstabe  $\omega$  (omega). Je nach Kontext auch andere Symbole, z.B.  $k$  für natürliche Zahlen oder  $x$  für reelle Zahlen..

**1.1.2 | Ereignisräume****Definition 1.2** Ereignisraum  $\Omega$  (2025)

Die Menge aller Elementarereignisse  $\Omega \neq \emptyset$  ist die Menge aller möglichen Ausgänge eines Zufallsexperiments. Ein Ereignisraum ist also zunächst einmal einfach eine nichtleere Menge.

Für einen Ereignisraum verwenden immer den großen griechischen Buchstaben  $\Omega$  (Omega). Wenn wir mehrere Ereignisräume benötigen, so schreiben wir  $\Omega, \tilde{\Omega}, \Omega_1, \Omega_2, \dots$  usw.

**Beispiel 1.2** Zu Definition 1.2 (2025)

- **Würfeln:**  $\Omega = \{1, \dots, 6\}$  oder  $\Omega = \{wuerfelsymbole\}$

Die Modellierung durch Würfelsymbole zeigt, dass es beim Modellieren wichtig ist anzugeben, welche Interpretation unsere Kodierung der Elementarereignisse haben soll. Man soll daher stets einen Satz der Art

“Dabei bedeutet  $\omega = wuerfelsymbol1$ , dass der Würfel eine Eins zeigt”

schreiben, wenn man einen Ereignisraum angibt.

- **Zeitmessung:**  $\Omega = [0, \infty)$  ist grundsätzlich eine sinnvolle Wahl, wenn wir das Messen einer zufälligen Zeit modellieren wollen. Sofern Zusatzinformationen vorliegen, können wir natürlich ein kleineres Intervall wählen.

**Kommentar 1.2** Siehe die Klammersymbolnotation, die bedeutet die Null ist drin, aber infinity nicht.  $\infty$  ist keine normale Zahl, sondern ein Symbol für Unbeschränktheit. Deshalb schreibt man praktisch immer die runde Klammer auf der Seite.

Häufig interessiert uns gar nicht der exakte Ausgang eines Zufallsexperiments, sondern nur, ob der Ausgang eine bestimmte Eigenschaft hat: Haben wir eine gerade Zahl gewürfelt? Ist die gemessene Zeit kürzer als eine Minute? Wir fassen also jene Elementarereignisse zusammen, die die gewünschte Eigenschaft haben. Dies führt zur folgenden Definition.

**Karteikarte 1.2** Was ist ein Ereignisraum  $\Omega$ ?

Die Menge aller Elementarereignisse, also aller möglichen Ausgänge eines Zufallsexperiments. Muss nichtleer sein ( $\Omega \neq \emptyset$ ). Notation: großer griechischer Buchstabe  $\Omega$  (Omega). Bei mehreren Ereignisräumen:  $\Omega, \tilde{\Omega}, \Omega_1, \Omega_2, \dots$

**Karteikarte 1.3** Wie wählt man den Ereignisraum beim Würfeln bzw. bei der Zeitmessung?

Würfeln:  $\Omega = \{1, \dots, 6\}$  (oder Würfelsymbole). Zeitmessung:  $\Omega = [0, \infty)$  als sinnvolle Grundwahl, kann bei Zusatzinformationen auf ein kleineres Intervall eingeschränkt werden. Wichtig: Bei Angabe von  $\Omega$  stets die Interpretation der Elementarereignisse angeben, z.B. “Dabei bedeutet  $\omega = 1$ , dass der Würfel eine Eins zeigt”.

### 1.1.3 | Ereignisse

#### Definition 1.3 Ereignis $A$ (2025)

(Messbare) Teilmenge des Ereignisraums  $A \subseteq \Omega$  ( $A = \emptyset, A = \Omega$ ) sind zulässig

Sprechweise:  $\omega \in A$  bedeutet “ $A$  ist eingetroffen”

Im Fall, dass der Ereignisraum  $\Omega \subseteq \mathbb{R}^n$  weder eine endliche noch eine abzählbar unendliche Menge ist, beschränken wir uns auf Ereignisse, die Intervalle oder bekannte geometrische Figuren wie Dreieck, Rechteck oder Kugel sind. Auch abzählbare Schnitte oder Vereinigungen solcher Objekte sind zulässig, sowie deren abzählbare Schnitte oder Vereinigungen. Und so weiter. Diese Einschränkung erlaubt es uns, Fragen der mathematischen Maß- und Integrationstheorie zu vermeiden.

#### Bemerkung 1.1 Zu Definition 1.3 (2026)

- Ein Ereignis  $A \subseteq \Omega$  ist also ein (messbares) Element der Potenzmenge  $\mathcal{P}(\Omega)$  von  $\Omega$ , das heißt,  $A \in \mathcal{P}(\Omega)$ .
- Ist  $\omega \in \Omega$  ein Elementarereignis, so ist die einelementige Menge  $\{\omega\} \in \mathcal{P}(\Omega)$  ein Ereignis in  $\Omega$ .

#### Beispiel 1.3 (2025) Zu Definition 1.3

- **Würfeln** einer geraden Zahl:

$$A = \{2, 4, 6\}, \quad \omega = 4 \Rightarrow \omega \in A$$

Wir sagen: “gerade Zahl gewürfelt”

- **Zeitmessung:**  $A = [100, 200] \subset \Omega = [0, \infty)$

#### Karteikarte 1.4 Was ist ein Ereignis $A$ ?

Eine (messbare) Teilmenge des Ereignisraums,  $A \subseteq \Omega$ . Auch  $A = \emptyset$  und  $A = \Omega$  sind zulässig. Sprechweise:  $\omega \in A$  bedeutet “ $A$  ist eingetroffen”. Formal ist  $A$  ein Element der Potenzmenge  $\mathcal{P}(\Omega)$ , also  $A \in \mathcal{P}(\Omega)$ .

#### Karteikarte 1.5 Ist ein Elementarereignis auch ein Ereignis?

Ja. Ist  $\omega \in \Omega$  ein Elementarereignis, so ist die einelementige Menge  $\{\omega\} \in \mathcal{P}(\Omega)$  ein Ereignis in  $\Omega$ .

**Kommentar 1.3** Beim geeigneten  $\Omega$  können Modelle sich bereits unterscheiden. Bspw. Münzwurf: Man kann “k”, “z” nehmen oder “Kopf”, “Zahl”. Das sind verschiedenen  $\Omega$ , aber beide wären passend.

- Finden des geeigneten  $\Omega$
- Ereignisse müssen **Wahrscheinlichkeit (WS)** zugeordnet bekommen

#### 1. Möglichkeit: WS für $\Omega$ abzählbar

**Kommentar 1.4** Wenn sie abzählbar sagt, meint sie sowohl endlich als auch abzählbar unendlich.

#### Karteikarte 1.6 Welche Ereignisse betrachtet man, wenn $\Omega \subseteq \mathbb{R}^n$ weder endlich noch abzählbar unendlich ist?

Man beschränkt sich auf Ereignisse, die Intervalle oder bekannte geometrische Figuren sind (Dreieck, Rechteck, Kugel), sowie abzählbare Schnitte oder Vereinigungen solcher Objekte. Dies vermeidet Probleme der Maß- und Integrationstheorie..

### 1.1.4 | Zähldichten und Wahrscheinlichkeitsmaße

#### Definition 1.4 Zähldichte / $\mu$ (2025)

Sei  $\Omega \neq \emptyset$  eine abzählbare Menge.

1. Eine Abbildung  $\mu : \Omega \rightarrow [0, 1]$  heißt mit

$$\underbrace{\sum_{\omega \in \Omega} \mu(\omega)}_{\text{Normierung}} = 1$$

Zähldichte / Wahrscheinlichkeitsfunktion auf  $\Omega$ .

2. Die WS  $\mathbb{P}(A)$  einer Ereignisses  $A \subseteq \Omega$  ist bei gegebener Wahrscheinlichkeitsfunktion  $\mu$  definiert durch

$$\mathbb{P}(A) := \sum_{\omega \in A} \mu(\omega)$$

$\mathbb{P}$  heißt Wahrscheinlichkeitsmaß und liegt immer zwischen Null und 1

**Kommentar 1.5** Zu Definition 1.4 (i): Die Reihe (Normierung) muss 1 sein und konvergieren.

Wenn man max abzählbar hat, dann sind die Wahrscheinlichkeiten einfach teile der Summe (Normierung) und daher ist das einfach.

**Kommentar 1.6** TODO: Was hat die Potenzmenge von Omega damit zu tun?

#### Bemerkung 1.2 (2025) Zu Definition 1.4 (ii)

Konvention:  $\mathbb{P}(\emptyset) = 0$

#### Bemerkung 1.3 Zu Definition 1.4 (2025)

$$0 \leq \mathbb{P} \leq 1, \quad \forall A \subseteq \Omega \quad \underbrace{(\forall A \in \mathcal{P}(\Omega))}_{\mathcal{P}(\Omega) \text{ Potenzmenge von } \Omega}$$

$\mathbb{P}$  ist eine Abb.

$$\mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1] \quad \text{mit } \mathbb{P}(\emptyset) = 0, \quad \mathbb{P}(\Omega) = 1$$

#### Lemma 1.1 Eigenschaften des Wahrscheinlichkeitsmaßes für abzählbare Ereignisräume (2026)

Sei  $\Omega \neq \emptyset$  eine abzählbare Menge und  $\mathbb{P}$  ein Wahrscheinlichkeitsmaß auf  $\Omega$ . Dann gelten:

- $0 \leq \mathbb{P}(A) \leq 1$  für alle  $A \subseteq \mathcal{P}(\Omega)$
- $\mathbb{P}(\emptyset) = 0$
- $\mathbb{P}(\Omega) = 1$

**Beweis.**

- Untere Schranke: Da  $\mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega)$  gilt und alle Summanden nichtnegativ sind, folgt  $\mathbb{P}(A) \geq 0$
- Obere Schranke: Aus

$$\mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega) \leq \sum_{\omega \in \Omega} \mu(\omega) = 1$$

folgt  $\mathbb{P}(A) \leq 1$ . Dabei haben wir in der Abschätzung erneut verwendet, daß alle Summanden nichtnegativ sind.

■  $\mathbb{P}(\emptyset) = 0$  gilt gemäß Konvention aus 1.2.

■  $\mathbb{P}(\Omega) = \sum_{\omega \in \Omega} \mu(\omega) = 1$  folgt direkt aus der Normierung der Wahrscheinlichkeitsfunktion.

### Karteikarte 1.7 Was ist eine Zähldichte / Wahrscheinlichkeitsfunktion $\mu$ ?

Sei  $\Omega \neq \emptyset$  abzählbar. Eine Abbildung  $\mu : \Omega \rightarrow [0, 1]$  mit  $\sum_{\omega \in \Omega} \mu(\omega) = 1$  (Normierung) heißt Zähldichte bzw. Wahrscheinlichkeitsfunktion auf  $\Omega$ .

### Karteikarte 1.8 Wie berechnet man aus einer Zähldichte $\mu$ die Wahrscheinlichkeit $P(A)$ eines Ereignisses?

$P(A) := \sum_{\omega \in A} \mu(\omega)$ .  $P$  heißt Wahrscheinlichkeitsmaß und liegt immer zwischen 0 und 1..

### Karteikarte 1.9 Welchen Wert hat $P(\emptyset)$ ?

Konvention:  $P(\emptyset) = 0$ .

### Karteikarte 1.10 Welche drei Grundeigenschaften hat ein Wahrscheinlichkeitsmaß $P$ auf abzählbarem $\Omega$ ?

(1)  $0 \leq P(A) \leq 1$  für alle  $A \in \mathcal{P}(\Omega)$ . (2)  $P(\emptyset) = 0$ . (3)  $P(\Omega) = 1$ .  $P$  ist eine Abbildung  $P : \mathcal{P}(\Omega) \rightarrow [0, 1]$ .

### Karteikarte 1.11 Wie zeigt man $0 \leq P(A) \leq 1$ ?

Untere Schranke:  $P(A) = \sum_{\omega \in A} \mu(\omega) \geq 0$ , da alle Summanden nichtnegativ sind. Obere Schranke:  $P(A) = \sum_{\omega \in A} \mu(\omega) \leq \sum_{\omega \in \Omega} \mu(\omega) = 1$ , ebenfalls weil alle Summanden nichtnegativ sind.

### Karteikarte 1.12 Was ist der Unterschied zwischen $\mu$ und $P$ bezüglich ihres Definitionsbereichs?

$\mu$  hat als Argument ein einzelnes Elementarereignis  $\omega$  (also  $\mu(\omega)$ ), während  $P$  auf der Potenzmenge  $\mathcal{P}(\Omega)$  definiert ist und daher das einelementige Ereignis  $\{\omega\}$  als Argument hat (also  $P(\{\omega\})$ ).

## 1.1.5 | Wahrscheinlichkeitsräume

### Definition 1.5 Wahrscheinlichkeitsraum (2025)

$(\Omega, \mathbb{P})$  heißt Wahrscheinlichkeitsraum.  
 $(\Omega, \mu)$

**Bemerkung 1.4** Zu Definition 1.5 (2025)

Für  $\Omega$  abzählbar:  $\mu$  legt  $\mathbb{P}$  eindeutig und umgekehrt!

$$\mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega) \quad \forall A \in \mathcal{P}(\Omega)$$

$$\mu(\omega) = \mathbb{P}(\underbrace{\{\omega\}}_{\text{1-elementige Menge}}) \quad \forall \omega \in \Omega$$

**Länger aus dem Skript:** (2026) Da es eine ein-eindeutige Zuordnung zwischen der Wahrscheinlichkeitsfunktion  $\mu$  und dem Wahrscheinlichkeitsmaß  $\mathbb{P}$  gibt, bezeichnen wir auch das Paar  $(\Omega, \mathbb{P})$  als Wahrscheinlichkeitsraum. Die Zuordnung von  $\mu$  zu  $\mathbb{P}$  ist direkt durch die Definition von  $\mathbb{P}$  in Definition 1.4 gegeben. Für eine gegebene Wahrscheinlichkeitsfunktion erhalten wir so ein eindeutig bestimmtes Wahrscheinlichkeitsmaß. Ist ein Wahrscheinlichkeitsmaß  $\mathbb{P}$  gegeben, so ergibt sich die zugehörige Wahrscheinlichkeitsfunktion  $\mu$  sofort aus den Wahrscheinlichkeiten der Elementarereignisse:

$$\mu(\omega) = \mathbb{P}(\{\omega\}), \quad \forall \omega \in \Omega$$

Beachten Sie hier, dass die Wahrscheinlichkeitsfunktion  $\mu$  als Argument ein Elementarereignis, also ein einzelnes  $\omega \in \Omega$  hat, während das Wahrscheinlichkeitsmaß  $\mathbb{P}$  auf der Potenzmenge  $\mathcal{P}(\Omega)$  von  $\Omega$  definiert ist und daher das einelementige Ereignis  $\{\omega\}$  als Argument hat.

**Karteikarte 1.13** Was ist ein Wahrscheinlichkeitsraum?

Das Paar  $(\Omega, \mu)$  heißt Wahrscheinlichkeitsraum. Es besteht eine ein-eindeutige Zuordnung zwischen der Wahrscheinlichkeitsfunktion  $\mu$  und dem Wahrscheinlichkeitsmaß  $P$ :  $P(A) = \sum_{\omega \in A} \mu(\omega)$  und umgekehrt  $\mu(\omega) = P(\{\omega\})$ .

**1.1.6 | Modellierung****Beispiel 1.4** Einmal Würfeln (2025)

$\Omega = \{1, \dots, 6\}$ ,  $A = \{6\}$  (sechs gewürfel),  $B = \{2, 4, 6\}$  (gerade Zahl).

Dabei beudeute  $\omega = k$ , dass der Würfel  $k$  Augen hat. Wie wählen wir  $\mu$ ?

**1. fairer Würfel:**

$$\mu(k) = \text{const} \quad \forall k \in \Omega$$

$$\mu(k) := \frac{1}{6} \left( \text{weil } \sum_{k=1}^6 \mu(k) \stackrel{!}{=} 1 \right)$$

$$\mathbb{P}(A) = \mu(a) = \frac{1}{6}, \quad \mathbb{P}(B) = \sum_{k \in \{2,4,6\}} \mu(k) = \frac{1}{6} \cdot \#B = \frac{3}{6} = \frac{1}{2}$$

**2. gezinkter Würfel:** Seien

$$\mu(1) = \frac{1}{2}, \mu(2) = \mu(3) = \mu(4) = \mu(5) = \frac{1}{12}, \mu(6) = \frac{1}{6}$$

$$\text{Probe: } \sum_{k=1}^6 \mu(k) \stackrel{!}{=} 1$$

**Kommentar 1.7** Zu Beispiel 1.4: In Hausaufgaben zu jedem Omega hinzuschreiben, was es bedeutet! "Dabei beudeute  $\omega = k$ , dass ..."

**Kommentar 1.8** Zu Beispiel 1.4 (1.): Ein ebener Würfel ist ein "fairer Würfel", weil alle Seiten gleich Wahrscheinlich sind.

**Kommentar 1.9** Zu Beispiel 1.4 (2.): In der Klausur wenn bei einer Probe ein Fehler herauskommt, gerne hinschreiben man hat gemerkt da ist ein Fehler und wo der gewesen sein muss, besser als nichts hinschreiben.



Wie wählen wir  $\Omega$  und  $\mu$  (bzw.  $\mathbb{P}$ )?

■ Frage der Erfahrung

■ wichtiges Thema und Lernziel dieses Semester

### Beispiel 1.5 Zweimal würfeln mit fairem Würfel - Augensumme (2025)

1. **Ansatz:**  $\Omega_1 = \{1, \dots, 6\}^2 = \{(i, j) : i, j \in \{1, \dots, 6\}\}$

Für  $\omega = (i, j) \in \Omega_1$  bedeutet  $i$  die Augenzahl des ersten Würfels und  $j$  jene des zweiten Würfels.

Aus Symmetriegründen wählen wir  $\mu_1(\omega)$  konstant, also

$$\mu_1(\omega) = \frac{1}{|\Omega_1|} = \frac{1}{36} \quad \forall \omega \in \Omega_1$$

$A_k^{(1)} \leq \Omega_1$ : Augensumme ist  $k$

Für  $k \leq 1$  oder  $k \geq 13$ :

$$A_k^{(1)} = \emptyset \Rightarrow \mathbb{P}_1(A_k^{(1)}) = 0$$

Für  $k = \{2, \dots, 12\}$ :

$$\mathbb{P}_1(A_2^{(1)}) = \mathbb{P}_1(\{(1, 1)\}) = \mu_1((1, 1)) = \frac{1}{36}$$

$$\mathbb{P}_1(A_3^{(1)}) = \mathbb{P}_1(\{(1, 2), (2, 1)\}) = \mu_1((1, 2)) + \mu_1((2, 1)) = \frac{2}{36}$$

usw...Es wird immer eines mehr

| $k$                       | 2              | 3              | 4              | 5              | 6              | 7              | 8              | 9              | 10             | 11             | 12             |
|---------------------------|----------------|----------------|----------------|----------------|----------------|----------------|----------------|----------------|----------------|----------------|----------------|
| $\mathbb{P}_1(A_k^{(1)})$ | $\frac{1}{36}$ | $\frac{2}{36}$ | $\frac{3}{36}$ | $\frac{4}{36}$ | $\frac{5}{36}$ | $\frac{6}{36}$ | $\frac{5}{36}$ | $\frac{4}{36}$ | $\frac{3}{36}$ | $\frac{2}{36}$ | $\frac{1}{36}$ |

Probe:

$$\sum_{k=2}^{12} \mathbb{P}_1(A_k^{(1)}) = 1$$

2. **Ansatz:** "Wir beachten die Reihenfolge beim Würfeln nicht"

$$\Omega_2 = \{(i, j) \in \Omega_1 : i \leq j\}$$

Dabei bedeute  $\omega = (i, j)$ , dass sowohl  $i$  als auch  $j$  gewürfelt wurden.

Finde  $\mu_2$ !

(1)  $i \leq j$ :  $1 \times i$  und  $1 \times j$  gewürfelt

$$\mu_2((i, j)) = \mu_1((i, j)) + \mu_1((j, i)) = \frac{2}{36}$$

(2)  $i = j$ :  $2 \times i$  gewürfelt

$$\mu_2((i, i)) = \frac{1}{36}$$

Probe machen!

$$A_k^{(2)} = \{(i, j) \in \Omega_2 : i + j = k\}$$

Exemplische Ausrechnung:

$$\mathbb{P}_2(A_4^{(2)}) = \mu_2((1, 3)) + \mu_2((2, 2)) = \frac{2}{36} + \frac{1}{36} = \frac{3}{36}$$

3. **Ansatz:**  $\Omega_3 = \{2, 3, \dots, 12\}$

Finde  $\mu_3$ ?  $\rightarrow$  Verwende Tabelle aus dem 1. Ansatz, denn  $\mu_3(k) = \mathbb{P}(A_k^{(1)})$ :

|            |                |                |                |                |                |                |                |                |                |                |                |
|------------|----------------|----------------|----------------|----------------|----------------|----------------|----------------|----------------|----------------|----------------|----------------|
| $k$        | 2              | 3              | 4              | 5              | 6              | 7              | 8              | 9              | 10             | 11             | 12             |
| $\mu_3(k)$ | $\frac{1}{36}$ | $\frac{2}{36}$ | $\frac{3}{36}$ | $\frac{4}{36}$ | $\frac{5}{36}$ | $\frac{6}{36}$ | $\frac{5}{36}$ | $\frac{4}{36}$ | $\frac{3}{36}$ | $\frac{2}{36}$ | $\frac{1}{36}$ |

**Kommentar 1.10** Man hat beim Modellieren immer die Wahl. Und man muss aufpassen wie man es macht.

**Beispiel 1.6 Reißzwecke “würfeln” - Symmetrieüberlegungen helfen nicht (2025)**

$\Omega = \{R, S\}$  (R auf Kopf, S auf Seite)

Definition:  $\mu(S) > \mu(R)$

10.000 Würfe; 4213 R

Möchte  $\mu(R) \approx \frac{4213}{10.000} = 0,4213$  (relative Häufigkeit)

-> Gesetz der gr. Zahlen

-> Statistik

**Kommentar 1.11** Take-Home message: Wann immer möglich, modelliere so, dass  $\mu(\omega) = \text{const} \forall \omega \in \Omega$  (erfordert Symmetrieargumente)

**Karteikarte 1.14 Was ist die Take-Home-Message beim Modellieren von  $\mu$ ?**

Wann immer möglich, modelliere so, dass  $\mu(\omega) = \text{const} \forall \omega \in \Omega$  gilt (Gleichverteilung). Dies erfordert Symmetrieargumente..

## 1.2 | Gleichverteilung auf einer endlichen Menge

(2025)

**Definition 1.6 Gleichverteilung (2025)**

Sei  $\Omega \neq \emptyset$  eine endl. Menge, d.h.  $0 < \#\Omega < \infty$ . Gilt  $\mu(\omega) = \mu(\tilde{\omega}) \quad \forall \omega, \tilde{\omega} \in \Omega$  d.h. die **Wahrscheinlichkeitsfunktion**  $\mu$  ist konstant, so heißen die wfkt  $\mu$  und das zugehörige Maß  $P$  die Gleichverteilung auf  $\Omega$

**Lemma 1.2 Rechnen mit der Gleichverteilung (2026)**

Sei  $\mu$  die Gleichverteilung auf  $\Omega$ . Dann gelten:

$$(a) \mu(\omega) = \frac{1}{\#\Omega} \quad \forall \omega \in \Omega$$

$$(b) \mathbb{P}(A) = \frac{\#A}{\#\Omega} \quad \forall A \in \mathcal{P}(\Omega) \quad (\forall A \subseteq \Omega)$$

**Beweis.**

$$(a) 1 = \sum_{\omega \in \Omega} \mu(\omega) \stackrel{a)}{=} c \cdot \#\Omega \Rightarrow c = \frac{1}{\#\Omega}$$

$$(b) \mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega) \stackrel{a)}{=} \frac{\#A}{\#\Omega}$$

$\mathbb{P}(A)$  ist die Anzahl der günstigen Ausgänge, geteilt durch die Anzahl aller möglichen Ausgänge

<sup>a</sup>Wir dürfen annehmen, dass ein  $c \in [0, 1]$  existiert mit  $\mu(\omega) = c \quad \forall \omega \in \Omega$

**Bemerkung 1.5** (2025) Im Fall der Gleichverteilung reduziert sich das Berechnen von **WS** auf Abzählprobleme.

**Bemerkung 1.6** Keine Gleichverteilung, wenn der Ereignisraum nicht endlich ist (Skript 26 - Bemerkung 1.18)

Warum müssen wir voraussetzen, dass  $\#\Omega < \infty$ ? Nehmen wir an, es gäbe eine Gleichverteilung  $\mu$  auf einer abzählbar unendlichen Menge  $\Omega$ . Wir können der Einfachheit halber annehmen, dass  $\Omega$  die Menge der natürlichen Zahlen  $\mathbb{N}$  ist. Dann gibt es also ein  $c \in [0, 1]$  mit

$$1 = \sum_{k=1}^{\infty} \mu(k) = c \cdot \#\mathbb{N}$$

Nun gibt es zwei Fälle. Entweder,  $c = 0$ . Dann erhalten wir den Widerspruch  $1 = 0$ . Andernfalls, wenn  $c > 0$  gilt, erhalten wir ebenfalls einen Widerspruch, nämlich  $1 = \infty$ . Folglich kann es auf einer nicht endlichen Menge keine Gleichverteilung geben

**Beispiel 1.7** Gleichverteilung

- $1 \times$  Werfen einer fairen Münze:  $\Omega = \{K, Z\}, \mu(\omega) = \frac{1}{2} \forall \omega \in \Omega$
- $1 \times$  Würfeln oder  $2 \times$  Würfeln mit fairem Würfel

**Beispiel 1.8** KEINE Gleichverteilung (2026)

- Augensumme beim wiederholten Würfeln
- Werfen einer Reißzwecke

**Karteikarte 1.15** Wann heißt  $\mu$  Gleichverteilung auf  $\Omega$ ?

Sei  $\Omega \neq \emptyset$  endlich, d.h.  $0 < \#\Omega < \infty$ . Gilt  $\mu(\omega) = \mu(\tilde{\omega})$  für alle  $\omega, \tilde{\omega} \in \Omega$  (d.h.  $\mu$  ist konstant), so heißen  $\mu$  und das zugehörige  $P$  die Gleichverteilung auf  $\Omega$ .

**Karteikarte 1.16** Wie berechnet man  $\mu(\omega)$  und  $P(A)$  bei Gleichverteilung?

(a)  $\mu(\omega) = \frac{1}{\#\Omega}$  für alle  $\omega \in \Omega$ . (b)  $P(A) = \frac{\#A}{\#\Omega}$  für alle  $A \subseteq \Omega$ . Anschaulich: Anzahl der günstigen Ausgänge geteilt durch Anzahl aller möglichen Ausgänge..

**Karteikarte 1.17** Wie beweist man  $\mu(\omega) = \frac{1}{\#\Omega}$  bei Gleichverteilung?

Da  $\mu$  konstant ist, existiert ein  $c \in [0, 1]$  mit  $\mu(\omega) = c$  für alle  $\omega$ . Aus der Normierung folgt  $1 = \sum_{\omega \in \Omega} \mu(\omega) = c \cdot \#\Omega$ , also  $c = \frac{1}{\#\Omega}$ .

**Karteikarte 1.18** Worauf reduziert sich das Berechnen von Wahrscheinlichkeiten bei Gleichverteilung?

Auf reine Abzählprobleme (Kombinatorik), da  $P(A) = \frac{\#A}{\#\Omega}$  gilt..

**Karteikarte 1.19** Warum kann es keine Gleichverteilung auf einer abzählbar unendlichen Menge geben?

Annahme: Gleichverteilung  $\mu$  auf  $\Omega = \mathbb{N}$  mit Wert  $c$ . Aus  $1 = \sum_{k=1}^{\infty} \mu(k) = c \cdot \#\mathbb{N}$  folgt ein Widerspruch: Für  $c = 0$  ergibt sich  $1 = 0$ , für  $c > 0$  ergibt sich  $1 = \infty$ . Beide Fälle sind unmöglich, also existiert keine Gleichverteilung auf unendlichen Mengen. Deshalb ist in der Definition  $\#\Omega < \infty$  vorausgesetzt..

Vorlesung 25.04.2025 (V02 2025), ergänzt mit dem Skript aus 2026

## Lernziele

- Unterschied zwischen disjunkten und paarweise disjunkten Mengen
- Rechenregeln für Wahrscheinlichkeiten
  - Komplementär Wahrscheinlichkeit
  - Ein- und Ausschlussprinzip
  - Spezialfall paarweise disjunkter Mengen

## 1.3 | Wahrscheinlichkeitsräume, deren Ereignisraum nicht abzählbar ist

**Beispiel 1.9** Wahrscheinlichkeitsraum (2025)

Stoppen einer Zeit bis zu einer Stunde in ms.

$$\begin{aligned} \Omega &= \{0, 1, \dots, 360000\} && \text{(Zeit in ms)} \\ \mu(\omega) &:= \frac{1}{\#\Omega} \quad \forall \omega \in \Omega && \text{(Gleichverteilung)} \\ \mathbb{P}(A) &= \frac{\#A}{\#\Omega} \\ A &= \{600000, \dots, 9000000\} && \text{Zeit liegt zw. 10 und 15 Minuten} \\ \mathbb{P}(A) &= \frac{300001}{3600001} \approx \frac{300000}{3600000} = \frac{1}{12} \end{aligned}$$

Wir wollen kontinuierlich modellieren:

$$\begin{aligned}\tilde{\Omega} &= [0, 60] && \text{(in Minuten)} \\ \text{bzw. } \tilde{\Omega} &= [0, 360000] && \text{(in ms)} \\ \tilde{A} &= [10, 15] \\ \tilde{\mathbb{P}}(\tilde{A}) &\stackrel{!}{=} \frac{15 - 10}{60 - 0} = \frac{5}{60} = \frac{1}{12}\end{aligned}$$

Um auch modellieren zu können, dass Intervalle **WS** haben, die nicht **iwas** von ihrer Länge abgängen, arbeiten wir mit R-Integralen. **R-Integral**?

**Kommentar 1.12** TODO: Was genau ist  $\tilde{\Omega}$  ?

### 1.3.1 | Eindimensionale Dichten

**Definition 1.7 Eindimensionale Dichte** (2025, Skript 26 - Definition 1.22)

Eine Funktion  $f : \mathbb{R} \rightarrow [0, \infty)$ , die (uneigentlich) Riemann-integrierbar ist, heißt Dichte, sofern

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

**Bemerkung 1.7 Zu Definition 1.7** (Skript 26 - Bemerkung 1.23)

**Dichten sind nichtnegativ:** Die Definition einer **Dichte**  $f$  beinhaltet die Forderung  $f \leq 0$ , das heißt, es muss

$$f(x) \geq 0 \forall x \in \mathbb{R}$$

gelten.

Die folgende Bemerkung erinnert uns wohl an die für den Zweck dieser Vorlesung wichtigsten Aussagen über die Existenz von Riemann-Integralen.

**Bemerkung 1.8** Zu Definition 1.7 (2025, Skript 26 - Bemerkung 1.24)**Riemann-Integrierbarkeit**

■

- $f$  monoton oder  $f$  stetig  $\Rightarrow \int_a^b f(x)dx$  existiert für alle  $(a, b \in \mathbb{R})$  auch: für  $-\infty < a < b < \infty$
- $f$  stückweise stetig oder stückweise monoton,  $\Rightarrow \int_a^b f(x)dx$  existiert  $(a, b \in \mathbb{R})$  auch: für  $-\infty < a < b < \infty$
- $f \geq 0$  :  $f$  Riemann-integrierbar  $\Leftrightarrow \lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx < \infty$ 
  - Damit ist gemeint: Ist  $f \geq 0$ , so ist  $f$  genau dann uneigentlich Riemann-integrierbar über  $\mathbb{R}$ , wenn das Riemann-Integral  $\int_a^b f(x)dx$  für jede Wahl  $-\infty < a < b < \infty$  existiert und  $\lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx$  existiert. In diesem Fall gilt  $\int_{-\infty}^{\infty} f(x)dx = \lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx$
- $f$  ist uneigentlich Riemann-integrierbar über  $\mathbb{R}$ , gdw. sowohl  $(-\infty, 0]$  als auch  $[0, \infty)$  uneigentlich Riemann-integrierbar ist.
- $f$  ist genau dann uneigentlich Riemann-integrierbar über  $[0, \infty)$ , wenn  $f$  über jedes Intervall  $[0, b]$  Riemann-integrierbar ist und  $\lim_{b \rightarrow \infty} \int_0^b f(x)dx$  existiert. In diesem Fall schreiben wir

$$\int_0^{\infty} f(x)dx = \lim_{b \rightarrow \infty} \int_0^b f(x)dx$$

- Analog:  $f$  ist genau dann uneigentlich Riemann-integrierbar über  $(-\infty, 0]$ , wenn  $f$  über jedes Intervall  $[a, 0]$  Riemann-integrierbar ist und  $\lim_{a \rightarrow -\infty} \int_a^0 f(x)dx$  existiert. In diesem Fall schreiben wir

$$\int_{-\infty}^0 f(x)dx = \lim_{a \rightarrow -\infty} \int_a^0 f(x)dx$$

**Karteikarte 1.20** Was ist eine (eindimensionale) Dichte?

Eine Funktion  $f : \mathbb{R} \rightarrow [0, \infty)$ , die (uneigentlich) Riemann-integrierbar ist, heißt Dichte, sofern  $\int_{-\infty}^{\infty} f(x)dx = 1$  (Normierungsbedingung)..

**Karteikarte 1.21** Welche Vorzeichenbedingung erfüllt eine Dichte  $f$ ?

Dichten sind nichtnegativ:  $f(x) \geq 0$  für alle  $x \in \mathbb{R}$ .

**Karteikarte 1.22** Welche hinreichenden Kriterien für Riemann-Integrierbarkeit von  $f$  auf  $[a, b]$  kennst du?

$\int_a^b f(x)dx$  existiert für  $-\infty < a < b < \infty$ , wenn  $f$  monoton ODER stetig ist, oder wenn  $f$  stückweise stetig ODER stückweise monoton ist..

**Karteikarte 1.23** Wann ist eine nichtnegative Funktion  $f \geq 0$  uneigentlich Riemann-integrierbar über  $\mathbb{R}$ ?

Genau dann, wenn  $\lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx < \infty$  existiert (und  $\int_a^b f(x)dx$  für jede Wahl  $-\infty < a < b < \infty$  existiert). In diesem Fall gilt  $\int_{-\infty}^{\infty} f(x)dx = \lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx$ .

**Karteikarte 1.24** Wie zerlegt man die uneigentliche Riemann-Integrierbarkeit von  $f$  über  $\mathbb{R}$ ?

$f$  ist uneigentlich Riemann-integrierbar über  $\mathbb{R}$  genau dann, wenn sowohl  $(-\infty, 0]$  als auch  $[0, \infty)$  uneigentlich

Riemann-integrierbar sind. Für  $[0, \infty)$ :  $f$  integrierbar über jedes  $[0, b]$  und  $\lim_{b \rightarrow \infty} \int_0^b f(x) dx$  existiert; man schreibt dann  $\int_0^\infty f(x) dx := \lim_{b \rightarrow \infty} \int_0^b f(x) dx$ . Analog für  $(-\infty, 0]$  mit  $\lim_{a \rightarrow -\infty} \int_a^0 f(x) dx$ .

### 1.3.2 | Wahrscheinlichkeitsräume mit Dichten

#### Definition 1.8 Wahrscheinlichkeitsräume mit Dichten (2025, Skript 26 - Definition 1.25)

Sei eine Dichte  $f \geq 0$  gegeben (also  $f : \mathbb{R} \rightarrow [0, \infty)$ ). Wir setzen

$$\begin{aligned}\mathbb{P}([a, b]) &:= \int_a^b f(x) dx && \text{für alle } -\infty < a < b < \infty \\ \mathbb{P}([-\infty, b]) &:= \int_{-\infty}^b f(x) dx \\ \mathbb{P}([a, \infty]) &:= \int_a^\infty f(x) dx \\ \mathbb{P}\left(\bigcup_{i \in I} [a_i, b_i]\right) &:= \sum_{i \in I} \int_{a_i}^{b_i} f(x) dx && \text{für } I \subseteq \mathbb{N} \text{ (abzählbar) und } a_i < b_i \leq a_{i+1}^*\end{aligned}$$

Falls

$$a_1 = -\infty : (-\infty, b_1] \quad ; \quad b = +\infty : [a, \infty)$$

\* Auch geschrieben als: Seien  $I \subseteq \mathbb{N}$  eine abzählbare Indexmenge und  $[a_i, b_i]$  Intervalle mit  $a_i \leq b_i \leq a_{i+1} \leq b_{i+1}$  für alle  $i, i+1 \in I$ .

#### Beispiel 1.10 (2025) fehlt

**Kommentar 1.13 Zu Definition 1.8** Die Definition von  $\mathbb{P}$  auf einer abzählbaren Vereinigung disjunkter, aufsteigend geordneter Intervalle  $[a_i, b_i]$  ist additiv über die Dichte  $f$  definiert. Uneigentliche Randintervalle ( $a_1 = -\infty$  bzw.  $b_{\max} = +\infty$ ) werden gesondert als Halbintervallen behandelt. Eine alternative, schwächere Formulierung erlaubt statt  $a_i < b_i$  auch  $a_i \leq b_i$ , wodurch entartete (einpunktige) Intervalle zugelassen werden; da diese jeweils das Maß 0 besitzen, ändert sich der Wert von  $\mathbb{P}$  dadurch nicht.

#### Bemerkung 1.9 Zu Definition 1.8 (Skript 26 - Bemerkung 1.26)

- Wann immer das Wahrscheinlichkeitsmass  $\mathbb{P}$  durch eine eindimensionale Dichte gegeben ist, betrachten wir nur Wahrscheinlichkeiten von Mengen, die wir darstellen können als maximal abzählbar unendliche Vereinigung oder als maximal abzählbar unendlichen Schnitt von Intervallen. Auch können wir wiederum Vereinigungen und Schnitte von derart erhaltenen Mengen betrachten. Diese Prozedur kann beliebig oft wiederholt werden. Trotzdem gibt es Mengen, denen wir keine Wahrscheinlichkeit zuordnen können. Da es nicht ganz einfach ist, derartige - pathologische - Mengen zu konstruieren, bedeutet das für uns keine wesentliche Einschränkung.
- Um ein Zufallsexperiment zu modellieren, in dem nur Elementarereignisse aus einer echten Teilmenge  $I \subseteq \mathbb{R}$  angenommen werden können, wählen wir eine Dichte, die außerhalb von  $I$  Null ist, das heißt, es soll  $f(x) = 0$  für alle  $x \notin I$

#### Lemma 1.3 Wahrscheinlichkeit einelementiger Mengen (Skript 26 - Lemma 1.27)

Ist ein Wahrscheinlichkeitsmass  $\mathbb{P}$  durch eine Dichte  $f$  gegeben, so gilt

$$\mathbb{P}(\{a\}) = 0 \quad \forall a \in \mathbb{R}$$

**Beweis.** Skript 26 Seite 11

**Korollar 1.1 Dichten sind nicht eindeutig bestimmt** (Skript 26 - Korollar 1.28)

Das Wahrscheinlichkeitsmass  $\mathbb{P}$  sei durch eine Dichte  $f$  gegeben. Sei  $g$  eine weitere Dichte, die sich in höchstens abzählbar vielen Punkten von  $f$  unterscheidet, das heißt, es gebe eine abzählbare Menge  $M$  derart, dass  $g(x) = f(x)$  für alle  $x \in \mathbb{R} \setminus M$ . Dann definiert  $g$  dasselbe Wahrscheinlichkeitsmass  $\mathbb{P}$  wie  $f$ .

**Korollar 1.2 Wahrscheinlichkeit von Intervallen** (Skript 26 - Korollar 1.29)

Sei  $\mathbb{P}$  durch eine Dichte  $f$  gegeben. Dann gilt für jede Wahl von  $a, b \in \mathbb{R}$  mit  $-\infty < a < b < \infty$ ,

$$\mathbb{P}([a, b]) = \mathbb{P}((a, b]) = \mathbb{P}([a, b)) = \mathbb{P}((a, b))$$

**Beispiel 1.11 Messen einer zufälligen Zeit** (Skript 26 - Beispiel 1.30)

Wir wählen  $\Omega = \mathbb{R}$  und die Dichte

$$f(x) = \begin{cases} \frac{1}{60} & x \in [0, 60] \\ 0 & \text{sonst} \end{cases}$$

Dabei verstehen wir  $\omega \in \Omega$  als die gemessene Zeit (in Minuten) bei einer Realisierung des Zufallsexperiments. Die Tatsache, daß  $f = 0$  außerhalb von  $[0, 60]$  gilt, reflektiert, daß in unserem Experiment nur Zeiten innerhalb einer Stunde ab Start möglich sein sollen.

Wir müssen zeigen, daß  $f$  eine Dichte ist

1.  $f \geq 0$  gilt per Definition von  $f$
2.  $f$  ist **stückweise stetig** und daher Riemann-integrierbar
3. Die Normierungsbedingung ist erfüllt, weil

$$\int_{-\infty}^{\infty} f(x) dx = \int_0^{60} f(x) dx = \int_0^{60} \frac{1}{60} dx = \frac{60 - 0}{60} = 1$$

Wir sehen, dass, wie zuvor,

$$\mathbb{P}([10, 15]) = \int_{10}^{15} f(x) dx = \int_{10}^{15} \frac{1}{60} dx = \frac{5}{60} = \frac{1}{12}$$

gilt.



**Bemerkung 1.10** Vorgehen beim Berechnen von Integralen mit stückweise gegebener Dichte (Skript 26 - Bemerkung 1.31)

Es empfiehlt sich, sukzessive wie in obigem Beispiel vorzugehen:

1. Integral über Intervall aufschreiben
2. Grenzen anpassen, so daß nicht mehr über Intervalle integriert wird, auf denen  $f = 0$  gilt
3. Konkrete Form von  $f$  einsetzen
4. Integral ausrechnen

Genauer

1. Integral über Intervall aufschreiben:

- $\int_{-\infty}^{\infty} f(x) dx$ , um zu verifizieren, daß  $f$  die Normierungsbedingung erfüllt
- $\mathbb{P}([a, b]) = \int_{-\infty}^{\infty} f(x) dx$ , um eine Wahrscheinlichkeit zu berechnen

2. Grenzen anpassen, so daß nicht mehr über Intervalle integriert wird, auf denen  $f = 0$  gilt:

- $\int_{-\infty}^{\infty} f(x) dx = \int_0^{60} f(x) dx$
- $\mathbb{P}([50, 70]) = \int_{50}^{70} f(x) dx = \int_{50}^{60} f(x) dx$

3. Konkrete Form von  $f$  einsetzen:

- $\mathbb{P}([10, 15]) = \int_{10}^{15} f(x) dx \int_{10}^{15} \frac{1}{60} dx$
- $\mathbb{P}([50, 70]) = \int_{50}^{70} f(x) dx = \int_{50}^{60} f(x) dx = \int_{50}^{60} \frac{1}{60} dx$

4. Integral ausrechnen:

- $\mathbb{P}([10, 15]) = \int_{10}^{15} f(x) dx \int_{10}^{15} \frac{1}{60} dx = 1$
- $\mathbb{P}([50, 70]) = \int_{50}^{70} f(x) dx = \int_{50}^{60} f(x) dx = \int_{50}^{60} \frac{1}{60} dx = \frac{1}{6}$

**Bemerkung 1.11** (Skript 26) Falls  $f$  durch eine Fallunterscheidung mit mehr Fällen als in unserem Beispiel gegeben ist, so muss im dritten Schritt das Integral entsprechend aufgespalten werden,

$$\int_a^d f(x) dx = \int_a^b f(x) dx + \int_b^c f(x) dx + \int_c^d f(x) dx$$

Für  $a < b < c < d$ , bevor die konkrete Form von  $f$  eingesetzt wird.

Losgelöst von der Idee, daß wir eine zufällige Zeit messen wollen, können wir ganz allgemein für ein beliebiges beschränktes Intervall  $I$  eine Dichte definieren derart, daß die Wahrscheinlichkeit, daß der Ausgang des entsprechenden Zufallsexperiments in einem Teilintervall  $J \subseteq I$  liegt, weiterhin nur von der Länge des entsprechenden Teilintervalls  $J$  abhängt

**Karteikarte 1.25** Wie definiert man  $P$  auf Intervallen, wenn eine Dichte  $f \geq 0$  gegeben ist?

$P([a, b]) := \int_a^b f(x) dx$  für  $-\infty < a < b < \infty$ ;  $P([-\infty, b]) := \int_{-\infty}^b f(x) dx$ ;  $P([a, \infty]) := \int_a^{\infty} f(x) dx$ . Für abzählbare, aufsteigend geordnete disjunkte Intervalle  $[a_i, b_i]$ ,  $i \in I \subseteq \mathbb{N}$ :  $P(\bigcup_{i \in I} [a_i, b_i]) := \sum_{i \in I} \int_{a_i}^{b_i} f(x) dx$ .

**Karteikarte 1.26** Welche Mengen können bei einem Wahrscheinlichkeitsraum mit Dichte überhaupt eine Wahrscheinlichkeit bekommen?

Nur Mengen, die als maximal abzählbar unendliche Vereinigung oder Schnitt von Intervallen darstellbar sind (auch wiederholt kombiniert). Es gibt zwar pathologische Mengen ohne zugeordnete Wahrscheinlichkeit, diese sind aber schwer zu konstruieren und für die Praxis irrelevant..

**Karteikarte 1.27** Wie modelliert man ein Zufallsexperiment, bei dem nur Werte aus einer Teilmenge  $I \subseteq \mathbb{R}$  angenommen werden können?

Man wählt eine Dichte  $f$ , die außerhalb von  $I$  Null ist, also  $f(x) = 0$  für alle  $x \notin I$ .

**Karteikarte 1.28** Welche Wahrscheinlichkeit hat eine einelementige Menge  $\{a\}$ , wenn  $P$  durch eine Dichte gegeben ist?

$P(\{a\}) = 0$  für alle  $a \in \mathbb{R}$ . (Dichte-Modelle weisen einzelnen Punkten also stets Wahrscheinlichkeit 0 zu, im Gegensatz zu diskreten Modellen.).

**Karteikarte 1.29** Sind Dichten, die zu einem gegebenen Wahrscheinlichkeitsmaß gehören, eindeutig bestimmt?

Nein. Unterscheiden sich zwei Dichten  $f$  und  $g$  nur auf einer höchstens abzählbaren Menge  $M$  (d.h.  $g(x) = f(x)$  für alle  $x \notin M$ ), so definieren sie dasselbe Wahrscheinlichkeitsmaß  $P$ .

**Karteikarte 1.30** Spielt es bei einer Dichte eine Rolle, ob ein Intervall offen, halboffen oder abgeschlossen ist?

Nein. Für  $-\infty < a < b < \infty$  gilt  $P([a, b]) = P((a, b]) = P([a, b)) = P((a, b))$ , da einzelne Randpunkte jeweils Wahrscheinlichkeit 0 haben..

**Karteikarte 1.31** In welchen 4 Schritten berechnet man Integrale mit stückweise gegebener Dichte?

(1) Integral über das gewünschte Intervall aufschreiben (Normierung oder  $P([a, b])$ ). (2) Grenzen anpassen, sodass nicht mehr über Bereiche integriert wird, auf denen  $f = 0$  gilt. (3) Konkrete Form von  $f$  einsetzen. (4) Integral ausrechnen. Beispiel:  $P([50, 70]) = \int_{50}^{70} f(x)dx = \int_{50}^{60} f(x)dx = \int_{50}^{60} \frac{1}{60}dx = \frac{1}{6}$ .

**Karteikarte 1.32** Wie geht man vor, wenn die Dichte  $f$  durch mehr als zwei Fälle definiert ist?

Das Integral muss vor dem Einsetzen der konkreten Form von  $f$  entsprechend aufgespalten werden:  $\int_a^d f(x)dx = \int_a^b f(x)dx + \int_b^c f(x)dx + \int_c^d f(x)dx$  für  $a < b < c < d$ .

### 1.3.3 | Uniforme Verteilung

**Definition 1.9** Uniforme Verteilung auf einem Intervall (Kontinuumsäquivalent zu gleichverteilt) (2025, Skript 26 - Definition 1.32)

Die uniforme Verteilung auf einem beschränkten Intervall  $I \subseteq \mathbb{R}$  (äquivalent zu  $I = [a, b]$  mit  $-\infty < a < b < \infty$ ) ist gegeben durch eine Dichte

$$f(x) = \begin{cases} \frac{1}{|I|} & x \in I \\ 0 & \text{sonst} \end{cases} = \begin{cases} \frac{1}{b-a} & x \in I \\ 0 & \text{sonst} \end{cases}$$

wobei  $|I|$  die Intervalllänge bezeichnet.

**Beispiel 1.12** Zu Definition 1.9 txc(Skript 26 - Definition 1.32)

Sei nun  $[a, b] = [0, 10]$ . Die Wahrscheinlichkeit, daß der Ausgang des Zufallsexperiments sehr klein oder sehr groß

ist, sagen wir entweder kleiner als 0.1 oder größer als 9.9 ist, beträgt

$$\mathbb{P}((-\infty, 0.0) \cup (9.9, \infty)) = \int_0^{0.1} f(x) dx + \int_{9.9}^{10} f(x) dx = \frac{1}{10}[0.1 + 0.1] = \frac{2}{100} = \frac{1}{50}$$

**Bemerkung 1.12 Zu Beispiel 1.11** (Skript 26 - Bemerkung 1.33)

Der Wert  $\frac{1}{b-a}$  ergibt sich aus der Normierungsbedingung. Daraus ergibt sich, daß es auf einem nicht beschränkten Intervall keine uniforme Verteilung geben kann. Der Beweis verwendet dieselbe Idee wie jene, die wir in Bemerkung 1.6 benutzt haben.

Wir können die Definition der uniformen Verteilung verallgemeinern.

**Definition 1.10 Uniforme Verteilung auf einer Menge M** (Skript 26 - Definition 1.34)

Sei  $M \subseteq \mathbb{R}$  eine Menge, der wir einen Inhalt  $|M| = \lambda(M)$  zuordnen können. Ist  $|M| < \infty$ , so ist die uniforme Verteilung auf M gegeben durch die Dichte

$$f(x) = \begin{cases} \frac{1}{|M|} & x \in M \\ 0 & \text{sonst} \end{cases}$$

**Bemerkung 1.13** (Skript 26 - Bemerkung 1.35)

Die uniforme Verteilung auf einer beschränkten Menge  $M \subseteq \mathbb{R}$  ist das kontinuierliche Analogon der Gleichverteilung auf einer endlichen Menge. Es gilt

$$\mathbb{P}(A) = \frac{|A \cap M|}{|M|}$$

für alle  $A \subseteq \mathbb{R}$ , für die der Inhalt  $|A|$  definiert ist.

Wartezeiten werden häufig mit Hilfe der Exponentialverteilung modelliert.

**Karteikarte 1.33 Was ist die uniforme Verteilung auf einem Intervall  $I = [a, b]$  (Kontinuumsäquivalent zur Gleichverteilung)?**

Gegeben durch die Dichte  $f(x) = \frac{1}{|I|} = \frac{1}{b-a}$  für  $x \in I$ , sonst 0, wobei  $|I|$  die Intervalllänge ist. Voraussetzung:  $I$  beschränkt,  $-\infty < a < b < \infty$ .

**Karteikarte 1.34 Warum kann es keine uniforme Verteilung auf einem unbeschränkten Intervall geben?**

Der Dichtewert  $\frac{1}{b-a}$  ergibt sich aus der Normierungsbedingung  $\int f(x) dx = 1$ . Bei unbeschränktem Intervall würde dies (analog zum Beweis, dass es keine Gleichverteilung auf unendlichen Mengen gibt) zu einem Widerspruch führen — daher ist eine uniforme Verteilung nur auf beschränkten Intervallen definierbar..

**Karteikarte 1.35 Wie verallgemeinert man die uniforme Verteilung von Intervallen auf beliebige Mengen  $M \subseteq \mathbb{R}$ ?**

Sei  $M \subseteq \mathbb{R}$  eine Menge mit Inhalt  $|M| = \lambda(M) < \infty$ . Die uniforme Verteilung auf  $M$  ist gegeben durch  $f(x) = \frac{1}{|M|}$  für  $x \in M$ , sonst 0..

**Karteikarte 1.36 Wie berechnet man bei uniformer Verteilung auf  $M$  die Wahrscheinlichkeit eines beliebigen Ereignisses  $A$ ?**

$P(A) = \frac{|A \cap M|}{|M|}$  für alle  $A \subseteq \mathbb{R}$ , für die der Inhalt  $|A|$  definiert ist. Dies ist das kontinuierliche Analogon zur

Gleichverteilung auf einer endlichen Menge ( $P(A) = \frac{\#A}{\#\Omega}$ )..

### 1.3.4 | Exponentialverteilung

**Definition 1.11 Exponentialverteilung** (2025, Skript 26 - Definition 1.36)

Die Exponentialverteilung zum Parameter  $\alpha > 0$  ist gegeben durch die Dichte

$$f(x) = \begin{cases} 0 & \text{für } x < 0 \\ \alpha e^{-\alpha x} & \text{für } x \geq 0 \end{cases} \quad (1.1)$$

**Bemerkung 1.14 Zu Definition 1.11 - Die Exponentialverteilung ist wohldefiniert** (2025, Skript 26 - Lemma 1.37)

Gleichung 1.1 ist eine Dichte :

■  $f \geq 0$

■  $f$  R-integrierbar, da stückweise stetig

$$\begin{aligned} g(x) &= e^{-\alpha x} \\ g'(x) &= (-\alpha)e^{-\alpha x} \quad (\text{Produktregel}) \end{aligned}$$

Die folgende Rechnung zeigt sowohl die Existenz des uneigentlichen Riemann- Integrals über  $\mathbb{R}$  als auch, daß die Normierungsbedingung erfüllt ist.

$$\begin{aligned} \int_{-\infty}^{\infty} f(x) dx &= \int_0^{\infty} f(x) dx \\ &= \int_0^{\infty} \alpha e^{-\alpha x} dx \\ &= \lim_{N \rightarrow \infty} \int_0^N \alpha e^{-\alpha x} dx \\ &= \lim_{N \rightarrow \infty} [-e^{-\alpha x} \Big|_{x=0}^N] \\ &= \lim_{N \rightarrow \infty} [-e^{-\alpha N} - \underbrace{(-e^{-\alpha \cdot 0})}_{=1}] \\ &= 1 - \underbrace{\lim_{N \rightarrow \infty} e^{-\alpha N}}_{=1} \\ &= 1 \end{aligned}$$

## Rechnen mit Wahrscheinlichkeiten (V02)

Vorlesung 25.04.2025 (V02 2025), ergänzt durch Skript 2026 für Vorlesung 24.04.2026 (V02 2026)

### Lernziele

- Unterschied zwischen disjunkten und paarweise disjunkten Mengen kennen
- Rechenregeln für Wahrscheinlichkeiten anwenden und beweisen können, insbesondere
  - Komplementärwahrscheinlichkeit (“Gegenwahrscheinlichkeit”)
  - Ein-und-Ausschlußprinzip
  - Spezialfall: Wahrscheinlichkeit der Vereinigung paarweise disjunkter Mengen

### 2.1 | Mengenoperationen und Ereignisse

#### **Definition 2.1** Komplement von Mengen (Skript 2026 - Definition 2.1)

Gilt  $A \subseteq \Omega$ , so schreiben wir  $A^c$  für das Komplement von  $A$  in  $\Omega$ , das heißt, wir setzen

$$A^c = \Omega \setminus A$$

#### **Bemerkung 2.1** Zu Definition 2.1 (Skript 2026 - Definition 2.1)



Diese Notation ist mit Vorsicht anzuwenden, da sie voraussetzt, dass klar ist, auf welche Referenz- Obermenge  $\Omega$  wir uns beziehen.

#### **Definition 2.2** Vereinigung/Schnitt abzählbar vieler Mengen (2025, Skript 2026 - Definition 2.2)


$I \subseteq \mathbb{N}$  Indexmenge.

Für jedes  $i \in I$  sei  $A_i \subseteq \Omega$ :

- $A_i \in \mathcal{R}(\Omega)$  für  $\Omega$  abzählbar
  - $A_i$  ein Intervall für  $\Omega = \mathbb{R}$  (oder  $\Omega = [0, \infty)$  oder  $\Omega = [a, b]$ )
- (a)  $\bigcup_{i \in I} A_i = \{\omega \in \Omega : \omega \in A_i \text{ für mind. ein } i \in I\} = \{\omega \in \Omega : \exists j \in I \text{ mit } \omega \in A_j\}$
- (b)  $\bigcap_{i \in I} A_i = \{\omega \in \Omega : \omega \in A_i \text{ für alle } i \in I\} = \{\omega \in \Omega : \omega \in A_i \forall j \in I\}$


**Lemma 2.1** Rechenregeln für Mengen und Ereignisse (2025, Skript 26 - Lemma 2.3)Seien  $A, B, C \subset \Omega$ .(a) Transitivität:  $A \subset B, B \subset C \Rightarrow A \subset C$ (b) Distributivgesetz:  $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$  und  $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$ 

- Kommutativitätsgesetz:  $A \cup B = B \cup A$  und  $A \cap B = B \cap A$
- Assoziativgesetz:  $(A \cup B) \cup C = A \cup (B \cup C)$  und  $(A \cap B) \cap C = A \cap (B \cap C)$
- de Morgansche Regeln:  $(A \cup B)^c = A^c \cap B^c$  und  $(A \cap B)^c = A^c \cup B^c$

**Beweis.** Skript 26 Seite 20**Karteikarte 2.1** Wie ist das Komplement  $A^c$  einer Menge  $A \subseteq \Omega$  definiert? $A^c := \Omega \setminus A$ . Achtung: Diese Notation setzt voraus, dass klar ist, auf welche Referenz-Obermenge  $\Omega$  man sich bezieht..**Karteikarte 2.2** Wie sind Vereinigung und Schnitt abzählbar vieler Mengen  $A_i, i \in I$ , definiert? $\bigcup_{i \in I} A_i = \{\omega \in \Omega : \exists j \in I \text{ mit } \omega \in A_j\}$  (mind. ein  $A_i$  enthält  $\omega$ ).  $\bigcap_{i \in I} A_i = \{\omega \in \Omega : \omega \in A_i \forall i \in I\}$  (alle  $A_i$  enthalten  $\omega$ )..**Karteikarte 2.3** Welche drei Rechenregeln für Mengen/Ereignisse kennst du (Kommutativ-, Assoziativ-, de Morgan)?Kommutativität:  $A \cup B = B \cup A, A \cap B = B \cap A$ . Assoziativität:  $(A \cup B) \cup C = A \cup (B \cup C)$ , analog für  $\cap$ . De Morgan:  $(A \cup B)^c = A^c \cap B^c$  und  $(A \cap B)^c = A^c \cup B^c$ ..**2.1.1 | Disjunktheit****Definition 2.3**  $A, B, A_1, A_2, \dots \subset \Omega$  (2025)(a)  $A$  und  $B$  heißen disjunkt, wenn  $A \cap B = \emptyset$ **Abbildung 2.2:** Disunkte Mengen.


Sei  $I$  eine beliebige Indexmenge. Für jedes  $i \in I$  sei eine Menge  $A_i \subseteq \Omega$  gegeben.

(b)  $A_1, A_2, \dots$  heißen disjunkt, wenn  $\bigcap_i A_i = \emptyset$  (Alle Mengen liegen getrennt voneinander)



**Abbildung 2.3:** Disjunkte Mengen.

(c)  $A_1, A_2, \dots$  heißen paarweise disjunkt, wenn  $A_i \cap A_j = \emptyset \quad \forall i, j \text{ mit } i \neq j$



**Abbildung 2.4:** Disjunkte Mengenfamilie; paarweise disjunkte Mengen.

(d) Sind  $A_1, A_2, \dots$  paarweis disjunkt, so schreiben wir  $\dot{\bigcup}_i A_i$  für die Vereinigung  $\bigcup_i A_i$ .

■ Wir sprechen von einer disjunkten Vereinigung

**Bemerkung 2.2** (2025)

paarweise disjunkt  $\Rightarrow$  disjunkt

$$\bigcup_i A_i \subset A_1 \cap A_2 = \emptyset$$

**Beispiel 2.1** Disjunkte und paarweise disjunkte Mengen beim Würfeln (Skript 26 - Beispiel 2.5)

Sei  $\Omega = \{1, \dots, 6\}$

- Setze  $A = \{2, 4, 6\}$ ,  $B = \{3, 6\}$  und  $C = \{1\}$ . Dann ist  $A \cap B = \{6\} \neq \emptyset$ , also sind A und B nicht disjunkt, während  $A \cap C = \emptyset$  impliziert, daß A und C disjunkt sind.
- Seien  $A_1 = \{1, 3\}$ ,  $A_2 = \{3, 5\}$  und  $A_3 = \{1, 5\}$ . Dann sind  $A_1, A_2$  und  $A_3$  disjunkt, aber nicht paarweise disjunkt, weil  $A_1 \cap A_2 \cap A_3 = \emptyset$ , aber  $A_1 \cap A_2 = \{3\} \neq \emptyset$ .

**Lemma 2.2** Relation zwischen den Konzepten “disjunkt” und “paarweise disjunkt” (Skript 26 - Lemma 2.6)

Sei  $I$  eine beliebige Indexmenge. Für jedes  $i \in I$  sei eine Menge  $A_i \subseteq \Omega$  gegeben.

1. paarweise disjunkt  $\Rightarrow$  disjunkt:

$$A_i \cap A_j = \emptyset \quad \forall i, j \in I \text{ mit } i \neq j \Rightarrow \bigcap_{i \in I} A_i = \emptyset$$

**2.** disjunkt  $\nRightarrow$  paarweise disjunkt.

Es gibt Beispiele von disjunkten Mengen, die nicht paarweise disjunkt sind.

**Beweis.** Skript 26 Seite 22

**Beispiel 2.2** Disjunkte und paarweise disjunkte Mengen (Skript 26 - Beispiel 2.7) Wir wählen

$$\begin{aligned} A_1 &= \{1, 2, 3, 4, \dots\}, \\ A_2 &= \{2, 3, 4, \dots\}, \\ A_3 &= \{3, 4, \dots\}, \\ &\vdots \\ A_k &= \{k, k+1, \dots\} = \{j \in \mathbb{N} : j \geq k\}. \end{aligned}$$

Die Mengen  $A_i$ ,  $i \in \mathbb{N}$ , sind *nicht paarweise disjunkt*:

Für jede Wahl von  $i, j \in \mathbb{N}$  mit  $i < j$  gilt

$$A_i \cap A_j = A_j \neq \emptyset.$$

Dennoch sind die Mengen  $A_i$ ,  $i \in \mathbb{N}$  *disjunkt*

$$\bigcap_{i \in \mathbb{N}} A_i = \emptyset.$$

Zum Beweis nehmen wir an, es gäbe ein  $\ell \in \mathbb{N}$  mit

$$\ell \in \bigcap_{i \in \mathbb{N}} A_i.$$

Dann müsste  $\ell \in A_i$  für alle  $i \in \mathbb{N}$  gelten. Insbesondere müsste

$$\ell \in A_{\ell+1} = \{\ell+1, \ell+2, \dots\}$$

sein. Dies ist jedoch unmöglich. Also existiert kein solches  $\ell$ , und damit folgt

$$\bigcap_{i \in \mathbb{N}} A_i = \emptyset.$$

**Karteikarte 2.4** Wann heißen zwei Mengen  $A, B$  disjunkt?

Wenn  $A \cap B = \emptyset$  gilt..

**Karteikarte 2.5** Wann heißt eine Familie  $A_1, A_2, \dots$  (allgemein  $A_i, i \in I$ ) disjunkt?

Wenn der Gesamtschnitt aller Mengen leer ist:  $\bigcap_i A_i = \emptyset$ . (Es reicht, dass es keinen gemeinsamen Punkt in ALLEN Mengen gibt — einzelne Paare können sich trotzdem überschneiden!).

**Karteikarte 2.6** Wann heißt eine Familie  $A_1, A_2, \dots$  paarweise disjunkt?

Wenn  $A_i \cap A_j = \emptyset$  für alle  $i \neq j$  gilt (jedes Paar einzeln betrachtet ist disjunkt). Achtung: In der Quelldefinition steht fälschlich  $\neq \emptyset$ , korrekt ist aber  $= \emptyset$  für paarweise Disjunktheit..

**Karteikarte 2.7** Welche Notation verwendet man für die Vereinigung paarweise disjunkter Mengen?

$\dot{\bigcup}_i A_i$  statt  $\bigcup_i A_i$ , wenn die  $A_i$  paarweise disjunkt sind. Man spricht von einer disjunkten Vereinigung..



**Karteikarte 2.8** Folgt aus paarweiser Disjunktheit die (einfache) Disjunktheit einer Mengenfamilie?

Ja: paarweise disjunkt  $\Rightarrow$  disjunkt, denn  $\bigcap_i A_i \subseteq A_1 \cap A_2 = \emptyset$ .

**Karteikarte 2.9** Beispiel: Sind  $A = \{2, 4, 6\}$ ,  $B = \{3, 6\}$ ,  $C = \{1\}$  beim Würfeln disjunkt?

$A \cap B = \{6\} \neq \emptyset \Rightarrow A, B$  NICHT disjunkt.  $A \cap C = \emptyset \Rightarrow A, C$  disjunkt. Zweites Beispiel:  $A_1 = \{1, 3\}$ ,  $A_2 = \{3, 5\}$ ,  $A_3 = \{1, 5\}$  sind disjunkt ( $A_1 \cap A_2 \cap A_3 = \emptyset$ ), aber NICHT paarweise disjunkt (da z.B.  $A_1 \cap A_2 = \{3\} \neq \emptyset$ ).

**Karteikarte 2.10** Gilt auch die Umkehrung: disjunkt  $\Rightarrow$  paarweise disjunkt?

Nein. Disjunkt impliziert NICHT paarweise disjunkt — es gibt Gegenbeispiele (siehe  $A_k = \{k, k+1, \dots\}$ : die Mengen sind disjunkt, aber keine zwei von ihnen sind paarweise disjunkt, da  $A_i \cap A_j = A_j \neq \emptyset$  für  $i < j$ ).

**Karteikarte 2.11** Beispiel: Warum sind  $A_k = \{k, k+1, k+2, \dots\}$  für  $k \in \mathbb{N}$  disjunkt, aber nicht paarweise disjunkt?

Nicht paarweise disjunkt: Für  $i < j$  gilt  $A_i \cap A_j = A_j \neq \emptyset$ . Aber disjunkt:  $\bigcap_{i \in \mathbb{N}} A_i = \emptyset$ , denn gäbe es ein  $\ell$  im Gesamtschnitt, müsste  $\ell \in A_{\ell+1} = \{\ell+1, \ell+2, \dots\}$  gelten — unmöglich, da  $\ell < \ell+1$ .

## 2.2 | Erste Rechenregeln für Wahrscheinlichkeiten

**Satz 2.1** (2025)

Seien  $A, B, A_1, A_2, \dots \subset \Omega$  (und Intervalle, falls  $\mathbb{P}$  durch Dichte gegeben ist)

(a) Additivität: Seien  $A_1, A_2, \dots$  paarweise disjunkt, dann gilt:

$$\mathbb{P}(\dot{\bigcup}_i A_i) = \sum_i \mathbb{P}(A_i)$$

Gilt auch für Dichten!

**Beweis.**

$$\begin{aligned} \mathbb{P}(\dot{\bigcup}_i A_i) &= \mathbb{P}(\{\omega \in \Omega : \exists i \text{ mit } \omega \in A_i\}) \\ &= \sum_i \underbrace{\sum_{\omega \in A_i} \mu(\omega)}_{\mathbb{P}(A_i)} \\ &= \sum_i \mathbb{P}(A_i) \end{aligned}$$

Wir haben die Summe/Reihe umsortiert

(b) Komplementärwahrscheinlichkeit (“Gegenwahrscheinlichkeit”)

$$\mathbb{P}(A^c) = \mathbb{P}(\Omega \setminus A) = 1 - \mathbb{P}(A)$$

**Beweis.**

$$\begin{aligned} \Omega = A \dot{\cup} A^c &\stackrel{(a)}{\Rightarrow} 1 \stackrel{\text{Normierung}}{=} \mathbb{P}(\Omega) = \mathbb{P}(A \dot{\cup} A^c) \stackrel{(a)}{=} \mathbb{P}(A) + \mathbb{P}(A^c) \\ &\Rightarrow \mathbb{P}(A^c) = 1 - \mathbb{P}(A) \end{aligned}$$

(c) Monotonie:

$$A \subset B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$$

**Beweis**

$$\begin{aligned} B &= A \dot{\cup} (B \setminus A) \\ \mathbb{P}(B) &= \mathbb{P}(A) + \underbrace{\mathbb{P}(B \setminus A)}_{\geq 0} \geq \mathbb{P}(A) \end{aligned}$$

(d)  $A \subset B \Rightarrow \mathbb{P}(A) = \mathbb{P}(B) - \mathbb{P}(B \setminus A)$ 

(e) Wahrscheinlichkeit von Vereinigungen:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$$

**Beweis.**

$$\begin{aligned} A \cup B &= A \dot{\cup} [B \setminus (A \cap B)] \\ \mathbb{P}(A \cup B) &= \mathbb{P}(A) + \underbrace{\mathbb{P}(B \setminus (A \cap B))}_{\stackrel{(d)}{=} \mathbb{P}(B) - \mathbb{P}(A \cap B)} \\ &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \end{aligned}$$

Weitere Beweise Skript 2026 ab Seite 23.

**Bemerkung 2.3** (2025)Sind  $A, B$  disjunkt, so gilt nach (a):  $\mathbb{P}(A \dot{\cup} B) = \mathbb{P}(A) + \mathbb{P}(B)$ .Sind  $A, B$  nicht disjunkt, so gilt nach (e):  $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$ .Sind  $A, B, C$  paarweise disjunkt, so gilt nach (a):  $\mathbb{P}(A \cup B \cup C) \stackrel{(a)}{=} \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C)$ .Was passiert, wenn  $A, B, C$  nicht paarweise disjunkt sind?

$$\begin{aligned} \mathbb{P}(A \cup B \cup C) &= \mathbb{P}(A \cup (B \cup C)) \\ &= \mathbb{P}(A) \mathbb{P}(B \cup C) - \mathbb{P}(A \cap (B \cup C)) \\ &= \mathbb{P}(A) + [\mathbb{P}(B) + \mathbb{P}(C) - \mathbb{P}(B \cap C)] - \mathbb{P}((A \cap B) \cup (A \cap C)) \\ &= \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) \\ &\quad - \mathbb{P}(A \cap B) - \mathbb{P}(A \cap C) - \mathbb{P}(B \cap C) \\ &\quad + \underbrace{\mathbb{P}((A \cap B) \cap (A \cap C))}_{= A \cap B \cap C} \end{aligned}$$

Mengen

Paare von Mengen

Tripel von Mengen

**Karteikarte 2.12** Additivität von  $P$ : Wie berechnet man  $P$  einer disjunkten Vereinigung  $\bigcup_i A_i$ ?

$P\left(\bigcup_i A_i\right) = \sum_i P(A_i)$ , für paarweise disjunkte  $A_1, A_2, \dots$ . Gilt auch bei durch Dichten gegebenem  $P$ . Beweis: Umsortieren der Doppelsumme  $\sum_i \sum_{\omega \in A_i} \mu(\omega) = \sum_i P(A_i)$ .

**Karteikarte 2.13** Wie lautet die Formel für die Komplementärwahrscheinlichkeit (Gegenwahrscheinlichkeit)?

$P(A^c) = P(\Omega \setminus A) = 1 - P(A)$ . Beweis:  $\Omega = A \dot{\cup} A^c \Rightarrow 1 = P(\Omega) = P(A) + P(A^c) \Rightarrow P(A^c) = 1 - P(A)$  (folgt aus

Additivität)..

**Karteikarte 2.14** Monotonie von  $P$ : Was folgt aus  $A \subseteq B$  für  $P(A)$  und  $P(B)$ ?

$A \subseteq B \Rightarrow P(A) \leq P(B)$ . Beweis:  $B = A \dot{\cup} (B \setminus A) \Rightarrow P(B) = P(A) + \underbrace{P(B \setminus A)}_{\geq 0} \geq P(A)$ ..

**Karteikarte 2.15** Wie berechnet man  $P(A)$ , wenn  $A \subseteq B$  bekannt ist (Formel mit  $B \setminus A$ )?

$A \subseteq B \Rightarrow P(A) = P(B) - P(B \setminus A)$ ..

**Karteikarte 2.16** Wie lautet die Formel für  $P(A \cup B)$  bei nicht notwendig disjunkten  $A, B$ ?

$P(A \cup B) = P(A) + P(B) - P(A \cap B)$ . Beweis:  $A \cup B = A \dot{\cup} [B \setminus (A \cap B)]$ , dann Additivität und  $P(B \setminus (A \cap B)) = P(B) - P(A \cap B)$  einsetzen..

**Karteikarte 2.17** Wie berechnet man  $P(A \cup B)$  bzw.  $P(A \cup B \cup C)$  je nachdem ob die Mengen (paarweise) disjunkt sind?

$A, B$  disjunkt:  $P(A \dot{\cup} B) = P(A) + P(B)$ .  $A, B$  nicht disjunkt:  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ .  $A, B, C$  paarweise disjunkt:  $P(A \cup B \cup C) = P(A) + P(B) + P(C)$ . Allgemein (nicht paarweise disjunkt): siehe Ein- und Ausschlussprinzip für drei Ereignisse..

### 2.2.1 | Das Ein- und Ausschlußprinzip

**Satz 2.2** Ein- und Ausschlußprinzip für drei Ereignisse (Skript 26 - Lemma 2.9)

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) && \text{(Mengen)} \\ &\quad - P(A \cap B) - P(A \cap C) - P(B \cap C) && \text{(Paare von Mengen)} \\ &\quad + P(A \cap B \cap C) && \text{(Tripel von Mengen)} \end{aligned}$$

Beweis.

$$\begin{aligned} P(A \cup B \cup C) &= P((A \cup B) \cup C) \\ &= P(A \cup B) + P(C) - P((A \cup B) \cap C) \\ &= P(A \cup B) + P(C) - P((A \cap C) \cup (B \cap C)) \\ &= P(A) + P(B) - P(A \cap B) + P(C) \\ &\quad - \left[ P(A \cap C) + P(B \cap C) - P((A \cap C) \cap (B \cap C)) \right] \\ &= P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) \\ &\quad - P(B \cap C) + P(A \cap B \cap C). \end{aligned}$$

**Satz 2.3** Ein- und Ausschlußprinzip für  $n$  Ereignisse (2025, Skript 26 - Theorem 2.10)

$$\begin{aligned} &A_2, \dots, A_n \subset \Omega \\ \mathbb{P} \left( \bigcup_{i=1}^n A_i \right) &= \sum_{k=1}^n (-1)^{k+1} \sum_{a \leq i_1 \leq \dots \leq i_k \leq n} \mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}) \end{aligned}$$

**Beweis.** Die Fälle  $n = 2$  und  $n = 3$  haben wir bereits behandelt. Der Beweis für beliebiges  $n$  kann mit Hilfe vollständiger Induktion geführt werden.

**Beispiel 2.3** Werfen einer Sechs bei  $n$ -maligem Würfeln (Skript 26 - Beispiel 2.11)

Wie groß ist die Wahrscheinlichkeit, bei  $n$ -maligem Würfeln mit einem fairen Würfel mindestens eine Sechs zu werfen?

Siehe Skript 2026 Seite 25

**Karteikarte 2.18** Wie lautet das Ein- und Ausschlussprinzip für drei Ereignisse  $A, B, C$ ?

$$P(A \cup B \cup C) = \underbrace{P(A) + P(B) + P(C)}_{\text{Mengen}} - \underbrace{P(A \cap B) - P(A \cap C) - P(B \cap C)}_{\text{Paare}} + \underbrace{P(A \cap B \cap C)}_{\text{Tripel}}..$$

**Karteikarte 2.19** Wie lautet das allgemeine Ein- und Ausschlussprinzip für  $n$  Ereignisse?

$P(\bigcup_{i=1}^n A_i) = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < \dots < i_k \leq n} P(A_{i_1} \cap \dots \cap A_{i_k})$ . Man summiert über alle möglichen Schnitte von  $k$  Mengen (mit alternierendem Vorzeichen), für  $k = 1, \dots, n$ . Beweis für allgemeines  $n$ : vollständige Induktion (Fälle  $n = 2, 3$  als Basis)..

# KAPITEL 3

## Bedingte Wahrscheinlichkeiten (V03 2025; V06 2026)

Vorlesung 02.05.2025 (V03 2025) und Vorlauf Kapitel 6 am 22.05.2026 (V05 2026) und 29 Mai 2026 (V06 2026)

### Lernziele

- Definition und Bedeutung bedingter Wahrscheinlichkeiten kennen
- Modellieren von Zufallsexperimenten, wenn diese durch bedingte Wahrscheinlichkeiten beschrieben sind
- Satz von der totalen Wahrscheinlichkeit kennen und anwenden können
- Bayes-Formel kennen und anwenden können

**Kommentar 3.1** Warnung von ihr: Bei Aufgaben zur bedingten WS kommt es sehr auf die Sprache an.

Zusammenhang mit der Unabhängigkeit? Zwei Ereignisse A,B sind unabh. genau dann, wenn die WS der Schnitt auch das Produkt der einzelnen WS ist usw. ( siehe Anschnitt aus alten Aufzeichnungen)...

### Beispiel 3.1 Einmaliges Würfeln (2025+2026 zsm.)

Wie wahrscheinlich ist es, daß eine 1 oder eine 6 gewürfelt wurde? Einmaliges Würfeln

Wie wahrscheinlich ist es, dass eine 1 oder eine 6 gewürfelt wurde?

$|\Omega| = \{1, \dots, 6\}$ ,  $\mathbb{P}$  Gleichverteilung,  $A = \{1, 6\}$ ,  $\mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{2}{6} = \frac{1}{3}$

Wie wahrscheinlich ist es, dass eine 1 oder eine 6 gewürfelt wurde, wenn wir schon wissen, dass die geworfene Zahl durch 3 teilbar ist?

Was ist “ $\mathbb{P}$  von A, gegeben B”  $\mathbb{P}(A | B)$  mit  $B = \{3, 6\}$ ?

Wahrscheinlichkeit von A:

$$\mathbb{P}(A) = \frac{\text{Anz. günstige Ausgänge}}{\text{Anz. mögliche Ausgänge}} = \frac{|A|}{|\Omega|}$$

Wahrscheinlichkeit von A gegeben B:

$$\mathbb{P}(A | B) = \frac{\text{Anz. günstige Ausgänge in } A \cap B}{\text{Anz. mögliche Ausgänge in } B} = \frac{|A \cap B|}{|B|} = \frac{|\{6\}|}{|\{3, 6\}|} = \frac{1}{2}$$

### Notation 3.1 (2025+2026 zsm.)

$|A| = \#A$

### Definition 3.1 Bedingte Wahrscheinlichkeit (B-WS) (2025+2026 zsm.)

Für Ereignisse A und B heißt

$$\mathbb{P}(A \mid B) = \begin{cases} \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, & \text{falls } \mathbb{P}(B) > 0, \\ 0, & \text{falls } \mathbb{P}(B) = 0, \end{cases}$$

die bedingte Wahrscheinlichkeit von A gegeben B.

**Kommentar 3.2** Zu Definition 3.1: Wenn  $\mathbb{P}$  durch eine Dichte gegeben ist, muss man die Definition über Integrale interpretieren.

**Beobachtung 3.1** (2025+2026 zsm.)

Bei Gleichverteilung gilt

$$\mathbb{P}(A \mid B) = \frac{\frac{\#|A \cap B|}{\#|\Omega|}}{\frac{\#|B|}{\#|\Omega|}} = \frac{|A \cap B|}{|B|}$$

D.h., die bedingte Wahrscheinlichkeit von A gegeben B ist tatsächlich der relative Anteil von A in B.

**Frage 3.1** (2025+2026 zsm.)

In obigem Beispiel gilt  $\mathbb{P}(A \mid B) > \mathbb{P}(A)$ . Gilt das immer?

**Antwort** Nein! Sowohl  $\mathbb{P}(A_1 \mid B_1) > \mathbb{P}(A_1)$  als auch  $\mathbb{P}(A_2 \mid B_2) < \mathbb{P}(A_2)$  sind möglich.

**Beispiel 3.2** (2025+2026 zsm.)

$\Omega = \{1, \dots, 6\}$  mit Gleichverteilung  $\mathbb{P}$

$$A_1 = \{1, 6\}, \quad A_2 = \{1, 2, 3, 4\}, \quad B = B_1 = B_2 = \{3, 6\}$$

Dann gelten

$$\mathbb{P}(A_1 \mid B) = \frac{|A_1 \cap B|}{|B|} = \frac{1}{2} > \frac{1}{3} = \mathbb{P}(A_1)$$

$$\mathbb{P}(A_2 \mid B) = \frac{|A_2 \cap B|}{|B|} = \frac{1}{2} < \frac{2}{3} = \mathbb{P}(A_2)$$

**Beispiel 3.3** Beispiel: Zweifacher Wurf einer fairen Münze (2025+2026 zsm.)

$\Omega = \{KK, KZ, ZK, ZZ\}$  mit Gleichverteilung  $\mathbb{P}$

Jemand wirft die Münze zweimal und sagt uns nur, dass dabei mindestens einmal Zahl gefallen ist.

Wie groß ist die Wahrscheinlichkeit, dass zweimal Zahl gefallen ist?

**Antwort:**  $A = \{ZZ\}$ ,  $B = \{KZ, ZK, ZZ\}$

$$\mathbb{P}(A \mid B) = \frac{|A \cap B|}{|B|} = \frac{1}{3}$$

**Frage 3.2** (2025+2026 zsm.)

Jemand wirft die Münze zweimal und sagt uns nur, dass beim ersten Wurf Zahl gefallen ist.

Wie groß ist die Wahrscheinlichkeit, dass zweimal Zahl gefallen ist?

$$A = \{ZZ\}, \quad C = \{ZK, ZZ\}$$

$$\mathbb{P}(A \mid C) = \frac{|A \cap C|}{|C|} = \frac{1}{2}$$

**Regel 3.1 Rechenregeln für bedingte Wahrscheinlichkeiten** (diskreter Fall - analog für Fall einer Dichte) (2025+2026 zsm.)

Für ein festes Ereignis  $B$  mit  $\mathbb{P}(B) > 0$  definiert

$$\mu_B(\omega) = \mathbb{P}(\{\omega\} \mid B) = \begin{cases} \frac{\mathbb{P}(\{\omega\})}{\mathbb{P}(B)} = \frac{\mu(\{\omega\})}{\mathbb{P}(B)}, & \text{falls } \omega \in B, \\ 0, & \text{falls } \omega \notin B, \end{cases}$$

eine Wahrscheinlichkeitsfunktion, und es gilt

$$\sum_{\omega \in A} \mu_B(\omega) = \frac{1}{\mathbb{P}(B)} = \sum_{\omega \in A \cap B} \mu(\omega) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \mathbb{P}(A \mid B)$$

für alle  $A \subseteq \Omega$ .

Die Abbildung  $A \mapsto \mathbb{P}(A \mid B)$  ist also ein Wahrscheinlichkeitsmaß.

Es gelten also alle bekannten Rechenregeln für Wahrscheinlichkeiten, z.B.

$$\mathbb{P}(A^c \mid B) = 1 - \mathbb{P}(A \mid B)$$

oder

$$\mathbb{P}(A_1 \cup^+ A_2 \mid B) = \mathbb{P}(A_1 \mid B) + \mathbb{P}(A_2 \mid B)$$

(Achtung: nur für disjunkte Ereignisse.)

Achtung! Die Abbildung  $B \mapsto \mathbb{P}(A \mid B)$  ist kein Wahrscheinlichkeitsmaß!

(Beweisen Sie dies selbständig, indem Sie z.B. Beispiele finden mit  $\mathbb{P}(A \mid B) \neq 1 - \mathbb{P}(A \mid B^c)$  oder  $\mathbb{P}(A \mid B_1 \cup B_2) \neq \mathbb{P}(A \mid B_1) + \mathbb{P}(A \mid B_2)$ .)

**Beispiel 3.4 Gedächtnislosigkeit der Exponentialverteilung** (2025+2026 zsm.)

Parameter  $z > 0$ ; Dichte :

$$f(x) = \begin{cases} ze^{-zx}, & x \geq 0 \\ 0, & \text{sonst} \end{cases}$$

$$\mathbb{P}(I) = \int_a^b f(x) dx \text{ für } I = (a, b] \subset [0, \infty)$$

Warteschleife beim Kundenservice als Exponentialverteilung

- Sie haben schon 10 Min gewartet ( $t = 10$ )
- **WS**, dass Sie noch **mindestens** weitere 10 Minuten warten?  
( $T = t + 10 = 20$ )

Gesucht:  $\mathbb{P}([T, a] \mid [t, \infty))$

$$\mathbb{P}([T, a] \mid [t, \infty)) = \frac{\mathbb{P}([T, a]) \cap \mathbb{P}([t, \infty))}{\mathbb{P}([t, \infty))} = \frac{\mathbb{P}([T, \infty))}{\mathbb{P}([t, \infty))}$$

Nebenrechnung:

$$\begin{aligned}
 \mathbb{P}([\tau, \infty)) &= \int_{\tau}^{\infty} z e^{-zx} dx \\
 &= \lim_{N \rightarrow \infty} \int_{\tau}^{\infty} z e^{-zx} dx \\
 &= \lim_{N \rightarrow \infty} (-e^{-zx}) \Big|_{x=\tau}^N \\
 &= \lim_{N \rightarrow \infty} [\underbrace{-e^{-zN}}_{\rightarrow_{N \rightarrow \infty} 0} + e^{-z\tau}] \\
 &= e^{-z\tau}
 \end{aligned}$$

Zurück zur Hauptrechnung:

$$\begin{aligned}
 \mathbb{P}([T, a] | [t, \infty)) &= \frac{\mathbb{P}([T, \infty))}{\mathbb{P}([t, \infty))} \\
 &\stackrel{NR}{=} \frac{e^{-zT}}{e^{-zt}} \\
 &= e^{-z(T-t)} \\
 &\stackrel{T=10+t}{=} e^{-zt} \\
 &\stackrel{NR}{=} \mathbb{P}([t, \infty))
 \end{aligned}$$

### Regel 3.2 Neue Rechenregel: Sukzessives Bedingen (2025+2026 zsm.)

Aus der Definition der bedingten Wahrscheinlichkeit folgt

$$\mathbb{P}(A \cap B) = \mathbb{P}(A | B) \mathbb{P}(B) \quad \forall A, B \subseteq \Omega.$$

Da Multiplikation mit Null wieder Null ergibt, gilt diese Formel auch im Fall  $\mathbb{P}(B) = 0$ .

$$\mathbb{P}(B) = 0 \Rightarrow \mathbb{P}(A \cap B) \leq \mathbb{P}(B) = 0 \Rightarrow \mathbb{P}(A \cap B) = 0$$

Wiederholtes Anwenden zeigt

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_3 | A_1 \cap A_2) \mathbb{P}(A_1 \cap A_2)$$

und damit

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_3 | A_1 \cap A_2) \mathbb{P}(A_2 | A_1) \mathbb{P}(A_1)$$

für alle  $A_1, A_2, A_3 \subseteq \Omega$ .

Mit vollständiger Induktion beweist man die allgemeine Formel

$$\mathbb{P}(A_1 \cap A_2 \cap \dots \cap A_n) = \mathbb{P}(A_n | A_1 \cap \dots \cap A_{n-1}) \dots \mathbb{P}(A_2 | A_1) \mathbb{P}(A_1)$$

für alle  $A_1, \dots, A_n \subseteq \Omega$ .

### Beispiel 3.5 Wie wahrscheinlich ist es, dass beim Skat jeder der drei Spieler genau ein As hat? (2025+2026 zsm.)



## Modell

$$\Omega = \left\{ (S_1, S_2, S_3) : S_i \subseteq \{1, \dots, 32\}, |S_i| = 10 \forall i \in \{1, 2, 3\}, S_i \cap S_j = \emptyset \text{ für } i \neq j \right\}.$$

$(S_1, S_2, S_3) \in \Omega$  bedeute:

■ Spieler  $i$  erhält die 10 Karten  $S_i$ ,  $i \in \{1, 2, 3\}$ .

■ Die übrigen 2 Karten

$$\{1, \dots, 32\} \setminus (S_1 \cup^+ S_2 \cup^+ S_3)$$

liegen im Skat.

■ Die vier Asse seien die Karten mit den Nummern 1, 2, 3, 4.

■ Gleichverteilung:

$$\mu(\omega) = \frac{1}{|\Omega|} = \frac{1}{\binom{32}{10} \binom{22}{10} \binom{12}{10}} \quad \forall \omega \in \Omega.$$

**Rechnung** Beispiel: Wie wahrscheinlich ist es, dass beim Skat alle genau ein As haben?

$$A_i = \{ |S_i \cap \{1, 2, 3, 4\}| = 1 \}, \quad i = 1, 2, 3$$

(Spieler  $i$  hat genau ein As)

$$A = A_1 \cap A_2 \cap A_3$$

(Jeder Spieler hat genau ein As)

$$\mathbb{P}(A) = \mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_1) \mathbb{P}(A_2 | A_1) \mathbb{P}(A_3 | A_1 \cap A_2) = \mathbb{P}(A_3 | A_1 \cap A_2) \mathbb{P}(A_2 | A_1) \mathbb{P}(A_1)$$

$$\mathbb{P}(A_1) = \frac{|A_1|}{|\Omega|} = \frac{\binom{4}{1} \binom{28}{9} \binom{22}{10} \binom{12}{10}}{\binom{32}{10} \binom{22}{10} \binom{12}{10}} = \frac{\binom{4}{1} \binom{28}{9}}{\binom{32}{10}}$$

$$\mathbb{P}(A_2 | A_1) = \frac{|A_1 \cap A_2|}{|A_1|} = \frac{\binom{4}{1} \binom{28}{9} \binom{3}{1} \binom{19}{9} \binom{12}{10}}{\binom{4}{1} \binom{28}{9} \binom{22}{10} \binom{12}{10}} = \frac{\binom{3}{1} \binom{19}{9}}{\binom{22}{10}}$$

$$\mathbb{P}(A_3 | A_1 \cap A_2) = \frac{|A_1 \cap A_2 \cap A_3|}{|A_1 \cap A_2|} = \dots = \frac{\binom{2}{1} \binom{10}{9}}{\binom{12}{10}}$$

Somit

$$\mathbb{P}(A) = \frac{\binom{4}{1} \binom{28}{9}}{\binom{32}{10}} \cdot \frac{\binom{3}{1} \binom{19}{9}}{\binom{22}{10}} \cdot \frac{\binom{2}{1} \binom{10}{9}}{\binom{12}{10}}$$

$$\mathbb{P}(A) \approx 0.056.$$

## Definition 3.2 Formel von der totalen Wahrscheinlichkeit (2025+2026 zsm.)

Sei  $(\Omega, \mathbb{P})$  ein Wahrscheinlichkeitsraum und (abzählbar viele  $B_i$ )  $B_1, B_2, \dots \subseteq \Omega$  paarweise disjunkte Ereignisse mit

$$\bigcup_i^+ B_i = \Omega.$$

Dann gilt

$$\mathbb{P}(A) = \sum_i \mathbb{P}(A \mid B_i) \mathbb{P}(B_i)$$

für alle Ereignisse  $A \subseteq \Omega$ .

Hinweis:  $B_1, B_2, \dots$  ist eine Partition von  $\Omega$

**Beweis (im einfachsten Fall).** Für

$$\Omega = B_1 \cup^+ B_2, \quad B_1 \cap B_2 = \emptyset$$

(also  $B_1 = B$  und  $B_2 = B^c$ ) gilt

$$A = A \cap (B_1 \cup^+ B_2) = (A \cap B_1) \cup^+ (A \cap B_2).$$

Da die Ereignisse  $A \cap B_1$  und  $A \cap B_2$  disjunkt sind, folgt (über Rechenregeln für Wahrscheinlichkeiten)

$$\mathbb{P}(A) = \mathbb{P}(A \cap B_1) + \mathbb{P}(A \cap B_2) \quad (1)$$

und mit der Definition der bedingten Wahrscheinlichkeit

$$\mathbb{P}(A \cap B_i) = \mathbb{P}(A \mid B_i) \mathbb{P}(B_i), \quad i = 1, 2. \quad (2)$$

Einsetzen von (2) in (1) ergibt

$$\mathbb{P}(A) = \mathbb{P}(A \mid B_1) \mathbb{P}(B_1) + \mathbb{P}(A \mid B_2) \mathbb{P}(B_2).$$

Der allgemeine Fall geht vollkommen analog und verbleibt als Hausaufgabe.

### Beispiel 3.6 Herr Zimmerlich und sein Regenschirm (2025+2026 zsm.)

Herr Zimmerlich hasst es, nass zu werden. Wenn der Wetterbericht Regen ankündigt, nimmt er seinen Schirm mit einer Wahrscheinlichkeit von 90% mit. (Die fehlenden 10% sind seiner Vergesslichkeit geschuldet.)

Auch wenn der Wetterbericht einen trockenen Tag verheißt, nimmt Herr Zimmerlich mit einer Wahrscheinlichkeit von 30% trotzdem seinen Schirm mit.

Dem feuchten Bielefelder Klima gemäß nehmen wir an, dass für 60% aller Tage Regen vorhergesagt wird.

Frage: Wie groß ist die Wahrscheinlichkeit, dass Herr Zimmerlich das Haus ohne Schirm verlässt?

#### Modellierung

$$\Omega = \{r, \bar{r}\} \times \{s, \bar{s}\} = \{(r, s), (\bar{r}, s), (r, \bar{s}), (\bar{r}, \bar{s})\}$$

Dabei sei  $(r, \bar{s})$  das Elementarereignis, dass Regen vorhergesagt wurde und Herr Zimmerlich keinen Schirm mitnimmt, usw.

$$R = \{(r, s), (\bar{r}, s)\} \quad (\text{Regen vorhergesagt})$$

$$S = \{(r, s), (\bar{r}, s)\} \quad (\text{Schirm dabei})$$

$$\mathbb{P}(S \mid R) = \frac{9}{10}, \quad \mathbb{P}(S \mid R^c) = \frac{3}{10}, \quad \mathbb{P}(R) = \frac{6}{10}.$$

**Gesucht:**

$$\mathbb{P}(S^c).$$

**Problem:** Wie können wir diese „absolute“ Wahrscheinlichkeit aus den bedingten Wahrscheinlichkeiten bestimmen?

**Lösung:** Die Formel der totalen Wahrscheinlichkeit mit

$$\Omega = R \cup R^c$$

zeigt:

$$\mathbb{P}(S^c) = \mathbb{P}(S^c \mid R) \mathbb{P}(R) + \mathbb{P}(S^c \mid R^c) \mathbb{P}(R^c).$$

Nach Zurückführen auf die gegebenen Daten und Einsetzen erhalten wir

$$\begin{aligned} \mathbb{P}(S^c) &= [1 - \mathbb{P}(S \mid R)] \mathbb{P}(R) + [1 - \mathbb{P}(S \mid R^c)] [1 - \mathbb{P}(R)] \\ &= \left(1 - \frac{9}{10}\right) \frac{6}{10} + \left(1 - \frac{3}{10}\right) \left(1 - \frac{6}{10}\right) = \frac{34}{100}. \end{aligned}$$

**Satz 3.1 Satz von Bayes (einfache Version)** (2025+2026 zsm.)

Seien  $(\Omega, \mu)$  ein Wahrscheinlichkeitsraum und  $A, B \subseteq \Omega$  Ereignisse mit  $\mathbb{P}(B) > 0$ .

Dann gilt

$$\mathbb{P}(A \mid B) = \mathbb{P}(B \mid A) \cdot \frac{\mathbb{P}(A)}{\mathbb{P}(B)}.$$

**Beweis.** Direkt nach Definition der bedingten Wahrscheinlichkeit gilt

$$\mathbb{P}(A \mid B) \mathbb{P}(B) = \mathbb{P}(A \cap B) = \mathbb{P}(B \mid A) \mathbb{P}(A).$$

Division durch  $\mathbb{P}(B)$  ergibt die gesuchte Formel:

$$\mathbb{P}(A \mid B) = \mathbb{P}(B \mid A) \cdot \frac{\mathbb{P}(A)}{\mathbb{P}(B)}.$$

**Beispiel 3.7** (2025+2026 zsm.)

Neue Frage:

Sie haben den Wetterbericht nicht gehört, aber Sie sehen, dass Herr Zimmerlich seinen Schirm dabei hat.

Wie groß ist die Wahrscheinlichkeit, dass für diesen Tag Regen vorhergesagt wurde?

**Gesucht:**

$$\mathbb{P}(R \mid S).$$

**Problem:** Wie können wir „Bedingungen umkehren“?

**Lösung:** Satz von Bayes / Bayes-Formel.

**Lösung** Nach dem Satz von Bayes (einfache Version) ist

$$\mathbb{P}(R \mid S) = \mathbb{P}(S \mid R) \cdot \frac{\mathbb{P}(R)}{\mathbb{P}(S)}.$$

Da

$$\mathbb{P}(S) = 1 - \mathbb{P}(S^c) = 1 - \frac{34}{100} = \frac{66}{100},$$

folgt

$$\mathbb{P}(R \mid S) = \frac{9}{10} \cdot \frac{\frac{6}{10}}{\frac{66}{100}} = \frac{9}{11}.$$

**Satz 3.2 Satz von Bayes (allgemeine Version)** (2025+2026 zsm.)

Sei  $(\Omega, \mathbb{P})$  ein Wahrscheinlichkeitsraum,  $B_1, B_2, \dots \subseteq \Omega$  Ereignisse mit

$$\bigcup_i^+ B_i = \Omega,$$

und  $A \subseteq \Omega$  ein Ereignis mit  $\mathbb{P}(A) > 0$ .

Dann gilt für jedes  $i$

$$\mathbb{P}(B_i \mid A) = \frac{\mathbb{P}(A \mid B_i) \mathbb{P}(B_i)}{\underbrace{\sum_j \mathbb{P}(A \mid B_j) \mathbb{P}(B_j)}_{\stackrel{*}{=} \mathbb{P}(A)}}.$$

\* Satz der totalen WS

**Beweis.** Kombiniere die einfache Version des Satzes von Bayes

$$\mathbb{P}(B_i \mid A) = \mathbb{P}(A \mid B_i) \frac{\mathbb{P}(B_i)}{\mathbb{P}(A)}$$

mit der Formel von der totalen Wahrscheinlichkeit

$$\mathbb{P}(A) = \sum_j \mathbb{P}(A \mid B_j) \mathbb{P}(B_j).$$

Einsetzen von  $\mathbb{P}(A)$  in die Bayes-Formel ergibt

$$\mathbb{P}(B_i \mid A) = \frac{\mathbb{P}(A \mid B_i) \mathbb{P}(B_i)}{\sum_j \mathbb{P}(A \mid B_j) \mathbb{P}(B_j)}.$$

Die Details sind eine Hausaufgabe.

# KAPITEL 4

## Zufallsvariablen und ihre Verteilung

Vorlesung 09.05.2025 (V04 2025)

**Zufallsvariablen** ermöglichen es uns nicht nur, Ereignisse übersichtlicher darzustellen, sondern sind auch das optimale Werkzeug, um in systematischer Weise von einem **Wahrscheinlichkeitsraum** mit vielen Elementarereignissen zu einem kleineren **Wahrscheinlichkeitsraum** zu wechseln.

### Lernziele

- Konzepte
  - Zufallsvariablen als Abbildung und ihre Verteilung als Wahrscheinlichkeitsmaß
  - Verteilungsfunktion einer Zufallsvariablen
  - gemeinsame Verteilung von Zufallsvariablen, Randverteilung, Randdichte
- Fakten
  - Eigenschaften von Verteilungsfunktionen
  - Die gemeinsame Verteilung bestimmt die Randverteilungen.
  - Die Umkehrung ist im allgemeinen falsch.

### 4.1 | Die Verteilung einer Zufallsvariablen

**Beispiel 4.1 n-faches Werfen einer fairen Münze** (2025)

$$\Omega_n = \{0, 1\}^n, \quad \mu_n(\{\omega\}) = \left(\frac{1}{2}\right)^n \quad \forall \omega \in \Omega \quad (\text{Gleichverteilung})$$

$\omega_i = 1$  bedeute "Kopf"

Falls es uns interessiert, wie oft "Kopf" fällt:

$$S_n(\omega) := \sum_{i=1}^n \omega_i \quad \text{ist Anzahl "Erfolge" (Kopf)}$$

$$S_n : \Omega_n \rightarrow \{0, 1, \dots, n\} \quad \text{Abbildung!}$$

Falls der relative Anteil der Erfolge relevant ist:

$$T_n : \Omega_n \rightarrow [0, 1]$$

$$T_n(\omega) := \frac{1}{n} S_n(\omega) = \frac{1}{n} \sum_{i=1}^n \omega_i \quad \forall \omega \in \Omega$$

**Definition 4.1 Zufallsvariable** (2025)

Für einen Wahrscheinlichkeitsraum  $(\Omega, \mathbb{P})$  und eine Menge  $E \neq \emptyset$  nennen wir eine messbare Abbildung

$$X : \Omega \rightarrow E$$

eine  $E$ -wertige Zufallsvariable.

**Kommentar 4.1** Zu Definition 4.1: Zufallsvariable ist keine Variable: Es ist eine Zuordnungsvorschrift der Stochastik, welche jedem möglichen Ergebnis eines Zufallsexperiments eine Größe zuordnet. Also das Ergebnis eines Zufallsexperiments.

**Bemerkung 4.1** (Skript 26 - Bemerkung 3.3.)

Ist der Ereignisraum  $\Omega$  abzählbar, so ist eine Zufallsvariable nichts anderes als eine Abbildung, die auf dem  $\Omega$  des Wahrscheinlichkeitsraums definiert ist. Ist  $\Omega \subseteq \mathbb{R}_d$ , kommen eigentlich noch Messbarkeitsfragen hinzu, die wir im Rahmen dieser Vorlesung jedoch ignorieren wollen.

Wie wir bereits in Beispiel 4.1 gesehen haben, ist es praktisch, Ereignisse mit Hilfe von Zufallsvariablen auszudrücken. Wenn uns nur Ereignisse interessieren, die durch ein und dieselbe Zufallsvariable ausgedrückt werden können, so können wir sogar noch einen Schritt weitergehen und einen neuen Wahrscheinlichkeitsraum einführen, der nur noch solche Ereignisse kennt. Die folgende Definition ist ein erster Schritt in diese Richtung.

**Definition 4.2 Bild- und Wertebereich einer Zufallsvariablen** (Skript 26 - Definition 3.4.)

Sei  $X : \Omega \rightarrow E$  eine  $E$ -wertige Zufallsvariable auf einem Wahrscheinlichkeitsraum  $(\Omega, \mathbb{P})$ . Dann heißt  $E$  der Wertebereich von  $X$ , und

$$X(\Omega) = \{X(\omega) : \omega \in \Omega\}$$

der Bildbereich von  $X$ .

**Bemerkung 4.2** (Skript 26 - Bemerkung 3.5.)

Es gilt stets  $X(\Omega) \subseteq E$ . Der Bildbereich ist die kleinstmögliche Menge, die alle Werte enthält, die  $X$  annehmen kann.

St Sn wie in Beispiel 4.1 die Anzahl der Erfolge in einem Zufallsexperiment der Länge  $n \in \mathbb{N}$ , so können wir Sn auffassen als Abbildung von  $\Omega$  nach  $E = \mathbb{N}_0$ , aber auch als Abbildung nach  $E = \{0, 1, \dots, n\}$  oder gar nach  $E = \mathbb{R}$ . Unabhängig davon, wie wir den Wertebereich  $E$  wählen, gilt für den Bildbereich stets  $X(\Omega) = \{0, 1, \dots, n\}$ .

**Definition 4.3 Verteilung einer Zufallsvariable** (2025)

Sei  $X$  eine  $E$ -wertige Zufallsvariable auf  $(\Omega, \mathbb{P})$

$$\mathbb{P}_X(B) := \mathbb{P}(\{\omega \in \Omega : X(\omega) \in B\}) \quad \forall \text{ messbaren } B \subset E = \underbrace{\mathbb{P}(X \in B)}_{\text{Kurzschreibweise}}$$

Das Wahrscheinlichkeitsmaß  $\mathbb{P}_X$  auf  $E$  heißt Verteilung von  $X$ .

**Kommentar 4.2** Zu Definition 4.3: Die Verteilung von  $X$  beschreibt, wie die Werte von  $X$  verteilt sind, also wie wahrscheinlich verschiedene Ergebnisse von  $X$  sind.

**Beispiel 4.2 Fortsetzung Münzwurf** (Skript 26 - Beispiel 3.7.)

Die Zufallsvariable  $S_n$  aus Beispiel 4.1 hat den Bildbereich  $S_n(\Omega_n) = \{0, \dots, n\}$ . Für  $k \in S_n(\Omega_n)$  gilt

$$\mathbb{P}_{S_n}(\{k\}) = \mathbb{P}_n(\{\omega \in \Omega_n : S_n(\omega) \in \{k\}\}) = \mathbb{P}_n\left(\left\{\omega \in \Omega_n : \sum_{i=1}^n \omega_i = k\right\}\right) = \binom{n}{k} 2^n$$

weil  $\mathbb{P}_n$  die Gleichverteilung auf  $\Omega_n = \{0, 1\}^n$  ist und es  $\binom{n}{k}$  viele Elementarereignisse  $\omega \in \Omega_n$  gibt, für die  $S_n(\omega) = k$  gilt.

Ist  $B \subseteq S_n(\Omega_n)$ , so folgt mit den Rechenregeln für Wahrscheinlichkeiten, dass:

$$\begin{aligned} \mathbb{P}_{S_n}(B) &= \mathbb{P}_n(\{\omega \in \Omega_n : S_n(\omega) \in B\}) \\ &= \mathbb{P}_n\left(\left\{\omega \in \Omega_n : \sum_{i=1}^n \omega_i \in B\right\}\right) \\ &= \mathbb{P}_n\left(\bigcup_{k \in B} \left\{\omega \in \Omega_n : \sum_{i=1}^n \omega_i = k\right\}\right) \\ &= \sum_{k \in B} \mathbb{P}_n\left(\left\{\omega \in \Omega_n : \sum_{i=1}^n \omega_i = k\right\}\right) \\ &= \sum_{k \in B} \binom{n}{k} 2^n \end{aligned}$$

**Bemerkung 4.3 Sprunghöhen der Verteilungsfunktion** (Skript 26 - Bemerkung 3.8.)

In Definition 4.3 wird behauptet, dass die Abbildung  $\mathbb{P}_X$ , die auf den messbaren Teilmengen von  $E$  definiert ist und Werte in  $[0, 1]$  annimmt, tatsächlich ein **Wahrscheinlichkeitsmaß** ist. Das müssen wir natürlich zeigen. Wir werden uns das Leben aber ein wenig leichter machen, und den Beweis nur in dem Fall führen, in dem  $\mathbb{P}$  durch eine Wahrscheinlichkeitsfunktion  $\mu$  gegeben ist.

In diesem Fall entfällt auch die Notwendigkeit zu prüfen, ob eine Menge  $B \subseteq E$  messbar ist, denn wenn  $\Omega$  eine abzählbare Menge ist, dann kann die **Zufallsvariable**  $X$ , die auf  $\Omega$  definiert ist, ebenfalls nur abzählbar viele Werte annehmen.

**Lemma 4.1** (2025)

Ist  $\Omega$  abzählbar und  $\mathbb{P}$  durch die **Wahrscheinlichkeitsfunktion**  $\mu$  gegeben, so ist  $\mathbb{P}_X$  (aus Definition 4.3) ein **Wahrscheinlichkeitsmaß**.

**Beweis.**

$$\mu_X(e) = \mathbb{P}_X(\{e\}) = \mathbb{P}(X \in \{e\}) = \mathbb{P}(X = e) = \sum_{\substack{\omega \in \Omega \\ X(\omega) = e}} \mu(\omega) \geq 0$$

z.z. Normierung

$$\sum_{e \in E} \mu_X(e) = \sum_{e \in E} \sum_{\substack{\omega \in \Omega: \\ X(\omega) = e}} \mu(\omega) = \sum_{\substack{\omega \in \Omega: \\ e \in E: \\ X(\omega) = e}} \mu(\omega) = \sum_{\substack{\omega \in \Omega: \\ X(\omega) = e}} \mu(\omega) = \sum_{\omega \in \Omega} \mu(\omega) = 1$$

(Ausführlicher auf Seite 31 im Skript 26)

**Korollar 4.1 Induzierter Wahrscheinlichkeitsraum** (Skript 26 - Korollar 3.10.)

$(E, \mathbb{P}_X)$  ist ein **Wahrscheinlichkeitsraum**.

**Beispiel 4.3** (Skript 26 - Beispiel 3.11.)

Im Beispiel 4.1 und der Fortsetzung 4.2 erhalten wir als neuen, induzierten **Wahrscheinlichkeitsraum**, je nach Wahl des Wertebereichs

- (a)  $(\{0, \dots, n\}, \mathbb{P}_{S_n})$ , wobei das **Wahrscheinlichkeitsmaß**  $\mathbb{P}_{S_n}$  gegeben ist durch die **Wahrscheinlichkeitsfunktion**  $\{0, \dots, n\} \ni k \mapsto \binom{n}{k} 2^{-n}$ ,
- (b)  $(\mathbb{N}_0, \mathbb{P}_{S_n})$ , wobei das **Wahrscheinlichkeitsmaß**  $\mathbb{P}_{S_n}$  gegeben ist durch die **Wahrscheinlichkeitsfunktion**

$$\mathbb{N}_0 \ni k \mapsto \begin{cases} \binom{n}{k} 2^{-n}, & \forall k \in \{0, \dots, n\} \\ 0 & \text{sonst} \end{cases}$$

Im folgenden wollen wir die Notation etwas vereinfachen, damit wir für Ereignisse, die durch eine **Zufallsvariable** ausgedrückt werden, nicht immer wieder mühsam  $\{\omega \in \Omega : X(\omega) \in \dots\}$  schreiben müssen.

## 4.2 | Notationen

(2025)

$$\mathbb{P}(X \in B) = \mathbb{P}(\{\omega \in \Omega : X(\omega) \in B\})$$

Falls  $B$  ein Intervall ist:

$$\mathbb{P}(X \geq b), \quad \mathbb{P}(a < X \leq b), \dots$$

**Definition 4.4 Wertebereich** (2025)

Geg.:

$$X : \Omega \rightarrow E \quad \text{Zufallsvariable auf } (\Omega, \mathbb{P})$$

Dann heißt  $E$  der Wertebereich und  $X(\Omega) := \{X(\omega) : \omega \in \Omega\}$  heißt Bildbereich.

**Lemma 4.2 Existenz einer Zufallsvariablen mit vorgegebener Verteilung** (Skript 26 - Lemma 3.13.)

Sei  $(\tilde{\Omega}, \tilde{\mathbb{P}})$  ein beliebiger **Wahrscheinlichkeitsraum**. Dann existieren ein **Wahrscheinlichkeitsraum**  $(\Omega, \mathbb{P})$  und eine **Zufallsvariable**  $X$  auf  $(\Omega, \mathbb{P})$  derart, dass die **Verteilung** von  $X$  das vorgegebene **Wahrscheinlichkeitsmaß**  $\tilde{\mathbb{P}}$  ist. d.h. es gilt  $\mathbb{P}_X = \tilde{\mathbb{P}}$ .

**Beweis.** Der Beweis ist verwirrend einfach. Wir können nämlich einfach folgende Wahl treffen:

$$\Omega = \tilde{\Omega}, \quad \mathbb{P} = \tilde{\mathbb{P}}, \quad X(\omega) = \omega \quad \forall \omega \in \Omega$$

Dann gilt für jede messbare Menge  $B \subseteq \Omega$ :

$$\mathbb{P}_X(B) = \mathbb{P}(\{\omega \in \Omega : X(\omega) \in B\}) = \mathbb{P}(B) = \tilde{\mathbb{P}}(B)$$

Dabei haben wir verwendet, dass  $X$  als Abbildung die Identität auf  $\Omega$  ist und daher

$$\{\omega \in \Omega : X(\omega) \in B\} = B$$

gilt. Da  $B \subseteq \Omega$  beliebig war, haben wir gezeigt, dass  $\mathbb{P} = \tilde{\mathbb{P}}$  gilt.



**Beispiel 4.4** Zu Definition 4.4 (2025)

$$S_n : \Omega_n \rightarrow \{0, \dots, n\}$$

$$S_n : \Omega_n \rightarrow \mathbb{N}_0$$

**Bemerkung 4.4** Zu Definition 4.4 (2025)

$X(\Omega) \subset E$  gilt immer.

**Kommentar 4.3** Denn  $X(\Omega)$  ist ein  $\omega \in \Omega$  und jedes  $\omega$  ist ein Element aus  $E$ .

**Bemerkung 4.5** Zu Definition 4.4 (2025)

Gegeben ist ein **Wahrscheinlichkeitsmaß** auf  $\tilde{\Omega}$ , so existiert eine **Zufallsvariable**, deren **Verteilung** genau dieses **Wahrscheinlichkeitsmaß** ist.

Sei  $(\tilde{\Omega}, \tilde{\mathbb{P}})$  ein beliebiger **Wahrscheinlichkeitsraum**.

$X : \Omega \rightarrow \tilde{\Omega}$  definiert durch:

$$\Omega := \tilde{\Omega}$$

$$\mathbb{P} := \tilde{\mathbb{P}}$$

$$X(\omega) = \omega \quad \text{Identität} \quad \forall \omega \in \Omega$$

$$(X \in B) = \mathbb{P}(\underbrace{\{\omega \in \Omega : X(\omega) \in B\}}_{=B}) = \mathbb{P}(B) = \tilde{\mathbb{P}}(B)$$

$\Rightarrow X$  hat **Verteilung**  $\tilde{\mathbb{P}}$

**Kommentar 4.4** Zu jedem **Wahrscheinlichkeitsmaß** auf einem Messraum existiert eine **Zufallsvariable**, die genau dieses Maß als **Verteilung** hat.

aka. Für jede vorgegebene Wahrscheinlichkeitsverteilung kann man ein Zufallsexperiment konstruieren, das diese **Verteilung** als Ergebnis hat.

**Definition 4.5 Verteilungsfunktion** (Skript 26 - Definition 3.14.)

Seien  $(\Omega, \mathbb{P})$  ein **Wahrscheinlichkeitsraum** und  $X : \Omega \rightarrow \mathbb{R}$  eine  $\mathbb{R}$ -wertige **Zufallsvariable**. Dann heißt die Funktion  $F_X : \mathbb{R} \rightarrow [0, 1]$ , die gegeben ist durch

$$F_X(x) = \mathbb{P}(X \leq x) = \mathbb{P}_X((-\infty, x]) \quad \forall x \in \mathbb{R}$$

die **Verteilungsfunktion**.

**Bemerkung 4.6** Achtung, Verwechslungsgefahr! Wahrscheinlichkeitsfunktion  $\mu_X$  und **Verteilungsfunktion**  $F_X$  sind verschiedene Konzepte!

**Beispiel 4.5 Fortsetzung des Münzwurf-Beispiels** (Skript 26 - Beispiel 3.15.)

Wir werfen nun unsere faire Münze fünfmal, das heißt, wir betrachten die **Zufallsvariable**  $S_5$ . Die zugehörige

Verteilungsfunktion ist gegeben durch

$$F_{S_5}(x) = \mathbb{P}(S_5 \leq x) = \begin{cases} 0, & \text{für } x < 0, \\ \mathbb{P}(S_5 \leq 0) = \mu_{S_5}(0) = 2^{-5} = \frac{1}{32}, & \text{für } 0 \leq x < 1, \\ \mathbb{P}(S_5 \leq 1) = \mu_{S_5}(0) + \mu_{S_5}(1) = 2^{-5} + \binom{5}{1}2^{-5} = \frac{6}{32}, & \text{für } 1 \leq x < 2, \\ \mathbb{P}(S_5 \leq 2) = \sum_{i=0}^2 \mu_{S_5}(i) = F_{S_5}(1) + \mu_{S_5}(2) = \frac{1}{2}, & \text{für } 2 \leq x < 3, \\ \mathbb{P}(S_5 \leq 3) = \sum_{i=0}^3 \mu_{S_5}(i) = F_{S_5}(2) + \mu_{S_5}(3) = \frac{26}{32}, & \text{für } 3 \leq x < 4, \\ \mathbb{P}(S_5 \leq 4) = \sum_{i=0}^4 \mu_{S_5}(i) = F_{S_5}(3) + \mu_{S_5}(4) = \frac{31}{32}, & \text{für } 4 \leq x < 5, \\ 1, & \text{für } x \geq 5. \end{cases}$$

**Lemma 4.3 Eigenschaften von Verteilungsfunktionen I: allgemeine Eigenschaften** (Skript 26 - Lemma 3.17.)

Sei  $F_X$  eine Verteilungsfunktion. Dann gelten:

- $F_X$  ist monoton wachsend
- $F_X$  ist rechtsstetig, d.h.: Für jedes  $x_0 \in \mathbb{R}$  und jede Folge  $(x_n)_{n \in \mathbb{N}}$  mit  $x_n \searrow x_0$  gilt  $\lim_{n \rightarrow \infty} F_X(x_n) = F_X(x_0)$
- $\lim_{x \rightarrow -\infty} F_X(x) = 0$  und  $\lim_{x \rightarrow \infty} F_X(x) = 1$

**Lemma 4.4 Rechnen mit Verteilungsfunktionen I: allgemeine Rechenregeln** (Skript 26 - Lemma 3.17.)

Sei  $-\infty < a \leq b < \infty$ . Für die Verteilungsfunktion einer Zufallsvariablen  $X$  gelten neben der definierenden Gleichheit (siehe (b)) auch die folgenden Rechenregeln:

- $\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a)$
- $\mathbb{P}(X \leq b) = F_X(b)$
- $\mathbb{P}(X > a) = 1 - F_X(a)$

## 4.3 | Zufallsvariablen mit abzählbarem Bildbereich

**Beispiel 4.6 Beispiel Geometrische Verteilung** (Skript 26 - Beispiel 3.18.)

Wir werfen eine faire Münze bis das erste Mal Kopf fällt. In einem ersten Schritt begrenzen wir die Anzahl der Versuche und werfen maximal  $n$ -mal. Das offensichtliche Modell für das  $n$ -malige Werfen einer fairen Münze ist.

$$\Omega_n = \{0, 1\}^n \quad \text{und} \quad \mu_n(\omega) = 2^{-n} \quad \forall \omega \in \Omega$$

Dabei bedeute  $\omega_i = 1$ , dass im  $i$ -ten Wurf Kopf fällt.

Die einelementige Menge  $A_n = \{(0, 0, \dots, 0, 1)\} \subseteq \Omega_n$  beschreibt das Ereignis, dass im  $n$ -ten Wurf das erste Mal Kopf fällt. Es gilt  $\mathbb{P}_n(A_n) = \mu_n((0, 0, \dots, 0, 1)) = 2^{-n}$ .

Wenn wir wirklich den Münzwurf wiederholen wollen, bis zum ersten Mal Kopf fällt, wissen wir nicht, welches  $n$  wir wählen sollten, da bei  $n$  Würfen stets eine positive Restwahrscheinlichkeit bestehen bleibt, dass wir keinen solchen Erfolg erzielen.

Wir wählen daher einen anderen Ansatz, der die obigen Erkenntnisse nutzt. Sei  $\Omega = \{1, 2, \dots\} = \mathbb{N}$ . Dabei bedeute  $\omega = k \in \Omega$ , dass der erste Erfolg zur Zeit  $k$  eintritt. Gemäß der vorangegangenen Betrachtung wählen wir

$\mu(k) = 2^{-k}$  für alle  $k \in \Omega = \mathbb{N}$ .

Als nächstes überzeugen wir uns davon, dass  $\mu$  eine Wahrscheinlichkeitsfunktion ist. Offensichtlich ist  $\mu(k) > 0$  für alle  $k \in \mathbb{N}$ , und es gilt

$$\sum_{k=1}^{\infty} \mu(k) = \sum_{k=1}^{\infty} 2^{-k} = \frac{1}{2} \sum_{l=0}^{\infty} 2^{-l}$$

wobei wir den Summationsindex um 1 verschoben haben, indem wir  $l = k - 1$  setzen. Berechnen der geometrischen Reihe zeigt, dass

$$\sum_{k=1}^{\infty} \mu(k) = \frac{1}{2} \frac{1}{1 - \frac{1}{2}} = 1$$

Damit haben wir gezeigt, dass  $\mu$  eine Wahrscheinlichkeitsfunktion auf  $\Omega = \mathbb{N}$  ist. Eine  $\mathbb{N}$ -wertige Zufallsvariable  $X$ , deren Verteilung durch  $\mu_X = \mu$  gegeben ist, nennen wir geometrisch verteilt.

Der Bildbereich von  $X$  ist also  $\mathbb{N}$ . Wir berechnen die Verteilungsfunktion  $F_X$  folgendermaßen:

$$\begin{aligned} \mathbb{P}(X \leq x) &= 0, \text{ für } x < 1, F_X(k) = \mathbb{P}(X \leq k) = \sum_{i=1}^k \mu_X(i) = \sum_{i=1}^k 2^{-i} = 1 - \frac{1}{2^k}, \text{ für } k \in \mathbb{N}, \\ F_X(x) &= \mathbb{P}(X \leq x) = \mathbb{P}(X \leq \lfloor x \rfloor) = F_X(\lfloor x \rfloor) = 1 - \frac{1}{2^{\lfloor x \rfloor}}, \text{ für } x \in [1, \infty) \setminus \mathbb{N}. \end{aligned}$$

#### Bemerkung 4.7 Sprunghöhen der Verteilungsfunktion (Skript 26 - Bemerkung 3.19.)

Am Beispiel der geometrischen Verteilung sehen wir in Abbildung 3.2 (siehe Skript 2026), dass die Sprunghöhen der Verteilungsfunktion den Werten der Wahrscheinlichkeitsfunktion  $\mu_X$  entsprechen. Das ist kein Zufall. Nimmt eine Zufallsvariable  $X$  nur abzählbar viele Werte  $x_1, x_2, \dots$  an, so gilt stets

$$\begin{aligned} \mu_X(x_i) &= \mathbb{P}(X = x_i) \\ &= \mathbb{P}(X \leq x_i) - \mathbb{P}(X \leq x_{i-1}) \\ &= F_X(x_i) - F_X(x_{i-1}) \end{aligned} \quad \forall i \geq 2$$

sowie

$$\begin{aligned} \mu_X(x_1) &= \mathbb{P}(X = x_1) \\ &= \mathbb{P}(X \leq x_1) - \mathbb{P}(X \leq x_0) \\ &= F_X(x_1) - 0 \\ &= F_X(x_1) \end{aligned}$$

Wir ergänzen nun unser Lemma über die Eigenschaften von Verteilungsfunktionen um eine Aussage über diskrete Zufallsvariablen.

#### Lemma 4.5 Eigenschaften von Verteilungsfunktionen II: diskrete Zufallsvariable (Skript 26 - Lemma 3.20.)

Sei  $F_X$  eine Verteilungsfunktion. Dann gelten:

- $F_X$  ist monoton wachsend
- $F_X$  ist rechtsstetig, d.h.: Für jedes  $x_0 \in \mathbb{R}$  und jede Folge  $(x_n)_{n \in \mathbb{N}}$  mit  $x_n \searrow x_0$  gilt  $\lim_{n \rightarrow \infty} F_X(x_n) = F_X(x_0)$
- $\lim_{x \rightarrow -\infty} F_X(x) = 0$  und  $\lim_{x \rightarrow \infty} F_X(x) = 1$
- Nimmt die Zufallsvariable  $X$  nur abzählbare viele Werte an, so ist  $F_X$  stückweise konstant.

## 4.4 | Zufallsvariablen mit Dichte

### Definition 4.6 Dichte einer Zufallsvariable (Skript 26 - Definition 3.21.)

Seien  $(\Omega, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X: \Omega \rightarrow \mathbb{R}$  eine  $\mathbb{R}$ -wertige Zufallsvariable. Wir sagen, dass die Zufallsvariable  $X$  *absolutstetig mit Dichte  $f$*  ist, wenn eine Dichte  $f: \mathbb{R} \rightarrow [0, \infty)$  existiert derart, dass

$$\mathbb{P}_X((-\infty, x]) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f(u) du \quad \forall x \in \mathbb{R}. \quad (4.1)$$

### Bemerkung 4.8 (Skript 26 - Bemerkung 3.22.)

Umgekehrt können wir natürlich (4.1) verwenden, um zu einer gegebenen Dichte  $f$  eine Zufallsvariable  $X$  zu konstruieren, deren Verteilung  $\mathbb{P}_X$  die Dichte  $f$  hat.

Ohne Beweis merken wir an dieser Stelle an, dass (4.1) das Wahrscheinlichkeitsmaß  $\mathbb{P}_X$  eindeutig festlegt.

### Beispiel 4.7 Uniform verteilte Zufallsvariablen (Skript 26 - Beispiel 3.23.)

Sei  $f$  die Dichte der uniformen Verteilung auf einem Intervall  $[a, b]$ , das heißt, es gelte

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{für } x \in [a, b], \\ 0 & \text{sonst.} \end{cases}$$

Sei  $X$  eine Zufallsvariable mit Dichte  $f$ . Wir sagen, dass  $X$  *uniform verteilt* ist. Wir wollen nun für diese Zufallsvariable die Verteilungsfunktion  $F_X$  berechnen.

- Als erstes betrachten wir  $x < a$ . Für alle  $u < a$  gilt  $f(u) = 0$ , woraus

$$F_X(x) = \int_{-\infty}^x f(u) du = \int_{-\infty}^x 0 du = 0$$

folgt.

- Sei nun  $a \leq x \leq b$ . Wir teilen das  $F_X(x)$  definierende Integral auf in ein Integral bis  $a$  und ein weiteres Integral von  $a$  bis  $x$ :

$$F_X(x) = \int_{-\infty}^a f(u) du + \int_a^x f(u) du = F_X(a) + \int_a^x \frac{1}{b-a} du.$$

Wir haben den ersten Summanden  $F_X(a) = 0$  bereits berechnet. Daher folgt

$$F_X(x) = \int_a^x \frac{1}{b-a} du = \frac{x-a}{b-a}.$$

- Es bleibt der Fall  $x > b$  zu betrachten. Einerseits können wir wieder das Integral aufspalten, diesmal bei  $b$ , und erhalten

$$F_X(x) = \int_{-\infty}^b f(u) du + \int_b^x f(u) du = F_X(b) + 0 = 1.$$

Andererseits können wir auch schlaue argumentieren:  $F_X$  ist monoton wachsend. Daraus folgt, dass  $F_X(x) \geq F_X(b) = 1$  gelten muss. Da eine Verteilungsfunktion durch 1 beschränkt ist, folgt bereits  $F_X(x) = 1$  für alle  $x \geq b$ .

Somit gilt

$$F_X(x) = \begin{cases} 0 & \text{für } x < a, \\ \frac{x-a}{b-a} & \text{für } a \leq x \leq b, \\ 1 & \text{für } x > b. \end{cases}$$

#### Beispiel 4.8 Exponentialverteilte Zufallsvariablen (Skript 26 - Beispiel 3.24.)

Sei  $f$  die Dichte der Exponentialverteilung mit Parameter  $\alpha > 0$ , das heißt, es gelte

$$f(x) = \begin{cases} \alpha e^{-\alpha x} & \text{für } x > 0, \\ 0 & \text{sonst.} \end{cases}$$

Sei  $X$  eine Zufallsvariable mit Dichte  $f$ . Wir sagen, dass  $X$  *exponentialverteilt mit Parameter  $\alpha$*  ist. Wir wollen nun die Verteilungsfunktion  $F_X$  von  $X$  bestimmen.

- Als erstes betrachten wir  $x \leq 0$ . Für alle  $u \leq 0$  gilt  $f(u) = 0$ , woraus wieder

$$F_X(x) = \int_{-\infty}^x f(u) du = 0$$

folgt.

- Sei nun  $x > 0$ . Wir teilen wieder das  $F_X(x)$  definierende Integral auf, diesmal in ein Integral bis 0 und ein weiteres Integral von 0 bis  $x$ :

$$F_X(x) = F_X(0) + \int_0^x \alpha e^{-\alpha u} du = \int_0^x \alpha e^{-\alpha u} du.$$

Der Integrand  $h(u) = \alpha e^{-\alpha u}$  besitzt die Stammfunktion  $H(u) = -e^{-\alpha u}$ . Daher folgt

$$F_X(x) = H(u) \Big|_{u=0}^x = 1 - e^{-\alpha x}.$$

Somit gilt

$$F_X(x) = \begin{cases} 0 & \text{für } x \leq 0, \\ 1 - e^{-\alpha x} & \text{für } x > 0. \end{cases}$$

#### Lemma 4.6 Rechnen mit Verteilungsfunktionen II: Zufallsvariable mit Dichte (Skript 26 - Lemma 3.25.)

Sei  $-\infty < a \leq b < \infty$ . Für die Verteilungsfunktion einer Zufallsvariablen  $X$  mit Dichte  $f$  gelten neben der definierenden Gleichheit (siehe (b)) auch die folgenden Rechenregeln.

$$(a) \quad \mathbb{P}(a < X \leq b) = \int_a^b f(x) dx = F_X(b) - F_X(a),$$

$$(b) \quad \mathbb{P}(X \leq b) = \int_{-\infty}^b f(x) dx = F_X(b),$$

$$(c) \quad \mathbb{P}(X > a) = \int_a^{\infty} f(x) dx = 1 - F_X(a),$$

(d)

$$\begin{aligned}\mathbb{P}(a \leq X < b) &= \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X \leq b) = \mathbb{P}(a < X < b) = F_X(b) - F_X(a), \\ \mathbb{P}(X \leq b) &= \mathbb{P}(X < b) = F_X(b), \\ \mathbb{P}(X > a) &= \mathbb{P}(X \geq a) = 1 - F_X(a).\end{aligned}$$

**Lemma 4.7 Eigenschaften von Verteilungsfunktionen: finale Version** (Skript 26 - Lemma 3.26.)Sei  $F_X$  eine Verteilungsfunktion. Dann gelten:

- (a)  $F_X$  ist monoton wachsend.
- (b)  $F_X$  ist rechtsstetig, d.h.: Für jedes  $x_0 \in \mathbb{R}$  und jede Folge  $(x_n)_{n \in \mathbb{N}}$  mit  $x_n \searrow x_0$  gilt  $\lim_{n \rightarrow \infty} F_X(x_n) = F_X(x_0)$ .
- (c)  $\lim_{x \rightarrow -\infty} F_X(x) = 0$  und  $\lim_{x \rightarrow \infty} F_X(x) = 1$ .
- (d) Nimmt die Zufallsvariable  $X$  nur abzählbar viele Werte an, so ist  $F_X$  stückweise konstant.
- (e) Hat  $X$  eine Dichte, so ist  $F_X$  eine stetige Funktion.
- (f) Hat  $X$  eine Dichte  $f$  und ist  $f$  stetig in einem Punkt  $a \in \mathbb{R}$ , so gilt  $f(a) = F_X'(a)$ .

## 4.5 | Mehrdimensionale Zufallsvariablen und ihre gemeinsame Verteilung: Abzählbare Bildbereiche

Für das folgende Beispiel ist die sogenannte charakteristische Funktion, die Ihnen bereits im Kontext der *Analysis* begegnet ist, nützlich. Im Rahmen dieser Vorlesung werden wir stattdessen von einer *Indikatorfunktion* sprechen, weil der Begriff *charakteristische Funktion* im Bereich der Wahrscheinlichkeitstheorie eine andere Bedeutung hat.

**Definition 4.7 Indikatorfunktion bzw. charakteristische Funktion** (Skript 26 - Definition 3.27.)

Sei  $\Omega \neq \emptyset$  eine beliebige Menge. Für eine Teilmenge  $B \subseteq \Omega$  heißt die Abbildung  $B: \Omega \rightarrow \{0, 1\}$ , die gegeben ist durch

$$B(\omega) = \begin{cases} 1 & \text{für } \omega \in B, \\ 0 & \text{für } \omega \notin B, \end{cases}$$

die *Indikatorfunktion* bzw. die *charakteristische Funktion* der Menge  $B$ .

**Beispiel 4.9 Robin und Uli würfeln ...** (Skript 26 - Beispiel 3.28.)

Robin und Uli würfeln dreimal mit einem fairen Würfel. Robin gewinnt jedes Mal einen Euro, wenn eine Eins fällt, während Uli einen Euro gewinnt, wenn eine Sechs fällt.

Wir modellieren das dreimalige Würfeln wie üblich mit  $\Omega = \{1, \dots, 6\}^3$  und der Gleichverteilung  $\mathbb{P}$  auf  $\Omega$ . Die folgenden beiden Zufallsvariablen beschreiben den Gewinn von Robin und jenen von Uli:

$$\begin{aligned}X(\omega) &= \sum_{i=1}^3 \mathbf{1}_{\{1\}}(\omega_i) \quad \forall \omega \in \Omega && \text{(Robins Gewinn)} \\ Y(\omega) &= \sum_{i=1}^3 \mathbf{1}_{\{6\}}(\omega_i) \quad \forall \omega \in \Omega && \text{(Ulis Gewinn)}\end{aligned}$$

Wir wollen beides gleichzeitig beschreiben. Daher sei  $Y = (X, Y)$ . Die neue Zufallsvariable  $Y$  hat den Wertebereich  $\{0, 1, 2, 3\}^2$ .<sup>a</sup> Da der Wertebereich von  $Y$  zweidimensional ist, bietet es sich an, die Wahrscheinlichkeitsfunktion  $\mu_Z$

der Verteilung von  $Y$  in Tabellenform anzugeben.

Die Zeilensummen ergeben die Verteilung von  $X$ . So gilt zum Beispiel, dass

$$\mathbb{P}(X = 2) = \sum_{j=1}^3 \mathbb{P}(X = 2, Y = j) = \sum_{j=1}^3 \mu_Z((2, j)) = 3\left(\frac{1}{6}\right)^2 \frac{4}{6} + 3\left(\frac{1}{6}\right)^3 + 0 + 0 = \frac{15}{6^3} = 3\left(\frac{1}{6}\right)^2 \frac{5}{6}.$$

Rechts erkennen wir die Wahrscheinlichkeit, dass Robin in drei Runden zweimal gewinnt, wenn Uli gar nicht mitspielt. Ebenso ergeben die Spaltensummen die Verteilung von  $Y$ , und es gilt zum Beispiel, dass

$$\mathbb{P}(Y = 1) = \sum_{i=1}^3 \mathbb{P}(X = i, Y = 1) = \sum_{i=1}^3 \mu_Z((i, 1)) = \dots = \frac{75}{6^3}.$$

Es bietet sich an, die Tabelle um die Verteilungen von  $X$  und  $Y$  zu ergänzen:

| $\mu_Z((x, y))$ | $y = 0$                                    | $y = 1$                                     | $y = 2$                                    | $y = 3$                      | $\mu_X(x)$                                 |
|-----------------|--------------------------------------------|---------------------------------------------|--------------------------------------------|------------------------------|--------------------------------------------|
| $x = 0$         | $\left(\frac{4}{6}\right)^3$               | $3 \frac{1}{6} \left(\frac{4}{6}\right)^2$  | $3 \left(\frac{1}{6}\right)^2 \frac{4}{6}$ | $\left(\frac{1}{6}\right)^3$ | $\left(\frac{5}{6}\right)^3$               |
| $x = 1$         | $3 \frac{1}{6} \left(\frac{4}{6}\right)^2$ | $3! \left(\frac{1}{6}\right)^2 \frac{4}{6}$ | $3 \left(\frac{1}{6}\right)^3$             | 0                            | $3 \frac{1}{6} \left(\frac{5}{6}\right)^2$ |
| $x = 2$         | $3 \left(\frac{1}{6}\right)^2 \frac{4}{6}$ | $3 \left(\frac{1}{6}\right)^3$              | 0                                          | 0                            | $3 \left(\frac{1}{6}\right)^2 \frac{5}{6}$ |
| $x = 3$         | $\left(\frac{1}{6}\right)^3$               | 0                                           | 0                                          | 0                            | $\left(\frac{1}{6}\right)^3$               |
| $\mu_Y(y)$      | $\left(\frac{5}{6}\right)^3$               | $3 \frac{1}{6} \left(\frac{5}{6}\right)^2$  | $3 \left(\frac{1}{6}\right)^2 \frac{5}{6}$ | $\left(\frac{1}{6}\right)^3$ | 1                                          |

Unten rechts sehen wir die Kontrolle: Die Summe über alle Felder im Inneren der Tabelle muss 1 betragen, genau wie die Summen der am Rand vermerkten Zeilen- bzw. Spaltensummen.

<sup>a</sup>Offensichtlich gilt in diesem Fall, dass der Bildbereich  $Y(\Omega)$  eine echte Teilmenge von  $\{0, 1, 2, 3\}^2$  ist, weil es u.a. nicht möglich ist, dass sowohl Robin als auch Uli zweimal gewinnen.

**Definition 4.8 Gemeinsame Verteilung und Randverteilung von Zufallsvariablen** (Skript 26 - Definition 3.29.)

Sei  $(\Omega, \mathbb{P})$  ein Wahrscheinlichkeitsraum.

- (a) Seien  $X_1, \dots, X_n$  Zufallsvariablen, die auf  $\Omega$  definiert sind. Dann heißt die Verteilung der  $n$ -dimensionalen Zufallsvariablen  $X = (X_1, \dots, X_n)$  die *gemeinsame Verteilung der Zufallsvariablen*  $X_1, \dots, X_n$ .
- (b) Ist andersherum eine  $n$ -dimensionale Zufallsvariable  $X = (X_1, \dots, X_n)$  auf  $\Omega$  gegeben, so heißt die Verteilung von  $X_i$  die  *$i$ -te Randverteilung von  $X$* .

**Bemerkung 4.9 Warnung!** (Skript 26 - Bemerkung 3.30.)

Wir haben bereits in Beispiel 3.28 gesehen, wie wir aus einer gemeinsamen Verteilung von Zufallsvariablen die Randverteilungen ausrechnen können. Leider gilt die Umkehrung nicht! Wir werden dies in einer der kommenden Vorlesungen genauer analysieren.

Das Berechnen einer Randverteilung aus der gemeinsamen Verteilung von Zufallsvariablen funktioniert im Fall von Zufallsvariablen mit abzählbarem Bildbereich durch "heraus summieren" der restlichen Variablen.

**Lemma 4.8 Bestimmen von Randverteilungen für Zufallsvariablen mit abzählbarem Bildbereich** (Skript 26 - Lemma 3.31.)

Seien  $(\Omega, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X_1, \dots, X_n$  Zufallsvariablen auf  $(\Omega, \mathbb{P})$ . Dabei sei jedes  $X_i$  eine  $E_i$ -

wertige Zufallsvariable. Ist  $\mu_X$  die Wahrscheinlichkeitsfunktion der gemeinsamen Verteilung der Zufallsvariablen  $X_1, \dots, X_n$ , so ist für jedes  $k \in \{1, \dots, n\}$  die Wahrscheinlichkeitsfunktion  $\mu_{X_k}$  von  $X_k$  gegeben durch

$$\mu_{X_k}(x) = \sum_{u_1 \in E_1} \cdots \sum_{u_{k-1} \in E_{k-1}} \sum_{u_{k+1} \in E_{k+1}} \cdots \sum_{u_n \in E_n} \mu_X(u_1, \dots, u_{k-1}, x, u_{k+1}, \dots, u_n) \quad \forall x \in E_k.$$

*Beweis.* Um die Notation übersichtlich halten zu können, führen wir den Beweis für  $n = 3$  und  $k = 2$  und schreiben  $X = X_1$ ,  $Y = X_2$ ,  $Z = X_3$  und entsprechend  $x = u_1$ ,  $y$  für die Werte von  $Y = X_2$  und  $z = u_3$ . Aus der Definition von  $\mu_X$  folgt, dass

$$\mu_Y(y) = \mathbb{P}(Y = y) = \mathbb{P}(X \in E_1, Y = y, Z \in E_3) = \sum_{x \in E_1} \sum_{z \in E_3} \mu_X(x, y, z) \quad \forall y \in E_2,$$

also gilt  $\mu_Y(y) = \sum_{x \in E_1} \sum_{z \in E_3} \mu_X(x, y, z)$  für alle  $y \in E_2$ . □

## 4.6 | Mehrdimensionale Zufallsvariablen und ihre gemeinsame Verteilung: Dichten

VL vom 15. Mai 2026

### Beispiel 4.10 Zufällige Punkte im Quadrat (Skript 26 - Beispiel 3.32.)

Wie groß ist die Wahrscheinlichkeit, dass ein im Einheitsquadrat  $Q$  zufällig gewählter Punkt im Dreieck  $D$  unter der Winkelhalbierenden liegt?

Das Quadrat  $Q$  und das Dreieck  $D$  sind gegeben durch

$$Q = [0, 1] \times [0, 1] = \{(x, y) \in \mathbb{R}^2 : 0 \leq x \leq 1, 0 \leq y \leq 1\},$$

$$D = \{(x, y) \in Q : y \leq x\}.$$

Intuitiv würden wir erwarten, dass  $\mathbb{P}(D) = \frac{|D|}{|Q|} = \frac{1}{2}$  gilt, das heißt, wir erwarten, dass sich die Wahrscheinlichkeit als Verhältnis der Inhalte von Dreieck und Quadrat ergibt.

Zum ‘Aufwärmen’ beginnen wir damit, die Inhalte von Quadrat und Dreieck formal zu berechnen:

$$|Q| = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbb{1}_Q(x, y) dx dy = \int_0^1 \left( \int_0^1 1 dx \right) dy = \int_0^1 1 dy = 1,$$

$$|D| = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbb{1}_D(x, y) dx dy = \int_0^1 \left( \int_y^1 1 dx \right) dy = \int_0^1 (1 - y) dy = 1 - \frac{1}{2} = \frac{1}{2}.$$

Dabei haben wir in der Berechnung des Inhalts des Dreiecks beim zweiten Gleichheitszeichen die Indikatorfunktion ersetzt durch das Einsetzen der Integralgrenzen, die die Indikatorfunktion vorschreibt. Um im Dreieck  $D$  zu sein, müssen zwei Bedingungen erfüllt sein: Einerseits muss  $x, y \in [0, 1]$  gelten, andererseits muss auch  $y \leq x$  gelten. Da das äußere Integral die Integrationsvariable  $y$  hat, fordern wir dort nur, dass  $y \in [0, 1]$  gilt, was zum Integral  $\int_0^1 \dots dy$  führt. (Die Grenzen des äußeren Integrals dürfen nicht von  $x$  abhängen!) Das innere Integral hängt nun von  $y$  ab. Wir behandeln  $y \in [0, 1]$  wie einen Parameter, wenn wir das innere Integral berechnen. Das innere Integral hat  $x$  als Integrationsvariable, und  $x$  muss  $x \in [0, 1]$  sowie  $y \leq x$  erfüllen. Wir fassen diese beiden Bedingungen zusammen und erhalten ein Integral der Form  $\int_y^1 \dots dx$ . Schließlich rechnen wir erst das innere Integral (als Funktion des Parameters  $y$ ) und dann das äußere Integral aus.

Alternativ können wir die Rechnung für den Inhalt des Dreiecks durch Vertauschen der Integrationsreihenfolge



vereinfachen. Das Vertauschen ist möglich, weil die Indikatorfunktion eine messbare, nicht negative Funktion ist:

$$|D| = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} D(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} D(x, y) dy dx = \int_0^1 \left( \int_0^x 1 dy \right) dx = \int_0^1 x dx = \frac{1}{2}.$$

Da wir mit der uniformen Verteilung auf dem Quadrat arbeiten, gilt, wie erwartet,

$$\mathbb{P}(D) = \frac{\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} D(x, y) dx dy}{\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} Q(x, y) dx dy} = \frac{1}{2}.$$

**Definition 4.9 Mehrdimensionale Dichten** (Skript 26 - Definition 3.33.)

- (a) Eine Funktion  $f: \mathbb{R}^n \rightarrow [0, \infty)$  heißt *n-dimensionale Dichte*, falls  $f$  Riemann-integrierbar ist und die Normierungsbedingung

$$\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, \dots, x_n) dx_1 \dots dx_n = 1$$

erfüllt ist.

- (b) Eine *n*-dimensionale Dichte  $f$  heißt *gemeinsame Dichte der Zufallsvariablen*  $X_1, \dots, X_n$ , wobei jedes  $X_i$  eine  $E_i$ -wertige Zufallsvariable auf demselben Wahrscheinlichkeitsraum  $(\Omega, \mathbb{P})$  ist, wenn

$$\mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) = \int_{-\infty}^{a_1} \cdots \int_{-\infty}^{a_n} f(x_1, \dots, x_n) dx_1 \dots dx_n \quad \forall a_1 \in E_1, \dots, a_n \in E_n$$

gilt.

Dabei verstehen wir unter  $\{X_1 \leq a_1, \dots, X_n \leq a_n\}$  das Ereignis, dass alle  $n$  Bedingungen simultan erfüllt sind, das heißt,

$$\begin{aligned} \{X_1 \leq a_1, \dots, X_n \leq a_n\} &= \{\omega \in \Omega: X_1(\omega) \leq a_1 \text{ und } \dots \text{ und } X_n(\omega) \leq a_n\} \\ &= \{X_1 \leq a_1\} \cap \cdots \cap \{X_n \leq a_n\} \\ &= \bigcap_{i=1}^n \{X_i \leq a_i\}. \end{aligned}$$

**Definition 4.10 uniforme Verteilung** (Skript 26 - Definition 3.34.)

Sei  $C \subset \mathbb{R}^n$  eine messbare Menge in  $\mathbb{R}^n$  mit endlichem Inhalt, das heißt, es gelte  $|C| = \lambda^n(C) < \infty$ . Dann heißt die Funktion  $f: \mathbb{R}^n \rightarrow [0, \infty)$ , die durch

$$f(x_1, \dots, x_n) = \frac{1}{|C|} \mathbb{I}_C((x_1, \dots, x_n)) = \begin{cases} \frac{1}{|C|} & \text{für } (x_1, \dots, x_n) \in C, \\ 0 & \text{sonst,} \end{cases} \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n$$

definiert ist, *Dichte der uniformen Verteilung auf C*.

**Lemma 4.9 Berechnen von Randdichten** (Skript 26 - Lemma 3.35.)

Sei  $f: \mathbb{R}^n \rightarrow [0, \infty)$  eine *n*-dimensionale Dichte der gemeinsamen Verteilung der Zufallsvariablen  $X_1, \dots, X_n$ . Für

$k \in \{1, \dots, n\}$  ist die Funktion  $f_k: \mathbb{R} \rightarrow [0, \infty)$ , gegeben durch

$$f_k(x) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(u_1, \dots, u_{k-1}, x, u_{k+1}, \dots, u_n) dx_1 \dots dx_{k-1} dx_{k+1} \dots dx_n \quad \forall x \in \mathbb{R},$$

eine Dichte der Zufallsvariablen  $X_k$ .

*Beweis.* Um von einer übersichtlicheren Notation profitieren zu können, führen wir den Beweis nur für  $n = 2$  und  $k = 1$ . Wir schreiben  $X = X_1$ ,  $Y = X_2$  sowie  $x = x_1$  und  $y = x_2$ . Für beliebiges  $a \in \mathbb{R}$  gilt

$$\begin{aligned} \mathbb{P}(X \leq a) &= \mathbb{P}(X \leq a, Y \in \mathbb{R}) \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y)_{(-\infty, a]}(x) dx dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^a f(x, y) dx dy. \end{aligned}$$

Da  $f$  eine nichtnegative, messbare Funktion ist, dürfen wir die Integrationsreihenfolge vertauschen. Damit folgt

$$\mathbb{P}(X \leq a) = \int_{-\infty}^a \left( \int_{-\infty}^{\infty} f(x, y) dy \right) dx = \int_{-\infty}^a f_X(x) dx$$

mit  $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$ . Da  $a \in \mathbb{R}$  beliebig war, folgt, dass  $f_X$  eine Dichte von  $X$  ist.

*Es ist eine gute Übung für Sie, entlang der Schritte dieses Beweises den Beweis für  $n = 3$  und  $k = 2$  selbständig zu führen.* □

Im Vergleich zum Fall von Wahrscheinlichkeitsfunktionen erhalten wir hier die Verteilung von  $X_k$  aus der gemeinsamen Verteilung von  $(X_1, \dots, X_n)$ , indem wir die restlichen Variablen “heraus integrieren” anstelle von “heraus summieren”.

**Definition 4.11 Randdichte** (Skript 26 - Definition 3.36.)

Die Dichte  $f_k$  von  $X_k$  gemäß Lemma 4.9 nennen wir  $k$ -te Randdichte von  $(X_1, \dots, X_n)$ .

# KAPITEL 5

## Unabhängigkeit von Ereignissen (und Bernoulli-Experimente)

Vorlesung 16.05.2025 (V05 2025)

### 5.1 | Stochastische Unabhängigkeit von Ereignissen

Was bedeutet stochastische Unabhängigkeit?

**Intuition:** Zwei Ereignisse  $A$  und  $B$  sind unabhängig, wenn die Information des Eintretens des jeweils einen keinen Einfluss darauf hat, als wie wahrscheinlich wir ein Eintreten auch des jeweils anderen einschätzen ( Bspw. mehrmals hintereinander Würfeln).

**Formal:** Um  $A$  und  $B$  unabhängig zu nennen, sollten also gelten (2025)

$$\mathbb{P}(B|A) = \mathbb{P}(B) \text{ und } \mathbb{P}(A|B) = \mathbb{P}(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

( $\mathbb{P}(A|B)$ : die bedingte Wahrscheinlichkeit von  $A$  gegeben  $B$ .) wobei jede dieser beiden Gleichungen äquivalent ist zu.

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$$

Also

$$\mathbb{P}(A|B) = \mathbb{P}(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \Leftrightarrow \mathbb{P}(A) \cdot \mathbb{P}(B) = \mathbb{P}(A \cap B)$$

$\mathbb{P}(A \cap B)$ : WS, dass  $A$  und  $B$  gleichzeitig eintreten

**Definition 5.1** Zwei Ereignisse  $A, B \subseteq \Omega$  heißen unabhängig, wenn  $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$ .

**Beispiel 5.1** TODO

**Beobachtung 5.1** (2025)

unabhängig  $\neq$  disjunkt! Also sind disjunkte Ereignisse unabhängig, wenn  $0 = \mathbb{P}(\emptyset) = \mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$ , also muss entweder  $\mathbb{P}(A) = 0$  oder  $\mathbb{P}(B) = 0$  sein (mindestens eines der Ereignisse WS Null haben):

$$0 = \mathbb{P}(\emptyset) = \mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B) \Leftrightarrow \mathbb{P}(A) = 0 \text{ oder } \mathbb{P}(B) = 0$$

**Kommentar 5.1** disjunkte Ereignisse:  $A \cap B = \emptyset \Rightarrow A$  und  $B$  können nicht gleichzeitig eintreten.  
unabhängige Ereignisse:  $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$

**Beobachtung 5.2** (2025)

Es gilt:  $A, B$  unabhängig  $\Leftrightarrow A, B^c$  unabhängig  $\Leftrightarrow A^c, B^c$  unabhängig.

**Beweis.** z.z.  $\mathbb{P}(A \cap B^c) = \mathbb{P}(A) \cdot \mathbb{P}(B^c)$

Siehe Folie 9

**Beobachtung 5.3**  $A$  kann unabhängig von sich selbst sein. (2025)

$$\mathbb{P}(A) = \mathbb{P}(A \cap A) = \mathbb{P}(A) \cdot \mathbb{P}(A) = \mathbb{P}(A)^2 \Leftrightarrow \mathbb{P}(A) \in \{0, 1\}$$

Umgangssprachlicher gesagt:  $A$  kann unabhängig von sich selbst sein, wenn seine WS entweder 0 oder 1 ist.

**Definition 5.2** Unabhängigkeit von  $n$  Ereignissen. (2025)

Die Ereignisse  $A_1, \dots, A_n \subseteq \Omega$  heißen unabhängig, wenn

$$\mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}) = \mathbb{P}(A_{i_1}) \cdots \mathbb{P}(A_{i_k})$$

für alle  $k = 2, \dots, n$  und alle Auswahlen von  $k$  verschiedenen Indizes  $i_1, \dots, i_k \in \{1, \dots, n\}$ . (Also alle Paare, Tripel, etc. prüfen.)

**Beispiel 5.2** siehe Folie 14--15**Bemerkung 5.1** (2025)

Es genügt nicht, paarweise Unabhängigkeit zu prüfen! Sachen können paarweise unabhängig, aber nicht insgesamt unabhängig sein.

**Bemerkung 5.2** (2025) Es genügt nicht,  $\mathbb{P}(A_1 \cap \dots \cap A_n) = \mathbb{P}(A_1) \cdots \mathbb{P}(A_n)$  zu prüfen. Es kann insgesamt unabhängig sein, aber nicht paarweise etc. unabhängig.

## 5.2 | Unabhängige Nacheinanderausführung von Zufallsexperimenten

(2025) Sollen Zufallsexperimente  $(\Omega_1, \mathbb{P}_1), \dots, (\Omega_n, \mathbb{P}_n)$  unabhängig nacheinander ausgeführt werden, so modellieren wir dies mit dem W-Raum  $(\Omega, \mathbb{P})$  mit

$$\Omega = \Omega_1 \times \dots \times \Omega_n$$

und – im Fall, dass wir abzählbare  $\Omega_i$  haben –

$$\mu(\omega) = \mu_1(\omega_1) \cdots \mu_n(\omega_n) \forall \omega = (\omega_1, \dots, \omega_n) \in \Omega$$

Sind nämlich  $A_1 \subseteq \Omega_1, \dots, A_n \subseteq \Omega_n$ , so sind bei dieser Wahl

$$B_1 = A_1 \times \Omega_2 \times \dots \times \Omega_n$$

$$B_2 = \Omega_1 \times A_2 \times \Omega_3 \times \dots \times \Omega_n$$

$$\vdots$$

$$B_n = \Omega_1 \times \dots \times \Omega_{n-1} \times A_n$$

$B_1$  bedeutet: Im ersten Experiment tritt  $A_1$  ein, die anderen sind egal. unabhängig, denn für  $k = 2, \dots, n$  und  $i_1, \dots, i_k \in \{1, \dots, n\}$  verschieden gilt:

$$\underbrace{\mathbb{P}(B_{i_1} \cap \dots \cap B_{i_k})}_{= A_1 \times A_2 \times \dots \times A_n} = \mathbb{P}_{i_1} A_{i_1} \cdot \dots \cdot \mathbb{P}_{i_k} A_{i_k} = \mathbb{P}(B_{i_1}) \cdot \dots \cdot \mathbb{P}(B_{i_k}) \quad (5.1)$$

**Beweis.** Selbstständig (siehe Hinweis Folie 20)

**Beispiel 5.3** Folie 21

Sind die  $\Omega_i$  nicht alle abzählbar, so definieren wir  $\mathbb{P}$  auf  $\Omega = \Omega_1 \times \dots \times \Omega_n$

$$\mathbb{P}(A_1 \times \dots \times A_n) = \mathbb{P}_1(A_1) \cdot \dots \cdot \mathbb{P}_n(A_n) \quad \forall A_i \subseteq \Omega_i \forall i \quad (5.2)$$

motiviert durch Formel (5.1).

**Bemerkung 5.3** (2025)

Formel (5.2) kann immer als Definition verwendet werden. Falls alle  $\mathbb{P}_i$  durch **WS**  $\mu_i$  gegeben sind, folgt aus Formel (5.2):

$$\begin{aligned} \mu((\omega_1, \dots, \omega_n)) &= \mathbb{P}(\{(\omega_1, \dots, \omega_n)\}) \\ &= \mathbb{P}(\{\omega_1\} \times \{\omega_2\} \times \dots \times \{\omega_n\}) \\ &\stackrel{(5.2)}{=} \mathbb{P}_1(\{\omega_1\}) \cdot \mathbb{P}_2(\{\omega_2\}) \cdot \dots \cdot \mathbb{P}_n(\{\omega_n\}) \\ &= \mu_1(\omega_1) \cdot \mu_2(\omega_2) \cdot \dots \cdot \mu_n(\omega_n) \end{aligned}$$

## 5.3 | Die Binomialverteilung

**Definition 5.3 Einfaches Bernoulli-Experiment** (2025)

Ein Bernoulli-Experiment ist ein Zufallsexperiment mit genau zwei möglichen Ergebnissen: Einem "Treffer" oder einer "Niete".

$\Omega_1 = \{0, 1\}$ ;  $\omega = 1$  bedeutet Erfolg,  $\omega = 0$  bedeutet Misserfolg.

$\mu_1(1) = p$ ,  $\mu_1(0) = 1 - p$  und dabei heißt  $p \in [0, 1]$  die Erfolgswahrscheinlichkeit.

**Definition 5.4 Bernoulli-Experiment der Länge  $n$**

Wiederhole dasselbe einfache Bernoulli-Experiment  $n$ -mal unabhängig.

$$\Omega_n = \{0, 1\}^n, \mu_n((\omega_1, \dots, \omega_n)) = p^{\overbrace{\sum_{i=1}^n \omega_i}^{=k}} \cdot (1-p)^{n-\overbrace{\sum_{i=1}^n \omega_i}^{=k}}$$

$$\begin{aligned} \Omega_n &= \underbrace{\Omega_1 \times \dots \times \Omega_n}_{n\text{-mal}} \\ \mu_n((\omega_1, \dots, \omega_n)) &= \mu_1(\omega_1) \cdot \dots \cdot \mu_1(\omega_n) \quad \forall \omega \in \Omega_n \\ &= p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{n-\sum_{i=1}^n \omega_i} \end{aligned}$$

**Definition 5.5 Binomialverteilung (2025)**

Suche WS für genau  $k$  Erfolge in Bernoulli-Experiment der Länge  $n$ .

$$A_k = \{S_n = k\} = \{(\omega_1, \dots, \omega_n) \in \{0, 1\}^n : \underbrace{\sum_{i=1}^n \omega_i}_{S_n(\omega)} = k\}$$

$\binom{n}{k}$  Möglichkeiten,  $k$  Einsen auf die  $n$  Stellen zu verteilen.

$$\Rightarrow \mathcal{B}_{n,p}(k) := \mathbb{P}(A_k) = \binom{n}{k} p^k (1-p)^{n-k} \text{ für alle } k \in \{0, \dots, n\}$$

$\mathcal{B}_{n,p}(k)$  ist eine Wahrscheinlichkeitsfunktion auf  $\Omega = \{0, \dots, n\}$ , denn

$$\sum_{k=0}^n \mathcal{B}_{n,p}(k) = \sum_{k=0}^n \mathbb{P}(A_k) = \mathbb{P}(\dot{\cup}_{k=0}^n A_k) = \mathbb{P}(\{0, 1\}^n) = 1$$

$\mathcal{B}_{n,p}$  heißt Binomialverteilung mit den Parametern  $n$  und  $p$ .

Eine Zufallsvariable  $X$ , deren Verteilung  $\mathbb{P}_X$  die  $\mathcal{B}_{n,p}$ -Verteilung ist, heißt binomialverteilt mit den Parametern  $n$  und  $p$ .

**Beispiel 5.4** Einfaches Bernoulli-Experiment Siehe Folie 29

**Beispiel 5.5** Bernoulli-Experiment der Länge  $n$  Siehe Folie 29

**Beispiel 5.6** Binomialverteilung : Siehe Folie 29

**Problem 5.1** Wie wahrscheinlich ist, dass in einem Bernoulli-Experiment der Länge  $n$  der erste Erfolg im  $n$ -ten Versuch eintritt? (2025)

$$A_n = \{(0, \dots, 0, 1)\}, \quad \mathbb{P}(A_n) = \mu_n((0, \dots, 0, 1)) = p(1-p)^{n-1}$$

**Definition 5.6** geometrische Verteilung mit Erfolgswahrscheinlichkeit  $p$  (2025)

Siehe Folie 33

**Definition 5.7** Unabhängigkeit von Zufallsvariable (2025)

Siehe Folie 35

## Unabhängigkeiten von Zufallsvariable

Vorlesung 23 Mai 2025 (V06 2025) und Vorlesung 22.05.2026 (V05 2026)

### Beispiel 6.1 Die Randverteilungen legen die gemeinsame Verteilung nicht eindeutig fest (2026)

Wir werfen eine faire Münze zweimal. Die Ergebnisse der beiden Würfe sollen notiert werden.

Alex schreibt korrekt auf, während Kim einen Moment lang abgelenkt ist, dadurch das Ergebnis des zweiten Wurfs verpasst und als Notlösung einfach so tut, als hätten beide Würfe dasselbe Ergebnis gehabt.

Modellierung

$$\Omega = \{0, 1\}^2$$

mit Gleichverteilung  $\mathbb{P}$ .

Zufallsvariable

- Alex notiert den zweifachen Münzwurf

$X : \Omega \rightarrow \Omega$  mit  $X = (X_1, X_2)$  wobei  $X_1((\omega_1, \omega_2)) = \omega_1$  und  $X_2((\omega_1, \omega_2)) = \omega_2$  für alle  $\omega \in \Omega$   
(das heißt,  $X$  ist die Identität auf  $\Omega$ )

- Kim notiert nur den ersten Münzwurf

$Y : \Omega \rightarrow \Omega$  mit  $Y = (Y_1, Y_2)$  wobei  $Y_1((\omega_1, \omega_2)) = \omega_1$  und  $Y_2((\omega_1, \omega_2)) = Y_1((\omega_1, \omega_2)) = \omega_1$  für alle  $\omega \in \Omega$

|                     |               |               |                  |
|---------------------|---------------|---------------|------------------|
| $\mu_X((x_1, x_2))$ | $x_2 = 0$     | $x_2 = 1$     | $\mu_{X_1}(x_1)$ |
| $x_1 = 0$           | $\frac{1}{4}$ | $\frac{1}{4}$ | $\frac{1}{2}$    |
| $x_1 = 1$           | $\frac{1}{4}$ | $\frac{1}{4}$ | $\frac{1}{2}$    |
| $\mu_{X_2}(x_2)$    | $\frac{1}{2}$ | $\frac{1}{2}$ | 1                |
| $\mu_Y((y_1, y_2))$ | $y_2 = 0$     | $y_2 = 1$     | $\mu_{Y_1}(y_1)$ |
| $y_1 = 0$           | $\frac{1}{2}$ | 0             | $\frac{1}{2}$    |
| $y_1 = 1$           | 0             | $\frac{1}{2}$ | $\frac{1}{2}$    |
| $\mu_{Y_2}(y_2)$    | $\frac{1}{2}$ | $\frac{1}{2}$ | 1                |

Offensichtlich sind die Randverteilungen von  $X$  und von  $Y$  gleich, während die gemeinsame Verteilung von  $Y_1$  und  $Y_2$  ist nicht dieselbe ist wie jene von  $X_1$  und  $X_2$ .

### Beispiel 6.2 n-mal würfeln mit fairem Würfel (2025)

$\Omega\{1, \dots, 6\}^n$ ,  $\omega_i$  das Ereignis des i-ten Wurfs.  $\mathbb{P}$  gleichverteilt.

$X_i : \Omega \rightarrow \{1, \dots, 6\}$ ,  $X_i(\omega) = \omega_i \quad \forall i \in \{1, \dots, 6\}$

z.z.  $X_i, \dots, X_n$  unabhängig

$\mathbb{P}(X_1 = k_1, \dots, X_n = k_n)$  für  $k_i \in \{1, \dots, 6\}$

$$\mathbb{P}(\{(k_1, \dots, k_n)\}) = \frac{1}{6^n}$$

$$\begin{aligned}\mathbb{P}(X_i = k_i) &= \mathbb{P}(X_1 \in \{1, \dots, 6\}, \dots, X_{i-1} \in \{1, \dots, 6\}, X_i = k_i, X_{i+1} \in \{1, \dots, 6\}, \dots, X_n \in \{1, \dots, 6\}) \\ &= \mathbb{P}(\{1, \dots, 6\}^{i-1} \times \dots) \\ &= \frac{6^{n-1}}{6^n} = \frac{1}{6}\end{aligned}$$

$$\mathbb{P}(X_1 = k_1, \dots, X_n = k_n) = \mathbb{P}(X_1 = k_1) \cdot \dots \cdot \mathbb{P}(X_n = k_n)$$

! jetzt müssen wir noch prüfen: Paare, Tripel, ... Danach:  $X_1, \dots, X_n$  bewiesenermaßen unabhängig  
Beispielsweise:  $\Rightarrow \{x_1 \in \{2, 4, 6\}, \dots, \{x_4 \leq 4\}\}$  unabhängig

Frage: müssen wir die Paare und Tripel wirklich prüfen?

**Karteikarte 6.1** Legen die Randverteilungen von Zufallsvariablen deren gemeinsame Verteilung eindeutig fest?

Nein, im Allgemeinen nicht. Zwei Zufallsvektoren können identische Randverteilungen haben, aber unterschiedliche gemeinsame Verteilungen (z.B. weil im einen Fall Unabhängigkeit vorliegt und im anderen nicht). Erst zusätzliche Information wie Unabhängigkeit legt die gemeinsame Verteilung eindeutig fest (vgl. Korollar zur Verteilungsfunktion)..

**Satz 6.1** (2026) Seien  $X_1, \dots, X_n$  unabhängig  $\Rightarrow \mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \mathbb{P}(X_1 \in B_1) \cdot \dots \cdot \mathbb{P}(X_n \in B_n)$

**Beweis.** Um zu zeigen, dass

$$\mathbb{P}(X_1 \in B_1, X_3 = B_3) = \mathbb{P}(X_1 = B_3) \cdot \mathbb{P}(X_3 = B_3)$$

gilt, wählen wir

$$B_2 = E_2, B_4 = E_4, \dots, B_n = E_n$$

**Definition 6.1** Unabhängigkeit von Zufallsvariablen (2026)

Auf einem Wahrscheinlichkeitsraum  $(\Omega, \mathbb{P})$  seien Zufallsvariablen  $X_1, \dots, X_n$  gegeben mit  $X_i : \Omega \rightarrow E_i$  für  $i = 1, \dots, n$ . Die Zufallsvariablen  $X_1, \dots, X_n$  heißen unabhängig, wenn die Ereignisse

$$\{X_1 \in B\}, \dots, \{X_n \in B\}$$

für alle Wahlen von messbaren Mengen  $B_i \subseteq E_i, i = 1, \dots, n$ , unabhängig sind.

Diese Definition ist zunächst einmal abschreckend. Wir haben bereits gesehen, wie viele Bedingungen für den Nachweis der Unabhängigkeit von  $n$  Ereignissen zu prüfen sind. Und nun sollen wir diesen Aufwand auch noch für jede Wahl von  $B_i$  betreiben! Wir werden uns daher im folgenden darum bemühen, einfacher nachzuweisende Kriterien für Unabhängigkeit herzuleiten.

Als erstes halten wir fest, dass es im diskreten Fall genügt, einelementige Mengen  $B_i$  zu betrachten.



## 6.1 | Unabhängigkeit für Zufallsvariable mit abzählbarem Bildbereich

**Kommentar 6.1** In 2025 und 2026 wurden diese Informationen verschieden formuliert. Hier befinden sich alle drei Versionen und eine zusammengeführte Version. Es handelt sich dabei um verschiedene Charakterisierungen der Unabhängigkeit (also es sind nur verschiedene Betrachtungsweisen des gleichen Umstands). Es sind danach auch noch weitere Charakterisierungen bzw. Konsequenzen zu finden.

### Satz 6.2 Satz I. - Charakterisierung über Ereignisse (2025)

Seien  $X_1, \dots, X_n$  Zufallsvariable auf  $(\Omega, \mathbb{P})$ ;  $X_i$  sei  $E_i$ -wertig.

Dann

$$X_1, \dots, X_n \text{ unabhängig} \Leftrightarrow \{X_1 = x_1\}, \dots, \{X_n = x_n\} \text{ unabhängig } \forall x_i \in E_i (i = 1, \dots, n)$$

**Beweis.** Siehe Folie 2 (2025)

### Satz 6.3 Satz II. - Neuformulierung von Satz I. / Charakterisierung über Produktform (2025)

Haben  $X_1, \dots, X_n$  abzählbare Werte-/Bildbereiche. Dann

$$X_1, \dots, X_n \text{ unabhängig} \Leftrightarrow \mu_{X_1, \dots, X_n}((x_1, \dots, x_n)) = \prod_{i=1}^n \mu_{x_i}(x_i)$$

### Theorem 6.1 Unabhängigkeit für Zufallsvariable mit abzählbarem Bildbereich (2026)

Auf einem Wahrscheinlichkeitsraum  $(\Omega, \mathbb{P})$  seien  $Z$   $X_1, \dots, X_n$  mit abzählbarem Bildbereich gegeben. Dann sind  $X_1, \dots, X_n$  genau dann unabhängig, wenn die Ereignisse

$$\{X_1 = x_1\}, \dots, \{X_n = x_n\}$$

für alle  $x_i \in X_i(\Omega), i = 1, \dots, n$  unabhängig sind.

**Beweis.** Siehe Skript S. 58.

**Kommentar 6.2** Gemeinsam haben alle drei Formulierungen:

$$X_1, \dots, X_n \text{ sind } Z \text{ auf Wahrscheinlichkeitsraum } (\Omega, \mathbb{P})$$

Verschieden formuliert sind:

$$\text{“haben abzählbare Werte-/Bildbereiche”} \Leftrightarrow X_i \text{ sei } E_i\text{-wertig}$$

und

$$X_1, \dots, X_n \text{ unabhängig} \Leftrightarrow \underbrace{\text{wenn die Ereignisse } \{X_1 = x_1\}, \dots, \{X_n = x_n\} \text{ für alle } x_i \in X_i(\Omega), i = 1, \dots, n \text{ unabhängig sind.}}_{\mu_{X_1, \dots, X_n}((x_1, \dots, x_n)) = \prod_{i=1}^n \mu_{x_i}(x_i)} \underbrace{\{X_1 = x_1\}, \dots, \{X_n = x_n\} \text{ unabhängig } \forall x_i \in E_i (i = 1, \dots, n)}$$

### Korollar 6.1 Konsequenz aus Satz 6.3 (2026)

Abzählbarer Bildbereich

Es genügt

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_1 = x_1) \cdot \dots \cdot \mathbb{P}(X_n = x_n) \forall x_i \in X_i(\Omega)$$

zu zeigen, um Unabhängigkeit von  $X_1, \dots, X_n$  zu zeigen.

### Satz 6.4 Charakterisierung über die Produktform der Verteilungsfunktion (2026)

$X_1, \dots, X_n$  unabhängig

$$\begin{aligned}\Leftrightarrow \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) &= \mathbb{P}(X_1 \leq a_1) \cdots \mathbb{P}(X_n \leq a_n) \\ &= F_{X_1}(a_1) \cdots F_{X_n}(a_n) \quad \forall a_i \in \mathbb{R}\end{aligned}$$

**Korollar 6.2** Konsequenz aus Satz 6.4 (2025)

$X_1, \dots, X_n$  unabhängig  $\Leftrightarrow$  gemeinsame Verteilung eindeutig bestimmt durch (Rand-)Verteilungen von  $X_1, \dots, X_n$   
Aka.:

$X_1, \dots, X_n$  unabhängig  $\Rightarrow$  gemeinsame Verteilung von  $X_1, \dots, X_n$  eindeutig bestimmt durch die Randverteilung

**Bemerkung 6.1** Zu Korollar 6.2 (2025)

Das Korollar sagt uns, wie wir unabhängige Zufallsvariablen mit Zähldichte modellieren.  
Ohne Unabhängigkeit ist das nicht der Fall!

**Bemerkung 6.2** Erinnerung an mathematisches Kriterium für Unabhängigkeit (2026)

Wie haben gesehen, dass Unabhängigkeit bereits gezeigt ist, wenn  $\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_1 = x_1) \cdots \mathbb{P}(X_n = x_n) \forall x_i \in E_i (i = 1, \dots, n)$  gilt. Wenn also die Produktform existiert. (Es ist nicht erforderlich  $X_{i_1}, \dots, X_{i_k}$  separat zu betrachten.)

**Bemerkung 6.3** Anwendung des mathematischen Kriteriums für Unabhängigkeit (2025)

(a) Wenn wir die Produktform finden: Beweis der Unabhängigkeit Wenn man also zeigen kann  $\mathbb{P}_{X_1, \dots, X_n} = \prod_i \mathbb{P}_{X_i}$

Umkehridee:

(b) Gegeben Verteilung der  $X_i$ : Wir nutzen die Produktform, um die gemeinsame Verteilung für unabhängig  $X_i$  zu bestimmen. Also wenn die  $X_i$  unabhängig sind und die Randverteilungen bekannt sind, dann kann man die gemeinsame Verteilung berechnen durch

$$\mathbb{P}_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_i \mathbb{P}_{X_i}(x_i)$$

**Karteikarte 6.2** Wie ist Unabhängigkeit von Zufallsvariablen  $X_1, \dots, X_n$  allgemein (mit  $X_i : \Omega \rightarrow E_i$ ) definiert?

$X_1, \dots, X_n$  heißen unabhängig, wenn für alle messbaren Mengen  $B_i \subseteq E_i$  ( $i = 1, \dots, n$ ) die Ereignisse  $\{X_1 \in B_1\}, \dots, \{X_n \in B_n\}$  (im Sinne der Unabhängigkeit von Ereignissen) unabhängig sind, d.h.  $P(X_1 \in B_1, \dots, X_n \in B_n) = P(X_1 \in B_1) \cdots P(X_n \in B_n)$  für alle Wahlen von  $B_1, \dots, B_n$ .

**Karteikarte 6.3** Satz I: Wie lässt sich Unabhängigkeit von  $X_1, \dots, X_n$  über einelementige Ereignisse charakterisieren?

$X_1, \dots, X_n$  unabhängig  $\Leftrightarrow \{X_1 = x_1\}, \dots, \{X_n = x_n\}$  sind unabhängig für alle  $x_i \in E_i$  ( $i = 1, \dots, n$ ). Man muss also nicht beliebige messbare Mengen  $B_i$  prüfen, sondern es genügt, einzelne Werte zu betrachten..

**Karteikarte 6.4** Satz II: Wie charakterisiert man Unabhängigkeit von  $X_1, \dots, X_n$  mit abzählbaren Bildbereichen über die Produktform?

$X_1, \dots, X_n$  unabhängig  $\Leftrightarrow p_{X_1, \dots, X_n}((x_1, \dots, x_n)) = \prod_{i=1}^n p_{X_i}(x_i)$  für alle  $(x_1, \dots, x_n)$ , d.h. die gemeinsame Zähldichte zerfällt in das Produkt der Randdichten..

**Karteikarte 6.5** Welche einzelne Gleichung genügt, um Unabhängigkeit von  $X_1, \dots, X_n$  mit abzählbarem Bildbereich zu zeigen?

Es genügt zu zeigen:  $P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1) \cdots P(X_n = x_n)$  für alle  $x_i \in X_i(\Omega)$ . Man muss NICHT zusätzlich Paare, Tripel etc. separat prüfen — die Produktform für alle  $n$ -Tupel gleichzeitig reicht hier aus..

**Karteikarte 6.6** Wie lässt sich Unabhängigkeit von  $X_1, \dots, X_n$  über die (gemeinsame) Verteilungsfunktion charakterisieren?

$X_1, \dots, X_n$  unabhängig  $\Leftrightarrow P(X_1 \leq a_1, \dots, X_n \leq a_n) = P(X_1 \leq a_1) \cdots P(X_n \leq a_n) = F_{X_1}(a_1) \cdots F_{X_n}(a_n)$  für alle  $a_1, \dots, a_n \in \mathbb{R}$ . Diese Charakterisierung funktioniert unabhängig davon, ob die  $X_i$  diskret sind oder eine Dichte haben..

**Karteikarte 6.7** Was folgt aus Unabhängigkeit von  $X_1, \dots, X_n$  für die gemeinsame Verteilung?

Sind  $X_1, \dots, X_n$  unabhängig, so ist ihre gemeinsame Verteilung eindeutig durch die Randverteilungen von  $X_1, \dots, X_n$  bestimmt. Ohne Unabhängigkeit gilt das nicht (siehe Alex/Kim-Beispiel: gleiche Randverteilungen, verschiedene gemeinsame Verteilung)..

**Karteikarte 6.8** Muss man bei der Anwendung des Produktform-Kriteriums  $X_{i_1}, \dots, X_{i_k}$  noch separat betrachten?

Nein. Gilt  $P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1) \cdots P(X_n = x_n)$  für alle  $x_i$ , so ist damit die Unabhängigkeit von  $X_1, \dots, X_n$  bereits vollständig gezeigt — es ist nicht nötig, Teilkollektionen (Paare, Tripel, ...) separat zu prüfen..

**Karteikarte 6.9** Welche zwei Anwendungsrichtungen hat das Produktform-Kriterium für Unabhängigkeit?

(a) Beweisrichtung: Findet man die Produktform  $p_{X_1, \dots, X_n} = \prod_i p_{X_i}$ , so ist Unabhängigkeit gezeigt. (b) Konstruktionsrichtung: Sind die Randverteilungen der  $X_i$  bekannt und sollen die  $X_i$  unabhängig sein, so erhält man die gemeinsame Verteilung als Produkt der Randverteilungen:  $p_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_i p_{X_i}(x_i)$ ..

## 6.1.1 | Poisson-Verteilte ZV

**Satz 6.5** Summe unabhängiger Poisson-verteilter Zufallsvariable ist wieder Poisson-verteilt. (2025)

Seien  $X_1, X_2$  unabhängig und Poisson-verteilt mit

$$\mu_{x_1}(k) = \mathbb{P}(X_1 = k) = \frac{z_1^k}{k!} e^{-z_1} \quad (z_1 > 0) \forall k \in \mathbb{N}_0$$

$$\mu_{x_2}(k) = \mathbb{P}(X_2 = k) = \frac{z_2^k}{k!} e^{-z_2} \quad (z_2 > 0) \forall k \in \mathbb{N}_0$$

Dann gilt:  $X_1 + X_2$  ist Poisson-Verteilt mit Parameter  $z_1 + z_2$ .

**Kommentar 6.3**  $X_1 + X_2$  nehmen beide Werte aus  $\mathbb{N}_0$  an, also ist die Summe auch in  $\mathbb{N}_0$ .

**Beweis.** Siehe auch Folie 6--7 2025

$X_1 + X_2$  ist poisson verteilt mit Parameter  $z_1 + z_2$

$$\begin{aligned}
 \mu_{X_1+X_2}(n) &= \mathbb{P}(X_1 + X_2 = n) \quad \text{für } n \in \mathbb{N}_0 \\
 &= \mathbb{P}\left(\bigcup_{k_1=0}^n \{X_1 = k_1, X_2 = n - k_1\}\right) \\
 &= \sum_{k_1=0}^n \mathbb{P}(X_1 = k_1, X_2 = n - k_1) \\
 &= \sum_{k_1=0}^n \mathbb{P}(X_1 = k_1) \mathbb{P}(X_2 = n - k_1) && \text{da unabhängig} \\
 &= \sum_{k_1=0}^n \frac{z_1^{k_1}}{k_1!} e^{-z_1} \frac{z_2^{n-k_1}}{(n-k_1)!} e^{-z_2} \\
 &= \sum_{k=0}^n \frac{n!}{k!(n-k)!} z_1^k z_2^{n-k} && \text{durch herausziehen von } \left[\frac{1}{n!} e^{-(z_1+z_2)}\right] \\
 &= \frac{(z_1 + z_2)^n}{n!} e^{-(z_1+z_2)}
 \end{aligned}$$

**Karteikarte 6.10** Was gilt für die Summe zweier unabhängiger, Poisson-verteilter Zufallsvariablen  $X_1, X_2$  mit Parametern  $\lambda_1, \lambda_2$ ?

$X_1 + X_2$  ist wieder Poisson-verteilt, und zwar mit Parameter  $\lambda_1 + \lambda_2$ . Beweisidee:  $P(X_1 + X_2 = n) = \sum_{k=0}^n P(X_1 = k)P(X_2 = n - k)$  (Unabhängigkeit), Einsetzen der Poisson-Zähldichten und Anwenden des Binomischen Lehrsatzes liefert  $\frac{(\lambda_1 + \lambda_2)^n}{n!} e^{-(\lambda_1 + \lambda_2)}$ .

## 6.2 | Zufallsvariable mit Dichten

**Satz 6.6** **Satz III.: Unabhängigkeiten von Zufallsvariable** (mit und ohne Dichte) (2025)

Seien  $X_1, \dots, X_n$  unabhängig  $\Leftrightarrow \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) = \mathbb{P}(X_1 \leq a_1) \cdot \dots \cdot \mathbb{P}(X_n \leq a_n) = \mathcal{F}_{x_1}(a_1) \cdot \dots \cdot \mathcal{F}_{x_n}(a_n) \forall a_1, \dots, a_n \in \mathbb{R}$ .

**Beweis.** Siehe Folie 8

**Satz 6.7** **Satz IV.** (2025, ergänzt 2026)

$X_1, \dots, X_n$  mit Dichten  $f_1, \dots, f_n$ . Dann gilt:  $X_1, \dots, X_n$  unabhängig  $\Leftrightarrow$  gemeinsame Dichte hat Produktform  $\Leftrightarrow (x_1, \dots, x_n) \mapsto f((x_1, \dots, x_n)) := f_1(x_1) \cdot \dots \cdot f_n(x_n)$  eine gemeinsame Sichte von  $X_1, \dots, X_n$  ist.

**Bemerkung 6.4** Zu Satz 6.7 (2026)

- Existenz der gem. **Dichte** ist nicht vorausgesetzt. Gegeben  $X_1, \dots, X_n$  mit Dichten  $f_1, \dots, f_n$

- Setze

$$f(x_1, \dots, x_n) := f_1(x_1) \cdots f_n(x_n) = \prod_{i=1}^n f_i(x_i) \quad \forall x_i \in \mathbb{R} (i = 1, \dots, n) \quad (6.1)$$

Aussage des Satzes ist:  $X_1, \dots, X_n$  unabhängig  $\Leftrightarrow f$  gem. **Dichte** von  $X_1, \dots, X_n$  ist

- $X_1, \dots, X_n$  mit Dichten  $f_1, \dots, f_n$ . Modelliere unabhängige Experimente durch gemeinsame **Dichte** (6.1).
- Gegen eine gem. **Dichte**  $f$  für  $X_1, \dots, X_n$  berechne Randdichten  $f_{x_1}, \dots, f_{x_n}$ .  
Gilt Gleichung (6.1)? Falls ja:  $X_1, \dots, X_n$  unabhängig. Falls (6.1) für  $(x_1, \dots, x_n)$  aus einer Menge  $\subseteq \mathbb{R}^n$  gilt mit  $\mathbb{R}^n \setminus M$  abzählbar, dann gilt Unabhängigkeit

**Kommentar 6.4** Vorsicht: Eine Wahrscheinlichkeitsdichte ist nur “fast überall” eindeutig.

Also: Die Produktform muss nicht an jedem einzelnen Punkt gelten. Es genügt, wenn sie fast überall gilt.

**Karteikarte 6.11** Wie charakterisiert man Unabhängigkeit von  $X_1, \dots, X_n$  mit Dichten  $f_1, \dots, f_n$ ?

$X_1, \dots, X_n$  unabhängig  $\Leftrightarrow$  die gemeinsame Dichte hat Produktform, d.h.  $f(x_1, \dots, x_n) := f_1(x_1) \cdots f_n(x_n)$  ist eine gemeinsame Dichte von  $X_1, \dots, X_n$ .

**Karteikarte 6.12** Muss die Existenz einer gemeinsamen Dichte bei Satz IV vorausgesetzt werden, und wie genau muss die Produktform gelten?

Nein, man setzt einfach  $f(x_1, \dots, x_n) := f_1(x_1) \cdots f_n(x_n)$  und prüft, ob dies eine gemeinsame Dichte von  $X_1, \dots, X_n$  ist. Eine Dichte ist nur “fast überall” eindeutig — die Produktform muss also nicht für jeden einzelnen Punkt gelten, es reicht, wenn sie auf einer Menge  $M \subseteq \mathbb{R}^n$  gilt, deren Komplement abzählbar (bzw. vom Maß Null) ist..

## 6.3 | Widerlegen von Unabhängigkeiten

**Bemerkung 6.5** Es genügt nicht einen Punkt zu finden, in dem (6.1) nicht gilt. (2025)

Wir brauchen eine Menge  $D \subseteq \mathbb{R}^n$  mit  $|D| = Z(D) > 0$ , so dass (6.1) auf  $D$  nicht gilt.

Einfacher: Zeigen, dass  $\mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) \neq \prod_{i=1}^n F_{x_i}(a_i)$ .

Zeigen Sie, dass die Produktform **nicht** gilt auf Quader oder verwenden Sie die (nicht geltende) Produktform der Verteilungsfunktion.

**Kommentar 6.5** Zu Bemerkung 6.5:

$\mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) \neq \prod_{i=1}^n F_{x_i}(a_i)$  bedeutet, die gemeinsame **Verteilungsfunktion** faktorisiert nicht. Das ist gemeint mit “verwenden Sie die (nicht geltende) Produktform der **Verteilungsfunktion**”, denn da  $F_{X_1, \dots, X_n}(a_1, \dots, a_n) = \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n)$  gilt, ist das die Negation der Produktform der **Verteilungsfunktion**.

**Kommentar 6.6** Zu Bemerkung 6.5:

Die Produktform der **Verteilungsfunktion** wird auf sogenannten “Quadern” geprüft. Damit sind Mengen der Form

$$(-\infty, a_1] \times \cdots \times (-\infty, a_n] \subseteq \mathbb{R}^n$$

gemeint.

Für den Zufallsvektor  $(X_1, \dots, X_n)$  entspricht ein solcher Quader dem Ereignis

$$\{X_1 \leq a_1, \dots, X_n \leq a_n\}.$$

Die gemeinsame **Verteilungsfunktion** ist daher gerade

$$F_{X_1, \dots, X_n}(a_1, \dots, a_n) = \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n).$$

Sind  $X_1, \dots, X_n$  unabhängig, so zerfällt diese Wahrscheinlichkeit in ein Produkt:

$$\mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) = \prod_{i=1}^n \mathbb{P}(X_i \leq a_i) = \prod_{i=1}^n F_{X_i}(a_i).$$

Man sagt dann:

Die **Verteilungsfunktion** besitzt Produktform auf Quadern.


Um zu zeigen, dass Zufallsvariablen nicht unabhängig sind, genügt es daher, einen Quader zu finden, für den diese Produktform nicht gilt.

*Danke an ChatGPT [?] (Überprüft)*

**Kommentar 6.7** Bei Bild Tafel link ganz unten reicht es an einem Punkt zu zeigen, weil wir da ganze Mengen benutzt haben. Heh?

**Beispiel 6.3** uniform. verteilung auf Rechteck (2026)

Sei  $(X, Y)$  ein zufälliger Punkt in  $\mathbb{R}$  (uniforme Verteilung)



$(X, Y)$  hat (gem.) Dichte  $f(x, y) = \frac{1}{a \cdot b} \quad \forall (x, y) \in \mathbb{R}^2$  Randdichten:

$$\begin{aligned} f_X(x) &= \int_{[0,b]} f(x, y) dy = \int_0^b \underbrace{f(x, y)}_{\frac{1}{a \cdot b}} dy = \frac{1}{a} [0, b](x) \\ f_Y(y) &= \frac{1}{b} [0, a](y) \\ f(x, y) &= [0, a] \times [0, b](x, y) \frac{1}{a \cot b} \\ &= f_X(x) f_Y(y) \end{aligned}$$

schlauer:

$$f(x, y) = \frac{1}{a \cot b} = \frac{1}{a} \underbrace{[0, a](x)}_{\text{Randdichte von } X} \cdot \frac{1}{b} \underbrace{[0, b](y)}_{\text{Randdichte von } Y}$$

Wir müssen die Randdichten gar nicht berechnen!  $X, Y$  unabhängig

**Kommentar 6.8** wenn man sieht die Dichte zerfällt in x und y Argument muss man nicht integrieren, sondern nur schauen, dass die Funktionen (?) das richtige Gewicht haben. OK. Gerald fragen...

**Beispiel 6.4** Dreieck (2026)




Abbildung 6.1

Sei  $(X, Y)$  ein zufälliger Punkt gleichverteilt im Dreieck  $D$ .

Gleichverteilt bedeutet: Dichte ist konstant auf  $D$  und 0 außerhalb.

$$\begin{aligned} f(x, y) &= \frac{1}{|D|} \mathbb{1}_D(x, y) \\ &= 2 \mathbb{1}_D(x, y) \\ &= \begin{cases} 2 & 0 \leq y \leq x \leq 1 \\ 0 & \text{sonst} \end{cases} \end{aligned}$$

Randdichten: (Man “integriert die andere Variable weg”)

$$\begin{aligned} f_X(x) &= \int_{-\infty}^{\infty} f(x, y) dy \\ &= \int_0^x 2 dy = 2x \mathbb{1}_{[0,1]}(x) \\ f_Y(y) &= \dots = 2(1-y) \mathbb{1}_{[0,1]}(y) \end{aligned}$$

Wenn  $X, Y$  unabhängig wären, dann würde gelten :

$$f(x, y) = f_X(x) f_Y(y) \quad (6.2)$$

Einsetzen ergibt:

$$\begin{aligned} f(x, y) &= 2 \cdot \mathbb{1}_D(x, y) \\ &\stackrel{?}{=} f_X(x) f_Y(y) \\ &= 2x2(1-y) \mathbb{1}_{[0,1]}(x, y) \end{aligned}$$

Wir sehen: Für  $(x, y) \in [0, 1]^2 \setminus D$  gilt  $f(x, y) = 0$ , also “rechte Seite”  $> 0$ .

Keine Unabhängigkeit. Für Erklärung siehe Kommentar 6.10.

Alternative: Statt Dichten zu vergleichen, kann man Unabhängigkeit auch testen über:

$$\mathbb{P}(X \leq a, Y \leq b) \stackrel{?}{=} F_X(a) F_Y(b)$$

Explizit: Berechne  $F_X$  und  $F_Y$ , zeige, dass es **einen** Punkt  $(a, b) \in \mathbb{R}^2$  gibt mit

$$\mathbb{P}(X \leq a, Y \leq b) \neq F_X(a) F_Y(b).$$

**Kommentar 6.9** Symbole und Terme in Beispiel 6.4

■  $D(x, y) = \text{Indikatorfunktion:}$

$$D(x, y) = \begin{cases} 1 & (x, y) \in D \\ 0 & \text{sonst} \end{cases}$$

■  $|D| = \text{Fläche des Dreiecks (hier: } |D| = \frac{1}{2})$

■  $f(x, y) = \text{gemeinsame Dichte von } (X, Y)$

■  $f_X(x)$  beschreibt die **Verteilung** von  $X$  alleine

■  $f_Y(y)$  beschreibt die **Verteilung** von  $Y$  alleine

**Kommentar 6.10** Für  $(x, y) \in [0, 1]^2 \setminus D$  gilt  $f(x, y) = 0$  weil in der Dichtefunktion oben explizit festgelegt wird, dass es außerhalb des Dreiecks 0 ist und  $[0, 1]^2 \setminus D$  ist alles außer das Dreieck.

Also ist die “rechte Seite”  $f_X(x) f_Y(y)$  aus 6.2).

Diese ist  $> 0$ , denn  $x$  kann 0 sein (siehe Bild 6.1, 0 ist der innerste Randpunkt von “außerhalb des Dreiecks”) und  $y$  kann 1 sein (analog äußerster Randpunkt von “außerhalb des Dreiecks”). Aber da es Randpunkte sind, haben sie keinen Einfluss auf die Dichte, denn Punkte haben keine Fläche und somit keine relevante “Menge”. Also kann man diese Punkte wegnorieren und einfach sagen  $x > 0$  und  $y < 1$ . Und wenn man das annimmt, dann erhält man:

$$f_X(x)f_Y(y) = 4x(1-y)_{[0,1]^2}(x, y)$$

Denn wir haben ja oben ausgerechnet, dass  $f_X(x) = 2x_{[0,1]}(x)$  und  $f_Y(y) = 2(1-y)_{[0,1]}(y)$ , INSO FERN  $X$  und  $Y$  unabhängig sind.

Weil aber  $y < 1$  gilt, muss  $1 - y > 0$  sein, also

$$\underbrace{4}_{>0} \underbrace{x(1-y)}_{>0}$$

Das ist dann ein Widerspruch damit, dass jeder Punkt außerhalb des Dreiecks  $f(x, y) = 0$  hat. Wir haben einen Punkt außerhalb des Dreiecks betrachtet, und der hatte  $f_X(x)f_Y(y) > 0$ . Also  $f(x, y) \neq f_X(x)f_Y(y)$ , was äquivalent ist zu “ $X$  und  $Y$  sind NICHT unabhängig”.

**Kommentar 6.11** Zu Beispiel 6.4

**Warum reicht ein einzelner Punkt zur Widerlegung?** Wenn Unabhängigkeit gilt, muss die Gleichung für *alle*  $(a, b)$  gelten. Findet man *einen einzigen* Punkt  $(a, b)$  mit Ungleichheit, ist Unabhängigkeit widerlegt.

Unabhängigkeit ist eine globale Eigenschaft und ein Gegenbeispiel genügt, um sie zu zerstören.”

**Karteikarte 6.13** Reicht ein einzelner Punkt, an dem die Produktform der Dichte nicht gilt, um Unabhängigkeit zu widerlegen?

Nein. Um Unabhängigkeit über die Dichte zu widerlegen, braucht man eine Menge  $D \subseteq \mathbb{R}^n$  mit positivem (Lebesgue-)Maß  $|D| > 0$ , auf der die Produktform  $f = f_1 \cdots f_n$  nicht gilt — ein einzelner Punkt hat Maß Null. Einfacher ist es meist, stattdessen zu zeigen, dass die Produktform der Verteilungsfunktion  $P(X_1 \leq a_1, \dots, X_n \leq a_n) \neq \prod_i F_{X_i}(a_i)$  an einem einzigen Punkt  $(a_1, \dots, a_n)$  verletzt ist — dort genügt bereits ein Punkt, da die Verteilungsfunktion (anders als die Dichte) punktweise eindeutig ist..

**Karteikarte 6.14** Was ist ein “Quader” im Kontext der Verteilungsfunktion, und was bedeutet “Produktform auf Quadern”?

Ein Quader ist eine Menge der Form  $(-\infty, a_1] \times \cdots \times (-\infty, a_n] \subseteq \mathbb{R}^n$ , dem Ereignis  $\{X_1 \leq a_1, \dots, X_n \leq a_n\}$  entsprechend. Sind  $X_1, \dots, X_n$  unabhängig, so zerfällt  $F_{X_1, \dots, X_n}(a_1, \dots, a_n) = P(X_1 \leq a_1, \dots, X_n \leq a_n)$  in  $\prod_i F_{X_i}(a_i)$  — man sagt, die Verteilungsfunktion hat Produktform auf Quadern. Um Nicht-Unabhängigkeit zu zeigen, genügt es, einen Quader zu finden, für den diese Produktform verletzt ist..



**Karteikarte 6.15** Muss man bei einer gemeinsamen Dichte immer erst die Randdichten  $f_X, f_Y$  berechnen, um Unabhängigkeit zu zeigen?

Nein. Lässt sich die gemeinsame Dichte bereits direkt als Produkt zweier Funktionen schreiben, von denen eine nur von  $x$  und die andere nur von  $y$  abhängt (und die jeweils zu einer Dichte normiert sind, d.h. Integral 1 ergeben), so sind diese Funktionen automatisch die Randdichten und die Unabhängigkeit folgt sofort aus der Faktorisierung — ohne die Randdichten separat auszurechnen..

**Karteikarte 6.16** Ein typisches Muster, an dem man Abhängigkeit bei Dichten erkennt: Was passiert, wenn der Träger der gemeinsamen Dichte kein Rechteck (Produktmenge) ist?

Hängt der Wertebereich einer Variable vom Wert der anderen ab (der Träger der gemeinsamen Dichte ist also keine Produktmenge  $A \times B$ , sondern z.B. ein Dreieck), so kann die gemeinsame Dichte nicht als Produkt zweier eindimensionaler Funktionen geschrieben werden: es gibt stets Punkte außerhalb des Trägers, an denen  $f = 0$  gilt, während  $f_X(x)f_Y(y) > 0$  wäre — die Zufallsvariablen sind dann nicht unabhängig..

**Karteikarte 6.17** Warum genügt ein einziger Gegenpunkt/Gegenquader, um Unabhängigkeit zu widerlegen?

Weil Unabhängigkeit verlangt, dass die Produktformel für ALLE Argumente (alle  $a_1, \dots, a_n$  bzw. – bei Dichten – auf einer Menge vollen Maßes) gilt. Findet man EINEN Punkt bzw. Quader, an dem die Gleichheit verletzt ist, ist die Allaussage widerlegt. Unabhängigkeit ist also eine globale Eigenschaft, und ein einziges Gegenbeispiel genügt, um sie zu zerstören..

**Definition 6.2** **Faltung** (2026)

$X, Y$  unabhängig Zufallsvariable . Dann heißt die Verteilung der Summe **Faltung** (der Verteilungen).

**Karteikarte 6.18** Was versteht man unter der Faltung zweier unabhängiger Zufallsvariablen  $X, Y$ ?

Die Verteilung der Summe  $X + Y$  zweier unabhängiger Zufallsvariablen  $X, Y$  heißt Faltung (der Verteilungen von  $X$  und  $Y$ )..



# KAPITEL 7

## Erwartungswert und Varianz von Zufallsvariablen

Vorlesung 30. Mai 2025 (V07 2025) und 05. Juni 2026 (V07 2026)

### Lernziele

#### Konzepte

- Erwartungswert einer Zufallsvariablen (gewichteter Mittelwert)
- Varianz als weitere Kennzahl

#### Fakten

- Zwei verschiedene Darstellungen des Erwartungswerts.
- Der Erwartungswert ist linear.

#### Wissen

- Existenz des Erwartungswerts prüfen können.
- Spezialfall:  $X(\Omega)$  ist eine endliche Menge (insbesondere erfüllt, wenn  $\Omega$  endlich ist).
- Spezialfall:  $X \geq 0$ .
- Erwartungswerte berechnen können.
- Erwartungswert und Varianz für die wichtigsten Verteilungen kennen
- Erwartungswert von Produkten zum Widerlegen von Unabhängigkeit
- Erwartungswert von Produkten bei Unabhängigkeit berechnen können
- Markov-Ungleichung kennen und anwenden können

### Grundgedanke

(2025) Die Verteilung charakterisiert eine Zufallsvariable  $X$  eindeutig (Im Sinne ihrer statistischen Eigenschaften: Wir können Wahrscheinlichkeiten berechnen wie z.B.  $\mathbb{P}(X \geq 2)$ , und diese Wahrscheinlichkeiten hängen nur von der Verteilung ab, nicht von der Wahl des Wahrscheinlichkeitsraums  $(\Omega, \mathbb{P})$ ).

Sind  $X$  und  $Y$  zwei Z mit derselben Verteilung, so gilt

$$\mathbb{P}(X \in A) = \mathbb{P}_X(A) = \mathbb{P}_Y(A) = \mathbb{P}(Y \in A)$$

für jedes  $A$ .

Es ist nicht immer klar, welche Verteilung zu einem sinnvollen Modell führt. Auch sind die Parameter der Verteilung nicht unbedingt bekannt. Siehe (2026)

■ **Binomialverteilung:**

$$\mathcal{B}_{n,p}(k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k \in \{0, \dots, n\}.$$

■ **Geometrische Verteilung:**

$$G_p(n) = p(1-p)^{n-1}, \quad n \in \mathbb{N}.$$

■ **Poisson-Verteilung:**

$$P_\lambda(k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k \in \mathbb{N}_0.$$

■ **Exponentialverteilung:**

$$f(x) = \omega e^{-\lambda x} \mathbb{1}_{[0,\infty)}(x), \quad x \in \mathbb{R}.$$

Wie können wir trotzdem Vorhersagen treffen?

Dies führt uns in die Statistik (später).

**Typische Fragestellungen:** Wie ...*im Mittel*? (2025)

- Wie groß ist der mittlere Gewinn bei einem Glücksspiel?
- Wie lange muss man bei einem wiederholten Zufallsexperiment im Mittel warten, bis ein bestimmtes Ereignis eintritt?
- Wie viele weitere Personen steckt eine infizierte Person im Mittel an?

**Beispiel 7.1 Ansteckungen** (2026)

- Die **Basisreproduktionszahl**  $R_0$  gibt an, wie viele Personen eine infizierte Person im Mittel ansteckt, wenn es in der Bevölkerung keine Immunität gibt. Gemäß RKI gilt:

$$R_0 \in [2.8, 3.8]$$

(vor möglicherweise ansteckenderen Mutationen).

- Die **zeitabhängige Reproduktionszahl**

$$R = R(t)$$

berücksichtigt Effekte durch Hygienemaßnahmen, Impfungen und Immunität. Sie gibt an, wie viele Personen eine infizierte Person in einem Zeitfenster gegebener Länge im Mittel ansteckt.

- Die **Inzidenz** setzt Neuinfektionen in Relation zur Bevölkerungsgröße. Die *7-Tage-Inzidenz* gibt beispielsweise an, wie viele neu infizierte Personen es in den vergangenen sieben Tagen pro 100 000 Einwohner gegeben hat.

**Beispiel 7.2 1 × Würfeln mit einem fairen Würfel** (2025)

Da herrscht eine Gleichverteilung, daher ist die erwartete Augenzahl ist das arithmetische Mittel.

$$\Omega = \{1, \dots, 6\}$$

mit Gleichverteilung  $\mathbb{P}$ .

Die Zufallsvariable

$$X : \Omega \rightarrow \mathbb{R}, \quad X(\omega) = \omega,$$

besitzt das Bild

$$X(\Omega) = \{1, \dots, 6\} \subseteq \mathbb{R}.$$

Für einen fairen Würfel ist der Erwartungswert die mittlere Augenzahl, also das arithmetische Mittel:

$$\mathbb{E}[X] = \frac{1 + 2 + 3 + 4 + 5 + 6}{6} = 3.5.$$

Die erwartete Augenzahl entspricht der mittleren Zahl von Schritten, die man in einem Würfelspiel pro Wurf vorwärtsgehen würde.

### Beispiel 7.3 Spiel, bei dem nicht alle Ausgänge gleichwahrscheinlich sind (2025)

1 × Würfeln eines fairen Würfels

Auszahlung:

- $k$  Euro, falls 2 gewürfelt
- 6 Euro, falls 2,  $\dots$ , 6 gewürfelt
- $\Omega = \{1, \dots, 6\}$  mit Gleichverteilung  $\mathbb{P}$ .

$\Omega = \{1, \dots, 6\}$  mit Gleichverteilung  $\mathbb{P}$

Die Auszahlung wird beschrieben durch die Zufallsvariable  $Y$  mit

$$Y(\omega) = k \cdot \mathbf{1}_{\{1\}}(\omega) + 6 \cdot \mathbf{1}_{\{2, \dots, 6\}}(\omega) \quad \forall \omega \in \Omega$$

Erwartete Auszahlung als arithmetisches Mittel:

$$\mathbb{E}[Y] = \sum_{\omega \in \Omega} Y(\omega) \mu(\omega) = \frac{k + 5 \cdot 6}{6} = 6 \cdot \frac{5}{6} + k \cdot \frac{1}{6} = 6 \cdot \mathbb{P}(Y = 6) + k \cdot \mathbb{P}(Y = k) = \sum_{I \in Y(\Omega)} I \cdot \mathbb{P}(Y = I)$$

### Karteikarte 7.1 Wieso reicht es oft aus, nur die Verteilung einer Zufallsvariablen zu kennen?

Weil alle Wahrscheinlichkeitsaussagen über  $X$  (z.B.  $P(X \in A)$ ) nur von der Verteilung  $P_X$  abhängen, nicht vom konkreten Wahrscheinlichkeitsraum. Haben  $X$  und  $Y$  dieselbe Verteilung, so gilt  $P(X \in A) = P_X(A) = P_Y(A) = P(Y \in A)$  für jedes  $A$ .

## 7.1 | Definition und Existenz des Erwartungswerts

**Definition 7.1** (2025) Der Erwartungswert einer Zufallsvariable  $X$  mit abzählbarem Bildbereich  $X(\Omega) \in \mathbb{R}$  ist gegeben durch

$$\mathbb{E}[X] = \mathbb{E}X = \sum_{x \in X(\Omega)} x \cdot \mathbb{P}(X = x)$$

insofern die Reihe absolut konvergiert, also  $\sum_{x \in X(\Omega)} |x| \cdot \mathbb{P}(X = x) < \infty$ .

Wir sprechen in diesem Fall von der Existenz des Erwartungswerts.

Der Erwartungswert einer Zufallsvariable  $X$  mit einer Dichte  $f$  ist gegeben durch

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x) dx = \lim_{N \rightarrow \infty} \int_{-N}^N x f(x) dx$$

insofern  $\int_{-\infty}^{\infty} |x| f(x) dx < \infty$ .

Wir sprechen in diesem Fall von der Existenz des Erwartungswerts.

**Hinweis:** Für Dichten  $f$ , die gerade Funktionen sind, gilt  $\int_{-N}^N x f(x) dx = 0$  für alle  $N$ , auch wenn der Erwartungswert ggf. gar nicht existiert.

**Bemerkung 7.1** (2026) Absolute Konvergenz der Reihe, die den Erwartungswert definiert, garantiert, dass wir die Summanden beliebig umsortieren dürfen. Es gilt daher

$$\mathbb{E}[X] \stackrel{\text{Def.}}{=} \sum_{x \in X(\Omega)} x \mathbb{P}(X = x) = \sum_{x \in \Omega} X(\omega) \mu(\omega)$$

sofern eine der Reihen absolut konvergent ist. (Vgl. obiges Bsp. mit dem Spiel.)

Wenn  $\Omega$  oder  $X(\Omega)$  endlich ist, so existiert der Erwartungswert automatisch.

Nimmt  $X$  nur nichtnegative Werte an, können wir einfach anfangen, den Erwartungswert auszurechnen, weil

$$\sum_{x \in X(\Omega)} |x| \mathbb{P}(X = x) = \sum_{x \in X(\Omega)} x \mathbb{P}(X = x)$$

bzw.

$$\int_{-\infty}^{\infty} |x| f(x) dx = \int_{-\infty}^{\infty} x f(x) dx = \int_0^{\infty} x f(x) dx$$

**Karteikarte 7.2** Wie ist der Erwartungswert einer Zufallsvariablen  $X$  mit abzählbarem Bildbereich definiert, und wann existiert er?

$E[X] = \sum_{x \in X(\Omega)} x \cdot P(X = x)$ , sofern die Reihe absolut konvergiert, d.h.  $\sum_{x \in X(\Omega)} |x| \cdot P(X = x) < \infty$ . Nur dann sprechen wir von der Existenz des Erwartungswerts..

**Karteikarte 7.3** Wie ist der Erwartungswert einer Zufallsvariablen  $X$  mit Dichte  $f$  definiert, und wann existiert er?

$E[X] = \int_{-\infty}^{\infty} x f(x) dx$ , sofern  $\int_{-\infty}^{\infty} |x| f(x) dx < \infty$ . Nur dann existiert der Erwartungswert..

**Karteikarte 7.4** Warum ist bei einer geraden Dichtefunktion  $f$  Vorsicht geboten, wenn man den Erwartungswert über symmetrische Integrationsgrenzen  $\pm N$  berechnet?

Für gerade Dichten gilt  $\int_{-N}^N x f(x) dx = 0$  für jedes  $N$  – auch dann, wenn der Erwartungswert gar nicht existiert (weil das uneigentliche Integral nicht absolut konvergiert). Symmetrische Grenzen können Existenz also vortäuschen, wo keine vorliegt..

**Karteikarte 7.5** Was garantiert die absolute Konvergenz der den Erwartungswert definierenden Reihe, und welche alternative Summationsform folgt daraus?

Absolute Konvergenz erlaubt beliebiges Umsortieren der Summanden. Deshalb gilt  $\sum_{x \in X(\Omega)} x \cdot P(X = x) = \sum_{\omega \in \Omega} X(\omega) \cdot P(\{\omega\})$ , sofern eine der beiden Reihen absolut konvergiert – man kann also wahlweise über die Werte von  $X$  oder über die Elementarereignisse summieren..

**Karteikarte 7.6** In welchen zwei Spezialfällen ist die Existenz des Erwartungswerts automatisch gesichert bzw. einfacher zu prüfen?

(1) Ist  $\Omega$  oder  $X(\Omega)$  endlich, existiert der Erwartungswert automatisch. (2) Nimmt  $X$  nur nichtnegative Werte an ( $X \geq 0$ ), fallen die Beträge weg:  $\sum |x|P(X = x) = \sum xP(X = x)$  (analog fürs Integral) – man kann also direkt mit der Berechnung beginnen, ohne getrennt Konvergenz nachzuweisen..

**Beispiel 7.4** Erwartungswert der Poisson-Verteilung (2026)

$X$  Poisson-verteilt, d.h., es existiert ein  $\lambda > 0$  mit

$$\mu_X(k) = \mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} \quad \text{für alle } k \in \mathbb{N}_0 = \{0, 1, 2, 3, \dots\}$$

Der Erwartungswert existiert, weil die folgende Rechnung ein endliches Ergebnis hat:

(Wir verwenden in dieser Argumentation, dass  $X$  nur nichtnegative Werte hat, d.h.,  $X \geq 0$ .)

$$\begin{aligned} \mathbb{E}[X] &\stackrel{*1}{=} \sum_{k=0}^{\infty} k \mathbb{P}(X = k) \\ &\stackrel{*2}{=} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \sum_{k=1}^{\infty} k \cdot \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} e^{-\lambda} \\ &= \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \\ &= \lambda e^{-\lambda} \underbrace{\sum_{l=0}^{\infty} \frac{\lambda^l}{l!}}_{=e^{\lambda}} \\ &= \lambda \end{aligned}$$

$$*1 \quad X(\Omega) = \mathbb{N}_0$$

$$*2 \quad \mathbb{P}(X = k) = \mu_X(k) = \dots$$

**Beispiel 7.5** Erwartungswert der geometrischen Verteilung (2026)

Wie lange müssen wir im Mittel warten, bis der erste Erfolg eintritt? (Zum Beispiel bis zur ersten Sechse beim Werfen eines fairen Würfels? – Raten Sie!)

$X$  geometrisch verteilt mit Erfolgswahrscheinlichkeit  $p \in (0, 1)$ , d.h.,

$$\mu_X(k) = \mathbb{P}(X = k) = p(1-p)^{k-1} \quad \text{für alle } k \in \mathbb{N}_0 = \{0, 1, 2, 3, \dots\}$$

Der Erwartungswert existiert, weil die folgende Rechnung ein endliches Ergebnis hat (Wir verwenden wieder, dass  $X \geq 0$ )).

$$h(x) = x^k \Rightarrow h'(x) = kx^{k-1}$$

$$\begin{aligned}
\mathbb{E}[X] &\stackrel{*1}{=} \sum_{k=1}^{\infty} k p (1-p)^{k-1} \\
&= p \sum_{k=1}^{\infty} \left( \frac{d}{dx} x^k \right) \Big|_{x=1-p} \\
&\stackrel{*2}{=} p \frac{d}{dx} \sum_{k=1}^{\infty} (x^k) \Big|_{x=1-p} \\
&= p \frac{d}{dx} \sum_{k=0}^{\infty} (x^k) \Big|_{x=1-p} \\
&= p \frac{d}{dx} \left( \frac{1}{1-x} \right) \Big|_{x=1-p} \\
&= p \frac{1}{(1-x)^2} \Big|_{x=1-p} \\
&= \frac{1}{p}
\end{aligned}$$

\*1 Definition Erwartungswert

\*2 gilt, weil gliedweises Differenzieren einer Potenzreihe im Innern ihres Konvergenzradius zulässig ist

### Beispiel 7.6 Erwartungswert der uniformen Verteilung auf [a, b] (2026)

(Raten. – Warum ist der Erwartungswert  $(a + b)/2$  ?)

Der Erwartungswert existiert, weil... Denn: Zu prüfen ist:  $\int_{-\infty}^{\infty} |x|f(x) dx < \infty$  für  $f(x) = \frac{1}{b-a} \mathbb{1}_{[a,b]}(x)$ .

Hier ist  $f(x) = 0$  außerhalb eines kompakten Intervalls (abgeschlossen und beschränkt).

$$\int_{-\infty}^{\infty} |x|f(x) dx = \int_a^b \frac{|x|}{b-a} dx \leq \int_a^b \frac{\max\{|a|, |b|\}}{b-a} dx = \max\{|a|, |b|\} \cdot 1 < \infty$$

...f stetig ist auf dem kompakten Intervall [a, b] und f = 0 außerhalb des Intervalls [a, b] gilt.

$$\mathbb{E}[X] = \int_a^b x \frac{1}{b-a} dx = \frac{1}{2(b-a)} x^2 \Big|_{x=a}^b = \frac{b^2 - a^2}{2(b-a)} = \underbrace{\frac{a+b}{2}}_*$$

\* Mittelpunkt des Intervalls

Erinnerung:  $\int_a^b x dx = \frac{x^2}{2} \Big|_{x=a}^b$

### Beispiel 7.7 Erwartungswert der Exponentialverteilung (2026)

Erinnerung:

$$F(x) := -e^{-\alpha x}, \quad F'(x) := \alpha e^{-\alpha x}, \quad \mathbb{E}[X] = \frac{1}{\alpha}$$

Der Erwartungswert existiert genau dann, wenn die folgende Berechnung einen endlichen Wert ergibt (was der



Fall ist, wir verwenden wieder, dass  $X \geq 0$ ):

$$\begin{aligned}
 \mathbb{E}[X] &= \int_0^\infty \underbrace{x}_{\downarrow} \underbrace{\alpha e^{-\alpha x}}_{\uparrow} dx \\
 &= - \lim_{N \rightarrow \infty} \underbrace{x e^{-\alpha x}}_{=0} \Big|_{x=0}^N + \int_0^\infty \underbrace{1 \cdot e^{-\alpha x}}_{=f(x) \cdot \frac{1}{\alpha}} dx \\
 &= 0 + \frac{1}{\alpha} \underbrace{\int_{-\infty}^\infty f(x) dx}_{=1} \\
 &= \frac{1}{\alpha}^*
 \end{aligned}$$

$$\begin{aligned}
 *f(x) &= \alpha e^{-\alpha x}_{[0,\infty)}(x) \\
 \Rightarrow \int_0^\infty e^{-\alpha x} dx &= \frac{1}{\alpha} \int_0^\infty \alpha e^{-\alpha x} dx \\
 &= \frac{1}{\alpha} \int_{-\infty}^\infty f(x) dx \\
 &= \frac{1}{\alpha}
 \end{aligned}$$

### 7.1.1 | Rechenregeln für den Erwartungswert

#### Satz 7.1 Der Erwartungswert ist linear (2026)

Geg.  $Z, X : \Omega \rightarrow \mathbb{R}$  und  $Y : \Omega \rightarrow \mathbb{R}$  auf  $(\Omega, \mathbb{P})$ ; Konstanten  $a, b \in \mathbb{R}$ .

Annahme:  $\mathbb{E}[X]$  und  $\mathbb{E}[Y]$  existieren.

Dann gelten  $aX + bY$  ist ebenfalls eine Zufallsvariable. Der Erwartungswert von  $aX + bY$  existiert und berechnet sich als

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

**Beweis (für Zufallsvariable mit abzählbarem Bildbereich)** Nehmen wir zunächst an, der Erwartungswert von  $aX + bY$  existiert. Dann dürfen alle Reihen beliebig umsortiert werden:

$$\begin{aligned}
 \mathbb{E}[aX + bY] &= \sum_{\omega \in \Omega} [aX(\omega) + bY(\omega)] \mu(\omega) \\
 &= a \sum_{\omega \in \Omega} X(\omega) \mu(\omega) + b \sum_{\omega \in \Omega} Y(\omega) \mu(\omega) \\
 &= a\mathbb{E}[X] + b\mathbb{E}[Y]
 \end{aligned}$$

Eine analoge Rechnung mit Betragszeichen und Abschätzungen zeigt die Existenz des Erwartungswerts:

$$\sum_{\omega \in \Omega} \underbrace{|aX(\omega) + bY(\omega)|}_{\leq |a||X(\omega)| + |b||Y(\omega)|} \mu(\omega) \leq |a| \underbrace{\sum_{\omega \in \Omega} |X(\omega)| \mu(\omega)}_{< \infty \text{ unab. Ver.}} + |b| \underbrace{\sum_{\omega \in \Omega} |Y(\omega)| \mu(\omega)}_{< \infty \text{ unab. Ver.}} < \infty$$

da nach Voraussetzung  $\mathbb{E}[X]$  und  $\mathbb{E}[Y]$  existieren.

**Beispiel 7.8** Augensumme bei mehrfachem Würfeln mit fairem Würfel (2026)

$$\Omega = \{1, \dots, 6\}^n$$

mit Gleichverteilung  $P$ .

Für  $i = 1, \dots, n$  sei

$$X_i(\omega) = \omega_i,$$

wobei  $\omega = (\omega_1, \dots, \omega_n) \in \Omega$ .

Die Zufallsvariable

$$X = \sum_{i=1}^n X_i$$

beschreibt die Augensumme (Und  $X_i$  das Ergebnis des  $i$ -ten Wurfs).

**Berechnung der erwarteten Augensumme für zweimaliges Würfeln ( $n = 2$ ):**

Direkt über die Verteilung:

$$\mathbb{E}[X] = \sum_{i=2}^{12} i \mathbb{P}(X_1 + X_2 = i) = \dots$$

was etwas aufwendig ist.

Alternativ:

$$\begin{aligned} \mathbb{E}[X] &= \sum_{\omega \in \Omega} (X_1(\omega) + X_2(\omega)) \mu(\omega) \\ &= \frac{1}{36} \sum_{\omega_1, \omega_2=1}^6 [\omega_1 + \omega_2] \\ &= \frac{1}{36} \sum_{\omega_1=1}^6 \sum_{\omega_2=1}^6 (\omega_1 + \omega_2) \\ &= \frac{1}{36} \left[ 6 \sum_{\omega_1=1}^6 \omega_1 + 6 \sum_{\omega_2=1}^6 \omega_2 \right] \\ &= \frac{1}{36} (6 \cdot 21 + 6 \cdot 21) = 7. \end{aligned}$$

Mit der Linearität des Erwartungswertes erhält man sofort:

$$\mathbb{E}[X] = \mathbb{E}[X_1] + \mathbb{E}[X_2] = 2 \cdot 3,5 = 7.$$

Dies verallgemeinert sich unmittelbar auf  $n$ -maliges Würfeln:

$$\mathbb{E}[X] = \mathbb{E}[X_1 + \dots + X_n] = \mathbb{E}[X_1] + \dots + \mathbb{E}[X_n] = n \cdot \frac{7}{2}.$$

**Beispiel 7.9** Binomialverteilung  $\mathbb{E}[X] = n \cdot p$  (2026)

$$X(\Omega) = \{0, \dots, n\}, \quad \#X(\Omega) = n + 1 < \infty$$

- $X$  sei binomialverteilt mit den Parametern  $n$  und  $p$ .
- Der Erwartungswert\* von  $X$  existiert, da der Bildbereich von  $X$  endlich ist.

erwartete Anzahl an Erfolgen in einem  $n$ -fach unabhängig wiederholten Bernoulli-Experiment

**1. Versuch** (mit binomischer Formel und etwas Geschick)

$$\mathbb{E}[X] = \sum_{k=0}^n k \underbrace{\binom{n}{k} p^k (1-p)^{n-k}}_{=\mathbb{P}(X=x)} = \dots$$

**2. Versuch** Wähle

$$\Omega = \{0, 1\}^n.$$

Die Anzahl der Erfolge lässt sich darstellen als

$$X = \sum_{i=1}^n X_i,$$

wobei

$$X_i(\omega) = \omega_i.$$

Für jede Indikatorvariable gilt

$$\mathbb{E}[X_i] = 0 \cdot \mathbb{P}(X_i = 0) + 1 \cdot \mathbb{P}(X_i = 1) = p.$$

Mit der Linearität des Erwartungswertes folgt unmittelbar:

$$\mathbb{E}[X] = \sum_{i=1}^n \underbrace{\mathbb{E}[X_i]}_{=p} = \sum_{i=1}^n p = np.$$

**Beispiel 7.10** St. Petersburg Paradoxon (Erwartungswert muss nicht existieren) (2026)

Ein Casino möchte folgendes Spiel anbieten: Eine faire Münze wird geworfen, bis zum ersten Mal Kopf erscheint. Passiert dies beim  $n$ -ten Wurf, so sei die Auszahlung  $X = 2^n$

$$\Omega = \mathbb{N}, \quad \mu(n) = p(1-p)^{n-1}, \quad p = \frac{1}{2}.$$

Die Zufallsvariable  $X : \Omega \rightarrow \mathbb{R}$  sei definiert durch  $X(n) = 2^n$  (Auszahlung) für alle  $n \in \Omega$

$$\mu_X(2^n) = \mathbb{P}(\underbrace{X = 2^n}_{\text{Kopf erstmalig im } n\text{-ten Wurf}}) = \mu(n) = p(1-p)^{n-1} = 2^{-n}, \quad n \in \Omega = \mathbb{N}.$$

$$\mu(n) = \left(\frac{1}{2}\right)^n = 2^{-n} \quad \forall n \in \Omega = \mathbb{N}$$

Was wäre ein fairer Einsatz für dieses Spiel? (Wir nennen den Einsatz fair, wenn der Einsatz gleich der erwarteten Auszahlung ist.)

Wir suchen also  $\mathbb{E}[X]$

$X \geq 0$ , EW existiert genau dann, wenn Rechnung endliches Ergebnis hat

Nun ist jedoch

$$\sum_{n=1}^{\infty} 2^n \mathbb{P}(X = 2^n) = \sum_{n=1}^{\infty} 2^n \mu_X(2^n) = \sum_{n=1}^{\infty} 2^n 2^{-n} = \sum_{n=1}^{\infty} 1 = \infty$$

Der Erwartungswert existiert also nicht. Ein fairer Einsatz kann nicht bestimmt werden.

**Erinnerung 7.1** (2026)

Aus Satz (E), d.h. der Linearität des Erwartungswertes, folgen:

$$\mathbb{E}[aX] = a\mathbb{E}[X] \quad \text{und} \quad \mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$$

für  $a \in \mathbb{R}$  und  $\mathbb{R}$ -wertige  $X$  und  $Y$  mit existierendem Erwartungswert

**Frage 7.1** (2026) Gilt auch  $\mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y]$ ?

Spezialfall  $X = Y$ :  $\mathbb{E}[E^2] = (\mathbb{E}[X])^2$ .

Gilt das?

**Beispiel 7.11** (2026) Es gibt Zufallsvariablen  $X, Y$  mit

$$\mathbb{E}[X \cdot Y] \neq \mathbb{E}[X] \cdot \mathbb{E}[Y].$$

Wähle

$$\mathbb{P}(X = +1) = \mathbb{P}(X = -1) = \frac{1}{2}$$

und

$$Y = X.$$

Dann gilt

$$\mathbb{E}[X] = \mathbb{E}[Y] = 0$$

und

$$\mathbb{E}[XY] = \mathbb{E}[X^2] = \mathbb{E}[1] = 1.$$

**Satz 7.2** Satz (P) (2026)

Seien

$$X : \Omega \rightarrow \mathbb{R} \quad \text{und} \quad Y : \Omega \rightarrow \mathbb{R}$$

zwei unabhängige Zufallsvariablen, deren Erwartungswerte existieren.

Dann existiert auch der Erwartungswert von  $X \cdot Y$ , und es gilt

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y].$$

**Beweis.**

**Schritt 1:** Wir nehmen zunächst an, dass der Erwartungswert von  $X \cdot Y$  existiert.

Wir beginnen mit der folgenden Darstellung. Für  $z \neq 0$  gilt: ( $xy = z$ )

$$\begin{aligned} \mathbb{P}(XY = z) &= \sum_{y \neq 0}^* \mathbb{P}(XY = z \mid Y = y) \mathbb{P}(Y = y) \\ &= \sum_{y \neq 0} P\left(X = \frac{z}{y} \mid Y = y\right) \mathbb{P}(Y = y) \\ &= \sum_{y \neq 0} P\left(X = \frac{z}{y}\right) \mathbb{P}(Y = y), \end{aligned}$$

da  $X$  und  $Y$  unabhängig sind.

$$\mathbb{P}(X \cdot Y = z) = \sum_{y \in Y(\Omega)} \mathbb{P}(X \cdot Y = z, Y = y) \stackrel{z \neq 0}{=} \sum_{y \in Y(\Omega), y \neq 0} \mathbb{P}(X \cdot Y = z \mid Y = y) \cdot \mathbb{P}(Y = y)$$

Aus

$$\mathbb{P}(XY = z) = \sum_{y \neq 0} P\left(X = \frac{z}{y}\right) \mathbb{P}(Y = y), \quad z \neq 0,$$

folgt

$$\begin{aligned}
 \mathbb{E}[XY] &= \sum_{z \in XY(\Omega), z \neq 0} z \mathbb{P}(XY = z) \\
 &= \sum_{z \neq 0} \sum_{y \neq 0} \frac{z}{y} y P\left(X = \frac{z}{y}\right) \mathbb{P}(Y = y) \\
 &= \sum_{y \neq 0} \sum_{x \neq 0} xy \mathbb{P}(X = x) \mathbb{P}(Y = y) \\
 &= \left( \sum_{y \neq 0} y \mathbb{P}(Y = y) \right) \left( \sum_{x \neq 0} x \mathbb{P}(X = x) \right) \\
 &= \mathbb{E}[X] \cdot \mathbb{E}[Y]
 \end{aligned}$$

**Schritt 2:** Eine analoge Rechnung zeigt die Existenz des Erwartungswerts:

**Satz 7.3**    **Kurzfassung Satz (P)**    (2026)

$$X, Y \text{ unabhängig mit ex. EW} \implies \mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y].$$

**Beispiel 7.12**    (2026)

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$$

impliziert nicht, dass  $X$  und  $Y$  unabhängig sind.

- Definiere Hilfszufallsvariablen  $X_1$  und  $Y_1$ , unabhängig mit

$$\mathbb{P}(X_1 = 0) = \mathbb{P}(X_1 = 1) = \frac{1}{2}$$

und

$$\mathbb{P}(Y_1 = 0) = \mathbb{P}(Y_1 = 1) = \frac{1}{2}.$$

- Setze

$$X := X_1 + Y_1, \quad Y := |X_1 - Y_1|.$$

**Beobachtungen**

- Bildbereiche:

$$X(\Omega) = \{0, 1, 2\}, \quad Y(\Omega) = \{0, 1\}.$$

- 

$$Y = 0 \iff X_1 = Y_1 \iff X \in \{0, 2\}.$$

- 

$$Y = 1 \iff X_1 \neq Y_1 \iff X = 1.$$

$X$  und  $Y$  sind nicht unabhängig.

$$\mathbb{P}(X = 1, Y = 0) = 0,$$

da

$$\{X = 1, Y = 0\} = \emptyset.$$

Andererseits gilt

$$\mathbb{P}(X = 1) = 2 \cdot \frac{1}{4} > 0$$

und

$$\mathbb{P}(Y = 0) = 2 \cdot \frac{1}{4} > 0.$$

Dennoch gilt  $\mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y]$ .

$$\begin{aligned} \mathbb{E}[XY] &= 0 \cdot \mathbb{P}(XY = 0) + 1 \cdot \mathbb{P}(XY = 1) + 2 \cdot \mathbb{P}(XY = 2) \\ &= 0 + \mathbb{P}(X = 1) + 0 \\ &= \frac{1}{2}. \end{aligned}$$

Außerdem

$$\begin{aligned} \mathbb{E}[X] \mathbb{E}[Y] &= (\mathbb{E}[X_1] + \mathbb{E}[Y_1]) \mathbb{P}(Y = 1) \\ &= 2 \mathbb{E}[X_1] \mathbb{P}(X = 1) \\ &= 2 \cdot \frac{1}{2} \cdot \frac{1}{2} \\ &= \frac{1}{2}. \end{aligned}$$

### Bemerkung 7.2 (2026)

Der Satz kann nicht nur zum Berechnen von Erwartungswerten von Produkten unabhängiger Zufallsvariablen verwendet werden, sondern kann auch benutzt werden, um zu zeigen, dass zwei Zufallsvariablen nicht unabhängig sein können, wenn der Erwartungswert des Produkts der Zufallsvariablen nicht ins Produkt der einzelnen Erwartungswerte zerfällt.

### Definition 7.2 Zusammengesetzte Zufallsvariablen (2026)

Eine Zufallsvariable  $X : \Omega \rightarrow \mathbb{R}$  und eine messbare Funktion  $f : \mathbb{R} \rightarrow \mathbb{R}$  können zusammengesetzt werden zu einer neuen Zufallsvariablen:

$$Y(\omega) = (f \circ X)(\omega) = f(X(\omega))$$

$$Y(\omega) = f(X(\omega)) \quad \forall \omega$$

### Satz 7.4 (2026)

Sofern der Erwartungswert  $\mathbb{E}[Y]$  existiert, gilt

$$\mathbb{E}[Y] = \sum_{x \in X(\Omega)} f(x) \mathbb{P}(X = x)$$

bzw., falls  $X$  Dichte  $d$  hat und EW von  $Y$  gleich  $f(x)$  existiert

$$\mathbb{E}[Y] = \int_{-\infty}^{\infty} f(x) d(x) dx$$

**Beweis.**

$$\begin{aligned}
 \mathbb{E}[Y] &= \sum_{y \in Y(\Omega)} y \mathbb{P}(Y = y) \\
 &= \sum_{y \in Y(\Omega)} y \sum_{x \in X(\Omega): f(x)=y} \mathbb{P}(X = x) \\
 &= \sum_{y \in Y(\Omega)} \sum_{x \in X(\Omega): f(x)=y} \underbrace{y}_{=f(x)} \mathbb{P}(X = x) \\
 &= \sum_{y \in Y(\Omega)} \sum_{x \in X(\Omega): f(x)=y} f(x) \mathbb{P}(X = x) \\
 &= \sum_{x \in X(\Omega)} f(x) \mathbb{P}(X = x) \\
 &= \mathbb{E}[f(x)]
 \end{aligned}$$

$$*Y = y \Leftrightarrow f(x) = y, \quad \mathbb{P}(Y = y) = \sum_{x \in X(\Omega): f(x)=y} \mathbb{P}(X = x)$$

**Beispiel 7.13** Zu Satz 7.4.

Mit  $f(x) = x^2$

**Karteikarte 7.7** Wie lautet der Satz über die Linearität des Erwartungswerts?

Existieren  $E[X]$  und  $E[Y]$ , so existiert für  $a, b \in \mathbb{R}$  auch  $E[aX + bY]$ , und es gilt  $E[aX + bY] = aE[X] + bE[Y]$ . Als Spezialfälle folgen  $E[aX] = aE[X]$  und  $E[X + Y] = E[X] + E[Y]$ .

**Karteikarte 7.8** Welchen praktischen Vorteil bietet die Linearität des Erwartungswerts bei Summen von Zufallsvariablen?

Statt  $E[X]$  für  $X = X_1 + \dots + X_n$  direkt über die (oft komplizierte) gemeinsame Verteilung zu berechnen, genügt es, die meist viel einfacheren Erwartungswerte der einzelnen  $X_i$  zu bestimmen und zu addieren:  $E[X] = \sum_i E[X_i]$ . Das funktioniert auch OHNE Unabhängigkeit der  $X_i$ .

**Karteikarte 7.9** Was versteht man unter einer aus  $X$  zusammengesetzten Zufallsvariablen  $Y = f(X)$ ?

Ist  $X : \Omega \rightarrow \mathbb{R}$  eine Zufallsvariable und  $f : \mathbb{R} \rightarrow \mathbb{R}$  eine (messbare) Funktion, so ist  $Y(\omega) := f(X(\omega)) = (f \circ X)(\omega)$  wieder eine Zufallsvariable..

**Karteikarte 7.10** Wie berechnet man  $E[f(X)]$ , ohne die Verteilung von  $Y = f(X)$  explizit zu bestimmen?

Sofern  $E[Y]$  existiert, gilt  $E[f(X)] = \sum_{x \in X(\Omega)} f(x) \cdot P(X = x)$  (diskreter Fall) bzw.  $E[f(X)] = \int_{-\infty}^{\infty} f(x) f_X(x) dx$  (falls  $X$  die Dichte  $f_X$  hat). Man muss die Verteilung von  $Y$  also nicht erst bestimmen..

**Karteikarte 7.11** Gilt allgemein  $E[XY] = E[X] \cdot E[Y]$  für beliebige Zufallsvariablen  $X, Y$ ?

Nein, im Allgemeinen nicht. Schon im einfachen Fall  $Y = X$  kann  $E[XY] \neq E[X] \cdot E[Y]$  gelten. Multiplikativität des Erwartungswerts benötigt eine Zusatzvoraussetzung – siehe Satz (P)..

**Karteikarte 7.12** Unter welcher Voraussetzung gilt  $E[XY] = E[X] \cdot E[Y]$ ? (Satz (P))

Sind  $X, Y$  unabhängige Zufallsvariablen mit existierendem Erwartungswert, so existiert auch  $E[XY]$ , und es gilt

$$E[XY] = E[X] \cdot E[Y]..$$

**Karteikarte 7.13** Wie kann man Satz (P) nutzen, um zu zeigen, dass zwei Zufallsvariablen NICHT unabhängig sind?

Per Kontraposition: Gilt  $E[XY] \neq E[X] \cdot E[Y]$  (zerfällt der Erwartungswert des Produkts also nicht in das Produkt der einzelnen Erwartungswerte), so können  $X$  und  $Y$  nicht unabhängig sein..

**Karteikarte 7.14** Folgt aus  $E[XY] = E[X] \cdot E[Y]$ , dass  $X$  und  $Y$  unabhängig sind?

Nein. Die Umkehrung von Satz (P) gilt nicht: Es gibt abhängige Zufallsvariablen  $X, Y$ , die dennoch  $E[XY] = E[X] \cdot E[Y]$  erfüllen. Aus der Produktformel für Erwartungswerte kann man also nicht auf Unabhängigkeit schließen..

**Karteikarte 7.15** Muss der Erwartungswert einer Zufallsvariablen  $X$  immer existieren, selbst wenn  $X \geq 0$  gilt?

Nein. Es gibt Zufallsvariablen  $X \geq 0$ , bei denen die Reihe bzw. das Integral zur Definition von  $E[X]$  divergiert (Stichwort: St.-Petersburg-Paradoxon). In solchen Fällen existiert kein endlicher Erwartungswert, und darauf aufbauende Begriffe (z.B. ein "fairer Einsatz") lassen sich nicht sinnvoll bestimmen..

## 7.2 | Varianz

**Definition 7.3**  $n$ -tes Moment von  $X$  (2026)

Für  $n \in \mathbb{N}$  heißt  $\mathbb{E}[X^n]$  das erste  $n$ -te Moment von  $X$ , insofern  $\mathbb{E}[|X|^n] < \infty$ . (Erwartungswert ist das 1. Moment)

**Definition 7.4** (2026)  $\mathbb{E}[(X - \mathbb{E}[X])^n]$  heißt das  $n$ -te zentrierte Moment von  $X$ . Es existiert, wenn  $\mathbb{E}[|X|^n] < \infty$ .

**Definition 7.5** (2026) Die Varianz von  $X$  ist das 2 zentrierte Moment, d.h.

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

(mittlere quadratische Abweichung)

Die Varianz von  $X$  existiert, wenn  $\text{Var}(X) < \infty$ .

Die Varianz einer Zufallsvariable  $X$  mit existierendem Erwartungswert ist gegeben durch

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x)$$

(gewichtete quadratische Abweichung vom Erwartungswert) bzw.

$$\text{Var}(X) = \int_{-\infty}^{\infty} \underbrace{(x - \mathbb{E}[X])^2}_{f(x)} d(x) = \int_{-\infty}^{\infty} f(x) d(x)$$

**Bemerkung 7.3** (2026)  $\text{Var}(X) \geq 0$

**Definition 7.6** Existierende Varianz (2025)



Wir sagen, dass die Varianz existiert, wenn

$$\text{Var}(X) = \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x) < \infty$$

bzw.

$$\int_{-\infty}^{\infty} (x - \mathbb{E}[X])^2 d(x) < \infty$$

### Beispiel 7.14 Bsp. (2026)

Seien  $X, Y$  Zufallsvariablen mit

$$\mathbb{P}(X = +1) = \frac{1}{2} = \mathbb{P}(X = -1)$$

und

$$Y = 100 \cdot X.$$

**Anhand des Erwartungswertes: kein Unterschied!**

$$\mathbb{E}[X] = 1 \cdot \mathbb{P}(X = 1) + (-1) \cdot \mathbb{P}(X = -1) = 1 \cdot \frac{1}{2} - 1 \cdot \frac{1}{2} = 0.$$

Da  $Y = 100X$  gilt,

$$\mathbb{E}[Y] = 100 \cdot \mathbb{E}[X] = 0.$$

**Die Varianz zeigt den Unterschied:**

da  $\mathbb{E}[X] = 0$ ,

$$\text{Var}(X) = \mathbb{E} \left[ \underbrace{(X - \mathbb{E}[X])^2}_{=0} \right] = \mathbb{E} \left[ \underbrace{X^2}_1 \right] = \mathbb{E}[1] = 1$$

Wegen  $X \in \{-1, 1\}$  ist

$$X^2 = 1,$$

also

$$\text{Var}(X) = \mathbb{E}[1] = 1.$$

Ebenso gilt wegen  $\mathbb{E}[Y] = 0$ ,

$$\text{Var}(Y) = \mathbb{E}[(Y - \mathbb{E}[Y])^2] = \mathbb{E}[Y^2] = \mathbb{E}[(100X)^2]$$

Damit folgt

$$\text{Var}(Y) = \mathbb{E}[100^2 X^2] = 100^2 \mathbb{E}[X^2] = 100^2.$$

### Beispiel 7.15 Bernoulli-Variable (Spezialfall der Binomialverteilung mit $n = 1$ ) (2026)

Zufallsvariable  $X$  mit  $\mathbb{P}(X = +1) = p = 1 - \mathbb{P}(X = 0)$  für Erfolgswahrscheinlichkeit  $p \in [0, 1]$  und  $\mathbb{E}[X] = p$ .

$Var(X)$  existiert, da

$$\begin{aligned}
 Var(X) &= \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x) \\
 &= (0 - \underbrace{\mathbb{E}[X] = p})^2 \underbrace{\mathbb{P}(X = 0)} = 1 - p + (1 - \underbrace{\mathbb{E}[X] = p})^2 \underbrace{\mathbb{P}(X = 1)} = p \\
 &= p^2(1 - p) + (1 - p)^2 p \\
 &= p(1 - p)[p + (1 - p)] \\
 &= p(1 - p) < \infty
 \end{aligned}$$

$$\begin{aligned}
 Var(X) &= (1 - \mathbb{E}[X])^2 p + (0 - \mathbb{E}[X])^2 (1 - p) \\
 &= (1 - p)^2 p + p^2 (1 - p) \\
 &= p(1 - p)
 \end{aligned}$$

**Beispiel 7.16** gleichverteilte Zufallsvariable auf  $\{1, \dots, n\}$  (2026)

Zufallsvariable  $X$  mit  $\mathbb{P}(X = k) = \frac{1}{n}$  für  $k = 1, \dots, n$

$$\mathbb{E}[X] = \sum_{k=1}^n k \cdot \frac{1}{n} = \frac{n(n+1)}{2n} = \frac{n+1}{2}$$

und

$$Var(X) = \frac{n^2 - 1}{12}$$

weil

$$\begin{aligned}
 Var(X) &= \frac{1}{n} \sum_{k=1}^n (k - \mathbb{E}[X])^2 \\
 &= \frac{1}{n} \sum_{k=1}^n (k^2 - 2k\mathbb{E}[X] + \mathbb{E}[X]^2) \\
 &= \frac{1}{n} \sum_{k=1}^n k^2 - 2\mathbb{E}[X] \cdot \underbrace{\frac{1}{n} \sum_{k=1}^n k}_{=\mathbb{E}[X]} + \mathbb{E}[X]^2 \\
 &= \frac{(n+1)(2n+1)}{6} - \mathbb{E}[X]^2 \\
 &= \frac{n^2 - 1}{12}
 \end{aligned}$$

**Lemma 7.1** Technisches Lemma (2026)

Für alle  $a \in \mathbb{R}$  gilt  $\mathbb{E}[(X - a)^2] = Var(X) + (\mathbb{E}[X] - a)^2$

**Beweis** TODO F 76

**Folgerung 7.1** Folgerung I (2026)

$a \Leftrightarrow \mathbb{E}[(X - a)^2]$  wird minimal für  $a = \mathbb{E}[X]$ .

In diesem Fall ist  $\mathbb{E}[(X - a)^2] = Var(X)$  per Definition der Varianz.

**Folgerung 7.2** Folgerung II und wichtige Rechenregel (2026)

Die Wahl  $a = 0$  zeigt

$$0 \leq \text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Es gilt daher stets  $(\mathbb{E}[X])^2 \leq \mathbb{E}[X^2]$ .

**Karteikarte 7.16** Was ist das  $n$ -te Moment einer Zufallsvariablen  $X$ ?

$E[X^n]$ , sofern  $E[|X|^n] < \infty$ . Das 1. Moment ist der Erwartungswert..

**Karteikarte 7.17** Was ist das  $n$ -te zentrierte Moment einer Zufallsvariablen  $X$ ?

$E[(X - E[X])^n]$ , sofern  $E[|X|^n] < \infty$  (bzw. sofern es existiert)..

**Karteikarte 7.18** Was ist die Varianz einer Zufallsvariablen  $X$ , und wie berechnet man sie im diskreten Fall bzw. bei einer Dichte?

Die Varianz ist das 2. zentrierte Moment:  $\text{Var}(X) = E[(X - E[X])^2]$  (mittlere quadratische Abweichung vom Erwartungswert). Diskret:  $\text{Var}(X) = \sum_{x \in X(\Omega)} (x - E[X])^2 P(X = x)$ . Bei Dichte  $f$ :  $\text{Var}(X) = \int_{-\infty}^{\infty} (x - E[X])^2 f(x) dx$ ..

**Karteikarte 7.19** Welches Vorzeichen hat die Varianz einer Zufallsvariablen stets?

$\text{Var}(X) \geq 0$ , da sie als Erwartungswert eines Quadrats (also einer nichtnegativen Zufallsvariablen) definiert ist..

**Karteikarte 7.20** Wann sagt man, dass die Varianz einer Zufallsvariablen  $X$  existiert?

Wenn  $\text{Var}(X) = \sum_{x \in X(\Omega)} (x - E[X])^2 P(X = x) < \infty$  (bzw. das entsprechende Integral bei einer Dichte endlich ist)..

**Karteikarte 7.21** Wie lautet das technische Lemma, das  $E[(X - a)^2]$  mit der Varianz in Beziehung setzt?

Für alle  $a \in \mathbb{R}$  gilt  $E[(X - a)^2] = \text{Var}(X) + (E[X] - a)^2$ ..

**Karteikarte 7.22** Für welchen Wert  $a$  wird  $E[(X - a)^2]$  minimal, und wie groß ist dieses Minimum?

$E[(X - a)^2]$  wird minimal für  $a = E[X]$ ; in diesem Fall gilt  $E[(X - a)^2] = \text{Var}(X)$  (folgt direkt aus dem technischen Lemma, da der Term  $(E[X] - a)^2$  dann verschwindet)..

**Karteikarte 7.23** Wie lautet der "Verschiebungssatz" zur Berechnung der Varianz, und welche Ungleichung folgt daraus?

Mit  $a = 0$  im technischen Lemma folgt  $\text{Var}(X) = E[X^2] - (E[X])^2$ . Da  $\text{Var}(X) \geq 0$ , folgt stets  $(E[X])^2 \leq E[X^2]$ ..

**7.2.1 | Rechenregeln für die Varianz****Satz 7.5** Satz (V) (2026)

Seien  $X, Y$  diskrete (?) Zufallsvariablen mit existierendem Erwartungswert,  $a, b \in \mathbb{R}$ .

(a)  $\text{Var}(aX + b) = a^2 \text{Var}(X)$

$$\begin{aligned}
& \text{Var}(aX + b) \mathbb{E} [(aX + b - \mathbb{E}[aX + b])^2] \\
& \mathbb{E} [(a(X - \mathbb{E}[X]))^2] \\
& a^2 \mathbb{E} [(X - \mathbb{E}[X])^2] \\
& = a^2 \text{Var}(X)
\end{aligned}$$

(b)  $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$  mit Kovarianz  $\text{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$ .

$$\begin{aligned}
\text{Var}(X + Y) &= \mathbb{E} [(X + Y - \mathbb{E}[X + Y])^2] \\
&= \mathbb{E} [(X - \mathbb{E}[X])^2] + 2\mathbb{E} [(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] + \mathbb{E} [(Y - \mathbb{E}[Y])^2] \\
&= \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)
\end{aligned}$$

(c)  $X$  und  $Y$  unabhängig  $\Rightarrow \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ .

$X$  und  $Y$  unabhängig  $\Rightarrow X - \mathbb{E}[X], Y - \mathbb{E}[Y]$  unabh.

$$\begin{aligned}
\text{Cov}(X, Y) &= \mathbb{E} [(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \\
&\stackrel{(P)}{=} \mathbb{E}[X - \mathbb{E}[X]] \mathbb{E}[Y - \mathbb{E}[Y]] \\
&= 0
\end{aligned}$$

(d) Für diskrete Zufallsvariablen gilt:

$\text{Var}(X) = 0 \Rightarrow$  Es existiert eine Konstante  $c$  mit  $\mathbb{P}(X = c) = 1$ .

$c = \mathbb{E}[X]$

**Beweis für (a) bis (c):** Verwende  $\text{Var}(Z) = \mathbb{E}[(Z - \mathbb{E}[Z])^2]$  und die Rechenregeln für den EW.

**Beweis für (d):**  $0 = \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x)$ .

Alle Summanden sind  $\geq 0$ , folglich impliziert  $\mathbb{P}(X = x) > 0$  sofort  $x = \mathbb{E}[X]$ , da die Summe nicht 0 sein könnte, wenn ein Summand nicht 0 wäre. Also muss jedes  $(x - \mathbb{E}[X])^2 \mathbb{P}(X = x)$  sein und wenn  $\mathbb{P}(X = x) > 0$ , muss also  $(x - \mathbb{E}[X])^2 = 0$  sein, also muss  $x - \mathbb{E}[X] = 0$  sein, also  $x = \mathbb{E}[X]$ .

Damit ist gezeigt, dass  $\mathbb{P}(X = \mathbb{E}[X]) = 1$ , da jedes  $x \in X$  gleich  $\mathbb{E}[X]$  ist.

Kann nicht gelten, wenn  $f$  Dichte hat

**Karteikarte 7.24** Wie ist die Kovarianz zweier Zufallsvariablen  $X, Y$  definiert?

$\text{Cov}(X, Y) := E[(X - E[X])(Y - E[Y])]$ .

**Karteikarte 7.25** Satz (V)(a): Wie verhält sich die Varianz unter einer affinen Transformation  $aX + b$ ?

$\text{Var}(aX + b) = a^2 \cdot \text{Var}(X)$  – die additive Konstante  $b$  hat keinen Einfluss, da sie den Erwartungswert nur verschiebt..

**Karteikarte 7.26** Satz (V)(b): Wie berechnet sich  $\text{Var}(X + Y)$  im Allgemeinen (ohne Unabhängigkeitsannahme)?

$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$ .

**Karteikarte 7.27 Satz (V)(c):** Wie vereinfacht sich  $\text{Var}(X + Y)$ , wenn  $X$  und  $Y$  unabhängig sind?  
 $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ , da bei Unabhängigkeit  $\text{Cov}(X, Y) = 0$  gilt (Satz (P)), angewendet auf die ebenfalls unabhängigen  $X - E[X]$  und  $Y - E[Y]$ ..

**Karteikarte 7.28 Satz (V)(d):** Was bedeutet  $\text{Var}(X) = 0$  für eine (diskrete) Zufallsvariable  $X$ ?  
 $\text{Var}(X) = 0$  gilt genau dann, wenn  $X$  fast sicher konstant ist, d.h. es gibt ein  $c \in \mathbb{R}$  (nämlich  $c = E[X]$ ) mit  $P(X = c) = 1$ ..

**Beispiel 7.17 Binomialverteilte Zufallsvariable  $S_n$  mit Parametern  $n$  und  $p$  (2026)**

$\Omega = \{0, 1\}^n$  und

$$p(\omega) = p^{\sum_{i=1}^n \omega_i} (1-p)^{n - \sum_{i=1}^n \omega_i}$$

Darstellung:

$$S_n = \sum_{i=1}^n X_i$$

mit

$$X_i(\omega) = \omega_i \quad \text{für alle } \omega \in \Omega.$$

Dabei sind die  $X_i$  unabhängig mit

$$\mathbb{P}(X_i = 1) = p$$

und

$$\mathbb{P}(X_i = 0) = 1 - p = q$$

für alle  $i$ .

$$\mathbb{E}[X] = \sum_{i=1}^n \mathbb{E}[X_i] = np$$

nach Satz (E).

Unter Verwendung der Unabhängigkeit der  $X_i$  folgt ohne weitere Arbeit aus Satz (V)(7.5)

$$\text{Var}(X) = \sum_{i=1}^n \underbrace{\text{Var}(X_i)}_{=pq} = npq$$

**Beispiel 7.18 Poisson-verteilte Zufallsvariable  $X$  mit Parameter  $\lambda > 0$  (2026)**

$$\mathbb{E}[X] = \lambda = \text{Var}(X)$$

Trick:

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \mathbb{E}[X(X-1)] + \mathbb{E}[X] - (\mathbb{E}[X])^2$$

Wir wissen bereits:

$$\mathbb{E}[X] = \lambda \quad \text{und} \quad (\mathbb{E}[X])^2 = \lambda^2$$

Die Behauptung folgt daher aus

$$\mathbb{E}[X(X-1)] = \sum_{k=2}^{\infty} k(k-1) \frac{\lambda^k}{k!} e^{-\lambda} = \lambda^2 \sum_{l=0}^{\infty} \frac{\lambda^l}{l!} e^{-\lambda} = \lambda^2$$

und damit

$$\text{Var}(X) = \mathbb{E}[X(X-1)] + \mathbb{E}[X] - (\mathbb{E}[X])^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

**Beispiel 7.19** geometrisch verteilte Zufallsvariable  $X$  mit Erfolgswahrscheinlichkeit  $p$  (2026)

$$\mathbb{E}[X] = \frac{1}{p} \quad \text{und} \quad \text{Var}(X) = \frac{1-p}{p^2}$$

(Nicht auswendig lernen)

**Beispiel 7.20** auf  $[a, b]$  uniform verteilte Zufallsvariable  $X$  (2026)

Dann ist

$$\mathbb{E}[X] = \frac{a+b}{2}$$

und

$$\begin{aligned} \mathbb{E}[X^2] &= \int_a^b x^2 \frac{1}{b-a} dx \\ &= \frac{1}{3(b-a)} x^3 \Big|_{x=a}^b \\ &= \frac{b^3 - a^3}{3(b-a)} \\ &= \frac{1}{3}(a^2 + ab + b^2) \end{aligned}$$

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{a^2 + ab + b^2}{3} - \frac{a^2 + 2ab + b^2}{4} = \frac{(a-b)^2}{12}^*$$

\* Nicht auswendig lernen.

**Beispiel 7.21** Exponentialverteilte Zufallsvariable  $X$  (2026)

$$\mathbb{E}[X] = \frac{1}{\alpha}$$

$$\begin{aligned} \mathbb{E}[X^2] &= \int_0^\infty \underbrace{x^2}_{\downarrow} \underbrace{\alpha e^{-\alpha x}}_{\uparrow} dx \\ &= - \lim_{N \rightarrow \infty} x^2 e^{-\alpha x} \Big|_{x=0}^N + 2 \int_0^\infty x e^{-\alpha x} dx \\ &= 0 + \frac{2}{\alpha} \mathbb{E}[X] \\ &= \frac{2}{\alpha^2} \end{aligned}$$

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \frac{2}{\alpha^2} - \left(\frac{1}{\alpha}\right)^2 = \frac{1}{\alpha^2}$$

Ende der Vorlesung vom 5. Juni 2026

**Satz 7.6** (2026) Sei  $f_X$  eine Dichte der Zufallsvariablen  $X$ . Dann gelten:

(a) Die Zufallsvariable  $X^2$  hat die Dichte

$$f_{X^2}(y) = \begin{cases} \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})] & y > 0 \\ 0 & \text{sonst} \end{cases}$$

(b)  $\mathbb{E}[X^2] = \int_{-\infty}^{\infty} x^2 f_X(x) dx$

**Beweis (a).** Für  $y \leq 0$   $F_{X^2}(y) = \mathbb{P}(X^2 \leq y) = 0$ .

Sei nun  $y > 0$ . Die Substitution  $x = \sqrt{z}$  zeigt:

$$\begin{aligned} F_{X^2}(y) &= \mathbb{P}(X^2 \leq y) \\ &= \mathbb{P}(-\sqrt{y} < X \leq \sqrt{y}) \\ &= \int_0^{\sqrt{y}} f_X(x) dx + \int_{-\sqrt{y}}^0 f_X(x) dx \\ &= \int_0^{\sqrt{y}} f_X(x) dx + \int_0^{\sqrt{y}} f_X(-x) dx \\ &= \int_0^y \frac{1}{2\sqrt{z}} [f_X(\sqrt{z}) + f_X(-\sqrt{z})] dz \end{aligned}$$

**Beweis (b).** Die Definition des Erwartungswerts und die Substitutionen  $y = x^2$  sowie  $z = -x$ , die die Substitutionen in Teil (a) rückgängig machen, zeigen

$$\begin{aligned} \mathbb{E}[X^2] &= \int_{-\infty}^{\infty} y f_{X^2}(y) dy \\ &= \int_0^{\infty} \frac{y}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})] dy \\ &= \int_0^{\infty} \frac{x}{2} [f_X(\sqrt{y}) + f_X(-\sqrt{y})] 2x dx \\ &= \int_0^{\infty} x^2 f_X(x) dx + \int_{-\infty}^0 z^2 f_X(z) dz \\ &= \int_{-\infty}^{\infty} x^2 f_X(x) dx \end{aligned}$$

**Karteikarte 7.29** Wie berechnet man die Dichte von  $X^2$ , wenn  $X$  die Dichte  $f_X$  hat?

$$f_{X^2}(y) = \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})] \text{ für } y > 0, \text{ und } f_{X^2}(y) = 0 \text{ für } y \leq 0.$$

**Karteikarte 7.30** Muss man erst die Dichte von  $X^2$  bestimmen, um  $E[X^2]$  zu berechnen?

Nein. Es gilt direkt  $E[X^2] = \int_{-\infty}^{\infty} x^2 f_X(x) dx$  – man kann  $E[X^2]$  also unmittelbar über die (ursprüngliche) Dichte von  $X$  berechnen, ohne den Umweg über die Dichte von  $X^2$ . Dies ist ein Spezialfall des Transformationssatzes für  $E[f(X)]$  mit  $f(x) = x^2$ .

## Karteikarten Erwartungswert und Varianz der wichtigsten Verteilungen

**Karteikarte 7.31** Wie lauten Erwartungswert und Varianz einer binomialverteilten Zufallsvariablen mit Parametern  $n, p$ ?

$$E[X] = np \text{ und } \text{Var}(X) = np(1-p).$$

**Karteikarte 7.32** Wie lauten Erwartungswert und Varianz einer Bernoulli-verteilten Zufallsvariablen (Spezialfall  $n = 1$  der Binomialverteilung) mit Erfolgswahrscheinlichkeit  $p$ ?

$$E[X] = p \text{ und } \text{Var}(X) = p(1 - p) ..$$

**Karteikarte 7.33** Wie lautet die Zähldichte der geometrischen Verteilung mit Erfolgswahrscheinlichkeit  $p$ ?

$P(X = k) = p(1 - p)^{k-1}$  für  $k \in \mathbb{N} = \{1, 2, 3, \dots\}$  – die Wahrscheinlichkeit, dass der erste Erfolg im  $k$ -ten Versuch eintritt..

**Karteikarte 7.34** Wie lauten Erwartungswert und Varianz einer geometrisch verteilten Zufallsvariablen mit Erfolgswahrscheinlichkeit  $p$ ?

$$E[X] = \frac{1}{p} \text{ und } \text{Var}(X) = \frac{1 - p}{p^2} ..$$

**Karteikarte 7.35** Wie ist die Poisson-Verteilung mit Parameter  $\lambda > 0$  definiert?

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} \text{ für alle } k \in \mathbb{N}_0 = \{0, 1, 2, \dots\} ..$$

**Karteikarte 7.36** Wie lauten Erwartungswert und Varianz einer Poisson-verteilten Zufallsvariablen mit Parameter  $\lambda$ ?

$E[X] = \lambda$  und  $\text{Var}(X) = \lambda$  – Erwartungswert und Varianz stimmen bei der Poisson-Verteilung überein..

**Karteikarte 7.37** Wie lauten Erwartungswert und Varianz einer auf  $\{1, \dots, n\}$  gleichverteilten Zufallsvariablen?

$$E[X] = \frac{n+1}{2} \text{ und } \text{Var}(X) = \frac{n^2 - 1}{12} ..$$

**Karteikarte 7.38** Wie lauten Erwartungswert und Varianz einer auf  $[a, b]$  gleichverteilten (stetigen) Zufallsvariablen?

$$E[X] = \frac{a+b}{2} \text{ und } \text{Var}(X) = \frac{(b-a)^2}{12} ..$$

**Karteikarte 7.39** Wie lautet die Dichte der Exponentialverteilung mit Parameter  $\alpha > 0$ ?

$$f(x) = \begin{cases} 0 & x < 0 \\ \alpha e^{-\alpha x} & x \geq 0 \end{cases} . \text{ Die Exponentialverteilung wird häufig zur Modellierung von Wartezeiten verwendet..}$$

**Karteikarte 7.40** Wie lauten Erwartungswert und Varianz einer exponentialverteilten Zufallsvariablen mit Parameter  $\alpha$ ?

$$E[X] = \frac{1}{\alpha} \text{ und } \text{Var}(X) = \frac{1}{\alpha^2} ..$$

**Karteikarte 7.41** Wie berechnet man Erwartungswert und Varianz einer binomialverteilten Zufallsvariablen am elegantesten?

Man stellt  $X$  als Summe  $X = \sum_{i=1}^n X_i$  unabhängiger Bernoulli-Indikatorvariablen dar ( $X_i = 1$  bei Erfolg im  $i$ -ten Versuch). Dann folgt  $E[X] = \sum_i E[X_i] = np$  direkt aus der Linearität (auch ohne Unabhängigkeit), und  $\text{Var}(X) = \sum_i \text{Var}(X_i) = np(1 - p)$  folgt aus Satz (V)(c), da die  $X_i$  unabhängig sind..



**Karteikarte 7.42** Welcher Trick hilft, die Varianz zu berechnen, wenn  $E[X^2]$  direkt schwer zu bestimmen ist (z.B. bei der Poisson-Verteilung)?

Man nutzt  $\text{Var}(X) = E[X^2] - (E[X])^2 = E[X(X-1)] + E[X] - (E[X])^2$ , da  $E[X(X-1)] = E[X^2] - E[X]$ . Der Ausdruck  $E[X(X-1)]$  (ein sogenanntes faktorielles Moment) lässt sich bei manchen Verteilungen einfacher berechnen als  $E[X^2]$  direkt..



# KAPITEL 8

## Varianz und Kovarianz

### 8.1 | Vorlesung 8



## Grenzwertsätze

Vorlesung 13. Juni 2025 (V09 2025) und 12. Juni 2026 (V08 2026)

### 9.1 | Markoffsche und Tschebyscheffsche Ungleichung

#### Satz 9.1 Markoffsche Ungleichung (2026)

Sei  $X$  eine Zufallsvariable.  $\mathbb{E}[|X|^k]$  existiert für ein  $k \in \mathbb{N}$ . Dann existiert auch der Erwartungswert  $\mathbb{E}[X]$ , und es gilt

$$\mathbb{P}(\underbrace{|X - \mathbb{E}[X]|}_{*} \geq h) \leq \frac{\mathbb{E}[|X - \mathbb{E}[X]|^k]}{h^k} \quad \forall h > 0$$

\* Menge aller  $\omega \in \Omega$  derart, dass  $X(\omega)$  um mindestens  $h$  von ihrem EW  $\mathbb{E}[X]$  abweicht.

#### Satz 9.2 Tschebyscheffsche Ungleichung (Spezialfall $k = 2$ ) (2026)

Für eine Zufallsvariable  $X$ , deren Erwartungswert und Varianz existieren, gilt

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq h) \leq \frac{\text{Var}(X)}{h^2} \quad \forall h > 0$$

**Beweis:** Spezialfall diskreter Wahrscheinlichkeitsraums

$$\begin{aligned} \mathbb{P}(|X - \mathbb{E}[X]| \geq h) &= \sum_{\omega \in \Omega: |X(\omega) - \mathbb{E}[X]| \geq h} \mu(\omega) \\ &= \sum_{x \in X(\Omega): |x - \mathbb{E}[X]| \geq h} \mathbb{P}(\{\omega \in \Omega : X(\omega) = x\}) \\ &\leq \sum_{x \in X(\Omega): |x - \mathbb{E}[X]| \geq h} \left( \frac{|x - \mathbb{E}[X]|}{h} \right)^2 \mathbb{P}(X = x) \\ &\leq \frac{1}{h^2} \sum_{x \in X(\Omega)} |x - \mathbb{E}[X]|^2 \mathbb{P}(X = x) \\ &\leq \frac{1}{h^2} \text{Var}(X) \end{aligned}$$

**Beispiel 9.1** Die Tschebyscheffsche Ungleichung kann nicht verbessert werden (2026)

Sei  $N \in \mathbb{N}$  beliebig und die Zufallsvariable  $X$  mit  $X(\Omega) = \{-N, 0, +N\}$  und  $\mathbb{P}(X = \pm N) = \frac{1}{2N^2}$

$$\begin{aligned}\mathbb{P}(X = +N) &= \frac{1}{2N^2} \\ \mathbb{P}(X = -N) &= \frac{1}{2N^2} \\ \mathbb{P}(X = 0) &= 1 - \frac{1}{N^2}\end{aligned}$$

Aus  $\mathbb{E}[X] = 0$  folgt

$$\text{Var}(X) = N^2 \mathbb{P}(X = -N) + N^2 \mathbb{P}(X = +N) = 1$$

Denn

$$\text{Var}(X) = \mathbb{E}[X^2] = N^2 \mathbb{P}(X^2 = N) = N^2 \frac{2}{2N^2} = 1$$

Für jedes  $h \in (0, N]$  gilt

$$\begin{aligned}\mathbb{P}(|X - \underbrace{\mathbb{E}[X]}_{=0}| \geq h) &= \mathbb{P}(|X - \mathbb{E}[X]| > 0) \\ &= \mathbb{P}(X = N) + \mathbb{P}(X = -N) \\ &= \frac{1}{N^2} \\ &= \frac{\overbrace{\text{Var}(X)}^{=1}}{N^2} \\ &\leq \frac{1}{h^2} \text{Var}(X)\end{aligned}$$

Die Wahl  $h = N$  zeigt: Ungleichung kann nicht verbessert werden.

Die Wahl  $h = 2N$  dagegen zeigt, dass sie nicht immer gut ist:

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq 2N) = \mathbb{P}(|X| > N) = 0 < \frac{1}{(2N)^2} = \frac{\text{Var}(X)}{(2N)^2}$$

### Beispiel 9.2 Werfen eines fairen Würfels (2026)

Wie oft müssen wir einen fairen Würfel werfen, bis mit Ws.  $\geq 1 - 0.05$  die relative Häufigkeit einer Sechs um weniger als  $1/10$  von  $1/6$  abweicht?

**Ansatz:**  $\Omega = \{1, \dots, 6\}^N$  mit Gleichverteilung  $\mathbb{P}$  (für  $N$  Würfe) und Zufallsvariablen  $X_i \Omega \rightarrow \{0, 1\}$ .

Dabei sind  $X_i(\omega) = 1_{\{6\}}(\omega_i)$  unabhängig und identisch verteilt (u.i.v.) mit  $\mathbb{P}(X_i = 1) = \frac{1}{6}$ .

$S_N = \sum_{i=1}^N X_i$  ist die Anzahl der geworfenen Sechsen und  $\frac{1}{N} S_N$  ist die relative Häufigkeit einer Sechs.

**Gesucht** ist das kleinste  $N$  derart, dass  $\mathbb{P}(|\frac{S_N}{N} - \frac{1}{6}| \geq \frac{1}{10}) \leq \frac{5}{100}$  (Gegenereignis zu  $\mathbb{P}(|\frac{S_N}{N} - \frac{1}{6}| < \frac{1}{10}) \geq 1 - \frac{5}{100}$ ).

**Lösung:** für Tschebyscheffsche Ungleichung in Bezug auf EW und Var

Seien  $p = 1/6$  und  $q = 1 - p = 5/6$  und sei  $S_N$  binomialverteilt mit Parametern  $N$  und  $p$ . Dann ist

$$\mathbb{E}\left[\frac{1}{N} S_N\right] = \frac{1}{N} \mathbb{E}[S_N] \stackrel{*}{=} \frac{1}{N} N p = p = 1/6$$

\* da  $S_N$  binomialverteilt ist und

$$\text{Var}\left(\frac{1}{N}S_N\right) = \frac{1}{N}\text{Var}(S_N) \stackrel{**}{=} \frac{1}{N}Npq = \frac{1}{N}pq = \frac{1}{N}\frac{1}{6}\frac{5}{6}$$

\*\* Ebenfalls, weil  $S_N$  binomialverteilt ist.

Tschebyscheffsche Ungleichung:

$$\mathbb{P}\left(\underbrace{\left|\frac{S_N}{N} - \frac{1}{6}\right|}_{\text{Gegenereignis}} \geq \frac{1}{10}\right) \leq \frac{\text{Var}\left(\frac{S_N}{N}\right)}{(1/10)^2} = 100 \frac{5}{36N}$$

Wir wählen also  $N$  so groß, dass  $100 \frac{5}{36N} \leq \frac{5}{100}$ .

**Fazit** Jedes  $N \approx 278$  (genauer aus der Abschätzung  $(100)^2/36 \approx 277.7$ ) garantiert, dass mit Wahrscheinlichkeit  $\geq 0.95$  die relative Häufigkeit einer Sechsen bei  $N$ -maligem Würfeln um weniger als  $1/10$  von  $1/6$  abweicht.

Wenn wir  $N = 278$  wählen, sind wir auf der sicheren Seite.

Da wir abgeschätzt haben, ist dieses  $N$  möglicherweise nicht das minimale.

#### Karteikarte 9.1 Wie lautet die Markoffsche Ungleichung?

Existiert  $E[|X|^k]$  für ein  $k \in \mathbb{N}$ , so existiert auch  $E[X]$ , und für alle  $h > 0$  gilt  $P(|X - E[X]| \geq h) \leq \frac{E[|X - E[X]|^k]}{h^k}$ ..

#### Karteikarte 9.2 Wie lautet die Tschebyscheffsche Ungleichung (Spezialfall $k = 2$ der Markoffschen Ungleichung)?

Für eine Zufallsvariable  $X$ , deren Erwartungswert und Varianz existieren, gilt für alle  $h > 0$ :  $P(|X - E[X]| \geq h) \leq \frac{\text{Var}(X)}{h^2}$ ..

#### Karteikarte 9.3 Warum ist die Tschebyscheffsche Ungleichung praktisch nützlich?

Sie liefert eine universelle obere Schranke für die Wahrscheinlichkeit, dass  $X$  um mindestens  $h$  vom Erwartungswert abweicht – und das, obwohl man dafür nur Erwartungswert und Varianz von  $X$  kennen muss, nicht die vollständige Verteilung..

#### Karteikarte 9.4 Kann die Tschebyscheffsche Ungleichung im Allgemeinen verbessert werden?

Nein. Es gibt Zufallsvariablen, für die für ein bestimmtes  $h$  in der Ungleichung Gleichheit gilt (die Schranke  $\text{Var}(X)/h^2$  also exakt erreicht wird). Die Ungleichung ist somit scharf und kann nicht universell verbessert werden – für andere Werte von  $h$  kann dieselbe Schranke aber sehr grob sein..

#### Karteikarte 9.5 Wie nutzt man die Tschebyscheffsche Ungleichung, um eine Mindestanzahl $N$ von Versuchswiederholungen zu bestimmen, sodass die relative Häufigkeit mit vorgegebener Sicherheit nur wenig vom wahren Parameter abweicht?

Man modelliert  $S_N$  als binomialverteilt mit Parametern  $N, p$ , nutzt  $E[S_N/N] = p$  und  $\text{Var}(S_N/N) = pq/N$ , und schätzt  $P(|S_N/N - p| \geq \varepsilon) \leq \frac{pq}{N\varepsilon^2}$  ab. Man wählt dann  $N$  so groß, dass diese obere Schranke kleiner/gleich der gewünschten (kleinen) Fehlerwahrscheinlichkeit ist..

## 9.2 | Schwaches Gesetz der großen Zahlen

### Satz 9.3 Schwaches Gesetz der großen Zahlen (2025)

**Gegeben** Zufallsvariablen  $X_1, X_2, X_3, \dots$  auf einem  $(\Omega, \mathbb{P})$ . Dabei muss die Verteilung der  $X_i$  nicht identisch sein. Es gilt  $S_n = \sum_{i=1}^n X_i$

**Angenommen** alle Erwartungswerte  $\mathbb{E}[X_i]$  existieren mit  $\mathbb{E}[X_i] = \mathbb{E}[X_1]$  (es sind also alle gleich) für alle  $i \in \mathbb{N}$ .  
 $\exists C > 0$  mit  $\text{Var}(X_i) \leq C$  für alle  $i \in \mathbb{N}$ . (Beachte  $\text{Var}(X_i) < \infty \Rightarrow \mathbb{E}[X_i]$  ex.)

Die Zufallsvariablen sind paarweise unkorreliert (Also wenn  $\text{Cov}(X_i, X_j) = 0$  für  $i \neq j$ ) :

$$\mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])] = 0, \quad \text{für alle } i \neq j$$

Dann gilt:

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n}S_n - \mathbb{E}[X_1]\right| \geq \epsilon\right) = 0 \quad \forall \epsilon > 0$$

$S_n$ : arithmetisches Mittel und  $\frac{1}{n}S_n$  relative Häufigkeit, falls  $x_i$  Bernoulli-verteilt

Soll heißen.: Generell ist  $\frac{1}{n}S_n$  das arithmetische Mittel, aber bei einer Bernoulli-Verteilung ist  $\frac{1}{n}S_n$  auch gleichzeitig die relative Häufigkeit der Erfolge, da  $S_n$  die Anzahl der Erfolge unter  $n$  Versuchen ist.

**Beweis.** (siehe Folie 4--2025 bzw. 18--19 2026)

**Bemerkung 9.1** (2026) Unabhängigkeit  $\Rightarrow$  paarweise Unabhängigkeit  $\Rightarrow$  paarweise Unkorreliertheit

**Bemerkung 9.2** (2026)

$$\mathbb{E}\left[\frac{1}{n}S_n\right] = \mathbb{E}[X_1]$$

### Beispiel 9.3 Ermitteln der Erfolgswahrscheinlichkeit aus Daten (2025)

Geg.  $S_n$ , ges.  $\mathbb{E}\left[\frac{1}{n}S_n\right] = \mathbb{E}[X_1] = p = \text{Erfolgswahrscheinlichkeit}$ .

$S_n$  ist hier die Anzahl der Erfolge in einem  $n$ -mal unabhängig wiederholten Bernoulli-Experiment, z.B. Anzahl Sechsen bei  $n$ -maligem Werfen eines möglicherweise nicht fairen Würfels.

Erinnerung: Die relative Häufigkeit  $\frac{1}{n}S_n$  der Erfolge konvergiert gegen die Erfolgswahrscheinlichkeit  $p$ .

Die Wahrscheinlichkeit, daß die relative Häufigkeit um mindestens  $\epsilon$  von der Erfolgswahrscheinlichkeit abweicht, konvergiert gegen Null

**Notation 9.1** (2025)

$$x_k^{(n)} := (k - np) / \sqrt{npq} \quad \text{für } k = 0, \dots, n$$

$$\mathcal{B}_{n,p}(k) = \binom{n}{k} p^k q^{n-k}$$

**Erinnerung 9.1** (2025) Ist  $S_n$  binomialverteilt mit Parametern  $n$  und  $p$ , so gelten

$$\mathbb{P}(S_n = k) = \mathcal{B}_{n,p}(k)$$



$$\mathbb{E}[S_n] = np$$

$$\text{Var}(S_n) = npq$$

**Karteikarte 9.6** Wie lautet das Schwache Gesetz der großen Zahlen, und welche Voraussetzungen benötigt es?

Seien  $X_1, X_2, \dots$  Zufallsvariablen (nicht notwendig identisch verteilt) mit  $S_n = \sum_{i=1}^n X_i$ . Voraussetzungen: alle  $E[X_i]$  existieren und sind gleich ( $= E[X_1]$ ); es gibt  $C > 0$  mit  $\text{Var}(X_i) \leq C$  für alle  $i$ ; die  $X_i$  sind paarweise unkorreliert ( $\text{Cov}(X_i, X_j) = 0$  für  $i \neq j$ ). Dann gilt für jedes  $\varepsilon > 0$ :  $\lim_{n \rightarrow \infty} P(|\frac{1}{n}S_n - E[X_1]| \geq \varepsilon) = 0$ .

**Karteikarte 9.7** In welcher Beziehung stehen Unabhängigkeit, paarweise Unabhängigkeit und paarweise Unkorreliertheit?

Unabhängigkeit  $\Rightarrow$  paarweise Unabhängigkeit  $\Rightarrow$  paarweise Unkorreliertheit. Die Umkehrungen gelten im Allgemeinen nicht..

**Karteikarte 9.8** Wie verhält sich  $E[\frac{1}{n}S_n]$  zu  $E[X_1]$  im Kontext des schwachen Gesetzes der großen Zahlen?

$E[\frac{1}{n}S_n] = E[X_1]$  (unter den Voraussetzungen des schwachen Gesetzes der großen Zahlen, insbesondere gleicher Erwartungswerte aller  $X_i$ ).

**Karteikarte 9.9** Wozu kann man das Schwache Gesetz der großen Zahlen nutzen, wenn man eine unbekannte Erfolgswahrscheinlichkeit  $p$  schätzen möchte?

Ist  $S_n$  die Anzahl der Erfolge in  $n$  unabhängig wiederholten Bernoulli-Experimenten mit unbekanntem Parameter  $p$ , so konvergiert die relative Häufigkeit  $\frac{1}{n}S_n$  im Sinne des Gesetzes der großen Zahlen gegen  $p$ . Die Wahrscheinlichkeit, dass sie um mindestens  $\varepsilon$  von  $p$  abweicht, geht gegen 0. Man kann  $\frac{1}{n}S_n$  also als Schätzer für  $p$  verwenden..

## 9.3 | Lokaler zentraler Grenzwertsatz und Stirlingsche Formel

**Satz 9.4** Lokaler zentraler Grenzwertsatz (2025)

Sei  $L > 0$  eine beliebige Konstante. Dann gilt

$$\underbrace{\mathcal{B}_{n,p}(k)}_{\mathbb{P}(S_n=k)} \sim \frac{1}{\sqrt{2\pi npq}} e^{-(x_k^{(n)})^2/2} \text{ gleichmäßig für alle } k \text{ mit } |x_k^{(n)}| \leq L \quad (9.1)$$

Dabei bedeutet  $\sim$ :

$$f(n) \sim g(n) \Leftrightarrow \lim_{n \rightarrow \infty} \frac{f(n)}{g(n)} = 1$$

Man kann 9.1 auch schreiben als

$$\lim_{n \rightarrow \infty} \sup_{k: |x_k^{(n)}| \leq L} \left| \frac{B_{n,p}(k)}{\frac{1}{\sqrt{2\pi npq}} e^{-(x_k^{(n)})^2/2}} - 1 \right| = 0$$

**Beweis.**

- Ausschreiben des Binomialkoeffizienten in *Binomialverteilung*)
- Approximieren der Fakultäten mit Hilfe der Stirlingschen Formel (siehe unten)
- Sortieren der Terme

■ Sorgfältiges Berechnen des Limes  $n \rightarrow \infty$

schwaches Gesetz der großen Zahlen " $\frac{1}{n}S_n \rightarrow \frac{1}{6}$ " und  $\mathbb{P}(\frac{1}{n}S_n = \frac{1}{6})$  ist sehr klein.

### Ergänzung 9.1 Stirlingsche Formel (2025)

$$n! \sim \sqrt{2\pi n} \left(\frac{n}{e}\right)^n \text{ für große } n \quad (9.2)$$

| n  | n!        | Approximation        |
|----|-----------|----------------------|
| 1  | 1         | 0.922                |
| 2  | 2         | 1.919                |
| 3  | 6         | 5.836                |
| 4  | 24        | 23.506               |
| 5  | 120       | 118.019              |
| 6  | 720       | 710.078              |
| 7  | 5040      | 4980.4               |
| 8  | 40320     | 39902.4              |
| 9  | 362880    | 359537               |
| 10 | 3628800   | $3.5987 \cdot 10^6$  |
| 11 | 39916800  | $3.96156 \cdot 10^7$ |
| 12 | 479001600 | $4.75687 \cdot 10^8$ |

**Tabelle 9.1:** Exact factorial values and their approximations.

### Ergänzung 9.2 Stirlingsche Formel mit Fehlerabschätzung (2025)

$$1 \leq \frac{n!}{\sqrt{2\pi n} \left(\frac{n}{e}\right)^n} \leq 1 + \frac{1}{11n} \quad (9.3)$$

Die Approximation verwendet die untere Schranke und Fehler ist der Ordnung  $\frac{1}{n}$ .

### Beispiel 9.4 1200-mal Würfeln mit einem fairen Würfel. (2025)

Wie groß ist die Wahrscheinlichkeit, genau  $k$  Sechsen zu werfen?

a)  $k = 200$

$$B_{1200, \frac{1}{6}}(200) = 0.030888 \dots$$

Approximation gemäß lokalem zentralem Grenzwertsatz:

$$0.030901 \dots$$

b)  $k = 250$

$$B_{1200, \frac{1}{6}}(250) = 0.0000244 \dots$$

Approximation gemäß lokalem zentralem Grenzwertsatz:

$$0.0000170 \dots$$

### Neue Fragen: (2025)

Wie groß ist die Ws., zwischen 150 und 250 Sechsen zu werfen? Wie groß ist die Ws., mindestens 250 Sechsen zu werfen?

**Karteikarte 9.10** Wie ist die standardisierte Größe  $x_k^{(n)}$  definiert, die beim lokalen zentralen Grenzwertsatz auftritt?

$x_k^{(n)} := \frac{k - np}{\sqrt{npq}}$  für  $k = 0, \dots, n$  – der Abstand von  $k$  zum Erwartungswert  $np$  der Binomialverteilung, gemessen in Einheiten der Standardabweichung  $\sqrt{npq}$ .

**Karteikarte 9.11** Wie lautet der lokale zentrale Grenzwertsatz für die Binomialverteilung?

Für jede Konstante  $L > 0$  gilt  $B_{n,p}(k) \sim \frac{1}{\sqrt{2\pi npq}} e^{-(x_k^{(n)})^2/2}$  gleichmäßig für alle  $k$  mit  $|x_k^{(n)}| \leq L$ , wobei  $f(n) \sim g(n) :\Leftrightarrow \lim_{n \rightarrow \infty} f(n)/g(n) = 1$ . Die Binomialwahrscheinlichkeit wird für großes  $n$  also durch die Dichte der Standardnormalverteilung approximiert..

**Karteikarte 9.12** Wie lautet die Stirlingsche Formel zur Approximation von  $n!$  für große  $n$ ?

$n! \sim \sqrt{2\pi n} \left(\frac{n}{e}\right)^n$  für große  $n$ .

**Karteikarte 9.13** Wie lautet die Stirlingsche Formel mit expliziter Fehlerabschätzung?

$1 \leq \frac{n!}{\sqrt{2\pi n} (n/e)^n} \leq 1 + \frac{1}{11n}$ . Die Approximation verwendet die untere Schranke; der relative Fehler ist von der Ordnung  $\frac{1}{n}$ .

## 9.4 | Satz von de Moivre-Laplace und die Standardnormalverteilung

**Satz 9.5 Satz von de Moivre-Laplace** (Spezialfall des zentralen Grenzwertsatzes) (2025)

Sei  $S_n$  die Anzahl der Erfolge in einem  $n$ -fach unabhängig wiederholten Bernoulli-Experiment mit Erfolgswahrscheinlichkeit  $p \in (0, 1)$ .

Dann gilt für jede Wahl von Konstanten  $a, b$  mit  $-\infty < a < b < \infty$ :

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-x^2/2} dx = \int_a^b \varphi(x) dx \quad (9.4)$$

Dabei verstehen wir die rechte Seite als Riemann-Integral  $\int_a^b \varphi(x) dx$  mit

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \quad (9.5)$$

Standardisieren:  $X$  ist ZV mit existierender Varianz.

$Y := \frac{X - \mathbb{E}[X]}{\sqrt{\text{Var}(X)}}$  hat  $\mathbb{E}[Y] = 0$ ,  $\text{Var}(Y) = 1$

**Beweisidee:** Zunächst Approximieren der Summanden *Binomialverteilung* durch den lokalen zentralen Grenzwertsatz. Approximieren der Summe mithilfe eines Riemann-Integrals.

**Beweis.** Siehe Folie 23. 2025

**Kommentar 9.1** Zu Satz 9.5

Der Satz von de Moivre-Laplace macht eine Aussage über einen Grenzwert. Das bedeutet: Wenn man  $n$  tatsächlich gegen unendlich gehen lässt, dann konvergiert diese Wahrscheinlichkeit exakt gegen  $\Phi(b) - \Phi(a)$  in der Praxis hast du aber nie  $n = \infty$ .

**Bemerkung 9.3** Zu Satz 9.5 (2025)

$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$  heißt Dichte der Standardnormalverteilung.

Die Stammfunktion

$$\Phi(y) = \int_{-\infty}^y \varphi(x) dx = \int_{-\infty}^y \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx \quad (9.6)$$

ist die Verteilungsfunktion der Standardnormalverteilung.

Der Graph von  $\varphi$  ist die berühmte Gaußsche Glockenkurve.

$\Phi(y)$  ist die Fläche unter der Kurve  $\varphi$  von  $-\infty$  bis  $y$ .

**Regel 9.1** Rechenregeln (2025)

Dichte:

$$\int_{-\infty}^{\infty} \varphi(x) dx = 1 \quad (9.7)$$

Verteilungsfunktion:

$$\Phi(y) \rightarrow \begin{cases} 0 & \text{für } y \rightarrow -\infty \\ 1 & \text{für } y \rightarrow \infty \end{cases} \quad (9.8)$$

gerade Funktion:

$$\Phi(0) = \frac{1}{2} \quad (9.9)$$

$$\Phi(z) = \int_{-\infty}^z \varphi(x) dx = 1 - \int_z^{\infty} \varphi(x) dx = 1 - \int_{-\infty}^{-z} \underbrace{\varphi(y)}_{f(y)} dy = 1 - \Phi(-z) \quad (9.10)$$

( $y = -z$ )

Illustration in Abbildung 9.1.




Abbildung 9.1

**Ergänzung 9.3** (2026) Lokaler zentraler Grenzwertsatz und Satz von de Moivre-Laplace




Abbildung 9.2: Beispiel für  $n = 10$ ,  $p = 1/10$




Abbildung 9.3: Beispiel für  $n = 20$ ,  $p = 1/10$




Abbildung 9.4: Beispiel für  $n = 100$ ,  $p = 1/10$




Abbildung 9.5: Beispiel für  $n = 500$ ,  $p = 1/10$

**Beispiel 9.5** Vorlesung vs. Schlaf (2025)

**Frage:** Wie groß ist die Wahrscheinlichkeit, dass von den 142 Hörern einer 8-Uhr-Vorlesung nächste Woche zwischen 30% und 70% die Vorlesung besuchen?

**Geg.:**  $n = 142$  Hörer, jeder Einzelne besucht mit Wahrscheinlichkeit  $p \in (0, 1)$  die Vorlesung ( $p = \frac{2}{3}$ ).

**Vereinfachende Annahmen:** Alle Hörer besuchen die Vorlesung mit derselben Wahrscheinlichkeit und alle Hörer entscheiden sich unabhängig voneinander.

**Modell:**  $n$ -mal unabhängig wiederholtes Bernoulli-Experiment mit Erfolgswahrscheinlichkeit  $p$ . Also: Die Anzahl der Erfolge  $S_n$  ist  $\mathcal{B}_{n,p}$ -verteilt. Man betrachte jeden Anwesenden der  $n$  eingeschriebenen Hörer als "Erfolg".

Also:

$$\Omega = \{0, 1\}^n, \quad \mu(\omega) = p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{n-\sum_{i=1}^n \omega_i} \quad (\text{mit } n = 142 \text{ und } p = 2/3)$$

Anzahl der Erfolge ist die Anzahl Anwesender

$$S_n(\omega_i) = \sum_{i=1}^n \omega_i$$

Dass  $n$  Leute anwesende sind, ist das Ereignis:

$$A_n = \left\{ \frac{3}{10} \leq \frac{1}{n} S_n \leq \frac{7}{10} \right\} = \{S_n \in \{\lceil \frac{3}{10} \cdot n \rceil, \lceil \frac{3}{10} \cdot n \rceil + 1, \dots, \lfloor \frac{7}{10} \cdot n \rfloor\}\}$$

Für  $n = 142$  ist das  $\lceil \frac{3}{10} \cdot n \rceil = 43$  und  $\lfloor \frac{7}{10} \cdot n \rfloor = 99$  Mit  $p = \frac{2}{3}$ :

$$\mathbb{P}(A_n) = \sum_{k=\lceil \frac{3}{10} \cdot n \rceil}^{\lfloor \frac{7}{10} \cdot n \rfloor} \binom{142}{k} \left(\frac{2}{3}\right)^k \left(\frac{1}{3}\right)^{142-k} = \sum_{k=43}^{99} \binom{142}{k} \left(\frac{2}{3}\right)^k \left(\frac{1}{3}\right)^{142-k} \approx 0.80$$

Approximation mit dem Satz von de Moivre-Laplace (in Form  $a < \dots \leq b$  bringen) :

$$\begin{aligned} \mathbb{P}(A_n) &= \mathbb{P}\left(\frac{3n}{10} \leq S_n \leq \frac{7n}{10}\right) \\ &= \mathbb{P}\left(\lceil \frac{3n}{10} \rceil \leq S_n \leq \lfloor \frac{7n}{10} \rfloor\right) \\ &= \mathbb{P}\left(\lceil \frac{3n}{10} \rceil - 1 < S_n \leq \lfloor \frac{7n}{10} \rfloor\right) && (\text{weil } S_n \text{ ganzzahlig ist}) \\ &= \mathbb{P}\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) && (\text{Standardisieren, } q = 1 - p = 1/3) \\ &\stackrel{*}{\approx} \Phi(b) - \Phi(a) && (\text{Satz von de Moivre-Laplace}) \\ &\approx \Phi(0.77) - 0 \\ &\approx 0.7794v && (Tabelle) \end{aligned}$$

$$* \int_a^b \varphi(x) dx = \Phi(b) - \Phi(a)$$

mit

$$a = \frac{\lceil \frac{3n}{10} \rceil - 1 - np}{\sqrt{npq}} \approx -9.38 \quad \text{und} \quad b = \frac{\lfloor \frac{7n}{10} \rfloor - 1 - np}{\sqrt{npq}} \approx 0.77$$

Das Resultat wirft einige Fragen auf:

**Frage 9.1** Warum spielt die untere Grenze  $a$ , die von den 30% herrührt, praktisch keine Rolle? (2026)

**1. Antwort:**  $\Phi(a) \approx \Phi(-9) = 1 - \Phi(9)$  und  $\Phi(9)$  ist so nah an 1, dass wir diesen Wert nicht einmal in der Tabelle finden . . .

Aber das erklärt noch gar nichts – oder?

**2. Antwort:** Wir wissen aus dem Gesetz der großen Zahlen, dass  $\frac{1}{n}S_n$  in einem gewissen Sinne gegen  $p = 2/3 \approx 66\%$  konvergiert. Daher ist die Forderung, dass  $\frac{1}{n}S_n \leq 70\%$  sein soll, sehr viel restriktiver als die Forderung  $\frac{1}{n}S_n \geq 30\%$ .

**Kommentar 9.2** Da  $\frac{1}{n}S_n$  nach dem Gesetz der großen Zahlen gegen  $p = \frac{2}{3} \approx 66,7\%$  konvergiert, liegt es für große  $n$  mit hoher Wahrscheinlichkeit in der Nähe von 66,7%. Die Bedingung  $\frac{1}{n}S_n \geq 30\%$  ist daher nahezu immer erfüllt, während  $\frac{1}{n}S_n \leq 70\%$  nur eine kleine Abweichung vom Grenzwert zulässt und somit restriktiver ist.

**Karteikarte 9.14** Wie standardisiert man eine Zufallsvariable  $X$  mit existierender Varianz, und welche Eigenschaften hat die standardisierte Größe?

$Y := \frac{X - E[X]}{\sqrt{\text{Var}(X)}}$ . Es gilt stets  $E[Y] = 0$  und  $\text{Var}(Y) = 1$ .

**Karteikarte 9.15** Wie lautet der Satz von de Moivre-Laplace?

Sei  $S_n$  die Anzahl der Erfolge in einem  $n$ -fach unabhängig wiederholten Bernoulli-Experiment mit Erfolgswahrscheinlichkeit  $p \in (0, 1)$ ,  $q = 1 - p$ . Dann gilt für alle Konstanten  $-\infty < a < b < \infty$ :  $\lim_{n \rightarrow \infty} P\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) = \int_a^b \varphi(x) dx$ , wobei  $\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$  die Dichte der Standardnormalverteilung ist..

**Karteikarte 9.16** Was ist die Dichte  $\varphi$  der Standardnormalverteilung, und wie wird ihr Graph anschaulich genannt?

$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ . Der Graph von  $\varphi$  ist die berühmte Gaußsche Glockenkurve..

**Karteikarte 9.17** Wie ist die Verteilungsfunktion  $\Phi$  der Standardnormalverteilung definiert?

$\Phi(y) = \int_{-\infty}^y \varphi(x) dx$ , die Stammfunktion von  $\varphi$ .  $\Phi(y)$  entspricht der Fläche unter der Glockenkurve von  $-\infty$  bis  $y$ ..

**Karteikarte 9.18** Welche Grenzwerte gelten für die Dichte und Verteilungsfunktion der Standardnormalverteilung?

$\int_{-\infty}^{\infty} \varphi(x) dx = 1$  sowie  $\Phi(y) \rightarrow 0$  für  $y \rightarrow -\infty$  und  $\Phi(y) \rightarrow 1$  für  $y \rightarrow \infty$ ..

**Karteikarte 9.19** Welche Symmetrieeigenschaften hat die Standardnormalverteilung?

Da  $\varphi$  eine gerade Funktion ist, gilt  $\Phi(0) = \frac{1}{2}$  sowie  $\Phi(z) = 1 - \Phi(-z)$  für alle  $z \in \mathbb{R}$ ..

## 9.4.1 | Anwendungstechniken zum Satz von de Moivre-Laplace

**Frage 9.2** Die exakte Rechnung ergab  $\mathbb{P}(A_n) \approx 0.80$  (Genauer  $\mathbb{P}(A_n) \approx 0.804486$ ). Warum finden wir mit dem Satz von de Moivre-Laplace nur  $pe(A_n) \approx 0.78$ ? (2026)

**1. Antwort:**  $n = 142$  ist noch kein wirklich großes  $n$ .

**2. Antwort:** Grob gesprochen, approximieren wir eine diskrete Größe, die Anzahl der Erfolge  $S_n$ , durch etwas Kontinuierliches. Eine Verbesserung ist oft möglich durch die sogenannte Stetigkeitskorrektur: .

Wir modifizieren die Grenzen in  $A_n$  geschickt und rechnen

$$\begin{aligned}\mathbb{P}(A_n) &= \mathbb{P}\left(\left\lceil \frac{3n}{10} \right\rceil - 1 < S_n \leq \left\lfloor \frac{7n}{10} \right\rfloor\right) \\ &= \mathbb{P}\left(\left\lceil \frac{3n}{10} \right\rceil - \frac{1}{2} < S_n \leq \left\lfloor \frac{7n}{10} \right\rfloor + \frac{1}{2}\right) && \text{(weil } S_n \text{ ganzzahlig ist)} \\ &\approx \Phi(0.86) \approx 0.8051 && \text{(Tabelle)}\end{aligned}$$

Bingo!

Beachte, dass die Stetigkeitskorrektur nicht immer besser ist (siehe Hausaufgaben).

### Beispiel 9.6 Vorlesung vs. Schlaf II (2026)

Wie groß ist die Wahrscheinlichkeit, dass von 142 Hörern nächste Woche mindestens 90 die Vorlesung besuchen?

**Was ist anders als im obigen Beispiel?** Neu an dieser Frage ist, dass wir nur eine untere Schranke gegeben haben, d.h., wir suchen die Wahrscheinlichkeit von

$$B_n = \{S_n \geq 90\}$$

Dieser Fall ist in unserer Formulierung des Satzes von de Moivre-Laplace nicht vorgesehen!

**Idee, das Problem zu umgehen:** Wir werden uns künstlich eine triviale obere Schranke verschaffen.

$$\begin{aligned}\mathbb{P}(B_n) &= \mathbb{P}(S_n \geq 90) \\ &= \mathbb{P}(89 < S_n \leq n) && \text{(triviale obere Schranke)} \\ &= \mathbb{P}(89.5 < S_n \leq n) && (S_n \text{ ganzzahlig, Stetigkeitskorrektur)} \\ &= \mathbb{P}\left(c_n < \frac{S_n - np}{\sqrt{npq}} \leq d_n\right) && \text{(Standardisieren)} \\ &\approx \Phi(d_n) - \Phi(c_n) && \text{(Satz von de Moivre-Laplace)} \\ &= \Phi(d_n) - [1 - \underbrace{\Phi(-c_n)}_{>0}] \approx 0.8212 && \text{(Tabelle)}\end{aligned}$$

mit

$$c_n = \frac{89.5 - np}{\sqrt{npq}} \approx -0.92 \quad \text{und} \quad d_n = \frac{nq}{\sqrt{npq}} \sqrt{\frac{nq}{p}} \approx 8.43.$$

Exakte Rechnung ergibt  $\mathbb{P}(B_n) = 0.821556 \dots$



**Bemerkung 9.4** (2026)

Generell gelten, sofern der Satz von de Moivre-Laplace anwendbar ist,

$$\mathbb{P}(s_n > c) = \mathbb{P}\left(\frac{c - np}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{n - np}{\sqrt{npq}}\right) \approx 1 - \Phi\left(\frac{c - np}{\sqrt{npq}}\right)$$

und

$$\mathbb{P}(s_n \leq d) = \mathbb{P}\left(\frac{-1 - np}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{d - np}{\sqrt{npq}}\right) \approx \Phi\left(\frac{d - np}{\sqrt{npq}}\right)$$

weil für große  $n$

$$\Phi\left(\frac{-1 - np}{\sqrt{npq}}\right) \approx 0 \quad \text{und} \quad \frac{n - np}{\sqrt{npq}} \approx 1$$

**Karteikarte 9.20** Worauf muss man achten, wenn man den Satz von de Moivre-Laplace auf ein Ereignis wie  $\{c_1 \leq S_n \leq c_2\}$  mit ganzzahligem  $S_n$  anwendet?

Der Satz ist für halboffene Intervalle der Form  $a < \frac{S_n - np}{\sqrt{npq}} \leq b$  formuliert. Da  $S_n$  nur ganzzahlige Werte annimmt, muss man  $\{c_1 \leq S_n \leq c_2\}$  zunächst als die identische Menge  $\{c_1 - 1 < S_n \leq c_2\}$  umschreiben, bevor man standardisiert und den Satz anwendet..

**Karteikarte 9.21** Was ist die Stetigkeitskorrektur, und wozu dient sie?

Bei der Approximation von Wahrscheinlichkeiten für eine diskrete (ganzzahlige) Zufallsvariable  $S_n$  durch die stetige Standardnormalverteilung verschiebt man die Intervallgrenzen zusätzlich um  $\pm \frac{1}{2}$  (z.B. wird  $\{c_1 \leq S_n \leq c_2\}$  zu  $\{c_1 - \frac{1}{2} < S_n \leq c_2 + \frac{1}{2}\}$ ), um die Diskretisierung besser zu berücksichtigen. Dies verbessert die Approximation häufig, aber nicht immer..

**Karteikarte 9.22** Wie geht man vor, wenn man mit dem Satz von de Moivre-Laplace die Wahrscheinlichkeit eines einseitig beschränkten Ereignisses wie  $\{S_n \geq c\}$  approximieren möchte, obwohl der Satz beidseitige Schranken  $a < \cdot \leq b$  voraussetzt?

Man ergänzt künstlich eine triviale obere Schranke, z.B.  $S_n \leq n$  (da  $S_n$  ohnehin nicht größer als  $n$  sein kann), schreibt also  $\{S_n \geq c\} = \{c - 1 < S_n \leq n\}$ , und wendet den Satz auf dieses beidseitig beschränkte Intervall an..

**Karteikarte 9.23** Welche Näherungsformel ergibt sich (bei Anwendbarkeit des Satzes von de Moivre-Laplace) für  $P(S_n > c)$ ?

$P(S_n > c) \approx 1 - \Phi\left(\frac{c - np}{\sqrt{npq}}\right)$  für großes  $n$  (da die obere Standardisierungsgrenze gegen  $\infty$  strebt und  $\Phi$  dort gegen 1 geht)..

**Karteikarte 9.24** Welche Näherungsformel ergibt sich für  $P(S_n \leq d)$ ?

$P(S_n \leq d) \approx \Phi\left(\frac{d - np}{\sqrt{npq}}\right)$  für großes  $n$  (da die untere Standardisierungsgrenze gegen  $-\infty$  strebt und  $\Phi$  dort gegen 0 geht)..

**Karteikarte 9.25** Warum trägt eine Intervallgrenze bei einer Anwendung des Satzes von de Moivre-Laplace manchmal praktisch nicht zur approximierten Wahrscheinlichkeit bei?

Wenn diese Grenze nach Standardisierung sehr weit von 0 entfernt liegt, ist der zugehörige  $\Phi$ -Wert bereits extrem nah an 0 oder 1. Das passt zum Gesetz der großen Zahlen: Liegt eine Grenze weit von der durch  $p$  vorgegebenen typischen relativen Häufigkeit entfernt, wird sie für wachsendes  $n$  so gut wie nie unter- bzw. überschritten, während eine Grenze nahe am typischen Bereich noch deutlich ins Gewicht fällt..

## Lernziele

- **ZGWS**: Aussage formulieren können and anwenden können
- **PGWS**: Aussage formulieren können and anwenden können
- Wann wird welche Approximation verwendet?

## Ergänzung zum Satz von de Moivre-Laplace

### Erinnerung 9.2 Satz von de Moivre-Laplace (2026)

Sei  $S_n$  die Anzahl der Erfolge in einem  $n$ -fach unabhängig wiederholten Bernoulli-Experiment mit Erfolgswahrscheinlichkeit  $p \in (0, 1)$ .

Dann gilt für jede Wahl von Konstanten  $a, b$  mit  $-\infty < a < b < \infty$

$$\lim_{n \rightarrow \infty} \mathbb{P} \left( a < \frac{S_n - np}{\sqrt{npq}} \leq b \right) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-x^2/2} dx$$

Für große  $n$  folgt insbesondere, dass

$$\mathbb{P}(np - c < S_n \leq np + c) \approx \int_{-c/\sqrt{npq}}^{c/\sqrt{npq}} \underbrace{\frac{1}{\sqrt{2\pi}} e^{-x^2/2}}_{\text{Verteilungsfunktion der Standardnormalverteilung}} dx = \frac{1}{\sqrt{2\pi}} \int_{-c/\sqrt{npq}}^{c/\sqrt{npq}} e^{-x^2/2} dx = 2\Phi\left(\frac{c}{\sqrt{npq}}\right) - 1$$

Das folgt direkt aus dem allgemeinen Satz, wenn man die Konstanten  $a$  und  $b$  passend wählt.

Denn die WS für  $np - c < S_n \leq np + c$  ist äquivalent für die von  $-c < S_n - np \leq c$ . Weil  $\sqrt{npq} > 0$  (und das ist gegeben, weil  $p \in (0, 1)$ , also  $p$  ist echt größer als 0 und echt kleiner als 1;  $n \leq 1$  ist die Anzahl der Versuche;  $q = 1 - p$  und wir wissen ja bereits, dass  $p$  echt kleiner 1, also  $q > 0$ ), kann man dadurch teilen und das hat dann die passende Form, um Moivre-Laplace anzuwenden:

$$\frac{-c}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{c}{\sqrt{npq}}$$

Und die Gleichung ergibt sich aus

$$\Phi\left(\frac{c}{\sqrt{npq}}\right) - \Phi\left(-\frac{c}{\sqrt{npq}}\right) = \Phi\left(\frac{c}{\sqrt{npq}}\right) - \left(1 - \Phi\left(\frac{c}{\sqrt{npq}}\right)\right) = 2\Phi\left(\frac{c}{\sqrt{npq}}\right) - 1$$

- Ist  $c > 0$  nicht von  $n$  abhängig, so geht die WS mit  $n \rightarrow \infty$  gegen Null ( $c$  ist eine feste Konstante, hängt nicht von  $n$  ab)
- Ist  $0 < c \ll \sqrt{n}$ , so geht die WS mit  $n \rightarrow \infty$  immer noch gegen Null ( $c$  wächst, aber langsamer als  $\sqrt{n}$ )
- Relevanter Beitrag, d.h., WS größer als null, nur für  $c \approx \sqrt{n}$  (oder größer) ( $c$  wächst in derselben Größenordnung wie  $\sqrt{n}$ )

Das erklärt, wie sich die Wahrscheinlichkeit  $\mathbb{P}(np - c < S_n \leq np + c) \approx 2\Phi\left(\frac{c}{\sqrt{npq}}\right) - 1$  verhält, je nachdem wie schnell  $c$  mit  $n$  wächst (oder eben nicht wächst).

**Kommentar 9.3** Zu : Die Liste ist relevant, denn ist  $npq$  zu klein, ist die Normalapproximation schlecht, und man sollte lieber exakt mit der Binomialverteilung rechnen (oder mit der Poisson-Approximation, falls  $p$  sehr klein

ist).

**Karteikarte 9.26** Welche Näherungsformel ergibt sich aus dem Satz von de Moivre-Laplace für ein symmetrisches Intervall  $P(np - c < S_n \leq np + c)$ ?

$P(np - c < S_n \leq np + c) \approx 2\Phi\left(\frac{c}{\sqrt{npq}}\right) - 1$  für großes  $n$ . Dies folgt aus dem Satz von de Moivre-Laplace mit  $a = -c/\sqrt{npq}$ ,  $b = c/\sqrt{npq}$  und der Symmetrie  $\Phi(-z) = 1 - \Phi(z)$ .

**Karteikarte 9.27** Wie hängt das asymptotische Verhalten von  $P(np - c < S_n \leq np + c)$  von der Wachstumsordnung der Konstante  $c = c(n)$  ab?

Ist  $c > 0$  fest (unabhängig von  $n$ ), geht die Wahrscheinlichkeit für  $n \rightarrow \infty$  gegen 0. Wächst  $c$  zwar mit  $n$ , aber langsamer als  $\sqrt{n}$  (d.h.  $0 < c \ll \sqrt{n}$ ), geht die Wahrscheinlichkeit ebenfalls gegen 0. Erst wenn  $c$  in derselben Größenordnung wie  $\sqrt{n}$  wächst (oder schneller), ergibt sich ein relevanter, positiver Beitrag.

**Karteikarte 9.28** Wann ist die Normalapproximation (Satz von de Moivre-Laplace) für die Binomialverteilung schlecht, und was tut man dann stattdessen?

Ist  $npq$  zu klein, ist die Normalapproximation schlecht. Man sollte dann entweder exakt mit der Binomialverteilung rechnen oder – falls zusätzlich  $p$  sehr klein ist – die Poisson-Approximation verwenden.

## 9.5 | Vergleich Gesetz der großen Zahlen vs. ZGWS

**Beobachtung 9.1** Vergleich mit dem Gesetz der großen Zahlen (2026)

$$\begin{aligned} \mathbb{P}\left(\left|\frac{1}{n}S_n - \mathbb{E}[X_1]\right| \geq \epsilon\right) &= 1 - \mathbb{P}(-\epsilon < \frac{1}{n}S_n - p < \epsilon) \\ &\approx 1 - \mathbb{P}\left(-\frac{n\epsilon}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{n\epsilon}{\sqrt{npq}}\right) \end{aligned}$$

Gesetz der großen Zahlen:

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n}S_n - \mathbb{E}[X_1]\right| \geq \epsilon\right) = 0 \quad \forall \epsilon > 0$$

und Satz von de Moivre-Laplace

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-x^2/2} dx = \int_a^b \varphi(x) dx$$

Verhalten für beschrieben durch

- $\epsilon$  der Ordnung 1 (konstant) : Gesetz der großen Zahlen
- $\epsilon$  der Ordnung  $\frac{1}{\sqrt{n}}$  ()

**Kommentar 9.4** Bneutz man für Stichprobengröße bestimmen, Konfidenzintervalle, Fehlerabschätzung bei Simulationen / Monte-Carlo-Methoden, Qualitätskontrolle / Fehlerraten

**Karteikarte 9.29** Wie hängt es von der Größenordnung der betrachteten Abweichung  $\epsilon$  ab, ob das Gesetz der großen Zahlen oder der Satz von de Moivre-Laplace/Zentrale Grenzwertsatz das Verhalten von  $P(|\frac{1}{n}S_n - E[X_1]| \geq \epsilon)$  beschreibt?

Ist  $\epsilon$  von konstanter Ordnung (unabhängig von  $n$ ), beschreibt das Gesetz der großen Zahlen das Verhalten (die Wahrscheinlichkeit geht gegen 0, ohne quantitative Aussage über die Geschwindigkeit). Ist  $\epsilon$  dagegen von der

Ordnung  $\frac{1}{\sqrt{n}}$  (skaliert mit der Stichprobengröße), liefert der Satz von de Moivre-Laplace/Zentrale Grenzwertsatz eine quantitative Näherung mit einem nicht-trivialen Grenzwert..

**Karteikarte 9.30 Klausur-Faustregel: Woran erkennt man, ob eine Aufgabe das Gesetz der großen Zahlen oder den Zentralen Grenzwertsatz (Satz von de Moivre-Laplace) erfordert?**

Wird nur gefragt, ob ein Grenzwert existiert bzw. etwas konvergiert, reicht das Gesetz der großen Zahlen. Wird dagegen gefragt, wie groß  $n$  sein muss, wie genau eine Schätzung ist, oder soll ein Konfidenzintervall angegeben werden, ist der Zentrale Grenzwertsatz gefragt (mit der  $\Phi$ -Tabelle)..

**Karteikarte 9.31 Wofür wird der Zentrale Grenzwertsatz (bzw. der Satz von de Moivre-Laplace) in der Praxis typischerweise verwendet?**

Zum Bestimmen benötigter Stichprobengrößen, zur Angabe von Konfidenzintervallen, zur Fehlerabschätzung bei Simulationen/Monte-Carlo-Methoden sowie in der Qualitätskontrolle bzw. bei Fehlerraten..

## 9.6 | ZGWS

**Satz 9.6 ZGWS Verallgemeinerung des Satzes von de Moivre-Laplace (2026)**

Gegeben Zufallsvariablen  $X_1, X_2, X_3, \dots$  auf einem Wahrscheinlichkeitsraum  $(\Omega, \mathbb{P})$ .

Angenommen  $X_1, X_2, X_3, \dots$  sind unabhängig und identisch verteilt und  $\sigma^2 = \text{Var}(X_i) \in (0, \infty)$  für alle  $i$ .

(Beachte  $\text{Var}(X_i) < \infty \Rightarrow \mathbb{E}[X_i]$  ex.)

Dabei ist  $S_n = \sum_{i=1}^n X_i$  und  $\mathcal{M} = \mathbb{E}[X_i]$ .

Dann gilt:

$$\lim_{n \rightarrow \infty} \mathbb{P} \left( a < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq b \right) = \Phi(b) - \Phi(a)$$

**Satz 9.7 ZGWS für Bernoulli-Variablen (2026)**

Sind die Zufallsvariablen  $X_1, X_2, X_3, \dots$  unabhängige Bernoulli-Variablen, so gelten:  $\mathcal{M} = \mathbb{E}[X_i] = p$  und  $\sigma^2 = \text{Var}(X_1) = pq$  mit  $q = 1 - p$  und es folgt

$$\lim_{n \rightarrow \infty} \mathbb{P} \left( a < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq b \right) = \mathbb{P} \left( a < \frac{S_n - np}{\sqrt{npq}} \leq b \right) = \Phi(b) - \Phi(a)$$

Man kann den zentralen Grenzwertsatz verallgemeinern, indem man bestimmte Voraussetzungen abschwächt:

**Lemma 9.1 Bekannte Verallgemeinerungen (2026)**

- Die Voraussetzung der identischen Verteilung kann abgeschwächt werden (z.B. zur Lindeberg-Bedingung).
  - Also: man muss nicht verlangen, dass alle  $X_i$  dieselbe Verteilung haben. Zum Beispiel darf  $X_1$  normalverteilt sein,  $X_2$  exponentialverteilt,  $X_3$  wieder was anderes, solange sie noch unabhängig sind. Damit der ZGWS trotzdem noch gilt, braucht man aber eine Ersatzbedingung, die dafür sorgt, dass keine einzelne Variable die Summe zu stark dominiert. Das ist die Lindeberg-Bedingung.
- Die Voraussetzung der Unabhängigkeit kann abgeschwächt werden (ZGWS von Lindeberg-Feller).
  - Es gibt Verallgemeinerungen des ZGWS für gewisse Arten von abhängigen Zufallsvariablen. Diese Verallgemeinerung erlaubt es, den ZGWS trotzdem anzuwenden, solange die Abhängigkeit nicht zu stark ist.
- Die Voraussetzungen  $\sigma^2 > 0$  und  $\sigma^2 < \infty$  dagegen sind notwendig

**Beispiel 9.7** Augensumme in 420 Würfeln eines fairen Würfels (2026)

Wie groß ist die WS, dass die Augensumme zwischen 1400 und 1550 liegt?


- $\Omega = \{1, \dots, 6\}^n$  mit  $n = 420$
- $\mathbb{P}$  Gleichverteilung auf  $\Omega$
- $X_i(\omega) = \omega_i$  für  $i = 1, \dots, n$  sind unabhängige, identisch verteilte ZV
- $\mathcal{M} = \mathbb{E}[X_i] = \frac{7}{2}$  und  $\sigma^2 = \text{Var}(X_i) = \frac{35}{12}$
- $S_n(\omega) = \sum_{i=1}^n X_i(\omega)$  ist die Augensumme in n Würfeln

$$\begin{aligned}
 \mathbb{P}(1400 \leq S_n \leq 1550) &= \mathbb{P}(1399 < S_n \leq 1550) \\
 &= \mathbb{P}\left(\frac{1399 - n\mathcal{M}}{\sqrt{n\sigma^2}} < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq \frac{1550 - n\mathcal{M}}{\sqrt{n\sigma^2}}\right) \\
 &= \mathbb{P}\left(\frac{1399 - 420 \cdot \frac{7}{2}}{\sqrt{420 \cdot \frac{35}{12}}} < \frac{S_n - 420 \cdot \frac{7}{2}}{\sqrt{420 \cdot \frac{35}{12}}} \leq \frac{1550 - 420 \cdot \frac{7}{2}}{\sqrt{420 \cdot \frac{35}{12}}}\right) \\
 &= \mathbb{P}\left(-\frac{71}{35} < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq \frac{80}{35}\right) \\
 &\approx \Phi(2.29) - \Phi(-2.03) \\
 &\approx 0.9890 - (1 - 0.9788) = 0.9678
 \end{aligned}$$

**Beispiel 9.8** Augensumme aus n Würfeln eines fairen Würfels (2026)

Jede Durchführung des Experiments ergibt die Augensumme aus n Würfeln eines fairen Würfels. Jedes Histogramm für ein festes n zeigt diese Augensumme in jeweils 5000 Durchführungen des Experiments. Vergleich mit der entsprechend skalierten Gaußschen Glockenkurve.

$n \in \{1, 2, 3, 4, 5, 10, 50, 100\}$

**Karteikarte 9.32** Wie lautet der Zentrale Grenzwertsatz (Verallgemeinerung des Satzes von de Moivre-Laplace)?

Seien  $X_1, X_2, \dots$  unabhängig und identisch verteilt mit  $\sigma^2 = \text{Var}(X_i) \in (0, \infty)$  und  $\mu = E[X_i]$  für alle  $i$ , sowie

$S_n = \sum_{i=1}^n X_i$ . Dann gilt für alle  $-\infty < a < b < \infty$ :  $\lim_{n \rightarrow \infty} P\left(a < \frac{S_n - n\mu}{\sqrt{n\sigma^2}} \leq b\right) = \Phi(b) - \Phi(a)$ .

**Karteikarte 9.33** Wie spezialisiert sich der Zentrale Grenzwertsatz auf unabhängige Bernoulli-Variablen, und wie heißt dieser Spezialfall?

Für unabhängige Bernoulli-Variablen  $X_i$  mit  $\mu = E[X_i] = p$  und  $\sigma^2 = \text{Var}(X_i) = pq$  ( $q = 1 - p$ ) ergibt sich  $\lim_{n \rightarrow \infty} P\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) = \Phi(b) - \Phi(a)$  – das ist genau der Satz von de Moivre-Laplace..

**Karteikarte 9.34** Welche Voraussetzungen des Zentralen Grenzwertsatzes können abgeschwächt werden, und welche sind notwendig?

Die Voraussetzung identischer Verteilung kann abgeschwächt werden (z.B. zur Lindeberg-Bedingung, die verhindert, dass eine einzelne Variable die Summe dominiert). Die Unabhängigkeitsvoraussetzung kann ebenfalls abgeschwächt werden (Zentraler Grenzwertsatz von Lindeberg-Feller, für bestimmte Arten schwacher Abhängigkeit). Die Voraussetzungen  $\sigma^2 > 0$  und  $\sigma^2 < \infty$  sind dagegen notwendig..

## 9.7 | PGWS

**Satz 9.8** PGWS Approximationen der Binomialverteilung (2026)

Gilt  $np_n \rightarrow \alpha > 0$  für  $n \rightarrow \infty$ , so gilt für jedes feste  $k \in \mathbb{N}$

$$\mathcal{B}_{n,p}(k) \rightarrow \mathcal{P}_\alpha(k) = \frac{\alpha^k}{k!} e^{-\alpha} \quad \text{für } n \rightarrow \infty$$

**Beweis.** Sei  $k$  fest und  $np_n \rightarrow \alpha > 0$  für  $n \rightarrow \infty$ . Daraus folgt insbesondere:  $p_n \rightarrow 0$  für  $n \rightarrow \infty$ .

$$\begin{aligned} \mathcal{B}_{n,p}(k) &= \binom{n}{k} p_n^k (1 - p_n)^{n-k} \\ &= \frac{n(n-1)\dots(n-k+1)}{k!} p_n^k (1 - p_n)^{n-k} \\ &= \underbrace{1 \cdot \left(1 - \frac{1}{n}\right) \dots \left(1 - \frac{k-1}{n}\right)}_{\rightarrow 1} \underbrace{\frac{(np_n)^k}{k!}}_{\rightarrow \frac{\alpha^k}{k!}} \underbrace{\left(1 - \frac{np_n}{n}\right)^n}_{\xrightarrow{*} e^{-\alpha}} \underbrace{(1 - p_n)^{-k}}_{\rightarrow 1} \\ &\rightarrow \frac{\alpha^k}{k!} e^{-\alpha} \\ &= \mathcal{P}_\alpha(k) \end{aligned}$$

\*  $\left(1 - \frac{\alpha_n}{n}\right)^n \rightarrow e^{-\alpha}$  gilt auch für Folge  $(\alpha_n)_n$  mit  $\alpha_n \rightarrow \alpha$ , nicht nur für feste  $\alpha$ .

**Bemerkung 9.5** Fehlerabschätzung / Güte der Approximation (2026)

Gegeben  $S_n$  binomialverteilt mit Parametern  $n$  und  $p_n$  und  $Z_{np_n}$  poisson-verteilt mit Parameter  $np_n$ . Angenommen  $np_n \rightarrow \alpha$ . Dann gilt die Abschätzung

$$\sup_{C \subset \mathbb{N}_0} |\mathbb{P}(S_n \in C) - \mathbb{P}(Z_{np_n} \in C)| \leq 2np_n^2 = 2 \underbrace{np_n}_{\rightarrow \alpha} p_n$$

Und für jede Konstante  $K > 2$  und  $n$  groß genug gilt

$$\sup_{C \subset \mathbb{N}_0} |\mathbb{P}(S_n \in C) - \mathbb{P}(Z_{np_n} \in C)| \leq K\alpha p_n \rightarrow 0 \quad \text{für } n \rightarrow \infty$$

**Bemerkung 9.6** Die Poisson-Approximation ist gut, wenn  $n$  groß im Vergleich zu  $k$  ist ( $n \gg k$ ) und  $p$  klein ist ( $n \gg \alpha := np$ ). Das heißt insbesondere, dass die Erfolgswahrscheinlichkeit klein sein muss. Für derartige seltene Ereignisse verwenden wir  $\mathbb{P}(S_n = k) \approx \mathcal{P}_\alpha(k)$  mit  $\alpha := np$ .

**Karteikarte 9.35 Wann ist die Poisson-Approximation ist gut?**

Wenn  $n$  groß im Vergleich zu  $k$  ist ( $n \gg k$ ) und  $p$  klein ist ( $n \gg \alpha := np$ ). Das heißt insbesondere, daß die Erfolgswahrscheinlichkeit klein sein muss..

**Beispiel 9.9 Seltenes Ereignis / Roulette (2026)**

Wir betrachten ein Roulettespiel mit 36 “Zahlen” und einer “Null”.

Wir setzen immer auf eine bestimmte Zahl:  $p = 1/37$  und wir tun dies  $n = 37$  Mal. Das heißt, wir erwarten im Mittel einen Gewinn:  $\alpha = np = 1$ .

Wie groß ist die **WS**,  $0\times, 1\times, 2\times, \dots$  zu gewinnen?

| $k$      | $\mathcal{B}_{37,1/37}(k)$ | $\mathcal{P}_1(k)$  |
|----------|----------------------------|---------------------|
| 0        | 0.363                      | 0.368               |
| 1        | 0.363                      | 0.368               |
| 2        | 0.186                      | 0.184               |
| $\vdots$ | $\vdots$                   | $\vdots$            |
| 5        | 0.00261                    | 0.00306             |
| $\vdots$ | $\vdots$                   | $\vdots$            |
| 15       | $1.5 \cdot 10^{14}$        | $2.8 \cdot 10^{13}$ |

**Beispiel 9.10 Historisches Beispiel zur Poisson-Approximation: Tote durch Hufschlag in Preussen (2026)**

Vorliegende Daten: 10 Armeecorps über 20 Jahre, entspricht 200 Corps-Jahren.

| Tote $k$ | Anzahl Jahre mit $k$ Toten | $200 \cdot P_\varrho(k)$ mit $\varrho = 0,61$ |
|----------|----------------------------|-----------------------------------------------|
| 0        | 109                        | 109                                           |
| 1        | 65                         | 66                                            |
| 2        | 22                         | 20                                            |
| 3        | 3                          | 4                                             |
| 4        | 1                          | 1                                             |
| $\geq 5$ | 0                          | 0                                             |

**Tabelle 9.2:** Die durch Schlag eines Pferdes im preussischen Heere Getöteten (Ladislaus von Bortkiewicz, Das Gesetz der kleinen Zahlen, Teubner (1898))

Hier wurde  $\alpha$  gewählt als die mittlere Anzahl an Toten pro (Corps-)Jahr:

$$\alpha = (1 \cdot 65 + 2 \cdot 22 + 3 \cdot 3 + 1 \cdot 4) / 200 = 0,61$$

**Beispiel 9.11 Beispiel zur Poisson-Approximation: Zellzählung im Gitternetz (2026)**

Zellen unter dem Mikroskop, Gitternetz, im Schnitt  $\nu$  Zellen pro kleinem Quadrat,  $N$  Quadrate.

**Modellierung:** Verteile  $N\nu$  Zellen zufällig und unabhängig voneinander auf  $N$  Quadrate. Wahrscheinlichkeit  $p = 1/N$  für eine Zelle, im vorab gewählten Quadrat  $\varphi$  zu landen. Wahrscheinlichkeit  $k$  Zellen im Quadrat  $\varphi$  zu finden, ist  $\mathcal{B}_{N\nu,1/N}(k)$ .

$$np_n \equiv \nu \begin{cases} n &= N\nu \\ p_n &= \frac{1}{N} \end{cases}$$

Bei großer Zahl  $N$  von Quadraten gelten  $N\nu \gg k$  und  $N\nu \gg \underbrace{(N\nu)}_n \underbrace{\frac{1}{N}}_{p_n} = \nu$ .

Poisson-Approximation zeigt  $\mathcal{B}_{N\nu, 1/N}(k) \approx \mathcal{P}_\nu(k)$ .

Dies rechtfertigt, eine derartige **Verteilung** von Zellen oder Teilchen mit Hilfe der **Poisson-Verteilung** zu modellieren.

### Beispiel 9.12 Beispiel zur Poisson-Approximation: Im zeitlichen Verlauf eintreffende Rechenaufträge (2026)

Im Schnitt  $\alpha$  eintreffende Rechenaufträge pro Zeiteinheit (z.B. pro Stunde)

**WS**, dass ein Auftrag eintrifft in einem sehr kleinen Zeitfenster der Länge  $\delta \ll 1$  sei näherungsweise  $\alpha\delta$ . ( $\delta$  sehr klein, z.B. eine Millisekunde)).

Wir zerlegen das Gesamtzeitintervall  $[0, t]$  in  $N$  sehr kleine, disjunkte Teilintervalle der Länge  $t/N$ . (für ein festes  $t$ , z.B. 30 Minuten, 24 Stunden, drei Wochen, ...)

$$[0, t) = \bigcup_{k=1}^N \left[ \frac{k-1}{N} \cdot t, \frac{k}{N} \cdot t \right)$$

**WS**, dass ein Auftrag eintrifft in einem bestimmten dieser Zeitfenster, ist näherungsweise  $\alpha t/N$ .

**Annahmen:** Für großes  $N$  sind die Zeitfenster so klein, dass wir annehmen dürfen, dass in jedem Fenster ein oder kein Auftrag eintrifft (d.h., wir schließen aus, dass mehr als ein Auftrag eintreffen kann). Ob ein Auftrag in einem bestimmten Fenster eintrifft, sei unabhängig vom Eintreffen von Aufträgen in allen anderen Zeitfenstern.

**Modellierung:** Damit haben wir jedem Zeitfenster, d.h. jedem  $k$ , eine **Bernoulli-Variable** zugeordnet, die uns sagt, ob im zugehörigen Zeitfenster  $k$  ein Auftrag eintrifft. Die Erfolgswahrscheinlichkeit dieser **Bernoulli-Variable** ist  $\alpha t/N$  (Also die **WS**, dass ein Auftrag in einem bestimmten Zeitfenster eintritt). Die Anzahl der Aufträge, die im Intervall  $[0, t)$  eintreffen, ist binomialverteilt mit Parametern  $N$  und  $\alpha t/N$ .

$$n = N, \quad p_n = \frac{\alpha t}{N} = \alpha t \frac{1}{N}$$

Für die **WS**, insgesamt  $\varphi$  Aufträge im Intervall  $[0, t)$  zu haben, ergibt die Poisson-Approximation für große  $N$ :

$$\mathcal{B}_{N, \alpha t/N}(\varphi) \approx \mathcal{P}_{N \cdot \alpha t/N}(\varphi) = \mathcal{P}_{\alpha t}(\varphi)$$

(Beachten Sie, dass wir in diesem Problem  $N$  beliebig groß machen dürfen. Wir verwenden hier die beliebige Teilbarkeit der Zeit!)

Wiederum rechtfertigt unsere Betrachtung, beim Modellieren derartiger Prozesse generell die **Poisson-Verteilung** zu verwenden.

### Lemma 9.2 Poisson-Approximation für Erfolgswahrscheinlichkeit $p$ nahe 1 (2026)

Betrachte die Anzahl Erfolge  $S_n$  in einem unabhängig  $n$ -mal wiederholten Bernoulli-Experiment mit:

- $n$  groß
- $p$  nahe bei 1, d.h.,  $q = 1 - p$  klein

Zusatzüberlegung erlaubt es, die Poisson-Approximation anzuwenden: Tausche die Rollen von “Erfolg” und “Misserfolg” (zähle Misserfolge !)

$\tilde{S}_n = n - S_n$  zählt die Anzahl der “Misserfolge”  $\tilde{S}_n$  ist  $\mathcal{B}_{n, q}$ -verteilt.



Sei  $\tilde{\alpha} = \mathbb{E}[\tilde{S}_n] = nq$ .

Poisson-Approximation:

$$\mathbb{P}(\tilde{S}_n = k) = \mathcal{B}_{n,q}(k) \approx \mathcal{P}_{\tilde{\alpha}}(k); \quad \forall k \in \mathbb{N}_0$$

“Zurück übersetzen”: Für alle  $k \in \mathbb{N}_0$  gilt:

$$\mathbb{P}(S_n = k) = \mathbb{P}(\tilde{S}_n = n - k) = \mathcal{B}_{n,q}(n - k) \approx \mathcal{P}_{\tilde{\alpha}}(n - k) = \frac{(nq)^{(n-k)}}{(n - k)!} e^{-nq}$$

Also:

$$\mathbb{P}(S_n = k) = \mathbb{P}((n - S_n) = n - k) = \mathcal{B}_{n,q}(n - k) \approx \mathcal{P}_{\mathbb{E}[n - S_n]}(n - k) = \frac{(nq)^{(n-k)}}{(n - k)!} e^{-nq}$$

Bzw.:

$$\mathbb{P}(S_n = k) = \mathbb{P}((n - S_n) = n - k) = \mathcal{B}_{n,q}(n - k) \approx \mathcal{P}_{nq}(n - k) = \frac{(nq)^{(n-k)}}{(n - k)!} e^{-nq}$$

## Beispielaufgabe Laubfrosch

(2026)

Ein Laubfrosch legt  $n = 1000$  Eier. Aus jedem Ei entwickelt sich mit der WS  $p = \frac{1}{200}$  ein Frosch.

### Aufgabe 9.1 Wahrscheinlichkeitsraum angeben und Modell rechtfertigen

Ziel: Wahrscheinlichkeit, dass sich höchstens zwei Frösche entwickeln.

**Lösung:**  $n = 1000$ ,  $\Omega = \{0, 1\}^{1000}$

$\omega_i = 1$  bedeutet i-tes Ei entwickelt sich zum Frosch.

$$\mu(\omega) = p^{\sum_{i=1}^n \omega_i} (1 - p)^{n - \sum_{i=1}^n \omega_i} \quad \forall \omega \in \Omega$$

Annahme: Frösche entwickeln sich unabhängig voneinander mit gleicher WS

### Aufgabe 9.2 Zufallsvariable, die Anzahl der Frösche angibt, die Verteilung und ggf. Parameter

$S_n : \Omega \rightarrow \{0, \dots, n\}$  und

$$S_n(\omega) := \sum_{i=1}^n \omega_i \quad \forall \omega \in \Omega$$

Als Anzahl von Erfolgen in unabhängig wiederholten Bernoulli-Experimenten ist  $S_n$  binomialverteilt mit Parametern  $n$  und  $p$ .

### Aufgabe 9.3 Erwartungswert und Varianz

$S_n$  ist binomialverteilt mit Parametern  $n$  und  $p$ . Daher existieren EW und Varianz und es gilt:

$$\mathbb{E}[S_n] = np = 1000 \frac{1}{200} = 5$$

und

$$\text{Var}(S_n) = np(1 - p) = 5 \cdot \left(1 - \frac{1}{200}\right) = 5 \cdot \frac{199}{200} = \frac{199}{40}$$

**Aufgabe 9.4 WS. maximal zwei Frösche zu haben**

$$\alpha = pn = 5$$

$$\begin{aligned}\mathbb{P}(S_n \leq 2) &= \mathbb{P}(S_n = 0) + \mathbb{P}(S_n = 1) + \mathbb{P}(S_n = 2) \\ &\approx \left[ \frac{\alpha^0}{0!} e^{-\alpha} + \frac{\alpha^1}{1!} e^{-\alpha} + \frac{\alpha^2}{2!} e^{-\alpha} \right] && \text{Poisson - Approx.} \\ &= \left[ 1 + 5 + \frac{25}{2} \right] e^{-\alpha} && * \\ &= \left[ 1 + 5 + \frac{25}{2} \right] e^{-5} && **\end{aligned}$$

\*  $n$  groß,  $p = \frac{1}{200}$  klein

\*\*  $k = 0, 1, 2$  klein gegenüber  $n$

**Bemerkung 9.7** Bruchrechnung im Kontext der Binomialapproximation nicht ausmultiplizieren! (2026)

Sondern mit Parametern rechnen und  $n$  und  $p$  so spät wie möglich einsetzen.

**Karteikarte 9.36** Wie lautet der Poissonsche Grenzwertsatz (Poisson-Approximation der Binomialverteilung)?

Gilt  $np_n \rightarrow \alpha > 0$  für  $n \rightarrow \infty$ , so gilt für jedes feste  $k \in \mathbb{N}_0$ :  $B_{n,p_n}(k) \rightarrow P_\alpha(k) = \frac{\alpha^k}{k!} e^{-\alpha}$ .

**Karteikarte 9.37** Wie gut ist die Poisson-Approximation quantitativ, wenn  $S_n$  binomialverteilt mit Parametern  $n, p_n$  und  $Z_{np_n}$  Poisson-verteilt mit Parameter  $np_n$  ist?

Es gilt  $\sup_{C \subseteq \mathbb{N}_0} |P(S_n \in C) - P(Z_{np_n} \in C)| \leq 2np_n^2$ . Gilt zusätzlich  $np_n \rightarrow \alpha$ , so ist diese Schranke für jede Konstante  $K > 2$  und  $n$  groß genug durch  $K\alpha p_n$  beschränkt, was für  $n \rightarrow \infty$  gegen 0 geht..

**Karteikarte 9.38** Unter welchen Bedingungen ist die Poisson-Approximation der Binomialverteilung gut?

Wenn  $n$  groß im Vergleich zu  $k$  ist ( $n \gg k$ ) und  $p$  klein ist, genauer  $n \gg \alpha := np$ . Insbesondere muss die Erfolgswahrscheinlichkeit klein sein – die Approximation eignet sich also für seltene Ereignisse:  $P(S_n = k) \approx P_\alpha(k)$  mit  $\alpha := np$ .

**Karteikarte 9.39** Welches allgemeine Modellierungsprinzip rechtfertigt die Poisson-Verteilung als Modell für Zählungen seltener, über viele Einheiten (Raum oder Zeit) verteilter Ereignisse?

Verteilt man eine Gesamtheit potenzieller Ereignisse unabhängig auf sehr viele kleine Einheiten (z.B. Rasterquadrate oder kurze Zeitintervalle), sodass jede einzelne Einheit nur mit kleiner Wahrscheinlichkeit ein Ereignis enthält, so ist die Gesamtzahl der Ereignisse binomialverteilt mit großem  $n$  und kleinem  $p$  – und damit nach dem Poissonschen Grenzwertsatz näherungsweise Poisson-verteilt mit Parameter  $\alpha = np$ .

**Karteikarte 9.40** Wie kann man die Poisson-Approximation anwenden, wenn die Erfolgswahrscheinlichkeit  $p$  nahe bei 1 liegt (statt nahe bei 0)?

Man vertauscht die Rollen von Erfolg und Misserfolg und zählt stattdessen die Misserfolge:  $\tilde{S}_n := n - S_n$  ist  $B_{n,q}$ -verteilt mit  $q = 1 - p$  klein, also gut durch Poisson mit Parameter  $\tilde{\alpha} = nq$  approximierbar. Zurückübersetzt ergibt

$$\text{sich } P(S_n = k) = P(\tilde{S}_n = n - k) \approx P_{nq}(n - k) = \frac{(nq)^{n-k}}{(n - k)!} e^{-nq}..$$

**Karteikarte 9.41** Welchen praktischen Rechentipp sollte man bei Approximationen der Binomialverteilung (Normal- oder Poisson-Approximation) beachten?

Man sollte Ausdrücke mit den Parametern  $n$  und  $p$  möglichst lange symbolisch stehen lassen und diese erst so spät wie möglich durch ihre konkreten Zahlenwerte ersetzen, statt frühzeitig auszumultiplizieren – das vereinfacht die Rechnung und vermeidet Fehler..

**Siehe auch** Zusammenhang Poissonscher Grenzwertsatz, Zentraler Grenzwertsatz, Satz von de Moivre-Laplace und Gesetz der großen Zahlen auf Seite 189.



## Statistik

### 10.1 | Daten, Häufigkeitsverteilungen und ihre Darstellung in der beschreibenden Statistik

#### 10.1.1 | Daten und Häufigkeitsverteilungen

**Erstes Ziel:** Darstellung empirischer Daten

#### Grundbegriffe

##### Definition 10.1 Datenerhebung (Skript 26)

Feststellen der Werte von Merkmalen an ausgewählten Versuchseinheiten.

##### Beispiel 10.1 Beispiel Datenerhebung (Skript 26)

| Versuchseinheit | Merkmal                        |
|-----------------|--------------------------------|
| Schweinchen     | Lage (beim Schweinewürfeln)    |
| Schweinchen     | Farbe (beim Ziehen aus Beutel) |
| Studierende     | erster Buchstabe vom Vornamen  |
|                 | Geburtstag                     |
|                 | Abiturnote                     |
| Schüler         | Alter in Jahren                |
|                 | Größe                          |
|                 | Gewicht                        |

##### Definition 10.2 Merkmal (Skript 26)

zu untersuchende Größe (ein- oder mehrdimensional, vgl. Farbe mit dem Tripel (Alter, Größe, Gewicht)).

##### Beispiel 10.2 Schweinewürfeln (Skript 26)

Fünf bis sieben Elementarereignisse (abhängig von Problemstellung):

- **Suhle:** Das Schwein liegt auf dem Rücken
- **Haxe:** Das Schwein steht auf seinen Füßen
- **Schnauze:** Das Schwein balanciert auf Vorderpfoten und Schnauze
- **Backe:** Das Schwein lehnt auf Vorderpfoten, Schnauze und einem Ohr

- ☐ ...auf Vorderpfoten, Schnauze und linkem Ohr
- ☐ ...auf Vorderpfoten, Schnauze und rechtem Ohr

■ **Faule Sau:** Das Schwein liegt auf der Seite

- ☐ ...und der Punkt ist *sichtbar*
- ☐ ...und der Punkt ist *nicht sichtbar*

Wir betrachten die folgenden sechs Elementarereignisse: *Suhle*, *Haxe*, *Schnauze*, *Backe*, *Faul-mit-Punkt*, *Faul-ohne-Punkt*.


**Modell**

$$\Omega = \{\text{Suhle}, \text{Haxe}, \text{Schnauze}, \text{Backe}, \text{Faul-mit-Punkt}, \text{Faul-ohne-Punkt}\}$$


Wie finden wir  $\mu(\omega)$  für alle  $\omega \in \Omega$ ?

**Experiment am 14.01.2026** (gerechtfertigt durch das Gesetz der großen Zahlen)


| Elementarereignis | Anzahl | relative Häufigkeit |
|-------------------|--------|---------------------|
| Suhle             | 59     | $\frac{59}{166}$    |
| Haxe              | 10     | $\frac{10}{166}$    |
| Schnauze          | 3      | $\frac{3}{166}$     |
| Backe             | 2      | $\frac{2}{166}$     |
| Faul-mit-Punkt    | 46     | $\frac{46}{166}$    |
| Faul-ohne-Punkt   | 46     | $\frac{46}{166}$    |
| $\Sigma$          | 166    | 1                   |




(a) Kreisdiagramm — kleiner Datensatz (Beispiel 1.3)



(b) Kreisdiagramm — Experiment vom 14.01.2026 ( $n = 166$ )



(a) Balkendiagramm — kleiner Datensatz



(b) Balkendiagramm — Experiment vom 14.01.2026

**Beispiel 10.3 Merkmale treten in verschiedenen Ausprägungen auf** (Skript 26)

| Versuchseinheit | Merkmal                       | Ausprägung                                                    |
|-----------------|-------------------------------|---------------------------------------------------------------|
| Schweinchen     | Lage                          | Suhle, Haxe, Schnauze, Backe, Faul-mit-Punkt, Faul-ohne-Punkt |
| Schweinchen     | Farbe                         | weiß, braun, rosa, schwarz                                    |
| Studierende     | erster Buchstabe vom Vornamen | A,...,Z                                                       |
|                 | Geburtstag                    | 1, ..., 365                                                   |
|                 | Abiturnote                    | $x/10$ mit $x \in \{10, \dots, 40\}$                          |
| Schüler         | Alter in Jahren               | $n \in \mathbb{N}$                                            |
|                 | Größe                         | $l \in (0, \infty)$                                           |
|                 | Gewicht                       | untergewichtig, normal, übergewichtig                         |

**Definition 10.3 Arten von Merkmalen** (Skript 26)

Für quantitative **Merkmale** unterscheiden wir zwischen *diskreten* und *stetigen Merkmalen* (vgl. Alter in Jahren mit Größe).

Für qualitative **Merkmale** unterscheiden wir zwischen *ordinalen Merkmalen* bzw. *Rangmerkmalen* einerseits und *nominalen Merkmalen* andererseits. Rangmerkmale weisen im Gegensatz zu nominalen **Merkmale** eine natürliche Ordnung auf (vgl. untergewichtig, normal, übergewichtig mit weiß, braun, rosa, schwarz).

**Definition 10.4 Grundgesamtheit / Population** (Skript 26)

Die Menge aller Merkmalsträger, über die eine Aussage getroffen werden soll.

Die **Grundgesamtheit** muss bei jeder **Datenerhebung** sorgfältig definiert werden.

| Versuchseinheit | Merkmal                       | Grundgesamtheit                               |
|-----------------|-------------------------------|-----------------------------------------------|
| Schweinchen     | Lage                          | alle vorhandenen Schweinchen nach dem Würfeln |
| Schweinchen     | Farbe                         | alle Schweinchen im Beutel                    |
| Studierende     | erster Buchstabe vom Vornamen | alle Studierenden im Hörsaal                  |
|                 | Geburtstag                    |                                               |
|                 | Abiturnote                    |                                               |
| Schüler         | Alter in Jahren               | alle Schüler einer Jahrgangsstufe             |
|                 | Größe                         |                                               |
|                 | Gewicht                       |                                               |

**Stichprobe:** Die **Grundgesamtheit** ist oft zu groß, um komplett ausgewertet zu werden. In der Regel wird daher nur eine Stichprobe ausgewertet.

**Definition 10.5 Stichprobe vom Umfang  $n$**  (Skript 26)

Eine Teilmenge der Größe  $n$ , die zufällig aus der Grundgesamtheit gewählt wurde.

Dabei wird, leicht missbräuchlich, in der Regel nicht unterschieden zwischen den  $n$  **Versuchseinheiten**, die für die Stichprobe aus der **Grundgesamtheit** gewählt werden, und den zu der Stichprobe gehörenden **Merkmalsausprägungen**.

**Definition 10.6 Urliste** (Skript 26)

Die erhobenen Daten, d.h., die Elemente der Stichprobe zusammen mit ihren Merkmalsausprägungen.

**Beispiel 10.4** (Skript 26)

| Versuchseinheit | Merkmalsausprägung |
|-----------------|--------------------|
| Schweinchen 1   | Suhle              |
| Schweinchen 2   | Schnauze           |
| Schweinchen 3   | Faul-mit-Punkt     |
| Schweinchen 4   | Haxe               |
| Schweinchen 5   | Backe              |
| Schweinchen 6   | Haxe               |
| Schweinchen 7   | Suhle              |
| Schweinchen 8   | Suhle              |

Kürzere Darstellung als Liste:

(1, Suhle), (2, Schnauze), (3, Faul-mit-Punkt), (4, Haxe), (5, Backe), (6, Haxe), (7, Suhle), (8, Suhle)

### Definition 10.7 Häufigkeitsverteilung (Skript 26)

Gegeben: Stichprobe  $x_1, \dots, x_n$ ; Merkmal  $X$  mit genau  $s$  möglichen Ausprägungen  $a_1, \dots, a_s$ .

- (a) **Absolute Häufigkeit** = Anzahl der Ausprägung  $a_i$  in der Stichprobe  $x_1, \dots, x_n$  (Wie viele der Werte sind gleich  $a$ ) :

$$H_n(a_i) = \#\{j \in \{1, \dots, n\} : x_j = a_i\}$$

- (b) **Absolute empirische Häufigkeitsverteilung** der Stichprobe  $x_1, \dots, x_n$ : Abbildung  $H_n : \{a_1, \dots, a_s\} \rightarrow \{0, \dots, n\}$  mit  $a_i \mapsto H_n(a_i)$  für  $i = 1, \dots, s$ .

(Gibt an, wie oft jeder beobachtete Wert in der Stichprobe vorkommt.)

- (c) **Relative Häufigkeit** = Anteil der Ausprägung  $a_i$  in der Stichprobe  $x_1, \dots, x_n$ :

$$h_n(a_i) = \frac{1}{n} H_n(a_i)$$

Gibt also an, welchen Anteil der Stichprobe ein bestimmter Wert ausmacht.

- (d) **Relative Häufigkeitsverteilung** der Stichprobe  $x_1, \dots, x_n$ : Abbildung  $h_n : \{a_1, \dots, a_s\} \rightarrow \{\frac{k}{n} : k \in \{0, \dots, n\}\}$  mit  $a_i \mapsto h_n(a_i)$  für  $i = 1, \dots, s$ .

### Bemerkung 10.1

$$H_n(a_1) + \dots + H_n(a_s) = n \quad \text{und} \quad h_n(a_1) + \dots + h_n(a_s) = 1$$

### Beispiel 10.5 Werfen von acht Schweinchen (Skript 26)

Stichprobe: Suhle, Schnauze, Faul-mit-Punkt, Haxe, Backe, Haxe, Suhle, Suhle

bzw. Urliste: (1, Suhle), (2, Schnauze), (3, Faul-mit-Punkt), (4, Haxe), (5, Backe), (6, Haxe), (7, Suhle), (8, Suhle)

| Merkmalsausprägung | $H_n(a_i)$ | $h_n(a_i)$ |
|--------------------|------------|------------|
| Suhle              | 3          | 3/8        |
| Haxe               | 2          | 1/4        |
| Schnauze           | 1          | 1/8        |
| Backe              | 1          | 1/8        |
| Faul-mit-Punkt     | 1          | 1/8        |
| Faul-ohne-Punkt    | 0          | 0          |

### Karteikarte 10.1 Was ist ein Merkmal im Kontext der beschreibenden Statistik?

Eine Eigenschaft, die an einer Versuchseinheit erhoben bzw. gemessen wird (z.B. Lage, Farbe, Alter, Größe). Ein



Merkmal tritt in verschiedenen Ausprägungen auf..

**Karteikarte 10.2 Was ist die Grundgesamtheit?**

Die Grundgesamtheit ist die Gesamtheit aller Versuchseinheiten, über die im Rahmen einer Datenerhebung eine Aussage getroffen werden soll..

**Karteikarte 10.3 Warum muss die Grundgesamtheit sorgfältig definiert werden?**

Da sie je nach Merkmal und Fragestellung unterschiedlich abgegrenzt ist..

**Karteikarte 10.4 Was ist eine Stichprobe, und warum wird meist sie statt der gesamten Grundgesamtheit ausgewertet?**

Eine Stichprobe ist eine (in der Regel kleinere) Teilmenge von  $n$  Versuchseinheiten aus der Grundgesamtheit. Man wertet sie aus, weil die vollständige Grundgesamtheit oft zu groß ist. Der Begriff "Stichprobe" wird üblicherweise sowohl für die gewählten Versuchseinheiten als auch für die zugehörigen Merkmalsausprägungen verwendet..

**Karteikarte 10.5 Was ist eine Urliste?**

Die Liste der ursprünglich (in Erhebungsreihenfolge, unsortiert) erfassten Daten einer Stichprobe, typischerweise dargestellt als Paare (Index/Versuchseinheit, Merkmalsausprägung)..

**Karteikarte 10.6 Welche Arten von Merkmalen unterscheidet man?**

Quantitative Merkmale (z.B. Alter in Jahren oder Größe) und qualitative Merkmale (z.B. untergewichtig/normal/übergewichtig oder Farbe)..

**Karteikarte 10.7 Welche Arten von quantitativen Merkmalen unterscheidet man?**

Diskret (z.B. Alter in Jahren) und stetig (z.B. Größe)..

**Karteikarte 10.8 Welche Arten von qualitativen Merkmalen unterscheidet man?**

In ordinale Merkmale/Rangmerkmale mit natürlicher Ordnung (z.B. untergewichtig/normal/übergewichtig) und nominale Merkmale ohne natürliche Ordnung (z.B. Farbe)..

**Karteikarte 10.9 Wie ist die absolute Häufigkeit  $H_n(a_i)$  einer Ausprägung  $a_i$  in einer Stichprobe  $x_1, \dots, x_n$  definiert?**

$H_n(a_i) = \#\{j \in \{1, \dots, n\} : x_j = a_i\}$  – die Anzahl der Stichprobenwerte, die gleich  $a_i$  sind..

**Karteikarte 10.10 Wie ist die relative Häufigkeit  $h_n(a_i)$  einer Ausprägung  $a_i$  definiert?**

$h_n(a_i) = \frac{1}{n} H_n(a_i)$ ..

**Karteikarte 10.11 Wie geht man bei der Bildung von Histogramm-Klassen mit Ausreißern in den Daten um?**

Man bildet für die Ausreißer eine Restklasse. Für diese wird kein eigener Balken gezeichnet, sondern nur vermerkt, wie viele Elemente sie enthält..

**Karteikarte 10.12 Welche Lagemaße wurden behandelt?**

Arithmetisches Mittel, Modalwert (Modus), Median (Zentralwert) und empirisches  $p$ -Quantil (der Median ist der

Spezialfall  $x_{1/2}$  des  $p$ -Quantils)..

### 10.1.2 | Graphische Darstellungen eindimensionaler Daten

Für den kleinen Datensatz (Beispiel 10.5) und den großen Datensatz (aus der Vorlesung vom 14.01.2026) mit den Schweinchen haben wir u.a. folgende Möglichkeiten der graphischen Darstellung: Kreis- bzw. Tortendiagramm sowie Stab- bzw. Balkendiagramm (siehe Abbildungen oben).


#### Beispiel 10.6 Alter von Berufstätigen (Skript 26)

21, 22, 24, 28, 28, 28, 32, 32, 33, 35,  
 35, 36, 37, 37, 37, 40, 40, 41, 43, 43,  
 44, 47, 48, 48, 53, 53, 53, 58, 60, 60,  
 24, 25, 26, 27, 27, 27, 27, 28, 29, 31,  
 31, 31, 31, 32, 33, 33, 34, 34, 35, 35,  
 35, 36, 36, 36, 36, 37, 37, 37, 37, 38,  
 38, 39, 39, 39, 39, 41, 41, 41, 41, 42,  
 42, 42, 45, 45, 45, 46, 47, 47, 47, 48,  
 49, 49, 49, 52, 52, 52, 54, 54, 55, 55,  
 55, 56, 57, 61, 64, 65, 65, 65, 65

(Simulierte Daten, bereits der Größe nach geordnet, mit Stichprobengröße  $n = 100$ .)


|       |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |
|-------|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|
| Alter | 18 | 19 | 20 | 21 | 22 | 23 | 24 | 25 | 26 | 27 | 28 | 29 | 30 | 31 | 32 | 33 | 34 | 35 | 36 | 37 |
| Anz.  | 0  | 0  | 0  | 1  | 1  | 0  | 2  | 1  | 1  | 4  | 4  | 1  | 0  | 4  | 3  | 3  | 2  | 5  | 5  | 7  |
| Alter | 38 | 39 | 40 | 41 | 42 | 43 | 44 | 45 | 46 | 47 | 48 | 49 | 50 | 51 | 52 | 53 | 54 | 55 | 56 | 57 |
| Anz.  | 2  | 4  | 2  | 5  | 3  | 2  | 1  | 3  | 1  | 4  | 3  | 3  | 0  | 0  | 3  | 3  | 2  | 3  | 1  | 1  |
| Alter | 58 | 59 | 60 | 61 | 62 | 63 | 64 | 65 | 66 | 67 |    |    |    |    |    |    |    |    |    |    |
| Anz.  | 1  | 0  | 2  | 1  | 0  | 0  | 1  | 5  | 0  | 0  |    |    |    |    |    |    |    |    |    |    |

Weder Balken- noch Kreisdiagramm sind sinnvoll bei so vielen verschiedenen Ausprägungen:



**Histogramm** Klasseneinteilung wählen: Jede Klasse möge 5 Jahre erfassen – aber stimmt das am Rand?

|       |           |       |       |       |       |       |       |       |       |       |           |
|-------|-----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-----------|
| Alter | $\leq 19$ | 20–24 | 25–29 | 30–34 | 35–39 | 40–44 | 45–49 | 50–54 | 55–59 | 60–64 | $\geq 65$ |
| Anz.  | 0         | 4     | 11    | 12    | 23    | 13    | 14    | 8     | 6     | 4     | 5         |



Wenn als Alter zum Beispiel nur Werte im Bereich 18–67 auftreten können, sollte die Breite der Randbalken angepasst werden (schmalere Klassen “18–19” und “65–67”).

**Bemerkung 10.2 Restklasse** Sollte es Ausreißer in den Daten geben (z.B. einen Berufstätigen im Alter von 91 Jahren), so wird eine Restklasse gebildet. Für diese wird kein Balken gezeichnet, sondern nur vermerkt, wie viele Elemente sie hat.

Es gibt weitere übliche Darstellungen wie das Stamm-Blatt-Diagramm oder den Box-Plot. Wir verweisen diesbezüglich auf die Literatur.

## 10.2 | Empirische Häufigkeitsverteilungen und ihre Lagemaße

**Ziel:** Charakterisierung von **Häufigkeitsverteilungen** durch Kennzahlen.

**Gegeben:** Stichprobe  $x_1, \dots, x_n$  eines eindimensionalen **Merkmals**  $X$ .

**Definition 10.8 Lagemaß** (Skript 26)

Sei  $X$  ein quantitatives **Merkmal**. Eine Funktion  $l: \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $(x_1, \dots, x_n) \mapsto l(x_1, \dots, x_n)$ , heißt *Lagemaß*, wenn

$$l(x_1 + a, \dots, x_n + a) = l(x_1, \dots, x_n) + a \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n \quad \forall a \in \mathbb{R}.$$

Anschaulich bedeutet das, dass ein Verschieben der Werte der Stichprobe um  $a$  äquivalent ist zum Verschieben des **Lagemaßes** um  $a$ .

**Kommentar 10.1 Andere Definitionen von Lagemaß** **Wikipedia:** Ein Lagemaß oder Lageparameter ist in der Stochastik eine Kennzahl der Verteilung einer Zufallsvariable beziehungsweise eines Wahrscheinlichkeitsmaßes. Anschaulich ist es die Aufgabe eines Lagemaßes, den “typischen” Wert einer Zufallsvariable anzugeben.

**Björn Walther:** Lagemaße (auch Lageparameter) sind Kennzahlen, die im Rahmen der deskriptiven Statistik genutzt werden. Sie treffen eine Aussage über die zentrale Tendenz von Variablen im Datensatz. Mit ihnen ist also erkennbar, wo in der Stichprobe die “Musik spielt”.

**Welt der BWL:** Lagemaße der Statistik – auch Maße der zentralen Tendenz genannt – geben an, was in einer Datenmenge das Zentrum bzw. der Schwerpunkt ist, zum Beispiel der häufigste Wert oder der Durchschnitt.

**studyflix** Lageparameter geben die zentrale Tendenz des Datensatzes an. Konkret wird also untersucht, ob die gemessenen Werte eher groß oder klein sind. Bei einer Umfrage kann man beispielsweise ermitteln, ob eher jüngere oder ältere Menschen befragt wurden.

**Beispiel 10.7 Zu Definition 10.8**

■ Das *arithmetische Mittel*  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$  der Stichprobe  $x_1, \dots, x_n$  ist ein **Lagemaß**.

■ Das *geometrische Mittel*  $\bar{x}_g = \sqrt[n]{x_1 \cdots x_n}$  der Stichprobe  $x_1, \dots, x_n$  ist *kein* **Lagemaß**.

■ Das *harmonische Mittel*  $\bar{x}_h = \frac{n}{\frac{1}{x_1} + \cdots + \frac{1}{x_n}}$  der Stichprobe  $x_1, \dots, x_n$  ist *kein* **Lagemaß**.

Wir wollen diese Aussagen beweisen.

**Beweis - Das arithmetische Mittel  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$  ist ein Lagemaß:** Sei  $l_{\text{arith}}(x_1, \dots, x_n) = \frac{1}{n} \sum_{i=1}^n x_i$ . Dann gilt für alle  $(x_1, \dots, x_n) \in \mathbb{R}^n$  und alle  $a \in \mathbb{R}$

$$l_{\text{arith}}(x_1 + a, \dots, x_n + a) = \frac{1}{n} \sum_{i=1}^n [x_i + a] = \frac{1}{n} \sum_{i=1}^n x_i + \frac{1}{n} \sum_{i=1}^n a = l_{\text{arith}}(x_1, \dots, x_n) + a.$$

**Beweis - Das geometrische Mittel  $\bar{x}_g = \sqrt[n]{x_1 \cdots x_n}$  ist kein Lagemaß:** Beachte zunächst, dass das geometrische Mittel nur für  $x_1, \dots, x_n \geq 0$  sinnvoll definiert ist. Auch wenn wir nur  $x_1, \dots, x_n \geq 0$  und  $a > 0$  betrachten, erfüllt das geometrische Mittel nicht die Anforderung an ein **Lagemaß**:

Seien  $n = 2$  und  $l_g(x_1, x_2) = \sqrt{x_1 \cdot x_2}$ . Wäre  $l_g$  ein **Lagemaß**, so müsste gelten

$$(*) \quad l_g(x_1 + a, x_2 + a) = l_g(x_1, x_2) + a \quad \forall (x_1, x_2) \in \mathbb{R}^2 \quad \forall a \in \mathbb{R}.$$

Quadrieren beider Seiten zeigt, dass  $(*)$  äquivalent ist zu  $\sqrt{x_1 \cdot x_2} = \frac{x_1 + x_2}{2}$ . Das heißt, dass das geometrische Mittel nur dann ein **Lagemaß** sein kann, wenn arithmetisches und geometrisches Mittel für alle  $(x_1, x_2) \in \mathbb{R}^2$  gleich wären.

**Beweis - Das harmonische Mittel  $\bar{x}_h = \frac{n}{\frac{1}{x_1} + \cdots + \frac{1}{x_n}}$  ist kein Lagemaß:** Beachte zunächst, dass das harmonische Mittel nur für  $x_1, \dots, x_n \neq 0$  sinnvoll definiert ist. Selbst wenn wir nur  $x_1, \dots, x_n > 0$  und  $a > 0$  betrachten, erfüllt das harmonische Mittel nicht die Anforderung an ein **Lagemaß**:


Seien  $n = 2$  und  $l_h(x_1, x_2) = \frac{2}{1/x_1 + 1/x_2}$ . Die Wahl  $x_1 = 1$ ,  $x_2 = 2$  und  $a = 1$  zeigt

$$l_h(x_1 + a, x_2 + a) = \frac{2}{\frac{1}{1+1} + \frac{1}{2+1}} = \frac{12}{5} \quad \text{und} \quad l_h(x_1, x_2) + a = \frac{2}{\frac{1}{1} + \frac{1}{2}} + 1 = \frac{7}{3},$$

also  $l_h(x_1 + a, x_2 + a) \neq l_h(x_1, x_2) + a$ .

**Beispiel 10.8 10× Würfeln** (Skript 26)

Stichprobe 6, 2, 5, 4, 1, 6, 5, 4, 5, 4 der Länge  $n = 10$ .



■ Arithmetisches Mittel  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{10} [6 + 2 + 5 + 4 + 1 + 6 + 5 + 4 + 5 + 4] = 4.2$

■ Geometrisches Mittel  $\bar{x}_g = \sqrt[n]{x_1 \cdots x_n} = \sqrt[10]{6 \cdot 2 \cdot 5 \cdot 4 \cdot 1 \cdot 6 \cdot 5 \cdot 4 \cdot 5 \cdot 4} \approx 3.77$

■ Harmonisches Mittel  $\bar{x}_h = \frac{n}{\frac{1}{x_1} + \cdots + \frac{1}{x_n}} = \frac{10}{\frac{1}{6} + \frac{1}{2} + \frac{1}{5} + \frac{1}{4} + \frac{1}{1} + \frac{1}{6} + \frac{1}{5} + \frac{1}{4} + \frac{1}{5} + \frac{1}{4}} \approx 3.14$

### Satz 10.1 Eigenschaften des arithmetischen Mittels (Skript 26)

- (a) **Schwerpunkteigenschaft:** Die Schwerpunkteigenschaft (auch Nulleigenschaft genannt) besagt, dass die Summe der scheinbaren Fehler bzw. die Summe der Abweichungen aller beobachteten Messwerte vom arithmetischen Mittel gleich Null ist. Also:

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

- (b) **Minimierungseigenschaft:**  $\sum_{i=1}^n (x_i - c)^2 \rightarrow \min$  für  $c = \bar{x}$ .

Das arithmetische Mittel minimiert die quadratische Abweichung der Stichprobenwerte von einer Konstanten  $c \in \mathbb{R}$ :

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \inf_{c \in \mathbb{R}} \sum_{i=1}^n (x_i - c)^2$$

**Beweis.**

- (a) Linearität der Summe und die Definition von  $\bar{x}$  zeigen, dass

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} = \sum_{i=1}^n x_i - n \cdot \frac{1}{n} \sum_{i=1}^n x_i = 0.$$

- (b) Eine Nullergänzung und Ausquadrieren zeigen, dass

$$\sum_{i=1}^n (x_i - c)^2 = \sum_{i=1}^n [(x_i - \bar{x}) + (\bar{x} - c)]^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + 2(\bar{x} - c) \sum_{i=1}^n (x_i - \bar{x}) + n(\bar{x} - c)^2.$$

Der erste Summand auf der rechten Seite hängt nicht von  $c$  ab. Der zweite Summand ist gleich Null aufgrund der Schwerpunkteigenschaft. Der dritte Summand ist stets nichtnegativ und gleich Null genau dann, wenn  $c = \bar{x}$  ist. Somit wird

$$\sum_{i=1}^n (x_i - c)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - c)^2$$

minimal für  $c = \bar{x}$  mit Wert  $\sum_{i=1}^n (x_i - \bar{x})^2$ .

### Definition 10.9 Modalwert / Modus (Skript 26)

Sei  $X$  ein beliebiges eindimensionales Merkmal ( $X$  kann nominal sein) mit Ausprägungen  $a_1, \dots, a_s$ . Eine Ausprägung  $a$  des Merkmals  $X$  heißt *Modalwert* oder *Modus*, wenn

$$H_n(a) \geq H_n(x_i) \quad \forall i = 1, \dots, n.$$

Also wenn die Ausprägung  $a$  die größte Häufigkeit hat. Also der Modalwert der Wert, der in der Stichprobe am häufigsten vorkommt.


**Bemerkung 10.3** (Skript 26)

- (a)  $a$  ist genau dann ein Modalwert, wenn keine andere Ausprägung in der Stichprobe häufiger auftritt als  $a$ .
- (b) Der Modalwert ist in der Regel nicht eindeutig, siehe folgendes Beispiel.
- (c)  $H_n(a) \geq H_n(x_i) \forall i = 1, \dots, n \iff H_n(a) \geq H_n(a_k) \forall k = 1, \dots, s$ .
- (d) Für quantitative **Merkmale** ist der Modalwert ein **Lagemaß**.


**Definition 10.10 Unimodal** (Skript 26)

Wir schreiben  $x_{\text{mod}}$  für den Modalwert einer Stichprobe, sofern dieser eindeutig bestimmt ist. In diesem Fall heißen die Häufigkeitsverteilungen  $H_n$  und  $h_n$  *unimodal*.

Umgangssprachlich: Unimodalität bedeutet, dass es nur einen einzigen Höchstwert (Modalwert / Modus) gibt.

**Beispiel 10.9 Würfeln** (Skript 26)

Stichprobe 6, 2, 5, 4, 1, 6, 5, 4, 5, 4,  $n = 10$   
 Modalwerte 4 und 5 — *nicht* unimodal



Stichprobe 6, 2, 5, 4, 1, 6, 5, 4, 5, 4, 5,  $n = 11$   
 Modalwert  $x_{\text{mod}} = 5$  — unimodal

**Definition 10.11 Median / Zentralwert** (Skript 26)

Sei  $X$  ein quantitatives **Merkmal**. Ist die Stichprobe  $x_1, \dots, x_n$  gegeben, so schreiben wir  $x_{(1)}, \dots, x_{(n)}$  für die *geordnete Stichprobe*, d.h. es gelten

$$\{x_1, \dots, x_n\} = \{x_{(1)}, \dots, x_{(n)}\} \quad \text{und} \quad x_{(1)} \leq \dots \leq x_{(n)}.$$

Der *Median* oder *Zentralwert* ist definiert durch

$$x_{\text{med}} = \begin{cases} x_{(\frac{n+1}{2})} & \text{falls } n \text{ ungerade ist,} \\ \frac{1}{2} [x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}] & \text{falls } n \text{ gerade ist.} \end{cases}$$

**Beispiel 10.10 Würfeln** (Skript 26)

Stichprobe 6, 2, 5, 4, 1, 6, 5, 4, 5, 4  
 geordnet 1, 2, 4, 4, 4, 5, 5, 5, 6, 6,  $n = 10$

$$x_{\text{med}} = \frac{1}{2} [x_{(5)} + x_{(6)}] = \frac{4 + 5}{2} = 4.5$$

Stichprobe 6, 2, 5, 4, 1, 6, 5, 4, 5, 4, 5  
 geordnet 1, 2, 4, 4, 4, 5, 5, 5, 5, 6, 6,  $n = 11$

$$x_{\text{med}} = x_{(6)} = 5$$

**Satz 10.2 Eigenschaften des Medians** (Skript 26)

(a) Der Median ist ein **Lagemaß**.

(b) Der Median  $x_{\text{med}}$  erfüllt

$$\sum_{\substack{k=1: \\ a_k \leq x_{\text{med}}}}^s h_n(a_k) \geq \frac{1}{2} \quad \text{und} \quad \sum_{\substack{k=1: \\ a_k \geq x_{\text{med}}}}^s h_n(a_k) \geq \frac{1}{2}.$$

Das heißt, mindestens die Hälfte der Werte in der Stichprobe sind kleiner oder gleich dem Wert des Medians und mindestens die Hälfte der Werte in der Stichprobe sind größer oder gleich dem Wert des Medians.

(c) Gelten

$$\sum_{\substack{k=1: \\ a_k \leq a}}^s h_n(a_k) \geq \frac{1}{2} \quad \text{und} \quad \sum_{\substack{k=1: \\ a_k \geq a}}^s h_n(a_k) \geq \frac{1}{2} \quad \text{für ein } a \in \mathbb{R},$$

so folgt  $x_{(\lceil n/2 \rceil)} \leq a \leq x_{(\lceil n/2 \rceil + 1)}$ . Dabei muss  $a$  keine Ausprägung des **Merkmals**  $X$  sein.

(d) **Minimierungseigenschaft:** Der Median minimiert die absoluten Abweichungen

$$\sum_{i=1}^n |x_i - c| \rightarrow \min \quad \text{für ein } c \in \left[ x_{(\lfloor \frac{n+1}{2} \rfloor)}, x_{(\lceil \frac{n+1}{2} \rceil)} \right].$$

**Beweis.**

(a) Können Sie diese Aussage selbst beweisen?

(b) Zu zeigen ist, dass der Median  $\sum_{k=1: a_k \leq x_{\text{med}}}^s h_n(a_k) \geq \frac{1}{2}$  und  $\sum_{k=1: a_k \geq x_{\text{med}}}^s h_n(a_k) \geq \frac{1}{2}$  erfüllt. Wir begnügen uns damit, die erste Aussage zu zeigen; die zweite lässt sich analog beweisen.

Unter Verwendung der Definition der absoluten empirischen Häufigkeitsverteilung sehen wir, dass

$$\sum_{\substack{k=1: \\ a_k \leq x_{\text{med}}}}^s h_n(a_k) = \frac{1}{n} \sum_{\substack{k=1: \\ a_k \leq x_{\text{med}}}}^s H_n(a_k) = \frac{1}{n} \# \{i \in \{1, \dots, n\} : x_i \leq x_{\text{med}}\} = \frac{1}{n} \# \{i \in \{1, \dots, n\} : x_{(i)} \leq x_{\text{med}}\}.$$

**1. Fall:  $n$  ungerade.** Für ungerade  $n$  ist  $x_{\text{med}} = x_{(\frac{n+1}{2})}$ , und daher

$$\# \{i \in \{1, \dots, n\} : x_{(i)} \leq x_{\text{med}}\} \geq \frac{n+1}{2} \geq \frac{n}{2},$$

weil mindestens die  $\frac{n+1}{2}$  Elemente  $x_{(1)} \leq \dots \leq x_{(\frac{n+1}{2})}$  in der Menge sind. Daraus folgt die Behauptung.

Beispiel:  $n = 5$ , geordnete Stichprobe  $1, 1, 2, 2, 5$  (Augenzahl beim Würfeln). Es ist  $x_{\text{med}} = x_{(3)} = 2$ , und  $\frac{1}{5} \# \{i : x_{(i)} \leq 2\} = \frac{4}{5} \geq \frac{1}{2}$ , ebenso  $\sum_{k: a_k \leq x_{\text{med}}} h_5(a_k) = h_5(1) + h_5(2) = \frac{2}{5} + \frac{2}{5} = \frac{4}{5} \geq \frac{1}{2}$ .

**2. Fall:  $n$  gerade.** Für gerade  $n$  ist  $x_{\text{med}} = \frac{1}{2} \left[ x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)} \right] \geq x_{(\frac{n}{2})}$ , weil  $x_{(\frac{n}{2}+1)} \geq x_{(\frac{n}{2})}$ . Daher gilt  $\# \{i : x_{(i)} \leq x_{\text{med}}\} \geq \frac{n}{2}$ , weil mindestens die  $\frac{n}{2}$  Elemente  $x_{(1)} \leq \dots \leq x_{(\frac{n}{2})}$  in der Menge sind.

Beispiel:  $n = 6$ , geordnete Stichprobe  $1, 1, 1, 2, 2, 5$ . Es ist  $x_{\text{med}} = \frac{1}{2} [x_{(3)} + x_{(4)}] = \frac{3}{2}$ , und  $\frac{1}{6} \# \{i : x_{(i)} \leq \frac{3}{2}\} = \frac{3}{6} = \frac{1}{2} \geq \frac{1}{2}$ , ebenso  $h_6(1) = \frac{3}{6} = \frac{1}{2} \geq \frac{1}{2}$ .

(c) Wir müssen zeigen: Gelten  $\sum_{k: a_k \leq a} h_n(a_k) \geq \frac{1}{2}$  und  $\sum_{k: a_k \geq a} h_n(a_k) \geq \frac{1}{2}$  für ein  $a \in \mathbb{R}$ , so folgt  $x_{(\lceil n/2 \rceil)} \leq a \leq x_{(\lceil n/2 \rceil + 1)}$ .

Wir schreiben wieder die Summen um und erhalten  $\# \{i : x_{(i)} \leq a\} \geq \frac{n}{2}$  und  $\# \{i : x_{(i)} \geq a\} \geq \frac{n}{2}$ .

**1. Fall:  $n$  ungerade.** Für ungerade  $n$  ist  $\frac{n}{2} \notin \mathbb{N}$ . Daher müssen sogar  $\#\{i : x_{(i)} \leq a\} \geq \frac{n+1}{2}$  und  $\#\{i : x_{(i)} \geq a\} \geq \frac{n+1}{2}$  gelten. Folglich ergibt sich durch Abzählen von unten bzw. oben, dass  $x_{(1)} \leq \dots \leq x_{(\frac{n+1}{2})} \leq a$  und  $x_{(n)} \geq \dots \geq x_{(\frac{n+1}{2})} \geq a$  gelten. Damit haben wir sogar  $x_{\text{med}} = x_{(\frac{n+1}{2})} = a$  gezeigt.

Beispiel:  $n = 5$ , geordnete Stichprobe 1, 1, 2, 2, 5. Es gilt  $h_5(1) = \frac{2}{5} < \frac{1}{2}$ , aber  $h_5(1) + h_5(2) \geq \frac{1}{2}$ ; ebenso von oben betrachtet muss  $a = 2$  gelten.

**2. Fall:  $n$  gerade.** Für gerade  $n$  wissen wir nur  $\#\{i : x_{(i)} \leq a\} \geq \frac{n}{2}$  und  $\#\{i : x_{(i)} \geq a\} \geq \frac{n}{2}$ . Wieder ergibt sich  $x_{(1)} \leq \dots \leq x_{(\frac{n}{2})} \leq a$  und  $x_{(n)} \geq \dots \geq x_{(\frac{n}{2}+1)} \geq a$ . Damit haben wir  $x_{(\frac{n}{2})} \leq a \leq x_{(\frac{n}{2}+1)}$  gezeigt.

Beispiel:  $n = 6$ , geordnete Stichprobe 1, 1, 1, 2, 2, 5. Es gilt  $h_6(1) \geq \frac{1}{2}$ , also muss  $a \geq 1$  gelten; von oben betrachtet muss  $a \leq 2$  gelten. Somit muss  $1 \leq a \leq 2$  gelten; insbesondere ist der Median  $x_{\text{med}} = \frac{3}{2}$  eine zulässige Wahl von  $a$ .

**Kommentar 10.2** Zu 10.2 (c):  $\sum_{a_k \leq a}^s h_n(a_k) \geq \frac{1}{2}$  bedeutet mindestens die Hälfte aller Beobachtungen liegt links von  $a$  oder genau bei  $a$ .

$\sum_{a_k \geq a}^s h_n(a_k) \geq \frac{1}{2}$  bedeutet mindestens die Hälfte aller Beobachtungen liegt rechts von  $a$  oder genau bei  $a$ .

$x_{(\lceil n/2 \rceil)} \leq a \leq x_{(\lceil n/2 \rceil + 1)}$  ist einfach der Median.

Also wenn ein Wert  $a$  diese beiden Bedingungen erfüllt, ist er einfach der Median.

“Dabei muss  $a$  keine Ausprägung des Merkmals  $X$  sein.” bedeutet, dass der Median keiner von den Beobachteten Werten sein muss. Sondern bspw. auch dazwischen liegen kann.

### Beispiel 10.11 Würfeln (Skript 26)

geordnete Stichprobe 1, 2, 4, 4, 4, 5, 5, 5, 6, 6,  $n = 10$ ,  
 $x_{\text{med}} = 4.5$

$$\sum_{\substack{k=1: \\ a_k \leq x_{\text{med}}}}^s h_n(a_k) = \frac{1+1+0+3}{10} = \frac{5}{10} = \frac{1}{2} \geq \frac{1}{2}$$

$$\sum_{\substack{k=1: \\ a_k \geq x_{\text{med}}}}^s h_n(a_k) = \frac{3+2}{10} = \frac{5}{10} = \frac{1}{2} \geq \frac{1}{2}$$

geordnete Stichprobe 1, 2, 4, 4, 4, 5, 5, 5, 5, 6, 6,  $n = 11$ ,  
 $x_{\text{med}} = 5$

$$\sum_{\substack{k=1: \\ a_k \leq x_{\text{med}}}}^s h_n(a_k) = \frac{1+1+0+3+4}{11} = \frac{9}{11} \geq \frac{1}{2}$$

$$\sum_{\substack{k=1: \\ a_k \geq x_{\text{med}}}}^s h_n(a_k) = \frac{4+2}{11} = \frac{6}{11} \geq \frac{1}{2}$$

### Karteikarte 10.13 Wie ist ein Lagemaß formal definiert?

Eine Funktion  $l : \mathbb{R}^n \rightarrow \mathbb{R}$  heißt Lagemaß, wenn  $l(x_1 + a, \dots, x_n + a) = l(x_1, \dots, x_n) + a$  für alle  $(x_1, \dots, x_n) \in \mathbb{R}^n$  und alle  $a \in \mathbb{R}$  gilt (Translationsäquivarianz): Verschiebt man alle Stichprobenwerte um  $a$ , verschiebt sich auch der Wert des Lagemaßes um  $a$ .

### Karteikarte 10.14 Welche der drei klassischen Mittelwerte (arithmetisches, geometrisches, harmonisches Mittel) sind Lagemaße im formalen Sinn?

Nur das arithmetische Mittel ist ein Lagemaß. Geometrisches Mittel und harmonisches Mittel sind KEINE Lagemaße – sie erfüllen die Translationsäquivarianz-Eigenschaft  $l(x + a) = l(x) + a$  im Allgemeinen nicht..

### Karteikarte 10.15 Wie lautet die Schwerpunkteigenschaft (Nulleigenschaft) des arithmetischen Mittels?

$\sum_{i=1}^n (x_i - \bar{x}) = 0$  – die Summe der Abweichungen aller Werte vom arithmetischen Mittel ist stets Null..



**Karteikarte 10.16** Wie lautet die Minimierungseigenschaft des arithmetischen Mittels?

Das arithmetische Mittel minimiert die quadratische Abweichung der Stichprobenwerte von einer Konstanten:  $\sum_{i=1}^n (x_i - \bar{x})^2 = \inf_{c \in \mathbb{R}} \sum_{i=1}^n (x_i - c)^2$ , d.h.  $\sum_{i=1}^n (x_i - c)^2$  wird minimal für  $c = \bar{x}$ .

**Karteikarte 10.17** Wie ist der Modalwert (Modus) einer Stichprobe definiert?

Eine Ausprägung  $a$  heißt Modalwert/Modus des Merkmals  $X$ , wenn  $H_n(a) \geq H_n(x_i)$  für alle  $i = 1, \dots, n$  gilt – also wenn  $a$  die Ausprägung mit der größten Häufigkeit in der Stichprobe ist..

**Karteikarte 10.18** Welche Eigenschaften hat der Modalwert (Definitionsbereich, Eindeutigkeit, Lagemaß-Eigenschaft)?

Der Modalwert ist auch für nominale Merkmale definiert (er benötigt keine Ordnung). Er ist in der Regel nicht eindeutig bestimmt. Für quantitative Merkmale ist der Modalwert ein Lagemaß..

**Karteikarte 10.19** Wann heißt eine Häufigkeitsverteilung unimodal?

Wenn der Modalwert  $x_{\text{mod}}$  eindeutig bestimmt ist, d.h. es gibt nur eine einzige Ausprägung mit maximaler Häufigkeit..

**Karteikarte 10.20** Wie ist der Median (Zentralwert)  $x_{\text{med}}$  einer Stichprobe  $x_1, \dots, x_n$  definiert?

Mit der geordneten Stichprobe  $x_{(1)} \leq \dots \leq x_{(n)}$ :  $x_{\text{med}} = x_{(\frac{n+1}{2})}$  falls  $n$  ungerade, und  $x_{\text{med}} = \frac{1}{2} [x_{(n/2)} + x_{(n/2+1)}]$  falls  $n$  gerade..

**Karteikarte 10.21** Welche "Halbierungseigenschaft" erfüllt der Median bezüglich der relativen Häufigkeiten?

$\sum_{k: a_k \leq x_{\text{med}}} h_n(a_k) \geq \frac{1}{2}$  und  $\sum_{k: a_k \geq x_{\text{med}}} h_n(a_k) \geq \frac{1}{2}$  – mindestens die Hälfte der Stichprobenwerte ist kleiner-gleich, und mindestens die Hälfte ist größer-gleich dem Median..

**Karteikarte 10.22** Wie lässt sich der Median durch die Halbierungseigenschaft eindeutig charakterisieren (auch wenn  $a$  selbst kein beobachteter Wert ist)?

Erfüllt ein  $a \in \mathbb{R}$  die beiden Ungleichungen  $\sum_{k: a_k \leq a} h_n(a_k) \geq \frac{1}{2}$  und  $\sum_{k: a_k \geq a} h_n(a_k) \geq \frac{1}{2}$ , so folgt  $x_{(\lceil n/2 \rceil)} \leq a \leq x_{(\lceil n/2 \rceil + 1)}$ .  $a$  muss dabei keine tatsächlich beobachtete Ausprägung sein..

**Karteikarte 10.23** Welche Minimierungseigenschaft besitzt der Median?

Der Median minimiert die Summe der absoluten Abweichungen:  $\sum_{i=1}^n |x_i - c| \rightarrow \min$  für  $c$  im Intervall  $\left[ x_{(\lfloor \frac{n+1}{2} \rfloor)}, x_{(\lceil \frac{n+1}{2} \rceil)} \right]$ ..

## 10.3 | Empirische Häufigkeitsverteilungen und ihre Streumaße

**Ziel:** Charakterisierung von Häufigkeitsverteilungen durch Kennzahlen (Fortsetzung).

**Gegeben:**

- Quantitatives, eindimensionales Merkmal  $X$  mit Ausprägungen  $a_1, \dots, a_s$
- Stichprobe  $x_1, \dots, x_n$
- geordnete Stichprobe  $x_{(1)}, \dots, x_{(n)}$

**Definition 10.12 Streumaß** (Skript 26)

Eine Funktion  $s : \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $(x_1, \dots, x_n) \mapsto s(x_1, \dots, x_n)$ , heißt **Streumaß**, wenn

$$s(x_1 + a, \dots, x_n + a) = s(x_1, \dots, x_n) \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n \quad \forall a \in \mathbb{R}.$$

Anschaulich bedeutet das, dass ein Verschieben der Werte der Stichprobe um ein  $a$  den Wert eines **Streumaßes** nicht verändert.

**Kommentar 10.3 Andere Definitionen von Streumaß** **Wikipedia:** Streuungsmaße, auch Dispersionsmaße (lateinisch dispersio „Zerstreuung“, von dispergere „verteilen, ausbreiten, zerstreuen“) oder Streuungsparameter genannt, fassen in der deskriptiven Statistik verschiedene Maßzahlen zusammen, die die Streubreite von Beobachtungswerten beziehungsweise einer Häufigkeitsverteilung um einen geeigneten Lageparameter herum beschreiben.

**Welt der BWL:** Streuungsmaße in der Statistik geben an, wie stark die einzelnen Datenwerte oder Messwerte streuen, das heißt, wie weit sie zum Beispiel von einem berechneten Mittelwert oder auch von einem Vorgabewert nach oben und unten abweichen.

**Kommentar 10.4 Warum braucht man Streumaße?** “Die Frage, wie weit Daten um den Mittelwert streuen – ob sie sich eng darum drängen oder weit davon entfernt sind – lässt der Durchschnitt unbeantwortet. Das bedeutet, dass sich eine Verteilung durch die bloße Angabe von einem oder mehreren Mittelwerten nur unzureichend beschreiben lässt.

Deshalb werden Streuungsmaße genutzt, um die Variabilität eines Merkmals darzustellen.”

(eLearning-Modul 16 - Streuungsmaße des statistischen Bundesamts)

**Beispiel 10.12 Ein ganzer Zoo an Streumaßen** (Skript 26)

Im Folgenden dient uns zur Illustration stets die (geordnete) Stichprobe 1, 1, 2, 2, 2, 3, 4, 4, 4, 6 der Länge  $n = 10$ . Wir können uns die Stichprobe vorstellen als das Ergebnis von 10-maligem Würfeln.

- (a) Die *Spannweite*  $x_{\max} - x_{\min} = x_{(n)} - x_{(1)}$  der Stichprobe  $x_1, \dots, x_n$  ist ein **Streumaß** (nicht robust gegenüber Ausreißern).

Im Beispiel:  $x_{\max} - x_{\min} = 6 - 1 = 5$ .

- (b) Die *Medianabweichung* ist der “Median der absoluten Abweichung vom Median” und wird folgendermaßen definiert: Wir bilden zunächst eine neue Stichprobe  $y_1, \dots, y_n$  mit  $y_i = |x_i - x_{\text{med}}|$ . Die Medianabweichung der ursprünglichen Stichprobe  $x_1, \dots, x_n$  ist der Median  $y_{\text{med}}$  der neuen Stichprobe (robust gegenüber Ausreißern).

Im Beispiel: Es ist  $x_{\text{med}} = 2.5$ , und die geordnete Stichprobe  $y_{(1)}, \dots, y_{(10)}$  ergibt sich folglich als 0.5, 0.5, 0.5, 0.5, 1.5, 1.5, 1.5, 1.5, 1.5, 3.5 mit Median  $y_{\text{med}} = 1.5$ .

|                        |     |     |     |     |     |     |     |     |     |     |
|------------------------|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| <b>originale Werte</b> | 1   | 1   | 2   | 2   | 2   | 3   | 4   | 4   | 4   | 6   |
| neue Stichprobe        | 0.5 | 0.5 | 0.5 | 0.5 | 1.5 | 1.5 | 1.5 | 1.5 | 1.5 | 3.5 |
| (orig. Wert - 1.5)     |     |     |     |     |     |     |     |     |     |     |

- (c) Die *mittlere absolute Abweichung vom Median* ist definiert durch das arithmetische Mittel der Hilfsstichprobe  $y_1, \dots, y_n$  mit  $y_i = |x_i - x_{\text{med}}|$ :

$$\bar{s} = \frac{1}{n} \sum_{i=1}^n |x_i - x_{\text{med}}| = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}$$

(nicht robust gegenüber Ausreißern; seien z.B.  $n = 3$  sowie  $x_1 = x_2 = 0$ . Für  $x_3$  betrachten wir zwei Werte: Ist  $x_3 = 0$ , so gelten  $x_{\text{med}} = 0$  und folglich  $\bar{s} = 0$ . Haben wir dagegen mit  $x_3 = 100$  einen Ausreißer, so ist weiterhin  $x_{\text{med}} = 0$ , denn der Median ist robust, aber es gilt  $\bar{s} = 100/3$ .)

Im Beispiel:  $\bar{s} = \bar{y} = 1.3$ .

$$0.5 + 0.5 + 0.5 + 0.5 + 1.5 + 1.5 + 1.5 + 1.5 + 1.5 + 3.5 = 13$$

und

$$13/10 = 1.3$$

(d) Die *mittlere absolute Abweichung vom arithmetischen Mittel* ist definiert als

$$\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

(nicht robust gegenüber Ausreißern; seien z.B.  $n = 100$  und alle  $x_i$  klein, d.h.  $|x_i| \leq \varepsilon$ . Dann ist auch  $|\bar{x}| \leq \varepsilon$ , und es folgt  $\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \leq 2\varepsilon$ . Haben wir dagegen einen Ausreißer  $x_{100} = 10\,000$ , während  $|x_1|, \dots, |x_{99}| = 0$ , so ist  $\bar{x} = 100$  und  $\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| = 198$ .)

Im Beispiel:  $\bar{x} = (1 + 1 + 2 + 2 + 2 + 3 + 4 + 4 + 4 + 6)/10 = 29/10 = 2.9$  und  $\bar{s} = \frac{1}{10} \sum_{i=1}^n |x_i - 2.9| = 1.3$ .

(e) Die *mittlere quadratische Abweichung vom arithmetischen Mittel* oder (Stichproben-) *Varianz* ist definiert als

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

(nicht robust gegenüber Ausreißern; verwenden Sie das Beispiel aus (d)).

Im Beispiel:  $\bar{x} = 29/10 = 2.9$  und

$$s^2 = \frac{1}{10} \left[ (1 - 2.9)^2 + (1 - 2.9)^2 + (2 - 2.9)^2 + (2 - 2.9)^2 + (2 - 2.9)^2 + (3 - 2.9)^2 + (4 - 2.9)^2 + (4 - 2.9)^2 + (4 - 2.9)^2 + (6 - 2.9)^2 \right]$$

Der folgende Satz wird uns eine bessere Methode zeigen, die Stichprobenvarianz in diesem Fall zu berechnen.

(f) Die *Standardabweichung* ist definiert als  $s = \sqrt{s^2}$  (nicht robust gegenüber Ausreißern, da die Stichprobenvarianz nicht robust ist).

Im Beispiel:  $s = \sqrt{s^2} = \sqrt{2.29} \approx 1.513$

### Satz 10.3 Berechnen der (Stichproben-)Varianz / Steinersche Formel (Skript 26)

$$s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \left( \frac{1}{n} \sum_{i=1}^n x_i \right)^2$$

**Beweis.** “Beweisen Sie dieses Resultat selbständig.”

**Beispiel 10.13** (Skript 26) Für die (geordnete) Stichprobe 1, 1, 2, 2, 2, 3, 4, 4, 4, 6 der Länge  $n = 10$  gilt

$$\begin{aligned}s^2 &= \frac{1}{10} [1^2 + 1^2 + 2^2 + 2^2 + 2^2 + 3^2 + 4^2 + 4^2 + 4^2 + 6^2] - 2.9^2 \\&= \frac{1}{10} [1 + 1 + 4 + 4 + 4 + 9 + 16 + 16 + 16 + 36] - 5.2441 \\&= \frac{1}{10} [107] - 5.2441 \\&= 10.7 - 5.2441 \\&= 5.4559\end{aligned}$$

**Satz 10.4 Berechnen von  $\bar{s}$  und  $s^2$  mittels der Häufigkeitsverteilung** (Skript 26)

$$(a) \quad \bar{s} = \frac{1}{n} \sum_{k=1}^s |a_k - x_{\text{med}}| H_n(a_k) = \sum_{k=1}^s |a_k - x_{\text{med}}| h_n(a_k)$$

$$(b) \quad s^2 = \frac{1}{n} \sum_{k=1}^s [a_k - \bar{x}]^2 H_n(a_k) = \sum_{k=1}^s [a_k - \bar{x}]^2 h_n(a_k)$$

**Beweis.**

$$\bar{s} = \frac{1}{n} \sum_{i=1}^n |x_i - x_{\text{med}}| = \frac{1}{n} \sum_{k=1}^s \sum_{\substack{i=1: \\ x_i=a_k}}^n |x_i - x_{\text{med}}| = \frac{1}{n} \sum_{k=1}^s |a_k - x_{\text{med}}| H_n(a_k) = \sum_{k=1}^s |a_k - x_{\text{med}}| h_n(a_k)$$

sowie

$$s^2 = \frac{1}{n} \sum_{i=1}^n [x_i - \bar{x}]^2 = \frac{1}{n} \sum_{k=1}^s \sum_{\substack{i=1: \\ x_i=a_k}}^n [x_i - \bar{x}]^2 = \frac{1}{n} \sum_{k=1}^s [a_k - \bar{x}]^2 H_n(a_k) = \sum_{k=1}^s [a_k - \bar{x}]^2 h_n(a_k).$$

In beiden Rechnungen haben wir verwendet, dass für gegebenes  $k$  in der inneren Summe  $\sum_{i=1: x_i=a_k}^n \dots$  die jeweiligen Summanden  $|x_i - x_{\text{med}}| = |a_k - x_{\text{med}}|$  bzw.  $[x_i - \bar{x}]^2 = [a_k - \bar{x}]^2$  konstant sind. Daher müssen wir nur die Anzahl der Summanden bestimmen, und diese beträgt jeweils  $H_n(a_k)$ .

**Beispiel 10.14** (Skript 26)

Für die geordnete Stichprobe 1, 1, 2, 2, 2, 3, 4, 4, 4, 6 der Länge  $n = 10$  gilt

$$s^2 = \frac{1}{10} \left[ 2 \cdot (1 - 2.9)^2 + 3 \cdot (2 - 2.9)^2 + (3 - 2.9)^2 + 3 \cdot (4 - 2.9)^2 + (6 - 2.9)^2 \right] \approx 2.9.$$

**Definition 10.13 Empirisches  $p$ -Quantil** (Skript 26)

Sei  $p \in (0, 1)$ . Dann heißt

$$x_p = \begin{cases} x_{(\lceil np \rceil)} & \text{falls } np \notin \mathbb{N} \\ \frac{1}{2} [x_{(np)} + x_{(np+1)}] & \text{falls } np \in \mathbb{N} \end{cases}$$

empirisches  $p$ -Quantil.

**Kommentar 10.5 Andere Definitionen von empirisches  $p$ -Quantil** **Wikipedia:** Ein empirisches ( $p$ -)Quantil, auch Stichprobenquantil oder kurz Quantil (von lat. quantillus für wie wenig?) genannt, ist in der Statistik eine Kennzahl einer Stichprobe. Für jede Zahl  $p$  zwischen 0 und 1 teilt – vereinfacht dargestellt – ein empirisches  $p$ -Quantil die Stichprobe so, dass ein Anteil der Stichprobe von  $p$  kleiner als das empirische  $p$ -Quantil ist und ein Anteil von  $1 - p$  der Stichprobe größer als das empirische  $p$ -Quantil ist;

**studyflix:** Quantile gehören zu den Lagemaßen der Statistik. Sie teilen eine bestimmte Menge an Daten so ein, dass ein Teil  $p$  kleiner oder gleich und der andere Teil  $1-p$  größer oder gleich dem Quantil ist.

**Spektrum.de:** innerhalb der Mathematischen Statistik verwendeter Begriff für eine Größe, die eine geordnete Stichprobe so zerlegt, daß eine gewissen Anzahl der Daten kleiner als sie selbst ist.

**Bemerkung 10.4** (Skript 26)

(a)  $x_{1/2} = x_{\text{med}}$

(b) Wie der Median ist auch das empirische  $p$ -Quantil ein robustes Lagemaß.

**Beispiel 10.15 10× Würfeln** (Skript 26)

Geordnete Stichprobe: 1, 1, 2, 2, 2, 3, 4, 4, 4, 6,  $n = 10$ .

■  $p = 1/2$ :  $np = 5 \in \mathbb{N}$  und  $x_{1/2} = x_{\text{med}} = \frac{1}{2}[x_{(5)} + x_{(6)}] = \frac{1}{2}[2 + 3] = \frac{5}{2} = 2.5$

■  $p = 1/4$ :  $np = 2.5 \notin \mathbb{N}$ ,  $\lceil np \rceil = 3$  und  $x_{1/4} = x_{(3)} = 2$

■  $p = 3/4$ :  $np = 7.5 \notin \mathbb{N}$ ,  $\lceil np \rceil = 8$  und  $x_{3/4} = x_{(8)} = 4$

**Satz 10.5 Charakterisierung des  $p$ -Quantils** (Skript 26)

(a) Das  $p$ -Quantil  $x_p$  erfüllt

$$\sum_{\substack{k=1: \\ a_k \leq x_p}}^s h_n(a_k) \geq p \quad \text{und} \quad \sum_{\substack{k=1: \\ a_k \geq x_p}}^s h_n(a_k) \geq 1 - p.$$

Das heißt, mindestens  $100p\%$  der Werte in der Stichprobe sind kleiner oder gleich dem Wert des  $p$ -Quantils und mindestens  $100(1-p)\%$  der Werte in der Stichprobe sind größer oder gleich dem Wert des  $p$ -Quantils.

(b) Gelten

$$\sum_{\substack{k=1: \\ a_k \leq a}}^s h_n(a_k) \geq p \quad \text{und} \quad \sum_{\substack{k=1: \\ a_k \geq a}}^s h_n(a_k) \geq 1 - p \quad \text{für ein } a \in \mathbb{R},$$

so folgt  $x_{(\lceil np \rceil)} \leq a \leq x_{(\lceil np \rceil + 1)}$ . Dabei muss  $a$  keine Ausprägung des Merkmals  $X$  sein.

Wir wissen sogar, dass  $x_{(np)} \leq a \leq x_{(np+1)}$  für  $np \in \mathbb{N}$  gilt, sowie  $a = x_{(\lceil np \rceil)}$  sonst.

**Definition 10.14  $p$ -Quantilsabstand** (Skript 26)

Sei  $p \in (0, \frac{1}{2})$ . Wir nennen  $x_{1-p} - x_p$  den  $p$ -Quantilsabstand. Der  $1/4$ -Quantilsabstand wird auch Quartilsabstand genannt.

Zeigen Sie das folgende Lemma als Hausaufgabe.

**Lemma 10.1  $p$ -Quantilsabstand als Streumaß** (Skript 26)

Der  $p$ -Quantilsabstand ist ein Streumaß.

In unserem Beispieldatensatz zum Würfeln sehen wir, dass der Quartilsabstand

$$x_{3/4} - x_{1/4} = 4 - 2 = 2$$

beträgt.

**Karteikarte 10.24 Wozu benötigt man Streumaße zusätzlich zu Lagemaßen?**

Lagemaße beschreiben nur die zentrale Tendenz einer Verteilung, sagen aber nichts darüber aus, wie stark die Daten um diesen zentralen Wert streuen. Streumaße erfassen diese Variabilität/Streubreite der Beobachtungswerte..

**Karteikarte 10.25 Wie ist ein Streumaß formal definiert?**

Eine Funktion  $s : \mathbb{R}^n \rightarrow \mathbb{R}$  heißt Streumaß, wenn  $s(x_1 + a, \dots, x_n + a) = s(x_1, \dots, x_n)$  für alle  $(x_1, \dots, x_n) \in \mathbb{R}^n$  und alle  $a \in \mathbb{R}$  gilt (Translationsinvarianz): Verschiebt man alle Stichprobenwerte um  $a$ , ändert sich der Wert des Streumaßes nicht..

**Karteikarte 10.26 Wie ist die Spannweite einer Stichprobe formal definiert?**

Spannweite =  $x_{\max} - x_{\min} = x_{(n)} - x_{(1)}$ ..

**Karteikarte 10.27 Ist die Spannweite einer Stichprobe robust gegenüber Ausreißern?**

Sie ist ein Streumaß, aber NICHT robust gegenüber Ausreißern..

**Karteikarte 10.28 Wie ist die Medianabweichung formal definiert?**

Man bildet die Hilfsstichprobe  $y_i = |x_i - x_{\text{med}}|$ ; die Medianabweichung ist der Median  $y_{\text{med}}$  dieser Hilfsstichprobe ("Median der absoluten Abweichungen vom Median")..

**Karteikarte 10.29 Ist die Medianabweichung robust gegenüber Ausreißern?**

Ha, sie ist robust gegenüber Ausreißern..

**Karteikarte 10.30 Wie kann man die Medianabweichung umgangssprachlich beschreiben?**

Der "typische" Abstand eines Datenpunkts vom Median: Man schaut sich an, wie weit jeder Wert vom Median entfernt ist, und nimmt davon wiederum den Median..

**Karteikarte 10.31 Wie ist die mittlere absolute Abweichung vom Median formal definiert?**

$\bar{s} = \frac{1}{n} \sum_{i=1}^n |x_i - x_{\text{med}}|$  (arithmetisches Mittel der Hilfsstichprobe  $y_i = |x_i - x_{\text{med}}|$ )..

**Karteikarte 10.32 Ist die mittlere absolute Abweichung vom Median robust?**

Nein, sie ist NICHT robust gegenüber Ausreißern - obwohl der Median selbst robust ist..

**Karteikarte 10.33 Wie kann man die mittlere absolute Abweichung vom Median umgangssprachlich beschreiben?**

Die durchschnittliche Entfernung der Datenpunkte vom Median, ohne Berücksichtigung der Richtung (des Vorzeichens) der Abweichung..

**Karteikarte 10.34 Wie ist die mittlere absolute Abweichung vom arithmetischen Mittel formal definiert?**

$\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$ ..

**Karteikarte 10.35 Ist die mittlere absolute Abweichung vom arithmetischen Mittel robust?**

Nein, sie ist NICHT robust gegenüber Ausreißern..

**Karteikarte 10.36** Wie kann man die mittlere absolute Abweichung vom arithmetischen Mittel umgangssprachlich beschreiben?

Die durchschnittliche Entfernung der Datenpunkte vom arithmetischen Mittel, ohne Berücksichtigung der Richtung (des Vorzeichens) der Abweichung..

**Karteikarte 10.37** Wie ist die (Stichproben-)Varianz  $s^2$  definiert?

$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$  – die mittlere quadratische Abweichung vom arithmetischen Mittel..

**Karteikarte 10.38** Ist die (Stichproben-)Varianz  $s^2$  robust gegenüber Ausreißern?

nein, sie ist NICHT robust gegenüber Ausreißern..

**Karteikarte 10.39** Wie kann man die (Stichproben-)Varianz umgangssprachlich beschreiben?

Ein Maß dafür, wie stark die Daten im Schnitt um das arithmetische Mittel streuen, wobei größere Abweichungen durch das Quadrieren überproportional stark ins Gewicht fallen..

**Karteikarte 10.40** Wie ist die (Stichproben-)Standardabweichung definiert?

$s = \sqrt{s^2}$ , die Wurzel der Stichprobenvarianz. Sie ist ebenfalls nicht robust gegenüber Ausreißern (da  $s^2$  es nicht ist)..

**Karteikarte 10.41** Wie kann man die (Stichproben-)Standardabweichung umgangssprachlich beschreiben?

Die "typische" Streuung der Daten um das arithmetische Mittel, gemessen in derselben Einheit wie die ursprünglichen Daten (im Gegensatz zur Varianz, die in quadrierten Einheiten gemessen wird)..

**Karteikarte 10.42** Wie lautet die Steinersche Formel zur (oft einfacheren) Berechnung der Stichprobenvarianz?

$$s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \left( \frac{1}{n} \sum_{i=1}^n x_i \right)^2 ..$$

**Karteikarte 10.43** Wie lässt sich  $\bar{s}$  (mittlere absolute Abweichung vom Median) mithilfe der Häufigkeitsverteilung statt der Rohdaten berechnen?

$\bar{s} = \frac{1}{n} \sum_{k=1}^s |a_k - x_{\text{med}}| H_n(a_k) = \sum_{k=1}^s |a_k - x_{\text{med}}| h_n(a_k)$  – man summiert über die  $s$  verschiedenen Ausprägungen statt über alle  $n$  Beobachtungen..

**Karteikarte 10.44** Wie lässt sich  $s^2$  (Varianz) mithilfe der Häufigkeitsverteilung statt der Rohdaten berechnen?

$s^2 = \frac{1}{n} \sum_{k=1}^s (a_k - \bar{x})^2 H_n(a_k) = \sum_{k=1}^s (a_k - \bar{x})^2 h_n(a_k)$  – man summiert über die  $s$  verschiedenen Ausprägungen statt über alle  $n$  Beobachtungen..

**Karteikarte 10.45** Wie ist das empirische  $p$ -Quantil  $x_p$  definiert?

Für  $p \in (0, 1)$ :  $x_p = x_{(\lceil np \rceil)}$  falls  $np \notin \mathbb{N}$ , und  $x_p = \frac{1}{2} [x_{(np)} + x_{(np+1)}]$  falls  $np \in \mathbb{N}$ ..

**Karteikarte 10.46** Wie kann man das  $p$ -Quantil umgangssprachlich beschreiben?

Der Wert, bis zu dem ungefähr  $100p\%$  der Daten liegen – eine Verallgemeinerung des Medians (der genau das 50%-Quantil ist) auf beliebige Anteile..

**Karteikarte 10.47** Wie hängt das  $p$ -Quantil mit dem Median zusammen, und welche Lagemaßeigenschaft hat es?

$x_{1/2} = x_{\text{med}}$ . Wie der Median ist auch das empirische  $p$ -Quantil ein robustes Lagemaß..

**Karteikarte 10.48** Wie lässt sich das  $p$ -Quantil analog zum Median charakterisieren?

Das  $p$ -Quantil erfüllt  $\sum_{k:a_k \leq x_p} h_n(a_k) \geq p$  und  $\sum_{k:a_k \geq x_p} h_n(a_k) \geq 1 - p$  – mindestens  $100p\%$  der Werte sind kleiner-gleich, mindestens  $100(1 - p)\%$  größer-gleich  $x_p$ . Umgekehrt: Erfüllt ein  $a$  diese beiden Ungleichungen (für gegebenes  $p$ ), so liegt  $a$  zwischen  $x_{(\lceil np \rceil)}$  und  $x_{(\lceil np \rceil + 1)}$ ;  $a$  muss dabei keine beobachtete Ausprägung sein..

**Karteikarte 10.49** Was ist der  $p$ -Quantilsabstand, und wie heißt der Spezialfall  $p = 1/4$ ?

Für  $p \in (0, \frac{1}{2})$  ist der  $p$ -Quantilsabstand definiert als  $x_{1-p} - x_p$ ..

**Karteikarte 10.50** Wie heißt der Spezialfall  $p = 1/4$  des  $p$ -Quantilsabstands?

Der Fall  $p = 1/4$  heißt Quartilsabstand..

**Karteikarte 10.51** Wie kann man den  $p$ -Quantilsabstand umgangssprachlich beschreiben?

Die Breite des "mittleren" Bereichs der Daten zwischen dem unteren und dem oberen Quantil ( $x_p$  bis  $x_{1-p}$ ): je kleiner  $p$ , desto mehr der (mittleren) Daten wird erfasst, und je größer dieser Abstand, desto stärker streuen die Daten..

**Karteikarte 10.52** Ist der  $p$ -Quantilsabstand ein Streumaß?

Ja, der  $p$ -Quantilsabstand ist ein Streumaß (erfüllt die Translationsinvarianz-Eigenschaft  $s(x + a) = s(x)$ )..

**Karteikarte 10.53** Welche der behandelten Streumaße sind robust gegenüber Ausreißern?

Robust: Medianabweichung,  $p$ -Quantilsabstand. NICHT robust: Spannweite, mittlere absolute Abweichung vom Median, mittlere absolute Abweichung vom arithmetischen Mittel, (Stichproben-)Varianz, (Stichproben-)Standardabweichung..



# KAPITEL 11

## Schließende Statistik: Testtheorie I

**Ziel:** Schließen von einer Stichprobe auf Verteilungsparameter.

### Annahme

Im Folgenden nehmen wir stets an, dass eine Stichprobe  $x_1, \dots, x_n$  vorliegt, von der wir annehmen können, dass sie aus Werten besteht, die von einem  $n$ -fach unabhängig wiederholten Zufallsexperiment stammen.

Das heißt, wir nehmen an, dass es einen Wahrscheinlichkeitsraum  $(\Omega, \mathbb{P})$ , unabhängige, identisch verteilte,  $\mathbb{R}$ -wertige Zufallsvariablen  $X_1, \dots, X_n$  und ein  $\omega \in \Omega$  gibt derart, dass

$$(x_1, \dots, x_n) = (X_1(\omega), \dots, X_n(\omega)).$$

Wir werden die Theorie jeweils am Beispiel von **Bernoulli-Variablen** illustrieren.

#### Beispiel 11.1 Fragestellung im Fall von Bernoulli-Variablen (Skript 26)

Die  $n$  unabhängigen **Bernoulli-Variablen** können wir als Modell verstehen für das Werfen einer (nicht unbedingt fairen) Münze, für das Werfen einer Reißzwecke oder auch für einen Spezialfall des Werfens unserer Schweinchen: Beim Werfen der Schweinchen in der Vorlesung haben wir die Schweinchen 166-mal geworfen. Wenn wir nur jene Würfe als Erfolg gezählt hätten, in denen ein Schweinchen auf der Schnauze gelandet ist, so wäre dies ein Bernoulli-Experiment gewesen. Wir können jedoch auch im Nachhinein die anderen Resultate ignorieren und unser Experiment als reines Bernoulli-Experiment betrachten, wenn uns nur eine der möglichen Positionen interessiert.

All diesen Situationen ist gemein, dass wir die tatsächliche Erfolgswahrscheinlichkeit nicht kennen und auch kein Symmetrieargument verwenden können, um diese zu bestimmen. Wir arbeiten daher zunächst mit einem **Parameter**, der in der Statistik üblicherweise mit  $\theta$  bezeichnet wird und die Rolle der Erfolgswahrscheinlichkeit übernimmt.

Im Fall von **Bernoulli-Variablen** ist das Modell für das Zufallsexperiment also gegeben durch

- Ereignisraum  $\Omega = \{0, 1\}^n$
- unbekannte Erfolgswahrscheinlichkeit  $\theta \in [0, 1]$
- Wahrscheinlichkeitsfunktion  $\mu_\theta(\omega) = \theta^{\sum_{i=1}^n \omega_i} (1 - \theta)^{n - \sum_{i=1}^n \omega_i}$  für alle  $\omega \in \Omega$
- $X_i : \Omega \rightarrow \{0, 1\}$  mit  $X_i(\omega) = \omega_i$  für alle  $\omega \in \Omega$  und alle  $i \in \{1, \dots, n\}$

#### Definition 11.1 Stichprobe, Stichprobenvariable und Stichprobenraum (Skript 26)

- (a) Die Zufallsvariablen  $X_1, \dots, X_n$  heißen *Stichprobenvariable*.

(b) Eine Realisation

$$x = (x_1, \dots, x_n) = (X_1(\omega), \dots, X_n(\omega)) = X(\omega)$$

für ein gegebenes  $\omega \in \Omega$  heißt *Stichprobe*.

(c) Der Bildbereich  $\mathcal{X} = X(\Omega) = (X_1, \dots, X_n)(\Omega)$  der  $n$ -dimensionalen Zufallsvariablen  $X$  heißt *Stichprobenraum*. Der *Stichprobenraum*  $\mathcal{X}$  ist die Menge aller möglichen Stichproben (bei gegebenem Experiment  $t$ ).

### Beispiel 11.2 Bernoulli-Variable (Skript 26)

Im Fall von *Bernoulli-Variablen* erfüllen die unabhängigen *Stichprobenvariablen*  $X_1, \dots, X_n$

$$\mathbb{P}_\theta(X_i = 1) = \theta \quad \text{und} \quad \mathbb{P}_\theta(X_i = 0) = 1 - \theta \quad \forall i \in \{1, \dots, n\}.$$

Ist  $n = 3$  und  $\omega \in \Omega$  zum Beispiel gegeben durch  $\omega = (0, 0, 1)$ , so ergibt sich die Stichprobe zu  $x = (x_1, x_2, x_3) = (X_1(\omega), X_2(\omega), X_3(\omega)) = (0, 0, 1)$ , weil die *Stichprobenvariablen* in diesem Fall die Projektionen von  $\Omega$  auf die einzelnen Komponenten sind.

Der *Stichprobenraum* ist  $\mathcal{X} = X(\Omega) = \{0, 1\}^3$ .

### Definition 11.2 Statistisches Modell (Skript 26)

Ein *statistisches Modell* für ein gegebenes Zufallsexperiment ist eine Familie  $\mathcal{P}$  von Wahrscheinlichkeitsmaßen  $\mathbb{P}$  auf dem *Stichprobenraum*  $\mathcal{X}$ , wobei die Wahrscheinlichkeitsmaße  $\mathbb{P} \in \mathcal{P}$  die möglichen *Verteilungen* von  $X = (X_1, \dots, X_n)$  beschreiben.

Gilt  $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ , so heißt  $\Theta$  der *Parameterraum* und  $\theta \in \Theta$  heißt *Parameter*.

### Beispiel 11.3 Bernoulli-Variable (Skript 26)

Im Fall von unabhängigen *Bernoulli-Variablen* als *Stichprobenvariable*  $X_1, \dots, X_n$  ist das zugehörige statistische Modell gegeben durch  $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ , wobei wir im Allgemeinen  $\Theta = [0, 1]$  wählen und  $\mathbb{P}_\theta$  durch die Wahrscheinlichkeitsfunktion  $\mu_\theta$  mit

$$\mu_\theta(\omega) = \theta^{\sum_{i=1}^n \omega_i} (1 - \theta)^{n - \sum_{i=1}^n \omega_i} \quad \text{für alle } \omega \in \Omega$$

gegeben ist.

Wenn wir Grund haben anzunehmen, dass für die Erfolgswahrscheinlichkeit gewisse Werte ausgeschlossen werden können, so kann  $\Theta$  auch als echte Teilmenge von  $[0, 1]$  gewählt werden.

### Karteikarte 11.1 Welche Grundannahme trifft man in der schließenden Statistik über das Zustandekommen einer Stichprobe $x_1, \dots, x_n$ ?

Man nimmt an, dass es einen Wahrscheinlichkeitsraum, unabhängige identisch verteilte Zufallsvariablen  $X_1, \dots, X_n$  und ein  $\omega \in \Omega$  gibt, sodass  $(x_1, \dots, x_n) = (X_1(\omega), \dots, X_n(\omega))$  gilt – die Stichprobe ist also die Realisierung von  $n$  unabhängig wiederholten, identisch verteilten Zufallsexperimenten..

### Karteikarte 11.2 Was sind die Stichprobenvariablen $X_1, \dots, X_n$ ?

Die zugrundeliegenden Zufallsvariablen, deren Realisierung die Stichprobe liefert – sie modellieren das (unabhängig wiederholte) Zufallsexperiment, aus dem die Daten stammen..

### Karteikarte 11.3 Was ist eine Stichprobe (formal, als Realisierung)?

Für ein gegebenes  $\omega \in \Omega$  ist die Stichprobe  $x = (x_1, \dots, x_n) = (X_1(\omega), \dots, X_n(\omega)) = X(\omega)$  – also der konkret

beobachtete Wert der Stichprobenvariablen..

**Karteikarte 11.4** Was ist der wesentliche Unterschied zwischen den Stichprobenvariablen  $X_1, \dots, X_n$  und einer Stichprobe  $x_1, \dots, x_n$ ?

Die Stichprobenvariablen sind Zufallsvariablen (zufällig, vor der Erhebung); eine Stichprobe ist eine konkrete, feste Realisierung dieser Zufallsvariablen – die tatsächlich beobachteten Zahlenwerte..

**Karteikarte 11.5** Was ist der Stichprobenraum  $\mathcal{X}$ ?

Der Bildbereich  $\mathcal{X} = X(\Omega)$  der  $n$ -dimensionalen Zufallsvariablen  $X = (X_1, \dots, X_n)$  – die Menge aller möglichen Stichproben bei gegebenem Experiment..

**Karteikarte 11.6** Was ist ein statistisches Modell?

Eine Familie  $\{P_\theta : \theta \in \Theta\}$  von Wahrscheinlichkeitsmaßen auf dem Stichprobenraum, welche die möglichen Verteilungen von  $X = (X_1, \dots, X_n)$  beschreibt..

**Karteikarte 11.7** Was sind Parameterraum  $\Theta$  und Parameter  $\theta$ ?

In einem statistischen Modell  $\{P_\theta : \theta \in \Theta\}$  heißt  $\Theta$  der Parameterraum, und jedes  $\theta \in \Theta$  heißt Parameter – er indiziert, welches konkrete Wahrscheinlichkeitsmaß aus der Modellfamilie vorliegt..

**Karteikarte 11.8** Muss der Parameterraum  $\Theta$  bei Bernoulli-Stichprobenvariablen immer ganz  $[0, 1]$  sein?

Nein. Hat man Grund zur Annahme, dass gewisse Werte der Erfolgswahrscheinlichkeit ausgeschlossen werden können, darf  $\Theta$  auch als echte Teilmenge von  $[0, 1]$  gewählt werden..

Unser Ziel ist es nun, systematisch aus Stichproben Schlüsse zu ziehen über die dem Zufallsexperiment zugrunde liegende Wahrscheinlichkeitsverteilung. Konkreter heißt das: Wir nehmen an, dass wir die **Verteilung** der **Stichprobenvariablen** bis auf den oder die **Parameter** der **Verteilung** kennen, und wollen nun anhand einer Stichprobe die **Parameter** der **Verteilung** bestmöglich schätzen. Im Fall von **Bernoulli-Variablen** heißt das, dass wir die Erfolgswahrscheinlichkeit  $\theta$  schätzen wollen. Im Folgenden werden wir auch andere Kennzahlen der Wahrscheinlichkeitsverteilung wie Erwartungswert oder Varianz schätzen.

## 11.1 | Punktschätzer

Grundsätzlich gibt es verschiedene Typen von Resultaten, die wir anhand einer Stichprobe gewinnen können:

1. **Punktschätzer:** Resultat ist ein Wert  $\theta$  oder  $g(\theta)$  mit  $\theta \in \Theta$
2. **Bereichsschätzer:** Resultat ist eine Teilmenge von  $\Theta$
3. **Hypothesentest:** Resultat ist eine Ja-Nein-Entscheidung über eine den **Parameter** betreffende **Hypothese**

Wir befassen uns in diesem Kapitel mit **Punktschätzern**.

**Definition 11.3 Punktschätzer** (Skript 26)

Sei ein statistisches Modell der Form  $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$  gegeben.

- (a) Ein **Schätzer** für  $\theta \in \Theta$  ist eine Abbildung  $t : \mathcal{X} \rightarrow \Theta$ . Wir nennen auch die Zufallsvariable  $T = t(X) = t((X_1, \dots, X_n))$  einen **Schätzer** für  $\theta \in \Theta$ . Eine Realisierung  $t(x) = t((x_1, \dots, x_n))$  bzw.  $T(\omega)$  heißt **Schätzung** für  $\theta$ .

- (b) Sei zusätzlich eine Abbildung  $g : \Theta \rightarrow \Gamma$  gegeben. Ein **Schätzer** für  $g(\theta)$  ist eine Abbildung  $t : \mathcal{X} \rightarrow \Gamma$ . Wir nennen auch die Zufallsvariable  $T = t(X) = t((X_1, \dots, X_n))$  einen **Schätzer** für  $g(\theta)$ . Eine Realisierung  $t(x) = t((x_1, \dots, x_n))$  bzw.  $T(\omega)$  heißt *Schätzung* für  $g(\theta)$ .

Wir werden uns zunächst auf **Schätzer** für  $\theta$  konzentrieren und später auf **Schätzer** für  $g(\theta)$  zurückkommen.

| <b>Schätzer (Funktion)</b>                                                                                   | <b>Schätzung (Funktionswert <math>t</math>)</b>                                        |
|--------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------|
| Rechenvorschrift $t : \mathcal{X} \rightarrow \Theta$ ;<br>ordnet jeder Stichprobe einen<br>Parameterwert zu | Ergebnis $t(x)$ der Auswertung<br>der Rechenvorschrift für eine<br>konkrete Stichprobe |

### Bemerkung 11.1 Unterschied zwischen Schätzer und Schätzung für $\theta$

#### Beispiel 11.4 Schätzer können absurd schlecht sein (Skript 26)

Im Fall von unabhängigen **Bernoulli-Variablen** als **Stichprobenvariable**  $X_1, \dots, X_n$  haben wir den **Stichprobenraum**  $\mathcal{X} = \{0, 1\}^n$  sowie den **Parameterraum**  $\Theta = [0, 1]$ . Gemäß Definition ist die Abbildung

$$t : \mathcal{X} \rightarrow \Theta \text{ mit } t(x) = \frac{1}{2} \text{ für alle } x \in \mathcal{X}$$

eine zulässige Wahl für einen **Schätzer** der Erfolgswahrscheinlichkeit. Offensichtlich ist diese, nicht von der Stichprobe abhängige Wahl nicht sinnvoll.

Motiviert durch das Gesetz der großen Zahlen und die Tatsache, dass für **Bernoulli-Variable** der Erwartungswert der Erfolgswahrscheinlichkeit entspricht, vermuten wir, dass das arithmetische Mittel der Stichprobenwerte

$$t(x) = \frac{1}{n} \sum_{i=1}^n x_i$$

eine klügere Wahl sein sollte.

Dies wirft die Frage auf, wann ein **Schätzer** ein guter **Schätzer** ist. Wir benötigen Kriterien, um **Schätzer** systematisch beurteilen zu können.

#### Karteikarte 11.9 Welche drei Arten von Resultaten kann man anhand einer Stichprobe über den Parameter gewinnen?

Punktschätzer (ein einzelner Wert  $\theta$  bzw.  $g(\theta)$ ), Bereichsschätzer (eine Teilmenge von  $\Theta$ ) und Hypothesentest (eine Ja-Nein-Entscheidung über eine Hypothese zum Parameter)..

#### Karteikarte 11.10 Wie ist ein Schätzer für den Parameter $\theta$ definiert?

Eine Abbildung  $t : \mathcal{X} \rightarrow \Theta$  vom Stichprobenraum in den Parameterraum. Auch die Zufallsvariable  $T = t(X)$  wird Schätzer genannt..

#### Karteikarte 11.11 Was ist eine Schätzung (im Unterschied zum Schätzer)?

Die Realisierung  $t(x)$  des Schätzers für eine konkrete Stichprobe  $x$  – der Zahlenwert, den man erhält, wenn man die Rechenvorschrift  $t$  auf die beobachteten Daten anwendet..

#### Karteikarte 11.12 Was ist der wesentliche Unterschied zwischen einem Schätzer und einer Schätzung?

Ein Schätzer ist eine Rechenvorschrift/Funktion, die jeder möglichen Stichprobe einen Parameterwert zuordnet; eine Schätzung ist das konkrete Ergebnis dieser Rechenvorschrift für eine tatsächlich beobachtete Stichprobe..

**Karteikarte 11.13** Wie verallgemeinert sich der Schätzerbegriff auf eine Funktion  $g(\theta)$  des Parameters?

Für eine Abbildung  $g : \Theta \rightarrow \Gamma$  ist ein Schätzer für  $g(\theta)$  eine Abbildung  $t : \mathcal{X} \rightarrow \Gamma$  (bzw. die Zufallsvariable  $T = t(X)$ ). Der Schätzer für  $\theta$  selbst ist der Spezialfall  $\Gamma = \Theta$ ,  $g = \text{id}$ .

**Karteikarte 11.14** Schließt die Definition eines Schätzers offensichtlich unsinnige Wahlen aus?

Nein. Formal ist jede Abbildung  $t : \mathcal{X} \rightarrow \Theta$  ein zulässiger Schätzer – selbst eine konstante Funktion, die jede Stichprobe ignoriert. Man braucht daher zusätzliche Gütekriterien, um sinnvolle von unsinnigen Schätzern zu unterscheiden.

### 11.1.1 | Kriterien zur Beurteilung von Punktschätzern

**Definition 11.4 Kriterien zur Beurteilung von Punktschätzern** (Skript 26)

Gegeben seien ein statistisches Modell der Form  $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ , eine Abbildung  $g : \Theta \rightarrow \Gamma$ , sowie ein Schätzer  $t : \mathcal{X} \rightarrow \Gamma$  für  $g(\theta)$ .<sup>a</sup>

- (a) Der *Bias* des Schätzers  $t$  ist definiert als

$$\text{Bias}_t(\theta) = \mathbb{E}_\theta[T] - g(\theta) = \mathbb{E}_\theta[t((X_1, \dots, X_n))] - g(\theta) \quad \text{für alle } \theta \in \Theta.$$

Dabei sei  $\mathbb{E}_\theta$  der Erwartungswert, der mit dem Wahrscheinlichkeitsmaß  $\mathbb{P}_\theta$  definiert ist.

- (b) Der Schätzer  $t$  heißt *erwartungstreu*, wenn  $\text{Bias}_t(\theta) = 0$  für alle  $\theta \in \Theta$  gilt.
- (c) Das *Risiko* des Schätzers  $t$  im Punkt  $\theta \in \Theta$  ist definiert als die erwartete quadratische Abweichung des Schätzers von  $g(\theta)$ , das heißt,

$$R(\theta, t) = \mathbb{E}_\theta[(T - g(\theta))^2].$$

- (d) Die *Risikofunktion* des Schätzers  $t$  ist definiert als die Abbildung  $\theta \mapsto R(\theta, t)$ .
- (e) Sind  $t_1, t_2 : \mathcal{X} \rightarrow \Gamma$  zwei Schätzer für  $g(\theta)$ , so sagen wir, dass  $t_1$  *mindestens so gut* ist wie  $t_2$ , wenn  $R(\theta, t_1) \leq R(\theta, t_2)$  für alle  $\theta \in \Theta$  gilt. Gilt zusätzlich, dass es ein  $\theta \in \Theta$  gibt mit  $R(\theta, t_1) < R(\theta, t_2)$ , so sagen wir, dass  $t_1$  *besser*
- (f) als  $t_2$  ist.

<sup>a</sup>Der Fall, dass wir mit einem Schätzer für den Parameter  $\theta$  selbst arbeiten, entspricht der Wahl  $\Gamma = \Theta$  und  $g(x) = x$  für alle  $x \in \mathcal{X}$ . Wir müssen daher die beiden Fälle nicht unterscheiden.

**Beispiel 11.5** Das arithmetische Mittel als Schätzer im Fall von Bernoulli-Variablen (Skript 26)

Im Fall von unabhängigen Bernoulli-Variablen als Stichprobenvariable  $X_1, \dots, X_n$  erhalten wir folgende Ergebnisse für den Schätzer  $t$  mit

$$t(x) = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{für alle } x \in \{0, 1\}^n,$$

den wir verwenden wollen, um den Parameter  $\theta$ , d.h. die Erfolgswahrscheinlichkeit, zu schätzen.

- (a) Der Bias des Schätzers  $t$  ist

$$\text{Bias}_t(\theta) = \mathbb{E}_\theta \left[ \frac{1}{n} \sum_{i=1}^n X_i \right] - \theta = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_\theta[X_i] - \theta = 0 \quad \text{für alle } \theta \in \Theta,$$

weil für die Bernoulli-Variablen  $\mathbb{E}_\theta[X_i] = \theta$  gilt.


(b) Daher ist der Schätzer  $t$  erwartungstreu.

(c) Das Risiko des Schätzers  $t$  im Punkt  $\theta \in \Theta$  ergibt sich zu

$$R(\theta, t) = \mathbb{E}_{\theta} \left[ \left( \frac{1}{n} \sum_{i=1}^n X_i - \theta \right)^2 \right] = \text{Var}_{\theta} \left( \frac{1}{n} \sum_{i=1}^n X_i \right) = \frac{1}{n} \text{Var}_{\theta}(X_1) = \frac{\theta(1-\theta)}{n}.$$

Auch für unbekanntes  $\theta \in \Theta = [0, 1]$  können wir eine von  $\theta$  unabhängige obere Schranke an das Risiko bestimmen. Die Abbildung  $\theta \mapsto \theta(1-\theta)$  wird maximal in  $\theta = \frac{1}{2}$  mit Wert  $\frac{1}{4}$ . Daher gilt

$$R(\theta, t) = \frac{\theta(1-\theta)}{n} \leq \frac{1}{4n} \quad \text{für alle } \theta \in \Theta.$$



(d) Die Risikofunktion des Schätzers  $t$  ist gegeben durch die Abbildung  $\theta \mapsto \frac{\theta(1-\theta)}{n}$ .

(e) Wir wollen nun den Schätzer  $t$  mit einem anderen Schätzer vergleichen. Sei der Schätzer  $\tilde{t}$  gegeben durch

$$\tilde{t}(x) = \frac{x_1 + x_n}{2} \quad \text{für alle } x \in \{0, 1\}^n,$$

das heißt, wir sind “faul” und verwenden nur den ersten und den letzten Stichprobenwert. Das Risiko von  $\tilde{t}$  in  $\theta$  ist gegeben durch  $R(\theta, \tilde{t}) = \frac{\theta(1-\theta)}{2}$

(f) (dieselbe Rechnung wie für  $t$ , nur diesmal mit Stichprobengröße 2).

Wir haben das – keineswegs überraschende – Ergebnis, dass  $t$  mindestens so gut ist wie  $\tilde{t}$ , sofern  $n \geq 2$ . Für  $n > 2$  haben wir sogar, dass  $t$  besser als  $\tilde{t}$  ist.

#### Karteikarte 11.15 Wie ist der Bias eines Schätzers $t$ für $g(\theta)$ definiert?

$\text{bias}_t(\theta) = E_{\theta}[T] - g(\theta)$  für alle  $\theta \in \Theta$ , wobei  $E_{\theta}$  der Erwartungswert bezüglich  $P_{\theta}$  ist..

#### Karteikarte 11.16 Was misst der Bias eines Schätzers anschaulich?

Die systematische Verzerrung des Schätzers: Um wie viel der Erwartungswert des Schätzers (im Mittel über viele Wiederholungen) vom wahren Wert  $g(\theta)$  abweicht..

#### Karteikarte 11.17 Wann heißt ein Schätzer erwartungstreu?

Wenn  $\text{bias}_t(\theta) = 0$  für alle  $\theta \in \Theta$  gilt, d.h. wenn der Erwartungswert des Schätzers stets mit dem wahren Wert  $g(\theta)$  übereinstimmt..

**Karteikarte 11.18** Wie ist das Risiko  $R(\theta, t)$  eines Schätzers  $t$  im Punkt  $\theta$  definiert?

$R(\theta, t) = E_\theta[(T - g(\theta))^2]$  – die erwartete quadratische Abweichung des Schätzers vom wahren Wert  $g(\theta)$ ..

**Karteikarte 11.19** Was misst das Risiko eines Schätzers anschaulich, im Unterschied zum Bias?

Das Risiko fasst systematische Verzerrung (Bias) und zufällige Schwankung (Varianz) des Schätzers in einer einzigen Zahl zusammen – es misst, wie weit der Schätzer im quadratischen Mittel vom wahren Wert entfernt liegt, egal ob durch Verzerrung oder Streuung..

**Karteikarte 11.20** Was ist die Risikofunktion eines Schätzers?

Die Abbildung  $\theta \mapsto R(\theta, t)$ , die für jeden möglichen Parameterwert das Risiko des Schätzers angibt..

**Karteikarte 11.21** Wann heißt ein Schätzer  $t_1$  mindestens so gut wie ein Schätzer  $t_2$  (für dieselbe Größe  $g(\theta)$ )?

Wenn  $R(\theta, t_1) \leq R(\theta, t_2)$  für alle  $\theta \in \Theta$  gilt..

**Karteikarte 11.22** Wann heißt ein Schätzer  $t_1$  besser als ein Schätzer  $t_2$ ?

Wenn  $t_1$  mindestens so gut ist wie  $t_2$  und es zusätzlich ein  $\theta \in \Theta$  mit  $R(\theta, t_1) < R(\theta, t_2)$  gibt..

**Rechenregeln für Bias und Risiko****Lemma 11.1** Rechenregeln für Bias und Risiko (Skript 26)

Sei  $t$  ein Schätzer für  $g(\theta)$ . Dann gelten:

- (a) Der Schätzer  $t$  ist genau dann erwartungstreu, wenn  $E_\theta[T] = g(\theta)$  für alle  $\theta \in \Theta$  gilt.
- (b)  $R(\theta, t) = (\text{Bias}_t(\theta))^2 + \text{Var}_\theta(T)$
- (c) Ist  $t$  erwartungstreu, so gilt  $R(\theta, t) = \text{Var}_\theta(T)$ .

**Beweis.**

- (a) Folgt direkt aus der Definition des Bias und der Erwartungstreue.
- (b) Aus der Definition von Bias und Risiko folgt mit Hilfe einer Nullergänzung, dass

$$\begin{aligned} R(\theta, t) &= E_\theta[(T - g(\theta))^2] = E_\theta\left[\left((T - E_\theta[T]) + (E_\theta[T] - g(\theta))\right)^2\right] \\ &= E_\theta[(T - E_\theta[T])^2] + 2(E_\theta[T] - g(\theta)) E_\theta[T - E_\theta[T]] + (E_\theta[T] - g(\theta))^2 \\ &= \text{Var}_\theta(T) + (\text{Bias}_t(\theta))^2. \end{aligned}$$

- (c) Folgt direkt aus der Definition der Erwartungstreue.

**Karteikarte 11.23** Wie lässt sich Erwartungstreue eines Schätzers  $t$  äquivalent charakterisieren?

$t$  ist genau dann erwartungstreu, wenn  $E_\theta[T] = g(\theta)$  für alle  $\theta \in \Theta$  gilt..

**Karteikarte 11.24** Wie zerlegt sich das Risiko  $R(\theta, t)$  allgemein in Bias und Varianz?

$R(\theta, t) = (\text{bias}_t(\theta))^2 + \text{Var}_\theta(T)$  – das Risiko ist die Summe aus quadriertem Bias und Varianz des Schätzers (Bias-Varianz-Zerlegung)..

**Karteikarte 11.25** Wie vereinfacht sich das Risiko, wenn der Schätzer erwartungstreu ist?

$R(\theta, t) = \text{Var}_\theta(T)$  – bei Erwartungstreue ist das Risiko genau die Varianz des Schätzers, der Bias-Term entfällt..

**Anwendung**

Bisher haben wir ausschließlich den **Parameter** geschätzt, der im Spezialfall der **Bernoulli-Variablen** mit dem Erwartungswert zusammenfällt. Im allgemeinen Fall, wenn die **Stichprobenvariablen** möglicherweise eine andere **Verteilung** haben, dient das arithmetische Mittel als **Schätzer** für den Erwartungswert. Wir sehen uns als Nächstes ein paar Beispiele an. Der allgemeine Fall verbleibt als Hausaufgabe.

**Beispiel 11.6** Das arithmetische Mittel als **Schätzer** des Erwartungswerts (Skript 26)

Seien  $X_1, \dots, X_n$  **Stichprobenvariable** und  $t$  ein **Schätzer** für den Erwartungswert, der durch

$$t(x) = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{für alle } x \in \mathcal{X}$$

definiert ist.

- (a) **Geometrisch verteilte Stichprobenvariable.** Sei  $\theta \in \Theta = [0, 1]$  und gelte

$$\mathbb{P}_\theta(X_i = k) = (1 - \theta)^{k-1} \theta \quad \text{für alle } k \in \mathbb{N}.$$

Dann ist der **Bias** des **Schätzers**  $t$  gegeben durch

$$\text{Bias}_t(\theta) = \mathbb{E}_\theta \left[ \frac{1}{n} \sum_{i=1}^n X_i \right] - \mathbb{E}[X_1] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_\theta[X_i] - \mathbb{E}[X_1] = 0 \quad \text{für alle } \theta \in \Theta,$$

weil  $X_1, \dots, X_n$  identisch verteilt sind. Wir schätzen mit  $t$  den Erwartungswert  $\mathbb{E}[X_1] = \frac{1}{\theta}$ . Der **Schätzer** ist erwartungstreu.

- (b) **Gleichverteilte Stichprobenvariable.** Sei  $\theta \in \Theta = \mathbb{N}$  und gelte

$$\mathbb{P}_\theta(X_i = k) = \frac{1}{\theta} \quad \text{für alle } k \in \{1, \dots, \theta\}.$$

Dann ist der **Bias** des **Schätzers**  $t$  gegeben durch

$$\text{Bias}_t(\theta) = \mathbb{E}_\theta \left[ \frac{1}{n} \sum_{i=1}^n X_i \right] - \mathbb{E}_\theta[X_1] = 0 \quad \text{für alle } \theta \in \Theta,$$

weil  $X_1, \dots, X_n$  identisch verteilt sind. Wir schätzen mit  $t$  den Erwartungswert  $\mathbb{E}_\theta[X_1] = \frac{\theta+1}{2}$ . Der **Schätzer** ist erwartungstreu.

- (c) **Poisson-verteilte Stichprobenvariable.** Sei  $\theta \in \Theta = \mathbb{N}$  und gelte

$$\mathbb{P}_\theta(X_i = k) = \frac{\theta^k}{k!} e^{-\theta} \quad \text{für alle } k \in \mathbb{N}_0.$$

Dann ist der **Bias** des **Schätzers**  $t$  gegeben durch

$$\text{Bias}_t(\theta) = \mathbb{E}_\theta \left[ \frac{1}{n} \sum_{i=1}^n X_i \right] - \mathbb{E}_\theta[X_1] = 0 \quad \text{für alle } \theta \in \Theta,$$

weil  $X_1, \dots, X_n$  identisch verteilt sind. Wir schätzen mit  $t$  den Erwartungswert  $\mathbb{E}_\theta[X_1] = \theta$ . Der **Schätzer** ist erwartungstreu.



Wir können auch Funktionen des **Parameters** schätzen. Wir betrachten hier exemplarisch die Varianz als eine solche Funktion.

**Beispiel 11.7 Schätzer für die Varianz (Skript 26)**

Seien  $X_1, \dots, X_n$  unabhängige **Stichprobenvariable**  $a$  und  $t$  ein **Schätzer** für den Erwartungswert, der durch

$$t(x) = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{für alle } x \in \mathcal{X}$$

definiert ist.

Eine naheliegende Idee ist es, analog zur Stichprobenvarianz, die Abbildung  $s^2$  mit

$$s^2(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n \left( x_i - \frac{1}{n} \sum_{j=1}^n x_j \right)^2 \quad \text{für alle } x \in \mathcal{X}$$

zu wählen.

Ist dieser **Schätzer** erwartungstreu?

Wir können uns die (Schreib-)Arbeit etwas erleichtern, wenn wir annehmen, dass  $\mathbb{E}_\theta[X_i] = 0$  gilt. Diese Annahme bedeutet keine Einschränkung der Allgemeingültigkeit des herzuleitenden Resultats, wie wir mittels einer Nullergänzung leicht sehen:

$$\begin{aligned} X_i - t(X) &= (X_i - \mathbb{E}_\theta[X_i]) + \left( \mathbb{E}_\theta[X_1] - \frac{1}{n} \sum_{i=1}^n X_i \right) \\ &= (X_i - \mathbb{E}_\theta[X_i]) - \left( \frac{1}{n} \sum_{i=1}^n (X_i - \mathbb{E}_\theta[X_i]) \right) \\ &= (X_i - \mathbb{E}_\theta[X_i]) - t((X_1 - \mathbb{E}_\theta[X_1], \dots, X_n - \mathbb{E}_\theta[X_n])). \end{aligned}$$

Das heißt,  $X_i - t(X)$  hängt nicht vom Erwartungswert der **Stichprobenvariablen** ab.

Im Folgenden nehmen wir also an, dass  $\mathbb{E}_\theta[X_i] = 0$  gilt. Umschreiben zeigt:

$$s^2(X) = \frac{1}{n} \sum_{i=1}^n [X_i^2 - 2X_i t(X) + (t(X))^2] = \frac{1}{n} \sum_{i=1}^n X_i^2 - 2(t(X))^2 + (t(X))^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (t(X))^2.$$

Daher gilt

$$\mathbb{E}_\theta[s^2(X)] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_\theta[X_i^2] - \mathbb{E}_\theta[(t(X))^2] = \mathbb{E}_\theta[X_1^2] - \mathbb{E}_\theta[(t(X))^2] = \mathbb{E}_\theta[X_1^2] - \frac{1}{n^2} \sum_{i,j=1}^n \mathbb{E}_\theta[X_i X_j].$$

Für  $i \neq j$  gilt aufgrund der Unabhängigkeit von  $X_i$  und  $X_j$ , dass  $\mathbb{E}_\theta[X_i X_j] = \mathbb{E}_\theta[X_i] \mathbb{E}_\theta[X_j] = 0$ . Daher bleiben von der Doppelsumme nur die Diagonalterme, das heißt,

$$\mathbb{E}_\theta[s^2(X)] = \mathbb{E}_\theta[X_1^2] - \frac{1}{n^2} \sum_{i=1}^n \mathbb{E}_\theta[X_i^2] = \mathbb{E}_\theta[X_1^2] - \frac{1}{n} \mathbb{E}_\theta[X_1^2].$$

Da wir angenommen haben, dass  $\mathbb{E}_\theta[X_1] = 0$  gilt, folgt

$$\mathbb{E}_\theta[s^2(X)] = \left(1 - \frac{1}{n}\right) \text{Var}_\theta(X_1).$$

Wir sehen somit, dass  $s^2$  *kein* erwartungstreuer **Schätzer** der Varianz ist. Wir sehen aber auch, dass der Unterschied nur im Vorfaktor  $1 - \frac{1}{n}$  liegt. Wenn wir  $s^2$  mit  $\frac{n}{n-1}$  multiplizieren, erhalten wir einen erwartungstreuen **Schätzer**.

In der Tat definiert

$$\hat{\sigma}^2(x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{für alle } x \in \mathcal{X}$$

einen erwartungstreuen **Schätzer** für die Varianz, wenn der Erwartungswert unbekannt ist und daher durch den **Schätzer**  $\bar{x}$  ersetzt werden muss.

<sup>a</sup>Wir nehmen nicht an, dass die Stichprobenvariablen **Bernoulli-Variable** sind.

**Karteikarte 11.26** Ist das arithmetische Mittel  $\bar{x}$  ein erwartungstreuer Schätzer für die Erfolgswahrscheinlichkeit  $\theta$  bei unabhängigen Bernoulli-Stichprobenvariablen?

Ja,  $\text{bias}(\theta) = 0$  für alle  $\theta \in [0, 1]$ , da  $E_\theta[X_i] = \theta$  für alle  $i$  gilt..

**Karteikarte 11.27** Wie groß ist das Risiko des arithmetischen Mittels als Schätzer der Erfolgswahrscheinlichkeit bei Bernoulli-Stichprobenvariablen?

$R(\theta, t) = \frac{\theta(1-\theta)}{n}$  (da der Schätzer erwartungstreu ist, entspricht das Risiko der Varianz  $\text{Var}_\theta(\bar{X}) = \frac{1}{n} \text{Var}_\theta(X_1)$ )..

**Karteikarte 11.28** Wie erhält man aus  $R(\theta, t) = \frac{\theta(1-\theta)}{n}$  eine vom unbekannten  $\theta$  unabhängige obere Schranke für das Risiko?

Man maximiert  $\theta(1-\theta)$  über  $\theta \in [0, 1]$ ; das Maximum liegt bei  $\theta = \frac{1}{2}$  mit Wert  $\frac{1}{4}$ . Damit folgt die gleichmäßige Schranke  $R(\theta, t) \leq \frac{1}{4n}$  für alle  $\theta \in [0, 1]$  – man erhält also eine Risikoschranke, ohne den wahren Parameter zu kennen..

**Karteikarte 11.29** Ist es i. A. sinnvoll, möglichst viele Stichprobenwerte in einen Schätzer einzubeziehen, statt nur einen Teil zu verwenden?

Ja. Ein Schätzer, der weniger unabhängige Beobachtungen einbezieht, hat i.d.R. eine größere Varianz und damit ein mindestens so hohes (oft höheres) Risiko als ein Schätzer, der alle verfügbaren Stichprobendaten nutzt..

**Karteikarte 11.30** Ist das arithmetische Mittel  $\bar{X}$  allgemein (für beliebige i.i.d. Stichprobenvariablen mit existierendem Erwartungswert) ein erwartungstreuer Schätzer des Erwartungswerts?

Ja. Da  $X_1, \dots, X_n$  identisch verteilt sind, gilt stets  $E\left[\frac{1}{n} \sum_i X_i\right] = E[X_1]$  – unabhängig von der konkreten zugrundeliegenden Verteilung..

**Karteikarte 11.31** Welchen Rechentrick nutzt man oft bei Bias-/Varianzrechnungen für Schätzer, um die Rechnung zu vereinfachen?

Man darf o.B.d.A. annehmen, dass  $E[X_i] = 0$  gilt, da  $X_i - \bar{X}$  (und damit alle daraus abgeleiteten Größen wie  $s^2$ ) nur von den zentrierten Variablen  $X_i - E[X_i]$  abhängt, nicht vom tatsächlichen Wert des Erwartungswerts selbst..

**Karteikarte 11.32** Ist die naive Stichprobenvarianz  $s^2(x) = \frac{1}{n} \sum_i (x_i - \bar{x})^2$  ein erwartungstreuer Schätzer der wahren Varianz?

Nein. Es gilt  $E[s^2(X)] = \left(1 - \frac{1}{n}\right) \text{Var}_\theta(X_1)$  – der naive Schätzer unterschätzt die Varianz systematisch..

**Karteikarte 11.33** Warum unterschätzt die naive Stichprobenvarianz die wahre Varianz systematisch?

Weil der unbekannte Erwartungswert durch das Stichprobenmittel  $\bar{x}$  ersetzt wird, das selbst aus denselben Daten berechnet ist und sich ihnen "besser anpasst" als der wahre Erwartungswert. Die beobachteten quadratischen

Abweichungen vom Stichprobenmittel sind daher im Mittel kleiner als die Abweichungen vom wahren Erwartungswert..

**Karteikarte 11.34** Wie lautet der erwartungstreue ("korrigierte") Schätzer für die Varianz?

$$\hat{\sigma}^2(x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \text{ (Bessel-Korrektur: Vorfaktor } \frac{1}{n-1} \text{ statt } \frac{1}{n})..$$

**Karteikarte 11.35** Woher kommt der Korrekturfaktor  $\frac{n}{n-1}$  bei der erwartungstreuen Stichprobenvarianz?

Aus  $E[s^2(X)] = (1 - \frac{1}{n}) \text{Var}_\theta(X_1) = \frac{n-1}{n} \text{Var}_\theta(X_1)$ : Multipliziert man den naiven Schätzer  $s^2$  mit  $\frac{n}{n-1}$ , verschwindet der Verzerrungsfaktor und man erhält einen erwartungstreuen Schätzer..



# Teil II

## Tutorien



# KAPITEL 12

Tutorium 20.04.2026

**12.1 | PÜ 1.1.4 - Faire Münze 3-mal Werfen**

**12.2 | PÜ 1.1.5 - Faire Münze n-mal Werfen**

**12.3 | PÜ 1.1.6 - Mensch ärgere dich nicht**





# KAPITEL 13

Tutorium 27.04.2026

## 13.1 | PÜ 1.2.4

Die Funktion  $f : \mathbb{R} \rightarrow \mathbb{R}$  sei gegeben durch

$$f(x) = \begin{cases} 3cx^2(1-x) & \text{für } x \in [0, 1], \\ 0 & \text{sonst} \end{cases}$$

wobei  $c \in \mathbb{R}$  eine Konstante sei.

**Aufgabe 13.1 (a) Bestimmen Sie ein  $c \in \mathbb{R}$  derart, dass  $f$  eine Dichte ist**

**Lösung:**  $f(x)$  ist eine Dichte, wenn  $\int_{\mathbb{R}} f(x) dx = 1$  also  $\int_{-\infty}^{\infty} f(x) dx = 1$  (Von Studi vorgestellt)

$$\begin{aligned} \int 3cx^2(1-x) dx &= 3c \cdot \int x^2(1-x) dx \\ &= 3c \cdot \int_0^1 x^2 - x^3 dx \\ &= 3c \cdot \left[ \frac{1}{3}x^3 - \frac{1}{4}x^4 \right]_0^1 \\ &= 3c \cdot \left( \frac{1}{3} - \frac{1}{4} \right) \\ &= c \cdot \frac{1}{4} \end{aligned}$$

$$c \cdot \frac{1}{4} = 1 \Rightarrow c = 4$$

Sei  $\mathbb{P}$  das Wahrscheinlichkeitsmaß mit Dichte  $f$ , wie Sie sie in (a) bestimmt haben.

*Hinweis:* Falls Sie die Konstante  $c$  nicht bestimmen konnten, rechnen Sie im folgenden bitte mit der unbestimmten Konstanten weiter.

**Aufgabe 13.2 (b) Berechnen Sie die folgenden Wahrscheinlichkeiten**

$$\mathbb{P}\left(\left(\frac{1}{2}, \infty\right)\right), \mathbb{P}\left((-\infty, 0)\right), \mathbb{P}\left([1, \infty)\right) \text{ und } \mathbb{P}\left(\left\{\frac{1}{2}\right\}\right)$$

**Lösung:** (von Tutor)

$$pe((\frac{1}{2}, \infty)) = \frac{11}{16}$$

$$\begin{aligned}\mathbb{P}((-\infty, 0)) &= \int_{-\infty}^0 f(x) dx \\ &= \int_{-\infty}^0 0 dx \\ &= 0\end{aligned}$$

$$\begin{aligned}\mathbb{P}([1, \infty)) &= \int_1^{\infty} f(x) dx \\ &= \int_1^{\infty} 0 dx \\ &= 0\end{aligned}$$

$$\begin{aligned}\mathbb{P}(\{\frac{1}{2}\}) &= \int_{\frac{1}{2}}^{\frac{1}{2}} f(x) dx \\ &= 12 \cdot \left[ \frac{1}{3} \cdot x^3 - \frac{1}{4} \cdot x^4 \right]_{\frac{1}{2}}^{\frac{1}{2}} \\ &= 12 \cdot \left( \frac{1}{3} \cdot \frac{1}{2^3} - \frac{1}{4} \cdot \frac{1}{2^4} - \frac{1}{3} \cdot \frac{1}{2^3} + \frac{1}{4} \cdot \frac{1}{2^4} \right) \\ &= 0\end{aligned}$$

# KAPITEL 14

## Tutorium 04.05.2026 (Zusatztutorium)

### 14.1 | PÜ 1.0.1

Aus dem Intervall  $[0, 1]$  wird rein zufällig eine Zahl gezogen. Wir betrachten in dieser Aufgabe nur die Nachkommastellen der Dezimalentwicklung.

**Aufgabe 14.1 (a) Modellieren Sie dieses Zufallsexperiment, indem Sie einen geeigneten Wahrscheinlichkeitsraum angeben.**

$$\Omega = [0, 1]$$

Und Dichte:


$$f(x) = \begin{cases} 1, & x \in [0, 1] \\ 0, & \text{sonst} \end{cases}$$

Das ergibt:

$$\mathbb{P}(A) = \int_A f(x) dx$$

**Aufgabe 14.2 (b) Definieren Sie die folgenden Ereignisse als Teilmengen des Ereignisraums, und zeichnen Sie diese in einer Skizze des Intervalls ein**

1. Die erste Nachkommastelle der Zahl ist ungerade:  $A_1 = \bigsqcup_{k=1}^5 [\frac{2k-1}{10}, \frac{2k}{10})$
2. Die zweite Nachkommastelle der Zahl ist gleich 4:  $A_2 = \bigsqcup_{i=0}^9 [\frac{10i+4}{100}, \frac{10i+5}{100})$
3. Die Summe der ersten beiden Nachkommastellen der Zahl beträgt 5:  $A_3 = \bigsqcup_{i=0}^5 [\frac{10i+(5-i)}{100}, \frac{10i+(5-i)+1}{100})$
4. Die Zahl ist exakt  $\frac{1}{\pi}$ :  $A_4 = \{\frac{1}{\pi}\} = 0,3138\dots$
5. Die Zahl ist um höchstens  $\frac{1}{100}$  von  $\frac{1}{\pi}$  entfernt:  $A_5 = [\frac{1}{\pi} - \frac{1}{100}, \frac{1}{\pi} + \frac{1}{100}]$



**Aufgabe 14.3 Berechnen Sie die Wahrscheinlichkeiten dieser Ereignisse.****Lösung:** Für 1.

$$\mathbb{P}(A_1) = \mathbb{P}\left(\bigcup_{k=1}^5 \left[\frac{2k-1}{10}, \frac{2k}{10}\right)\right) = \sum_{k=1}^5 \mathbb{P}\left(\left[\frac{2k-1}{10}, \frac{2k}{10}\right)\right) = \sum_{k=1}^5 \mathbb{P}\left(\left[\frac{1}{10}, \frac{2}{10}\right)\right) = 5 \mathbb{P}\left(\left[\frac{1}{10}, \frac{2}{10}\right)\right) = 5 \cdot \frac{1}{10} = \frac{1}{2}$$

Für 2.

$$\mathbb{P}(A_2) = \sum_{i=0}^9 \mathbb{P}\left(\left[\frac{10i+4}{100}, \frac{10i+5}{100}\right)\right) = 10 \cdot \frac{1}{100} = \frac{1}{10}$$

Für 3.

$$\mathbb{P}(A_3) = \sum_{i=0}^5 \mathbb{P}\left(\left[\frac{10i+(5-i)}{100}, \frac{10i+(5-i)+1}{100}\right)\right) = 6 \cdot \frac{1}{100} = \frac{3}{50}$$

Für 4. WS für Einpunktmenge bei Dichte ist  $0 = \int_{1/\pi}^{1/\pi} 1 dx = \frac{1}{\pi} - \frac{1}{\pi}$ 

Für 5.

$$\mathbb{P}(A_5) = \mathbb{P}\left(\left[\frac{1}{\pi} - \frac{1}{100}, \frac{1}{\pi} + \frac{1}{100}\right]\right) = \frac{2}{100}$$

**14.2 | PÜ 1.0.2.**

Beim Spiel Mensch ärgere dich nicht würfelt der Spieler zunächst einmal. Dann wird die Figur des Spielers auf dem Brett um die entsprechende Anzahl an Feldern vorgerückt. Falls der Spieler eine 6 würfelt hat, so darf er anschließend erneut würfeln. Wieder wird die Figur um die entsprechende Anzahl an Feldern vorgerückt. Dieser Vorgang wird wiederholt, bis der Würfel zum ersten Mal keine 6 zeigt. Uns interessiert nur, um wie viele Felder die Figur insgesamt vorgerückt wird

**Aufgabe 14.4 Geben Sie einen geeigneten Wahrscheinlichkeitsraum für dieses Zufallsexperiment an.****Lösung:**  $\Omega = \mathbb{N}$  also

$$\tilde{\Omega} = \{(k, l) \mid k \in \mathbb{N}_0, l \in \{0, \dots, 5\}\} = \mathbb{N}_0 \times \{0, \dots, 5\}$$

$$\mu = \text{?} \rightarrow \mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega)$$

Für  $1 \leq \omega \leq 6 :: \mu_1 \sim \cup_{\{1, \dots, 6\}}$ 

$$\mu(\omega) = \mu_1(\omega) = \frac{1}{6} \quad \forall \omega \in \{1, \dots, 5\}$$

$$\mu(6) = 0$$

Für  $7 \leq \omega \leq 12 :: \mu_2 \sim \cup_{\{1, \dots, 6\}^2}$ 

$$\mu(\omega) = \mu_2((6, 6 - \omega)) = \frac{1}{36} \quad \forall \omega \in \{7, \dots, 11\}$$

 $\mu(12) = \mu_2((6, 6)) = 0$  ist falsch!, weil wir direkt nochmal würfeln würden nach der zweiten 6, richtig wäre:

$$\mu(12) = 0 \text{ und } \mu_2((6, 6)) = \frac{1}{36}$$

Weitere Beispiele:

$$\text{bspw. } \mu(7) = \mu_2((6, 1))$$

$$\text{und bspw. } \mu(72) = \mu(6 \cdot 12 + 1) = \frac{1}{6^{13}}$$

Damit man überhaupt den zweiten Wurf machen darf, muss das erste ja schon eine 6 gewesen sein, deswegen  $1/36$

**Aufgabe 14.5**

$$\frac{\mathbb{N}}{6} = \{n \in \mathbb{N} : n \text{ nichtkongruent mod } 6\}$$

also auch

$$\mathbb{N}_0 \times \{0, \dots, 5\}$$

dannam ende mit dem squiggy arrow muss man noch ausrechnen, dass das eine Zähldichte ist

## 14.3 | PÜ 1.0.3.



# KAPITEL 15

Tutorium 11.05.2026

**15.1 | PÜ 1.3.4.**





# KAPITEL 16

Tutorium 18.05.2026

**16.1 | PÜ 1.4.4.**

**16.2 | PÜ 1.4.5.**



# KAPITEL 17

Tutorium 26.05.2026

**17.1 | PÜ 1.5.4.**

**17.2 | PÜ 1.5.5.**



# KAPITEL 18

## Tutorium 01.06.2026

### 18.1 | PÜ 1.6.4.

Auf einem Tisch stehen zwei Urnen.

- Urne  $U_K$  enthalte eine schwarze Kugel und zwei weiße Kugeln.
- Urne  $U_Z$  enthalte zwei schwarze Kugeln und eine weiße Kugel.

Die Kugeln unterscheiden sich nur durch ihre Farbe. Mavi wirft eine faire Münze, um sich zwischen den beiden Urnen zu entscheiden.

- Wenn die Münze Kopf zeigt, dann zieht Mavi nacheinander und ohne Zurücklegen zwei Kugeln aus Urne  $U_K$ .
- Wenn die Münze Zahl zeigt, dann zieht Mavi nacheinander und ohne Zurücklegen zwei Kugeln aus Urne  $U_Z$ .

**Aufgabe 18.1 (a) Geben Sie einen geeigneten Ereignisraum  $\Omega$  an, mit dem Sie die folgenden Aufgabenteile bearbeiten können.**

**Meine Lösung:**  $\Omega = \{k, z\} \times \{s, w\}^2$ , wobei  $\omega = (k, s, w)$  bedeutet, dass aus der Urne  $U_K$  erst eine schwarze und dann eine weiße Kugel gezogen wurde.

**Tutor Lösung:**  $\Omega = \{k, z\} \times \{s, w\}^2$  mit der Bemerkung, dass  $\mathbb{P}((k, s, s)) = \mathbb{P}(z, w, w) = 0$ . Die Bemerkung muss nicht dazu. Dabei ist  $\{k, z\}$  der Münzwurf und  $\{s, w\}^2$  das Ziehen zweier Kugeln.

Man kann es auch direkt mit Tripeln machen, aber das ist mehr Schreibarbeit. Aber dann hat man die Sachen mit  $\mathbb{P} = 0$  auch nicht drin, sondern nur das, was tatsächlich möglich ist.

**Aufgabe 18.2 (b) Definieren Sie jene Ereignisse als Teilmengen von  $\Omega$ , die Sie benötigen, um die folgenden Aufgabenteile bearbeiten zu können.**

**Meine Lösung:**

$$\begin{aligned}
 S_i &= \{\text{i schwarze Kugeln gezogen}\} \\
 W_i &= \{\text{i weiße Kugeln gezogen}\} \\
 S_1 = W_1 &= \{(k, s, w), (k, w, s), (z, w, s), (z, s, w)\} \\
 S_0 = W_2 &= \{(k, w, w)\} \\
 S_2 = W_0 &= \{(z, s, s)\} \\
 U_K &= \{\text{Es wurde aus Urne } U_K \text{ gezogen}\} \\
 &= \{(k, s, w), (k, w, s), (k, w, w)\} \\
 U_Z &= \{\text{Es wurde aus Urne } U_Z \text{ gezogen}\} \\
 &= \{(z, s, w), (z, w, s), (z, s, s)\}
 \end{aligned}$$

(Alle Ereignisse, nicht nur die für die Aufgaben relevanten...)

**Tutor Lösung:**

$$\begin{aligned}
 W &= \{k, z\} \times \{w\}^2 \\
 K &= \{k\} \times \{s, w\}^2 \\
 Z &= \{z\} \times \{s, w\}^2
 \end{aligned}$$

**Aufgabe 18.3 (c) Bestimmen Sie aus dem Text die Wahrscheinlichkeiten bzw. bedingten Wahrscheinlichkeiten der Ereignisse aus (b).**

**Meine Lösung:**

$$\begin{aligned}
 P(U_Z) &= P(U_K) = \frac{1}{2} \\
 P(S_0 \mid U_K) &= \frac{2}{3} \cdot \frac{1}{2} = \frac{2}{6} \\
 P(S_0 \mid U_Z) &= 0
 \end{aligned}$$

(Nicht weiter gemacht)

**Tutor Lösung:**

$$\begin{aligned}
 \mathbb{P}(K) &= \mathbb{P}(Z) = \frac{1}{2} \\
 \mathbb{P}(W \mid K) &= \frac{2}{3} \cdot \frac{1}{2} = \frac{2}{6} = \frac{1}{3} \\
 \mathbb{P}(W \mid Z) &= 0
 \end{aligned}$$

**Aufgabe 18.4 (d) Berechnen Sie die Wahrscheinlichkeit, dass Mavi mindestens eine schwarze Kugel zieht (d.h., die Wahrscheinlichkeit, dass Mavi eine oder zwei schwarze Kugeln zieht)**

**Tutor Lösung:**  $\mathbb{P}(\text{"Mindestens eine schwarze Kugel gezogen"}) = \mathbb{P}(W^c) = 1 - \mathbb{P}(W)$ , wobei  $W = \{\text{"Es werden nur weiße Kugeln gezogen"}\}$

$$\begin{aligned}\mathbb{P}(W) &= \mathbb{P}(W \mid K) \cdot \mathbb{P}(K) + \mathbb{P}(W \mid Z) \cdot \mathbb{P}(Z) \\ &= \frac{1}{3} \cdot \frac{1}{2} + 0 \cdot \frac{1}{2} \\ &= \frac{1}{6}\end{aligned}$$

**Aufgabe 18.5 (e) Sie wissen, dass Mavi mindestens eine schwarze Kugel gezogen hat. Berechnen Sie die Wahrscheinlichkeit, dass Mavi aus der Urne  $U_Z$  gezogen hat.**

**Tutor Lösung:**

$$\begin{aligned}\mathbb{P}(\text{"Zahl"} \mid \text{"min. 1 schwarze Kugel"}) &= \mathbb{P}(Z \mid W^c) \\ &\stackrel{\text{Bayes}}{=} \frac{\mathbb{P}(W^c \mid Z) \cdot \mathbb{P}(Z)}{\mathbb{P}(W^c)} \\ &= \frac{(1 - \mathbb{P}(W \mid Z)) \cdot \mathbb{P}(Z)}{\mathbb{P}(W^c)} \\ &= \frac{\frac{1}{2}}{\frac{5}{6}} = \frac{6}{10} \\ &= \frac{3}{5}\end{aligned}$$

## 18.2 | Besprechung ÜB 1.5.1

Seien  $X, Y$  ZVs mit gemeinsamer Dichte  $f$ :

$$f(x, y) = \begin{cases} c \cdot e^{-x + \frac{y}{2}}, & x \in [0, 1], y \geq 0 \\ 0, & \text{sonst} \end{cases}$$

**(a) Finde  $c$ , sodass  $f$  Dichte ist**

$f \geq 0$  sqiggy-Pfeil zu  $c \stackrel{!}{\geq} 0$

$$\begin{aligned}1 &\stackrel{!}{=} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy \\ &= c \cdot \int_0^1 e^{-x} dx \int_0^{\infty} e^{\frac{1}{2}y} dy \\ &= c \cdot [-e^{-x}]_0^1 \cdot [-2 \cdot e^{-\frac{y}{2}}]_0^{\infty} \\ &= c \cdot (1 - e^{-1}) \cdot (2)\end{aligned}$$

sqiggy-Pfeil zu:

$$c = \frac{1}{2(1 - e^{-1})} \geq 0$$

(b)

Bemerkte:  $\chi$ 

$$f(x, y) = \underbrace{c_1 \cdot e^{-x} \cdot \chi_{[0,1]}(x)}_{f_X(x)} \cdot \underbrace{c_2 \cdot e^{-\frac{y}{2}} \cdot \chi_{[0,\infty)}(y)}_{f_Y(y)}$$

mit  $c = c_1 \cdot c_2$  TO-DO von Bild abtippen, hat weggewischt

(c)

 $F_X$  &  $F_Y = ?$  $x < 0$ :  $F_X(x) = 0$ 

$$x \in [0, 1]: F_X(x) = \int_0^x c_1 e^{-\tilde{x}} d\tilde{x} = c_1 \cdot (1 - e^{-x}) = \frac{1-e^{-x}}{1-e^{-1}}$$

 $x > 1$ :  $F_X(x) = 1$ 

sqiggy-Pfeil zu:

$$f_X(x) = \begin{cases} 0, & x < 0 \\ \frac{1-e^{-x}}{1-e^{-1}}, & x \in [0, 1] \\ 1, & x > 1 \end{cases}$$

TO-DO von Bild abtippen, hat weggewischt

(d)

(e)

$$\begin{aligned} \mathbb{P}(X > Y) &= \int_0^1 f_X(x) \underbrace{\int_0^x f_Y(y) dy}_{F_Y(x)} dx \\ &= \int_0^1 2ce^{-x} \cdot (1 - e^{-\frac{x}{2}}) dx \\ &= 2c \int_0^1 e^{-x} - e^{-\frac{3}{2}x} dx \\ &= 2c \cdot ((1 - e^{-1}) - [-\frac{2}{3}e^{-\frac{3}{2}x}]_0^1) \\ &= 2c \cdot ((1 - e^{-1}) - (-\frac{2}{3} - \frac{2}{3}e^{-\frac{3}{2}})) \end{aligned}$$

## 18.3 | Besprechung ÜB 1.5.2

Seien  $X, Y \sim \text{Exp}(\lambda)$ ,  $X \perp\!\!\!\perp Y$ 

(a)

$$\mathbb{P}(X > 10) = 1 - \mathbb{P}(X \leq 10)$$

Für  $\lambda = \frac{1}{5}$ 

$$\mathbb{P}(X > 10) = 1 - \mathbb{P}(X \leq 10) = 1 - F_X(10) = 1 - (1 - e^{-\frac{1}{5} \cdot 10}) = e^{-2}$$



(c)

$$\underbrace{\mathbb{P}(X + Y \leq Z)}_{F_{X+Y}(z)} = \int_0^2 f_X(x) \underbrace{\int_0^{z-x} f_Y(y) dy}_{F_Y(z-x)} dx$$

*= TODOrestvonBild*

subsubsection\*(c oder b?)

**18.4 | Besprechung ÜB 1.5.3**

To-do von Bild

**18.5 | PÜ 2.1.4****18.6 | PÜ 2.1.5****18.7 | PÜ 2.1.6**



# KAPITEL 19

## Tutorium 15.06.2026

Binomialverteilung benutzt man, wenn es aus der Aufgabenstellungen hervor sinnvoll ist oder wenn die Aufgabenstellung sagt, dass etwas binomialverteilt ist.

$$\begin{aligned}\mathbb{P}(X_n \leq \delta) &= \mathbb{P}(X_n - np \leq \delta - np) \\ &= \mathbb{P}\left(\frac{X_n - np}{\sqrt{npq}} \leq \frac{\delta - np}{\sqrt{npq}}\right) \\ &\approx^* \Phi\left(\frac{\delta - np}{\sqrt{npq}}\right)\end{aligned}$$

\* das ist das Anwenden von Moire-Laplace.

Tscheby:

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq \delta) \leq \frac{\text{Var}(X)}{\delta^2}$$

### 19.1 | PÜ 2.2.4.

Der Lufthansa Airbus A380 bietet insgesamt 526 Fluggästen Platz. Da Kunden manchmal ihren Flug nicht antreten, lassen Fluggesellschaften zwecks optimaler Auslastung Überbuchungen zu. Es sollen möglichst viele Tickets verkauft werden, wobei jedoch die Wahrscheinlichkeit einer Überbuchung maximal 5% betragen soll. Erfahrungsgemäß erscheinen Kunden mit einer Wahrscheinlichkeit von 10% nicht zum Flug.

**Aufgabe 19.1 (a) Geben Sie einen geeigneten Wahrscheinlichkeitsraum an, der es erlaubt, die folgenden Aufgabenteile zu bearbeiten. Diskutieren Sie, welche Annahmen Sie machen müssen, um Ihre Wahl des Wahrscheinlichkeitsraums zu rechtfertigen.**

**Lösung Tutor**

$$\Omega = \left\{ \underbrace{0}_{\text{kommt nicht}}, \underbrace{1}_{\text{kommt}} \right\}^n$$

kommt nicht ist  $q = \frac{1}{10}$  und kommt ist  $p = \frac{9}{10}$ .

$$\mathbb{P}(\{\omega\}) = p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{\sum_{i=1}^n (1-\omega_i)}$$

Bspw.  $\{\omega\} = (1, 0, 1, 1, 0)$

Wenn Binomialverteilt, geht man davon aus jeder hat die gleich WS zu kommen und sie sind unabhängig (wir ignorieren bspw., dass Familien meistens zusammen reisen oder absagen).

Erwartungswert berechnet den Durchschnitt einer ZV!

**Aufgabe 19.2 (b) Geben Sie ein Verfahren an, wie die Frage, wie viele Tickets unter den oben genannten Bedingungen maximal angeboten werden können, exakt beantwortet werden könnte**

**Lösung des Tutors:** Man definiert eine ZV  $S_n$  über die aufsummiert wird:

$$S_n(\underbrace{\omega}_{\omega=\omega_1, \dots, \omega_n}) = \sum_{i=1}^n \omega_i$$

$S_n$  ist die Anzahl der Leute, die kommen.

Wenn wir die WS der Überbuchung auf maximal 0,05 halten wollen, interessiert uns

$$\mathbb{P}(S_n > 526) \leq 0,05$$

■  $n$  = Anzahl verkaufte Tickets (wir wollen  $n$  maximieren)

■  $S_n$  = Anzahl der Personen, die kommen

Auf Basis dessen oben:

$$\underbrace{\mathbb{P}(S_n \leq 526)}_{=\sum_{i=1}^{526} \binom{n}{i} p^i (1-p)^{n-i}} \geq 0,95$$

Starte bei  $n = 526$  und berechne  $\mathbb{P}(S_n \leq 526)$  mit inkrementierendem  $n$  und wenn es bei einem  $n$  über 0,95 liegt, dann ist das das gesuchte  $n$  das  $n-1$  ist.

$$\begin{aligned} \mathbb{P}(S_n \leq 526) &= \mathbb{P}(S_n - np \leq 526 - np) \\ &= \mathbb{P}\left(\frac{S_n - np}{\sqrt{npq}} \leq \frac{526 - np}{\sqrt{npq}}\right) \\ &\approx \phi\left(\underbrace{\frac{526 - np}{\sqrt{npq}}}_{\geq 1,65}\right) \end{aligned}$$

$$\frac{526 - np}{\sqrt{npq}} \geq 1,65$$

$p$  und  $q$  einsetzen

$$526 - (\sqrt{n})^2 \cdot \frac{9}{10} \geq 1,65\sqrt{n} \cdot \frac{3}{10}$$

und dann landet man durch Rumschieben bei

$$\underbrace{(\sqrt{n})^2}_x + \underbrace{1,65 \cdot \frac{1}{3}}_{c_1} \underbrace{\sqrt{n}}_x - \underbrace{\frac{10}{90,9?}}_{c_2} \leq 0$$

TODO noch das letzte von der Tafel

**Aufgabe 19.3 (c) Nutzen Sie den Satz von de Moivre-Laplace, um näherungsweise zu bestimmen, wie viele Tickets unter den oben genannten Bedingungen maximal angeboten werden können.**

## 19.2 | PÜ 2.2.5

Eine Süßwarenfirma gibt an, daß 25% ihrer Gummibärchen die beliebte Farbe rot haben. Im folgenden gehen wir davon aus, daß die Angaben des Herstellers richtig sind. Wir nehmen auch an, daß die Gummibärchen unabhängig voneinander rot sind oder eine andere Farbe haben.

Trotzdem waren in einer kleineren Stichprobe lediglich 20% der Gummibärchen rot. Wir wollen der Sache auf den Grund gehen und kaufen daher  $n$  weitere Gummibärchen. Sei  $b_n$  die Wahrscheinlichkeit, dass höchstens 20% der neu gekauften  $n$  Gummibärchen rot sind.

**Aufgabe 19.4 (a) Geben Sie für jedes beliebige  $n \in \mathbb{N}$  einen geeigneten Wahrscheinlichkeitsraum an, der es erlaubt, die folgenden Aufgabenteile zu bearbeiten**

$$\Omega = \left\{ \underbrace{0}_{\text{nicht rot}}, \underbrace{1}_{\text{rot}} \right\}^n$$

wobei  $n$  die Anzahl der gekauften Gummibärchen ist.

$$\mathbb{P}(\{\omega\}) = p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{\sum_{i=1}^n (1-\omega_i)}$$

mit  $p=0,25$  = WS für rot und  $q = 1-p$

**Aufgabe 19.5 (b) Definieren Sie eine Zufallsvariable  $S_n$ , die die Anzahl der roten Gummibärchen unter den  $n$  gekauften Gummibärchen angibt.**

$$S_n = \sum_{i=1}^n \omega_i, \quad S_n \sim \text{Bin}(n, p)$$

**Aufgabe 19.6 (c) Sei  $n = 20$ . Berechnen Sie  $b_{20}$  auf drei Nachkommastellen genau, d.h., geben Sie die Wahrscheinlichkeit in der Form 0.xyz bzw. xy.z % an.**

$$\frac{S_n}{n} (= \text{mitHtchenzeichen}) \text{ Durchschnittliche Anzahl rot}$$

Es gilt

$$\mathbb{P}\left(\frac{1}{n}S_n \leq \frac{1}{5}\right) = \mathbb{P}\left(S_n \leq \frac{n}{5}\right)$$

Und mit  $n = 20$

$$\mathbb{P}\left(S_{20} \leq \frac{20}{5}\right) = \mathbb{P}(S_{20} \leq 4) = \sum_{i=1}^4 \binom{20}{i} p^i \cdot (1-p)^{20-i} = 0,4148\dots$$

**Aufgabe 19.7 (d) Beweisen Sie mit Hilfe der Tschebysche!schen Ungleichung, daß  $b_{200} < b_{20}$  gilt.**

Also  $b_n = \mathbb{P}\left(\frac{1}{n}S_n \leq \frac{1}{5}\right)$

Heißt wir müssen  $\mathbb{P}(|X - \mathbb{E}[X]| \geq \delta) \leq \frac{\text{Var}(X)}{\delta^2}$  in jene Form umwandeln. Erstmal Erwartungswert von beiden Seiten abziehen(?):

$$\mathbb{P}\left(\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right] \leq \frac{1}{5} - \mathbb{E}\left[\frac{1}{n}S_n\right]\right)$$

Es ist ja

$$\mathbb{E}\left[\frac{1}{n}S_n\right] = \frac{1}{n}\mathbb{E}[S_n] = \frac{1}{n} \cdot np = p \stackrel{\text{Aufgabe}}{=} \frac{1}{4}$$

Also

$$\begin{aligned} \mathbb{P}\left(\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right] \leq \frac{1}{5} - \mathbb{E}\left[\frac{1}{n}S_n\right]\right) &= \mathbb{P}\left(\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right] \leq -\frac{1}{20}\right) \\ &= \mathbb{P}\left(\left|\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right]\right| \geq \frac{1}{20}\right) \end{aligned}$$

TODO die Sachen von der Tafel noch zu ende

Aufgabe 19.8 (e) Zeigen Sie mit Hilfe der Tschebysche!schen Ungleichung, dass  $\lim_{n \rightarrow \infty} b_n = 0$  gilt

## 19.3 | PÜ 2.2.6

# KAPITEL 20

Tutorium 22.06.2026

## 20.1 | PÜ 2.3.4

Bei einer Maschine, die Elektronikbauteile produziert, ist im Schnitt jedes 50. Bauteil fehlerhaft. Wir testen eine Lieferung von 300 Bauteilen. Wie groß ist die Wahrscheinlichkeit, dass genau 3 Bauteile fehlerhaft sind?

Denken Sie daran, einen Wahrscheinlichkeitsraum anzugeben und die benötigten Zufallsvariablen zu definieren!

### Aufgabe 20.1

$$\Omega = \{0, 1\}^n, \quad n = 300$$

mit

$$\mu(\omega) = p^{\sum_{i=1}^n \omega_i} q^{n - \sum_{i=1}^n \omega_i} \quad \text{mit} \quad p = \frac{1}{50}, q = \frac{49}{50}$$

Teil ist kaputt ist Erfolg, damit wir uns nicht mit Gegenwahrscheinlichkeiten auseinandersetzen müssen.

$$S_n(\omega) = \sum_{i=1}^n \omega_i$$

Annahme: teile sind Unabhängig voneinander kaputt und immer  $p = \frac{1}{50}$

$$\begin{aligned} \mathbb{P}(S_n = x) &= \binom{n}{x} \cdot p^x \cdot q^{n-x} \\ &= \binom{300}{3} \left(\frac{1}{50}\right)^3 \left(\frac{49}{50}\right)^{297} \\ &\approx 0,0883 \end{aligned}$$

Poisson Approximation (p klein q groß)

$$\alpha = np = \frac{300}{50} = 6$$

Sei  $X \sim \text{Poi}(\alpha)$

$$\begin{aligned} \mathbb{P}(S_n = 3) &\approx \mathbb{P}(X = 3) \\ &= \frac{\alpha^3}{3!} e^{-\alpha} \\ &= \frac{6^3}{3!} e^{-6} \\ &\approx 0,0892 \end{aligned}$$

$$\mathbb{P}(S_n = k) = \binom{n}{k} p^k q^{n-k}$$

$$\begin{aligned}\mathbb{P}(S_n \in A) &= \sum_{k \in A} \mathbb{P}(S_n = k) \\ &= \sum_{k \in A}\end{aligned}$$

TODO ! Noch Rest von Bildern eintragen

**20.2 | PÜ 2.3.5**

**20.3 | PÜ 2.3.6**



# KAPITEL 21

Tutorium 29.06.2026

**21.1 | PÜ 2.4.4**

**21.2 | PÜ 2.4.5**



# KAPITEL 22

Tutorium 06.07.2026

**22.1 | PÜ 2.5.4**

**22.2 | PÜ 2.5.5**



## Tutorium 13.07.2026

### 23.1 | PÜ 2.6.4

Ein Politiker fällt wiederholt durch fragwürdige Äußerungen auf. Während er bei der letzten Wahl noch 30% der Stimmen erhalten hat, geht sein Wahlkampfteam mittlerweile davon aus, daß dieser Wert gesunken ist. Der Politiker widerspricht dem vehement.

In einer Stichprobe werden 200 Personen befragt. 45 Personen sprechen sich weiterhin für den Politiker aus.

**Aufgabe 23.1** Läßt sich die Hypothese, daß sich die Unterstützung der Wähler für den Politiker nicht verändert hat, halten? Verwenden Sie einen geeigneten Hypothesentest zum Signifikanzniveau von 5%.

**Parameter (Tutor):**  $H_0 = \theta \in \Theta_0 = \left\{\frac{3}{10}\right\}$  und  $H_A = \theta \in \Theta_A = \left[0, \frac{3}{10}\right)$ . Man muss dann einen Hypothesentest mit Signifikanzniveau  $\alpha = 0,05$ .

**Modell dahinter (extra Info für Kontext, noch von der Aufgabe gefordert):**

- Stichprobenraum:  $\chi = \{0, 1\}^n$  mit  $n = 200$ 
  - Jedes  $x \in \chi$  ist ein n-fach unabhängig wiederholtes Bernoulli-Experiment
- $\Theta = [0, 1] \leftarrow$  "Zustimmung"
- $P = \{\mathbb{P}_\theta : \theta \in \Theta\}$ , wobei
  - $\mathbb{P}_\theta$  durch die Wahrscheinlichkeitsfunktion  $\mu_\theta$  mit  $\mu_\theta(x) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}$ ,  $\forall x \in \chi$  gegeben ist.
- Konkrete Stichprobe:  $\tilde{x} \in \chi$  mit  $\sum_{i=1}^n \tilde{x}_i = 45$
- $n = 200$
- Stichprobenvariablen:
  - $X = (X_1, \dots, X_n)$  mit  $\{X_i\}_{i=1}^n$  unabhängig identisch verteilt
  - $X_i \sim \text{Ber}()$

**Weitere Lösung:**

$$t : \chi \rightarrow \{0, \dots, n\}$$

Möglich:

$$t(x) = n\bar{x} = \sum_{i=1}^n x_i$$

$$t(x) = n - n\bar{x} = n - \sum_{i=1}^n x_i$$

ABER:  $t(x) = n\bar{x} = \sum_{i=1}^n x_i$  dann wäre das bei Zustimmung irgendwie sehr groß, also nehmen wir:

$$t(x) = n - n\bar{x} = n - \sum_{i=1}^n x_i$$

deshalb

$$\begin{aligned} p(x) &= \sup_{\theta \in \Theta_0} \mathbb{P}_{\theta}(t(X) \geq t(x)) \\ &= \mathbb{P}_{\frac{3}{10}}(t(X) \geq t(x)) \\ &= \mathbb{P}_{\frac{3}{10}}\left(n - \sum_{i=1}^n X_i \geq n - \sum_{i=1}^n x_i\right) \\ &= \mathbb{P}_{\frac{3}{10}}\left(\sum_{i=1}^n X_i \leq \underbrace{\sum_{i=1}^n x_i}_{n\bar{x}}\right) \end{aligned}$$

$\phi(x) = 1 \Rightarrow H_0$  wird verworfen (Die konkrete Stichprobe soll 1 sein, wenn wir unsere Stichprobe verwerfen. )

$$\phi(x) = \begin{cases} 1, & p(x) \leq \alpha \\ 0, & \text{sonst} \end{cases} = \mathbb{I}_{[0, \alpha]}$$

Betrachte  $p(\tilde{x}) = \mathbb{P}_{\frac{3}{10}}(\sum_{i=1}^n X_i \leq 45)$

$$\begin{aligned} \sum_{i=1}^n X_i &\sim \text{Bin}\left(n, \frac{3}{10}\right) = \text{Bin}_{200, \frac{3}{10}}(\{0, \dots, 45\}) \\ &= \sum_{i=1}^{45} \binom{n}{i} \left(\frac{3}{10}\right)^i \left(\frac{7}{10}\right)^{n-i} \\ &\approx 0,011 \end{aligned}$$

*Taschenrechner*

$$\Rightarrow \phi(\tilde{x}) = \mathbb{I}_{[0, 0.05]}(p(\tilde{x})) = \mathbb{I}_{[0, \alpha]}(0,011) = 1$$

$H_0$  muss verworfen werden.

Ablauf so einer Aufgabenlösung:

1. Hypothese aufstellen
2. Signifikanzniveau festlegen
3. Teststatistik aufstellen
4. p-Wert und Test + Entscheidungsregel
5. "Durchführung" / Auswertung der Stichprobe
6. Schlussfolgerung

Hier umgesetzt als:

1. Hypothese aufstellen

- $H_0 = \theta \in \Theta_0 = \left\{ \frac{3}{10} \right\}$  (Punkthypothese, keine Veränderung)
- $H_A = \theta \in \Theta_A = \left[ 0, \frac{3}{10} \right)$  (Alternative Hypothese, negative Veränderung)

2. Signifikanzniveau festlegen
3. Teststatistik aufstellen
4. p-Wert und Test + Entscheidungsregel
5. “Durchführung” / Auswertung der Stichprobe
6. Schlussfolgerung

Zusatz des Tutors:

|                                                      |       |       |       |       |       |
|------------------------------------------------------|-------|-------|-------|-------|-------|
| k =                                                  | 45    | 46    | 47    | 48    | 49    |
| $\mathbb{P}_{\frac{3}{10}}(\sum_{i=1}^n X_i \leq k)$ | 0,011 | 0,017 | 0,025 | 0,036 | 0,056 |

**Tabelle 23.1:** Ab 49 Zustimmungen hätte man die Hypothese nicht verwefen müssen - “48 und kleiner” ist unser Verwerfungsbereich

## 23.2 | PÜ 2.6.5

Beantworten Sie die folgenden Fragen zur Theorie der **Hypothesentests**. Eine Begründung Ihrer Antworten ist nicht nötig.

### Aufgabe 23.2 Ein Fehler erster Art tritt ein, wenn ...

**Lösung:** wir  $H_0$  verwerfen, wenn  $H_0$  wahr ist (Definition **Fehler erster Art**)

Anmerkung: Fehler zweiter Art ist wir verwerfen  $H_0$  nicht, obwohl  $H_0$  falsch ist (wir  $H_0$  akzeptieren, wenn  $H_0$  falsch ist)

**Kommentar 23.1** Es KANN passieren, dass Definitionen abgefragt werden in der Klausur (in Form von Multiple Choice oder speziellen Fragen). Oder man einen Hypothesentest aufstellen muss.

### Aufgabe 23.3 Wenn eine Hypothese zum Signifikanzniveau 0.6 verworfen wird, dann ...

**Herleitung:** Entspricht ja

$$\phi(x) = \begin{cases} 1, & p(x) \leq 0.6 \\ 0, & \text{sonst} \end{cases} = \mathbb{I}_{[0,0.6]}$$

Muss nicht für jedes Alpha verworfen werden, daher auch nicht für 0,5.

**Lösung:** kann es der Fall sein, dass sie zum Signifikanzniveau 0.5 verworfen wird

### Aufgabe 23.4 Der p-Wert eines Hypothesentests gibt folgendes an:

**Lösung:** Das kleinste Signifikanzniveau für das Verwerfen der Hypothese  $H_0$  (per Definition, denn wenn wir eine konkrete Stichprobe haben (also  $p(x)$  festhalten)) und das Signifikanzniveau danach aussuchen, dann kann das SN nicht kleiner als  $p(x)$  sein?)

### Aufgabe 23.5 Ordnen Sie die folgenden Schritte gemäß der korrekten Durchführung eines Hypothesentests

**Lösung:**

1. Wahl von Hypothese und Alternative
2. Wahl des Signifikanzniveaus
3. Wahl der Teststatistik
4. Wahl der Entscheidungsregel
5. Auswertung der Stichprobe
6. Schlussfolgerung

## 23.3 | Besprechung ÜB 2.5.1

Wir nehmen in dieser Aufgabe an, daß unsere Stichprobe von einem  $n$ -mal unabhängig wiederholten Bernoulli-Experiment mit unbekannter Erfolgswahrscheinlichkeit  $\theta \in (0, 1)$  stammt.

Wir wissen aus der Vorlesung, daß das arithmetische Mittel der Stichprobenwerte ein erwartungstreuer Schätzer für  $\theta$  ist.

*todo*

**Aufgabe 23.6** Begründen Sie, warum  $t$  so definiert ein Schätzer für die Varianz  $\theta(1 - \theta)$  ist.

Siehe Bild TODO

**Ist dieser Schätzer erwartungstreu?**



## Teil III

## Anhang



## 23.4 | Übersichten

| Verteilung                                | Parameter                        | $E[X]$          | $\text{Var}(X)$    | Anwendung                                         |
|-------------------------------------------|----------------------------------|-----------------|--------------------|---------------------------------------------------|
| Bernoulli $\text{Ber}(p)$                 | $p \in (0, 1)$                   | $p$             | $pq$               | Einzelnes Ja/Nein-Experiment                      |
| Binomial $\text{Bin}(n, p)$               | $n \in \mathbb{N}, p \in (0, 1)$ | $np$            | $npq$              | Anzahl Erfolge bei $n$ unabh. Bernoulli-Versuchen |
| Geometrisch $\text{Geo}(p)$               | $p \in (0, 1)$                   | $\frac{1}{p}$   | $\frac{1-p}{p^2}$  | Wartezeit bis zum ersten Erfolg                   |
| Poisson $\text{Poi}(\lambda)$             | $\lambda > 0$                    | $\lambda$       | $\lambda$          | Seltene Ereignisse in festem Intervall            |
| Diskret Gleichverteilt $U\{1, \dots, n\}$ | $n \in \mathbb{N}$               | $\frac{n+1}{2}$ | $\frac{n^2-1}{12}$ | Würfeln, Zufallszahl aus endlicher Menge          |

Tabelle 23.2: Diskrete Verteilungen

| Verteilung                        | Parameter                          | $E[X]$              | $\text{Var}(X)$       | Anwendung                                          |
|-----------------------------------|------------------------------------|---------------------|-----------------------|----------------------------------------------------|
| Stetig Gleichverteilt $U(a, b)$   | $a < b$                            | $\frac{a+b}{2}$     | $\frac{(b-a)^2}{12}$  | ”Keine Information auf Intervall                   |
| Normal $N(\mu, \sigma^2)$         | $\mu \in \mathbb{R}, \sigma^2 > 0$ | $\mu$               | $\sigma^2$            | Grenzverteilung durch ZGWS, Messfehler             |
| Exponential $\text{Exp}(\lambda)$ | $\lambda > 0$                      | $\frac{1}{\lambda}$ | $\frac{1}{\lambda^2}$ | Wartezeit bis zum nächsten Ereignis, gedächtnislos |

Tabelle 23.3: Stetige Verteilungen

| Satz                                               | Anwendbar auf                                                                  | Aussage / Zweck                                                                                                           |
|----------------------------------------------------|--------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------|
| Satz von de Moivre-Laplace                         | $\text{Bin}(n, p)$                                                             | $\text{Bin}(n, p) \rightarrow N(np, npq)$ für $n \rightarrow \infty$ ; Approximation der Binomial- durch Normalverteilung |
| Poisson-Approximation (Gesetz seltener Ereignisse) | $\text{Bin}(n, p)$ mit kleinem $p$ , großem $n$                                | $\text{Bin}(n, p) \rightarrow \text{Poi}(\lambda)$ für $n \rightarrow \infty, p \rightarrow 0, np \rightarrow \lambda$    |
| Zentraler Grenzwertsatz (ZGWS)                     | beliebige unabh. $X_i$ mit endlicher Varianz (i.i.d. oder Lindeberg-Bedingung) | $\frac{S_n - E[S_n]}{\sqrt{\text{Var}(S_n)}} \rightarrow N(0, 1)$ in Verteilung                                           |
| Schwaches Gesetz der großen Zahlen (WGGZ)          | i.i.d. $X_i$ mit endlichem $E[X_i]$                                            | $\frac{S_n}{n} \xrightarrow{P} \mu$ (stochastische Konvergenz)                                                            |
| Starkes Gesetz der großen Zahlen (SGGZ)            | i.i.d. $X_i$ mit endlichem $E[X_i]$                                            | $\frac{S_n}{n} \xrightarrow{\text{f.s.}} \mu$ (fast sichere Konvergenz)                                                   |
| Ungleichung von Chebyshev                          | jede Verteilung mit endlicher Varianz                                          | $\mathbb{P}( X - \mu  \geq k\sigma) \leq \frac{1}{k^2}$ ; grobe Abschätzung, kein Verteilungswissen nötig                 |
| Ungleichung von Markov                             | jede nichtnegative Zufallsvariable                                             | $\mathbb{P}(X \geq a) \leq \frac{E[X]}{a}$ ; schwächer, aber allgemeiner als Chebyshev                                    |

### 23.4.1 | Zusammenhang Poissonscher Grenzwertsatz, Zentraler Grenzwertsatz, Satz von de Moivre-Laplace und Gesetz der großen Zahlen

| Satz                       | Fragestellung                          | Ergebnis                                                              |
|----------------------------|----------------------------------------|-----------------------------------------------------------------------|
| Gesetz der großen Zahlen   | Konvergiert der Durchschnitt?          | Der Stichprobenmittelwert nähert sich dem Erwartungswert an           |
| Zentraler Grenzwertsatz    | Wie schwanken Summen bzw. Mittelwerte? | Die normierte Summe wird asymptotisch normalverteilt                  |
| Satz von de Moivre-Laplace | Spezialfall des ZGWS                   | Die Binomialverteilung wird durch eine Normalverteilung approximiert  |
| Poissonscher Grenzwertsatz | Seltene Ereignisse                     | Die Binomialverteilung wird durch eine Poissonverteilung approximiert |

## Gesetz der großen Zahlen

Seien  $X_1, \dots, X_n$  unabhängige und identisch verteilte Zufallsvariablen mit Erwartungswert  $\mu$ . Dann gilt

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Nach dem (schwachen) Gesetz der großen Zahlen gilt

$$\bar{X}_n \xrightarrow{P} \mu.$$

Beim starken Gesetz der großen Zahlen gilt sogar

$$\bar{X}_n \xrightarrow{\text{f.s.}} \mu.$$

**Interpretation:** Mit wachsender Stichprobengröße nähert sich der Stichprobenmittelwert immer stärker dem Erwartungswert an.

Das Gesetz der großen Zahlen macht jedoch keine Aussage darüber, wie groß die zufälligen Abweichungen sind oder wie diese verteilt sind.

## Zentraler Grenzwertsatz

Unter denselben Voraussetzungen sowie einer endlichen Varianz  $\sigma^2$  gilt

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \Rightarrow N(0, 1).$$

Äquivalent für den Stichprobenmittelwert:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \Rightarrow N(0, 1).$$

**Interpretation** Die zufälligen Abweichungen des Mittelwertes vom Erwartungswert sind für große Stichproben näherungsweise normalverteilt.

Der Zentrale Grenzwertsatz liefert somit deutlich mehr Information als das Gesetz der großen Zahlen.

## Zusammenhang zwischen GGZ und ZGWS

Der Zentrale Grenzwertsatz zeigt, dass

$$\bar{X}_n - \mu = O\left(\frac{1}{\sqrt{n}}\right).$$

Da

$$\frac{1}{\sqrt{n}} \rightarrow 0,$$

folgt daraus unmittelbar die Aussage des schwachen Gesetzes der großen Zahlen.

Anschaulich gilt:

- Das Gesetz der großen Zahlen beschreibt, dass der Fehler gegen Null verschwindet.
- Der Zentrale Grenzwertsatz beschreibt zusätzlich die Verteilung dieses Fehlers.

### Satz von de Moivre-Laplace

Sei

$$X_n \sim \text{Bin}(n, p).$$

Dann gilt

$$\frac{X_n - np}{\sqrt{np(1-p)}} \Rightarrow N(0, 1).$$

Der Satz von de Moivre-Laplace ist somit ein Spezialfall des Zentralen Grenzwertsatzes für Bernoulli-Zufallsvariablen. Er liefert die Approximation

$$\text{Bin}(n, p) \approx N(np, np(1-p)).$$

Diese Approximation ist insbesondere geeignet, wenn

- $n$  groß ist,
- $p$  weder sehr klein noch sehr groß ist.

### Poissonscher Grenzwertsatz

Betrachte nun

$$X_n \sim \text{Bin}(n, p_n),$$

wobei

$$p_n \rightarrow 0, \quad np_n \rightarrow \lambda.$$

Dann gilt

$$X_n \Rightarrow \text{Pois}(\lambda).$$

Hier wird die Binomialverteilung nicht durch eine Normalverteilung, sondern durch eine Poissonverteilung angenähert.

Diese Approximation eignet sich insbesondere für seltene Ereignisse, beispielsweise:


- Defekte Bauteile,
- Verkehrsunfälle,
- Druckfehler.

### Verhältnis zwischen de Moivre-Laplace und Poissonschem Grenzwertsatz

Beide Grenzwertsätze gehen von der Binomialverteilung aus, betrachten jedoch unterschiedliche Grenzfälle.

| $\text{Bin}(n, p)$    | $\text{Bin}(n, p_n)$                          |
|-----------------------|-----------------------------------------------|
| $p = \text{konstant}$ | $p_n \rightarrow 0, np_n \rightarrow \lambda$ |
| $\Downarrow$          | $\Downarrow$                                  |
| $N(np, np(1-p))$      | $\text{Pois}(\lambda)$                        |

## Gesamtübersicht



## Merksätze

- **Gesetz der großen Zahlen:** Der Stichprobenmittelwert konvergiert gegen den Erwartungswert.
- **Zentraler Grenzwertsatz:** Die normierten Abweichungen vom Erwartungswert sind asymptotisch normalverteilt.
- **de Moivre-Laplace:** Spezialfall des Zentralen Grenzwertsatzes für Binomialverteilungen.
- **Poissonscher Grenzwertsatz:** Spezialfall für seltene Ereignisse mit  $p \rightarrow 0$  und  $np \rightarrow \lambda$ ; die Grenzverteilung ist eine Poissonverteilung.

## 23.5 | Referenzen

# Symbole und Begriffe

| Gegenstand                  | Beschreibung    | Symbol                 |
|-----------------------------|-----------------|------------------------|
| Binomialverteilung          |                 | $\mathcal{B}_{n,p}$    |
| Dichte                      |                 | $f$                    |
| Elementarereignis           |                 | $\omega$               |
| Ereignisraum                |                 | $\Omega$               |
| Erwartungswert              | $\mathbb{E}[X]$ | $\mathbb{E}$           |
| Potenzmenge                 |                 | $\mathcal{P}$          |
| Wahrscheinlichkeitsfunktion |                 | $\mu$                  |
| Wahrscheinlichkeitsmaß      |                 | $\mathbb{P}$           |
| Wahrscheinlichkeitsraum     |                 | $(\Omega, \mathbb{P})$ |





# Glossar

**Absolute Konvergenz** . 71

**B-WS** Bedingte Wahrscheinlichkeit. 31

**Bernoulli-Experiment** . 55, 56

**Bias** todo. 143, 145, 146

**Covarianz** todo. 86, 98

**Ereignis** *B*. 7, 8, 10–12, 14, 15, 17, 23–25, 27–29, 53–56, 105

**Familie von Wahrscheinlichkeitsmaßen** todo. 140, 141, 143

**Gleichverteilung** . 5

**paarweise unkorreliert** todo. 98

**Parameter** todo. 139–147

**Parameterraum** todo. 140–146

**PGWS** Poissonscher Grenzwertsatz. iv, 108, 112–118

**Poisson-Verteilung** todo. 114

**stückweise stetig** Eine Funktion  $f: [a, b] \rightarrow \mathbb{R}$  heißt *stückweise stetig*, wenn es eine Zerlegung

$$a = x_0 < x_1 < \dots < x_n = b$$

gibt, sodass  $f$  auf jedem offenen Teilintervall

$$(x_{i-1}, x_i), \quad i = 1, \dots, n,$$

stetig ist und an den Zerlegungspunkten die einseitigen Grenzwerte

$$\lim_{x \rightarrow x_i^-} f(x) \quad \text{und} \quad \lim_{x \rightarrow x_i^+} f(x)$$

jeweils existieren und endlich sind.. 16, 18, 22

**Summe der ersten n Zufallsvariablen** todo. 39–43, 98–101, 104–116

**Varianz** todo. 82–88, 95–99, 101, 110, 111, 115

**Verteilung** todo. iii, 39–46, 48–52, 56, 60, 66, 67, 69, 110, 114, 115, 140, 141, 146

**Verteilungsfunktion** todo. 39, 41, 43–48, 59, 63–65

**Verteilungsfunktion der Standardnormalverteilung**  $\int_{-\infty}^y \frac{1}{\sqrt{2\pi}} e^{x^2/2} dx$ . 101, 102, 104–108, 110, 111

**WS** Wahrscheinlichkeit. 7, 8, 12, 15, 33, 53–56, 108, 111, 113–115

**ZGWS** Zentraler Grenzwertsatz. iv, 108–111

**Zufallsvariable** X. iii, iv, 39–52, 56–67, 69, 71–89

# Index

- Bernoulli-Experiment, 53, 55, 56
- Binomialverteilung, 56, 70, 98, 99, 101, 104, 112–115
- Dichte, 15–22, 27, 33, 46, 62, 63, 72, 74, 75
- Dichte der Standardnormalverteilung, 102
- Faltung, 67
- Gesetz der großen Zahlen, 189
- Moivre-Laplace, 189
- Poissonscher Grenzwertsatz, 189
- Produktform, 59, 60, 64
- Standardnormalverteilung, 102
- Stetigkeitskorrektur, 106
- Verteilung
  - einer Zufallsvariable, 40–43, 46, 69
- Verteilungsfunktion
  - einer Zufallsvariable, 43–48, 65
- Verteilungsfunktion der Standardnormalverteilung, 102
- Zentraler Grenzwertsatz, 189
- Zufallsvariable, 67, 71, 72