




Vorlesung Wahrscheinlichkeits- theorie und Statistik

Sommersemester 2026

Vorlesung von Prof. Gentz

Vorlesungsnotizen und Aufarbeitung

Liliana Sanfilippo

Inhaltsverzeichnis

I	Skript	1
1	Modellieren zufälliger Ereignisse	5
1.1	Wahrscheinlichkeitsräume	5
1.1.1	Elementarereignisse	5
1.1.2	Ereignisräume	6
1.1.3	Ereignisse	7
1.1.4	Zähldichten und Wahrscheinlichkeitsmaße	8
1.1.5	Wahrscheinlichkeitsräume	9
1.1.6	Modellierung	10
1.2	Gleichverteilung auf einer endlichen Menge	12
1.3	Wahrscheinlichkeitsräume, deren Ereignisraum nicht abzählbar ist	14
1.3.1	Eindimensionale Dichten	15
1.3.2	Wahrscheinlichkeitsräume mit Dichten	17
1.3.3	Uniforme Verteilung	20
1.3.4	Exponentialverteilung	22
2	Rechnen mit Wahrscheinlichkeiten	23
2.1	Mengenoperationen und Ereignisse	23
2.1.1	Disjunktheit	24
2.2	Erste Rechenregeln für Wahrscheinlichkeiten	27
2.2.1	Das Ein- und Ausschlußprinzip	29
3	Bedingte Wahrscheinlichkeiten	31
4	Zufallsvariablen und ihre Verteilung	39
4.1	Die Verteilung einer Zufallsvariablen	39
4.2	Notationen	40
4.3	Zufallsvariablen mit abzählbarem Bildbereich	41
4.4	Zufallsvariablen mit Dichte	41
4.5	Mehrdimensionale Zufallsvariablen und ihre gemein- same Verteilung: Abzählbare Bildbereiche	41
4.6	Mehrdimensionale Zufallsvariablen und ihre gemein- same Verteilung: Dichten	41
5	Unabhängigkeit und Bernoulli-Experimente	43
5.1	Stochastische Unabhängigkeit von Ereignissen	43
5.2	Unabhängige Nacheinanderausführung von Zufallsexperimenten	44
5.3	Die Binomialverteilung	45

6	Unabhängigkeiten von Zufallsvariable (ZV)	47
6.1	Unabhängigkeit für Zufallsvariable mit abzählbarem Bildbereich	48
6.1.1	Poisson-Verteilte ZV	50
6.2	ZV mit Dichten	51
6.3	Widerlegen von Unabhängigkeiten	52
7	Erwartungswert und Varianz von Zufallsvariablen	57
8	Varianz und Covarianz	75
8.1	Vorlesung 8	75
9	Grenzwertsätze	77
9.0.1	Beispielaufgabe Laubfrosch	92
II	Tutorien	95
10	Tutorium 20.04.2026	97
10.1	PÜ 1.1.4 - Faire Münze 3-mal Werfen	97
10.2	PÜ 1.1.5 - Faire Münze n-mal Werfen	97
10.3	PÜ 1.1.6 - Mensch ärgere dich nicht	97
11	Tutorium 27.04.2026	99
11.1	PÜ 1.2.4	99
12	Tutorium 04.05.2026 (Zusatztutorial)	101
12.1	PÜ 1.0.1	101
12.2	PÜ 1.0.2.	102
12.3	PÜ 1.0.3.	103
13	Tutorium 11.05.2026	105
13.1	PÜ 1.3.4.	105
14	Tutorium 18.05.2026	107
14.1	PÜ 1.4.4.	107
14.2	PÜ 1.4.5.	107
15	Tutorium 26.05.2026	109
15.1	PÜ 1.5.4.	109
15.2	PÜ 1.5.5.	109
16	Tutorium 01.06.2026	111
16.1	PÜ 1.6.4.	111
16.2	Besprechung ÜB 1.5.1	113
16.3	Besprechung ÜB 1.5.2	114
16.4	Besprechung ÜB 1.5.3	115
16.5	PÜ 2.1.4	115
16.6	PÜ 2.1.5	115
16.7	PÜ 2.1.6	115

17 Tutorium 15.06.2026	117
17.1 PÜ 2.2.4.	117
17.2 PÜ 2.2.5	118
17.3 PÜ 2.2.6	120
18 Tutorium 22.06.2026	121
18.1 PÜ 2.3.4	121
18.2 PÜ 2.3.5	122
18.3 PÜ 2.3.6	122
19 Tutorium 29.06.2026	123
19.1 PÜ 2.4.4	123
19.2 PÜ 2.4.5	123
20 Tutorium 06.07.2026	125
20.1 PÜ 2.5.4	125
20.2 PÜ 2.5.5	125
III Anhang	127
20.3 Übersichten	129
20.4 Referenzen	129
Glossary	129
Index	133

Teil I

Skript

Legende

Skript	normale schwarze Schrift
Meine Anmerkungen und Notizen	Lila Schrift
Schriftliche Anmerkungen der Professorin	Orangene Schrift

KAPITEL 1

Modellieren zufälliger Ereignisse

Vorlesung 11.04.2025 (V01 2025), ergänzt durch Skript (Skript 2026)

1.1 | Wahrscheinlichkeitsräume

Kommentar 1.1 Fehlkalkulationen durch unzureichende Modelle bzw. fehlende Parameter werden oft als Zufall gesehen. Wir versuchen Modelle so zu wählen, dass sie möglichst einfach sind




Abbildung 1.1

Lernziele

- modellieren einfacher Zufallsexperimente
- **Wahrscheinlichkeitsraum** kennen und verwenden
- **Gleichverteilung** kennen und erkennen

1.1.1 | Elementarereignisse

Definition 1.1 **Elementarereignis** ω (2025)

Möglicher Ausgang eines Zufallsexperiments.

Es ist üblich, für Elementarereignisse den kleinen griechischen Buchstaben ω (omega) zu verwenden. Davon weichen wir in konkreten Situationen manchmal ab. So schreiben wir zum Beispiel auch k , wenn das Elementarereignis eine natürliche Zahl ist, oder x , wenn es eine reelle Zahl ist.

Beispiel 1.1 Zu Definition 1.1 (2025)

- Würfeln: $\omega = 3$ (3 gewürfelt)
- Zeitmessung: $\omega = 100$ (Sec)

Karteikarte 1.1 Was ist ein Elementarereignis?

Ein möglicher Ausgang eines Zufallsexperiments. Notation: kleiner griechischer Buchstabe ω (omega). Je nach Kontext auch andere Symbole, z.B. k für natürliche Zahlen oder x für reelle Zahlen..

1.1.2 | Ereignisräume**Definition 1.2** Ereignisraum Ω (2025)

Die Menge aller Elementarereignisse $\Omega \neq \emptyset$ ist die Menge aller möglichen Ausgänge eines Zufallsexperiments. Ein Ereignisraum ist also zunächst einmal einfach eine nichtleere Menge.

Für einen Ereignisraum verwenden immer den großen griechischen Buchstaben Ω (Omega). Wenn wir mehrere Ereignisräume benötigen, so schreiben wir $\Omega, \tilde{\Omega}, \Omega_1, \Omega_2, \dots$ usw.

Beispiel 1.2 Zu Definition ?? (2025)

- **Würfeln:** $\Omega = \{1, \dots, 6\}$ oder $\Omega = \{wuerfelsymbole\}$

Die Modellierung durch Würfelsymbole zeigt, daß es beim Modellieren wichtig ist anzugeben, welche Interpretation unsere Kodierung der Elementarereignisse haben soll. Man soll daher stets einen Satz der Art

“Dabei bedeutet $\omega = wuerfelsymbol1$, dass der Würfel eine Eins zeigt”

schreiben, wenn man einen Ereignisraum angibt.

- **Zeitmessung:** $\Omega = [0, \infty)$ ist grundsätzlich eine sinnvolle Wahl, wenn wir das Messen einer zufälligen Zeit modellieren wollen. Sofern Zusatzinformationen vorliegen, können wir natürlich ein kleineres Intervall wählen.

Kommentar 1.2 Siehe die Klammersymbolnotation, die bedeutet die Null ist drin, aber infinity nicht. ∞ ist keine normale Zahl, sondern ein Symbol für Unbeschränktheit. Deshalb schreibt man praktisch immer die runde Klammer auf der Seite.

Häufig interessiert uns gar nicht der exakte Ausgang eines Zufallsexperiments, sondern nur, ob der Ausgang eine bestimmte Eigenschaft hat: Haben wir eine gerade Zahl gewürfelt? Ist die gemessene Zeit kürzer als eine Minute? Wir fassen also jene Elementarereignisse zusammen, die die gewünschte Eigenschaft haben. Dies führt zur folgenden Definition.

Karteikarte 1.2 Was ist ein Ereignisraum Ω ?

Die Menge aller Elementarereignisse, also aller möglichen Ausgänge eines Zufallsexperiments. Muss nichtleer sein ($\Omega \neq \emptyset$). Notation: großer griechischer Buchstabe Ω (Omega). Bei mehreren Ereignisräumen: $\Omega, \tilde{\Omega}, \Omega_1, \Omega_2, \dots$

Karteikarte 1.3 Wie wählt man den Ereignisraum beim Würfeln bzw. bei der Zeitmessung?

Würfeln: $\Omega = \{1, \dots, 6\}$ (oder Würfelsymbole). Zeitmessung: $\Omega = [0, \infty)$ als sinnvolle Grundwahl, kann bei Zusatzinformationen auf ein kleineres Intervall eingeschränkt werden. Wichtig: Bei Angabe von Ω stets die Interpretation der Elementarereignisse angeben, z.B. “Dabei bedeutet $\omega = 1$, dass der Würfel eine Eins zeigt”.

1.1.3 | Ereignisse

Definition 1.3 Ereignis A (2025)

(Messbare) Teilmenge des Ereignisraums $A \subseteq \Omega$ ($A = \emptyset, A = \Omega$) sind zulässig

Sprechweise: $\omega \in A$ bedeutet “ A ist eingetroffen”

Im Fall, dass der Ereignisraum $\Omega \subseteq \mathbb{R}^n$ weder eine endliche noch eine abzählbar unendliche Menge ist, beschränken wir uns auf Ereignisse, die Intervalle oder bekannte geometrische Figuren wie Dreieck, Rechteck oder Kugel sind. Auch abzählbare Schnitte oder Vereinigungen solcher Objekte sind zulässig, sowie deren abzählbare Schnitte oder Vereinigungen. Und so weiter. Diese Einschränkung erlaubt es uns, Fragen der mathematischen Maß- und Integrationstheorie zu vermeiden.

Bemerkung 1.1 Zu Definition ?? (2026)

- Ein Ereignis $A \subseteq \Omega$ ist also ein (messbares) Element der Potenzmenge $\mathcal{P}(\Omega)$ von Ω , das heißt, $A \in \mathcal{P}(\Omega)$.
- Ist $\omega \in \Omega$ ein Elementarereignis, so ist die einelementige Menge $\{\omega\} \in \mathcal{P}(\Omega)$ ein Ereignis in Ω .

Beispiel 1.3 (2025) Zu Definition 1.3

- **Würfeln** einer geraden Zahl:

$$A = \{2, 4, 6\}, \quad \omega = 4 \Rightarrow \omega \in A$$

Wir sagen: “gerade Zahl gewürfelt”

- **Zeitmessung:** $A = [100, 200] \subset \Omega = [0, \infty)$

Karteikarte 1.4 Was ist ein Ereignis A ?

Eine (messbare) Teilmenge des Ereignisraums, $A \subseteq \Omega$. Auch $A = \emptyset$ und $A = \Omega$ sind zulässig. Sprechweise: $\omega \in A$ bedeutet “ A ist eingetroffen”. Formal ist A ein Element der Potenzmenge $\mathcal{P}(\Omega)$, also $A \in \mathcal{P}(\Omega)$.

Karteikarte 1.5 Ist ein Elementarereignis auch ein Ereignis?

Ja. Ist $\omega \in \Omega$ ein Elementarereignis, so ist die einelementige Menge $\{\omega\} \in \mathcal{P}(\Omega)$ ein Ereignis in Ω .

Kommentar 1.3 Beim geeigneten Ω können Modelle sich bereits unterscheiden. Bspw. Münzwurf: Man kann “k”, “z” nehmen oder “Kopf”, “Zahl”. Das sind verschiedenen Ω , aber beide wären passend.

- Finden des geeigneten Ω
- Ereignisse müssen **Wahrscheinlichkeiten (WS)** zugeordnet bekommen

1. Möglichkeit: WS für Ω abzählbar

Kommentar 1.4 Wenn sie abzählbar sagt, meint sie sowohl endlich als auch abzählbar unendlich.

Karteikarte 1.6 Welche Ereignisse betrachtet man, wenn $\Omega \subseteq \mathbb{R}^n$ weder endlich noch abzählbar unendlich ist?

Man beschränkt sich auf Ereignisse, die Intervalle oder bekannte geometrische Figuren sind (Dreieck, Rechteck, Kugel), sowie abzählbare Schnitte oder Vereinigungen solcher Objekte. Dies vermeidet Probleme der Maß- und Integrationstheorie..

1.1.4 | Zähldichten und Wahrscheinlichkeitsmaße

Definition 1.4 Zähldichte / μ (2025)

Sei $\Omega \neq \emptyset$ eine abzählbare Menge.

1. Eine Abbildung $\mu : \Omega \rightarrow [0, 1]$ heißt mit

$$\underbrace{\sum_{\omega \in \Omega} \mu(\omega)}_{\text{Normierung}} = 1$$

Zähldichte / Wahrscheinlichkeitsfunktion auf Ω .

2. Die WS $\mathbb{P}(A)$ einer Ereignisses $A \subseteq \Omega$ ist bei gegebener Wahrscheinlichkeitsfunktion μ definiert durch

$$\mathbb{P}(A) := \sum_{\omega \in A} \mu(\omega)$$

$\mathbb{P}$ heißt Wahrscheinlichkeitsmaß und liegt immer zwischen Null und 1

Kommentar 1.5 Zu Definition 1.4 (i): Die Reihe (Normierung) muss 1 sein und konvergieren.

Wenn man max abzählbar hat, dann sind die Wahrscheinlichkeiten einfach teile der Summe (Normierung) und daher ist das einfach.

Kommentar 1.6 TODO: Was hat die Potenzmenge von Omega damit zu tun?

Bemerkung 1.2 (2025) Zu Definition 1.4 (ii)

Konvention: $\mathbb{P}(\emptyset) = 0$

Bemerkung 1.3 Zu Definition 1.4 (2025)

$$0 \leq \mathbb{P} \leq 1, \quad \forall A \subseteq \Omega \quad \underbrace{(\forall A \in \mathcal{P}(\Omega))}_{\mathcal{P}(\Omega) \text{ Potenzmenge von } \Omega}$$

$\mathbb{P}$ ist eine Abb.

$$\mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1] \quad \text{mit } \mathbb{P}(\emptyset) = 0, \quad \mathbb{P}(\Omega) = 1$$

Lemma 1.1 Eigenschaften des Wahrscheinlichkeitsmaßes für abzählbare Ereignisräume (2026)

Sei $\Omega \neq \emptyset$ eine abzählbare Menge und $\mathbb{P}$ ein Wahrscheinlichkeitsmaß auf Ω . Dann gelten:

- $0 \leq \mathbb{P}(A) \leq 1$ für alle $A \subseteq \mathcal{P}(\Omega)$
- $\mathbb{P}(\emptyset) = 0$
- $\mathbb{P}(\Omega) = 1$

Beweis.

- Untere Schranke: Da $\mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega)$ gilt und alle Summanden nichtnegativ sind, folgt $\mathbb{P}(A) \geq 0$
- Obere Schranke: Aus

$$\mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega) \leq \sum_{\omega \in \Omega} \mu(\omega) = 1$$

folgt $\mathbb{P}(A) \leq 1$. Dabei haben wir in der Abschätzung erneut verwendet, daß alle Summanden nichtnegativ sind.

■ $\mathbb{P}(\emptyset) = 0$ gilt gemäß Konvention aus 1.2.

■ $\mathbb{P}(\Omega) = \sum_{\omega \in \Omega} \mu(\omega) = 1$ folgt direkt aus der Normierung der Wahrscheinlichkeitsfunktion.

Karteikarte 1.7 Was ist eine Zähldichte / Wahrscheinlichkeitsfunktion μ ?

Sei $\Omega \neq \emptyset$ abzählbar. Eine Abbildung $\mu : \Omega \rightarrow [0, 1]$ mit $\sum_{\omega \in \Omega} \mu(\omega) = 1$ (Normierung) heißt Zähldichte bzw. Wahrscheinlichkeitsfunktion auf Ω .

Karteikarte 1.8 Wie berechnet man aus einer Zähldichte μ die Wahrscheinlichkeit $P(A)$ eines Ereignisses?

$P(A) := \sum_{\omega \in A} \mu(\omega)$. P heißt Wahrscheinlichkeitsmaß und liegt immer zwischen 0 und 1..

Karteikarte 1.9 Welchen Wert hat $P(\emptyset)$?

Konvention: $P(\emptyset) = 0$.

Karteikarte 1.10 Welche drei Grundeigenschaften hat ein Wahrscheinlichkeitsmaß P auf abzählbarem Ω ?

(1) $0 \leq P(A) \leq 1$ für alle $A \in \mathcal{P}(\Omega)$. (2) $P(\emptyset) = 0$. (3) $P(\Omega) = 1$. P ist eine Abbildung $P : \mathcal{P}(\Omega) \rightarrow [0, 1]$.

Karteikarte 1.11 Wie zeigt man $0 \leq P(A) \leq 1$?

Untere Schranke: $P(A) = \sum_{\omega \in A} \mu(\omega) \geq 0$, da alle Summanden nichtnegativ sind. Obere Schranke: $P(A) = \sum_{\omega \in A} \mu(\omega) \leq \sum_{\omega \in \Omega} \mu(\omega) = 1$, ebenfalls weil alle Summanden nichtnegativ sind.

Karteikarte 1.12 Was ist der Unterschied zwischen μ und P bezüglich ihres Definitionsbereichs?

μ hat als Argument ein einzelnes Elementarereignis ω (also $\mu(\omega)$), während P auf der Potenzmenge $\mathcal{P}(\Omega)$ definiert ist und daher das einelementige Ereignis $\{\omega\}$ als Argument hat (also $P(\{\omega\})$).

1.1.5 | Wahrscheinlichkeitsräume

Definition 1.5 Wahrscheinlichkeitsraum (2025)

$(\underbrace{\Omega, \mathbb{P}}_{(\Omega, \mu)})$ heißt Wahrscheinlichkeitsraum.

Bemerkung 1.4 Zu Definition 1.5 (2025)

Für Ω abzählbar: μ legt $\mathbb{P}$ eindeutig und umgekehrt!

$$\mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega) \quad \forall A \in \mathcal{P}(\Omega)$$

$$\mu(\omega) = \mathbb{P}(\underbrace{\{\omega\}}_{\text{1-elementige Menge}}) \quad \forall \omega \in \Omega$$

Länger aus dem Skript: (2026) Da es eine ein-eindeutige Zuordnung zwischen der Wahrscheinlichkeitsfunktion μ und dem Wahrscheinlichkeitsmaß $\mathbb{P}$ gibt, bezeichnen wir auch das Paar $(\Omega, \mathbb{P})$ als Wahrscheinlichkeitsraum. Die Zuordnung von μ zu $\mathbb{P}$ ist direkt durch die Definition von $\mathbb{P}$ in Definition 1.4 gegeben. Für eine gegebene Wahrscheinlichkeitsfunktion erhalten wir so ein eindeutig bestimmtes Wahrscheinlichkeitsmaß. Ist ein Wahrscheinlichkeitsmaß $\mathbb{P}$ gegeben, so ergibt sich die zugehörige Wahrscheinlichkeitsfunktion μ sofort aus den Wahrscheinlichkeiten der Elementarereignisse:

$$\mu(\omega) = \mathbb{P}(\{\omega\}), \quad \forall \omega \in \Omega$$

Beachten Sie hier, dass die Wahrscheinlichkeitsfunktion μ als Argument ein Elementarereignis, also ein einzelnes $\omega \in \Omega$ hat, während das Wahrscheinlichkeitsmaß $\mathbb{P}$ auf der Potenzmenge $\mathcal{P}(\Omega)$ von Ω definiert ist und daher das einelementige Ereignis $\{\omega\}$ als Argument hat.

Karteikarte 1.13 Was ist ein Wahrscheinlichkeitsraum?

Das Paar (Ω, μ) heißt Wahrscheinlichkeitsraum. Es besteht eine ein-eindeutige Zuordnung zwischen der Wahrscheinlichkeitsfunktion μ und dem Wahrscheinlichkeitsmaß P : $P(A) = \sum_{\omega \in A} \mu(\omega)$ und umgekehrt $\mu(\omega) = P(\{\omega\})$.

1.1.6 | Modellierung**Beispiel 1.4** Einmal Würfeln (2025)

$\Omega = \{1, \dots, 6\}$, $A = \{6\}$ (sechs gewürfel), $B = \{2, 4, 6\}$ (gerade Zahl).

Dabei beudeute $\omega = k$, dass der Würfel k Augen hat. Wie wählen wir μ ?

1. fairer Würfel:

$$\mu(k) = \text{const} \quad \forall k \in \Omega$$

$$\mu(k) := \frac{1}{6} \left(\text{weil } \sum_{k=1}^6 \mu(k) \stackrel{!}{=} 1 \right)$$

$$\mathbb{P}(A) = \mu(a) = \frac{1}{6}, \quad \mathbb{P}(B) = \sum_{k \in \{2,4,6\}} \mu(k) = \frac{1}{6} \cdot \#B = \frac{3}{6} = \frac{1}{2}$$

2. gezinkter Würfel: Seien

$$\mu(1) = \frac{1}{2}, \mu(2) = \mu(3) = \mu(4) = \mu(5) = \frac{1}{12}, \mu(6) = \frac{1}{6}$$

$$\text{Probe: } \sum_{k=1}^6 \mu(k) \stackrel{!}{=} 1$$

Kommentar 1.7 Zu Beispiel ?? : In Hausaufgaben zu jedem Omega hinzuschreiben, was es bedeutet! “Dabei beudeute $\omega = k$, dass ...”

Kommentar 1.8 Zu Beispiel ?? (1.): Ein ebener Würfel ist ein “fairer Würfel”, weil alle Seiten gleich Wahrscheinlich sind.

Kommentar 1.9 Zu Beispiel ?? (2.): In der Klausur wenn bei einer Probe ein Fehler herauskommt, gerne hinschreiben man hat gemerkt da ist ein Fehler und wo der gewesen sein muss, besser als nichts hinschreiben.

Wie wählen wir Ω und μ (bzw. $\mathbb{P}$)?

■ Frage der Erfahrung

■ wichtiges Thema und Lernziel dieses Semester

Beispiel 1.5 Zweimal würfeln mit fairem Würfel - Augensumme (2025)

1. **Ansatz:** $\Omega_1 = \{1, \dots, 6\}^2 = \{(i, j) : i, j \in \{1, \dots, 6\}\}$

Für $\omega = (i, j) \in \Omega_1$ bedeutet i die Augenzahl des ersten Würfels und j jene des zweiten Würfels.

Aus Symmetriegründen wählen wir $\mu_1(\omega)$ konstant, also

$$\mu_1(\omega) = \frac{1}{|\Omega_1|} = \frac{1}{36} \quad \forall \omega \in \Omega_1$$

$A_k^{(1)} \leq \Omega_1$: Augensumme ist k

Für $k \leq 1$ oder $k \geq 13$:

$$A_k^{(1)} = \emptyset \Rightarrow \mathbb{P}_1(A_k^{(1)}) = 0$$

Für $k = \{2, \dots, 12\}$:

$$\mathbb{P}_1(A_2^{(1)}) = \mathbb{P}_1(\{(1, 1)\}) = \mu_1((1, 1)) = \frac{1}{36}$$

$$\mathbb{P}_1(A_3^{(1)}) = \mathbb{P}_1(\{(1, 2), (2, 1)\}) = \mu_1((1, 2)) + \mu_1((2, 1)) = \frac{2}{36}$$

usw...Es wird immer eines mehr

k	2	3	4	5	6	7	8	9	10	11	12
$\mathbb{P}_1(A_k^{(1)})$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{5}{36}$	$\frac{6}{36}$	$\frac{5}{36}$	$\frac{4}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{1}{36}$

Probe:

$$\sum_{k=2}^{12} \mathbb{P}_1(A_k^{(1)}) = 1$$

2. **Ansatz:** "Wir beachten die Reihenfolge beim Würfeln nicht"

$$\Omega_2 = \{(i, j) \in \Omega_1 : i \leq j\}$$

Dabei bedeute $\omega = (i, j)$, dass sowohl i als auch j gewürfelt wurden.

Finde μ_2 !

(1) $i \leq j$: $1 \times i$ und $1 \times j$ gewürfelt

$$\mu_2((i, j)) = \mu_1((i, j)) + \mu_1((j, i)) = \frac{2}{36}$$

(2) $i = j$: $2 \times i$ gewürfelt

$$\mu_2((i, i)) = \frac{1}{36}$$

Probe machen!

$$A_k^{(2)} = \{(i, j) \in \Omega_2 : i + j = k\}$$

Exemplische Ausrechnung:

$$\mathbb{P}_2(A_4^{(2)}) = \mu_2((1, 3)) + \mu_2((2, 2)) = \frac{2}{36} + \frac{1}{36} = \frac{3}{36}$$

3. **Ansatz:** $\Omega_3 = \{2, 3, \dots, 12\}$

Finde μ_3 ? $\rightarrow$ Verwende Tabelle aus dem 1. Ansatz, denn $\mu_3(k) = \mathbb{P}(A_k^{(1)})$:

k	2	3	4	5	6	7	8	9	10	11	12
$\mu_3(k)$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{5}{36}$	$\frac{6}{36}$	$\frac{5}{36}$	$\frac{4}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{1}{36}$

Kommentar 1.10 Man hat beim Modellieren immer die Wahl. Und man muss aufpassen wie man es macht.

Beispiel 1.6 Reißzwecke “würfeln” - Symmetrieüberlegungen helfen nicht (2025)

$\Omega = \{R, S\}$ (R auf Kopf, S auf Seite)

Definition: $\mu(S) > \mu(R)$

10.000 Würfe; 4213 R

Möchte $\mu(R) \approx \frac{4213}{10.000} = 0,4213$ (relative Häufigkeit)

-> Gesetz der gr. Zahlen

-> Statistik

Kommentar 1.11 Take-Home message: Wann immer möglich, modelliere so, dass $\mu(\omega) = \text{const} \forall \omega \in \Omega$ (erfordert Symmetrieargumente)

Karteikarte 1.14 Was ist die Take-Home-Message beim Modellieren von μ ?

Wann immer möglich, modelliere so, dass $\mu(\omega) = \text{const} \forall \omega \in \Omega$ gilt (Gleichverteilung). Dies erfordert Symmetrieargumente..

1.2 | Gleichverteilung auf einer endlichen Menge

(2025)

Definition 1.6 Gleichverteilung (2025)

Sei $\Omega \neq \emptyset$ eine endl. Menge, d.h. $0 < \#\Omega < \infty$. Gilt $\mu(\omega) = \mu(\tilde{\omega}) \quad \forall \omega, \tilde{\omega} \in \Omega$ d.h. die Wahrscheinlichkeitsfunktion μ ist konstant, so heißen die wfkt μ und das zugehörige Maß P die Gleichverteilung auf Ω

Lemma 1.2 Rechnen mit der Gleichverteilung (2026)

Sei μ die Gleichverteilung auf Ω . Dann gelten:

$$(a) \mu(\omega) = \frac{1}{\#\Omega} \quad \forall \omega \in \Omega$$

$$(b) \mathbb{P}(A) = \frac{\#A}{\#\Omega} \quad \forall A \in \mathcal{P}(\Omega) \quad (\forall A \subseteq \Omega)$$

Beweis.

$$(a) 1 = \sum_{\omega \in \Omega} \mu(\omega) \stackrel{a)}{=} c \cdot \#\Omega \Rightarrow c = \frac{1}{\#\Omega}$$

$$(b) \mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega) \stackrel{a)}{=} \frac{\#A}{\#\Omega}$$

$\mathbb{P}(A)$ ist die Anzahl der günstigen Ausgänge, geteilt durch die Anzahl aller möglichen Ausgänge

^aWir dürfen annehmen, dass ein $c \in [0, 1]$ existiert mit $\mu(\omega) = c \quad \forall \omega \in \Omega$

Bemerkung 1.5 (2025) Im Fall der Gleichverteilung reduziert sich das Berechnen von WS auf Abzählprobleme.

Bemerkung 1.6 Keine Gleichverteilung, wenn der Ereignisraum nicht endlich ist (Skript 26 - Bemerkung 1.18)

Warum müssen wir voraussetzen, dass $\#\Omega < \infty$? Nehmen wir an, es gäbe eine Gleichverteilung μ auf einer abzählbar unendlichen Menge Ω . Wir können der Einfachheit halber annehmen, dass Ω die Menge der natürlichen Zahlen $\mathbb{N}$ ist. Dann gibt es also ein $c \in [0, 1]$ mit

$$1 = \sum_{k=1}^{\infty} \mu(k) = c \cdot \#\mathbb{N}$$

Nun gibt es zwei Fälle. Entweder, $c = 0$. Dann erhalten wir den Widerspruch $1 = 0$. Andernfalls, wenn $c > 0$ gilt, erhalten wir ebenfalls einen Widerspruch, nämlich $1 = \infty$. Folglich kann es auf einer nicht endlichen Menge keine Gleichverteilung geben

Beispiel 1.7 Gleichverteilung

- $1 \times$ Werfen einer fairen Münze: $\Omega = \{K, Z\}, \mu(\omega) = \frac{1}{2} \forall \omega \in \Omega$
- $1 \times$ Würfeln oder $2 \times$ Würfeln mit fairem Würfel

Beispiel 1.8 KEINE Gleichverteilung (2026)

- Augensumme beim wiederholten Würfeln
- Werfen einer Reißzwecke

Karteikarte 1.15 Wann heißt μ Gleichverteilung auf Ω ?

Sei $\Omega \neq \emptyset$ endlich, d.h. $0 < \#\Omega < \infty$. Gilt $\mu(\omega) = \mu(\tilde{\omega})$ für alle $\omega, \tilde{\omega} \in \Omega$ (d.h. μ ist konstant), so heißen μ und das zugehörige P die Gleichverteilung auf Ω .

Karteikarte 1.16 Wie berechnet man $\mu(\omega)$ und $P(A)$ bei Gleichverteilung?

(a) $\mu(\omega) = \frac{1}{\#\Omega}$ für alle $\omega \in \Omega$. (b) $P(A) = \frac{\#A}{\#\Omega}$ für alle $A \subseteq \Omega$. Anschaulich: Anzahl der günstigen Ausgänge geteilt durch Anzahl aller möglichen Ausgänge..

Karteikarte 1.17 Wie beweist man $\mu(\omega) = \frac{1}{\#\Omega}$ bei Gleichverteilung?

Da μ konstant ist, existiert ein $c \in [0, 1]$ mit $\mu(\omega) = c$ für alle ω . Aus der Normierung folgt $1 = \sum_{\omega \in \Omega} \mu(\omega) = c \cdot \#\Omega$, also $c = \frac{1}{\#\Omega}$.

Karteikarte 1.18 Worauf reduziert sich das Berechnen von Wahrscheinlichkeiten bei Gleichverteilung?

Auf reine Abzählprobleme (Kombinatorik), da $P(A) = \frac{\#A}{\#\Omega}$ gilt..

Karteikarte 1.19 Warum kann es keine Gleichverteilung auf einer abzählbar unendlichen Menge geben?

Annahme: Gleichverteilung μ auf $\Omega = \mathbb{N}$ mit Wert c . Aus $1 = \sum_{k=1}^{\infty} \mu(k) = c \cdot \#\mathbb{N}$ folgt ein Widerspruch: Für $c = 0$ ergibt sich $1 = 0$, für $c > 0$ ergibt sich $1 = \infty$. Beide Fälle sind unmöglich, also existiert keine Gleichverteilung auf unendlichen Mengen. Deshalb ist in der Definition $\#\Omega < \infty$ vorausgesetzt..

Vorlesung 25.04.2025 (V02 2025), ergänzt mit dem Skript aus 2026

Lernziele

- Unterschied zwischen disjunkten und paarweise disjunkten Mengen
- Rechenregeln für Wahrscheinlichkeiten
 - Komplementär Wahrscheinlichkeit
 - Ein- und Ausschlussprinzip
 - Spezialfall paarweise disjunkter Mengen

1.3 | Wahrscheinlichkeitsräume, deren Ereignisraum nicht abzählbar ist

Beispiel 1.9 Wahrscheinlichkeitsraum (2025)

Stoppen einer Zeit bis zu einer Stunde in ms.

$$\begin{aligned} \Omega &= \{0, 1, \dots, 360000\} && \text{(Zeit in ms)} \\ \mu(\omega) &:= \frac{1}{\#\Omega} \quad \forall \omega \in \Omega && \text{(Gleichverteilung)} \\ \mathbb{P}(A) &= \frac{\#A}{\#\Omega} \\ A &= \{600000, \dots, 9000000\} && \text{Zeit liegt zw. 10 und 15 Minuten} \\ \mathbb{P}(A) &= \frac{300001}{3600001} \approx \frac{300000}{3600000} = \frac{1}{12} \end{aligned}$$

Wir wollen kontinuierlich modellieren:

$$\begin{aligned}\tilde{\Omega} &= [0, 60] && \text{(in Minuten)} \\ \text{bzw. } \tilde{\Omega} &= [0, 360000] && \text{(in ms)} \\ \tilde{A} &= [10, 15] \\ \tilde{\mathbb{P}}(\tilde{A}) &\stackrel{!}{=} \frac{15 - 10}{60 - 0} = \frac{5}{60} = \frac{1}{12}\end{aligned}$$

Um auch modellieren zu können, dass Intervalle **WS** haben, die nicht **iwas** von ihrer Länge abgängen, arbeiten wir mit R-Integralen. **R-Integral**?

Kommentar 1.12 TODO: Was genau ist $\tilde{\Omega}$?

1.3.1 | Eindimensionale Dichten

Definition 1.7 **Eindimensionale Dichte** (2025, Skript 26 - Definition 1.22)

Eine Funktion $f : \mathbb{R} \rightarrow [0, \infty)$, die (uneigentlich) Riemann-integrierbar ist, heißt Dichte, sofern

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

Bemerkung 1.7 **Zu Definition 1.7** (Skript 26 - Bemerkung 1.23)

Dichten sind nichtnegativ: Die Definition einer **Dichte** f beinhaltet die Forderung $f \leq 0$, das heißt, es muss

$$f(x) \geq 0 \forall x \in \mathbb{R}$$

gelten.

Die folgende Bemerkung erinnert uns wohl an die für den Zweck dieser Vorlesung wichtigsten Aussagen über die Existenz von Riemann-Integralen.

Bemerkung 1.8 Zu Definition 1.7 (2025, Skript 26 - Bemerkung 1.24)**Riemann-Integrierbarkeit**

■

- f monoton oder f stetig $\Rightarrow \int_a^b f(x)dx$ existiert für alle $(a, b \in \mathbb{R})$ auch: für $-\infty < a < b < \infty$
- f stückweise stetig oder stückweise monoton, $\Rightarrow \int_a^b f(x)dx$ existiert $(a, b \in \mathbb{R})$ auch: für $-\infty < a < b < \infty$
- $f \geq 0$: f Riemann-integrierbar $\Leftrightarrow \lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx < \infty$
 - Damit ist gemeint: Ist $f \geq 0$, so ist f genau dann uneigentlich Riemann-integrierbar über $\mathbb{R}$, wenn das Riemann-Integral $\int_a^b f(x)dx$ für jede Wahl $-\infty < a < b < \infty$ existiert und $\lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx$ existiert. In diesem Fall gilt $\int_{-\infty}^{\infty} f(x)dx = \lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx$
- f ist uneigentlich Riemann-integrierbar über $\mathbb{R}$, gdw. sowohl $(-\infty, 0]$ als auch $[0, \infty)$ uneigentlich Riemann-integrierbar ist.
- f ist genau dann uneigentlich Riemann-integrierbar über $[0, \infty)$, wenn f über jedes Intervall $[0, b]$ Riemann-integrierbar ist und $\lim_{b \rightarrow \infty} \int_0^b f(x)dx$ existiert. In diesem Fall schreiben wir

$$\int_0^{\infty} f(x)dx = \lim_{b \rightarrow \infty} \int_0^b f(x)dx$$

- Analog: f ist genau dann uneigentlich Riemann-integrierbar über $(-\infty, 0]$, wenn f über jedes Intervall $[a, 0]$ Riemann-integrierbar ist und $\lim_{a \rightarrow -\infty} \int_a^0 f(x)dx$ existiert. In diesem Fall schreiben wir

$$\int_{-\infty}^0 f(x)dx = \lim_{a \rightarrow -\infty} \int_a^0 f(x)dx$$

Karteikarte 1.20 Was ist eine (eindimensionale) Dichte?

Eine Funktion $f : \mathbb{R} \rightarrow [0, \infty)$, die (uneigentlich) Riemann-integrierbar ist, heißt Dichte, sofern $\int_{-\infty}^{\infty} f(x)dx = 1$ (Normierungsbedingung)..

Karteikarte 1.21 Welche Vorzeichenbedingung erfüllt eine Dichte f ?

Dichten sind nichtnegativ: $f(x) \geq 0$ für alle $x \in \mathbb{R}$.

Karteikarte 1.22 Welche hinreichenden Kriterien für Riemann-Integrierbarkeit von f auf $[a, b]$ kennst du?

$\int_a^b f(x)dx$ existiert für $-\infty < a < b < \infty$, wenn f monoton ODER stetig ist, oder wenn f stückweise stetig ODER stückweise monoton ist..

Karteikarte 1.23 Wann ist eine nichtnegative Funktion $f \geq 0$ uneigentlich Riemann-integrierbar über $\mathbb{R}$?

Genau dann, wenn $\lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx < \infty$ existiert (und $\int_a^b f(x)dx$ für jede Wahl $-\infty < a < b < \infty$ existiert). In diesem Fall gilt $\int_{-\infty}^{\infty} f(x)dx = \lim_{N \rightarrow \infty} \int_{-N}^N f(x)dx$.

Karteikarte 1.24 Wie zerlegt man die uneigentliche Riemann-Integrierbarkeit von f über $\mathbb{R}$?

f ist uneigentlich Riemann-integrierbar über $\mathbb{R}$ genau dann, wenn sowohl $(-\infty, 0]$ als auch $[0, \infty)$ uneigentlich

Riemann-integrierbar sind. Für $[0, \infty)$: f integrierbar über jedes $[0, b]$ und $\lim_{b \rightarrow \infty} \int_0^b f(x) dx$ existiert; man schreibt dann $\int_0^\infty f(x) dx := \lim_{b \rightarrow \infty} \int_0^b f(x) dx$. Analog für $(-\infty, 0]$ mit $\lim_{a \rightarrow -\infty} \int_a^0 f(x) dx$.

1.3.2 | Wahrscheinlichkeitsräume mit Dichten

Definition 1.8 Wahrscheinlichkeitsräume mit Dichten (2025, Skript 26 - Definition 1.25)

Sei eine Dichte $f \geq 0$ gegeben (also $f : \mathbb{R} \rightarrow [0, \infty)$). Wir setzen

$$\begin{aligned}\mathbb{P}([a, b]) &:= \int_a^b f(x) dx && \text{für alle } -\infty < a < b < \infty \\ \mathbb{P}([-\infty, b]) &:= \int_{-\infty}^b f(x) dx \\ \mathbb{P}([a, \infty]) &:= \int_a^\infty f(x) dx \\ \mathbb{P}\left(\bigcup_{i \in I} [a_i, b_i]\right) &:= \sum_{i \in I} \int_{a_i}^{b_i} f(x) dx && \text{für } I \subseteq \mathbb{N} \text{ (abzählbar) und } a_i < b_i \leq a_{i+1}^*\end{aligned}$$

Falls

$$a_1 = -\infty : (-\infty, b_1] \quad ; \quad b = +\infty : [a, \infty)$$

* Auch geschrieben als: Seien $I \subseteq \mathbb{N}$ eine abzählbare Indexmenge und $[a_i, b_i]$ Intervalle mit $a_i \leq b_i \leq a_{i+1} \leq b_{i+1}$ für alle $i, i+1 \in I$.

Beispiel 1.10 (2025) fehlt

Kommentar 1.13 Zu Definition 1.8 Die Definition von $\mathbb{P}$ auf einer abzählbaren Vereinigung disjunkter, aufsteigend geordneter Intervalle $[a_i, b_i]$ ist additiv über die Dichte f definiert. Uneigentliche Randintervalle ($a_1 = -\infty$ bzw. $b_{\max} = +\infty$) werden gesondert als Halboffene Intervalle behandelt. Eine alternative, schwächere Formulierung erlaubt statt $a_i < b_i$ auch $a_i \leq b_i$, wodurch entartete (einpunktige) Intervalle zugelassen werden; da diese jeweils das Maß 0 besitzen, ändert sich der Wert von $\mathbb{P}$ dadurch nicht.

Bemerkung 1.9 Zu Definition 1.8 (Skript 26 - Bemerkung 1.26)

- Wann immer das Wahrscheinlichkeitsmass $\mathbb{P}$ durch eine eindimensionale Dichte gegeben ist, betrachten wir nur Wahrscheinlichkeiten von Mengen, die wir darstellen können als maximal abzählbar unendliche Vereinigung oder als maximal abzählbar unendlichen Schnitt von Intervallen. Auch können wir wiederum Vereinigungen und Schnitte von derart erhaltenen Mengen betrachten. Diese Prozedur kann beliebig oft wiederholt werden. Trotzdem gibt es Mengen, denen wir keine Wahrscheinlichkeit zuordnen können. Da es nicht ganz einfach ist, derartige - pathologische - Mengen zu konstruieren, bedeutet das für uns keine wesentliche Einschränkung.
- Um ein Zufallsexperiment zu modellieren, in dem nur Elementarereignisse aus einer echten Teilmenge $I \subseteq \mathbb{R}$ angenommen werden können, wählen wir eine Dichte, die außerhalb von I Null ist, das heißt, es soll $f(x) = 0$ für alle $x \notin I$

Lemma 1.3 Wahrscheinlichkeit einelementiger Mengen (Skript 26 - Lemma 1.27)

Ist ein Wahrscheinlichkeitsmass $\mathbb{P}$ durch eine Dichte f gegeben, so gilt

$$\mathbb{P}(\{a\}) = 0 \quad \forall a \in \mathbb{R}$$

Beweis. Skript 26 Seite 11

Korollar 1.1 Dichten sind nicht eindeutig bestimmt (Skript 26 - Korollar 1.28)

Das Wahrscheinlichkeitsmass $\mathbb{P}$ sei durch eine Dichte f gegeben. Sei g eine weitere Dichte, die sich in höchstens abzählbar vielen Punkten von f unterscheidet, das heißt, es gebe eine abzählbare Menge M derart, dass $g(x) = f(x)$ für alle $x \in \mathbb{R} \setminus M$. Dann definiert g dasselbe Wahrscheinlichkeitsmass $\mathbb{P}$ wie f .

Korollar 1.2 Wahrscheinlichkeit von Intervallen (Skript 26 - Korollar 1.29)

Sei $\mathbb{P}$ durch eine Dichte f gegeben. Dann gilt für jede Wahl von $a, b \in \mathbb{R}$ mit $-\infty < a < b < \infty$,

$$\mathbb{P}([a, b]) = \mathbb{P}((a, b]) = \mathbb{P}([a, b)) = \mathbb{P}((a, b))$$

Beispiel 1.11 Messen einer zufälligen Zeit (Skript 26 - Beispiel 1.30)

Wir wählen $\Omega = \mathbb{R}$ und die Dichte

$$f(x) = \begin{cases} \frac{1}{60} & x \in [0, 60] \\ 0 & \text{sonst} \end{cases}$$

Dabei verstehen wir $\omega \in \Omega$ als die gemessene Zeit (in Minuten) bei einer Realisierung des Zufallsexperiments. Die Tatsache, daß $f = 0$ außerhalb von $[0, 60]$ gilt, reflektiert, daß in unserem Experiment nur Zeiten innerhalb einer Stunde ab Start möglich sein sollen.

Wir müssen zeigen, daß f eine Dichte ist

1. $f \geq 0$ gilt per Definition von f
2. f ist stückweise stetig und daher Riemann-integrierbar
3. Die Normierungsbedingung ist erfüllt, weil

$$\int_{-\infty}^{\infty} f(x) dx = \int_0^{60} f(x) dx = \int_0^{60} \frac{1}{60} dx = \frac{60 - 0}{60} = 1$$

Wir sehen, dass, wie zuvor,

$$\mathbb{P}([10, 15]) = \int_{10}^{15} f(x) dx = \int_{10}^{15} \frac{1}{60} dx = \frac{5}{60} = \frac{1}{12}$$

gilt.

Bemerkung 1.10 Vorgehen beim Berechnen von Integralen mit stückweise gegebener Dichte (Skript 26 - Bemerkung 1.31)

Es empfiehlt sich, sukzessive wie in obigem Beispiel vorzugehen:

1. Integral über Intervall aufschreiben
2. Grenzen anpassen, so daß nicht mehr über Intervalle integriert wird, auf denen $f = 0$ gilt
3. Konkrete Form von f einsetzen
4. Integral ausrechnen

Genauer

1. Integral über Intervall aufschreiben:

- $\int_{-\infty}^{\infty} f(x) dx$, um zu verifizieren, daß f die Normierungsbedingung erfüllt
- $\mathbb{P}([a, b]) = \int_{-\infty}^{\infty} f(x) dx$, um eine Wahrscheinlichkeit zu berechnen

2. Grenzen anpassen, so daß nicht mehr über Intervalle integriert wird, auf denen $f = 0$ gilt:

- $\int_{-\infty}^{\infty} f(x) dx = \int_0^{60} f(x) dx$
- $\mathbb{P}([50, 70]) = \int_{50}^{70} f(x) dx = \int_{50}^{60} f(x) dx$

3. Konkrete Form von f einsetzen:

- $\mathbb{P}([10, 15]) = \int_{10}^{15} f(x) dx \int_{10}^{15} \frac{1}{60} dx$
- $\mathbb{P}([50, 70]) = \int_{50}^{70} f(x) dx = \int_{50}^{60} f(x) dx = \int_{50}^{60} \frac{1}{60} dx$

4. Integral ausrechnen:

- $\mathbb{P}([10, 15]) = \int_{10}^{15} f(x) dx \int_{10}^{15} \frac{1}{60} dx = 1$
- $\mathbb{P}([50, 70]) = \int_{50}^{70} f(x) dx = \int_{50}^{60} f(x) dx = \int_{50}^{60} \frac{1}{60} dx = \frac{1}{6}$

Bemerkung 1.11 (Skript 26) Falls f durch eine Fallunterscheidung mit mehr Fällen als in unserem Beispiel gegeben ist, so muss im dritten Schritt das Integral entsprechend aufgespalten werden,

$$\int_a^d f(x) dx = \int_a^b f(x) dx + \int_b^c f(x) dx + \int_c^d f(x) dx$$

Für $a < b < c < d$, bevor die konkrete Form von f eingesetzt wird.

Losgelöst von der Idee, daß wir eine zufällige Zeit messen wollen, können wir ganz allgemein für ein beliebiges beschränktes Intervall I eine Dichte definieren derart, daß die Wahrscheinlichkeit, daß der Ausgang des entsprechenden Zufallsexperiments in einem Teilintervall $J \subseteq I$ liegt, weiterhin nur von der Länge des entsprechenden Teilintervalls J abhängt

Karteikarte 1.25 Wie definiert man P auf Intervallen, wenn eine Dichte $f \geq 0$ gegeben ist?

$P([a, b]) := \int_a^b f(x) dx$ für $-\infty < a < b < \infty$; $P([-\infty, b]) := \int_{-\infty}^b f(x) dx$; $P([a, \infty]) := \int_a^{\infty} f(x) dx$. Für abzählbare, aufsteigend geordnete disjunkte Intervalle $[a_i, b_i]$, $i \in I \subseteq \mathbb{N}$: $P(\bigcup_{i \in I} [a_i, b_i]) := \sum_{i \in I} \int_{a_i}^{b_i} f(x) dx$.

Karteikarte 1.26 Welche Mengen können bei einem Wahrscheinlichkeitsraum mit Dichte überhaupt eine Wahrscheinlichkeit bekommen?

Nur Mengen, die als maximal abzählbar unendliche Vereinigung oder Schnitt von Intervallen darstellbar sind (auch wiederholt kombiniert). Es gibt zwar pathologische Mengen ohne zugeordnete Wahrscheinlichkeit, diese sind aber schwer zu konstruieren und für die Praxis irrelevant..

Karteikarte 1.27 Wie modelliert man ein Zufallsexperiment, bei dem nur Werte aus einer Teilmenge $I \subseteq \mathbb{R}$ angenommen werden können?

Man wählt eine Dichte f , die außerhalb von I Null ist, also $f(x) = 0$ für alle $x \notin I$.

Karteikarte 1.28 Welche Wahrscheinlichkeit hat eine einelementige Menge $\{a\}$, wenn P durch eine Dichte gegeben ist?

$P(\{a\}) = 0$ für alle $a \in \mathbb{R}$. (Dichte-Modelle weisen einzelnen Punkten also stets Wahrscheinlichkeit 0 zu, im Gegensatz zu diskreten Modellen.).

Karteikarte 1.29 Sind Dichten, die zu einem gegebenen Wahrscheinlichkeitsmaß gehören, eindeutig bestimmt?

Nein. Unterscheiden sich zwei Dichten f und g nur auf einer höchstens abzählbaren Menge M (d.h. $g(x) = f(x)$ für alle $x \notin M$), so definieren sie dasselbe Wahrscheinlichkeitsmaß P .

Karteikarte 1.30 Spielt es bei einer Dichte eine Rolle, ob ein Intervall offen, halboffen oder abgeschlossen ist?

Nein. Für $-\infty < a < b < \infty$ gilt $P([a, b]) = P((a, b]) = P([a, b)) = P((a, b))$, da einzelne Randpunkte jeweils Wahrscheinlichkeit 0 haben..

Karteikarte 1.31 In welchen 4 Schritten berechnet man Integrale mit stückweise gegebener Dichte?

(1) Integral über das gewünschte Intervall aufschreiben (Normierung oder $P([a, b])$). (2) Grenzen anpassen, sodass nicht mehr über Bereiche integriert wird, auf denen $f = 0$ gilt. (3) Konkrete Form von f einsetzen. (4) Integral ausrechnen. Beispiel: $P([50, 70]) = \int_{50}^{70} f(x)dx = \int_{50}^{60} f(x)dx = \int_{50}^{60} \frac{1}{60}dx = \frac{1}{6}$.

Karteikarte 1.32 Wie geht man vor, wenn die Dichte f durch mehr als zwei Fälle definiert ist?

Das Integral muss vor dem Einsetzen der konkreten Form von f entsprechend aufgespalten werden: $\int_a^d f(x)dx = \int_a^b f(x)dx + \int_b^c f(x)dx + \int_c^d f(x)dx$ für $a < b < c < d$.

1.3.3 | Uniforme Verteilung

Definition 1.9 Uniforme Verteilung auf einem Intervall (Kontinuumsäquivalent zu gleichverteilt) (2025, Skript 26 - Definition 1.32)

Die uniforme Verteilung auf einem beschränkten Intervall $I \subseteq \mathbb{R}$ (äquivalent zu $I = [a, b]$ mit $-\infty < a < b < \infty$) ist gegeben durch eine Dichte

$$f(x) = \begin{cases} \frac{1}{|I|} & x \in I \\ 0 & \text{sonst} \end{cases} = \begin{cases} \frac{1}{b-a} & x \in I \\ 0 & \text{sonst} \end{cases}$$

wobei $|I|$ die Intervalllänge bezeichnet.

Beispiel 1.12 Zu Definition 1.9 txc(Skript 26 - Definition 1.32)

Sei nun $[a, b] = [0, 10]$. Die Wahrscheinlichkeit, daß der Ausgang des Zufallsexperiments sehr klein oder sehr groß

ist, sagen wir entweder kleiner als 0.1 oder größer als 9.9 ist, beträgt

$$\mathbb{P}((-\infty, 0.0) \cup (9.9, \infty)) = \int_0^{0.1} f(x) dx + \int_{9.9}^{10} f(x) dx = \frac{1}{10}[0.1 + 0.1] = \frac{2}{100} = \frac{1}{50}$$

Bemerkung 1.12 Zu Beispiel 1.11 (Skript 26 - Bemerkung 1.33)

Der Wert $\frac{1}{b-a}$ ergibt sich aus der Normierungsbedingung. Daraus ergibt sich, daß es auf einem nicht beschränkten Intervall keine uniforme Verteilung geben kann. Der Beweis verwendet dieselbe Idee wie jene, die wir in Bemerkung 1.6 benutzt haben.

Wir können die Definition der uniformen Verteilung verallgemeinern.

Definition 1.10 Uniforme Verteilung auf einer Menge M (Skript 26 - Definition 1.34)

Sei $M \subseteq \mathbb{R}$ eine Menge, der wir einen Inhalt $|M| = \lambda(M)$ zuordnen können. Ist $|M| < \infty$, so ist die uniforme Verteilung auf M gegeben durch die Dichte

$$f(x) = \begin{cases} \frac{1}{|M|} & x \in M \\ 0 & \text{sonst} \end{cases}$$

Bemerkung 1.13 (Skript 26 - Bemerkung 1.35)

Die uniforme Verteilung auf einer beschränkten Menge $M \subseteq \mathbb{R}$ ist das kontinuierliche Analogon der Gleichverteilung auf einer endlichen Menge. Es gilt

$$\mathbb{P}(A) = \frac{|A \cap M|}{|M|}$$

für alle $A \subseteq \mathbb{R}$, für die der Inhalt $|A|$ definiert ist.

Wartezeiten werden häufig mit Hilfe der Exponentialverteilung modelliert.

Karteikarte 1.33 Was ist die uniforme Verteilung auf einem Intervall $I = [a, b]$ (Kontinuumsäquivalent zur Gleichverteilung)?

Gegeben durch die Dichte $f(x) = \frac{1}{|I|} = \frac{1}{b-a}$ für $x \in I$, sonst 0, wobei $|I|$ die Intervalllänge ist. Voraussetzung: I beschränkt, $-\infty < a < b < \infty$.

Karteikarte 1.34 Warum kann es keine uniforme Verteilung auf einem unbeschränkten Intervall geben?

Der Dichtewert $\frac{1}{b-a}$ ergibt sich aus der Normierungsbedingung $\int f(x) dx = 1$. Bei unbeschränktem Intervall würde dies (analog zum Beweis, dass es keine Gleichverteilung auf unendlichen Mengen gibt) zu einem Widerspruch führen — daher ist eine uniforme Verteilung nur auf beschränkten Intervallen definierbar..

Karteikarte 1.35 Wie verallgemeinert man die uniforme Verteilung von Intervallen auf beliebige Mengen $M \subseteq \mathbb{R}$?

Sei $M \subseteq \mathbb{R}$ eine Menge mit Inhalt $|M| = \lambda(M) < \infty$. Die uniforme Verteilung auf M ist gegeben durch $f(x) = \frac{1}{|M|}$ für $x \in M$, sonst 0..

Karteikarte 1.36 Wie berechnet man bei uniformer Verteilung auf M die Wahrscheinlichkeit eines beliebigen Ereignisses A ?

$P(A) = \frac{|A \cap M|}{|M|}$ für alle $A \subseteq \mathbb{R}$, für die der Inhalt $|A|$ definiert ist. Dies ist das kontinuierliche Analogon zur

Gleichverteilung auf einer endlichen Menge ($P(A) = \frac{\#A}{\#\Omega}$)..

1.3.4 | Exponentialverteilung

Definition 1.11 Exponentialverteilung (2025, Skript 26 - Definition 1.36)

Die Exponentialverteilung zum Parameter $\alpha > 0$ ist gegeben durch die Dichte

$$f(x) = \begin{cases} 0 & \text{für } x < 0 \\ \alpha e^{-\alpha x} & \text{für } x \geq 0 \end{cases} \quad (1.1)$$

Bemerkung 1.14 Zu Definition 1.11 - Die Exponentialverteilung ist wohldefiniert (2025, Skript 26 - Lemma 1.37)

Gleichung 1.1 ist eine Dichte :

■ $f \geq 0$

■ f R-integrierbar, da stückweise stetig

$$\begin{aligned} g(x) &= e^{-\alpha x} \\ g'(x) &= (-\alpha)e^{-\alpha x} \text{ (Produktregel)} \end{aligned}$$

■ ???:

$$\begin{aligned} \int_{-\infty}^{\infty} f(x) dx &= \int_0^{\infty} f(x) dx \\ &= \int_0^{\infty} \alpha e^{-\alpha x} dx \\ &= \lim_{N \rightarrow \infty} \int_0^N \alpha e^{-\alpha x} dx \\ &= \lim_{N \rightarrow \infty} [-e^{-\alpha x} \Big|_{x=0}^N] \\ &= \lim_{N \rightarrow \infty} [-e^{-\alpha N} - \underbrace{(-e^{-\alpha \cdot 0})}_{=1}] \\ &= 1 - \underbrace{\lim_{N \rightarrow \infty} e^{-\alpha N}}_{=1} \\ &= 1 \end{aligned}$$

Rechnen mit Wahrscheinlichkeiten

Vorlesung 25.04.2025 (V02 2025), ergänzt durch Skript 2026

Lernziele

- Unterschied zwischen disjunkten und paarweise disjunkten Mengen kennen
- Rechenregeln für Wahrscheinlichkeiten anwenden und beweisen können, insbesondere
 - Komplementärwahrscheinlichkeit (“Gegenwahrscheinlichkeit”)
 - Ein-und-Ausschlußprinzip
 - Spezialfall: Wahrscheinlichkeit der Vereinigung paarweise disjunkter Mengen

2.1 | Mengenoperationen und Ereignisse

Definition 2.1 Komplement von Mengen (Skript 2026 - Definition 2.1)

Gilt $A \subseteq \Omega$, so schreiben wir A^c für das Komplement von A in Ω , das heißt, wir setzen

$$A^c = \Omega \setminus A$$

Bemerkung 2.1 Zu Definition 2.1 (Skript 2026 - Definition 2.1)



Diese Notation ist mit Vorsicht anzuwenden, da sie voraussetzt, dass klar ist, auf welche Referenz- Obermenge Ω wir uns beziehen.

Definition 2.2 Vereinigung/Schnitt abzählbar vieler Mengen (2025, Skript 2026 - Definition 2.2)


$I \subseteq \mathbb{N}$ Indexmenge.

Für jedes $i \in I$ sei $A_i \subseteq \Omega$:

- $A_i \in \mathcal{R}(\Omega)$ für Ω abzählbar
 - A_i ein Intervall für $\Omega = \mathbb{R}$ (oder $\Omega = [0, \infty)$ oder $\Omega = [a, b]$)
- (a) $\bigcup_{i \in I} A_i = \{\omega \in \Omega : \omega \in A_i \text{ für mind. ein } i \in I\} = \{\omega \in \Omega : \exists j \in I \text{ mit } \omega \in A_j\}$
- (b) $\bigcap_{i \in I} A_i = \{\omega \in \Omega : \omega \in A_i \text{ für alle } i \in I\} = \{\omega \in \Omega : \omega \in A_i \forall j \in I\}$

Lemma 2.1 Rechenregeln für Mengen und Ereignisse (2025, Skript 26 - Lemma 2.3)Seien $A, B, C \subset \Omega$.(a) Transitivität: $A \subset B, B \subset C \Rightarrow A \subset C$ (b) Distributivgesetz: $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$ und $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$

- Kommutativitätsgesetz: $A \cup B = B \cup A$ und $A \cap B = B \cap A$
- Assoziativgesetz: $(A \cup B) \cup C = A \cup (B \cup C)$ und $(A \cap B) \cap C = A \cap (B \cap C)$
- de Morgansche Regeln: $(A \cup B)^c = A^c \cap B^c$ und $(A \cap B)^c = A^c \cup B^c$

Beweis. Skript 26 Seite 20**Karteikarte 2.1** Wie ist das Komplement A^c einer Menge $A \subseteq \Omega$ definiert? $A^c := \Omega \setminus A$. Achtung: Diese Notation setzt voraus, dass klar ist, auf welche Referenz-Obermenge Ω man sich bezieht..**Karteikarte 2.2** Wie sind Vereinigung und Schnitt abzählbar vieler Mengen $A_i, i \in I$, definiert? $\bigcup_{i \in I} A_i = \{\omega \in \Omega : \exists j \in I \text{ mit } \omega \in A_j\}$ (mind. ein A_i enthält ω). $\bigcap_{i \in I} A_i = \{\omega \in \Omega : \omega \in A_i \forall i \in I\}$ (alle A_i enthalten ω)..**Karteikarte 2.3** Welche drei Rechenregeln für Mengen/Ereignisse kennst du (Kommutativ-, Assoziativ-, de Morgan)?Kommutativität: $A \cup B = B \cup A, A \cap B = B \cap A$. Assoziativität: $(A \cup B) \cup C = A \cup (B \cup C)$, analog für $\cap$. De Morgan: $(A \cup B)^c = A^c \cap B^c$ und $(A \cap B)^c = A^c \cup B^c$..**2.1.1 | Disjunktheit****Definition 2.3** $A, B, A_1, A_2, \dots \subset \Omega$ (2025)(a) A und B heißen disjunkt, wenn $A \cap B = \emptyset$ **Abbildung 2.2:** Disunkte Mengen.

Sei I eine beliebige Indexmenge. Für jedes $i \in I$ sei eine Menge $A_i \subseteq \Omega$ gegeben.

(b) $A_1, A_2, \dots$ heißen disjunkt, wenn $\bigcap_i A_i = \emptyset$ (Alle Mengen liegen getrennt voneinander)




Abbildung 2.3: Disjunkte Mengen.

(c) $A_1, A_2, \dots$ heißen paarweise disjunkt, wenn $A_i \cap A_j = \emptyset \quad \forall i, j \text{ mit } i \neq j$




Abbildung 2.4: Disjunkte Mengenfamilie; paarweise disjunkte Mengen.

(d) Sind $A_1, A_2, \dots$ paarweis disjunkt, so schreiben wir $\dot{\bigcup}_i A_i$ für die Vereinigung $\bigcup_i A_i$.

■ Wir sprechen von einer disjunkten Vereinigung

Bemerkung 2.2 (2025)

paarweise disjunkt $\Rightarrow$ disjunkt

$$\bigcup_i A_i \subset A_1 \cap A_2 = \emptyset$$

Beispiel 2.1 Disjunkte und paarweise disjunkte Mengen beim Würfeln (Skript 26 - Beispiel 2.5)

Sei $\Omega = \{1, \dots, 6\}$

- Setze $A = \{2, 4, 6\}$, $B = \{3, 6\}$ und $C = \{1\}$. Dann ist $A \cap B = \{6\} \neq \emptyset$, also sind A und B nicht disjunkt, während $A \cap C = \emptyset$ impliziert, daß A und C disjunkt sind.
- Seien $A_1 = \{1, 3\}$, $A_2 = \{3, 5\}$ und $A_3 = \{1, 5\}$. Dann sind A_1, A_2 und A_3 disjunkt, aber nicht paarweise disjunkt, weil $A_1 \cap A_2 \cap A_3 = \emptyset$, aber $A_1 \cap A_2 = \{3\} \neq \emptyset$.

Lemma 2.2 Relation zwischen den Konzepten “disjunkt” und “paarweise disjunkt” (Skript 26 - Lemma 2.6)

Sei I eine beliebige Indexmenge. Für jedes $i \in I$ sei eine Menge $A_i \subseteq \Omega$ gegeben.

1. paarweise disjunkt $\Rightarrow$ disjunkt:

$$A_i \cap A_j = \emptyset \quad \forall i, j \in I \text{ mit } i \neq j \Rightarrow \bigcap_{i \in I} A_i = \emptyset$$

2. disjunkt $\nRightarrow$ paarweise disjunkt.

Es gibt Beispiele von disjunkten Mengen, die nicht paarweise disjunkt sind.

Beweis. Skript 26 Seite 22

Beispiel 2.2 Disjunkte und paarweise disjunkte Mengen (Skript 26 - Beispiel 2.7) Wir wählen

$$A_1 = \{1, 2, 3, 4, \dots\},$$

$$A_2 = \{2, 3, 4, \dots\},$$

$$A_3 = \{3, 4, \dots\},$$

$$\vdots$$

$$A_k = \{k, k+1, \dots\} = \{j \in \mathbb{N} : j \geq k\}.$$

Die Mengen A_i , $i \in \mathbb{N}$, sind *nicht paarweise disjunkt*:

Für jede Wahl von $i, j \in \mathbb{N}$ mit $i < j$ gilt

$$A_i \cap A_j = A_j \neq \emptyset.$$

Dennoch sind die Mengen A_i , $i \in \mathbb{N}$ *disjunkt*

$$\bigcap_{i \in \mathbb{N}} A_i = \emptyset.$$

Zum Beweis nehmen wir an, es gäbe ein $\ell \in \mathbb{N}$ mit

$$\ell \in \bigcap_{i \in \mathbb{N}} A_i.$$

Dann müsste $\ell \in A_i$ für alle $i \in \mathbb{N}$ gelten. Insbesondere müsste

$$\ell \in A_{\ell+1} = \{\ell+1, \ell+2, \dots\}$$

sein. Dies ist jedoch unmöglich. Also existiert kein solches ℓ , und damit folgt

$$\bigcap_{i \in \mathbb{N}} A_i = \emptyset.$$

Karteikarte 2.4 Wann heißen zwei Mengen A, B disjunkt?

Wenn $A \cap B = \emptyset$ gilt..

Karteikarte 2.5 Wann heißt eine Familie $A_1, A_2, \dots$ (allgemein $A_i, i \in I$) disjunkt?

Wenn der Gesamtschnitt aller Mengen leer ist: $\bigcap_i A_i = \emptyset$. (Es reicht, dass es keinen gemeinsamen Punkt in ALLEN Mengen gibt — einzelne Paare können sich trotzdem überschneiden!).

Karteikarte 2.6 Wann heißt eine Familie $A_1, A_2, \dots$ paarweise disjunkt?

Wenn $A_i \cap A_j = \emptyset$ für alle $i \neq j$ gilt (jedes Paar einzeln betrachtet ist disjunkt). Achtung: In der Quelldefinition steht fälschlich $\neq \emptyset$, korrekt ist aber $= \emptyset$ für paarweise Disjunktheit..

Karteikarte 2.7 Welche Notation verwendet man für die Vereinigung paarweise disjunkter Mengen?

$\dot{\bigcup}_i A_i$ statt $\bigcup_i A_i$, wenn die A_i paarweise disjunkt sind. Man spricht von einer disjunkten Vereinigung..

Karteikarte 2.8 Folgt aus paarweiser Disjunktheit die (einfache) Disjunktheit einer Mengenfamilie?

Ja: paarweise disjunkt $\Rightarrow$ disjunkt, denn $\bigcap_i A_i \subseteq A_1 \cap A_2 = \emptyset$.

Karteikarte 2.9 Beispiel: Sind $A = \{2, 4, 6\}$, $B = \{3, 6\}$, $C = \{1\}$ beim Würfeln disjunkt?

$A \cap B = \{6\} \neq \emptyset \Rightarrow A, B$ NICHT disjunkt. $A \cap C = \emptyset \Rightarrow A, C$ disjunkt. Zweites Beispiel: $A_1 = \{1, 3\}$, $A_2 = \{3, 5\}$, $A_3 = \{1, 5\}$ sind disjunkt ($A_1 \cap A_2 \cap A_3 = \emptyset$), aber NICHT paarweise disjunkt (da z.B. $A_1 \cap A_2 = \{3\} \neq \emptyset$).

Karteikarte 2.10 Gilt auch die Umkehrung: disjunkt $\Rightarrow$ paarweise disjunkt?

Nein. Disjunkt impliziert NICHT paarweise disjunkt — es gibt Gegenbeispiele (siehe $A_k = \{k, k+1, \dots\}$: die Mengen sind disjunkt, aber keine zwei von ihnen sind paarweise disjunkt, da $A_i \cap A_j = A_j \neq \emptyset$ für $i < j$).

Karteikarte 2.11 Beispiel: Warum sind $A_k = \{k, k+1, k+2, \dots\}$ für $k \in \mathbb{N}$ disjunkt, aber nicht paarweise disjunkt?

Nicht paarweise disjunkt: Für $i < j$ gilt $A_i \cap A_j = A_j \neq \emptyset$. Aber disjunkt: $\bigcap_{i \in \mathbb{N}} A_i = \emptyset$, denn gäbe es ein ℓ im Gesamtschnitt, müsste $\ell \in A_{\ell+1} = \{\ell+1, \ell+2, \dots\}$ gelten — unmöglich, da $\ell < \ell+1$.

2.2 | Erste Rechenregeln für Wahrscheinlichkeiten

Satz 2.1 (2025)

Seien $A, B, A_1, A_2, \dots \subset \Omega$ (und Intervalle, falls $\mathbb{P}$ durch Dichte gegeben ist)

(a) Additivität: Seien $A_1, A_2, \dots$ paarweise disjunkt, dann gilt:

$$\mathbb{P}(\dot{\bigcup}_i A_i) = \sum_i \mathbb{P}(A_i)$$

Gilt auch für Dichten!

Beweis.

$$\begin{aligned} \mathbb{P}(\dot{\bigcup}_i A_i) &= \mathbb{P}(\{\omega \in \Omega : \exists i \text{ mit } \omega \in A_i\}) \\ &= \sum_i \underbrace{\sum_{\omega \in A_i} \mu(\omega)}_{\mathbb{P}(A_i)} \\ &= \sum_i \mathbb{P}(A_i) \end{aligned}$$

Wir haben die Summe/Reihe umsortiert

(b) Komplementärwahrscheinlichkeit (“Gegenwahrscheinlichkeit”)

$$\mathbb{P}(A^c) = \mathbb{P}(\Omega \setminus A) = 1 - \mathbb{P}(A)$$

Beweis.

$$\begin{aligned} \Omega = A \dot{\cup} A^c &\stackrel{(a)}{\Rightarrow} 1 \stackrel{\text{Normierung}}{=} \mathbb{P}(\Omega) = \mathbb{P}(A \dot{\cup} A^c) \stackrel{(a)}{=} \mathbb{P}(A) + \mathbb{P}(A^c) \\ &\Rightarrow \mathbb{P}(A^c) = 1 - \mathbb{P}(A) \end{aligned}$$

(c) Monotonie:

$$A \subset B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$$

Beweis

$$\begin{aligned} B &= A \dot{\cup} (B \setminus A) \\ \mathbb{P}(B) &= \mathbb{P}(A) + \underbrace{\mathbb{P}(B \setminus A)}_{\geq 0} \geq \mathbb{P}(A) \end{aligned}$$

(d) $A \subset B \Rightarrow \mathbb{P}(A) = \mathbb{P}(B) - \mathbb{P}(B \setminus A)$

(e) Wahrscheinlichkeit von Vereinigungen:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$$

Beweis.

$$\begin{aligned} A \cup B &= A \dot{\cup} [B \setminus (A \cap B)] \\ \mathbb{P}(A \cup B) &= \mathbb{P}(A) + \underbrace{\mathbb{P}(B \setminus (A \cap B))}_{\stackrel{(d)}{=} \mathbb{P}(B) - \mathbb{P}(A \cap B)} \\ &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \end{aligned}$$

Weitere Beweise Skript 2026 ab Seite 23.

Bemerkung 2.3 (2025)Sind A, B disjunkt, so gilt nach (a): $\mathbb{P}(A \dot{\cup} B) = \mathbb{P}(A) + \mathbb{P}(B)$.Sind A, B nicht disjunkt, so gilt nach (e): $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$.Sind A, B, C paarweise disjunkt, so gilt nach (a): $\mathbb{P}(A \cup B \cup C) \stackrel{(a)}{=} \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C)$.Was passiert, wenn A, B, C nicht paarweise disjunkt sind?

$$\begin{aligned} \mathbb{P}(A \cup B \cup C) &= \mathbb{P}(A \cup (B \cup C)) \\ &= \mathbb{P}(A) \mathbb{P}(B \cup C) - \mathbb{P}(A \cap (B \cup C)) \\ &= \mathbb{P}(A) + [\mathbb{P}(B) + \mathbb{P}(C) - \mathbb{P}(B \cap C)] - \mathbb{P}((A \cap B) \cup (A \cap C)) \\ &= \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) \\ &\quad - \mathbb{P}(A \cap B) - \mathbb{P}(A \cap C) - \mathbb{P}(B \cap C) \\ &\quad + \underbrace{\mathbb{P}((A \cap B) \cap (A \cap C))}_{= A \cap B \cap C} \end{aligned}$$

Mengen

Paare von Mengen

Tripel von Mengen

Karteikarte 2.12 Additivität von P : Wie berechnet man P einer disjunkten Vereinigung $\bigcup_i A_i$?

$P\left(\bigcup_i A_i\right) = \sum_i P(A_i)$, für paarweise disjunkte $A_1, A_2, \dots$. Gilt auch bei durch Dichten gegebenem P . Beweis: Umsortieren der Doppelsumme $\sum_i \sum_{\omega \in A_i} \mu(\omega) = \sum_i P(A_i)$.

Karteikarte 2.13 Wie lautet die Formel für die Komplementärwahrscheinlichkeit (Gegenwahrscheinlichkeit)?

$P(A^c) = P(\Omega \setminus A) = 1 - P(A)$. Beweis: $\Omega = A \dot{\cup} A^c \Rightarrow 1 = P(\Omega) = P(A) + P(A^c) \Rightarrow P(A^c) = 1 - P(A)$ (folgt aus

Additivität)..

Karteikarte 2.14 Monotonie von P : Was folgt aus $A \subseteq B$ für $P(A)$ und $P(B)$?

$A \subseteq B \Rightarrow P(A) \leq P(B)$. Beweis: $B = A \dot{\cup} (B \setminus A) \Rightarrow P(B) = P(A) + \underbrace{P(B \setminus A)}_{\geq 0} \geq P(A)$..

Karteikarte 2.15 Wie berechnet man $P(A)$, wenn $A \subseteq B$ bekannt ist (Formel mit $B \setminus A$)?

$A \subseteq B \Rightarrow P(A) = P(B) - P(B \setminus A)$..

Karteikarte 2.16 Wie lautet die Formel für $P(A \cup B)$ bei nicht notwendig disjunkten A, B ?

$P(A \cup B) = P(A) + P(B) - P(A \cap B)$. Beweis: $A \cup B = A \dot{\cup} [B \setminus (A \cap B)]$, dann Additivität und $P(B \setminus (A \cap B)) = P(B) - P(A \cap B)$ einsetzen..

Karteikarte 2.17 Wie berechnet man $P(A \cup B)$ bzw. $P(A \cup B \cup C)$ je nachdem ob die Mengen (paarweise) disjunkt sind?

A, B disjunkt: $P(A \dot{\cup} B) = P(A) + P(B)$. A, B nicht disjunkt: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$. A, B, C paarweise disjunkt: $P(A \cup B \cup C) = P(A) + P(B) + P(C)$. Allgemein (nicht paarweise disjunkt): siehe Ein- und Ausschlussprinzip für drei Ereignisse..

2.2.1 | Das Ein- und Ausschlußprinzip

Satz 2.2 Ein- und Ausschlußprinzip für drei Ereignisse (Skript 26 - Lemma 2.9)

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) && \text{(Mengen)} \\ &\quad - P(A \cap B) - P(A \cap C) - P(B \cap C) && \text{(Paare von Mengen)} \\ &\quad + P(A \cap B \cap C) && \text{(Tripel von Mengen)} \end{aligned}$$

Beweis.

$$\begin{aligned} P(A \cup B \cup C) &= P((A \cup B) \cup C) \\ &= P(A \cup B) + P(C) - P((A \cup B) \cap C) \\ &= P(A \cup B) + P(C) - P((A \cap C) \cup (B \cap C)) \\ &= P(A) + P(B) - P(A \cap B) + P(C) \\ &\quad - \left[P(A \cap C) + P(B \cap C) - P((A \cap C) \cap (B \cap C)) \right] \\ &= P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) \\ &\quad - P(B \cap C) + P(A \cap B \cap C). \end{aligned}$$

Satz 2.3 Ein- und Ausschlußprinzip für n Ereignisse (2025, Skript 26 - Theorem 2.10)

$$\begin{aligned} &A_2, \dots, A_n \subset \Omega \\ \mathbb{P} \left(\bigcup_{i=1}^n A_i \right) &= \sum_{k=1}^n (-1)^{k+1} \sum_{a \leq i_1 \leq \dots \leq i_k \leq n} \mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}) \end{aligned}$$

Beweis. Die Fälle $n = 2$ und $n = 3$ haben wir bereits behandelt. Der Beweis für beliebiges n kann mit Hilfe vollständiger Induktion geführt werden.

Beispiel 2.3 Werfen einer Sechse bei n -maligem Würfeln (Skript 26 - Beispiel 2.11)

Wie groß ist die Wahrscheinlichkeit, bei n -maligem Würfeln mit einem fairen Würfel mindestens eine Sechse zu werfen?

Siehe Skript 2026 Seite 25

Karteikarte 2.18 Wie lautet das Ein- und Ausschlussprinzip für drei Ereignisse A, B, C ?

$$P(A \cup B \cup C) = \underbrace{P(A) + P(B) + P(C)}_{\text{Mengen}} - \underbrace{P(A \cap B) - P(A \cap C) - P(B \cap C)}_{\text{Paare}} + \underbrace{P(A \cap B \cap C)}_{\text{Tripel}}..$$

Karteikarte 2.19 Wie lautet das allgemeine Ein- und Ausschlussprinzip für n Ereignisse?

$P(\bigcup_{i=1}^n A_i) = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < \dots < i_k \leq n} P(A_{i_1} \cap \dots \cap A_{i_k})$. Man summiert über alle möglichen Schnitte von k Mengen (mit alternierendem Vorzeichen), für $k = 1, \dots, n$. Beweis für allgemeines n : vollständige Induktion (Fälle $n = 2, 3$ als Basis)..

KAPITEL 3

Bedingte Wahrscheinlichkeiten

Vorlesung 02.05.2025 (V03 2025) und Vorlauf Kapitel 6 am 22.05.2026 (V05 2026) und 29 Mai 2026 (V06 2026)

Lernziele

- Definition und Bedeutung bedingter Wahrscheinlichkeiten kennen
- Modellieren von Zufallsexperimenten, wenn diese durch bedingte Wahrscheinlichkeiten beschrieben sind
- Satz von der totalen Wahrscheinlichkeit kennen und anwenden können
- Bayes-Formel kennen und anwenden können

Beispiel 3.1 Wahrscheinlichkeit, eine 6 zu würfeln, wenn wir schon wissen, dass eine gerade Zahl fällt. BILD

Definition 3.1 todo

Bemerkung 3.1 TODO

Kommentar 3.1 Warnung von ihr: Bei Aufgaben zur bedingten WS kommt es sehr auf die Sprache an.

Zusammenhang mit der Unabhängigkeit? Zwei Ereignisse A,B sind unabh. genau dann, wenn die WS der Schnitt auch das produkt der einzelnen WS ist usw. (siehe Anschnitt aus alten Aufzeichnungen)...

Satz 3.1 TODO foto

Beispiel 3.2 Einmaliges Würfeln (2025+2026 zsm.)

Wie wahrscheinlich ist es, daß eine 1 oder eine 6 gewürfelt wurde? Einmaliges Würfeln

Wie wahrscheinlich ist es, dass eine 1 oder eine 6 gewürfelt wurde?

$|\Omega| = \{1, \dots, 6\}$, $\mathbb{P}$ Gleichverteilung, $A = \{1, 6\}$, $\mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{2}{6} = \frac{1}{3}$

Wie wahrscheinlich ist es, dass eine 1 oder eine 6 gewürfelt wurde, wenn wir schon wissen, dass die geworfene Zahl durch 3 teilbar ist?

Was ist “ $\mathbb{P}$ von A, gegeben B” $\mathbb{P}(A | B)$ mit $B = \{3, 6\}$?

Wahrscheinlichkeit von A:

$$\mathbb{P}(A) = \frac{\text{Anz. günstige Ausgänge}}{\text{Anz. mögliche Ausgänge}} = \frac{|A|}{|\Omega|}$$

Wahrscheinlichkeit von A gegeben B:

$$\mathbb{P}(A | B) = \frac{\text{Anz. günstige Ausgänge in } A \cap B}{\text{Anz. mögliche Ausgänge in } B} = \frac{|A \cap B|}{|B|} = \frac{|\{6\}|}{|\{3, 6\}|} = \frac{1}{2}$$

Notation 3.1 (2025+2026 zsm.)

$$|A| = \#A$$

Definition 3.2 Bedingte Wahrscheinlichkeit (B-WS) (2025+2026 zsm.)

Für Ereignisse A und B heißt

$$\mathbb{P}(A | B) = \begin{cases} \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, & \text{falls } \mathbb{P}(B) > 0, \\ 0, & \text{falls } \mathbb{P}(B) = 0, \end{cases}$$

die bedingte Wahrscheinlichkeit von A gegeben B.

Kommentar 3.2 Zu Definition 3.2: Wenn $\mathbb{P}$ durch eine Dichte gegeben ist, muss man die Definition über Integrale interpretieren.

Beobachtung 3.1 (2025+2026 zsm.)

Bei Gleichverteilung gilt

$$\mathbb{P}(A | B) = \frac{\frac{\#|A \cap B|}{\#\Omega}}{\frac{\#|B|}{\#\Omega}} = \frac{|A \cap B|}{|B|}$$

D.h., die bedingte Wahrscheinlichkeit von A gegeben B ist tatsächlich der relative Anteil von A in B.

Frage 3.1 (2025+2026 zsm.)

In obigem Beispiel gilt $\mathbb{P}(A | B) > \mathbb{P}(A)$. Gilt das immer?

Antwort Nein! Sowohl $\mathbb{P}(A_1 | B_1) > \mathbb{P}(A_1)$ als auch $\mathbb{P}(A_2 | B_2) < \mathbb{P}(A_2)$ sind möglich.

Beispiel 3.3 (2025+2026 zsm.)

$\Omega = \{1, \dots, 6\}$ mit Gleichverteilung $\mathbb{P}$

$$A_1 = \{1, 6\}, \quad A_2 = \{1, 2, 3, 4\}, \quad B = B_1 = B_2 = \{3, 6\}$$

Dann gelten

$$\mathbb{P}(A_1 | B) = \frac{|A_1 \cap B|}{|B|} = \frac{1}{2} > \frac{1}{3} = \mathbb{P}(A_1)$$

$$\mathbb{P}(A_2 | B) = \frac{|A_2 \cap B|}{|B|} = \frac{1}{2} < \frac{2}{3} = \mathbb{P}(A_2)$$

Beispiel 3.4 Beispiel: Zweifacher Wurf einer fairen Münze (2025+2026 zsm.)

$\Omega = \{KK, KZ, ZK, ZZ\}$ mit Gleichverteilung $\mathbb{P}$

Jemand wirft die Münze zweimal und sagt uns nur, dass dabei mindestens einmal Zahl gefallen ist.

Wie groß ist die Wahrscheinlichkeit, dass zweimal Zahl gefallen ist?

Antwort: $A = \{ZZ\}, \quad B = \{KZ, ZK, ZZ\}$

$$\mathbb{P}(A | B) = \frac{|A \cap B|}{|B|} = \frac{1}{3}$$

Frage 3.2 (2025+2026 zsm.)

Jemand wirft die Münze zweimal und sagt uns nur, dass beim ersten Wurf Zahl gefallen ist.

Wie groß ist die Wahrscheinlichkeit, dass zweimal Zahl gefallen ist?

$$A = \{ZZ\}, \quad C = \{ZK, ZZ\}$$

$$\mathbb{P}(A | C) = \frac{|A \cap C|}{|C|} = \frac{1}{2}$$

Regel 3.1 Rechenregeln für bedingte Wahrscheinlichkeiten (diskreter Fall - analog für Fall einer Dichte) (2025+2026 zsm.)

Für ein festes Ereignis B mit $\mathbb{P}(B) > 0$ definiert

$$\mu_B(\omega) = \mathbb{P}(\{\omega\} | B) = \begin{cases} \frac{\mathbb{P}(\{\omega\})}{\mathbb{P}(B)} = \frac{\mu(\{\omega\})}{\mathbb{P}(B)}, & \text{falls } \omega \in B, \\ 0, & \text{falls } \omega \notin B, \end{cases}$$

eine Wahrscheinlichkeitsfunktion, und es gilt

$$\sum_{\omega \in A} \mu_B(\omega) = \frac{1}{\mathbb{P}(B)} = \sum_{\omega \in A \cap B} \mu(\omega) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \mathbb{P}(A | B)$$

für alle $A \subseteq \Omega$.

Die Abbildung $A \mapsto \mathbb{P}(A | B)$ ist also ein Wahrscheinlichkeitsmaß.

Es gelten also alle bekannten Rechenregeln für Wahrscheinlichkeiten, z.B.

$$\mathbb{P}(A^c | B) = 1 - \mathbb{P}(A | B)$$

oder

$$\mathbb{P}(A_1 \cup^+ A_2 | B) = \mathbb{P}(A_1 | B) + \mathbb{P}(A_2 | B)$$

(Achtung: nur für disjunkte Ereignisse.)

Achtung! Die Abbildung $B \mapsto \mathbb{P}(A | B)$ ist kein Wahrscheinlichkeitsmaß!

(Beweisen Sie dies selbständig, indem Sie z.B. Beispiele finden mit $\mathbb{P}(A | B) \neq 1 - \mathbb{P}(A | B^c)$ oder $\mathbb{P}(A | B_1 \cup B_2) \neq \mathbb{P}(A | B_1) + \mathbb{P}(A | B_2)$.)

Beispiel 3.5 Gedächtnislosigkeit der Exponentialverteilung (2025+2026 zsm.)

Parameter $z > 0$; Dichte :

$$f(x) = \begin{cases} ze^{-zx}, & x \geq 0 \\ 0, & \text{sonst} \end{cases}$$

$$\mathbb{P}(I) = \int_a^b f(x) dx \text{ für } I = (a, b] \subset [0, \infty)$$

Warteschleife beim Kundenservice als Exponentialverteilung

- Sie haben schon 10 Min gewartet ($t = 10$)
- **WS**, dass Sie noch **mindestens** weitere 10 Minuten warten?
($T = t + 10 = 20$)

Gesucht: $\mathbb{P}([T, a] | [t, \infty))$

$$\mathbb{P}([T, a] | [t, \infty)) = \frac{\mathbb{P}([T, a]) \cap \mathbb{P}([t, \infty))}{\mathbb{P}([t, \infty))} = \frac{\mathbb{P}([T, \infty))}{\mathbb{P}([t, \infty))}$$

Nebenrechnung:

$$\begin{aligned}\mathbb{P}([\tau, \infty)) &= \int_{\tau}^{\infty} z e^{-zx} dx \\ &= \lim_{N \rightarrow \infty} \int_{\tau}^{\infty} z e^{-zx} dx \\ &= \lim_{N \rightarrow \infty} (-e^{-zx}) \Big|_{x=\tau}^N \\ &= \lim_{N \rightarrow \infty} [\underbrace{-e^{-zN}}_{\rightarrow_{N \rightarrow \infty} 0} + e^{-z\tau}] \\ &= e^{-z\tau}\end{aligned}$$

Zurück zur Hauptrechnung:

$$\begin{aligned}\mathbb{P}([T, a] | [t, \infty)) &= \frac{\mathbb{P}([T, \infty))}{\mathbb{P}([t, \infty))} \\ &\stackrel{NR}{=} \frac{e^{-zT}}{e^{-zt}} \\ &= e^{-z(T-t)} \\ &\stackrel{T=10+t}{=} e^{-zt} \\ &\stackrel{NR}{=} \mathbb{P}([t, \infty))\end{aligned}$$

Regel 3.2 Neue Rechenregel: Sukzessives Bedingen (2025+2026 zsm.)

Aus der Definition der bedingten Wahrscheinlichkeit folgt

$$\mathbb{P}(A \cap B) = \mathbb{P}(A | B) \mathbb{P}(B) \quad \forall A, B \subseteq \Omega.$$

Da Multiplikation mit Null wieder Null ergibt, gilt diese Formel auch im Fall $\mathbb{P}(B) = 0$.

$$\mathbb{P}(B) = 0 \Rightarrow \mathbb{P}(A \cap B) \leq \mathbb{P}(B) = 0 \Rightarrow \mathbb{P}(A \cap B) = 0$$

Wiederholtes Anwenden zeigt

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_3 | A_1 \cap A_2) \mathbb{P}(A_1 \cap A_2)$$

und damit

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_3 | A_1 \cap A_2) \mathbb{P}(A_2 | A_1) \mathbb{P}(A_1)$$

für alle $A_1, A_2, A_3 \subseteq \Omega$.

Mit vollständiger Induktion beweist man die allgemeine Formel

$$\mathbb{P}(A_1 \cap A_2 \cap \dots \cap A_n) = \mathbb{P}(A_n | A_1 \cap \dots \cap A_{n-1}) \dots \mathbb{P}(A_2 | A_1) \mathbb{P}(A_1)$$

für alle $A_1, \dots, A_n \subseteq \Omega$.

Beispiel 3.6 Wie wahrscheinlich ist es, dass beim Skat jeder der drei Spieler genau ein As hat? (2025+2026 zsm.)

Modell

$$\Omega = \left\{ (S_1, S_2, S_3) : S_i \subseteq \{1, \dots, 32\}, |S_i| = 10 \forall i \in \{1, 2, 3\}, S_i \cap S_j = \emptyset \text{ für } i \neq j \right\}.$$

$(S_1, S_2, S_3) \in \Omega$ bedeute:

■ Spieler i erhält die 10 Karten S_i , $i \in \{1, 2, 3\}$.

■ Die übrigen 2 Karten

$$\{1, \dots, 32\} \setminus (S_1 \cup S_2 \cup S_3)$$

liegen im Skat.

■ Die vier Asse seien die Karten mit den Nummern 1, 2, 3, 4.

■ Gleichverteilung:

$$\mu(\omega) = \frac{1}{|\Omega|} = \frac{1}{\binom{32}{10} \binom{22}{10} \binom{12}{10}} \quad \forall \omega \in \Omega.$$

Rechnung Beispiel: Wie wahrscheinlich ist es, dass beim Skat alle genau ein As haben?

$$A_i = \{ |S_i \cap \{1, 2, 3, 4\}| = 1 \}, \quad i = 1, 2, 3$$

(Spieler i hat genau ein As)

$$A = A_1 \cap A_2 \cap A_3$$

(Jeder Spieler hat genau ein As)

$$\mathbb{P}(A) = \mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_1) \mathbb{P}(A_2 | A_1) \mathbb{P}(A_3 | A_1 \cap A_2) = \mathbb{P}(A_3 | A_1 \cap A_2) \mathbb{P}(A_2 | A_1) \mathbb{P}(A_1)$$

$$\mathbb{P}(A_1) = \frac{|A_1|}{|\Omega|} = \frac{\binom{4}{1} \binom{28}{9} \binom{22}{10} \binom{12}{10}}{\binom{32}{10} \binom{22}{10} \binom{12}{10}} = \frac{\binom{4}{1} \binom{28}{9}}{\binom{32}{10}}$$

$$\mathbb{P}(A_2 | A_1) = \frac{|A_1 \cap A_2|}{|A_1|} = \frac{\binom{4}{1} \binom{28}{9} \binom{3}{1} \binom{19}{9} \binom{12}{10}}{\binom{4}{1} \binom{28}{9} \binom{22}{10} \binom{12}{10}} = \frac{\binom{3}{1} \binom{19}{9}}{\binom{22}{10}}$$

$$\mathbb{P}(A_3 | A_1 \cap A_2) = \frac{|A_1 \cap A_2 \cap A_3|}{|A_1 \cap A_2|} = \dots = \frac{\binom{2}{1} \binom{10}{9}}{\binom{12}{10}}$$

Somit

$$\mathbb{P}(A) = \frac{\binom{4}{1} \binom{28}{9}}{\binom{32}{10}} \cdot \frac{\binom{3}{1} \binom{19}{9}}{\binom{22}{10}} \cdot \frac{\binom{2}{1} \binom{10}{9}}{\binom{12}{10}}$$

$$\mathbb{P}(A) \approx 0.056.$$

Definition 3.3 Formel von der totalen Wahrscheinlichkeit (2025+2026 zsm.)

Sei $(\Omega, \mathbb{P})$ ein Wahrscheinlichkeitsraum und (abzählbar viele B_i) $B_1, B_2, \dots \subseteq \Omega$ paarweise disjunkte Ereignisse mit

$$\bigcup_i^+ B_i = \Omega.$$

Dann gilt

$$\mathbb{P}(A) = \sum_i \mathbb{P}(A \mid B_i) \mathbb{P}(B_i)$$

für alle Ereignisse $A \subseteq \Omega$.

Hinweis: $B_1, B_2, \dots$ ist eine Partition von Ω

Beweis (im einfachsten Fall). Für

$$\Omega = B_1 \cup^+ B_2, \quad B_1 \cap B_2 = \emptyset$$

(also $B_1 = B$ und $B_2 = B^c$) gilt

$$A = A \cap (B_1 \cup^+ B_2) = (A \cap B_1) \cup^+ (A \cap B_2).$$

Da die Ereignisse $A \cap B_1$ und $A \cap B_2$ disjunkt sind, folgt (über Rechenregeln für Wahrscheinlichkeiten)

$$\mathbb{P}(A) = \mathbb{P}(A \cap B_1) + \mathbb{P}(A \cap B_2) \quad (1)$$

und mit der Definition der bedingten Wahrscheinlichkeit

$$\mathbb{P}(A \cap B_i) = \mathbb{P}(A \mid B_i) \mathbb{P}(B_i), \quad i = 1, 2. \quad (2)$$

Einsetzen von (2) in (1) ergibt

$$\mathbb{P}(A) = \mathbb{P}(A \mid B_1) \mathbb{P}(B_1) + \mathbb{P}(A \mid B_2) \mathbb{P}(B_2).$$

Der allgemeine Fall geht vollkommen analog und verbleibt als Hausaufgabe.

Beispiel 3.7 Herr Zimmerlich und sein Regenschirm (2025+2026 zsm.)

Herr Zimmerlich hasst es, nass zu werden. Wenn der Wetterbericht Regen ankündigt, nimmt er seinen Schirm mit einer Wahrscheinlichkeit von 90% mit. (Die fehlenden 10% sind seiner Vergesslichkeit geschuldet.)

Auch wenn der Wetterbericht einen trockenen Tag verheißt, nimmt Herr Zimmerlich mit einer Wahrscheinlichkeit von 30% trotzdem seinen Schirm mit.

Dem feuchten Bielefelder Klima gemäß nehmen wir an, dass für 60% aller Tage Regen vorhergesagt wird.

Frage: Wie groß ist die Wahrscheinlichkeit, dass Herr Zimmerlich das Haus ohne Schirm verlässt?

Modellierung

$$\Omega = \{r, \bar{r}\} \times \{s, \bar{s}\} = \{(r, s), (\bar{r}, s), (r, \bar{s}), (\bar{r}, \bar{s})\}$$

Dabei sei $(r, \bar{s})$ das Elementarereignis, dass Regen vorhergesagt wurde und Herr Zimmerlich keinen Schirm mitnimmt, usw.

$$R = \{(r, s), (\bar{r}, s)\} \quad (\text{Regen vorhergesagt})$$

$$S = \{(r, s), (\bar{r}, s)\} \quad (\text{Schirm dabei})$$

$$\mathbb{P}(S \mid R) = \frac{9}{10}, \quad \mathbb{P}(S \mid R^c) = \frac{3}{10}, \quad \mathbb{P}(R) = \frac{6}{10}.$$

Gesucht:

$$\mathbb{P}(S^c).$$

Problem: Wie können wir diese „absolute“ Wahrscheinlichkeit aus den bedingten Wahrscheinlichkeiten bestimmen?

Lösung: Die Formel der totalen Wahrscheinlichkeit mit

$$\Omega = R \cup R^c$$

zeigt:

$$\mathbb{P}(S^c) = \mathbb{P}(S^c \mid R) \mathbb{P}(R) + \mathbb{P}(S^c \mid R^c) \mathbb{P}(R^c).$$

Nach Zurückführen auf die gegebenen Daten und Einsetzen erhalten wir

$$\begin{aligned} \mathbb{P}(S^c) &= [1 - \mathbb{P}(S \mid R)] \mathbb{P}(R) + [1 - \mathbb{P}(S \mid R^c)] [1 - \mathbb{P}(R)] \\ &= \left(1 - \frac{9}{10}\right) \frac{6}{10} + \left(1 - \frac{3}{10}\right) \left(1 - \frac{6}{10}\right) = \frac{34}{100}. \end{aligned}$$

Satz 3.2 Satz von Bayes (einfache Version) (2025+2026 zsm.)

Seien (Ω, μ) ein Wahrscheinlichkeitsraum und $A, B \subseteq \Omega$ Ereignisse mit $\mathbb{P}(B) > 0$.

Dann gilt

$$\mathbb{P}(A \mid B) = \mathbb{P}(B \mid A) \cdot \frac{\mathbb{P}(A)}{\mathbb{P}(B)}.$$

Beweis. Direkt nach Definition der bedingten Wahrscheinlichkeit gilt

$$\mathbb{P}(A \mid B) \mathbb{P}(B) = \mathbb{P}(A \cap B) = \mathbb{P}(B \mid A) \mathbb{P}(A).$$

Division durch $\mathbb{P}(B)$ ergibt die gesuchte Formel:

$$\mathbb{P}(A \mid B) = \mathbb{P}(B \mid A) \cdot \frac{\mathbb{P}(A)}{\mathbb{P}(B)}.$$

Beispiel 3.8 (2025+2026 zsm.)

Neue Frage:

Sie haben den Wetterbericht nicht gehört, aber Sie sehen, dass Herr Zimmerlich seinen Schirm dabei hat.
Wie groß ist die Wahrscheinlichkeit, dass für diesen Tag Regen vorhergesagt wurde?

Gesucht:

$$\mathbb{P}(R \mid S).$$

Problem: Wie können wir „Bedingungen umkehren“?

Lösung: Satz von Bayes / Bayes-Formel.

Lösung Nach dem Satz von Bayes (einfache Version) ist

$$\mathbb{P}(R \mid S) = \mathbb{P}(S \mid R) \cdot \frac{\mathbb{P}(R)}{\mathbb{P}(S)}.$$

Da

$$\mathbb{P}(S) = 1 - \mathbb{P}(S^c) = 1 - \frac{34}{100} = \frac{66}{100},$$

folgt

$$\mathbb{P}(R \mid S) = \frac{9}{10} \cdot \frac{\frac{6}{10}}{\frac{66}{100}} = \frac{9}{11}.$$

Satz 3.3 Satz von Bayes (allgemeine Version) (2025+2026 zsm.)

Sei $(\Omega, \mathbb{P})$ ein Wahrscheinlichkeitsraum, $B_1, B_2, \dots \subseteq \Omega$ Ereignisse mit

$$\bigcup_i^+ B_i = \Omega,$$

und $A \subseteq \Omega$ ein Ereignis mit $\mathbb{P}(A) > 0$.

Dann gilt für jedes i

$$\mathbb{P}(B_i \mid A) = \frac{\mathbb{P}(A \mid B_i) \mathbb{P}(B_i)}{\underbrace{\sum_j \mathbb{P}(A \mid B_j) \mathbb{P}(B_j)}_{\doteq \mathbb{P}(A)}}.$$

* Satz der totalen WS

Beweis. Kombiniere die einfache Version des Satzes von Bayes

$$\mathbb{P}(B_i \mid A) = \mathbb{P}(A \mid B_i) \frac{\mathbb{P}(B_i)}{\mathbb{P}(A)}$$

mit der Formel von der totalen Wahrscheinlichkeit

$$\mathbb{P}(A) = \sum_j \mathbb{P}(A \mid B_j) \mathbb{P}(B_j).$$

Einsetzen von $\mathbb{P}(A)$ in die Bayes-Formel ergibt

$$\mathbb{P}(B_i \mid A) = \frac{\mathbb{P}(A \mid B_i) \mathbb{P}(B_i)}{\sum_j \mathbb{P}(A \mid B_j) \mathbb{P}(B_j)}.$$

Die Details sind eine Hausaufgabe.

KAPITEL 4

Zufallsvariablen und ihre Verteilung

Vorlesung 09.05.2025 (V04 2025)

4.1 | Die Verteilung einer Zufallsvariablen

Beispiel 4.1 n-faches Werfen einer fairen Münze (2025)

$$\Omega_n = \{0, 1\}^n, \quad \mu_n(\{\omega\}) = \left(\frac{1}{2}\right)^n \quad \forall \omega \in \Omega \quad (\text{Gleichverteilung})$$

$\omega_i = 1$ bedeute “Kopf”

Falls es uns interessiert, wie oft “Kopf” fällt:

$$S_n(\omega) := \sum_{i=1}^n \omega_i \quad \text{ist Anzahl "Erfolge" (Kopf)}$$

$$S_n : \Omega_n \rightarrow \{0, 1, \dots, n\} \quad \text{Abbildung!}$$

Falls der relative Anteil der Erfolge relevant ist:

$$T_n : \Omega_n \rightarrow [0, 1]$$

$$T_n(\omega) := \frac{1}{n} S_n(\omega) = \frac{1}{n} \sum_{i=1}^n \omega_i \quad \forall \omega \in \Omega$$

Definition 4.1 ZV (2025)

Für einen Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$ und eine Menge $E \neq \emptyset$ nennen wir eine messbare Abbildung

$$X : \Omega \rightarrow E$$

eine E -wertige ZV.

Kommentar 4.1 Zu Definition 4.1: ZV ist keine Variable: Es ist eine Zuordnungsvorschrift der Stochastik, welche jedem möglichen Ergebnis eines Zufallsexperiments eine Größe zuordnet. Also das Ergebnis eines Zufallsexperiments.

Definition 4.2 Verteilung einer ZV (2025)

Sei X eine E -wertige ZV auf $(\Omega, \mathbb{P})$

$$\mathbb{P}_X(B) := \mathbb{P}(\{\omega \in \Omega : X(\omega) \in B\}) \quad \forall \text{ messbaren } B \subset E = \underbrace{\mathbb{P}(X \in B)}_{\text{Kurzschreibweise}}$$

Das Wahrscheinlichkeitsmaß $\mathbb{P}_X$ auf E heißt Verteilung von X .

Kommentar 4.2 Zu Definition 4.2: Die Verteilung von X beschreibt, wie die Werte von X verteilt sind, also wie wahrscheinlich verschiedene Ergebnisse von X sind.

Lemma 4.1 (2025)

Ist Ω abzählbar und $\mathbb{P}$ durch die Wahrscheinlichkeitsfunktion μ gegeben, so ist $\mathbb{P}_X$ ein Wahrscheinlichkeitsmaß.

Beweis.

$$\mu_X(e) = \mathbb{P}_X(\{e\}) = \mathbb{P}(X \in \{e\}) = \mathbb{P}(X = e) = \sum_{\substack{\omega \in \Omega \\ X(\omega) = e}} \mu(\omega) \geq 0$$

z.z. Normierung

$$\sum_{e \in E} \mu_X(e) = \sum_{e \in E} \sum_{\substack{\omega \in \Omega: \\ X(\omega) = e}} \mu(\omega) = \sum_{\substack{\omega \in \Omega: \\ e \in E: \\ X(\omega) = e}} \mu(\omega) = \sum_{\substack{\omega \in \Omega: \\ X(\omega) = e}} \mu(\omega) = \sum_{\omega \in \Omega} \mu(\omega) = 1$$

4.2 | Notationen

(2025)

$$\mathbb{P}(X \in B) = \mathbb{P}(\{\omega \in \Omega : X(\omega) \in B\})$$

Falls B ein Intervall ist:

$$\mathbb{P}(X \geq b), \quad \mathbb{P}(a < X \leq b), \dots$$

Definition 4.3 Wertebereich (2025)

Geg.:

$$X : \Omega \rightarrow E \quad \text{ZV auf } (\Omega, \mathbb{P})$$

Dann heißt E der Wertebereich und $X(\Omega) := \{X(\omega) : \omega \in \Omega\}$ heißt Bildbereich.

Beispiel 4.2 Zu Definition 4.3 (2025)

$$S_n : \Omega_n \rightarrow \{0, \dots, n\}$$

$$S_n : \Omega_n \rightarrow \mathbb{N}_0$$

Bemerkung 4.1 Zu Definition 4.3 (2025)

$X(\Omega) \subset E$ gilt immer.

Kommentar 4.3 Denn $X(\Omega)$ ist ein $\omega \in \Omega$ und jedes ω ist ein Element aus E .

Bemerkung 4.2 Zu Definition 4.3 (2025)

Gegeben ist ein Wahrscheinlichkeitsmaß auf $\tilde{\Omega}$, so existiert eine ZV, deren Verteilung genau dieses Wahrscheinlichkeitsmaß ist.

Sei $(\tilde{\Omega}, \tilde{\mathbb{P}})$ ein beliebiger Wahrscheinlichkeitsraum.

$X : \Omega \rightarrow \tilde{\Omega}$ definiert durch:

$$\begin{aligned}\Omega &:= \tilde{\Omega} \\ \mathbb{P} &:= \tilde{\mathbb{P}} \\ X(\omega) &= \omega \quad \text{Identität} \quad \forall \omega \in \Omega \\ (X \in B) &= \mathbb{P}(\underbrace{\{\omega \in \Omega : X(\omega) \in B\}}_{=B}) = \mathbb{P}(B) = \tilde{\mathbb{P}}(B)\end{aligned}$$

$\Rightarrow X$ hat Verteilung $\tilde{\mathbb{P}}$

Kommentar 4.4 Zu jedem Wahrscheinlichkeitsmaß auf einem Messraum existiert eine Zufallsvariable, die genau dieses Maß als Verteilung hat.

aka. Für jede vorgegebene Wahrscheinlichkeitsverteilung kann man ein Zufallsexperiment konstruieren, das diese Verteilung als Ergebnis hat.

4.3 | Zufallsvariablen mit abzählbarem Bildbereich

Hier fehlt was

4.4 | Zufallsvariablen mit Dichte

Definition 4.4 Dichte einer ZV (2025)

Gegeben Dichte f

Hier fehlt was

4.5 | Mehrdimensionale Zufallsvariablen und ihre gemeinsame Verteilung: Abzählbare Bildbereiche

Hier fehlt was

4.6 | Mehrdimensionale Zufallsvariablen und ihre gemeinsame Verteilung: Dichten

Hier fehlt was

Unabhängigkeit und Bernoulli-Experimente

Vorlesung 16.05.2025 (V05 2025)

5.1 | Stochastische Unabhängigkeit von Ereignissen

Was bedeutet stochastische Unabhängigkeit?

Intuition: Zwei Ereignisse A und B sind unabhängig, wenn die Information des Eintretens des jeweils einen keinen Einfluss darauf hat, als wie wahrscheinlich wir ein Eintreten auch des jeweils anderen einschätzen (Bspw. mehrmals hintereinander Würfeln).

Formal: Um A und B unabhängig zu nennen, sollten also gelten (2025)

$$\mathbb{P}(B|A) = \mathbb{P}(B) \text{ und } \mathbb{P}(A|B) = \mathbb{P}(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

($\mathbb{P}(A|B)$: die bedingte Wahrscheinlichkeit von A gegeben B.) wobei jede dieser beiden Gleichungen äquivalent ist zu.

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$$

Also

$$\mathbb{P}(A|B) = \mathbb{P}(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \Leftrightarrow \mathbb{P}(A) \cdot \mathbb{P}(B) = \mathbb{P}(A \cap B)$$

$\mathbb{P}(A \cap B)$: WS, dass A und B gleichzeitig eintreten

Definition 5.1 Zwei Ereignisse $A, B \subseteq \Omega$ heißen unabhängig, wenn $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$.

Beispiel 5.1 TODO

Beobachtung 5.1 (2025)

unabhängig $\neq$ disjunkt! Also sind disjunkte Ereignisse unabhängig, wenn $0 = \mathbb{P}(\emptyset) = \mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$, also muss entweder $\mathbb{P}(A) = 0$ oder $\mathbb{P}(B) = 0$ sein (mindestens eines der Ereignisse WS Null haben):

$$0 = \mathbb{P}(\emptyset) = \mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B) \Leftrightarrow \mathbb{P}(A) = 0 \text{ oder } \mathbb{P}(B) = 0$$

Kommentar 5.1 disjunkte Ereignisse: $A \cap B = \emptyset \Rightarrow$ A und B können nicht gleichzeitig eintreten.
unabhängige Ereignisse: $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$

Beobachtung 5.2 (2025)

Es gilt: A, B unabhängig $\Leftrightarrow A, B^c$ unabhängig $\Leftrightarrow A^c, B^c$ unabhängig.

Beweis. z.z. $\mathbb{P}(A \cap B^c) = \mathbb{P}(A) \cdot \mathbb{P}(B^c)$

Siehe Folie 9

Beobachtung 5.3 A kann unabhängig von sich selbst sein. (2025)

$$\mathbb{P}(A) = \mathbb{P}(A \cap A) = \mathbb{P}(A) \cdot \mathbb{P}(A) = \mathbb{P}(A)^2 \Leftrightarrow \mathbb{P}(A) \in \{0, 1\}$$

Umgangssprachlicher gesagt: A kann unabhängig von sich selbst sein, wenn seine WS entweder 0 oder 1 ist.

Definition 5.2 Unabhängigkeit von n Ereignissen. (2025)

Die Ereignisse $A_1, \dots, A_n \subseteq \Omega$ heißen unabhängig, wenn

$$\mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}) = \mathbb{P}(A_{i_1}) \cdots \mathbb{P}(A_{i_k})$$

für alle $k = 2, \dots, n$ und alle Auswahlen von k verschiedenen Indizes $i_1, \dots, i_k \in \{1, \dots, n\}$. (Also alle Paare, Tripel, etc. prüfen.)

Beispiel 5.2 siehe Folie 14--15**Bemerkung 5.1** (2025)

Es genügt nicht, paarweise Unabhängigkeit zu prüfen! Sachen können paarweise unabhängig, aber nicht insgesamt unabhängig sein.

Bemerkung 5.2 (2025) Es genügt nicht, $\mathbb{P}(A_1 \cap \dots \cap A_n) = \mathbb{P}(A_1) \cdots \mathbb{P}(A_n)$ zu prüfen. Es kann insgesamt unabhängig sein, aber nicht paarweise etc. unabhängig.

5.2 | Unabhängige Nacheinanderausführung von Zufallsexperimenten

(2025) Sollen Zufallsexperimente $(\Omega_1, \mathbb{P}_1), \dots, (\Omega_n, \mathbb{P}_n)$ unabhängig nacheinander ausgeführt werden, so modellieren wir dies mit dem W-Raum $(\Omega, \mathbb{P})$ mit

$$\Omega = \Omega_1 \times \dots \times \Omega_n$$

und – im Fall, dass wir abzählbare Ω_i haben –

$$\mu(\omega) = \mu_1(\omega_1) \cdots \mu_n(\omega_n) \forall \omega = (\omega_1, \dots, \omega_n) \in \Omega$$

Sind nämlich $A_1 \subseteq \Omega_1, \dots, A_n \subseteq \Omega_n$, so sind bei dieser Wahl

$$B_1 = A_1 \times \Omega_2 \times \dots \times \Omega_n$$

$$B_2 = \Omega_1 \times A_2 \times \Omega_3 \times \dots \times \Omega_n$$

$$\vdots$$

$$B_n = \Omega_1 \times \dots \times \Omega_{n-1} \times A_n$$

B_1 bedeutet: Im ersten Experiment tritt A_1 ein, die anderen sind egal. unabhängig, denn für $k = 2, \dots, n$ und $i_1, \dots, i_k \in \{1, \dots, n\}$ verschieden gilt:

$$\underbrace{\mathbb{P}(B_{i_1} \cap \dots \cap B_{i_k})}_{= A_1 \times A_2 \times \dots \times A_n} = \mathbb{P}_{i_1} A_{i_1} \cdot \dots \cdot \mathbb{P}_{i_k} A_{i_k} = \mathbb{P}(B_{i_1}) \cdot \dots \cdot \mathbb{P}(B_{i_k}) \quad (5.1)$$

Beweis. Selbstständig (siehe Hinweis Folie 20)

Beispiel 5.3 Folie 21

Sind die Ω_i nicht alle abzählbar, so definieren wir $\mathbb{P}$ auf $\Omega = \Omega_1 \times \dots \times \Omega_n$

$$\mathbb{P}(A_1 \times \dots \times A_n) = \mathbb{P}_1(A_1) \cdot \dots \cdot \mathbb{P}_n(A_n) \quad \forall A_i \subseteq \Omega_i \forall i \quad (5.2)$$

motiviert durch Formel (5.1).

Bemerkung 5.3 (2025)

Formel (5.2) kann immer als Definition verwendet werden. Falls alle $\mathbb{P}_i$ durch WS μ_i gegeben sind, folgt aus Formel (5.2):

$$\begin{aligned} \mu((\omega_1, \dots, \omega_n)) &= \mathbb{P}(\{(\omega_1, \dots, \omega_n)\}) \\ &= \mathbb{P}(\{\omega_1\} \times \{\omega_2\} \times \dots \times \{\omega_n\}) \\ &\stackrel{(5.2)}{=} \mathbb{P}_1(\{\omega_1\}) \cdot \mathbb{P}_2(\{\omega_2\}) \cdot \dots \cdot \mathbb{P}_n(\{\omega_n\}) \\ &= \mu_1(\omega_1) \cdot \mu_2(\omega_2) \cdot \dots \cdot \mu_n(\omega_n) \end{aligned}$$

5.3 | Die Binomialverteilung

Definition 5.3 Einfaches Bernoulli-Experiment (2025)

Ein Bernoulli-Experiment ist ein Zufallsexperiment mit genau zwei möglichen Ergebnissen: Einem "Treffer" oder einer "Niete".

$\Omega_1 = \{0, 1\}$; $\omega = 1$ bedeutet Erfolg, $\omega = 0$ bedeutet Misserfolg.

$\mu_1(1) = p$, $\mu_1(0) = 1 - p$ und dabei heißt $p \in [0, 1]$ die Erfolgswahrscheinlichkeit.

Definition 5.4 Bernoulli-Experiment der Länge n

Wiederhole dasselbe einfache Bernoulli-Experiment n -mal unabhängig.

$$\Omega_n = \{0, 1\}^n, \mu_n((\omega_1, \dots, \omega_n)) = p^{\overbrace{\sum_{i=1}^n \omega_i}^{=k}} \cdot (1-p)^{n-\overbrace{\sum_{i=1}^n \omega_i}^{=k}}$$

$$\begin{aligned} \Omega_n &= \underbrace{\Omega_1 \times \dots \times \Omega_n}_{n\text{-mal}} \\ \mu_n((\omega_1, \dots, \omega_n)) &= \mu_1(\omega_1) \cdot \dots \cdot \mu_1(\omega_n) \quad \forall \omega \in \Omega_n \\ &= p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{n-\sum_{i=1}^n \omega_i} \end{aligned}$$

Definition 5.5 Binomialverteilung (2025)

Suche WS für genau k Erfolge in Bernoulli-Experiment der Länge n .

$$A_k = \{S_n = k\} = \{(\omega_1, \dots, \omega_n) \in \{0, 1\}^n : \underbrace{\sum_{i=1}^n \omega_i}_{S_n(\omega)} = k\}$$

$\binom{n}{k}$ Möglichkeiten, k Einsen auf die n Stellen zu verteilen.

$$\Rightarrow \mathcal{B}_{n,p}(k) := \mathbb{P}(A_k) = \binom{n}{k} p^k (1-p)^{n-k} \text{ für alle } k \in \{0, \dots, n\}$$

$\mathcal{B}_{n,p}(k)$ ist eine Wahrscheinlichkeitsfunktion auf $\Omega = \{0, \dots, n\}$, denn

$$\sum_{k=0}^n \mathcal{B}_{n,p}(k) = \sum_{k=0}^n \mathbb{P}(A_k) = \mathbb{P}(\cup_{k=0}^n A_k) = \mathbb{P}(\{0, 1\}^n) = 1$$

$\mathcal{B}_{n,p}$ heißt Binomialverteilung mit den Parametern n und p .

Eine ZV X , deren Verteilung $\mathbb{P}_X$ die $\mathcal{B}_{n,p}$ -Verteilung ist, heißt **binomialverteilt mit den Parametern n und p** .

Beispiel 5.4 Einfaches Bernoulli-Experiment Siehe Folie 29

Beispiel 5.5 Bernoulli-Experiment der Länge n Siehe Folie 29

Beispiel 5.6 Binomialverteilung : Siehe Folie 29

Problem 5.1 Wie wahrscheinlich ist, dass in einem Bernoulli-Experiment der Länge n der erste Erfolg im n -ten Versuch eintritt? (2025)

$$A_n = \{(0, \dots, 0, 1)\}, \quad \mathbb{P}(A_n) = \mu_n((0, \dots, 0, 1)) = p(1-p)^{n-1}$$

Definition 5.6 geometrische Verteilung mit Erfolgswahrscheinlichkeit p (2025)

Siehe Folie 33

Definition 5.7 Unabhängigkeit von ZV (2025)

Siehe Folie 35

Unabhängigkeiten von ZV

Vorlesung 23 Mai 2025 (V06 2025) und Vorlesung 22.05.2026 (V05 2026)

Beispiel 6.1 Die Randverteilungen legen die gemeinsame Verteilung nicht eindeutig fest (2026)

Wir werfen eine faire Münze zweimal. Die Ergebnisse der beiden Würfe sollen notiert werden.

Alex schreibt korrekt auf, während Kim einen Moment lang abgelenkt ist, dadurch das Ergebnis des zweiten Wurfs verpasst und als Notlösung einfach so tut, als hätten beide Würfe dasselbe Ergebnis gehabt.

Modellierung

$$\Omega = \{0, 1\}^2$$

mit Gleichverteilung $\mathbb{P}$.

Zufallsvariable

- Alex notiert den zweifachen Münzwurf

$X : \Omega \rightarrow \Omega$ mit $X = (X_1, X_2)$ wobei $X_1((\omega_1, \omega_2)) = \omega_1$ und $X_2((\omega_1, \omega_2)) = \omega_2$ für alle $\omega \in \Omega$
(das heißt, X ist die Identität auf Ω)

- Kim notiert nur den ersten Münzwurf

$Y : \Omega \rightarrow \Omega$ mit $Y = (Y_1, Y_2)$ wobei $Y_1((\omega_1, \omega_2)) = \omega_1$ und $Y_2((\omega_1, \omega_2)) = Y_1((\omega_1, \omega_2)) = \omega_1$ für alle $\omega \in \Omega$

$\mu_X((x_1, x_2))$	$x_2 = 0$	$x_2 = 1$	$\mu_{X_1}(x_1)$
$x_1 = 0$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$
$x_1 = 1$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$
$\mu_{X_2}(x_2)$	$\frac{1}{2}$	$\frac{1}{2}$	1
$\mu_Y((y_1, y_2))$	$y_2 = 0$	$y_2 = 1$	$\mu_{Y_1}(y_1)$
$y_1 = 0$	$\frac{1}{2}$	0	$\frac{1}{2}$
$y_1 = 1$	0	$\frac{1}{2}$	$\frac{1}{2}$
$\mu_{Y_2}(y_2)$	$\frac{1}{2}$	$\frac{1}{2}$	1

Offensichtlich sind die Randverteilungen von X und von Y gleich, während die gemeinsame Verteilung von Y_1 und Y_2 nicht dieselbe ist wie jene von X_1 und X_2 .

Beispiel 6.2 n-mal würfeln mit fairem Würfel (2025)

$\Omega\{1, \dots, 6\}^n$, ω_i das Ereignis des i-ten Wurfs. $\mathbb{P}$ gleichverteilt.

$X_i : \Omega \rightarrow \{1, \dots, 6\}$, $X_i(\omega) = \omega_i \quad \forall i \in \{1, \dots, 6\}$

z.z. $X_i, \dots, X_n$ unabhängig

$$\mathbb{P}(X_1 = k_1, \dots, X_n = k_n) \quad \text{für } k_i \in \{1, \dots, 6\}$$

$$\mathbb{P}(\{(k_1, \dots, k_n)\}) = \frac{1}{6^n}$$

$$\begin{aligned} \mathbb{P}(X_i = k_i) &= \mathbb{P}(X_1 \in \{1, \dots, 6\}, \dots, X_{i-1} \in \{1, \dots, 6\}, X_i = k_i, X_{i+1} \in \{1, \dots, 6\}, \dots, X_n \in \{1, \dots, 6\}) \\ &= \mathbb{P}(\{1, \dots, 6\}^{i-1} \times \dots) \\ &= \frac{6^{n-1}}{6^n} \end{aligned} \quad = \frac{1}{6}$$

$$\mathbb{P}(X_1 = k_1, \dots, X_n = k_n) = \mathbb{P}(X_1 = k_1) \cdot \dots \cdot \mathbb{P}(X_n = k_n)$$

! jetzt müssen wir noch prüfen: Paare, Tripel, ... Danach: $X_1, \dots, X_n$ bewiesenermaßen unabhängig

Beispielsweise: $\Rightarrow \{x_1 \in \{2, 4, 6\}, \dots, \{x_4 \leq 4\}\}$ unabhängig

Frage: müssen wir die Paare und Tripel wirklich prüfen?

Satz 6.1 (2026) Seien $X_1, \dots, X_n$ unabhängig $\Rightarrow \mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \mathbb{P}(X_1 \in B_1) \cdot \dots \cdot \mathbb{P}(X_n \in B_n)$

Beweis. Um zu zeigen, dass

$$\mathbb{P}(X_1 \in B_1, X_3 = B_3) = \mathbb{P}(X_1 = B_3) \cdot \mathbb{P}(X_3 = B_3)$$

gilt, wählen wir

$$B_2 = E_2, B_4 = E_4, \dots, B_n = E_n$$

Definition 6.1 Unabhängigkeit von Zufallsvariablen (2026)

Auf einem Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$ seien Zufallsvariablen $X_1, \dots, X_n$ gegeben mit $X_i : \Omega \rightarrow E_i$ für $i = 1, \dots, n$.

Die Zufallsvariablen $X_1, \dots, X_n$ heißen unabhängig, wenn die Ereignisse

$$\{X_1 \in B\}, \dots, \{X_n \in B\}$$

für alle Wahlen von messbaren Mengen $B_i \subseteq E_i, i = 1, \dots, n$, unabhängig sind.

Diese Definition ist zunächst einmal abschreckend. Wir haben bereits gesehen, wie viele Bedingungen für den Nachweis der Unabhängigkeit von n Ereignissen zu prüfen sind. Und nun sollen wir diesen Aufwand auch noch für jede Wahl von B_i betreiben! Wir werden uns daher im folgenden darum bemühen, einfacher nachzuweisende Kriterien für Unabhängigkeit herzuleiten.

Als erstes halten wir fest, dass es im diskreten Fall genügt, einelementige Mengen B_i zu betrachten.

6.1 | Unabhängigkeit für Zufallsvariable mit abzählbarem Bildbereich

Kommentar 6.1 In 2025 und 2026 wurden diese Informationen verschieden formuliert. Hier befinden sich alle drei Versionen und eine zusammengeführte Version. Es handelt sich dabei um verschiedene Charakterisierungen der Unabhängigkeit (also es sind nur verschiedene Betrachtungsweisen des gleichen Umstands). Es sind danach auch noch weitere Charakterisierungen bzw. Konsequenzen zu finden.

Satz 6.2 Satz I. - Charakterisierung über Ereignisse (2025)

Seien $X_1, \dots, X_n$ ZV auf $(\Omega, \mathbb{P})$; X_i sei E_i -wertig.

Dann

$$X_1, \dots, X_n \text{ unabhängig} \Leftrightarrow \{X_1 = x_1\}, \dots, \{X_n = x_n\} \text{ unabhängig } \forall x_i \in E_i (i = 1, \dots, n)$$

Beweis. Siehe Folie 2 (2025)

Satz 6.3 Satz II. - Neuformulierung von Satz I. / Charakterisierung über Produktform (2025)

Haben $X_1, \dots, X_n$ abzählbare Werte-/Bildbereiche. Dann

$$X_1, \dots, X_n \text{ unabhängig} \Leftrightarrow \mu_{X_1, \dots, X_n}((x_1, \dots, x_n)) = \prod_{i=1}^n \mu_{x_i}(x_i)$$

Theorem 6.1 Unabhängigkeit für Zufallsvariable mit abzählbarem Bildbereich (2026)

Auf einem **Wahrscheinlichkeitsraum** $(\Omega, \mathbb{P})$ seinen **ZVs** $X_1, \dots, X_n$ mit abzählbarem Bildbereich gegeben. Dann sind $X_1, \dots, X_n$ genau dann unabhängig, wenn die Ereignisse

$$\{X_1 = x_1\}, \dots, \{X_n = x_n\}$$

für alle $x_i \in X_i(\Omega), i = 1, \dots, n$ unabhängig sind.

Beweis. Siehe Skript S. 58.

Kommentar 6.2 Gemeinsam haben alle drei Formulierungen:

$$X_1, \dots, X_n \text{ sind ZVs auf Wahrscheinlichkeitsraum } (\Omega, \mathbb{P})$$

Verschieden formuliert sind:

$$\text{“haben abzählbare Werte-/Bildbereiche”} \Leftrightarrow X_i \text{ sei } E_i\text{-wertig}$$

und

$$X_1, \dots, X_n \text{ unabhängig} \Leftrightarrow \underbrace{\text{wenn die Ereignisse } \{X_1 = x_1\}, \dots, \{X_n = x_n\} \text{ für alle } x_i \in X_i(\Omega), i = 1, \dots, n \text{ unabhängig sind.}}_{\mu_{X_1, \dots, X_n}((x_1, \dots, x_n)) = \prod_{i=1}^n \mu_{x_i}(x_i)} \{X_1 = x_1\}, \dots, \{X_n = x_n\} \text{ unabhängig } \forall x_i \in E_i (i = 1, \dots, n)$$

Korollar 6.1 Konsequenz aus Satz 6.3 (2026)

Abzählbarer Bildbereich

Es genügt

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_1 = x_1) \cdot \dots \cdot \mathbb{P}(X_n = x_n) \forall x_i \in X_i(\Omega)$$

zu zeigen, um Unabhängigkeit von $X_1, \dots, X_n$ zu zeigen.

Satz 6.4 Charakterisierung über die Produktform der Verteilungsfunktion (2026)

$X_1, \dots, X_n$ unabhängig

$$\begin{aligned} \Leftrightarrow \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) &= \mathbb{P}(X_1 \leq a_1) \cdot \dots \cdot \mathbb{P}(X_n \leq a_n) \\ &= F_{X_1}(a_1) \cdot \dots \cdot F_{X_n}(a_n) \quad \forall a_i \in \mathbb{R} \end{aligned}$$

Korollar 6.2 Konsequenz aus Satz 6.4 (2025)

$X_1, \dots, X_n$ unabhängig $\Leftrightarrow$ gemeinsame Verteilung eindeutig bestimmt durch (Rand-)Verteilungen von $X_1, \dots, X_n$

Aka.:

$X_1, \dots, X_n$ unabhängig $\Rightarrow$ gemeinsame Verteilung von $X_1, \dots, X_n$ eindeutig bestimmt durch die Randverteilung

Bemerkung 6.1 Zu Korollar 6.2 (2025)

Das Korollar sagt uns, wie wir unabhängige Zufallsvariablen mit Zähldichte modellieren.
Ohne Unabhängigkeit ist das nicht der Fall!

Bemerkung 6.2 Erinnerung an mathematisches Kriterium für Unabhängigkeit (2026)

Wie haben gesehen, dass Unabhängigkeit bereits gezeigt ist, wenn $\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_1 = x_1) \cdot \dots \cdot \mathbb{P}(X_n = x_n) \forall x_i \in E_i (i = 1, \dots, n)$ gilt. Wenn also die Produktform existiert. (Es ist nicht erforderlich $X_{i_1}, \dots, X_{i_k}$ separat zu betrachten.)

Bemerkung 6.3 Anwendung des mathematischen Kriteriums für Unabhängigkeit (2025)

(a) Wenn wir die Produktform finden: Beweis der Unabhängigkeit Wenn man also zeigen kann $\mathbb{P}_{X_1, \dots, X_n} = \prod_i \mathbb{P}_{X_i}$

Umkehridee:

(b) Gegeben Verteilung der X_i : Wir nutzen die Produktform, um die gemeinsame Verteilung für unabhängig X_i zu bestimmen. Also wenn die X_i unabhängig sind und die Randverteilungen bekannt sind, dann kann man die gemeinsame Verteilung berechnen durch

$$\mathbb{P}_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_i \mathbb{P}_{X_i}(x_i)$$

6.1.1 | Poisson-Verteilte ZV**Satz 6.5** Summe unabhängiger Poisson-verteilter ZV ist wieder Poisson-verteilt. (2025)

Seien X_1, X_2 unabhängig und Poisson-verteilt mit

$$\mu_{x_1}(k) = \mathbb{P}(X_1 = k) = \frac{z_1^k}{k!} e^{-z_1} \quad (z_1 > 0) \forall k \in \mathbb{N}_0$$

$$\mu_{x_2}(k) = \mathbb{P}(X_2 = k) = \frac{z_2^k}{k!} e^{-z_2} \quad (z_2 > 0) \forall k \in \mathbb{N}_0$$

Dann gilt: $X_1 + X_2$ ist Poisson-Verteilt mit Parameter $z_1 + z_2$.

Kommentar 6.3 $X_1 + X_2$ nehmen beide Werte aus $\mathbb{N}_0$ an, also ist die Summe auch in $\mathbb{N}_0$.

Beweis. Siehe auch Folie 6--7 2025

$X_1 + X_2$ ist poisson verteilt mit Parameter $z_1 + z_2$

$$\begin{aligned}
 \mu_{X_1+X_2}(n) &= \mathbb{P}(X_1 + X_2 = n) \quad \text{für } n \in \mathbb{N}_0 \\
 &= \mathbb{P}\left(\bigsqcup_{k_1=0}^n \{X_1 = k_1, X_2 = n - k_1\}\right) \\
 &= \sum_{k_1=0}^n \mathbb{P}(X_1 = k_1, X_2 = n - k_1) \\
 &= \sum_{k_1=0}^n \mathbb{P}(X_1 = k_1) \mathbb{P}(X_2 = n - k_1) && \text{da unabhängig} \\
 &= \sum_{k_1=0}^n \frac{z_1^{k_1}}{k_1!} e^{-z_1} \frac{z_2^{n-k_1}}{(n-k_1)!} e^{-z_2} \\
 &= \sum_{k=0}^n \frac{n!}{k!(n-k)!} z_1^k z_2^{n-k} && \text{durch herausziehen von } \left[\frac{1}{n!} e^{-(z_1+z_2)}\right] \\
 &= \frac{(z_1 + z_2)^n}{n!} e^{-(z_1+z_2)}
 \end{aligned}$$

6.2 | ZV mit Dichten

Satz 6.6 Satz III.: Unabhängigkeiten von ZV (mit und ohne Dichte) (2025)

Seien $X_1, \dots, X_n$ unabhängig $\Leftrightarrow \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) = \mathbb{P}(X_1 \leq a_1) \cdot \dots \cdot \mathbb{P}(X_n \leq a_n) = \mathcal{F}_{x_1}(a_1) \cdot \dots \cdot \mathcal{F}_{x_n}(a_n) \forall a_1, \dots, a_n \in \mathbb{R}$.

Beweis. Siehe Folie 8

Satz 6.7 Satz IV. (2025, ergänzt 2026)

$X_1, \dots, X_n$ mit Dichten $f_1, \dots, f_n$. Dann gilt: $X_1, \dots, X_n$ unabhängig $\Leftrightarrow$ gemeinsame Dichte hat Produktform $\Leftrightarrow (x_1, \dots, x_n) \mapsto f((x_1, \dots, x_n)) := f_1(x_1) \cdot \dots \cdot f_n(x_n)$ eine gemeinsame Dichte von $X_1, \dots, X_n$ ist.

Bemerkung 6.4 Zu Satz 6.7 (2026)

■ Existenz der gem. Dichte ist nicht vorausgesetzt. Gegeben $X_1, \dots, X_n$ mit Dichten $f_1, \dots, f_n$

■ Setze

$$f(x_1, \dots, x_n) := f_1(x_1) \cdot \dots \cdot f_n(x_n) = \prod_{i=1}^n f_i(x_i) \quad \forall x_i \in \mathbb{R} (i = 1, \dots, n) \quad (6.1)$$

Aussage des Satzes ist: $X_1, \dots, X_n$ unabhängig $\Leftrightarrow f$ gem. Dichte von $X_1, \dots, X_n$ ist

■ $X_1, \dots, X_n$ mit Dichten $f_1, \dots, f_n$. Modelliere unabhängige Experimente durch gemeinsame Dichte (6.1).

■ Gegen eine gem. Dichte f für $X_1, \dots, X_n$ berechne Randdichten $f_{x_1}, \dots, f_{x_n}$.

Gilt Gleichung (6.1)? Falls ja: $X_1, \dots, X_n$ unabhängig. Falls (6.1) für $(x_1, \dots, x_n)$ aus einer Menge $\subseteq \mathbb{R}^n$ gilt mit $\mathbb{R}^n \setminus M$ abzählbar, dann gilt Unabhängigkeit

Kommentar 6.4 Vorsicht: Eine Wahrscheinlichkeitsdichte ist nur “fast überall” eindeutig.

Also: Die Produktform muss nicht an jedem einzelnen Punkt gelten. Es genügt, wenn sie fast überall gilt.

6.3 | Widerlegen von Unabhängigkeiten

Bemerkung 6.5 Es genügt nicht einen Punkt zu finden, in dem (6.1) nicht gilt. (2025)

Wir brauchen eine Menge $D \subseteq \mathbb{R}^n$ mit $|D| = Z(D) > 0$, so dass (6.1) auf D nicht gilt.

Einfacher: Zeigen, dass $\mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) \neq \prod_{i=1}^n F_{X_i}(a_i)$.

Zeigen Sie, dass die Produktform **nicht** gilt auf Quader oder verwenden Sie die (nicht geltende) Produktform der Verteilungsfunktion.

Kommentar 6.5 Zu Bemerkung 6.5:

$\mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) \neq \prod_{i=1}^n F_{X_i}(a_i)$ bedeutet, die gemeinsame Verteilungsfunktion faktorisiert nicht. Das ist gemeint mit “verwenden Sie die (nicht geltende) Produktform der Verteilungsfunktion”, denn da $F_{X_1, \dots, X_n}(a_1, \dots, a_n) = \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n)$ gilt, ist das die Negation der Produktform der Verteilungsfunktion.

Kommentar 6.6 Zu Bemerkung 6.5:

Die Produktform der Verteilungsfunktion wird auf sogenannten “Quadern” geprüft. Damit sind Mengen der Form

$$(-\infty, a_1] \times \dots \times (-\infty, a_n] \subseteq \mathbb{R}^n$$

gemeint.

Für den Zufallsvektor $(X_1, \dots, X_n)$ entspricht ein solcher Quader dem Ereignis

$$\{X_1 \leq a_1, \dots, X_n \leq a_n\}.$$

Die gemeinsame Verteilungsfunktion ist daher gerade

$$F_{X_1, \dots, X_n}(a_1, \dots, a_n) = \mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n).$$

Sind $X_1, \dots, X_n$ unabhängig, so zerfällt diese Wahrscheinlichkeit in ein Produkt:

$$\mathbb{P}(X_1 \leq a_1, \dots, X_n \leq a_n) = \prod_{i=1}^n \mathbb{P}(X_i \leq a_i) = \prod_{i=1}^n F_{X_i}(a_i).$$

Man sagt dann:

Die Verteilungsfunktion besitzt Produktform auf Quadern.

Um zu zeigen, dass Zufallsvariablen nicht unabhängig sind, genügt es daher, einen Quader zu finden, für den diese Produktform nicht gilt.

Danke an ChatGPT [?] (Überprüft)

Kommentar 6.7 Bei Bild Tafel link ganz unten reicht es an einem Punkt zu zeigen, weil wir da ganze Mengen benutzt haben. Okay ????

Beispiel 6.3 uniform. verteilung auf Rechteck (2026)

Sei (X, Y) ein zufälliger Punkt in $\mathbb{R}$ (uniforme Verteilung)



(X, Y) hat (gem.) Dichte $f(x, y) = \chi_R(x, y) \frac{1}{a \cdot b} \quad \forall (x, y) \in \mathbb{R}^2$ Randdichten:

$$f_X(x) = \chi_{[0,a]}(x) \int_0^b \underbrace{f(x, y)}_{\frac{1}{a \cdot b}} dy = \frac{1}{a} \chi_{[0,a]}(x)$$

$$f_Y(y) = \frac{1}{b} \chi_{[0,b]}(y)$$

$$\begin{aligned} f(x, y) &= \chi_{[0,a] \times [0,b]}(x, y) \frac{1}{a \cot b} \\ &= f_X(x) f_Y(y) \end{aligned}$$


schlauer:

$$f(x, y) = \chi_{\mathbb{R}}(x, y) \frac{1}{a \cot b} = \frac{1}{a} \underbrace{\chi_{[0,a]}(x)}_{\text{Randdichte von } X} \cdot \frac{1}{b} \underbrace{\chi_{[0,b]}(y)}_{\text{Randdichte von } Y}$$

Wir müssen die Randdichten gar nicht berechnen! X, Y unabhängig

Kommentar 6.8 wenn man sieht die Dichte zerfällt in x und y Argument muss man nicht integrieren, sondern nur schauen, dass die Funktionen (?) das richtige Gewicht haben. OK. Gerald fragen...

Beispiel 6.4 Dreieck (2026)



Sei (X, Y) ein zufälliger Punkt **gleichverteilt** im Dreieck D .

Gleichverteilt bedeutet: Dichte ist konstant auf D und 0 außerhalb.

$$\begin{aligned} f(x, y) &= \frac{1}{|D|} \chi_D(x, y) \\ &= 2 \chi_D(x, y) \\ &= \begin{cases} 2 & 0 \leq y \leq x \leq 1 \\ 0 & \text{sonst} \end{cases} \end{aligned}$$

Randdichten: (Man “integriert die andere Variable weg”)

$$\begin{aligned} f_X(x) &= \chi_{[0,1]}(x) \int_{-\infty}^{\infty} f(x, y) dy \\ &= \chi_{[0,1]}(x) \int_0^x 2 dy = 2x \chi_{[0,1]}(x) \\ f_Y(y) &= \dots = 2(1-y) \chi_{[0,1]}(y) \end{aligned}$$

Wenn X, Y unabhängig wären, dann würde gelten :

$$f(x, y) = f_X(x) f_Y(y) \quad (6.2)$$

Einsetzen ergibt:

$$\begin{aligned} f(x, y) &= 2 \cdot \chi_D(x, y) \\ &\stackrel{?}{=} f_X(x) f_Y(y) \\ &= 2x2(1-y)\chi_{[0,1]}(x, y) \end{aligned}$$

Wir sehen: Für $(x, y) \in [0, 1]^2 \setminus D$ gilt $f(x, y) = 0$, also “rechte Seite” > 0 .

Keine Unabhängigkeit. Für Erklärung siehe Kommentar 6.10.

Alternative: Statt Dichten zu vergleichen, kann man Unabhängigkeit auch testen über:

$$\mathbb{P}(X \leq a, Y \leq b) \stackrel{?}{=} F_X(a) F_Y(b)$$

Explizit: Berechne F_X und F_Y , zeige, dass es **einen** Punkt $(a, b) \in \mathbb{R}^2$ gibt mit

$$\mathbb{P}(X \leq a, Y \leq b) \neq F_X(a) F_Y(b).$$

Kommentar 6.9 Symbole und Terme in Beispiel 6.4

■ $\chi_D(x, y)$ = Indikatorfunktion:

$$\chi_D(x, y) = \begin{cases} 1 & (x, y) \in D \\ 0 & \text{sonst} \end{cases}$$

■ $|D|$ = Fläche des Dreiecks (hier: $|D| = \frac{1}{2}$)

■ $f(x, y)$ = gemeinsame Dichte von (X, Y)

■ $f_X(x)$ beschreibt die Verteilung von X alleine

■ $f_Y(y)$ beschreibt die Verteilung von Y alleine

Kommentar 6.10 Für $(x, y) \in [0, 1]^2 \setminus D$ gilt $f(x, y) = 0$ weil in der Dichtefunktion oben explizit festgelegt wird, dass es außerhalb des Dreiecks 0 ist und $[0, 1]^2 \setminus D$ ist alles außer das Dreieck.

Also ist die “rechte Seite” $f_X(x) f_Y(y)$ aus 6.2).

Diese ist > 0 , denn x kann 0 sein (siehe Bild ??, 0 ist der innerste Randpunkt von “außerhalb des Dreiecks”) und y kann 1 sein (analog äußerster Randpunkt von “außerhalb des Dreiecks”). Aber da es Randpunkte sind, haben sie keinen Einfluss auf die Dichte, denn Punkte haben keine Fläche und somit keine relevante “Menge”. Also kann man diese Punkte wegnorieren und einfach sagen $x > 0$ und $y < 1$. Und wenn man das annimmt, dann erhält man:

$$f_X(x) f_Y(y) = 4x(1-y)\chi_{[0,1]^2}(x, y)$$

Denn wir haben ja oben ausgerechnet, dass $f_X(x) = 2x\chi_{[0,1]}(x)$ und $f_Y(y) = 2(1-y)\chi_{[0,1]}(y)$, INSOERN X und Y unabhängig sind.

Weil aber $y < 1$ gilt, muss $1 - y > 0$ sein, also

$$\underbrace{\underbrace{4}_{>0} \underbrace{x}_{>0} \underbrace{(1-y)}_{>0}}_{>0}$$

Das ist dann ein Widerspruch damit, dass jeder Punkt außerhalb des Dreiecks $f(x, y) = 0$ hat. Wir haben einen Punkt außerhalb des Dreiecks betrachtet, und der hatte $f_X(x)f_Y(y) > 0$. Also $f(x, y) \neq f_X(x)f_Y(y)$, was äquivalent ist zu “ X und Y sind NICHT unabhängig”.

Kommentar 6.11 Zu Beispiel 6.4

Warum reicht ein einzelner Punkt zur Widerlegung? Wenn Unabhängigkeit gilt, muss die Gleichung für *alle* (a, b) gelten. Findet man *einen einzigen* Punkt (a, b) mit Ungleichheit, ist Unabhängigkeit widerlegt. „Unabhängigkeit ist eine globale Eigenschaft und ein Gegenbeispiel genügt, um sie zu zerstören.“

Definition 6.2 **Faltung** (2026)

X, Y unabhängig **ZV**. Dann heißt die Verteilung der Summe **Faltung** (der Verteilungen).

KAPITEL 7

Erwartungswert und Varianz von Zufallsvariablen

Vorlesung 30. Mai 2025 (V07 2025) und 05. Juni 2026 (V07 2026)

Lernziele

Konzepte

- Erwartungswert einer Zufallsvariablen (gewichteter Mittelwert)
- Varianz als weitere Kennzahl

Fakten

- Zwei verschiedene Darstellungen des Erwartungswerts.
- Der Erwartungswert ist linear.

Wissen

- Existenz des Erwartungswerts prüfen können.
- Spezialfall: $X(\Omega)$ ist eine endliche Menge (insbesondere erfüllt, wenn Ω endlich ist).
- Spezialfall: $X \geq 0$.
- Erwartungswerte berechnen können.
- Erwartungswert und Varianz für die wichtigsten Verteilungen kennen
- Erwartungswert von Produkten zum Widerlegen von Unabhängigkeit
- Erwartungswert von Produkten bei Unabhängigkeit berechnen können
- Markov-Ungleichung kennen und anwenden können

Grundgedanke

(2025) Die Verteilung charakterisiert eine ZV X eindeutig (Im Sinne ihrer statistischen Eigenschaften: Wir können Wahrscheinlichkeiten berechnen wie z.B. $\mathbb{P}(X \geq 2)$, und diese Wahrscheinlichkeiten hängen nur von der Verteilung ab, nicht von der Wahl des Wahrscheinlichkeitsraums $(\Omega, \mathbb{P})$).

Sind X und Y zwei ZVs mit derselben Verteilung, so gilt

$$\mathbb{P}(X \in A) = \mathbb{P}_X(A) = \mathbb{P}_Y(A) = \mathbb{P}(Y \in A)$$

für jedes A .

Es ist nicht immer klar, welche Verteilung zu einem sinnvollen Modell führt. Auch sind die Parameter der Verteilung nicht unbedingt bekannt. Siehe (2026)

■ **Binomialverteilung:**

$$\mathcal{B}_{n,p}(k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k \in \{0, \dots, n\}.$$

■ **Geometrische Verteilung:**

$$G_p(n) = p(1-p)^{n-1}, \quad n \in \mathbb{N}.$$

■ **Poisson-Verteilung:**

$$P_\lambda(k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k \in \mathbb{N}_0.$$

■ **Exponentialverteilung:**

$$f(x) = \omega e^{-\lambda x} \chi_{[0,\infty)}(x), \quad x \in \mathbb{R}.$$

Wie können wir trotzdem Vorhersagen treffen?

Dies führt uns in die Statistik (später).

Typische Fragestellungen: Wie ...*im Mittel*? (2025)

- Wie groß ist der mittlere Gewinn bei einem Glücksspiel?
- Wie lange muss man bei einem wiederholten Zufallsexperiment im Mittel warten, bis ein bestimmtes Ereignis eintritt?
- Wie viele weitere Personen steckt eine infizierte Person im Mittel an?

Beispiel 7.1 **Ansteckungen** (2026)

- Die **Basisreproduktionszahl** R_0 gibt an, wie viele Personen eine infizierte Person im Mittel ansteckt, wenn es in der Bevölkerung keine Immunität gibt. Gemäß RKI gilt:

$$R_0 \in [2.8, 3.8]$$

(vor möglicherweise ansteckenderen Mutationen).

- Die **zeitabhängige Reproduktionszahl**

$$R = R(t)$$

berücksichtigt Effekte durch Hygienemaßnahmen, Impfungen und Immunität. Sie gibt an, wie viele Personen eine infizierte Person in einem Zeitfenster gegebener Länge im Mittel ansteckt.

- Die **Inzidenz** setzt Neuinfektionen in Relation zur Bevölkerungsgröße. Die *7-Tage-Inzidenz* gibt beispielsweise an, wie viele neu infizierte Personen es in den vergangenen sieben Tagen pro 100 000 Einwohner gegeben hat.

Beispiel 7.2 **1 × Würfeln mit einem fairen Würfel** (2025)

Da herrscht eine Gleichverteilung, daher ist die erwartete Augenzahl ist das arithmetische Mittel.

$$\Omega = \{1, \dots, 6\}$$

mit Gleichverteilung $\mathbb{P}$.

Die Zufallsvariable

$$X : \Omega \rightarrow \mathbb{R}, \quad X(\omega) = \omega,$$

besitzt das Bild

$$X(\Omega) = \{1, \dots, 6\} \subseteq \mathbb{R}.$$

Für einen fairen Würfel ist der Erwartungswert die mittlere Augenzahl, also das arithmetische Mittel:

$$E[X] = \frac{1 + 2 + 3 + 4 + 5 + 6}{6} = 3.5.$$

Die erwartete Augenzahl entspricht der mittleren Zahl von Schritten, die man in einem Würfelspiel pro Wurf vorwärtsgehen würde.

Beispiel 7.3 Spiel, bei dem nicht alle Ausgänge gleichwahrscheinlich sind (2025)

1 × Würfeln eines fairen Würfels

Auszahlung:

- k Euro, falls 2 gewürfelt
- 6 Euro, falls 2, $\dots$, 6 gewürfelt
- $\Omega = \{1, \dots, 6\}$ mit Gleichverteilung $\mathbb{P}$.

$\Omega = \{1, \dots, 6\}$ mit Gleichverteilung $\mathbb{P}$

Die Auszahlung wird beschrieben durch die ZV Y mit

$$Y(\omega) = k \cdot \chi_{\{1\}}(\omega) + 6 \cdot \chi_{\{2, \dots, 6\}}(\omega) \quad \forall \omega \in \Omega$$

Erwartete Auszahlung als arithmetisches Mittel:

$$\mathbb{E}[Y] = \sum_{\omega \in \Omega} Y(\omega) \mu(\omega) = \frac{k + 5 \cdot 6}{6} = 6 \cdot \frac{5}{6} + k \cdot \frac{1}{6} = 6 \cdot \mathbb{P}(Y = 6) + k \cdot \mathbb{P}(Y = k) = \sum_{I \in Y(\Omega)} I \cdot \mathbb{P}(Y = I)$$

Definition 7.1 (2025) Der Erwartungswert einer ZV X mit abzählbarem Bildbereich $X(\Omega) \in \mathbb{R}$ ist gegeben durch

$$\mathbb{E}[X] = \mathbb{E}X = \sum_{x \in X(\Omega)} x \cdot \mathbb{P}(X = x)$$

insofern die Reihe absolut konvergiert, also $\sum_{x \in X(\Omega)} |x| \cdot \mathbb{P}(X = x) < \infty$.

Wir sprechen in diesem Fall von der Existenz des Erwartungswerts.

Der Erwartungswert einer ZV X mit einer Dichte f ist gegeben durch

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x) dx = \lim_{N \rightarrow \infty} \int_{-N}^N x f(x) dx$$

insofern $\int_{-\infty}^{\infty} |x| f(x) dx < \infty$.

Wir sprechen in diesem Fall von der Existenz des Erwartungswerts.

Hinweis: Für Dichten f , die gerade Funktionen sind, gilt $\int_{-N}^N x f(x) dx = 0$ für alle N , auch wenn der Erwartungswert ggf. gar nicht existiert.

Bemerkung 7.1 (2026) Absolute Konvergenz der Reihe, die den Erwartungswert definiert, garantiert, dass wir die Summanden beliebig umsortieren dürfen. Es gilt daher

$$\mathbb{E}[X] \stackrel{\text{Def.}}{=} \sum_{x \in X(\Omega)} x \mathbb{P}(X = x) = \sum_{x \in \Omega} X(\omega) \mu(\omega)$$

sofern eine der Reihen absolut konvergent ist. (Vgl. obiges Bsp. mit dem Spiel.)

Wenn Ω oder $X(\Omega)$ endlich ist, so existiert der Erwartungswert automatisch.

Nimmt X nur nichtnegative Werte an, können wir einfach anfangen, den Erwartungswert auszurechnen, weil

$$\sum_{x \in X(\Omega)} |x| \mathbb{P}(X = x) = \sum_{x \in X(\Omega)} x \mathbb{P}(X = x)$$

bzw.

$$\int_{-\infty}^{\infty} |x| f(x) dx = \int_{-\infty}^{\infty} x f(x) dx = \int_0^{\infty} x f(x) dx$$

Beispiel 7.4 Erwartungswert der Poisson-Verteilung (2026)

X Poisson-verteilt, d.h., es existiert ein $\lambda > 0$ mit

$$\mu_X(k) = \mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} \quad \text{für alle } k \in \mathbb{N}_0 = \{0, 1, 2, 3, \dots\}$$

Der Erwartungswert existiert, weil die folgende Rechnung ein endliches Ergebnis hat:

(Wir verwenden in dieser Argumentation, dass X nur nichtnegative Werte hat, d.h., $X \geq 0$.)

$$\begin{aligned} \mathbb{E}[X] &\stackrel{*1}{=} \sum_{k=0}^{\infty} k \mathbb{P}(X = k) \\ &\stackrel{*2}{=} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \sum_{k=1}^{\infty} k \cdot \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} e^{-\lambda} \\ &= \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \\ &= \lambda e^{-\lambda} \underbrace{\sum_{l=0}^{\infty} \frac{\lambda^l}{l!}}_{=e^{\lambda}} \\ &= \lambda \end{aligned}$$

$$*1 \quad X(\Omega) = \mathbb{N}_0$$

$$*2 \quad \mathbb{P}(X = k) = \mu_X(k) = \dots$$

Beispiel 7.5 Erwartungswert der geometrischen Verteilung (2026)

Wie lange müssen wir im Mittel warten, bis der erste Erfolg eintritt? (Zum Beispiel bis zur ersten Sechse beim Werfen eines fairen Würfels? – Raten Sie!)

X geometrisch verteilt mit Erfolgswahrscheinlichkeit $p \in (0, 1)$, d.h.,

$$\mu_X(k) = \mathbb{P}(X = k) = p(1-p)^{k-1} \quad \text{für alle } k \in \mathbb{N}_0 = \{0, 1, 2, 3, \dots\}$$

Der Erwartungswert existiert, weil die folgende Rechnung ein endliches Ergebnis hat (Wir verwenden wieder, dass $X \geq 0$).

$$h(x) = x^k \Rightarrow h'(x) = kx^{k-1}$$

$$\begin{aligned} \mathbb{E}[X] &\stackrel{*1}{=} \sum_{k=1}^{\infty} k p (1-p)^{k-1} \\ &= p \sum_{k=1}^{\infty} \left(\frac{d}{dx} x^k \right) \Big|_{x=1-p} \\ &\stackrel{*2}{=} p \frac{d}{dx} \sum_{k=1}^{\infty} (x^k) \Big|_{x=1-p} \\ &= p \frac{d}{dx} \sum_{k=0}^{\infty} (x^k) \Big|_{x=1-p} \\ &= p \frac{d}{dx} \left(\frac{1}{1-x} \right) \Big|_{x=1-p} \\ &= p \frac{1}{(1-x)^2} \Big|_{x=1-p} \\ &= \frac{1}{p} \end{aligned}$$

*1 Definition Erwartungswert

*2 gilt, weil gliedweises Differenzieren einer Potenzreihe im Innern ihres Konvergenzradius zulässig ist

Beispiel 7.6 Erwartungswert der uniformen Verteilung auf $[a, b]$ (2026)

(Raten. – Warum ist der Erwartungswert $(a+b)/2$?)

Der Erwartungswert existiert, weil... Denn: Zu prüfen ist: $\int_{-\infty}^{\infty} |x|f(x) dx < \infty$ für $f(x) = \frac{1}{b-a}\chi_{[a,b]}(x)$.

Hier ist $f(x) = 0$ außerhalb eines kompakten Intervalls (abgeschlossen und beschränkt).

$$\int_{-\infty}^{\infty} |x|f(x) dx = \int_a^b \frac{|x|}{b-a} dx \leq \int_a^b \frac{\max\{|a|, |b|\}}{b-a} dx = \max\{|a|, |b|\} \cdot 1 < \infty$$

...f stetig ist auf dem kompakten Intervall $[a, b]$ und $f = 0$ außerhalb des Intervalls $[a, b]$ gilt.

$$\mathbb{E}[X] = \int_a^b x \frac{1}{b-a} dx = \frac{1}{2(b-a)} x^2 \Big|_{x=a}^b = \frac{b^2 - a^2}{2(b-a)} = \underbrace{\frac{a+b}{2}}_*$$

* Mittelpunkt des Intervalls

Erinnerung: $\int_a^b x dx = \frac{x^2}{2} \Big|_{x=a}^b$

Beispiel 7.7 Erwartungswert der Exponentialverteilung (2026)

Erinnerung:

$$F(x) := -e^{-\alpha x}, \quad F'(x) := \alpha e^{-\alpha x}, \quad \mathbb{E}[X] = \frac{1}{\alpha}$$

Der Erwartungswert existiert genau dann, wenn die folgende Berechnung einen endlichen Wert ergibt (was der Fall ist, wir verwenden wieder, dass $X \geq 0$):

$$\begin{aligned} \mathbb{E}[X] &= \int_0^\infty \underbrace{x}_{\downarrow} \underbrace{\alpha e^{-\alpha x}}_{\uparrow} dx \\ &= - \lim_{N \rightarrow \infty} \underbrace{xe^{-\alpha x}}_{=0} \Big|_{x=0}^N + \int_0^\infty \underbrace{1 \cdot e^{-\alpha x}}_{=f(x) \cdot \frac{1}{\alpha}} dx \\ &= 0 + \frac{1}{\alpha} \underbrace{\int_{-\infty}^\infty f(x) dx}_{=1} \\ &= \frac{1}{\alpha}^* \end{aligned}$$

$$\begin{aligned} *f(x) &= \alpha e^{-\alpha x} \chi_{[0, \infty)}(x) \\ \Rightarrow \int_0^\infty e^{-\alpha x} dx &= \frac{1}{\alpha} \int_0^\infty \alpha e^{-\alpha x} dx \\ &= \frac{1}{\alpha} \int_{-\infty}^\infty f(x) dx \\ &= \frac{1}{\alpha} \end{aligned}$$

Satz 7.1 Der Erwartungswert ist linear (2026)

Geg. ZVs $X : \Omega \rightarrow \mathbb{R}$ und $Y : \Omega \rightarrow \mathbb{R}$ auf $(\Omega, \mathbb{P})$; Konstanten $a, b \in \mathbb{R}$.

Annahme: $\mathbb{E}[X]$ und $\mathbb{E}[Y]$ existieren.

Dann gelten $aX + bY$ ist ebenfalls eine Zufallsvariable. Der Erwartungswert von $aX + bY$ existiert und berechnet sich als

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

Beweis (für Zufallsvariable mit abzählbarem Bildbereich) Nehmen wir zunächst an, der Erwartungswert von $aX + bY$ existiert. Dann dürfen alle Reihen beliebig umsortiert werden:

$$\begin{aligned} \mathbb{E}[aX + bY] &= \sum_{\omega \in \Omega} [aX(\omega) + bY(\omega)] \mu(\omega) \\ &= a \sum_{\omega \in \Omega} X(\omega) \mu(\omega) + b \sum_{\omega \in \Omega} Y(\omega) \mu(\omega) \\ &= a\mathbb{E}[X] + b\mathbb{E}[Y] \end{aligned}$$

Eine analoge Rechnung mit Betragszeichen und Abschätzungen zeigt die Existenz des Erwartungswerts:

$$\sum_{\omega \in \Omega} \underbrace{|aX(\omega) + bY(\omega)|}_{\leq |a||X(\omega)| + |b||Y(\omega)|} \mu(\omega) \leq |a| \underbrace{\sum_{\omega \in \Omega} |X(\omega)| \mu(\omega)}_{< \infty \text{ unab. Ver.}} + |b| \underbrace{\sum_{\omega \in \Omega} |Y(\omega)| \mu(\omega)}_{< \infty \text{ unab. Ver.}} < \infty$$

da nach Voraussetzung $\mathbb{E}[X]$ und $\mathbb{E}[Y]$ existieren.

Beispiel 7.8 Augensumme bei mehrfachem Würfeln mit fairem Würfel (2026)

$$\Omega = \{1, \dots, 6\}^n$$

mit Gleichverteilung P .

Für $i = 1, \dots, n$ sei

$$X_i(\omega) = \omega_i,$$

wobei $\omega = (\omega_1, \dots, \omega_n) \in \Omega$.

Die Zufallsvariable

$$X = \sum_{i=1}^n X_i$$

beschreibt die Augensumme (Und X_i das Ergebnis des i -ten Wurfs) .

Berechnung der erwarteten Augensumme für zweimaliges Würfeln ($n = 2$):

Direkt über die Verteilung:

$$E[X] = \sum_{i=2}^{12} i \mathbb{P}(X_1 + X_2 = i) = \dots$$

was etwas aufwendig ist.

Alternativ:

$$\begin{aligned} E[X] &= \sum_{\omega \in \Omega} (X_1(\omega) + X_2(\omega)) \mu(\omega) \\ &= \frac{1}{36} \sum_{\omega_1, \omega_2=1}^6 [\omega_1 + \omega_2] \\ &= \frac{1}{36} \sum_{\omega_1=1}^6 \sum_{\omega_2=1}^6 (\omega_1 + \omega_2) \\ &= \frac{1}{36} \left[6 \sum_{\omega_1=1}^6 \omega_1 + 6 \sum_{\omega_2=1}^6 \omega_2 \right] \\ &= \frac{1}{36} (6 \cdot 21 + 6 \cdot 21) = 7. \end{aligned}$$

Mit der Linearität des Erwartungswertes erhält man sofort:

$$E[X] = E[X_1] + E[X_2] = 2 \cdot 3,5 = 7.$$

Dies verallgemeinert sich unmittelbar auf n -maliges Würfeln:

$$E[X] = E[X_1 + \dots + X_n] = E[X_1] + \dots + E[X_n] = n \cdot \frac{7}{2}.$$

Beispiel 7.9 Binomialverteilung $\mathbb{E}[X] = n \cdot p$ (2026)

$$X(\Omega) = \{0, \dots, n\}, \quad \#X(\Omega) = n + 1 < \infty$$

- X sei binomialverteilt mit den Parametern n und p .
- Der Erwartungswert* von X existiert, da der Bildbereich von X endlich ist.

erwartete Anzahl an Erfolgen in einem n -fach unabhängig wiederholten Bernoulli-Experiment

1. Versuch (mit binomischer Formel und etwas Geschick)

$$\mathbb{E}[X] = \sum_{k=0}^n k \underbrace{\binom{n}{k} p^k (1-p)^{n-k}}_{=\mathbb{P}(X=x)} = \dots$$

2. Versuch Wähle

$$\Omega = \{0, 1\}^n.$$

Die Anzahl der Erfolge lässt sich darstellen als

$$X = \sum_{i=1}^n X_i,$$

wobei

$$X_i(\omega) = \omega_i.$$

Für jede Indikatorvariable gilt

$$E[X_i] = 0 \cdot \mathbb{P}(X_i = 0) + 1 \cdot \mathbb{P}(X_i = 1) = p.$$

Mit der Linearität des Erwartungswertes folgt unmittelbar:

$$E[X] = \sum_{i=1}^n \underbrace{E[X_i]}_{=p} = \sum_{i=1}^n p = np.$$

Beispiel 7.10 St. Petersburg Paradoxon (Erwartungswert muss nicht existieren) (2026)

Ein Casino möchte folgendes Spiel anbieten: Eine faire Münze wird geworfen, bis zum ersten Mal Kopf erscheint. Passiert dies beim n -ten Wurf, so sei die Auszahlung $X = 2^n$

$$\Omega = \mathbb{N}, \quad \mu(n) = p(1-p)^{n-1}, \quad p = \frac{1}{2}.$$

Die Zufallsvariable $X : \Omega \rightarrow \mathbb{R}$ sei definiert durch $X(n) = 2^n$ (Auszahlung) für alle $n \in \Omega$

$$\mu_X(2^n) = \mathbb{P}(\underbrace{X = 2^n}_{\text{Kopf erstmalig im } n\text{-ten Wurf}}) = \mu(n) = p(1-p)^{n-1} = 2^{-n}, \quad n \in \Omega = \mathbb{N}.$$

$$\mu(n) = \left(\frac{1}{2}\right)^n = 2^{-n} \quad \forall n \in \Omega = \mathbb{N}$$

Was wäre ein fairer Einsatz für dieses Spiel? (Wir nennen den Einsatz fair, wenn der Einsatz gleich der erwarteten Auszahlung ist.)

Wir suchen also $\mathbb{E}[X]$

$X \geq 0$, EW existiert genau dann, wenn Rechnung endliches Ergebnis hat

Nun ist jedoch

$$\sum_{n=1}^{\infty} 2^n \mathbb{P}(X = 2^n) = \sum_{n=1}^{\infty} 2^n \mu_X(2^n) = \sum_{n=1}^{\infty} 2^n 2^{-n} = \sum_{n=1}^{\infty} 1 = \infty$$

Der Erwartungswert existiert also nicht. Ein fairer Einsatz kann nicht bestimmt werden.

Erinnerung 7.1 (2026)

Aus Satz (E), d.h. der Linearität des Erwartungswertes, folgen:

$$\mathbb{E}[aX] = a\mathbb{E}[X] \quad \text{und} \quad \mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$$

für $a \in \mathbb{R}$ und $\mathbb{R}$ -wertige X und Y mit existierendem Erwartungswert

Frage 7.1 (2026) Gilt auch $\mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y]$?

Spezialfall $X = Y$: $\mathbb{E}[E^2] = (\mathbb{E}[X])^2$.

Gilt das?

Beispiel 7.11 (2026) Es gibt Zufallsvariablen X, Y mit

$$\mathbb{E}[X \cdot Y] \neq \mathbb{E}[X] \cdot \mathbb{E}[Y].$$

Wähle

$$\mathbb{P}(X = +1) = \mathbb{P}(X = -1) = \frac{1}{2}$$

und

$$Y = X.$$

Dann gilt

$$\mathbb{E}[X] = \mathbb{E}[Y] = 0$$

und

$$\mathbb{E}[XY] = \mathbb{E}[X^2] = \mathbb{E}[1] = 1.$$

Satz 7.2 Satz (P) (2026)

Seien

$$X : \Omega \rightarrow \mathbb{R} \quad \text{und} \quad Y : \Omega \rightarrow \mathbb{R}$$

zwei unabhängige Zufallsvariablen, deren Erwartungswerte existieren.

Dann existiert auch der Erwartungswert von $X \cdot Y$, und es gilt

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y].$$

Beweis.

Schritt 1: Wir nehmen zunächst an, dass der Erwartungswert von $X \cdot Y$ existiert.

Wir beginnen mit der folgenden Darstellung. Für $z \neq 0$ gilt: ($xy = z$)

$$\begin{aligned} \mathbb{P}(XY = z) &= \sum_{y \neq 0}^* \mathbb{P}(XY = z \mid Y = y) \mathbb{P}(Y = y) \\ &= \sum_{y \neq 0} P\left(X = \frac{z}{y} \mid Y = y\right) \mathbb{P}(Y = y) \\ &= \sum_{y \neq 0} P\left(X = \frac{z}{y}\right) \mathbb{P}(Y = y), \end{aligned}$$

da X und Y unabhängig sind.

$$\mathbb{P}(X \cdot Y = z) = \sum_{y \in Y(\Omega)} \mathbb{P}(X \cdot Y = z, Y = y) \stackrel{z \neq 0}{=} \sum_{y \in Y(\Omega), y \neq 0} \mathbb{P}(X \cdot Y = z \mid Y = y) \cdot \mathbb{P}(Y = y)$$

Aus

$$\mathbb{P}(XY = z) = \sum_{y \neq 0} P\left(X = \frac{z}{y}\right) \mathbb{P}(Y = y), \quad z \neq 0,$$

folgt

$$\begin{aligned}\mathbb{E}[XY] &= \sum_{z \in XY(\Omega), z \neq 0} z \mathbb{P}(XY = z) \\ &= \sum_{z \neq 0} \sum_{y \neq 0} \frac{z}{y} y P\left(X = \frac{z}{y}\right) \mathbb{P}(Y = y) = \sum_{y \neq 0} \sum_{x \neq 0} xy \mathbb{P}(X = x) \mathbb{P}(Y = y) = \left(\sum_{y \neq 0} y \mathbb{P}(Y = y)\right) \left(\sum_{x \neq 0} x \mathbb{P}(X = x)\right) = \mathbb{E}[X] \cdot \mathbb{E}[Y].\end{aligned}$$

Schritt 2: Eine analoge Rechnung zeigt die Existenz des Erwartungswerts:

Satz 7.3 **Kurzfassung Satz (P)** (2026)

$$X, Y \text{ unabhängig mit ex. EW} \implies \mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y].$$

Beispiel 7.12 (2026)

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$$

impliziert nicht, dass X und Y unabhängig sind.

- Definiere Hilfszufallsvariablen X_1 und Y_1 , unabhängig mit

$$\mathbb{P}(X_1 = 0) = \mathbb{P}(X_1 = 1) = \frac{1}{2}$$

und

$$\mathbb{P}(Y_1 = 0) = \mathbb{P}(Y_1 = 1) = \frac{1}{2}.$$

- Setze

$$X := X_1 + Y_1, \quad Y := |X_1 - Y_1|.$$

Beobachtungen

- Bildbereiche:

$$X(\Omega) = \{0, 1, 2\}, \quad Y(\Omega) = \{0, 1\}.$$

-

$$Y = 0 \iff X_1 = Y_1 \iff X \in \{0, 2\}.$$

-

$$Y = 1 \iff X_1 \neq Y_1 \iff X = 1.$$

X und Y sind nicht unabhängig.

$$\mathbb{P}(X = 1, Y = 0) = 0,$$

da

$$\{X = 1, Y = 0\} = \emptyset.$$

Andererseits gilt

$$\mathbb{P}(X = 1) = 2 \cdot \frac{1}{4} > 0$$

und

$$\mathbb{P}(Y = 0) = 2 \cdot \frac{1}{4} > 0.$$

Dennoch gilt $\mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y]$.

$$\begin{aligned}\mathbb{E}[XY] &= 0 \cdot \mathbb{P}(XY = 0) + 1 \cdot \mathbb{P}(XY = 1) + 2 \cdot \mathbb{P}(XY = 2) \\ &= 0 + \mathbb{P}(X = 1) + 0 \\ &= \frac{1}{2}.\end{aligned}$$

Außerdem

$$\begin{aligned}\mathbb{E}[X] \mathbb{E}[Y] &= (\mathbb{E}[X_1] + \mathbb{E}[Y_1]) \mathbb{P}(Y = 1) \\ &= 2 \mathbb{E}[X_1] \mathbb{P}(X = 1) \\ &= 2 \cdot \frac{1}{2} \cdot \frac{1}{2} \\ &= \frac{1}{2}.\end{aligned}$$

Bemerkung 7.2 (2026)

Der Satz kann nicht nur zum Berechnen von Erwartungswerten von Produkten unabhängiger Zufallsvariablen verwendet werden, sondern kann auch benutzt werden, um zu zeigen, dass zwei Zufallsvariablen nicht unabhängig sein können, wenn der Erwartungswert des Produkts der Zufallsvariablen nicht ins Produkt der einzelnen Erwartungswerte zerfällt.

Definition 7.2 Zusammengesetzte Zufallsvariablen (2026)

Eine Zufallsvariable $X : \Omega \rightarrow \mathbb{R}$ und eine messbare Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$ können zusammengesetzt werden zu einer neuen Zufallsvariablen:

$$Y(\omega) = (f \circ X)(\omega) = f(X(\omega))$$

$$Y(\omega) = f(X(\omega)) \quad \forall \omega$$

Satz 7.4 (2026)

Sofern der Erwartungswert $\mathbb{E}[Y]$ existiert, gilt

$$\mathbb{E}[Y] = \sum_{x \in X(\Omega)} f(x) \mathbb{P}(X = x)$$

bzw., falls X Dichte d hat und EW von Y gleich $f(x)$ existiert

$$\mathbb{E}[Y] = \int_{-\infty}^{\infty} f(x) d(x) dx$$

Beweis.

$$\begin{aligned}\mathbb{E}[Y] &= \sum_{y \in Y(\Omega)} y \mathbb{P}(Y = y) \\&= \sum_{y \in Y(\Omega)} y \sum_{x \in X(\Omega): f(x)=y} \mathbb{P}(X = x) \\&= \sum_{y \in Y(\Omega)} \sum_{x \in X(\Omega): f(x)=y} \underbrace{y}_{=f(x)} \mathbb{P}(X = x) \\&= \sum_{y \in Y(\Omega)} \sum_{x \in X(\Omega): f(x)=y} f(x) \mathbb{P}(X = x) \\&= \sum_{x \in X(\Omega)} f(x) \mathbb{P}(X = x) \\&= \mathbb{E}[f(x)]\end{aligned}$$

$$*Y = y \Leftrightarrow f(x) = y, \quad \mathbb{P}(Y = y) = \sum_{x \in X(\Omega): f(x)=y} \mathbb{P}(X = x)$$

Beispiel 7.13 Zu Satz 7.4.

Mit $f(x) = x^2$

Definition 7.3 **n-tes Moment von X** (2026)

Für $n \in \mathbb{N}$ heißt $\mathbb{E}[X^n]$ das erste n-te Moment von X , insofern $\mathbb{E}[|X|^n] < \infty$. (Erwartungswert ist das 1. Moment)

Definition 7.4 (2026) $\mathbb{E}[(X - \mathbb{E}[X])^n]$ heißt das n-te zentrierte Moment von X . Es existiert, wenn $\mathbb{E}[|X|^n] < \infty$.

Definition 7.5 (2026) Die Varianz von X ist das 2 zentrierte Moment, d.h.

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

(mittlere quadratische Abweichung)

Die Varianz von X existiert, wenn $\text{Var}(X) < \infty$.

Die Varianz einer Zufallsvariable X mit existierendem Erwartungswert ist gegeben durch

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x)$$

(gewichtete quadratische Abweichung vom Erwartungswert) bzw.

$$\text{Var}(X) = \int_{-\infty}^{\infty} \underbrace{(x - \mathbb{E}[X])^2}_{=f(x)} d(x) dx$$

Bemerkung 7.3 (2026) $\text{Var}(X) \geq 0$

Definition 7.6 **Existierende Varianz** (2025)

Wir sagen, dass die Varianz existiert, wenn

$$\text{Var}(X) = \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x) < \infty$$

bzw.

$$\int_{-\infty}^{\infty} (x - \mathbb{E}[X])^2 d(x) < \infty$$

Beispiel 7.14 Bsp. (2026)

Seien X, Y Zufallsvariablen mit

$$\mathbb{P}(X = +1) = \frac{1}{2} = \mathbb{P}(X = -1)$$

und

$$Y = 100 \cdot X.$$

Anhand des Erwartungswertes: kein Unterschied!

$$\mathbb{E}[X] = 1 \cdot \mathbb{P}(X = 1) + (-1) \cdot \mathbb{P}(X = -1) = 1 \cdot \frac{1}{2} - 1 \cdot \frac{1}{2} = 0.$$

Da $Y = 100X$ gilt,

$$\mathbb{E}[Y] = 100 \cdot \mathbb{E}[X] = 0.$$

Die Varianz zeigt den Unterschied:

da $\mathbb{E}[X] = 0$,

$$\text{Var}(X) = \mathbb{E} \left[\underbrace{(X - \mathbb{E}[X])^2}_{=0} \right] = \mathbb{E} \left[\underbrace{X^2}_1 \right] = \mathbb{E}[1] = 1$$

Wegen $X \in \{-1, 1\}$ ist

$$X^2 = 1,$$

also

$$\text{Var}(X) = \mathbb{E}[1] = 1.$$

Ebenso gilt wegen $\mathbb{E}[Y] = 0$,

$$\text{Var}(Y) = \mathbb{E}[(Y - \mathbb{E}[Y])^2] = \mathbb{E}[Y^2] = \mathbb{E}[(100X)^2]$$

Damit folgt

$$\text{Var}(Y) = \mathbb{E}[100^2 X^2] = 100^2 \mathbb{E}[X^2] = 100^2.$$

Beispiel 7.15 Bernoulli-Variable (Spezialfall der Binomialverteilung mit $n = 1$) (2026)

Zufallsvariable X mit $\mathbb{P}(X = +1) = p = 1 - \mathbb{P}(X = 0)$ für Erfolgswahrscheinlichkeit $p \in [0, 1]$ und $\mathbb{E}[X] = p$.

$Var(X)$ existiert, da

$$\begin{aligned} Var(X) &= \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x) \\ &= (0 - \underbrace{\mathbb{E}[X] = p})^2 \underbrace{\mathbb{P}(X = 0)} = 1 - p + (1 - \underbrace{\mathbb{E}[X] = p})^2 \underbrace{\mathbb{P}(X = 1)} = p \\ &= p^2(1 - p) + (1 - p)^2 p \\ &= p(1 - p)[p + (1 - p)] \\ &= p(1 - p) < \infty \end{aligned}$$

$$\begin{aligned} Var(X) &= (1 - \mathbb{E}[X])^2 p + (0 - \mathbb{E}[X])^2 (1 - p) \\ &= (1 - p)^2 p + p^2 (1 - p) \\ &= p(1 - p) \end{aligned}$$

Beispiel 7.16 gleichverteilte Zufallsvariable auf $\{1, \dots, n\}$ (2026)

Zufallsvariable X mit $\mathbb{P}(X = k) = \frac{1}{n}$ für $k = 1, \dots, n$

$$\mathbb{E}[X] = \sum_{k=1}^n k \cdot \frac{1}{n} = \frac{n(n+1)}{2n} = \frac{n+1}{2}$$

und

$$Var(X) = \frac{n^2 - 1}{12}$$

weil

$$\begin{aligned} Var(X) &= \frac{1}{n} \sum_{k=1}^n (k - \mathbb{E}[X])^2 \\ &= \frac{1}{n} \sum_{k=1}^n (k^2 - 2k\mathbb{E}[X] + \mathbb{E}[X]^2) \\ &= \frac{1}{n} \sum_{k=1}^n k^2 - 2\mathbb{E}[X] \cdot \underbrace{\frac{1}{n} \sum_{k=1}^n k}_{=\mathbb{E}[X]} + \mathbb{E}[X]^2 \\ &= \frac{(n+1)(2n+1)}{6} - \mathbb{E}[X]^2 \\ &= \frac{n^2 - 1}{12} \end{aligned}$$

Lemma 7.1 Technisches Lemma (2026)

Für alle $a \in \mathbb{R}$ gilt $\mathbb{E}[(X - a)^2] = Var(X) + (\mathbb{E}[X] - a)^2$

Beweis TODO F 76

Folgerung 7.1 Folgerung I (2026)

$a \Leftrightarrow \mathbb{E}[(X - a)^2]$ wird minimal für $a = \mathbb{E}[X]$.

In diesem Fall ist $\mathbb{E}[(X - a)^2] = Var(X)$ per Definition der Varianz.

Folgerung 7.2 Folgerung II und wichtige Rechenregel (2026)

Die Wahl $a = 0$ zeigt

$$0 \leq \text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Es gilt daher stets $(\mathbb{E}[X])^2 \leq \mathbb{E}[X^2]$.

Satz 7.5 Satz (V) (2026)

Seien X, Y diskrete (?) Zufallsvariablen mit existierendem Erwartungswert, $a, b \in \mathbb{R}$.

(a) $\text{Var}(aX + b) = a^2 \text{Var}(X)$

$$\begin{aligned} \text{Var}(aX + b) &= \mathbb{E}[(aX + b - \mathbb{E}[aX + b])^2] \\ &= \mathbb{E}[(a(X - \mathbb{E}[X]))^2] \\ &= a^2 \mathbb{E}[(X - \mathbb{E}[X])^2] \\ &= a^2 \text{Var}(X) \end{aligned}$$

(b) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$ mit Kovarianz $\text{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$.

$$\begin{aligned} \text{Var}(X + Y) &= \mathbb{E}[(X + Y - \mathbb{E}[X + Y])^2] \\ &= \mathbb{E}[(X - \mathbb{E}[X])^2] + 2\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] + \mathbb{E}[(Y - \mathbb{E}[Y])^2] \\ &= \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y) \end{aligned}$$

(c) X und Y unabhängig $\Rightarrow \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$.

$$X \text{ und } Y \text{ unabhängig} \Rightarrow X - \mathbb{E}[X], Y - \mathbb{E}[Y] \text{ unabh.}$$

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \\ &\stackrel{(P)}{=} \mathbb{E}[X - \mathbb{E}[X]] \mathbb{E}[Y - \mathbb{E}[Y]] \\ &= 0 \end{aligned}$$

(d) Für diskrete Zufallsvariablen gilt:

$$\text{Var}(X) = 0 \Rightarrow \text{Es existiert eine Konstante } c \text{ mit } \mathbb{P}(X = c) = 1.$$

$$c = \mathbb{E}[X]$$

Beweis für (a) bis (c): Verwende $\text{Var}(Z) = \mathbb{E}[(Z - \mathbb{E}[Z])^2]$ und die Rechenregeln für den EW.

Beweis für (d): $0 = \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 \mathbb{P}(X = x).$

Alle Summanden sind ≥ 0 , folglich impliziert $\mathbb{P}(X = x) > 0$ sofort $x = \mathbb{E}[X]$, da die Summe nicht 0 sein könnte, wenn ein Summand nicht 0 wäre. Also muss jedes $(x - \mathbb{E}[X])^2 \mathbb{P}(X = x)$ sein und wenn $\mathbb{P}(X = x) > 0$, muss also $(x - \mathbb{E}[X])^2 = 0$ sein, also muss $x - \mathbb{E}[X] = 0$ sein, also $x = \mathbb{E}[X]$.

Damit ist gezeigt, dass $\mathbb{P}(X = \mathbb{E}[X]) = 1$, da jedes $x \in X$ gleich $\mathbb{E}[X]$ ist.

Kann nicht gelten, wenn f Dichte hat

Beispiel 7.17 Binomialverteilte Zufallsvariable S_n mit Parametern n und p (2026)

$$\Omega = \{0, 1\}^n \text{ und}$$

$$p(\omega) = p^{\sum_{i=1}^n \omega_i} (1 - p)^{n - \sum_{i=1}^n \omega_i}$$

Darstellung:

$$S_n = \sum_{i=1}^n X_i$$

mit

$$X_i(\omega) = \omega_i \quad \text{für alle } \omega \in \Omega.$$

Dabei sind die X_i unabhängig mit

$$\mathbb{P}(X_i = 1) = p$$

und

$$\mathbb{P}(X_i = 0) = 1 - p = q$$

für alle i .

$$\mathbb{E}[X] = \sum_{i=1}^n \mathbb{E}[X_i] = np$$

nach Satz (E).

Unter Verwendung der Unabhängigkeit der X_i folgt ohne weitere Arbeit aus Satz (V) (??)

$$\text{Var}(X) = \sum_{i=1}^n \underbrace{\text{Var}(X_i)}_{=pq} = npq$$

Beispiel 7.18 Poisson-verteilte Zufallsvariable X mit Parameter $\lambda > 0$ (2026)

$$\mathbb{E}[X] = \lambda = \text{Var}(X)$$

Trick:

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \mathbb{E}[X(X-1)] + \mathbb{E}[X] - (\mathbb{E}[X])^2$$

Wir wissen bereits:

$$\mathbb{E}[X] = \lambda \quad \text{und} \quad (\mathbb{E}[X])^2 = \lambda^2$$

Die Behauptung folgt daher aus

$$\mathbb{E}[X(X-1)] = \sum_{k=2}^{\infty} k(k-1) \frac{\lambda^k}{k!} e^{-\lambda} = \lambda^2 \sum_{l=0}^{\infty} \frac{\lambda^l}{l!} e^{-\lambda} = \lambda^2$$

und damit

$$\text{Var}(X) = \mathbb{E}[X(X-1)] + \mathbb{E}[X] - (\mathbb{E}[X])^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

Beispiel 7.19 geometrisch verteilte Zufallsvariable X mit Erfolgswahrscheinlichkeit p (2026)

$$\mathbb{E}[X] = \frac{1}{p} \quad \text{und} \quad \text{Var}(X) = \frac{1-p}{p^2}$$

(Nicht auswendig lernen)

Beispiel 7.20 auf $[a, b]$ uniform verteilte Zufallsvariable X (2026)

Dann ist

$$\mathbb{E}[X] = \frac{a+b}{2}$$

und

$$\begin{aligned}\mathbb{E}[X^2] &= \int_a^b x^2 \frac{1}{b-a} dx \\ &= \frac{1}{3(b-a)} x^3 \Big|_{x=a}^b \\ &= \frac{b^3 - a^3}{3(b-a)} \\ &= \frac{1}{3}(a^2 + ab + b^2)\end{aligned}$$

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{a^2 + ab + b^2}{3} - \frac{a^2 + 2ab + b^2}{4} = \frac{(a-b)^2}{12}^*$$

* Nicht auswendig lernen.

Beispiel 7.21 Exponentialverteilte Zufallsvariable X (2026)

$$\mathbb{E}[X] = \frac{1}{\alpha}$$

$$\begin{aligned}\mathbb{E}[X^2] &= \int_0^\infty \underbrace{x^2}_{\downarrow} \underbrace{\alpha e^{-\alpha x}}_{\uparrow} dx \\ &= - \lim_{N \rightarrow \infty} x^2 e^{-\alpha x} \Big|_{x=0}^N + 2 \int_0^\infty x e^{-\alpha x} dx \\ &= 0 + \frac{2}{\alpha} \mathbb{E}[X] \\ &= \frac{2}{\alpha^2}\end{aligned}$$

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \frac{2}{\alpha^2} - \left(\frac{1}{\alpha}\right)^2 = \frac{1}{\alpha^2}$$

Ende der Vorlesung vom 5. Juni 2026

Satz 7.6 (2026) TODO F 98–100

KAPITEL 8

Varianz und Kovarianz

8.1 | Vorlesung 8

Grenzwertsätze

Vorlesung 13. Juni 2025 (V09 2025) und 12. Juni 2026 (V08 2026)

Satz 9.1 Markoffsche Ungleichung (2026)

Sei X eine Zufallsvariable. $\mathbb{E}[|X|^k]$ existiert für ein $k \in \mathbb{N}$. Dann existiert auch der Erwartungswert $\mathbb{E}[X]$, und es gilt

$$\mathbb{P}(\underbrace{|X - \mathbb{E}[X]|}_{*} \geq h) \leq \frac{\mathbb{E}[|X - \mathbb{E}[X]|^k]}{h^k} \quad \forall h > 0$$

* Menge aller $\omega \in \Omega$ derart, dass $X(\omega)$ um mindestens h von ihrem EW $\mathbb{E}[X]$ abweicht.

Satz 9.2 Tschebyscheffsche Ungleichung (Spezialfall $k = 2$) (2026)

Für eine Zufallsvariable X , deren Erwartungswert und Varianz existieren, gilt

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq h) \leq \frac{\text{Var}(X)}{h^2} \quad \forall h > 0$$

Beweis: Spezialfall diskreter Wahrscheinlichkeitsraums

$$\begin{aligned} \mathbb{P}(|X - \mathbb{E}[X]| \geq h) &= \sum_{\omega \in \Omega: |X(\omega) - \mathbb{E}[X]| \geq h} \mu(\omega) \\ &= \sum_{x \in X(\Omega): |x - \mathbb{E}[X]| \geq h} \mathbb{P}(\{\omega \in \Omega : X(\omega) = x\}) \\ &\leq \sum_{x \in X(\Omega): |x - \mathbb{E}[X]| \geq h} \left(\frac{|x - \mathbb{E}[X]|}{h} \right)^2 \mathbb{P}(X = x) \\ &\leq \frac{1}{h^2} \sum_{x \in X(\Omega)} |x - \mathbb{E}[X]|^2 \mathbb{P}(X = x) \\ &\leq \frac{1}{h^2} \text{Var}(X) \end{aligned}$$

Beispiel 9.1 Die Tschebyscheffsche Ungleichung kann nicht verbessert werden (2026)

Sei $N \in \mathbb{N}$ beliebig und die Zufallsvariable X mit $X(\Omega) = \{-N, 0, +N\}$ und $\mathbb{P}(X = \pm N) = \frac{1}{2N^2}$

$$\begin{aligned} \mathbb{P}(X = +N) &= \frac{1}{2N^2} \\ \mathbb{P}(X = -N) &= \frac{1}{2N^2} \\ \mathbb{P}(X = 0) &= 1 - \frac{1}{N^2} \end{aligned}$$

Aus $\mathbb{E}[X] = 0$ folgt

$$\text{Var}(X) = N^2 \mathbb{P}(X = -N) + N^2 \mathbb{P}(X = +N) = 1$$

Denn

$$\text{Var}(X) = \mathbb{E}[X^2] = N^2 \mathbb{P}(X^2 = N) = N^2 \frac{2}{2N^2} = 1$$

Für jedes $h \in (0, N]$ gilt

$$\begin{aligned} \mathbb{P}(|X - \underbrace{\mathbb{E}[X]}_{=0}| \geq h) &= \mathbb{P}(|X - \mathbb{E}[X]| > 0) \\ &= \mathbb{P}(X = N) + \mathbb{P}(X = -N) \\ &= \frac{1}{N^2} \\ &= \frac{\overbrace{\text{Var}(X)}^{=1}}{N^2} \\ &\leq \frac{1}{h^2} \text{Var}(X) \end{aligned}$$

Die Wahl $h = N$ zeigt: Ungleichung kann nicht verbessert werden.

Die Wahl $h = 2N$ dagegen zeigt, dass sie nicht immer gut ist:

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq 2N) = \mathbb{P}(|X| > N) = 0 < \frac{1}{(2N)^2} = \frac{\text{Var}(X)}{(2N)^2}$$

Beispiel 9.2 Werfen eines fairen Würfels (2026)

Wie oft müssen wir einen fairen Würfel werfen, bis mit Ws. $\geq 1 - 0.05$ die relative Häufigkeit einer Sechs um weniger als $1/10$ von $1/6$ abweicht?

Ansatz: $\Omega = \{1, \dots, 6\}^N$ mit Gleichverteilung $\mathbb{P}$ (für N Würfe) und Zufallsvariablen $X_i \Omega \rightarrow \{0, 1\}$.

Dabei sind $X_i(\omega) = 1_{\{6\}}(\omega_i)$ unabhängig und identisch verteilt (u.i.v.) mit $\mathbb{P}(X_i = 1) = \frac{1}{6}$.

$S_N = \sum_{i=1}^N X_i$ ist die Anzahl der geworfenen Sechsen und $\frac{1}{N} S_N$ ist die relative Häufigkeit einer Sechs.

Gesucht ist das kleinste N derart, dass $\mathbb{P}(|\frac{S_N}{N} - \frac{1}{6}| \geq \frac{1}{10}) \leq \frac{5}{100}$ (Gegenereignis zu $\mathbb{P}(|\frac{S_N}{N} - \frac{1}{6}| < \frac{1}{10}) \geq 1 - \frac{5}{100}$).

Lösung: für Tschebyscheffsche Ungleichung in Bezug auf EW und Var

Seien $p = 1/6$ und $q = 1 - p = 5/6$ und sei S_N binomialverteilt mit Parametern N und p . Dann ist

$$\mathbb{E}\left[\frac{1}{N} S_N\right] = \frac{1}{N} \mathbb{E}[S_N] \stackrel{*}{=} \frac{1}{N} Np = p = 1/6$$

* da S_N binomialverteilt ist und

$$\text{Var}\left(\frac{1}{N} S_N\right) = \frac{1}{N} \text{Var}(S_N) \stackrel{**}{=} \frac{1}{N} Npq = \frac{1}{N} pq = \frac{1}{N} \frac{1}{6} \frac{5}{6}$$

** Ebenfalls, weil S_N binomialverteilt ist.

Tschebyscheffsche Ungleichung:

$$\mathbb{P}\left(\underbrace{\left|\frac{S_N}{N} - \frac{1}{6}\right|}_{\text{Gegenereignis}} \geq \frac{1}{10}\right) \leq \frac{\text{Var}\left(\frac{S_N}{N}\right)}{(1/10)^2} = 100 \frac{5}{36N}$$

Wir wählen also N so groß, dass $100 \frac{5}{36N} \leq \frac{5}{100}$.

Fazit Jedes $N \approx 278$ (genauer aus der Abschätzung $(100)^2/36 \approx 277.7$) garantiert, dass mit Wahrscheinlichkeit ≥ 0.95 die relative Häufigkeit einer Sechsen bei N -maligem Würfeln um weniger als $1/10$ von $1/6$ abweicht.

Wenn wir $N = 278$ wählen, sind wir auf der sicheren Seite.

Da wir abgeschätzt haben, ist dieses N möglicherweise nicht das minimale.

Satz 9.3 Schwaches Gesetz der großen Zahlen (2025)

Gegeben Zufallsvariablen $X_1, X_2, X_3, \dots$ auf einem $(\Omega, \mathbb{P})$. Dabei muss die Verteilung der X_i nicht identisch sein. Es gilt $S_n = \sum_{i=1}^n X_i$

Angenommen alle Erwartungswerte $\mathbb{E}[X_i]$ existieren mit $\mathbb{E}[X_i] = \mathbb{E}[X_1]$ (es sind also alle gleich) für alle $i \in \mathbb{N}$. $\exists C > 0$ mit $\text{Var}(X_i) \leq C$ für alle $i \in \mathbb{N}$. (Beachte $\text{Var}(X_i) < \infty \Rightarrow \mathbb{E}[X_i]$ ex.)

Die Zufallsvariablen sind paarweise unkorreliert (Also wenn $\text{Cov}(X_i, X_j) = 0$ für $i \neq j$):

$$\mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])] = 0, \quad \text{für alle } i \neq j$$

Dann gilt:

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\frac{1}{n}S_n - \mathbb{E}[X_1]| \geq \epsilon) = 0 \quad \forall \epsilon > 0$$

S_n : arithmetisches Mittel und $\frac{1}{n}S_n$ relative Häufigkeit, falls x_i Bernoulli-verteilt

Soll heißen.: Generell ist $\frac{1}{n}S_n$ das arithmetische Mittel, aber bei einer Bernoulli-Verteilung ist $\frac{1}{n}S_n$ auch gleichzeitig die relative Häufigkeit der Erfolge, da S_n die Anzahl der Erfolge unter n Versuchen ist.

Beweis. (siehe Folie 4--2025 bzw. 18--19 2026)

Bemerkung 9.1 (2026) Unabhängigkeit $\Rightarrow$ paarweise Unabhängigkeit $\Rightarrow$ paarweise Unkorreliertheit

Bemerkung 9.2 (2026)

$$\mathbb{E}\left[\frac{1}{n}S_n\right] = \mathbb{E}[X_1]$$

Beispiel 9.3 Ermitteln der Erfolgswahrscheinlichkeit aus Daten (2025)

Geg. S_n , ges. $\mathbb{E}\left[\frac{1}{n}S_n\right] = \mathbb{E}[X_1] = p$ = Erfolgswahrscheinlichkeit.

S_n ist hier die Anzahl der Erfolge in einem n -mal unabhängig wiederholten Bernoulli-Experiment, z.B. Anzahl Sechsen bei n -maligem Werfen eines möglicherweise nicht fairen Würfels.

Erinnerung: Die relative Häufigkeit $\frac{1}{n}S_n$ der Erfolge konvergiert gegen die Erfolgswahrscheinlichkeit p .

Die Wahrscheinlichkeit, daß die relative Häufigkeit um mindestens ϵ von der Erfolgswahrscheinlichkeit abweicht, konvergiert gegen Null

Notation 9.1 (2025)

$$x_k^{(n)} := (k - np) / \sqrt{npq} \quad \text{für } k = 0, \dots, n$$

$$\mathcal{B}_{n,p}(k) = \binom{n}{k} p^k q^{n-k}$$

Erinnerung 9.1 (2025) Ist S_n binomialverteilt mit Parametern n und p , so gelten

$$\mathbb{P}(S_n = k) = \mathcal{B}_{n,p}(k)$$

$$\mathbb{E}[S_n] = np$$

$$\text{Var}(S_n) = npq$$

Satz 9.4 Lokaler zentraler Gesetzswertsatz (2025)

Sei $L > 0$ eine beliebige Konstante. Dann gilt

$$\underbrace{\mathcal{B}_{n,p}(k)}_{\mathbb{P}(S_n=k)} \sim \frac{1}{\sqrt{2\pi npq}} e^{-(x_k^{(n)})^2/2} \text{ gleichm\"a\ss{}ig f\"ur alle } k \text{ mit } |x_k^{(n)}| \leq L \quad (9.1)$$

Dabei bedeutet $\sim$:

$$f(n) \sim g(n) \Leftrightarrow \lim_{n \rightarrow \infty} \frac{f(n)}{g(n)} = 1$$

Man kann 9.1 auch schreiben als

$$\lim_{n \rightarrow \infty} \sup_{k: |x_k^{(n)}| \leq L} \left| \frac{\mathcal{B}_{n,p}(k)}{\frac{1}{\sqrt{2\pi npq}} e^{-(x_k^{(n)})^2/2}} - 1 \right| = 0$$

Beweis.

- Ausschreiben des Binomialkoeffizienten in *Binomialverteilung*)
- Approximieren der Fakultäten mit Hilfe der Stirlingschen Formel (siehe unten)
- Sortieren der Terme
- Sorgfältiges Berechnen des Limes $n \rightarrow \infty$

schwaches Gesetz der großen Zahlen " $\frac{1}{n}S_n \rightarrow \frac{1}{6}$ " und $\mathbb{P}(\frac{1}{n}S_n = \frac{1}{6})$ ist sehr klein.

Ergänzung 9.1 Stirlingsche Formel (2025)

$$n! \sim \sqrt{2\pi n} \left(\frac{n}{e}\right)^n \text{ für große } n \quad (9.2)$$

n	n!	Approximation
1	1	0.922
2	2	1.919
3	6	5.836
4	24	23.506
5	120	118.019
6	720	710.078
7	5040	4980.4
8	40320	39902.4
9	362880	359537
10	3628800	$3.5987 \cdot 10^6$
11	39916800	$3.96156 \cdot 10^7$
12	479001600	$4.75687 \cdot 10^8$

Tabelle 9.1: Exact factorial values and their approximations.

Ergänzung 9.2 Stirlingsche Formel mit Fehlerabschätzung (2025)

$$1 \leq \frac{n!}{\sqrt{2\pi n} \binom{n}{e}^n} \leq 1 + \frac{1}{11n} \quad (9.3)$$

Die Approximation verwendet die untere Schranke und Fehler ist der Ordnung $\frac{1}{n}$.

Beispiel 9.4 1200-mal Würfeln mit einem fairen Würfel. (2025)

Wie groß ist die Wahrscheinlichkeit, genau k Sechsen zu werfen?

a) $k = 200$

$$B_{1200, \frac{1}{6}}(200) = 0.030888 \dots$$

Approximation gemäß lokalem zentralem Grenzwertsatz:

$$0.030901 \dots$$

b) $k = 250$

$$B_{1200, \frac{1}{6}}(250) = 0.0000244 \dots$$

Approximation gemäß lokalem zentralem Grenzwertsatz:

$$0.0000170 \dots$$

Neue Fragen: (2025)

Wie groß ist die Ws., zwischen 150 und 250 Sechsen zu werfen? Wie groß ist die Ws., mindestens 250 Sechsen zu werfen?

Satz 9.5 Satz von de Moivre-Laplace (Spezialfall des zentralen Grenzwertsatzes) (2025)

Sei S_n die Anzahl der Erfolge in einem n -fach unabhängig wiederholten Bernoulli-Experiment mit Erfolgswahrscheinlichkeit $p \in (0, 1)$.

Dann gilt für jede Wahl von Konstanten a, b mit $-\infty < a < b < \infty$:

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{x^2/2} dx = \int_a^b \varphi(x) dx \quad (9.4)$$

Dabei verstehen wir die rechte Seite als Riemann-Integral $\int_a^b \varphi(x) dx$ mit

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \quad (9.5)$$

Standartisieren: X ist ZV mit existierender Varianz.

$$Y := \frac{X - \mathbb{E}[X]}{\sqrt{\text{Var}(X)}} \text{ hat } \mathbb{E}[Y] = 0, \quad \text{Var}(Y) = 1$$

Beweisidee: Zunächst Approximieren der Summanden *Binomialverteilung* durch den lokalen zentralen Grenzwertsatz. Approximieren der Summe mithilfe eines Riemann-Integrals.

Beweis. Siehe Folie 23. 2025

Kommentar 9.1 Zu Satz 9.5

Der Satz von de Moivre-Laplace macht eine Aussage über einen Grenzwert. Das bedeutet: Wenn man n tatsächlich gegen unendlich gehen lässt, dann konvergiert diese Wahrscheinlichkeit exakt gegen $\Phi(b) - \Phi(a)$ in der Praxis hast du aber nie $n = \infty$.




Abbildung 9.2: Beispiel für $n = 10$, $p = 1/10$




Abbildung 9.3: Beispiel für $n = 20$, $p = 1/10$




Abbildung 9.4: Beispiel für $n = 100$, $p = 1/10$




Abbildung 9.5: Beispiel für $n = 500$, $p = 1/10$

Beispiel 9.5 Vorlesung vs. Schlaf (2025)

Frage: Wie groß ist die Wahrscheinlichkeit, dass von den 142 Hörern einer 8-Uhr-Vorlesung nächste Woche zwischen 30% und 70% die Vorlesung besuchen?

Geg.: $n = 142$ Hörer, jeder Einzelne besucht mit Wahrscheinlichkeit $p \in (0, 1)$ die Vorlesung ($p = \frac{2}{3}$).

Vereinfachende Annahmen: Alle Hörer besuchen die Vorlesung mit derselben Wahrscheinlichkeit und alle Hörer entscheiden sich unabhängig voneinander.

Modell: n -mal unabhängig wiederholtes Bernoulli-Experiment mit Erfolgswahrscheinlichkeit p . Also: Die Anzahl der Erfolge S_n ist $\mathcal{B}_{n,p}$ -verteilt. Man betrachte jeden Anwesenden der n eingeschriebenen Hörer als "Erfolg".

Also:

$$\Omega = \{0, 1\}^n, \quad \mu(\omega) = p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{n-\sum_{i=1}^n \omega_i} \quad (\text{mit } n = 142 \text{ und } p = 2/3)$$

Anzahl der Erfolge ist die Anzahl Anwesender

$$S_n(\omega_i) = \sum_{i=1}^n \omega_i$$

Dass n Leute anwesende sind, ist das Ereignis:

$$A_n = \left\{ \frac{3}{10} \leq \frac{1}{n} S_n \leq \frac{7}{10} \right\} = \{S_n \in \{\lceil \frac{3}{10} \cdot n \rceil, \lceil \frac{3}{10} \cdot n \rceil + 1, \dots, \lfloor \frac{7}{10} \cdot n \rfloor\}\}$$

Für $n = 142$ ist das $\lceil \frac{3}{10} \cdot n \rceil = 43$ und $\lfloor \frac{7}{10} \cdot n \rfloor = 99$ Mit $p = \frac{2}{3}$:

$$\mathbb{P}(A_n) = \sum_{k=\lceil \frac{3}{10} \cdot n \rceil}^{\lfloor \frac{7}{10} \cdot n \rfloor} \binom{142}{k} \left(\frac{2}{3}\right)^k \left(\frac{1}{3}\right)^{142-k} = \sum_{k=43}^{99} \binom{142}{k} \left(\frac{2}{3}\right)^k \left(\frac{1}{3}\right)^{142-k} \approx 0.80$$

Approximation mit dem Satz von de Moivre-Laplace (in Form $a < \dots \leq b$ bringen) :

$$\begin{aligned} \mathbb{P}(A_n) &= \mathbb{P}\left(\frac{3n}{10} \leq S_n \leq \frac{7n}{10}\right) \\ &= \mathbb{P}\left(\lceil \frac{3n}{10} \rceil \leq S_n \leq \lfloor \frac{7n}{10} \rfloor\right) \\ &= \mathbb{P}\left(\lceil \frac{3n}{10} \rceil - 1 < S_n \leq \lfloor \frac{7n}{10} \rfloor\right) && (\text{weil } S_n \text{ ganzzahlig ist}) \\ &= \mathbb{P}\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) && (\text{Standardisieren, } q = 1 - p = 1/3) \\ &\stackrel{*}{\approx} \Phi(b) - \Phi(a) && (\text{Satz von de Moivre-Laplace}) \\ &\approx \Phi(0.77) - 0 \\ &\approx 0.7794v && (Tabelle) \end{aligned}$$

$$* \int_a^b \varphi(x) dx = \Phi(b) - \Phi(a)$$

mit

$$a = \frac{\lceil \frac{3n}{10} \rceil - 1 - np}{\sqrt{npq}} \approx -9.38 \quad \text{und} \quad b = \frac{\lfloor \frac{7n}{10} \rfloor - 1 - np}{\sqrt{npq}} \approx 0.77$$

Das Resultat wirft einige Fragen auf:

Frage 9.1 Warum spielt die untere Grenze a , die von den 30% herrührt, praktisch keine Rolle? (2026)

1. Antwort: $\Phi(a) \approx \Phi(-9) = 1 - \Phi(9)$ und $\Phi(9)$ ist so nah an 1, dass wir diesen Wert nicht einmal in der Tabelle finden . . .

Aber das erklärt noch gar nichts – oder?

2. Antwort: Wir wissen aus dem Gesetz der großen Zahlen, dass $\frac{1}{n}S_n$ in einem gewissen Sinne gegen $p = 2/3 \approx 66\%$ konvergiert. Daher ist die Forderung, dass $\frac{1}{n}S_n \leq 70\%$ sein soll, sehr viel restriktiver als die Forderung $\frac{1}{n}S_n \geq 30\%$.

Kommentar 9.2 Da $\frac{1}{n}S_n$ nach dem Gesetz der großen Zahlen gegen $p = \frac{2}{3} \approx 66,7\%$ konvergiert, liegt es für große n mit hoher Wahrscheinlichkeit in der Nähe von 66,7%. Die Bedingung $\frac{1}{n}S_n \geq 30\%$ ist daher nahezu immer erfüllt, während $\frac{1}{n}S_n \leq 70\%$ nur eine kleine Abweichung vom Grenzwert zulässt und somit restriktiver ist.

Frage 9.2 Die exakte Rechnung ergab $\mathbb{P}(A_n) \approx 0.80$ (Genauer $\mathbb{P}(A_n) \approx 0.804486$). **Warum finden wir mit dem Satz von de Moivre-Laplace nur $pe(A_n) \approx 0.78$? (2026)**

1. Antwort: $n = 142$ ist noch kein wirklich großes n .

2. Antwort: Grob gesprochen, approximieren wir eine diskrete Größe, die Anzahl der Erfolge S_n , durch etwas Kontinuierliches. Eine Verbesserung ist oft möglich durch die sogenannte Stetigkeitskorrektur: .

Wir modifizieren die Grenzen in A_n geschickt und rechnen

$$\begin{aligned}\mathbb{P}(A_n) &= \mathbb{P}\left(\left\lceil \frac{3n}{10} \right\rceil - 1 < S_n \leq \left\lfloor \frac{7n}{10} \right\rfloor\right) \\ &= \mathbb{P}\left(\left\lceil \frac{3n}{10} \right\rceil - \frac{1}{2} < S_n \leq \left\lfloor \frac{7n}{10} \right\rfloor + \frac{1}{2}\right) \quad (\text{weil } S_n \text{ ganzzahlig ist}) \\ &\approx \Phi(0.86) \approx 0.8051 \quad (\text{Tabelle})\end{aligned}$$

Bingo!

Beachte, dass die Stetigkeitskorrektur nicht immer besser ist (siehe Hausaufgaben).

Beispiel 9.6 Vorlesung vs. Schlaf II (2026)

Wie groß ist die Wahrscheinlichkeit, dass von 142 Hörern nächste Woche mindestens 90 die Vorlesung besuchen?

Was ist anders als im obigen Beispiel? Neu an dieser Frage ist, dass wir nur eine untere Schranke gegeben haben, d.h., wir suchen die Wahrscheinlichkeit von

$$B_n = \{S_n \geq 90\}$$

Dieser Fall ist in unserer Formulierung des Satzes von de Moivre-Laplace nicht vorgesehen!

Idee, das Problem zu umgehen: Wir werden uns künstlich eine triviale obere Schranke verschaffen.

$$\begin{aligned}
 \mathbb{P}(B_n) &= \mathbb{P}(S_n \geq 90) \\
 &= \mathbb{P}(89 < S_n \leq n) && \text{(triviale obere Schranke)} \\
 &= \mathbb{P}(89.5 < S_n \leq n) && (S_n \text{ ganzzahlig, Stetigkeitskorrektur}) \\
 &= \mathbb{P}(c_n < \frac{S_n - np}{\sqrt{npq}} \leq d_n) && \text{(Standardisieren)} \\
 &\approx \Phi(d_n) - \Phi(c_n) && \text{(Satz von de Moivre-Laplace)} \\
 &= \Phi(d_n) - [1 - \underbrace{\Phi(-c_n)}_{>0}] \approx 0.8212 && \text{(Tabelle)}
 \end{aligned}$$

mit

$$c_n = \frac{89.5 - np}{\sqrt{npq}} \approx -0.92 \quad \text{und} \quad d_n = \frac{nq}{\sqrt{npq}} 0 \sqrt{\frac{nq}{p}} \approx 8.43.$$

Exakte Rechnung ergibt $\mathbb{P}(B_n) = 0.821556 \dots$

Bemerkung 9.4 (2026)

Generell gelten, sofern der Satz von de Moivre-Laplace anwendbar ist,

$$\mathbb{P}(s_n > c) = \mathbb{P}\left(\frac{c - np}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{n - np}{\sqrt{npq}}\right) \approx 1 - \Phi\left(\frac{c - np}{\sqrt{npq}}\right)$$

und

$$\mathbb{P}(s_n \leq d) = \mathbb{P}\left(\frac{-1 - np}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{d - np}{\sqrt{npq}}\right) \approx \Phi\left(\frac{d - np}{\sqrt{npq}}\right)$$

weil für große n

$$\Phi\left(\frac{-1 - np}{\sqrt{npq}}\right) \approx 0 \quad \text{und} \quad \frac{n - np}{\sqrt{npq}} \approx 1$$

Vorlesung 18. Juni 2026 (V09 2026)

Lernziele

- Zentraler Grenzwertsatz: Aussage formulieren können and anwenden können
- Poissonscher Grenzwertsatz: Aussage formulieren können and anwenden können
- Wann wird welche Approximation verwendet?

Erinnerung 9.2 Satz von de Moivre-Laplace (2026)

Sei S_n die Anzahl der Erfolge in einem n-fach unabhängigen wiederholten Bernoulli-Experiment mit Erfolgswahrscheinlichkeit $p \in (0, 1)$.

Dann gilt für jede Wahl von Konstanten a, b mit $-\infty < a < b < \infty$

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-x^2/2} dx$$

Für große n folgt insbesondere, dass

$$\mathbb{P}(np - c < S_n \leq np + c) \approx \int_{-c/\sqrt{npq}}^{c/\sqrt{npq}} \underbrace{\frac{1}{\sqrt{2\pi}} e^{-x^2/2}}_{\text{Verteilungsfunktion der Standardnormalverteilung}} dx = \frac{1}{\sqrt{2\pi}} \int_{-c/\sqrt{npq}}^{c/\sqrt{npq}} e^{-x^2/2} dx = 2\Phi\left(\frac{c}{\sqrt{npq}}\right) - 1$$

Das folgt direkt aus dem allgemeinen Satz, wenn man die Konstanten a und b passend wählt.

Denn die WS für $np - c < S_n \leq np + c$ ist äquivalent für die von $-c < S_n - np \leq c$. Weil $\sqrt{npq} > 0$ (und das ist gegeben, weil $p \in (0, 1)$, also p ist echt größer als 0 und echt kleiner als 1; $n \leq 1$ ist die Anzahl der Versuche; $q = 1 - p$ und wir wissen ja bereits, dass p echt kleiner 1, also $q > 0$), kann man dadurch teilen und das hat dann die passende Form, um Moivre-Laplace anzuwenden:

$$\frac{-c}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{c}{\sqrt{npq}}$$

Und die Gleichung ergibt sich aus

$$\Phi\left(\frac{c}{\sqrt{npq}}\right) - \Phi\left(-\frac{c}{\sqrt{npq}}\right) = \Phi\left(\frac{c}{\sqrt{npq}}\right) - \left(1 - \Phi\left(\frac{c}{\sqrt{npq}}\right)\right) = 2\Phi\left(\frac{c}{\sqrt{npq}}\right) - 1$$

- Ist $c > 0$ nicht von n abhängig, so geht die Ws. mit $n \rightarrow \infty$ gegen Null (c ist eine feste Konstante, hängt nicht von n ab)
- Ist $0 < c \ll \sqrt{n}$, so geht die Ws. mit $n \rightarrow \infty$ immer noch gegen Null (c wächst, aber langsamer als $\sqrt{n}$)
- Relevanter Beitrag, d.h., Ws. größer als null, nur für $c \approx \sqrt{n}$ (oder größer) (c wächst in derselben Größenordnung wie $\sqrt{n}$)

Das erklärt, wie sich die Wahrscheinlichkeit $\mathbb{P}(np - c < S_n \leq np + c) \approx 2\Phi\left(\frac{c}{\sqrt{npq}}\right) - 1$ verhält, je nachdem wie schnell c mit n wächst (oder eben nicht wächst).

Kommentar 9.3 Zu : Die Liste ist relevant, denn ist npq zu klein, ist die Normalapproximation schlecht, und man sollte lieber exakt mit der Binomialverteilung rechnen (oder mit der Poisson-Approximation, falls p sehr klein ist).

Beobachtung 9.1 Vergleich mit dem Gesetz der großen Zahlen (2026)

$$\begin{aligned} \mathbb{P}\left(\left|\frac{1}{n}S_n - \mathbb{E}[X_1]\right| \geq \epsilon\right) &= 1 - \mathbb{P}\left(-\epsilon < \frac{1}{n}S_n - p < \epsilon\right) \\ &\approx 1 - \mathbb{P}\left(-\frac{n\epsilon}{\sqrt{npq}} < \frac{S_n - np}{\sqrt{npq}} \leq \frac{n\epsilon}{\sqrt{npq}}\right) \end{aligned}$$

Gesetz der großen Zahlen:

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n}S_n - \mathbb{E}[X_1]\right| \geq \epsilon\right) = 0 \quad \forall \epsilon > 0$$

und Satz von de Moivre-Laplace

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{x^2/2} dx = \int_a^b \varphi(x) dx$$

Verhalten für beschrieben durch

- ϵ der Ordnung 1 (konstant) : Gesetz der großen Zahlen
- ϵ der Ordnung $\frac{1}{\sqrt{n}}$ ()

Kommentar 9.4 Benutzt man für Stichprobengröße bestimmen, Konfidenzintervalle, Fehlerabschätzung bei Simulationen / Monte-Carlo-Methoden, Qualitätskontrolle / Fehlerraten

Satz 9.6 Zentraler Grenzwertsatz Verallgemeinerung des Satzes von de Moivre-Laplace (2026)

Gegeben Zufallsvariablen $X_1, X_2, X_3, \dots$ auf einem Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$.

Angenommen $X_1, X_2, X_3, \dots$ sind unabhängig und identisch verteilt und $\sigma^2 = \text{Var}(X_i) \in (0, \infty)$ für alle i .

(Beachte $\text{Var}(X_i) < \infty \Rightarrow \mathbb{E}[X_i]$ ex.)

Dabei ist $S_n = \sum_{i=1}^n X_i$ und $\mathcal{M} = \mathbb{E}[X_i]$.

Dann gilt:

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(a < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq b \right) = \Phi(b) - \Phi(a)$$

Satz 9.7 Zentraler Grenzwertsatz für Bernoulli-Variablen (2026)

Sind die Zufallsvariablen $X_1, X_2, X_3, \dots$ unabhängige Bernoulli-Variablen, so gelten: $\mathcal{M} = \mathbb{E}[X_i] = p$ und $\sigma^2 = \text{Var}(X_1) = pq$ mit $q = 1 - p$ und es folgt

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(a < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq b \right) = \mathbb{P} \left(a < \frac{S_n - np}{\sqrt{npq}} \leq b \right) = \Phi(b) - \Phi(a)$$

Man kann den zentralen Grenzwertsatz verallgemeinern, indem man bestimmte Voraussetzungen abschwächt:

Lemma 9.1 Bekannte Verallgemeinerungen (2026)

- Die Voraussetzung der identischen Verteilung kann abgeschwächt werden (z.B. zur Lindeberg-Bedingung).
 - Also: man muss nicht verlangen, dass alle X_i dieselbe Verteilung haben. Zum Beispiel darf X_1 normalverteilt sein, X_2 exponentialverteilt, X_3 wieder was anderes, solange sie noch unabhängig sind. Damit der ZGWS trotzdem noch gilt, braucht man aber eine Ersatzbedingung, die dafür sorgt, dass keine einzelne Variable die Summe zu stark dominiert. Das ist die Lindeberg-Bedingung.
- Die Voraussetzung der Unabhängigkeit kann abgeschwächt werden (Zentraler Grenzwertsatz von Lindeberg-Feller).
 - Es gibt Verallgemeinerungen des ZGWS für gewisse Arten von abhängigen Zufallsvariablen. Diese Verallgemeinerung erlaubt es, den ZGWS trotzdem anzuwenden, solange die Abhängigkeit nicht zu stark ist.
- Die Voraussetzungen $\sigma^2 > 0$ und $\sigma^2 < \infty$ dagegen sind notwendig

Beispiel 9.7 Augensumme in 420 Würfeln eines fairen Würfels (2026)

Wie groß ist die Ws., daß die Augensumme zwischen 1400 und 1550 liegt?


- $\Omega = \{1, \dots, 6\}^n$ mit $n = 420$
- $\mathbb{P}$ Gleichverteilung auf Ω
- $X_i(\omega) = \omega_i$ für $i = 1, \dots, n$ sind unabhängige, identisch verteilte ZV
- $\mathcal{M} = \mathbb{E}[X_i] = \frac{7}{2}$ und $\sigma^2 = \text{Var}(X_i) = \frac{35}{12}$
- $S_n(\omega) = \sum_{i=1}^n X_i(\omega)$ ist die Augensumme in n Würfeln

$$\begin{aligned}
\mathbb{P}(1400 \leq S_n \leq 1550) &= \mathbb{P}(1399 < S_n \leq 1550) \\
&= \mathbb{P}\left(\frac{1399 - n\mathcal{M}}{\sqrt{n\sigma^2}} < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq \frac{1550 - n\mathcal{M}}{\sqrt{n\sigma^2}}\right) \\
&= \mathbb{P}\left(\frac{1399 - 420\frac{7}{2}}{\sqrt{420\frac{35}{12}}} < \frac{S_n - 420\frac{7}{2}}{\sqrt{420\frac{35}{12}}} \leq \frac{1550 - 420\frac{7}{2}}{\sqrt{420\frac{35}{12}}}\right) \\
&= \mathbb{P}\left(-\frac{71}{35} < \frac{S_n - n\mathcal{M}}{\sqrt{n\sigma^2}} \leq \frac{80}{35}\right) \\
&\approx \Phi(2.29) - \Phi(-2.03) \\
&\approx 0.9890 - (1 - 0.9788) = 0.9678
\end{aligned}$$

Beispiel 9.8 Augensumme aus n Würfeln eines fairen Würfels (2026)

Jede Durchführung des Experiments ergibt die Augensumme aus n Würfeln eines fairen Würfels. Jedes Histogramm für ein festes n zeigt diese Augensumme in jeweils 5000 Durchführungen des Experiments. Vergleich mit der entsprechend skalierten Gaußschen Glockenkurve.

$n \in \{1, 2, 3, 4, 5, 10, 50, 100\}$



Satz 9.8 Poissonscher Grenzwertsatz Approximationen der Binomialverteilung (2026)

Gilt $np_n \rightarrow \alpha > 0$ für $n \rightarrow \infty$, so gilt für jedes feste $k \in \mathbb{N}$

$$\mathcal{B}_{n,p}(k) \rightarrow \mathcal{P}_\alpha(k) = \frac{\alpha^k}{k!} e^{-\alpha} \quad \text{für } n \rightarrow \infty$$

Beweis. Sei k fest und $np_n \rightarrow \alpha > 0$ für $n \rightarrow \infty$. Daraus folgt insbesondere: $p_n \rightarrow 0$ für $n \rightarrow \infty$.

$$\begin{aligned}
 \mathcal{B}_{n,p}(k) &= \binom{n}{k} p_n^k (1-p_n)^{n-k} \\
 &= \frac{n(n-1)\dots(n-k+1)}{k!} p_n^k (1-p_n)^{n-k} \\
 &= \underbrace{1 \cdot \left(1 - \frac{1}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right)}_{\rightarrow 1} \underbrace{\frac{(np_n)^k}{k!}}_{\rightarrow \frac{\alpha^k}{k!}} \underbrace{\left(1 - \frac{np_n}{n}\right)^n}_{\xrightarrow{*} e^{-\alpha}} \underbrace{(1-p_n)^{-k}}_{\rightarrow 1} \\
 &\rightarrow \frac{\alpha^k}{k!} e^{-\alpha} \\
 &= \mathcal{P}_\alpha(k)
 \end{aligned}$$

* $(1 - \frac{\alpha_n}{n})^n \rightarrow e^{-\alpha}$ gilt auch für Folge $(\alpha_n)_n$ mit $\alpha_n \rightarrow \alpha$, nicht nur für feste α .

Bemerkung 9.5 Fehlerabschätzung / Güte der Approximation (2026)

Gegeben S_n binomialverteilt mit Parametern n und p_n und Z_{np_n} poisson-verteilt mit Parameter np_n . Angenommen $np_n \rightarrow \alpha$. Dann gilt die Abschätzung

$$\sup_{C \subset \mathbb{N}_0} |\mathbb{P}(S_n \in C) - \mathbb{P}(Z_{np_n} \in C)| \leq 2np_n^2 = 2 \underbrace{np_n}_{\rightarrow \alpha} p_n$$

Und für jede Konstante $K > 2$ und n groß genug gilt

$$\sup_{C \subset \mathbb{N}_0} |\mathbb{P}(S_n \in C) - \mathbb{P}(Z_{np_n} \in C)| \leq K\alpha p_n \rightarrow 0 \quad \text{für } n \rightarrow \infty$$

Bemerkung 9.6 Die Poisson-Approximation ist gut, wenn n groß im Vergleich zu k ist ($n \gg k$) und p klein ist ($n \gg \alpha := np$). Das heißt insbesondere, daß die Erfolgswahrscheinlichkeit klein sein muss. Für derartige seltene Ereignisse verwenden wir $\mathbb{P}(S_n = k) \approx \mathcal{P}_\alpha(k)$ mit $\alpha := np$.

Karteikarte 9.1 Wann ist die Poisson-Approximation ist gut?

Wenn n groß im Vergleich zu k ist ($n \gg k$) und p klein ist ($n \gg \alpha := np$). Das heißt insbesondere, daß die Erfolgswahrscheinlichkeit klein sein muss..

Beispiel 9.9 Seltenes Ereignis / Roulette (2026)

Wir betrachten ein Roulettespiel mit 36 "Zahlen" und einer "Null".

Wir setzen immer auf eine bestimmte Zahl: $p = 1/37$ und wir tun dies $n = 37$ Mal. Das heißt, wir erwarten im Mittel einen Gewinn: $\alpha = np = 1$.

Wie groß ist die Ws., $0\times, 1\times, 2\times, \dots$ zu gewinnen?

k	$\mathcal{B}_{37,1/37}(k)$	$\mathcal{P}_1(k)$
0	0.363	0.368
1	0.363	0.368
2	0.186	0.184
$\vdots$	$\vdots$	$\vdots$
5	0.00261	0.00306
$\vdots$	$\vdots$	$\vdots$
15	$1.5 \cdot 10^{14}$	$2.8 \cdot 10^{13}$

Beispiel 9.10 Historisches Beispiel zur Poisson-Approximation: Tote durch Hufschlag in Preussen (2026)

Vorliegende Daten: 10 Armee-corps über 20 Jahre, entspricht 200 Corps-Jahren.

Tote k	Anzahl Jahre mit k Toten	$200 \cdot P_{\varrho}(k)$ mit $\varrho = 0,61$
0	109	109
1	65	66
2	22	20
3	3	4
4	1	1
≥ 5	0	0

Tabelle 9.2: Die durch Schlag eines Pferdes im preussischen Heere Getöteten (Ladislaus von Bortkiewicz, Das Gesetz der kleinen Zahlen, Teubner (1898))

Hier wurde α gewählt als die mittlere Anzahl an Toten pro (Corps-)Jahr:

$$\alpha = (165 + 222 + 33 + 14)/200 = 0,61$$

Beispiel 9.11 Beispiel zur Poisson-Approximation: Zellzählung im Gitternetz (2026)

Zellen unter dem Mikroskop, Gitternetz, im Schnitt ν Zellen pro kleinem Quadrat, N Quadrate.

Modellierung: Verteile $N\nu$ Zellen zufällig und unabhängig voneinander auf N Quadrate. Wahrscheinlichkeit $p = 1/N$ für eine Zelle, im vorab gewählten Quadrat φ zu landen. Wahrscheinlichkeit k Zellen im Quadrat φ zu finden, ist $\mathcal{B}_{N\nu, 1/N}(k)$.

$$np_n \equiv \nu \begin{cases} n &= N\nu \\ p_n &= \frac{1}{N} \end{cases}$$

Bei großer Zahl N von Quadraten gelten $N\nu \gg k$ und $N\nu \gg \underbrace{(N\nu)}_n \underbrace{\frac{1}{N}}_{p_n} = \nu$.

Poisson-Approximation zeigt $\mathcal{B}_{N\nu, 1/N}(k) \approx \mathcal{P}_{\nu}(k)$.

Dies rechtfertigt, eine derartige Verteilung von Zellen oder Teilchen mit Hilfe der Poisson-Verteilung zu modellieren.

Beispiel 9.12 Beispiel zur Poisson-Approximation: Im zeitlichen Verlauf eintreffende Rechenaufträge (2026)

Im Schnitt α eintreffende Rechenaufträge pro Zeiteinheit (z.B. pro Stunde)

Ws., daß ein Auftrag eintrifft in einem sehr kleinen Zeitfenster der Länge $\delta \ll 1$ sei näherungsweise $\alpha\delta$. (δ sehr klein, z.B. eine Millisekunde)).

Wir zerlegen das Gesamtzeitintervall $[0, t]$ in N sehr kleine, disjunkte Teilintervalle der Länge t/N . (für ein festes t , z.B. 30 Minuten, 24 Stunden, drei Wochen, . . .)

$$[0, t] = \bigcup_{k=1}^N \left[\frac{k-1}{N} \cdot t, \frac{k}{N} \cdot t \right)$$

Ws., dass ein Auftrag eintrifft in einem bestimmten dieser Zeitfenster, ist näherungsweise $\alpha t/N$.

Annahmen: Für großes N sind die Zeitfenster so klein, daß wir annehmen dürfen, daß in jedem Fenster ein oder kein Auftrag eintrifft (d.h., wir schließen aus, daß mehr als ein Auftrag eintreffen kann) . Ob ein Auftrag in einem bestimmten Fenster eintrifft, sei unabhängig vom Eintreffen von Aufträgen in allen anderen Zeitfenstern.

Modellierung: Damit haben wir jedem Zeitfenster, d.h. jedem k , eine Bernoulli-Variable zugeordnet, die uns sagt, ob im zugehörigen Zeitfenster k ein Auftrag eintrifft. Die Erfolgsws. dieser Bernoulli-Variable ist $\alpha t/N$ (Also die Ws, dass ein Auftrag in einem bestimmten Zeitfenster eintritt). Die Anzahl der Aufträge, die im Intervall $[0, t)$ eintreffen, ist binomialverteilt mit Parametern N und $\alpha t/N$.

$$n = N, \quad p_n = \frac{\alpha t}{N} = \alpha t \frac{1}{N}$$

Für die Ws., insgesamt φ Aufträge im Intervall $[0, t)$ zu haben, ergibt die Poisson-Approximation für große N :

$$\mathcal{B}_{N, \alpha t/N}(\varphi) \approx \mathcal{P}_{N \cdot \alpha t/N}(\varphi) = \mathcal{P}_{\alpha t}(\varphi)$$

(Beachten Sie, daß wir in diesem Problem N beliebig groß machen dürfen. Wir verwenden hier die beliebige Teilbarkeit der Zeit!)

Wiederum rechtfertigt unsere Betrachtung, beim Modellieren derartiger Prozesse generell die Poisson-Verteilung zu verwenden.

Lemma 9.2 Poisson-Approximation für Erfolgswahrscheinlichkeit p nahe 1 (2026)

Betrachte die Anzahl Erfolge S_n in einem unabhängig n -mal wiederholten Bernoulli-Experiment mit:

- n groß
- p nahe bei 1, d.h., $q = 1 - p$ klein

Zusatzüberlegung erlaubt es, die Poisson-Approximation anzuwenden: Tausche die Rollen von “Erfolg” und “Mißerfolg” (zähle Mißerfolge !)

$\tilde{S}_n = n - S_n$ zählt die Anzahl der “Mißerfolge” $\tilde{S}_n$ ist $\mathcal{B}_{n,q}$ -verteilt.

Sei $\tilde{\alpha} = \mathbb{E}[\tilde{S}_n] = nq$.

Poisson-Approximation:

$$\mathbb{P}(\tilde{S}_n = k) = \mathcal{B}_{n,q}(k) \approx \mathcal{P}_{\tilde{\alpha}}(k); \quad \forall k \in \mathbb{N}_0$$

“Zurück übersetzen”: : Für alle $k \in \mathbb{N}_0$ gilt:

$$\mathbb{P}(S_n = k) = \mathbb{P}(\tilde{S}_n = n - k) = \mathcal{B}_{n,q}(n - k) \approx \mathcal{P}_{\tilde{\alpha}}(n - k) = \frac{(nq)^{(n-k)}}{(n - k)!} e^{-nq}$$

Also:

$$\mathbb{P}(S_n = k) = \mathbb{P}((n - S_n) = n - k) = \mathcal{B}_{n,q}(n - k) \approx \mathcal{P}_{\mathbb{E}[n - S_n]}(n - k) = \frac{(nq)^{(n-k)}}{(n - k)!} e^{-nq}$$

Bzw.:

$$\mathbb{P}(S_n = k) = \mathbb{P}((n - S_n) = n - k) = \mathcal{B}_{n,q}(n - k) \approx \mathcal{P}_{nq}(n - k) = \frac{(nq)^{(n-k)}}{(n - k)!} e^{-nq}$$

9.0.1 | Beispielaufgabe Laubfrosch

(2026)

Ein Laubfrosch legt $n = 1000$ Eier. Aus jedem Ei entwickelt sich mit der WS $p = \frac{1}{200}$ ein Frosch.

Aufgabe 9.1 Wahrscheinlichkeitsraum angeben und Modell rechtfertigen

Ziel: Wahrscheinlichkeit, dass sich höchstens zwei Frösche entwickeln.

Lösung: $n = 1000$, $\Omega = \{0, 1\}^{1000}$

$\omega_i = 1$ bedeutet i-tes Ei entwickelt sich zum Frosch.

$$\mu(\omega) = p^{\sum_{i=1}^n \omega_i} (1-p)^{n-\sum_{i=1}^n \omega_i} \quad \forall \omega \in \Omega$$

Annahme: Frösche entwickeln sich unabhängig voneinander mit gleicher Ws.

Aufgabe 9.2 Zufallsvariable, die Anzahl der Frösche angibt, die Verteilung und ggf. Parameter

$S_n : \Omega \rightarrow \{0, \dots, n\}$ und

$$S_n(\omega) := \sum_{i=1}^n \omega_i \quad \forall \omega \in \Omega$$

Als Anzahl von Erfolgen in unabhängig wiederholten Bernoulli-Experimenten ist S_n binomialverteilt mit Parametern n und p .

Aufgabe 9.3 Erwartungswert und Varianz

S_n ist binomialverteilt mit Parametern n und p . Daher existieren EW und Varianz und es gilt:

$$\mathbb{E}[S_n] = np = 1000 \frac{1}{200} = 5$$

und

$$\text{Var}(S_n) = np(1-p) = 5 \cdot \left(1 - \frac{1}{200}\right) = 5 \cdot \frac{199}{200} = \frac{199}{40}$$

Aufgabe 9.4 WS. maximal zwei Frösche zu haben

$$\alpha = pn = 5$$

$$\mathbb{P}(S_n \leq 2) = \mathbb{P}(S_n = 0) + \mathbb{P}(S_n = 1) + \mathbb{P}(S_n = 2)$$

$$\approx \left[\frac{\alpha^0}{0!} e^{-\alpha} + \frac{\alpha^1}{1!} e^{-\alpha} + \frac{\alpha^2}{2!} e^{-\alpha} \right] \quad \text{Pois. - Approx.}$$

$$= \left[1 + 5 + \frac{25}{2} \right] e^{-\alpha} \quad *$$

$$= \left[1 + 5 + \frac{25}{2} \right] e^{-5} \quad **$$

* n groß, $p = \frac{1}{200}$ klein

** $k = 0, 1, 2$ klein gegenüber n

Bemerkung 9.7 Bruchrechnung im Kontext der Binomialapproximation nicht ausmultiplizieren! (2026)

Sondern mit Parametern rechnen und n und p so spät wie möglich einsetzen.

Teil II

Tutorien

KAPITEL 10

Tutorium 20.04.2026

10.1 | PÜ 1.1.4 - Faire Münze 3-mal Werfen

10.2 | PÜ 1.1.5 - Faire Münze n-mal Werfen

10.3 | PÜ 1.1.6 - Mensch ärgere dich nicht

KAPITEL 11

Tutorium 27.04.2026

11.1 | PÜ 1.2.4

Die Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$ sei gegeben durch

$$f(x) = \begin{cases} 3cx^2(1-x) & \text{für } x \in [0, 1], \\ 0 & \text{sonst} \end{cases}$$

wobei $c \in \mathbb{R}$ eine Konstante sei.

Aufgabe 11.1 (a) Bestimmen Sie ein $c \in \mathbb{R}$ derart, dass f eine Dichte ist

Lösung: $f(x)$ ist eine Dichte, wenn $\int_{\mathbb{R}} f(x) dx = 1$ also $\int_{-\infty}^{\infty} f(x) dx = 1$ (Von Studi vorgestellt)

$$\begin{aligned} \int 3cx^2(1-x) dx &= 3c \cdot \int x^2(1-x) dx \\ &= 3c \cdot \int_0^1 x^2 - x^3 dx \\ &= 3c \cdot \left[\frac{1}{3}x^3 - \frac{1}{4}x^4 \right]_0^1 \\ &= 3c \cdot \left(\frac{1}{3} - \frac{1}{4} \right) \\ &= c \cdot \frac{1}{4} \end{aligned}$$

$$c \cdot \frac{1}{4} = 1 \Rightarrow c = 4$$

Sei $\mathbb{P}$ das Wahrscheinlichkeitsmaß mit Dichte f , wie Sie sie in (a) bestimmt haben.

Hinweis: Falls Sie die Konstante c nicht bestimmen konnten, rechnen Sie im folgenden bitte mit der unbestimmten Konstanten weiter.

Aufgabe 11.2 (b) Berechnen Sie die folgenden Wahrscheinlichkeiten

$$\mathbb{P}\left(\left(\frac{1}{2}, \infty\right)\right), \mathbb{P}\left((-\infty, 0)\right), \mathbb{P}\left([1, \infty)\right) \text{ und } \mathbb{P}\left(\left\{\frac{1}{2}\right\}\right)$$

Lösung: (von Tutor)

$$pe((\frac{1}{2}, \infty)) = \frac{11}{16}$$

$$\begin{aligned}\mathbb{P}((-\infty, 0)) &= \int_{-\infty}^0 f(x) \, dx \\ &= \int_{-\infty}^0 0 \, dx \\ &= 0\end{aligned}$$

$$\begin{aligned}\mathbb{P}([1, \infty)) &= \int_1^{\infty} f(x) \, dx \\ &= \int_1^{\infty} 0 \, dx \\ &= 0\end{aligned}$$

$$\begin{aligned}\mathbb{P}(\{\frac{1}{2}\}) &= \int_{\frac{1}{2}}^{\frac{1}{2}} f(x) \, dx \\ &= 12 \cdot \left[\frac{1}{3} \cdot x^3 - \frac{1}{4} \cdot x^4 \right]_{\frac{1}{2}}^{\frac{1}{2}} \\ &= 12 \cdot \left(\frac{1}{3} \cdot \frac{1}{2^3} - \frac{1}{4} \cdot \frac{1}{2^4} - \frac{1}{3} \cdot \frac{1}{2^3} + \frac{1}{4} \cdot \frac{1}{2^4} \right) \\ &= 0\end{aligned}$$

KAPITEL 12

Tutorium 04.05.2026 (Zusatztutorium)

12.1 | PÜ 1.0.1

Aus dem Intervall $[0, 1]$ wird rein zufällig eine Zahl gezogen. Wir betrachten in dieser Aufgabe nur die Nachkommastellen der Dezimalentwicklung.

Aufgabe 12.1 (a) Modellieren Sie dieses Zufallsexperiment, indem Sie einen geeigneten Wahrscheinlichkeitsraum angeben.

$$\Omega = [0, 1]$$

Und Dichte:


$$f(x) = \begin{cases} 1, & x \in [0, 1] \\ 0, & \text{sonst} \end{cases}$$

Das ergibt:

$$\mathbb{P}(A) = \int_A f(x) dx$$

Aufgabe 12.2 (b) Definieren Sie die folgenden Ereignisse als Teilmengen des Ereignisraums, und zeichnen Sie diese in einer Skizze des Intervalls ein

1. Die erste Nachkommastelle der Zahl ist ungerade: $A_1 = \bigsqcup_{k=1}^5 [\frac{2k-1}{10}, \frac{2k}{10})$
2. Die zweite Nachkommastelle der Zahl ist gleich 4: $A_2 = \bigsqcup_{i=0}^9 [\frac{10i+4}{100}, \frac{10i+5}{100})$
3. Die Summe der ersten beiden Nachkommastellen der Zahl beträgt 5: $A_3 = \bigsqcup_{i=0}^5 [\frac{10i+(5-i)}{100}, \frac{10i+(5-i)+1}{100})$
4. Die Zahl ist exakt $\frac{1}{\pi}$: $A_4 = \{\frac{1}{\pi}\} = 0,3138\dots$
5. Die Zahl ist um höchstens $\frac{1}{100}$ von $\frac{1}{\pi}$ entfernt: $A_5 = [\frac{1}{\pi} - \frac{1}{100}, \frac{1}{\pi} + \frac{1}{100}]$



Aufgabe 12.3 Berechnen Sie die Wahrscheinlichkeiten dieser Ereignisse.**Lösung:** Für 1.

$$\mathbb{P}(A_1) = \mathbb{P}\left(\bigcup_{k=1}^5 \left[\frac{2k-1}{10}, \frac{2k}{10}\right)\right) = \sum_{k=1}^5 \mathbb{P}\left(\left[\frac{2k-1}{10}, \frac{2k}{10}\right)\right) = \sum_{k=1}^5 \mathbb{P}\left(\left[\frac{1}{10}, \frac{2}{10}\right)\right) = 5 \mathbb{P}\left(\left[\frac{1}{10}, \frac{2}{10}\right)\right) = 5 \cdot \frac{1}{10} = \frac{1}{2}$$

Für 2.

$$\mathbb{P}(A_2) = \sum_{i=0}^9 \mathbb{P}\left(\left[\frac{10i+4}{100}, \frac{10i+5}{100}\right)\right) = 10 \cdot \frac{1}{100} = \frac{1}{10}$$

Für 3.

$$\mathbb{P}(A_3) = \sum_{i=0}^5 \mathbb{P}\left(\left[\frac{10i+(5-i)}{100}, \frac{10i+(5-i)+1}{100}\right)\right) = 6 \cdot \frac{1}{100} = \frac{3}{50}$$

Für 4. WS für Einpunktmenge bei Dichte ist $0 = \int_{1/\pi}^{1/\pi} 1 dx = \frac{1}{\pi} - \frac{1}{\pi}$

Für 5.

$$\mathbb{P}(A_5) = \mathbb{P}\left(\left[\frac{1}{\pi} - \frac{1}{100}, \frac{1}{\pi} + \frac{1}{100}\right]\right) = \frac{2}{100}$$

12.2 | PÜ 1.0.2.

Beim Spiel Mensch ärgere dich nicht würfelt der Spieler zunächst einmal. Dann wird die Figur des Spielers auf dem Brett um die entsprechende Anzahl an Feldern vorgerückt. Falls der Spieler eine 6 würfelt hat, so darf er anschließend erneut würfeln. Wieder wird die Figur um die entsprechende Anzahl an Feldern vorgerückt. Dieser Vorgang wird wiederholt, bis der Würfel zum ersten Mal keine 6 zeigt. Uns interessiert nur, um wie viele Felder die Figur insgesamt vorgerückt wird

Aufgabe 12.4 Geben Sie einen geeigneten Wahrscheinlichkeitsraum für dieses Zufallsexperiment an.**Lösung:** $\Omega = \mathbb{N}$ also

$$\tilde{\Omega} = \{(k, l) \mid k \in \mathbb{N}_0, l \in \{0, \dots, 5\}\} = \mathbb{N}_0 \times \{0, \dots, 5\}$$

$$\mu = \text{?} \rightarrow \mathbb{P}(A) = \sum_{\omega \in A} \mu(\omega)$$

Für $1 \leq \omega \leq 6 :: \mu_1 \sim \cup_{\{1, \dots, 6\}}$

$$\mu(\omega) = \mu_1(\omega) = \frac{1}{6} \quad \forall \omega \in \{1, \dots, 5\}$$

$$\mu(6) = 0$$

Für $7 \leq \omega \leq 12 :: \mu_2 \sim \cup_{\{1, \dots, 6\}^2}$

$$\mu(\omega) = \mu_2((6, 6 - \omega)) = \frac{1}{36} \quad \forall \omega \in \{7, \dots, 11\}$$

 $\mu(12) = \mu_2((6, 6)) = 0$ ist falsch!, weil wir direkt nochmal würfeln würden nach der zweiten 6, richtig wäre:

$$\mu(12) = 0 \text{ und } \mu_2((6, 6)) = \frac{1}{36}$$

Weitere Beispiele:

$$\text{bspw. } \mu(7) = \mu_2((6, 1))$$

$$\text{und bspw. } \mu(72) = \mu(6 \cdot 12 + 1) = \frac{1}{6^{13}}$$

Damit man überhaupt den zweiten Wurf machen darf, muss das erste ja schon eine 6 gewesen sein, deswegen $1/36$

Aufgabe 12.5

$$\frac{\mathbb{N}}{6} = \{n \in \mathbb{N} : n \text{ nichtkongruent mod } 6\}$$

also auch

$$\mathbb{N}_0 \times \{0, \dots, 5\}$$

dannam ende mit dem squiggy arrow muss man noch ausrechnen, dass das eine Zähldichte ist

12.3 | PÜ 1.0.3.

KAPITEL 13

Tutorium 11.05.2026

13.1 | PÜ 1.3.4.

KAPITEL 14

Tutorium 18.05.2026

14.1 | PÜ 1.4.4.

14.2 | PÜ 1.4.5.

KAPITEL 15

Tutorium 26.05.2026

15.1 | PÜ 1.5.4.

15.2 | PÜ 1.5.5.

KAPITEL 16

Tutorium 01.06.2026

16.1 | PÜ 1.6.4.

Auf einem Tisch stehen zwei Urnen.

- Urne U_K enthalte eine schwarze Kugel und zwei weiße Kugeln.
- Urne U_Z enthalte zwei schwarze Kugeln und eine weiße Kugel.

Die Kugeln unterscheiden sich nur durch ihre Farbe. Mavi wirft eine faire Münze, um sich zwischen den beiden Urnen zu entscheiden.

- Wenn die Münze Kopf zeigt, dann zieht Mavi nacheinander und ohne Zurücklegen zwei Kugeln aus Urne U_K .
- Wenn die Münze Zahl zeigt, dann zieht Mavi nacheinander und ohne Zurücklegen zwei Kugeln aus Urne U_Z .

Aufgabe 16.1 (a) Geben Sie einen geeigneten Ereignisraum Ω an, mit dem Sie die folgenden Aufgabenteile bearbeiten können.

Meine Lösung: $\Omega = \{k, z\} \times \{s, w\}^2$, wobei $\omega = (k, s, w)$ bedeutet, dass aus der Urne U_K erst eine schwarze und dann eine weiße Kugel gezogen wurde.

Tutor Lösung: $\Omega = \{k, z\} \times \{s, w\}^2$ mit der Bemerkung, dass $\mathbb{P}((k, s, s)) = \mathbb{P}(z, w, w) = 0$. Die Bemerkung muss nicht dazu. Dabei ist $\{k, z\}$ der Münzwurf und $\{s, w\}^2$ das Ziehen zweier Kugeln.

Man kann es auch direkt mit Tripeln machen, aber das ist mehr Schreibarbeit. Aber dann hat man die Sachen mit $\mathbb{P} = 0$ auch nicht drin, sondern nur das, was tatsächlich möglich ist.

Aufgabe 16.2 (b) Definieren Sie jene Ereignisse als Teilmengen von Ω , die Sie benötigen, um die folgenden Aufgabenteile bearbeiten zu können.

Meine Lösung:

$$\begin{aligned}
 S_i &= \{\text{i schwarze Kugeln gezogen}\} \\
 W_i &= \{\text{i weiße Kugeln gezogen}\} \\
 S_1 = W_1 &= \{(k, s, w), (k, w, s), (z, w, s), (z, s, w)\} \\
 S_0 = W_2 &= \{(k, w, w)\} \\
 S_2 = W_0 &= \{(z, s, s)\} \\
 U_K &= \{\text{Es wurde aus Urne } U_K \text{ gezogen}\} \\
 &= \{(k, s, w), (k, w, s), (k, w, w)\} \\
 U_Z &= \{\text{Es wurde aus Urne } U_Z \text{ gezogen}\} \\
 &= \{(z, s, w), (z, w, s), (z, s, s)\}
 \end{aligned}$$

(Alle Ereignisse, nicht nur die für die Aufgaben relevanten...)

Tutor Lösung:

$$\begin{aligned}
 W &= \{k, z\} \times \{w\}^2 \\
 K &= \{k\} \times \{s, w\}^2 \\
 Z &= \{z\} \times \{s, w\}^2
 \end{aligned}$$

Aufgabe 16.3 (c) Bestimmen Sie aus dem Text die Wahrscheinlichkeiten bzw. bedingten Wahrscheinlichkeiten der Ereignisse aus (b).

Meine Lösung:

$$\begin{aligned}
 P(U_Z) &= P(U_K) = \frac{1}{2} \\
 P(S_0 | U_K) &= \frac{2}{3} \cdot \frac{1}{2} = \frac{2}{6} \\
 P(S_0 | U_Z) &= 0
 \end{aligned}$$

(Nicht weiter gemacht)

Tutor Lösung:

$$\begin{aligned}
 \mathbb{P}(K) &= \mathbb{P}(Z) = \frac{1}{2} \\
 \mathbb{P}(W | K) &= \frac{2}{3} \cdot \frac{1}{2} = \frac{2}{6} = \frac{1}{3} \\
 \mathbb{P}(W | Z) &= 0
 \end{aligned}$$

Aufgabe 16.4 (d) Berechnen Sie die Wahrscheinlichkeit, dass Mavi mindestens eine schwarze Kugel zieht (d.h., die Wahrscheinlichkeit, dass Mavi eine oder zwei schwarze Kugeln zieht)

Tutor Lösung: $\mathbb{P}(\text{"Mindestens eine schwarze Kugel gezogen"}) = \mathbb{P}(W^c) = 1 - \mathbb{P}(W)$, wobei $W = \{\text{"Es werden nur weiße Kugeln gezogen"}\}$

$$\begin{aligned}\mathbb{P}(W) &= \mathbb{P}(W \mid K) \cdot \mathbb{P}(K) + \mathbb{P}(W \mid Z) \cdot \mathbb{P}(Z) \\ &= \frac{1}{3} \cdot \frac{1}{2} + 0 \cdot \frac{1}{2} \\ &= \frac{1}{6}\end{aligned}$$

Aufgabe 16.5 (e) Sie wissen, dass Mavi mindestens eine schwarze Kugel gezogen hat. Berechnen Sie die Wahrscheinlichkeit, dass Mavi aus der Urne U_Z gezogen hat.

Tutor Lösung:

$$\begin{aligned}\mathbb{P}(\text{"Zahl"} \mid \text{"min. 1 schwarze Kugel"}) &= \mathbb{P}(Z \mid W^c) \\ &\stackrel{\text{Bayes}}{=} \frac{\mathbb{P}(W^c \mid Z) \cdot \mathbb{P}(Z)}{\mathbb{P}(W^c)} \\ &= \frac{(1 - \mathbb{P}(W \mid Z)) \cdot \mathbb{P}(Z)}{\mathbb{P}(W^c)} \\ &= \frac{\frac{1}{2}}{\frac{5}{6}} = \frac{6}{10} \\ &= \frac{3}{5}\end{aligned}$$

16.2 | Besprechung ÜB 1.5.1

Seien X, Y ZVs mit gemeinsamer Dichte f :

$$f(x, y) = \begin{cases} c \cdot e^{-x + \frac{y}{2}}, & x \in [0, 1], y \geq 0 \\ 0, & \text{sonst} \end{cases}$$

(a) Finde c , sodass f Dichte ist

$f \geq 0$ sqiggy-Pfeil zu $c \stackrel{!}{\geq} 0$

$$\begin{aligned}1 &\stackrel{!}{=} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy \\ &= c \cdot \int_0^1 e^{-x} dx \int_0^{\infty} e^{\frac{1}{2}y} dy \\ &= c \cdot [-e^{-x}]_0^1 \cdot [-2 \cdot e^{-\frac{y}{2}}]_0^{\infty} \\ &= c \cdot (1 - e^{-1}) \cdot (2)\end{aligned}$$

sqiggy-Pfeil zu:

$$c = \frac{1}{2(1 - e^{-1})} \geq 0$$

(b)

Bemerke: χ

$$f(x, y) = \underbrace{c_1 \cdot e^{-x} \cdot \chi_{[0,1]}(x)}_{f_X(x)} \cdot \underbrace{c_2 \cdot e^{-\frac{y}{2}} \cdot \chi_{[0,\infty)}(y)}_{f_Y(y)}$$

mit $c = c_1 \cdot c_2$ TO-DO von Bild abtippen, hat weggewischt

(c)

 F_X & $F_Y = ?$ $x < 0$: $F_X(x) = 0$

$$x \in [0, 1]: F_X(x) = \int_0^x c_1 e^{-\tilde{x}} d\tilde{x} = c_1 \cdot (1 - e^{-x}) = \frac{1-e^{-x}}{1-e^{-1}}$$

 $x > 1$: $F_X(x) = 1$

sqiggy-Pfeil zu:

$$f_X(x) = \begin{cases} 0, & x < 0 \\ \frac{1-e^{-x}}{1-e^{-1}}, & x \in [0, 1] \\ 1, & x > 1 \end{cases}$$

TO-DO von Bild abtippen, hat weggewischt

(d)

(e)

$$\begin{aligned} \mathbb{P}(X > Y) &= \int_0^1 f_X(x) \underbrace{\int_0^x f_Y(y) dy}_{F_Y(x)} dx \\ &= \int_0^1 2ce^{-x} \cdot (1 - e^{-\frac{x}{2}}) dx \\ &= 2c \int_0^1 e^{-x} - e^{-\frac{3}{2}x} dx \\ &= 2c \cdot ((1 - e^{-1}) - [-\frac{2}{3}e^{-\frac{3}{2}x}]_0^1) \\ &= 2c \cdot ((1 - e^{-1}) - (-\frac{2}{3} - \frac{2}{3}e^{-\frac{3}{2}})) \end{aligned}$$

16.3 | Besprechung ÜB 1.5.2

Seien $X, Y \sim \text{Exp}(\lambda)$, $X \perp\!\!\!\perp Y$

(a)

$$\mathbb{P}(X > 10) = 1 - \mathbb{P}(X \leq 10)$$

Für $\lambda = \frac{1}{5}$

$$\mathbb{P}(X > 10) = 1 - \mathbb{P}(X \leq 10) = 1 - F_X(10) = 1 - (1 - e^{-\frac{1}{5} \cdot 10}) = e^{-2}$$

(c)

$$\underbrace{\mathbb{P}(X + Y \leq Z)}_{F_{X+Y}(z)} = \int_0^2 f_X(x) \overbrace{\int_0^{z-x} f_Y(y) dy}^{F_Y(z-x)} dx$$

= TODOrestvonBild

subsubsection*(c oder b?)

16.4 | Besprechung ÜB 1.5.3

To-do von Bild

16.5 | PÜ 2.1.4**16.6 | PÜ 2.1.5****16.7 | PÜ 2.1.6**

KAPITEL 17

Tutorium 15.06.2026

Binomialverteilung benutzt man, wenn es aus der Aufgabenstellung hervor sinnvoll ist oder wenn die Aufgabenstellung sagt, dass etwas binomialverteilt ist.

$$\begin{aligned}\mathbb{P}(X_n \leq \delta) &= \mathbb{P}(X_n - np \leq \delta - np) \\ &= \mathbb{P}\left(\frac{X_n - np}{\sqrt{npq}} \leq \frac{\delta - np}{\sqrt{npq}}\right) \\ &\stackrel{*}{\approx} \Phi\left(\frac{\delta - np}{\sqrt{npq}}\right)\end{aligned}$$

* das ist das Anwenden von Moire-Laplace.

Tscheby:

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq \delta) \leq \frac{\text{Var}(X)}{\delta^2}$$

17.1 | PÜ 2.2.4.

Der Lufthansa Airbus A380 bietet insgesamt 526 Fluggästen Platz. Da Kunden manchmal ihren Flug nicht antreten, lassen Fluggesellschaften zwecks optimaler Auslastung Überbuchungen zu. Es sollen möglichst viele Tickets verkauft werden, wobei jedoch die Wahrscheinlichkeit einer Überbuchung maximal 5% betragen soll. Erfahrungsgemäß erscheinen Kunden mit einer Wahrscheinlichkeit von 10% nicht zum Flug.

Aufgabe 17.1 (a) Geben Sie einen geeigneten Wahrscheinlichkeitsraum an, der es erlaubt, die folgenden Aufgabenteile zu bearbeiten. Diskutieren Sie, welche Annahmen Sie machen müssen, um Ihre Wahl des Wahrscheinlichkeitsraums zu rechtfertigen.

Lösung Tutor

$$\Omega = \left\{ \underbrace{0}_{\text{kommt nicht}}, \underbrace{1}_{\text{kommt}} \right\}^n$$

kommt nicht ist $q = \frac{1}{10}$ und kommt ist $p = \frac{9}{10}$.

$$\mathbb{P}(\{\omega\}) = p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{\sum_{i=1}^n (1-\omega_i)}$$

Bspw. $\{\omega\} = (1, 0, 1, 1, 0)$

Wenn Binomialverteilt, geht man davon aus jeder hat die gleich WS zu kommen und sie sind unabhängig (wir ignorieren bspw., dass Familien meistens zusammen reisen oder absagen).

Erwartungswert berechnet den Durchschnitt einer ZV!

Aufgabe 17.2 (b) Geben Sie ein Verfahren an, wie die Frage, wie viele Tickets unter den oben genannten Bedingungen maximal angeboten werden können, exakt beantwortet werden könnte

Lösung des Tutors: Man definiert eine ZV S_n über die aufsummiert wird:

$$S_n(\underbrace{\omega}_{\omega=\omega_1, \dots, \omega_n}) = \sum_{i=1}^n \omega_i$$

S_n ist die Anzahl der Leute, die kommen.

Wenn wir die WS der Überbuchung auf maximal 0,05 halten wollen, interessiert uns

$$\mathbb{P}(S_n > 526) \leq 0,05$$

■ n = Anzahl verkaufte Tickets (wir wollen n maximieren)

■ S_n = Anzahl der Personen, die kommen

Auf Basis dessen oben:

$$\underbrace{\mathbb{P}(S_n \leq 526)}_{=\sum_{i=1}^{526} \binom{n}{i} p^i (1-p)^{n-i}} \geq 0,95$$

Starte bei $n = 526$ und berechne $\mathbb{P}(S_n \leq 526)$ mit inkrementierendem n und wenn es bei einem n über 0,95 liegt, dann ist das das gesuchte n das $n-1$ ist.

$$\begin{aligned} \mathbb{P}(S_n \leq 526) &= \mathbb{P}(S_n - np \leq 526 - np) \\ &= \mathbb{P}\left(\frac{S_n - np}{\sqrt{npq}} \leq \frac{526 - np}{\sqrt{npq}}\right) \\ &\approx \phi\left(\underbrace{\frac{526 - np}{\sqrt{npq}}}_{\geq 1,65}\right) \end{aligned}$$

$$\frac{526 - np}{\sqrt{npq}} \geq 1,65$$

p und q einsetzen

$$526 - (\sqrt{n})^2 \cdot \frac{9}{10} \geq 1,65\sqrt{n} \cdot \frac{3}{10}$$

und dann landet man durch Rumschieben bei

$$\underbrace{(\sqrt{n})^2}_x + \underbrace{1,65 \cdot \frac{1}{3}}_{c_1} \underbrace{\sqrt{n}}_x - \underbrace{\frac{10}{90,9}}_{c_2} \leq 0$$

TODO noch das letzte von der Tafel

Aufgabe 17.3 (c) Nutzen Sie den Satz von de Moivre-Laplace, um näherungsweise zu bestimmen, wie viele Tickets unter den oben genannten Bedingungen maximal angeboten werden können.

17.2 | PÜ 2.2.5

Eine Süßwarenfirma gibt an, daß 25% ihrer Gummibärchen die beliebte Farbe rot haben. Im folgenden gehen wir davon aus, daß die Angaben des Herstellers richtig sind. Wir nehmen auch an, daß die Gummibärchen unabhängig voneinander rot sind oder eine andere Farbe haben.

Trotzdem waren in einer kleineren Stichprobe lediglich 20% der Gummibärchen rot. Wir wollen der Sache auf den Grund gehen und kaufen daher n weitere Gummibärchen. Sei b_n die Wahrscheinlichkeit, dass höchstens 20% der neu gekauften n Gummibärchen rot sind.

Aufgabe 17.4 (a) Geben Sie für jedes beliebige $n \in \mathbb{N}$ einen geeigneten Wahrscheinlichkeitsraum an, der es erlaubt, die folgenden Aufgabenteile zu bearbeiten

$$\Omega = \left\{ \underbrace{0}_{\text{nicht rot}}, \underbrace{1}_{\text{rot}} \right\}^n$$

wobei n die Anzahl der gekauften Gummibärchen ist.

$$\mathbb{P}(\{\omega\}) = p^{\sum_{i=1}^n \omega_i} \cdot (1-p)^{\sum_{i=1}^n (1-\omega_i)}$$

mit $p=0,25$ = WS für rot und $q = 1-p$

Aufgabe 17.5 (b) Definieren Sie eine Zufallsvariable S_n , die die Anzahl der roten Gummibärchen unter den n gekauften Gummibärchen angibt.

$$S_n = \sum_{i=1}^n \omega_i, \quad S_n \sim \text{Bin}(n, p)$$

Aufgabe 17.6 (c) Sei $n = 20$. Berechnen Sie b_{20} auf drei Nachkommastellen genau, d.h., geben Sie die Wahrscheinlichkeit in der Form 0.xyz bzw. xy.z % an.

$$\frac{S_n}{n} (= \text{mitHtchenzeichen}) \text{ Durchschnittliche Anzahl rot}$$

Es gilt

$$\mathbb{P}\left(\frac{1}{n}S_n \leq \frac{1}{5}\right) = \mathbb{P}\left(S_n \leq \frac{n}{5}\right)$$

Und mit $n = 20$

$$\mathbb{P}\left(S_{20} \leq \frac{20}{5}\right) = \mathbb{P}(S_{20} \leq 4) = \sum_{i=1}^4 \binom{20}{i} p^i \cdot (1-p)^{20-i} = 0,4148\dots$$

Aufgabe 17.7 (d) Beweisen Sie mit Hilfe der Tschebysche!schen Ungleichung, daß $b_{200} < b_{20}$ gilt.

Also $b_n = \mathbb{P}\left(\frac{1}{n}S_n \leq \frac{1}{5}\right)$

Heißt wir müssen $\mathbb{P}(|X - \mathbb{E}[X]| \geq \delta) \leq \frac{\text{Var}(X)}{\delta^2}$ in jene Form umwandeln. Erstmal Erwartungswert von beiden Seiten abziehen(?):

$$\mathbb{P}\left(\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right] \leq \frac{1}{5} - \mathbb{E}\left[\frac{1}{n}S_n\right]\right)$$

Es ist ja

$$\mathbb{E}\left[\frac{1}{n}S_n\right] = \frac{1}{n}\mathbb{E}[S_n] = \frac{1}{n} \cdot np = p \stackrel{\text{Aufgabe}}{=} \frac{1}{4}$$

Also

$$\begin{aligned} \mathbb{P}\left(\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right] \leq \frac{1}{5} - \mathbb{E}\left[\frac{1}{n}S_n\right]\right) &= \mathbb{P}\left(\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right] \leq -\frac{1}{20}\right) \\ &= \mathbb{P}\left(\left|\frac{1}{n}S_n - \mathbb{E}\left[\frac{1}{n}S_n\right]\right| \geq \frac{1}{20}\right) \end{aligned}$$

TODO die Sachen von der Tafel noch zu ende

Aufgabe 17.8 (e) Zeigen Sie mit Hilfe der Tschebysche!schen Ungleichung, dass $\lim_{n \rightarrow \infty} b_n = 0$ gilt

17.3 | PÜ 2.2.6

KAPITEL 18

Tutorium 22.06.2026

18.1 | PÜ 2.3.4

Bei einer Maschine, die Elektronikbauteile produziert, ist im Schnitt jedes 50. Bauteil fehlerhaft. Wir testen eine Lieferung von 300 Bauteilen. Wie groß ist die Wahrscheinlichkeit, dass genau 3 Bauteile fehlerhaft sind?

Denken Sie daran, einen Wahrscheinlichkeitsraum anzugeben und die benötigten Zufallsvariablen zu definieren!

Aufgabe 18.1

$$\Omega = \{0, 1\}^n, \quad n = 300$$

mit

$$\mu(\omega) = p^{\sum_{i=1}^n \omega_i} q^{n - \sum_{i=1}^n \omega_i} \quad \text{mit} \quad p = \frac{1}{50}, q = \frac{49}{50}$$

Teil ist kaputt ist Erfolg, damit wir uns nicht mit Gegenwahrscheinlichkeiten auseinandersetzen müssen.

$$S_n(\omega) = \sum_{i=1}^n \omega_i$$

Aunahme: teile sind Unabhängig voneinander kaputt und immer $p = \frac{1}{50}$

$$\begin{aligned} \mathbb{P}(S_n = x) &= \binom{n}{x} \cdot p^x \cdot q^{n-x} \\ &= \binom{300}{3} \left(\frac{1}{50}\right)^3 \left(\frac{49}{50}\right)^{297} \\ &\approx 0,0883 \end{aligned}$$

Poisson Approximation (p klein q groß)

$$\alpha = np = \frac{300}{50} = 6$$

Sei $X \sim Poi(\alpha)$

$$\begin{aligned} \mathbb{P}(S_n = 3) &\approx \mathbb{P}(X = 3) \\ &= \frac{\alpha^3}{3!} e^{-\alpha} \\ &= \frac{6^3}{3!} e^{-6} \\ &\approx 0,0892 \end{aligned}$$

$$\mathbb{P}(S_n = k) = \binom{n}{k} p^k q^{n-k}$$

$$\begin{aligned}\mathbb{P}(S_n \in A) &= \sum_{k \in A} \mathbb{P}(S_n = k) \\ &= \sum_{k \in A}\end{aligned}$$

TODO ! Noch Rest von Bildern eintragen

18.2 | PÜ 2.3.5

18.3 | PÜ 2.3.6

KAPITEL 19

Tutorium 29.06.2026

19.1 | PÜ 2.4.4

19.2 | PÜ 2.4.5

KAPITEL 20

Tutorium 06.07.2026

20.1 | PÜ 2.5.4

20.2 | PÜ 2.5.5

Teil III

Anhang

20.3 | Übersichten

Verteilung	Parameter	$E[X]$	$\text{Var}(X)$	Anwendung
Bernoulli $\text{Ber}(p)$	$p \in (0, 1)$	p	pq	Einzelnes Ja/Nein-Experiment
Binomial $\text{Bin}(n, p)$	$n \in \mathbb{N}, p \in (0, 1)$	np	npq	Anzahl Erfolge bei n unabh. Bernoulli-Versuchen
Geometrisch $\text{Geo}(p)$	$p \in (0, 1)$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	Wartezeit bis zum ersten Erfolg
Poisson $\text{Poi}(\lambda)$	$\lambda > 0$	λ	λ	Seltene Ereignisse in festem Intervall
Diskret Gleichverteilt $U\{1, \dots, n\}$	$n \in \mathbb{N}$	$\frac{n+1}{2}$	$\frac{n^2-1}{12}$	Würfeln, Zufallszahl aus endlicher Menge

Tabelle 20.1: Diskrete Verteilungen

Verteilung	Parameter	$E[X]$	$\text{Var}(X)$	Anwendung
Stetig Gleichverteilt $U(a, b)$	$a < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	”Keine Information auf Intervall
Normal $N(\mu, \sigma^2)$	$\mu \in \mathbb{R}, \sigma^2 > 0$	μ	σ^2	Grenzverteilung durch ZGWS, Messfehler
Exponential $\text{Exp}(\lambda)$	$\lambda > 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	Wartezeit bis zum nächsten Ereignis, gedächtnislos

Tabelle 20.2: Stetige Verteilungen

Satz	Anwendbar auf	Aussage / Zweck
Satz von de Moivre-Laplace	$\text{Bin}(n, p)$	$\text{Bin}(n, p) \rightarrow N(np, npq)$ für $n \rightarrow \infty$; Approximation der Binomial- durch Normalverteilung
Poisson-Approximation (Gesetz seltener Ereignisse)	$\text{Bin}(n, p)$ mit kleinem p , großem n	$\text{Bin}(n, p) \rightarrow \text{Poi}(\lambda)$ für $n \rightarrow \infty, p \rightarrow 0, np \rightarrow \lambda$
Zentraler Grenzwertsatz (ZGWS)	beliebige unabh. X_i mit endlicher Varianz (i.i.d. oder Lindeberg-Bedingung)	$\frac{S_n - E[S_n]}{\sqrt{\text{Var}(S_n)}} \rightarrow N(0, 1)$ in Verteilung
Schwaches Gesetz der großen Zahlen (WGGZ)	i.i.d. X_i mit endlichem $E[X_i]$	$\frac{S_n}{n} \xrightarrow{P} \mu$ (stochastische Konvergenz)
Starkes Gesetz der großen Zahlen (SGGZ)	i.i.d. X_i mit endlichem $E[X_i]$	$\frac{S_n}{n} \xrightarrow{\text{f.s.}} \mu$ (fast sichere Konvergenz)
Ungleichung von Chebyshev	jede Verteilung mit endlicher Varianz	$\mathbb{P}(X - \mu \geq k\sigma) \leq \frac{1}{k^2}$; grobe Abschätzung, kein Verteilungswissen nötig
Ungleichung von Markov	jede nichtnegative Zufallsvariable	$\mathbb{P}(X \geq a) \leq \frac{E[X]}{a}$; schwächer, aber allgemeiner als Chebyshev

20.4 | Referenzen

Symbole und Begriffe

Gegenstand	Beschreibung	Symbol
Binomialverteilung		$\mathcal{B}_{n,p}$
Dichte		f
Elementarereignis		ω
Ereignisraum		Ω
Erwartungswert	$\mathbb{E}[X]$	$\mathbb{E}$
Potenzmenge		$\mathcal{P}$
Wahrscheinlichkeitsfunktion		μ
Wahrscheinlichkeitsmaß		$\mathbb{P}$
Wahrscheinlichkeitsraum		$(\Omega, \mathbb{P})$

Glossar

Absolute Konvergenz . 59

B-WS Bedingte Wahrscheinlichkeit. 32

Bernoulli-Experiment . 45, 46

Covarianz todo. 71, 79

Ereignis B . 7, 8, 10–12, 14, 15, 17, 23–25, 27–29, 85

Gleichverteilung . 5

paarweise unkorreliert todo. 79

stückweise stetig Eine Funktion $f: [a, b] \rightarrow \mathbb{R}$ heißt *stückweise stetig*, wenn es eine Zerlegung

$$a = x_0 < x_1 < \dots < x_n = b$$

gibt, sodass f auf jedem offenen Teilintervall

$$(x_{i-1}, x_i), \quad i = 1, \dots, n,$$

stetig ist und an den Zerlegungspunkten die einseitigen Grenzwerte

$$\lim_{x \rightarrow x_i^-} f(x) \quad \text{und} \quad \lim_{x \rightarrow x_i^+} f(x)$$

jeweils existieren und endlich sind.. 16, 18, 22

Summe der ersten n Zufallsvariablen todo. 79–81, 84–90, 92, 93

Varianz todo. 68–73, 77–81, 88, 93

Verteilungsfunktion der Standardnormalverteilung $\int_{-\infty}^y \frac{1}{\sqrt{2\pi}} e^{x^2/2} dx$. 81, 82, 84–89

WS Wahrscheinlichkeiten. 7, 8, 12, 15, 33

ZV Zufallsvariable. iv, 39–41, 46–51, 55, 57, 59, 62

Index

Bernoulli-Experiment, 43, 45, 46

Binomialverteilung, 46, 58, 79–81, 84, 89–92

Dichte, 15–22, 27, 33, 41, 51, 59–62

Dichte der Standardnormalverteilung, 82

Faltung, 55

Produktform, 49, 50, 52

Standardnormalverteilung, 82

Stetigkeitskorrektur, 85

Verteilungsfunktion der Standardnormalverteilung, 82